

农作物产量预测技术的研究与应用

潘 赟 李 源

(信阳农林学院信息工程学院, 河南 信阳 464000)

摘 要: 农作物产量合理预测对保障粮食安全和进行粮食生产决议具有重要意义。本文以产量预测算法为主线, 总结了基于传统算法和基于深度学习算法进行产量预测的原理和流程。其中多变量时间预测模型将成为研究的主流, 多尺度遥感信息和深度学习技术融合将对未来农作物产量的预测产生重要影响。

关键词: 农作物; 产量预测; 多尺度遥感信息; 深度学习

中图分类号: S126 **文献标识码:** A **文章编号:** 1003-9767 (2024) 10-168-04

Research and Application of Crop Yield Forecasting Techniques

PAN Yun, LI Yuan

(Faculty of Information Engineering, Xinyang Agriculture and Forestry University, Xinyang Henan 464000, China)

Abstract: The reasonable prediction of crop yield is of great significance for ensuring food security and making food production decisions. This paper takes yield prediction algorithm as the main line, summarizes the principle of yield prediction based on traditional algorithm and deep learning algorithm. The multi-variable time prediction model will become the mainstream of research, and the fusion of multi-scale remote sensing information and deep learning technology will have an important impact on future crop yield prediction.

Keywords: crops; yield prediction; multi-scale remote sensing information; deep learning

0 引言

粮食安全问题是一个国家长治久安, 社会稳定的重要基础。其中农作物产量的合理预测可以为农作物增产和生产决议提供重要科学指导, 具有极大的现实意义。

传统的农作物产量预测工作专注于抽样统计模型预测, 常用的分析方法有自回归差分移动平均模型 (Autoregressive Integrated Moving Average Model, ARIMA)、灰色预测模型 (Gray Forecast Model, GM) 等。以上方法大多从单变量时序数据出发, 利用历史数据趋势完成对未来变化情况的预测。但是受到单变量因素的限制, 基于此类产生模型的精度较低, 无法满足实际生产的需要。

机器学习是一种能自动从训练数据中学习自变量和

因变量间映射关系的技术。为打破单变量的精度约束, 并探究更深层次变量间的影响, 后续研究者引入多个变量特征, 利用多元线性回归, 随机森林, 神经网络等机器学习模型, 提高了对农作物产量的预测性能。

近年来, 随着物联网、大数据、云计算和人工智能等新兴技术的迅猛发展, 相关研究范式产生了迁移, 传统的抽样统计模型和机器学习模型已经难以满足精准农业的现实需要。目前, 能深度捕获数据特征的, 基于深度学习的方法已经成为研究的主流, 并在农业图像识别和文本处理领域发挥了重要的决策辅助作用。

1 传统的农作物产量预测算法

依据影响标签变化的因素的多少, 时间预测任务可

收稿日期: 2024-04-29

基金项目: 河南省科技公关项目《基于 Graph 分级多模态融合网络的信阳毛尖产量预测研究》(项目编号: 242102210059)。

作者简介: 潘赟 (1982—), 女, 河南信阳人, 硕士研究生, 副教授。研究方向: 网络安全、人工智能。

分为单变量时间序列预测任务和多变量时间序列预测任务。

1.1 典型的单变量时间序列预测任务

1.1.1 ARIMA 模型

ARIMA 是一种利用过去一段时间的历史信息进行未来预测的单变量时间序列模型。ARIMA 认为过去一段时间的变化趋势和偶然事件的突变情况都会对未来时间点的值产生影响。ARIMA 模型主要应用于平稳时间序列数据的预测,通过捕捉数据间的自回归关系、差分关系和滑动平均关系来进行预测。对平稳序列进行时间预测的公式如下:

$$X_t = c + \varepsilon_t + \sum_{i=1}^p \varphi_i X_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} \quad (1)$$

其中, X_t 是第 t 个时间的值, c 是常数项, ε_t 是在第 t 个时刻的误差项, φ_i 是过去的第 $t-i$ 个时间序列的值对当前的第 t 个要预测的值的直接影响, ε_{t-j} 是过去的第 $t-j$ 个时间序列的值对当前的第 t 个要预测的值的误差影响。

而在农作物产量预测中, ARIMA 模型的主要使用流程如下: (1) 数据预处理: 对历史农作物产量数据进行数据清洗, 并剔除异常值; (2) 确定模型超参数: 对预处理后的数据进行平稳性检验, 并确定模型的差分参数; (3) 模型训练: 利用训练数据, 通过最大似然估计等方法得出 ARIMA 模型的其他参数; (4) 模型验证: 使用验证集进行验证; (5) 产量预测: 输入最新的数据进行农作物产量预测。

但差分操作的使用, 会导致 ARIMA 丢失部分数据信息。除此之外, 在数据较少, 序列排布无明显规律时, ARIMA 模型的性能也不尽如人意。

1.1.2 灰色预测模型

灰色预测模型^[1]是一种基于部分已知信息, 求解系统运动规律的数学方法, 比较适合信息匮乏的系统, 如短期预测任务, 其基本思想是通过对已知序列进行累加序列生成, 并根据生成的序列构建灰色微分方程, 最后再然后利用这个模型进行预测, 常见的模型有 GM(1,1), 其公式如下:

$$x_i^1 = \left\{ \sum_{j=1}^i x_j^0 \mid i=1,2,\dots \right\} \quad (2)$$

$$\frac{\Delta x^1}{\Delta t} + ax^1 = \mu \quad (3)$$

其中, x_i^1 是一阶累加序列, a, μ 均表示微分方程的参数, 可通过最小二乘法获取其值。使用 GM(1,1) 模型进行预测的主要流程如下: (1) 数据预处理: 对历史农作物产量数据进行数据清洗; (2) 灰色序列生成: 根据灰色系统理论, 对预处理后的数据进行灰色序列生成, 如累加;

(3) 灰色模型构建: 根据生成的灰色序列, 构建一个简化的微分方程; (4) 模型训练: 通过最小二乘法, 解出该模型的参数; (5) 模型验证: 使用验证集进行验证, 评估模型的预测效果; (6) 预测: 输入最新的数据进行预测。

1.2 典型的多变量时间序列预测任务

1.2.1 多元线性回归

多元线性回归 (Multivariate Linear Regression, MLR)^[2] 是一种用于研究多个自变量与一个因变量之间线性关系的机器学习模型。与之前的单变量模型不同, 时间变量只是影响未来产量的因素之一, MLR 模型会在多种因素的综合作用下进行线性预测分析, 其公式如下:

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_{p-1} X_{p-1} + \varepsilon \quad (4)$$

其中, β_i 表示第 i 项的偏回归系数, X_i 表示第 i 个预测相关变量, ε 表示偏置项。使用 MLR 模型进行预测的流程如下: (1) 数据预处理: 对历史农作物产量数据进行数据清洗, 使其满足 MLR 模型的输入要求; (2) 模型构建: 根据输入的数据个数确定 MLR 模型的参数个数; (3) 参数估计: 采用最小二乘法估计模型参数值; (4) 模型验证: 使用验证集进行模型验证; (5) 产量预测: 输入最新数据进行农作物产量预测。

1.2.2 BP 神经网络

为了提高模型的非线性拟合能力, 以 Rumelhart 为首的科学家小组提出了反向传播神经网络 (Back Propagation Neural Network, BPNN) 模型^[3]。每层的计算公式如下:

$$y = f(WX + b) \quad (5)$$

其中, f 代表激活函数, W 代表每层间的连接权重矩阵, b 表示每层的偏移量。它通过反向传播算法来训练网络参数, 具有较强的拟合能力。在农作物产量预测中, BPNN 可以应用于以下步骤: (1) 数据预处理: 对收集到的数据进行清洗、标准化等预处理工作; (2) 模型构建: 设定 BPNN 的输入节点数、隐藏层节点数、输出节点数等超参数; (3) 前向传播: 将预处理后的数据输入到网络中, 并进行前向传播; (4) 计算误差: 将网络输出结果与实际值进行比较, 得出计算误差; (5) 反向传播: 根据误差, 采用链式法则更新网络的权重和偏置参数; (6) 迭代训练: 重复步骤 3~5, 直到网络的误差达到预设的阈值, 或者达到预设的迭代次数; (7) 产量预测: 输入最新的数据进行农作物产量预测。

1.2.3 基于卫星遥感的模型

近年来, 利用环境和气象卫星进行大面积作物的生态环境和产量预测的技术得到飞速的发展。相比于之前的产量预测方法, 基于卫星遥感的方法可以更加高效准确的对较大区域农作物的产量进行预测。熊雄^[4]通过对水稻产区高分辨率遥感图像进行分割, 以提取稻穗特征,

并利用回归模型实现了对水稻产量的预测。Sami Khanal^[5]则结合多光谱影像数据,将遥感数据与机器学习算法相结合,构建了玉米产量预测模型。

虽然卫星影像能够绘出作物的发展趋势,但是其结果会受到作物类型、密度、地理位置(地形、土壤、水分、土地利用等)及气候条件(特别是云雾遮盖)等诸多因素的影响。比如,我国新疆棉花种植采用宽、窄行交错的密植方式增产,这就导致在这种分枝重叠的田间难以利用遥感技术和机器学习准确估算棉花产量^[6]。这些传统的多变量时间序列预测算法难以捕捉特征间的深层关系,存在效率低、精度差和泛化能力不足的问题。现在随着人工智能技术的迅速发展,能捕获更深层次特征的基于深度学习技术的农作物产量预测算法已引起了相关研究者的注意。

2 基于深度学习的农作物产量预测算法

目前主流的基于深度学习的算法主要分为三种:第一种是基于循环神经网络(Recurrent Neural Networks, RNN)^[7]的时间序列预测算法;第二种是基于时间卷积网络(Temporal Convolutional Network, TCN)^[8]的时间序列预测算法;最后一种是基于Transformer^[9]的时间序列预测算法。

2.1 典型深度学习算法

2.1.1 LSTM

长短期记忆(Long Short-Term Memory, LSTM)网络是一种特殊的RNN,它通过引入门机制来解决传统RNN在处理长序列时遇到的遗忘问题。LSTM的基本结构包括以下三个部分:(1)输入门:通过sigmoid激活函数控制输入的权重;(2)遗忘门:同样通过sigmoid激活函数控制遗忘的权重;(3)输出门:通过tanh激活函数控制输出的权重,相关公式如下:

$$i_t = \sigma(W_i X_t + U_i h_{t-1} + b_i) \quad (6)$$

$$f_t = \sigma(W_f X_t + U_f h_{t-1} + b_f) \quad (7)$$

$$o_t = \sigma(W_o X_t + U_o h_{t-1} + b_o) \quad (8)$$

$$\tilde{c}_t = \tanh(W_c X_t + U_c h_{t-1} + b_c) \quad (9)$$

$$c_t = f_t \times c_{t-1} + i_t \times \tilde{c}_t \quad (10)$$

$$h_t = o_t \times \tanh(c_t) \quad (11)$$

其中, i_t , f_t , o_t 分别表示输入、遗忘以及输出的门的权重。 W_i 、 W_f 、 W_o 、 W_c 分别表示与输入序列中的元素的词向量 X_t 相对应三个门以及候选值的计算系数。 U_i 、 U_f 、 U_o 、 U_c 分别表示与上一个输入序列中的隐藏单元 h_{t-1} 相对应三个门以及候选值的计算系数。 b 则对应各个门以及候选值的权重偏置。

2.1.2 TCN

TCN 是一种基于卷积神经网络(Convolutional Neural

Network, CNN)的时间序列预测模型。与基于RNN的模型不同,TCN结合了因果卷积的时序特性和膨胀卷积的并行优势,具有更好的并行计算能力和处理长序列的能力^[10]。TCN的核心模块是带有空洞卷积的残差连接块。该残差块中包含了两层空洞卷积和非线性映射激活函数,并使用WeightNorm和Dropout模块提高模型的泛化能力。在每层中,计算时间序列值的公式如下:

$$T_i = \text{Relu}(f_{l1}(\text{Relu}(f_{l2}(x_i, k_{l1}, d_{l2})), k_{l2}, d_{l2})) + x_i \quad (12)$$

其中, $f_l(\cdot)$ 代表对第 l 层进行因果卷积, $l \in Z^+$, k_l 是卷积核的尺寸, d_l 对应其采用的膨胀率。 $\text{Relu}(\cdot)$ 表示激活函数。 T_i 就代表第 i 个位置的时序编码值。

2.1.3 Transformer

与传统的RNN和CNN模型不同,Transformer模型采用自注意力机制来处理序列数据,具有更好的并行计算能力和处理长序列的能力。Transformer的核心在于多头自注意力机制,其每个自注意力机制部分的公式如下:

$$A(Q, K, V) = \text{soft max} \left(\frac{QK^T}{d} \right) V \quad (13)$$

其中, Q 代表查询矩阵, K 代表键矩阵, V 代表值矩阵。Transformer在编码器和解码器部分均使用到了多头自注意力机制,这两部分的区别在于:编码器是将多头自注意力机制和前馈神经网络结合,适用于处理输入序列;而解码器则在此基础上引入了带掩码的多头自注意力机制,更适合于生成输出序列。

2.1.4 其他方法

除了以上这些典型的深度学习算法之外,一些基于经典算法的改进算法也能取得不错的效果。李静雪^[11]结合LSTM和CNN提出了能整合输入信息间逻辑的LSTM-CNN混合模型。Liu等^[12]则结合了自编码器和RNN的特点,提出了能捕捉序列中的短期和长期依赖关系的SCINet模型,能够处理非平稳和非线性的时间序列数据。Zhou^[13]等在Transformer的基础上,提出概率掩码注意力(Probabilistic Masked Self-Attention, PMSA)机制,在保留了模型精度的同时,又大幅提高了Transformer类模型在处理长序列时的计算效率。

2.2 深度学习算法在农业产量预测问题上的应用

现在,将卫星遥感信息和植物形态数据进行融合的深度学习方法已经成为预测农作物产量的新型范式,其操作流程如图1所示。

深度学习方法的主要实施流程有以下几个步骤。

(1) 高效干净的数据是构建可靠模型的基础。在收集数据时,可在田间区域部署无人机平台,再结合卫星

遥感数据,定时、定点获得植物外在数据,此后,再利用数据清洗工具对图像进行对齐裁剪和数据标注。




图1 实施流程图

(2) 多尺度模型提取数据特征。在网络训练和预测环节中,可以使用多种特征提取器,如 VIT 和 YOLO 等,对多尺度的多变量农业数据进行深度特征提取和融合,然后再利用融合的特征进行产量预测。

(3) 验证与平台部署。在完成了对模型的训练和调优后,可以将调优后的模型部署到农业大数据云平台上。农业从业者可以通过云平台实时访问该模型,从而获得对农业生产的精准预测结果。此外,还可以将该模型部署到边缘设备,如无人机、智能手机等,以实现农田的实时监测和预测。

2.3 深度学习算法在农业产量预测问题上面临的挑战

尽管基于深度学习算法在农业产量预测中取得了显著成果,但仍面临一些挑战。

(1) 数据获取和标注难度大:深度学习算法需要使用大量有标签数据进行有监督学习,而在农业领域,获取高质量的标注数据较为困难。此外,农田环境复杂多变,这对数据采集设备的稳定性、准确性提出更高的要求。

(2) 模型解释性:深度学习模型往往被视为“黑箱”模型,其预测结果的解释性不强,远不如传统的机器学习和概率统计模型。在农业领域,提高模型的解释性有助于农业从业者更好地理解信任模型的预测结果。

(3) 抗干扰能力:农田环境中的噪声、异常值等因素可能会影响基于深度学习的模型的性能。如何提高模型的抗干扰能力,使其在复杂环境中仍能保持较高的预测准确性,也是当前研究者需要关注的问题。

3 结语

本文按照发展的时间顺序,总结了进行农业产量预测的典型算法,并得出以下结论:首先,包括时间变量在内的多变量时间预测模型已经成为研究的主流;其次,由于传统的农作物产量预测算法在处理现实复杂场景下效果不佳,因此,将多尺度遥感信息和深度学习技术进行融合的方法成了现在研究的重点。

未来对农作物产量的研究可以从以下方面展开:一

方面,充分利用遥感信息等数据,结合深度学习技术实现对农作物产量的精准预测;另一方面,通过对农作物产量的精确估计,实现资源的合理规划,为农业生产保驾护航。

参考文献

- [1] 耿德祥,孙惠合,汪顺勤.灰色线性回归在冬小麦产量长期预测中的应用[J].安徽农业科学,2009,37(24):11337-11338+11344.
- [2] 冯琳,庞玉亭,钟琪,等.1980-2016年气候变化对湖南省农业产量的影响[J].资源科学,2019,41(03):582-590.
- [3] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors[J]. Nature,1986,323:533-536.
- [4] 熊雄.基于深度学习的大田水稻稻穗分割及无损产量预估研究[D].武汉:华中科技大学,2018.
- [5] SAMI K,JOHN F,ANDREW K, et al.Integration of High Resolution Remotely Sensed Data and Machine Learning Techniques for Spatial Prediction of Soil Properties and Corn Yield[J].Computers and Electronics in Agriculture,2018,153:213-225.
- [6] LI F,BAI J,ZHANG M, et al.Yield estimation of high-density cotton fields using low-altitude UAV imaging and deep learning[J].Plant Methods,2022,18(1):1-11.
- [7] 赫晓慧,罗浩田,乔梦佳,等.基于CNN-RNN网络的中国冬小麦估产[J].农业工程学报,2021,37(17):124-132.
- [8] 张凯,龚龙庆,贺兆,等.基于3DCNN-TCN的农作物产量预测[J].微电子学与计算机,2023,40(10):83-89.
- [9] 王鹏新,杜江莉,张悦,等.基于遥感多参数和CNN-Transformer的冬小麦单产估测[J].农业机械学报,2024,55(03):173-182.
- [10] 李源,蔡忠祥.基于注意力机制的知识增强短文本分类[J].电子技术与软件工程,2022(19):220-225.
- [11] 李静雪.基于深度学习的农作物产量预测[D].北京:华北电力大学,2020.
- [12] LIU M, ZENG A, LAI Q, et al.Time Series is a Special Sequence: Forecasting with Sample Convolution and Interaction[J].arXiv:2021,2106.09305.
- [13] ZHOU H,ZHANG S,PENG J, et al. Informer:Beyond Efficient Transformer for Long Sequence Time-Series Forecasting[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021,35(12):11106-11115.