

中图分类号: TP399

论文编号: 10357Y20301029

安徽大学

硕士学位论文

基于 CNN-BiLSTM 融合注意力 机制的玉米产量预测方法研究

作者姓名	吴坤明
专业学位类别	电子信息硕士
专业学位领域	电子信息
指导教师	贾兆红、王海涛
企业导师	张辰辰

Research on corn yield prediction method based on CNN-BiLSTM fusion attention mechanism

A Dissertation Submitted for the Degree of Master

Candidate: Wu Kunming

Supervisor: JIA Zhaohong, WANG Haitao

Corporate Supervisor: ZHANG Chenchen

中图分类号：TP399

论文编号：10357Y20301029

硕 士 学 位 论 文

基于 CNN-BiLSTM 融合注意力机制的玉米产量预测方法研究

作者姓名	吴坤明	申请学位级别	电子信息硕士
指导教师姓名	贾兆红、王海涛	职 称	教授、教授
企业导师	张辰辰		
专业名称	人工智能	研究方向	智慧农业
学习时间自	2020 年 9 月 1 日	起至	2023 年 7 月 1 日止
论文提交日期	2023 年 3 月 31 日	论文答辩日期	2023 年 5 月 21 日

摘要

粮食安全是国家安全的重要基础之一，关系到经济发展和社会稳定。准确的产量预测可以为作物规划和种植提供科学指导。目前，已有研究开展了基于深度学习方法的玉米产量预测，但研究尚未考虑到长时间序列造成的数据间相关性下降的问题，也没有对特征权重分配进行深入分析，预测精度还有待提高。针对当前玉米产量预测领域存在的问题，本文开展了以下两个方面工作：

（1）玉米产量预测模型构建及实验分析

本文提出了一种基于 CNN-BiLSTM 融合注意力机制模型，模型由卷积神经网络模块、双向长短期记忆网络模块和注意力模块组成。模型以研究区域的最高温度、最低温度和降雨量数据作为原始数据，并将其转换为可反映玉米生长过程的累积气候参数 GDD、KDD 和 PRCP 作为预测玉米产量的输入。接着，基于构建的 CNN-BiLSTM-Attention 产量预测模型，完成了美国雨养玉米带的玉米产量预测实验与分析工作。实验基于研究区域的玉米生长特性合理划分了数据，并通过消融实验验证了模型各模块的有效性与必要性，最终完成了产量预测工作。结果表明，本文所提模型得到的作物产量预测结果优于 EWA、DeepCropNet 和 CNN-RNN 三种对比算法得到的结果。实验通过对单个州分别进行产量预测实验，提高了模型预测精度，并分析了不同气候因素会对模型预测性能产生的影响。同时，实验对玉米产量与生长影响因素分析进行了实验分析，确定了玉米生长过程中最重要的生长时期与气象因素，实验结果可为实际玉米种植的智能决策提供科学依据。

（2）设计并实现了玉米产量预测分析原型系统

本文通过对玉米产量预测系统进行需求分析，并按照软件工程化要求，设计并实现了一套用于玉米产量预测分析的原型系统，系统主要分为四个模块：系统管理模块、个人中心模块、产量预测模块和可视化图表模块。该系统实现了前后端分离，前端基于 html 前端开发，采用目前主流框架 Vue 进行开发；数据库通过关系型数据库 MySQL 构建；后端采用 Java 开发语言，并搭载 SpringBoot 框架，通过 Runtime 工具实现了玉米产量预测深度学习模型的调用，最终实现产量预测及分析相关可视化功能。

关键字：深度学习；数据挖掘；玉米产量预测；双向长短期记忆网络

Abstract

Food security is one of the key foundations of national security and it is linked to economic development and social stability. Accurate yield prediction can provide scientific guidance for crop planning and planting. There have been studies carried out on corn yield prediction based on deep learning methods. However, these studies have not yet taken into account the long time series problems, which can result in reduced correlation between data. In addition, these studies have also not discussed the knowledge point of feature weight assignment in depth, and the prediction accuracy of these studies still needs to be improved. In view of the current problems in the field of corn yield prediction, this thesis carried out the following two aspects of work:

(1) The construction of yield prediction model and the experiment and analysis of yield prediction were completed

This thesis proposes a CNN-BiLSTM fusion attention mechanism based model, which consists of a convolutional neural network module, a bi-directional long and short-term memory network module and an attention module. The model take the public data set of corn belt growth data of nine states in the United States as the research object, and uses the maximum temperature, minimum temperature and rainfall data involved in the data set as the original data. In this thesis, the raw data are converted into cumulative climate parameters GDD, KDD and PRCP, which are used as inputs for predicting corn yields. These three climatic cumulative parameters can reflect the corn growth process well. We have completed experimental and analytical work on corn yield prediction in the rainfed corn belt of the USA by using the constructed CNN-BiLSTM-Attention corn yield prediction model. In this thesis, the data were rationally divided according to the growth characteristics of corn in the study area. Ablation experiments were then conducted and this experiment verified the validity and necessity of the modules in the model. Finally, accurate corn yield prediction experiments were completed. The experimental results showed that the model constructed in this thesis obtained good crop yield prediction results, and the prediction results were better than the three comparison algorithms of EWA, DeepCropNet

and CNN-RNN. The experiment improved the prediction accuracy of the model through the yield prediction experiment of a single state, and proved that different climate factors would affect the prediction performance of the model. In addition, the experiment completed the analysis of the influencing factors in the process of corn growth. The experiment determines the most important growth period and meteorological factors in the process of corn growth through the combination of different growth periods and different characteristic parameters of corn. The conclusions of the experiments can provide a basis for intelligent decision making in practical corn growing.

(2) A prototype corn yield prediction and analysis system is designed and implemented

Based on the requirement analysis of the corn yield forecasting system, and according to the requirements of software engineering, a prototype system for corn yield forecasting analysis is designed and implemented. The core functions of the system are corn yield forecasting and visual analysis. The system is mainly divided into four modules: the system home module, personal centre module, yield prediction module and visualisation chart module. The system achieves a separation of front and back ends. The front-end is based on html and css technology and uses the current mainstream framework Vue, with a relational database Mysql. The back-end application is developed in Java and is equipped with the SpringBoot framework. The system is implemented through a Runtime tool for calling deep learning models for corn yield prediction. The final system implements yield forecasting and related visualisation functions.

Keywords: Deep learning; Data mining; Corn yield prediction; Bidirectional long short-term memory network

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究进展.....	2
1.3 主要研究内容.....	6
1.4 论文结构安排.....	7
第二章 相关方法与技术	8
2.1 传统产量预测方法.....	8
2.2 机器学习预测方法.....	10
第三章 基于 CNN-BiLSTM-Attention 的产量预测模型	16
3.1 数据准备与评价指标.....	16
3.1.1 特征参数选择.....	16
3.1.2 数据预处理.....	17
3.1.3 评价指标.....	18
3.2 模型构建.....	20
3.3 本章小结.....	26
第四章 玉米产量预测实验与分析	27
4.1 实验环境.....	27
4.2 研究区域与数据.....	27
4.3 实验结果与分析.....	29
4.3.1 消融实验.....	29
4.3.2 对比试验.....	30
4.3.3 地域差异预测分析.....	33
4.4 影响因素分析.....	35
4.4.1 雨养玉米带玉米产量波动趋势.....	35
4.4.2 不同生长期对玉米产量的影响分析.....	38
4.4.3 不同环境因素对玉米产量的影响分析	41
4.5 本章小结.....	42
第五章 玉米产量预测分析原型系统的设计与实现	43
5.1 需求分析.....	43
5.2 系统设计.....	44
5.2.1 系统架构设计.....	44
5.2.2 系统模块组成.....	45
5.2.3 数据库表设计.....	46
5.3 系统实现.....	50

5.4 系统测试.....	57
5.5 本章小结.....	61
总结与展望.....	62
参考文献.....	64

第一章 绪论

1.1 研究背景与意义

粮食安全是国家安全的重要基础之一，关系到经济发展和社会稳定。农作物产量预测对全球粮食安全具有重要意义，准确的产量预测可以为作物规划和种植提供科学指导^[1]。从全球粮食安全的角度来看，准确预测农作物产量可以帮助农民更好地管理农田，提高农作物的产量，从而改善全球粮食安全^[2]。从农民实际种植的角度来看，准确预测农作物产量可以帮助农民做出智能决策^[3]。

玉米是禾本科玉米属的一年生草本植物，是全球粮食产量第一的农作物，为全球粮食供应提供了重要支撑。它不仅是主要的粮食作物，而且还是重要的饲料作物。玉米的产量对全球粮食安全和饲料供应有重要影响，因此，准确预测玉米产量对于全球粮食安全和饲料供应等问题至关重要^[4,5]。

近几年，深度学习^[6]技术发展迅速，在基于数据挖掘、时间序列处理的预测问题等方面取得了巨大的进步。在数据挖掘方面，深度学习技术可以有效地提取数据中的模式和特征，从而提高数据挖掘的准确性和效率。此外，深度学习技术还可以有效地处理非结构化数据，从而提高数据挖掘的精确度。在时间序列处理方面，深度学习技术可以有效地处理复杂的时间序列数据，分析时序数据的前后关联性，计算数据与数据之间的关联程度，获取数据结构信息，能够有效抑制长时间序列数据在训练过程中的语义稀释问题，最终实现玉米精准产量预测^[7]。

基于深度学习技术的玉米产量预测是一个重要的研究课题^[8]，由于国内暂无公开的玉米产量数据集，本文选取以国外公开的经典数据集——美国雨养玉米带八个州数据为研究对象，重点研究美国雨养玉米带八个州的产量与环境因素之间的关系，旨在探索如何利用深度学习技术有效地预测美国雨养玉米带玉米的产量。玉米是一种重要的农作物，它的产量对经济有重要的影响^[9]。然而，由于气候变化和其他因素，带玉米的产量受到了很大的影响，有效地预测玉米的产量对于维护经济的稳定和可持续发展至关重要。

温度和水分对玉米生长至关重要，因为它们是玉米生长的关键因素。温度影响玉米的生长速度，而水分则是玉米生长的必要条件。正常情况下，玉米需要温度在 20—30

摄氏度之间，而水分则需要 50%—60% 之间。如果温度过高或水分过低，玉米的生长将受到影响，从而影响玉米的产量。此外，温度和水分还会影响玉米的发芽率、发芽速度、根系发育、叶片发育等，从而影响玉米的产量。因此，本文主要考虑基于温度与降水量的农作物产量预测研究。综上所述，基于玉米生长的气象因素与深度学习技术的玉米产量预测是一个重要的研究课题。

由于当前中国相关数据获取难度较大，本文所选取的研究区域为美国八个州的雨养玉米带玉米种植区，此区域存在开源数据集，并已有相近主题的研究成果可供学习。本文主要探索如何利用深度学习技术有效地预测美国雨养玉米带玉米的产量，主要研究内容是利用深度学习技术来构建玉米产量预测模型，以有效地预测美国雨养玉米带玉米的产量，分析玉米产量与生长影响因素之间的潜在关系，确定玉米生长过程中最重要的生长时期与气象因素，并完成玉米产量预测分析原型系统的设计与实现。根据研究区域的长时间序列环境数据，本文旨在挖掘环境数据与玉米产量间的内在关系，分析不同特征数据以及不同生长期对产量的影响程度，实现精准的玉米产量预测工作。

1.2 国内外研究进展

近几年来，随着智慧农业领域的迅速发展，国内外对农作物产量预测的研究受到了广泛关注。农作物产量预测的方法主要有基于统计学模型^[10]、基于作物模型^[11]、基于机器学习模型^{[12][13]}和基于深度学习模型^{[14][15]}等。研究人员在这一领域的主要研究方向有两个：一是分析不同环境因素对作物生长的影响程度；二是不断探索和优化不同的产量预测模型，以提升预测精度。

2023 年，Ren 等人^[16]利用基于过程的模型（WOFOST）和经验统计模型（RF 或 GRU）的优点，建立了不同组合下的玉米产量预测模型，动态预测不同生育阶段的玉米产量，并分析了不同生育期和特征的产量预测潜力。研究使用世界粮食研究（WOFOST）模型，通过输入气象、土壤、作物和管理数据来构建综合模拟数据集，并设计了不同生长阶段的不同特征组合，最终使用机器学习和深度学习混合方法预测了玉米产量。实验结果表明：玉米营养生长期和生殖生长期的主要特征分别为生长状态特征和水分相关特征；随着作物生长阶段的不断推进，预测产量的能力不断提高。特别是进入生殖生长期后，玉米粒开始形成，产量预测性能明显提高。该方法提高了

产量预测的准确性，为预测各生育期的产量提供了可靠的分析结果，有助于农民和政府的农业决策。该模型具有较好的鲁棒性，能够应用于其他作物的产量预测，对指导农业生产具有重要价值。

2019 年，Avinash 等人^[19]在稻谷收割期间进行了一项调查，以收集来自希布根杰地区南部八个村庄的 80 个农民的 APY 数据。利用这些数据，开发了统计回归模型。在图中，绘制了农作物种植面积与农作物产量的关系图。通过添加线性趋势线，已经得出了基于生产的统计回归模型。进一步使用斜率和系数来预测 2017 年的单产。通过与农民互动，在稻谷收获期间收集了数据。从 1997—2016 年的 DES 中合并了地区级区域和生产数据。从 DES 数据库获得 1997—2016 年农作物 APY 历史地区水平的数据。这些数据用于建立线性回归模型，以预测 2017 年的农作物产量。根据从光学（Sentinel-2B）和 SAR（Sentinel-1A）数据获得的基于卫星的稻谷种植面积图，最终通过简单的回归方法，已经对 Sahibganj 地区的农作物产量进行了预测。

2009 年，程伟^[20]等人提出了一种基于商空间粒度理论^[21]框架的农作物产量预测模型，该模型将温度、降水量、日照等环境因素作为输入，通过 SVM 算法构建了产量预测模型。该研究旨在挖掘粮食产量与研究区域气象数据之间存在的潜在时间序列联系。最终取得了 37.3 的 RMSE 与 0.8849 的 MAPE，相较于对比算法，精度达到最高。实验结果表明，混合粒度预测模型取得了较低的实验误差，因为他降低了产量预测问题的求解复杂性。该产量预测实验考虑了研究对象从播种到收获整个周期的环境数据，例如光、水分等气象数据。研究通过实验证明，作物的生长区域、种植时期和生长周期都会对产量预测的精度产生影响。通过影响因素分析工作，作者将作物的生长关键时期归结为 1、5 和 6 月，并重点关注这几个月的生长数据，极大地降低了该产量预测实验的复杂度，并同样能取得较高的预测精度。这一研究为后续产量预测领域的研究提供了开拓性的研究方向。

2015 年，Akhand^[22]等人利用人工神经网络建立了预测孟加拉国农作物产量的模型。采用基于极高分辨率辐射计（AVHRR）的遥感卫星数据植被健康指数（植被状况指数 VCI 和温度条件指数 TCI）作为输入变量，美国农作物产量的官方统计作为天线预测模型的目标变量，实际数据为孟加拉国的农作物产量数据。该模型用于预测孟加拉国的农作物产。以 1993—2011 年 19 年第 25—28 周植被健康指数（VCI&TCI）的遥感

卫星数据作为输入变量。输入数据和目标数据的长度必须相同预测数据是网络的输出数据，这些数据也被称为模拟模型的最终结果。经过网络训练后，计算网络输出。实验通过 ANN^[23]方法完成预测并得到的结果，预测误差小于 10%。因此，预测可以在未来任何不确定情况下规划和储存足够的大米方面发挥重要作用。该模型克服了时间序列分析数学中的计算困难。同时，它也充分利用了人工神经网络具有强大的信息处理能力、自我学习能力和较强的环境适应能力等特点。此外，ANN 模型非常灵活，可以提供预测未来需求的最优解决方案。

2019 年，林涛^[24]等人采用长短期记忆模型，综合作物物候、气象和遥感数据对县级玉米产量进行预测。通过将基于物候的遥感和气象指标相结合，LSTM 模型解释了整个玉米带 76%的产量变化，优于仅基于物候气象指标解释 39%的产量变化。LSTM 模型优于最小绝对收缩选择算子（LASSO）回归和随机森林（RF）方法，这是因为它的递归神经网络结构可以包含玉米产量和环境因素之间的累积和非线性关系。结果表明，玉米从吐丝期到蜡熟期是作物估产的关键时期。LSTM 模型在 2012 年极端天气事件下的产量估计具有较强的鲁棒性，其均方根误差从 LASSO 的 1.93Mg/ha 和 RF 的 2.43Mg/ha 降低到 1.47Mg/ha。这种深度学习方法有望基于公开的遥感和气象数据更好地了解全球作物生长状况。2020 年，林涛及其研究团队又研发了一种名为 DeepCropNet（DCN）的深度时空学习框架^[25]，通过时空学习模块的整合，了解作物产量与气象因子的相互作用。对于时间模式，应用将注意力机制纳入 LSTM 模型的时间学习模块来捕获和可视化时间累积效应。针对空间异质性问题，开发空间学习模块，促进 MTL 将不同气象区域的产量估算作为不同的任务，学习共同特征和区域特定特征。研究结果突出了 DCN 在作物产量估算中的潜力，因为它能够捕获时间一般格局和空间特定特征。由于累积效应，DCN 更多地关注生殖阶段而不是营养阶段。实验结果表明，DeepCropNet 能够获取玉米生长期中最关键的时间段。仅时间学习与 DCN 的对比证明，将空间学习模块混合到 DCN 中可以提高不同地区的玉米产量估算。结果表明，在估计气象对玉米产量的影响时考虑空间方差是有利的。该研究表明，DCN 是一种很有前途的作物产量估算方法，并且研究确定了该方法未来改进的方向。

2020 年，Saeed^[26]提出了一种基于深度学习的作物产量预测方法，该方法基于环境数据和管理实践准确预测了美国整个玉米带的玉米和大豆产量。深度学习模型的主要

限制之一是它们的黑盒属性，为了使所提出的模型更少黑盒，更具可解释性，使用反向传播方法基于训练好的 CNN-RNN 模型进行了特征选择。特征选择方法成功地估计了天气成分、土壤条件和管理变量的个体效应以及这些变量变得重要的时间段，是本研究的一项创新。这种方法可以扩展到解决其他研究问题。例如，类似的方法可用于根据杂交种相对于同一地点其他杂交种的相对性能，将其分类为低产或高产。所提出的方法明显优于其他流行的方法，如 LASSO，随机森林和 DFNN。所提出的模型是一个结合了 CNN 和 RNN 的混合模型。该模型的 CNN 部分旨在捕获天气数据的内在时间依赖性和在地下不同深度测量的土壤数据的空间依赖性。该模型的 RNN 部分则旨在捕捉由于植物育种和管理实践的不断改进而导致的作物产量多年来的增长趋势。该模型的性能对许多变量相对敏感，包括天气、土壤和管理。所提出的模型成功地预测了未经测试的环境中的产量，因此，它可以用于未来的产量预测任务。2021 年，Saeed 及其研究团队又提出了两种新的 CNN-DNN 集成类型^[27]，用于预测美国玉米带各州的县级玉米产量。其基本架构是 CNN 和深度神经网络的组合。CNN 负责从土壤和天气数据中提取有用的高级特征，并将其提供给全连接网络，以进行最终产量预测。两种集成类型使用相同的基本 CNN-DNN 结构，但以不同的方式生成基本模型，分别为异质集成和同质集成。同质集成使用一个固定的 CNN-DNN 网络，但将其应用于多个数据集。异构集成使用不同的基本 CNN-DNN 网络，这些网络结构相同但滤波器数量不同。通过 BEM、GEM 和堆叠广义集成三种集成创建方法将这两种集成类型生成的所有基础模型进行组合。数值结果表明，同构和异构类型的集成模型都可以超过之前的 CNN-RNN 模型。

2019 年，刘峻明^[28]采用以国内 25 年的小麦生长过程中的环境数据与小麦产量数据作为实验输入，通过随机森林算法进行了小麦产量预测实验。实验将环境数据中的几十种气象数据和经纬度数据等多种数据划分为多组特征集合，进行多组产量预测实验，并进行了影响因子分析。最终得出结论：以气象产量和相对气象产量建模的产量预测精度高于单产预测，并且小麦生长的空间数据特征对于产量预测能够起到关键作用。气象数据中，平均温度、最高温度和最低温度等温度数据在不同生长期所起到的作用不同，这一结果说明不能简单地将气象数据等特征进行划分作为输入，而应该将数据进行细粒度划分，将影响因素分析考虑得更全面，这样能够获得更好的产量预测

结果。

2020 年, Mohsen^[29]等人提出一种指数加权平均集成方法(EWA)预测美国玉米带三个州的玉米产量,在考虑完整和部分季节天气知识的情况下,使用天气、土壤、植物种群和种植日期数据预测玉米产量。研究对美国玉米带的三个州(伊利诺伊州、印第安纳州和爱荷华州)的玉米产量进行预测。在预测产量的同时,对输入特征重要性进行计算排序,实验结果表明,与传统机器学习模型相比,该方法取得了理想的产量预测结果。EWA 优化加权集成模型和平均集成模型是最精确的模型,RRMSE 达到 9.5%。堆叠 LASSO 的预测偏差最小(MBE 为 53 千克/公顷),而其他集成模型在偏差方面也优于基础模型。作者将提出的模型预测与文献预测进行比较,证明了其提出的集成模型的预测性能是可接受的。在只有部分季节天气知识的情况下,结果显示,最早在 6 月 1 日就可以做出 RRMSE 为 9.2%的理想产量预测结果。此外,在农业区域、州、县尺度上的实验结果表明,所提模型比单个模型和基准集成有更好的表现。

1.3 主要研究内容

根据玉米作物的特性以及研究区域的环境条件与生长数据,本文构建了玉米产量预测深度学习模型,完成了玉米产量预测与生长影响因素分析工作,并设计了玉米产量预测分析原型系统。本文将主要工作如下:

(1) 玉米产量预测模型构建

根据对当前产量预测领域已有相关方法的研究,以及玉米的生长环境与作物特性,本文设计了一种 CNN-BiLSTM 融合注意力机制的玉米产量预测模型,并分析了模型不同模块起到的作用以及参数设置。此外,还验证了选取的 BiLSTM 网络相较于传统 LSTM 网络的优越性。该部分为后续的玉米产量预测分析工作提供了模型基础。

(2) 玉米产量预测实验与分析

以研究区域的温度与降水量为原始数据,并将其转化为能够反映玉米生长过程的气候累积参数作为模型输入,完成了研究区域精准的玉米产量预测实验。通过实验分析,验证了本文所提出的 CNN-BiLSTM-Attention 模型的优越性,此外还对不同州进行了单独的产量预测分析,并分析了不同生长时期与不同气象因素对玉米产量的影响,这一工作能为实际玉米种植的智能决策提供决策依据。

(3) 玉米产量预测与分析原型系统研发

开发了一个玉米产量预测分析原型系统，通过对系统功能需求进行的确认，明确了玉米产量预测分析原型系统的用户类型和主要功能，设计了玉米产量预测分析原型系统整体架构，该系统实现了玉米产量预测、实验数据录入以及实现数据的可视化等功能。

1.4 论文结构安排

全文划分为六章，各章具体内容可以归类为以下几个部分：

第一章，绪论。本章主要介绍了课题的研究背景与意义；描述了近几年来在农作物产量预测的国内外文献综述；阐述了本研究的论文结构和主要研究内容。

第二章，农作物产量和预测相关方法与技术。本章对农作物产量预测的问题定义和本领域主流的研究方法。

第三章，构建了玉米产量预测工作所需的 CNN-BiLSTM 融合注意力机制的深度学习产量预测模型，并分析了各个模块的确定过程，并分析了其相对于之前研究所用到的模型技术的优越性。

第四章，基于 CNN-BiLSTM 融合注意力机制的玉米产量预测及影响因素分析。本章主要介绍了实验的研究区域、产量预测的消融实验与对比实验，并对单个州进行了产量预测分析，此外还就玉米生长特性对影响玉米产量的因素进行了相关性分析。

第五章，设计并实现了玉米产量预测分析原型系统。本部分主要从需求分析、系统设计、系统实现和系统测试四个方面描述了玉米产量预测分析原型系统的研发过程。

第二章 相关方法与技术

作物产量受到多种因素的影响，由于复杂的因素，成功的作物产量预测非常困难。各种环境因素经常相互作用，这使得产量预测更具挑战性，而天气成分等环境因素通常具有复杂的非线性效应，难以准确估计。

农作物产量预测领域的主流研究方法主要可划分为传统产量预测方法、基于机器学习的产量预测和基于深度学习技术的产量预测。传统产量预测方法主要包括作物图像纹理分析、环境数据分析、遥感数据分析等预测方法。随着机器学习等技术的逐渐火爆之后，研究人员逐渐将产量预测的重点，从农作物本身，转向了一些外在影响条件。例如，温度、降雨量和土壤的 PH 值等外在因素对作物的生长起着至关重要的作用。由于此类数据不需要过多的专业知识，只需要研究人员具备对数据进行处理的能力，因此，基于环境数据分析的作物产量预测，成为当下产量预测热门的方向。

近年来，深度学习已成为作物产量预测的潜在工具，它允许模型自动提取特征并从数据集中学习，智能农业技术也使农民能够通过提取作物生长的基本参数来实现最大的作物产量。本研究主要实现了深度学习方法在玉米产量预测领域的研究空白，并且指导我们分析环境因素对作物产量的影响。深度学习技术可以自动提取特征，从而更准确地预测作物产量，而智能农业技术则可以帮助农民更好地管理作物，从而获得更高的产量。因此，深度学习和智能农业技术在作物产量预测中发挥着重要作用，可以帮助全球粮食生产更加有效和可持续。

2.1 传统产量预测方法

农作物产量的精准预测可以加快育种的速度，田间调查法^[30]是一种最为经典的传统产量预测方法，该方法对田间农作物样本收割、脱粒、烘干、称重来对农作物的产量进行估测的产量预测方法，需要大量的人力物力，且容易造成人为误差。基于以上问题，早期研究人员尝试了几种不同方向的传统产量预测方法，包括基于作物图像纹理分析的作物产量预测、基于环境数据分析的作物产量预测和基于遥感数据分析的作物产量预测。

基于分形理论^[31]和纹理分析^[32]的作物单产预测是通过分析作物图像的几何特性和

纹理模式来预测作物单产。分形分析通过分析不同尺度作物图像的自相似性，可以提供作物冠层的复杂程度和结构信息，进而获取图像的分形维数，用来预测作物产量。纹理分析涉及分析作物图像中像素的空间排列，以识别与不同作物产量相关的模式和纹理，该方法可以从图像中提取纹理特征，如对比度、熵和同质性，并用于预测作物产量。作物环境模型主要包括农学预报模型^[33]与气象预报模型^[34]，这两种方法对研究人员的专业知识要求极高，并且实验需要大量的作物农学特征参数和气象资料作为支撑，该方法的实施难度较大。基于遥感数据分析的作物产量预测是一种利用卫星或无人机等遥感技术收集的数据来预测作物产量的技术。收集的数据包括关于作物健康、生长和环境条件的信息。通过分析这些数据，研究人员可以预测未来的作物产量，这可以用于农业规划、粮食安全评估和其他应用。这种方法越来越受欢迎，因为它能够提供关于大面积作物生产的及时和准确的信息，这可以帮助农民和决策者做出明智的决定。

（1）基于作物图像纹理分析的作物产量预测

基于纹理分析、分形理论建立农作物产量精确预测数学模型。以水稻为例，以成熟期水稻图像为主要研究对象，通过对图像进行分析、处理，来预测产量。这一思路，在目前产量预测方法的研究方面是个全新的思路。这种产量预测方法实现了方法简单、实用、投入较少的目的，为今后进一步研究田间产量精确预测系统，奠定理论基础。研究通过主成分分析进行特征提取，提取水稻穗头、田间群体图像的纹理特征这部分参数值，研究其与水稻穗头质量、田间平方米产量的相关关系，确定第一、第二主成分^[35]后，代替原来的特征参数作为新的综合变量。接着用多元线性回归方法建立水稻穗头质量、水稻平方米产量的数学模型，最后用后验差检验法对模型精度进行验证。

（2）基于环境数据分析的作物产量预测

基于环境数据分析的作物产量预测是一种利用温度、降水、土壤湿度、太阳辐射等环境数据预测作物产量的技术^[36, 37]。用于作物产量预测的环境数据可以从各种来源获得，包括气象站、遥感和作物模型。这些数据可用于估计作物可获得的水分和养分的数量，以及关键生长阶段(如开花和成熟)的时间。通过将这些信息与前几个季节的作物产量数据相结合，研究人员可以开发出可以在不同环境情景下预测未来作物产量的模型。基于环境数据分析的作物产量预测可用于各种应用，包括作物管理、粮食安全

全评估和商品交易。它可以帮助农民和决策者就种植、灌溉和肥料使用做出明智的决定，还可以就干旱、洪水或其他环境因素导致的潜在作物歉收提供早期预警。

（3）基于遥感数据分析的作物产量预测

卫星遥感可以通过各种光谱波段直接、及时地监测作物的生长状态^[38]。目前，广泛的研究主要集中在基于可见光和近红外的 VI 观测，以监测作物的进展和产量估计^[39]。然而，最近的一些研究表明，其它可用谱带与产量估计之间有很高的相关性，但很少被研究。例如，陆地表面温度（LST）就可以捕捉农业水和极端温度应力的产量变化。此外，影响作物产量的其他环境因素，如气候变量和土壤性质，含有非生物信息，可能无法通过卫星数据。因此，如何将遥感信息与其他环境因素结合起来进行产量估算需要进一步的研究。

2.2 机器学习预测方法

（1）线性回归

线性回归（Linear Regression）^[40]经常被应用于预测和推理。预测包括使用模型来预测一组给定自变量的因变量的值。推断涉及使用该模型来测试关于系数或变量之间关系的假设。线性回归是一种用于模拟因变量和一个或多个自变量之间关系的统计方法。线性回归的目标是找到变量之间的最佳线性关系，使预测值和实际值的平方误差之和最小^[41]。

在简单的线性回归中，只有一个自变量和一个因变量。线条的方程是 $y = b_0 + b_1x$ ，其中 y 是因变量， x 是自变量， b_0 是截距， b_1 是线条的斜率。斜率衡量 x 增加一个单位时 y 的变化，截距是 x 等于 0 时的 y 值。而多重线性回归是在有一个以上的自变量时使用，方程为 $y = b_0 + b_1x_1 + b_2x_2 + \dots$ 。其中 y 是因变量， $x_1, x_2, \dots, x_n$ 是自变量， $b_0, b_1, b_2, \dots, b_n$ 是自变量的系数。

近年来，线性回归方法在农作物产量预测上表现了出色的性能，因为它可以根据影响作物产量的各种因素的历史数据分析，可靠而准确地预测作物产量。有了准确的作物产量预测，农民和政策制定者可以对作物生产、资源分配和粮食安全做出明智的决定。例如基于天气的作物产量预测：线性回归可以用来预测基于天气数据的作物产

量，如温度、降雨量、湿度和风速，通过分析作物产量和天气数据之间的历史关系，可以建立一个线性回归模型，根据天气数据的值来预测未来的作物产量。

（2）随机森林

随机森林（Random forest, RF）^[42]是一种主要应用于分类、回归等问题的机器学习算法。它基于集合学习的思想，将多个决策树结合起来，以提高模型的准确性和稳健性。随机森林算法的基本原理可以概括为以下几点：

1) 决策树的集合：随机森林通过从训练集中随机选择一个特征子集和一个数据点子集来建立每个决策树，从而创建一个决策树的集合。这一操作被称为自举聚合或袋装化。

2) 分割标准：在决策树的每个节点上，算法根据分割标准（如基尼杂质或熵）选择最佳特征来分割数据。

3) 树的构建：决策树是通过根据所选特征将数据分割成更小的子集而递归建立的，直到所有的数据点都被归入各自的类别。

4) 回归预测：为了对一个新的数据点进行预测，该算法将数据点通过集合中的每一棵决策树，并在预测的类别中取得多数票。

5) 超参数调整：最后一步是调整模型的超参数，如集合中的树数、决策树的最大深度以及为每棵树选择的特征和数据点子集的大小。

由于随机森林算法对过拟合具有鲁棒性，并且可以处理分类和连续数据，它已被广泛应用于各个领域，如金融、医疗保健和自然语言处理。近年来，已有相关研究将随机森林算法应用到农作物产量预测领域，例如基于遥感的作物产量预测：随机森林可用于预测基于遥感数据的作物产量，如植被指数、树冠温度和土壤湿度的卫星图像。通过使用多个决策树分析作物产量和遥感数据之间的历史关系，随机森林可以确定对产量预测结果影响程度最高的几个遥感特征并着重考虑，以此提高预测模型的准确性。总的来说，随机森林算法是一个强大的农作物产量预测算法，因为它可以处理影响农作物产量的各种因素之间的复杂和非线性关系。有了准确的作物产量预测，农民和政策制定者可以对作物生产、资源分配和粮食安全做出明智的决定。

（3）支持向量机

支持向量机（Support Vector Machine, SVM）^[42]是一种用于分类和回归分析的监督

学习算法。SVM 的基本概念是找到一个超平面，将输入数据最好地分成两类。超平面的选择是为了使两类之间的边际最大化，也就是超平面与每类中最接近的数据点之间的距离。最接近超平面的数据点被称为支持向量，因此被称为“支持向量机”。

由于其能够处理数据点之间的复杂和非线性关系，并具有强大的理论基础，因此被广泛应用于各个领域，如图像识别、自然语言处理和生物信息学。由于支持向量机在回归问题上的出色表现，近年来，已有相关研究基于支持向量机算法开展了相关的农作物产量预测工作，并取得了出色的预测结果。例如使用支持向量机来预测不同环境条件下的作物产量，包括土壤，气候和生物因素等。SVM 可以通过粒度计算将问题空间划分为一系列子任务，使用 SVM 的超平面构造拆分问题空间来并行化处理。这主要是得益于线性 SVM 可用于处理更高维度的空间，能够降低问题的时间复杂度。进而实现精准的作物产量预测。

（4）人工神经网络

人工神经网络（Artificial Neural Network, ANN）^[44]是一种机器学习模型，其灵感来源于人脑的结构和功能。它由大量相互连接的节点组成，也被称为人工神经元，它们一起工作来处理和分析数据。神经元被组织成层，每一层都执行一个特定的功能。输入层接收输入数据，隐藏层进行计算和转换，而输出层产生最终结果。

神经元之间的连接由权重表示，在训练过程中调整权重以优化网络的性能。训练过程包括向网络提供一组训练实例，并调整权重以最小化预测输出和实际输出之间的差异。这个过程通常使用一种优化算法，如反向传播法。ANN 可用于广泛的应用，如图像识别、自然语言处理、语音识别和预测建模。它有能力学习和识别数据中的复杂模式和关系，使其成为解决许多现实世界问题的强大工具。然而，ANN 的性能高度依赖于训练数据的质量和数量，以及网络结构和超参数的选择。

反向传播神经网络（Back Propagation Neural Network, BPNN）^[46]是一种特殊类型的人工神经网络，被广泛用于监督学习问题，如分类和回归。它由几个相互连接的节点组成，也被称为人工神经元。BP 神经网络的训练过程包括两个阶段：前向传播和反向传播。前向传播步骤是反向传播算法的第一步，用于产生网络的预测输出。在反向传播阶段，预测输出和实际输出之间的误差被计算出来，这个误差通过网络向后传播，以调整神经元之间连接的权重。这些步骤加在一起，使 BP 神经网络能够从输入数据

中学习，并随着时间的推移提高其准确性。

近年来，BPNN 被广泛用于作物产量预测。它已被应用于农业的许多领域，如作物分类、产量预测和疾病检测。例如：用于开发考虑到各种因素的作物产量预测模型，如天气模式、土壤质量和作物生长模式。该网络可以在历史数据上进行训练，以学习这些因素和作物产量之间的复杂关系。一旦经过训练，该模型就可以用来根据新数据预测未来的作物产量。BPNN 还可用于开发精准农业技术，它可以通过识别水和肥料等资源的最有效使用来优化作物产量。该网络可以在有关土壤质量、天气模式和作物生长模式的数据上进行训练，以学习优化资源配置，实现最大产量。

（5）卷积神经网络

2015 年，lecun 等人指出卷积神经网络（Convolutional neural network model, CNN）是被设计用来处理多队列数据的，例如一张包含三通道 2 维彩色像素强度队列的图片。许多数据形态是多维队列的形式：1 维的是包括语言的信号序列，2 维的是图像或声谱图，3 维的是视频或立体图像。目前，CNN 模型具有训练速度快、准确率高的特点。从二十世纪九十年代早期开始，卷积神经网络已经有了大量的应用，最初是时延神经网络用于语音识别和文本阅读。二十世纪九十年代早期，卷积网络也曾被实验在自然图片中的目标检测上，包括人脸识别和手写体识别^[45]。

卷积神经网络由卷积层、池化层和全连接层组成。卷积层将一组卷积核应用于输入数据，以提取与特定任务相关的特征。每个卷积核是一个小的权重矩阵，与输入数据进行卷积，产生一个特征图，进而完成特征提取与降维操作。

本文使用的 1DCNN 网络有 2 个级联的卷积层，每个卷积层的输出经过 ReLU 激活后作为下一层的输入。池化层采用最大池化方法，利用 ReLU 激活函数去除不重要的特征。全连接层使用非线性函数将池化的神经元展开为一维向量，以方便处理数据。CNN 使用误差反向传播算法更新权值，使卷积层和池化层学习到最优参数矩阵。激活函数是一个在神经元输出中引入非线性的数学函数。它应用于神经元的输入和偏差的加权求和，并确定神经元的输出。目前主流的几种激活函数包括 Tanh、Sigmoid 和 ReLU 函数，它们在保留特征和去除冗余数据方面有很好的效果。这三种激活函数的公式如下：

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.1)$$

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2.2)$$

$$\text{ReLU}(x) = \max(0, x) \quad (2.3)$$

(6) 长短期记忆网络

2015 年, lecun 指出当 BP 算法第一次被公布时, 它最令人激动的应用就是训练递归神经网络 (Recurrent Neural Network, RNN) [47]。对于语音和语言这种连续输入的问题, 递归神经网络的效果通常是比较好的。递归神经网络在时域上展开, 可以看作是一个所有层共享相同权重的深度前馈网络。尽管他们的主要目标是学习到长期的依赖, 但是理论和实践经验都表明学习去长久地储存信息是很困难的。为了解决这一问题, 可以增大网络的存储量。这个方法最初的提议是一种采用了特殊隐藏单元的长短期记忆网络 (Long Short Term Memory, LSTM) [48]。LSTM 可以视为 RNN 的一种特殊形式, 它能够对上一个阶段得到的状态中有意义的数据设置权重, 从而达到记忆的效果, 将意义不大的数据视为冗余数据, 进行丢弃。同时对当前阶段的输入也设置权重, 通过这一系列的操作, 有效地减少了学习难度, 同时优化了 RNN 梯度消失和梯度爆炸的缺陷。




图 2.1 长短期记忆网络 (LSTM) 结构图

Fig2.1 Long and short-term memory network (LSTM) structure

LSTM 神经网络可以看作由若干个细胞组成, 每一个细胞是一个 LSTM 单元, 各个细胞单元串联在一起, 由上一个单元的输出加上当前新的数据一起作为当前单元的输入, 以此达到记忆的效果。一个 LSTM 单元的内部结构主要包含以下几个模块: 内部记忆 c_t 单元、输入门 i_t 、输出门 o_t 和遗忘门 f_t , 其结构图如图 2.1 所示。

遗忘门的作用是判断在上一个 LSTM 单元中得到的结果中需要丢弃什么信息。遗忘门公式如下:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad (2.4)$$

式中, W_f 、 U_f 代表权重参数, x_t 代表当前状态的输入, h_{t-1} 为上一单元的结果, b_f 代表偏置, 而 σ 则起到激励函数的作用, 通常选择 Sigmoid 函数^[49]作为激励函数。

输入门的作用是决定当前状态添加多少新的数据作为输入。输入门公式如下, 其参数的选择基本与遗忘门意义相同, 由权重参数决定数据的比重。

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad (2.5)$$

内部记忆单元是指当前细胞状态, 公式如下:

$$c'_t = \text{Tanh}(W_c x_t + U_c h_{t-1}) \quad (2.6)$$

$$c_t = f_t c_{t-1} + i_t c'_t \quad (2.7)$$

输出门的作用是决定当前单元输出内容, 它的信息基于细胞状态, 但还要经过一定过滤。输出门公式如下, σ 参数决定输出的数据, 激活函数 Tanh 对细胞状态进行处理, 再与 σ 中的 sigmoid 门的输出相乘, 输出最终状态 h_t 。

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (2.8)$$

$$h_t = o_t \text{Tanh}(c_t) \quad (2.9)$$

第三章 基于 CNN-BiLSTM-Attention 的产量预测模型

基于深度学习模型的农作物产量预测为目前主流的研究方法，基于本文研究区域所整理的数据，本文拟提出一种 CNN-BiLSTM 融合注意力机制的产量预测模型，为后续的玉米产量预测实验与分析完成模型构建工作。首先，本章确定了实验对象的选择，即玉米的历年产量数据和生长环境数据，并将获取到的数据进行了数据预处理。而后通过深度学习技术搭建并训练了预测模型，并确定了几种主流的评价指标定量，作为后续产量预测实验中定量评估模型预测结果优劣的标准，玉米产量预测设计流程如图 3.1 所示。




图 3.1 玉米产量预测设计流程图

Fig3.1 Maize yield forecast design flow chart

3.1 数据准备与评价指标

3.1.1 特征参数选择

利用温度数据作为回归变量，产量作为因变量的预测模型在研究中比较常见，最常见的温度变量就是积温^[50]。生长积温（Growing Degree Days，GDD）是指植物生长

所需的温度，它是指每日的最高温度和最低温度的平均值减去一个基准温度的结果。GDD 可以用来衡量植物生长的速度，从而更好地控制农作物的生长。热害积温 (Killing Degree Days, KDD) 是指植物受到热害的温度，它是指每日的最高温度减去一个基准温度的结果。KDD 可以用来衡量植物受到热害的程度，从而更好地控制农作物的生长。在玉米生长过程中，GDD 和 KDD 都可以用来控制玉米的生长。GDD 可以帮助玉米在适宜的温度下生长，而 KDD 可以帮助玉米避免受到过高温度的热害^[51]。

根据温度数据，计算出日度气候累积参数 GDD_d 、 KDD_d ，计算公式如下。

$$GDD_d = \frac{T_{\max,d} + T_{\min,d}}{2} - T_{low} \quad (3.1)$$

$$KDD_d = \begin{cases} T_{\max,d} - T_{high} & \text{if } T_{\max,d} > T_{high} \\ 0 & \text{if } T_{\max,d} \leq T_{high} \end{cases} \quad (3.2)$$

$$T_{\max} = \begin{cases} T_{\max,d} & \text{if } T_{low} < T_{\max,d} < T_{high} \\ T_{low} & \text{if } T_{\max,d} \leq T_{low} \\ T_{high} & \text{if } T_{\max,d} \geq T_{high} \end{cases} \quad (3.3)$$

其中 T_{high} 、 T_{low} 代表玉米生长最高与最低适宜温度， $T_{\max,d}$ 、 $T_{\min,d}$ 代表日最高温度与最低温度

根据研究区域玉米种植记录，在研究区域八个州中，密苏里州种植日期最早，为 4 月 5 日；印第安纳州收获日期最晚，截至 12 月 10 日。由此数据，将数据采集时间段设置为 4—11 月，作为玉米产量预测的监测期。

3.1.2 数据预处理

本文对输入数据进行了归一化处理，归一化是任何类型问题都需要开展的数据预处理工作，特别是数据挖掘和云计算等领域发挥着重要作用，它可以在数据进入下一阶段之前缩小或扩大数据的范围，从而将需要进行比较或者训练的数据放缩在同一尺度，使数据间的关联与差异更明显。目前有几种主流的归一化技术，如 Min-Max 归一化^[52]和 Z-score 归一化^[53]。

Min-Max 归一化原理为先找出数据集的最大值和最小值，并计算两者之间的差值，然后所有元素先减去最小值，再除以计算好的差值，计算结果即为归一化后的数据。经 Min-Max 归一化后，数据集整体将会平移到[0,1]的区间内，数据分布不变，其公式

如下：

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (3.4)$$

其中， x' 为经过 Min-Max 归一化之后的值， x 为归一化前的数据原值， $\max(x)$ 为所选取数据中的最大值， $\min(x)$ 为最小值。

Z-score 归一化方法的核心是均值和标准差，处理后的数据符合标准正态分布，且无量纲，均值为 0，方差为 1。Z-score 归一化的公式如下：

$$x' = \frac{x - \mu}{\sigma} \quad (3.5)$$

其中， x 为数据原值， μ 表示所选取数据的平均值， σ 为标准差， x' 表示归一化后的数据。

本文选用的归一化方法为 min-max 归一化，将数据放缩到[0, 1]区间。为确保研究过程中的数据可靠性，实验对数据还制定如下清洗和处理标准：

(1) 对于气候数据采集量空值多于 1/3 的站点，进行丢弃。反之，若当前月份缺失较少，则取当前月份均值；若当前月份缺失较多，则取当前年份均值；

(2) 根据农业相关知识，将玉米生长适宜温度设置为 9°C—29°C^[54]。

对于满足此范围的数据，由 GDD_d、KDD_d 和日降水量计算得出第 m 月的生长积温 GDD_m、热害积温 KDD_m 和累积降水量 PRCP_m 作为后续产量预测实验的输入。对于预处理得到的数据，最终按照 8: 2 的比例划分训练集与测试集。

3.1.3 评价指标

本文选取了四种主流评价指标定量评价模型的精度，对本文构建的 CNN-BiLSTM-Attention 模型与对比算法的产量预测结果进行对比。四种评价指标分别为决定系数、平均绝对误差、均方误差和均方根误差。第一个指标决定系数反映了自变量能解释因变量变异的百分比，后三个指标用于评估模型回归预测结果与真实值的误差。

(1) 决定系数

决定系数 (Coefficient Of Determination, R^2)^[55] 是一个统计指标，它被用来评估一个回归模型与观察数据的吻合程度，表示因变量中可从自变量中预测的方差比例。

R^2 的范围是 0 到 1，数值越高表示模型的拟合度越高。值为 0 表示模型不能解释因变量的任何变异，而值为 1 表示模型完全解释了因变量的变异。当然，高的 R^2 并不意味着模型是一个很好的拟合，因为模型中可能还有其他因素没有被考虑，需要综合考虑其他评价指标与影响因素。 R^2 的计算公式如下：

$$R^2 = 1 - \frac{\sum_{i=1}^m (\hat{y}_i - y_i)^2}{\sum_{i=1}^m (\bar{y}_i - y_i)^2} \quad (3.6)$$

(2) 平均绝对误差

平均绝对误差 (Mean Absolute Error, MAE) [56]，用于计算真实产量值和模型预测产量值间误差绝对值的平均值，计算公式如下：

$$MAE = \frac{1}{m} \sum_{i=1}^m |(y_i - \hat{y}_i)| \quad (3.7)$$

(3) 均方误差

均方误差 (Mean Square Error, MSE) 是一种统计学参数，用于计算数据集中预测值和实际值之间的平均平方差。它通过测量预测值与实际值的接近程度来评估回归模型的准确性。均方误差的计算方法是取每个真实值和预测值之间的差值，并将该差值平方化，然后取所有差值平方的平均值。较低的 MSE 表明模型与数据的拟合度较高，计算公式如下：

$$MSE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2 \quad (3.8)$$

(4) 均方根误差

均方根误差 (Root Mean Square Error, RMSE) 同样是一个统计指标，用于衡量数据集中预测值和实际值之间的差异。均方根误差的值为真实值与预测值之间平均平方差的平方根。RMSE 是一个评估模型精度的负项指标，实验取得的 RMSE 值越大，实验精度越低；而相反，较低的 RMSE 表明模型与数据的拟合度较高，其计算公式如下：

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2} \quad (3.9)$$

以上四个评估指标中, y_i 为真实产量值, $\hat{y}_i$ 为预测产量值, 而 $\bar{y}_i$ 则代表样本均值; m 、 i 分别代表样本总数和样本集中第 i 个样本。

3.2 模型构建

深度学习因具有自适应特征提取的优势和良好的学习效果而被广泛应用。深度学习克服了人工特征提取和机器学习特征提取过程繁琐的缺点。与机器学习方法不同, 深度学习方法不需要人工提取相关领域知识的特征, 也不需要深入了解不同数据的相关特性, 而是简单地根据其特性对数据进行编码, 并转换为相应的数值序列或数值矩阵, 然后输入到模型中进行训练和学习, 并利用 BP 算法经过多次迭代反向, 实现高效的分类预测。

目前, CNN、LSTM 和 BiLSTM^[57]都被应用于时间序列预测研究中, 但每个单独的模型都有其自身的缺陷。例如, CNN 使用卷积核作为特征提取器来自动提取潜在有用的信息, 每个特征映射图都是某个局部区域的特征快照, 相比于人类提取的有限特征, CNN 提取了丰富的特征, 但无法获取数据间的时间序列关系; LSTM 适合处理时间序列数据, 并且专门用于处理长期依赖信息缺失的问题, 但单向 LSTM 提取的特征信息不足; BiLSTM 是 LSTM 的改进模型, 利用正向 LSTM 和反向 LSTM 捕捉上下文信息, 并将两者结合以实现更好的学习。CNN-BiLSTM 集成模型可以提取连续序列之间的潜在特征, 克服长序列的信息依赖缺失问题, 防止不连续序列之间的关联信息丢失。传统的编码方法只考虑对单个单元的特征提取, 忽略了相邻单元之间的依赖关系; CNN 和 BiLSTM 共享每个特征的权重, 不能有效区分特征信息的重要性; 而注意力机制可以通过为不同年份具有不同特征的数据分配不同的权重来区分特征的重要性, 从而关注关键特征。该文在注意力机制的基础上提出了一种注意力机制。为此, 本文以美国雨养玉米带 9 个州作为研究区域, 构建了融合注意力机制的 CNN-BiLSTM 模型, 用于雨养玉米产量预测。

本文在已有模型算法基础上, 提出基于 CNN-BiLSTM 融合注意力机制的玉米产量预测方法。结合 BiLSTM 在处理时间序列以及 CNN 在特征提取上的优势, 另外为保证时序数据的前后关联性, 通过注意力机制进行权重分配, 计算数据与数据之间的关联程度, 获取数据结构信息, 能够有效抑制双向长短期记忆网络在处理长时间序列

数据时出现语义稀释的问题，最终实现玉米精准产量预测。模型以气象数据为输入，通过多个模块串联，逐步从输入数据中学习时序特征。模型结构如图 3.2 所示，该模型主要 CNN 模块、BiLSTM 模块和注意力机制模块组成。




图 3.2 CNN-BiLSTM-Attention 模型结构图

Fig3.2 Structure of CNN-BiLSTM-Attention model

卷积模块中，每个卷积核的维度为 1×24 ，而卷积核个数为 64，步长设置为 1，激活函数选用 ReLU 函数。卷积操作后接入一个 Dropout 层，随机丢弃的比例设置为 0.3，以防止出现过拟合现象。BiLSTM 模块中，隐藏层个数设置为 4 层，LSTM 单元数为 128，在 BiLSTM 模块后同样设置丢弃比例为 0.3 的 Dropout 层。模型通过 adam 优化器计算自适应学习率进行模型优化，将 MSE 作为模型损失函数，模型详细架构信息如下。

(1) 卷积模块

一维卷积神经网络通常用于对时间等序列数据的处理。在结构上，一维 CNN (1DCNN) 与常用的二维 CNN 几乎相同，其特征提取过程也由卷积和池化完成，并通过全连接层完成特征的输出。在使用方面，CNN 主要用于二维图像的特征识别，而 1DCNN 则广泛用于时间序列的特征识别和提取^[58]。虽然一维 CNN 只有一个维度，但

它在特征识别方面也具有 CNN 的平移不变性的优势。在一维 CNN 中, 由于卷积核是一维的, 一个大的卷积核不需要包含太多的参数和计算。为了获得更大的感受野, 该模型可以使用更大的卷积核宽度, 从而获得更全面的序列特征值视图。

LSTM 通常用于处理时间序列数据, 善于处理信息长期以来缺失问题, 但 LSTM 提取特征信息不充分, 而 CNN 正好可以弥补这一缺陷, 因此, 本文在长短期记忆网络前添加卷积神经网络模块, 学习数据潜在有用的特征信息, 提升模型的整体预测能力。

本文提出的一维 CNN 网络结构如 3.3 所示。分布式特征向量通过输入层输入到一维 CNN 网络中, 使用一维 CNN 网络提取每个子集的特征。本文中的一维 CNN 网络使用两个卷积层的级联。此外, 在卷积操作之间添加最大池化层, 以防止过拟合并提高操作效率。




图 3.3 一维卷积神经网络结构图

Fig3.3 Structure of a one-dimensional convolutional neural network

卷积模块初始结构为单层一维卷积神经网络, 通过实验验证不同深度网络结构对产量预测性能的影响。本文又分别设置了 2、4、8 等不同层数的卷积神经网络并进行了实验验证, 实验发现, 与单层的 CNN 相比, 更多层的 CNN 架构, 模型性能并未得到明显提升。因此, 综合考虑模型性能与系统负担问题, 本文最终采用单层一维卷积进行特征的提取。

(2) BiLSTM 模块

双向长短期记忆网络 (Bidirectional Long Short Term Memory Networks, BiLSTM) 是 LSTM 的一种特殊形式, 同意用于处理时间序列数据。BiLSTM 与 LSTM 的主要区

别在于，BiLSTM 使用两个独立的 LSTM 网络，一个用于处理正向序列，另一个用于处理反向序列。BiLSTM 的优势在于，它可以捕捉到序列数据中的双向关系，而 LSTM 只能捕捉到单向关系。BiLSTM 可以更好地捕捉到序列数据中的上下文信息，从而提高模型的准确性。此外，BiLSTM 还可以更好地处理噪声，因为它可以从反向序列中捕捉到噪声的影响，从而提高模型的鲁棒性。BiLSTM 还可以更有效地利用数据，因为它可以从正向序列和反向序列中提取有用的信息，从而提高模型的性能。BiLSTM 还可以更快地收敛，因为它可以从两个方向同时收敛，从而加快模型的训练速度。




图 3.4 LSTM 与 BiLSTM 模型收敛性对比

Fig3.4 LSTM versus BiLSTM model convergence

为验证 BiLSTM 模型在玉米产量预测方面的性能，本文对 BiLSTM 和 LSTM 进行了对比实验。对比实验分别对 LSTM 模型和 BiLSTM 模型设置了 1、2、4、8 四种隐藏层个数的网络结构，并命名为 LSTM₁、LSTM₂、LSTM₄、LSTM₈ 和 BiLSTM₁、BiLSTM₂、BiLSTM₄、BiLSTM₈。LSTM 模型和 BiLSTM 模型的收敛性对比结果如图 3.4 所示。

由图 3.4 可见，随着实验的推进，所有模型的 loss 值都随着迭代的进行而持续下降，但 BiLSTM 模型的收敛速度整体优于 LSTM 模型，特别是在迭代次数到达 80 次左右的时候，LSTM 模型的训练损失基本不再降低，而此时 BiLSTM 模型的损失有继续下降的趋势，说明其收敛性优于 LSTM 模型。

表 3.1 给出了 BiLSTM 和 LSTM 模型的 RMSE 和 R^2 评价指标值。从表 3.1 可见, 除 BiLSTM₁ 模型的性能低于 LSTM 外, 其余三个 BiLSTM 模型的性能均优于 LSTM。其中 BiLSTM₄ 的性能最优, R^2 为 0.817, RMSE 为 1.057mg/ha。为了更加直观地展现不同结构网络模块的优劣, 本文通过柱状图的形式可视化了 MSE、RMSE、MAE 和 R^2 四个指标的实验结果对比图, 对比结果如图 3.5 所示。基于以上实验结果, 本文后续所搭建的模型中, BiLSTM 模块将隐藏层个数设置为 4。

表 3.1 LSTM 与 BiLSTM 模型性能对比

Tab3.1 Performance comparison of LSTM and BiLSTM models

模型	RMSE(mg/ha)	R^2	MSE(mg ² /ha ²)	MAE(mg/ha)
LSTM ₁	1.129	0.789	1.275	7.878
LSTM ₂	1.149	0.788	1.320	7.879
LSTM ₄	1.309	0.758	1.713	8.219
LSTM ₈	1.149	0.788	1.320	7.745
BiLSTM ₁	1.178	0.773	1.388	8.166
BiLSTM ₂	1.100	0.802	1.210	7.664
BiLSTM ₄	1.057	0.817	1.117	7.150
BiLSTM ₈	1.083	0.808	1.173	7.349

由图 3.5 得出结论, BiLSTM 网络在处理时间序列数据时, 整体表现出了更低的误差与更高的相关性。这是由于在使用 LSTM 网络进行深度学习训练时, 当反向传播过程中的梯度变得非常大并导致数值溢出时, 梯度爆炸就会发生, 这使得模型训练变得困难。而 BiLSTM 由两个上下堆叠的 LSTM 网络组成, 一个从左到右处理序列, 另一个从右到左处理序列。梯度通过两个独立的 LSTM 网络进行传播, 提取长时间序列数据中的长期依赖关系, 通过有选择地记住或忘记过去的信息, 所以不会导致梯度在反向传播期间爆炸。由于玉米的生长是有机物积累的过程, 不同生长期之间存在着较强的联系, 这种时间序列联系贯穿了玉米生长的整个生长期, 而 BiLSTM 更擅长捕捉这种长时间序列之间的时序特征, 因此, 后续模型构建中采用 BiLSTM 网络而不是经典的 LSTM 网络。




图 3.5 LSTM 与 BiLSTM 模型性能对比图

Fig3.5 Performance comparison of LSTM and BiLSTM models

(3) 注意力机制模块

注意力机制目前广泛用于深度学习模型的优化，其本质就是权重分配。它会在进行预测时有选择地关注输入序列的特定部分，给输入序列中的每个元素分配一个权重，这个权重反映了元素在预测任务背景下的重要性。这些权重被用来计算输入序列的加权和，并作为模型下一层的输入。

注意力机制的实现方式有多种，本文采用的注意力机制结构如图 3.6 所示。

若 h_t 是 BiLSTM 输出的单元隐藏状态，则通过注意力机制捕捉目标的注意力权重为：

$$v_t = a^T \tanh(w \times h_t + b_v) \quad (3.10)$$

其中 a^T 和 w 代表学习权值。




图 3.6 注意力机制结构图

Fig3.6 Structure of the attentional mechanism

利用 softmax 函数将注意力权重进行归一化，计算概率向量 P_t ：

$$P_t = \frac{\exp(v_t)}{\sum_{t=1}^n \exp(v_t)} \quad (3.11)$$

将注意力权重分配给相应隐藏状态 h_t ，加权求和可得到注意力值，公式如下：

$$c_t = \sum_{t=1}^n P_t \cdot h_t \quad (3.12)$$

3.3 本章小结

本章搭建了玉米产量预测框架，介绍了模型的特征选择，并讲述了原始数据到实验输入数据的转化过程和数据预处理内容。实验选择参数为单层一维卷积、4 层 BiLSTM 网络搭建了基于 CNN-BiLSTM-Attention 的玉米产量预测模型，并分析了一维卷积神经网络、BiLSTM 网络的优势和注意力机制在模型中起到的作用。通过本章的模块收敛性等实验分析，完成了模型各模块的参数优化，验证了 CNN-BiLSTM-Attention 模型在产量预测的优越性。第四章，我们将基于本章所构建的产量预测模型进行雨养玉米产量预测与分析工作。

第四章 玉米产量预测实验与分析

在已有的研究成果中,对于玉米产量的预测工作中,研究人员主要选取最高温度、最低温度和降水量三种因素特征作为输入,通过深度学习方法提取时序特征,从而获得环境数据与产量之间的线性与非线性关系,最终达到产量预测的目的。然而,大多数研究都是以适用于大多数农作物的整个生长周期原始数据为输入,未对数据进行足够处理,没有考虑到玉米作物本身对何种因素更为敏感,也没有考虑不同生长周期的环境因素对玉米生长及产量的影响因素大小。

基于上文构建的 CNN-BiLSTM-Attention 产量预测模型,本章以最高温度、最低温度和降水量为原始气象数据,并将其转化为有利于反应玉米生长的气候累积参数 GDD、KDD 和 PRCP,利用前文构建的产量预测模型对 1981 年—2020 年美国雨养玉米带玉米产量相关数据进行训练,通过对其训练效果的观察,反复优化模型参数,最终得到最优参数下的深度学习模型,并完成了玉米产量预测工作。本章将已有研究所提出的三种深度学习模型作为对比算法,通过 RMSE 与 R^2 评估指标对模型进行评估。此外,本章对研究区域采集的玉米生长环境因素进行分析,提取对玉米产量影响较大的影响因素,这一工作能够为实际玉米种植过程中的智能决策提供科学依据。

4.1 实验环境

实验开发在 Windows10 专业版 64 位操作系统中完成,其中 Windows 配置为 Intel(R) Core(TM) i7-11800H CPU、16GB 内存, GPU 为英伟达 GeForce RTX3060 显卡, 6GB 显存,模型搭建及深度学习实验在 Pycharm 软件完成。

模型构建及实验在进行主要使用 tensorflow 和 Keras 深度学习库完成,数据处理主要使用 Pandas、Numpy 和 sklearn 库,实验的损失函数及预测结果可视化主要采用 matplotlib 库进行绘制。

4.2 研究区域与数据

由于目前国内数据收集难度较大,产量数据与气候数据之间粒度难以匹配,采集到的数据无法支撑起深度学习模型的训练工作。因此,本文重点关注 1981 年至 2020

年美国玉米带地区八个州的县级雨养玉米产量，2020 年这八个州的玉米产量占全美玉米总产量的 54.2%。此区域存在细粒度的气候与产量开源数据，已有相关研究以此数据进行产量预测工作^[59]。

图 4.1 为 2020 年该地区县级玉米产量分布图，研究考虑八个州，即明尼苏达州（MN）、威斯康星州（WI）、密歇根州（MI）、爱荷华州（IA）、伊利诺伊州（IL）、印第安纳州（IN）、俄亥俄州（OH）和密苏里州（MO）。颜色深浅代表玉米产量值的大小，颜色越深，玉米产量越高。




图 4.1 2020 年雨养玉米带县级产量分布图

Fig4.1 County-level production distribution in the rainfed maize belt in 2020

本研究从美国国家海洋和大气管理局应用气候信息系统获得美国气候数据集，包含了美国八个州的雨养玉米带的 2439 个站点 1980 年—2021 年的日最高气温、日最低气温、平均温度和降水量的日志数据^[60]。

本研究从美国农业统计局获得美国雨养玉米产量数据集，包含了 1980 年—2021 年的玉米产量值，产量数据单位为吨/公顷（mg/ha）。原始产量数据中有 750 个县，27248 个样本^[61]。

本文所选取玉米生长区 1981 年—2020 年的最高温度（Tmax）、最低温度（Tmin）与降水量（prcp）三个气候参数作为原始数据，根据玉米生长条件特性和已有关于能反映玉米作物生长的特征参数研究，将原始气候参数转换为有利于评估作物生长规律

的累积参数 GDD、KDD、PRCP。由于实验所选时间段为每年的 4-11 月共 8 个月，实验将 GDD、KDD 与 PRCP 细分到月度，以 GDD 为例，输入数据包含 GDD_{m4} 、 GDD_{m5} 、 GDD_{m6} 、 GDD_{m7} 、 GDD_{m8} 、 GDD_{m9} 、 GDD_{m10} 、 GDD_{m11} 八个参数。训练过程中，以每 40 年的气象数据作为一个训练样本，用来预测下一年份的产量数据。因此，输入数据维度为 40×24 。

4.3 实验结果与分析

4.3.1 消融实验

基于 CNN-BiLSTM 融合注意力机制模型主要包括卷积层、双向长短期记忆网络层、注意力层三个核心组件，为进一步证明本文所提出的 CNN-BiLSTM 融合注意力机制模型各个模块的有效性与必要性，本文设计了消融实验，实验通过删除和拆分模型的不同组成部分进行产量预测，进而评估各组件对产量预测性能提升的贡献。消融实验的具体设置和实验结果如下。

- 1) 消融实验 1：仅利用 CNN 训练模型，并通过全连接层进行预测结果的输出；
- 2) 消融实验 2：仅利用 BiLSTM 训练模型，通过全连接层进行预测结果的输出；
- 3) 消融实验 3：在原模型的基础上，去除 CNN 模块；
- 4) 消融实验 4：在原模型的基础上，去除注意力机制；
- 5) 本文提出的基于 CNN-BiLSTM 融合注意力机制方法。

表 4.1 消融实验设置及实验结果

Tab4.1 Ablation experimental setup and experimental results				
序号	模型	RMSE(mg/ha)	R^2	MSE(mg ² /ha ²)
1	CNN	1.115	0.797	1.243
2	BiLSTM	1.069	0.813	1.143
3	BiLSTM-Attention	1.066	0.814	1.136
4	CNN-BiLSTM	1.011	0.833	1.022
5	CNN-BiLSTM-Attention	0.957	0.850	0.916

对表 4.1 实验结果进行分析，可以得出如下结论：

- 1) 单独使用 BiLSTM 比单独使用 CNN 的性能要优，将两者结合起来后，模型性

能提升明显。产量预测主要工作是学习时序数据间的潜在关联，即更注重时序数据的前后关联性，这正是 BiLSTM 网络的主要工作。但 BiLSTM 存在提取特征信息不充分的问题，而 CNN 善于学习数据潜在有用的特征信息，能够弥补了这一缺陷，因此两个模块组合使得模型性能上升。

2) 引入注意力机制比单独使用 CNN-BiLSTM 的性能更优，这得益于注意力机制对特征向量的权重分配工作。模型引入注意力机制，能够有效抑制双向长短期记忆网络在处理长时间序列数据时出现语义稀释的问题。

3) 同时使用三种组件时能够让模型的 RMSE 降至 0.957mg/ha， R^2 提升至 0.85。实验结果验证了所提出改进策略的有效性。




图 4.2 消融实验训练误差对比图

Fig4.2 Comparison of training errors in ablation experiments

消融实验训练过程中损失曲线如图 4.2 所示，由图可知，随着迭代次数增加，模型的损失值均在不断降低。训练前期 CNN-BiLSTM-Attention 模型的训练误差大于其他模型，随着训练的推进，该模型的收敛速度加快，并逐步超越了其他模型。在训练至第 100 个批次时，其他模型的损失函数基本趋于收敛，而 CNN-BiLSTM-Attention 模型的损失值仍呈下降趋势，说明该模型具有更优的收敛性能。

4.3.2 对比试验

为进一步验证 CNN-BiLSTM-Attention 模型在产量预测方面的性能，本文选择深度学习模型 CNN-RNN、EWA、DeepCropNet 作为对比算法。

指数加权平均方法 (Exponentially Weighted Average Ensemble, EWA) 是将每个模型的预测平均组合在一起, 并且通常比给定的单个模型平均产生更好的性能。针对特点领域的问题, 有一些常规算法会表现良好, 其核心思想就是对于表现较好的模型, 给予更高的权重, 以获得最好的实验结果。目前 EWA 在时间序列预测领域也有较多的应用, 本文所采用的指数加权平均方法所集成的基础算法包括线性回归、支持向量机、随机森林和人工神经网络, 实验基于以上四个算法分别进行了产量预测, 其中, 单个机器学习模型表现最好的是 LASSO 模型, 其 RMSE 为 1.298mg/ha, 而通过 EWA 方法继承框架最终预测误差为 1.148mg/ha, 结果优于单个模型。

DeepCropNet (DCN) 模型是一种深度学习框架, 使用多层分层学习气象和产量数据的时空特征。DCN 由时间学习模块和空间学习模块两部分组成。DCN 的输入是气象因子的时间序列, 包括从玉米种植到成熟的县级周生长积温、热害积温和降水量。产量是县级玉米产量。在这项研究中, AT-LSTM 网络用于训练为研究区域所有数据的特征参数, 以学习和可视化从每周气象因子时间序列中捕获的一般时间模式。空间学习模块 (MTL) 用于学习玉米产量与气象因素之间关系中的区域特定特征, 时间学习模块的 LSTM 层和注意力网络层是共享的, 而空间学习模块的最终输出层是特定区域。共享层提取不同区域的通用特征, 特定区域的输出层根据局部特征生成权重, 用于每个区域的最终产量预测。

CNN-RNN 是一个深度学习混合模型, 它结合了 CNN、全连接层和 RNN 三大模块。CNN 模块用于捕获数据的线性与非线性效应, CNN 模块分为两个部分, W-CNN 采用一维卷积神经网络捕获气候数据的时间依赖性, S-CNN 则采用一维卷积神经网络去捕获数据的空间依赖性。RNN 模块旨在捕获作物产量在数年内的时间依赖性。全连接层主要起到将 WCNN 与 SCNN 提取的高级特征相结合的作用, 同时也降低了 CNN 模型输出的维数。RNN 模型由 k 个 LSTM 单元组成, 该单元使用从 $t-k$ 到 t 年的信息预测一个县 t 年的作物产量。模型所有权重都用 Xavier 方法初始化。模型使用 SGD 随机梯度下降法, 使用 adam 适应性矩估计算法作为优化器, 学习率为 0.03%, 迭代次数每经过 60000 次除以 2, 模型经过最多 350000 次迭代的训练。

一个回归实验结果的优劣主要有实验输出的预测值与真实值的拟合程度决定, 对比试验主要使用 MSE、RMSE、 R^2 三个评估指标来评判不同模型在玉米产量预测的优

劣。其中，MSE 与 RMSE 为负向指标，实验所得数值越大，则实验预测结果与真实值拟合程度越差，模型预测性能越差； R^2 为整项指标，实验所得 R^2 指标越大，则预测结果与真实产量值拟合程度越高，模型预测性能越好。本文采用 MSE 作为模型损失函数，AdaGrad 自适应梯度下降算法作为优化器。

各算法的对比结果如表 4.2 所示，可以看出 CNN-BiLSTM-Attention 最终得出的 R^2 为 0.85，RMSE 为 0.957mg/ha，MSE 为 0.916mg²/ha²，所有指标均优于 EWA、DeepCropNet 和 CNN-RNN 三种对比算法，可见本文提出的 CNN-BiLSTM-Attention 模型的预测性能最优。

表 4.2 四种算法精度对比

Tab4.2 Precision comparison of four algorithms			
模型	RMSE(mg/ha)	R^2	MSE(mg ² /ha ²)
EWA	1.148	/	1.318
DeepCropNet	1.000	0.780	1.000
CNN-RNN	0.975	0.750	0.951
CNN-BiLSTM-Attention	0.957	0.850	0.916

为了更直观地展现四种模型产量预测性能优劣，本文使用柱状图分别可视化了 MSE、RMSE 和 R^2 的实验结果对比，对比结果如图 4.3 所示，其中，图 c 仅可视化三个模型的性能，是因为此模型研究并未采用 R^2 作为实验评估指标。




图 4.3 不同算法性能对比图

Fig4.3 Performance comparison chart of different algorithms

综合分析以上四个模型的实验结果，DeepCropNet、CNN-RNN 和 CNN-BiLSTM-Attention 三个深度学习算法预测性能明显均优于由 LASSO 和随机森林等机器学习算

法指数加权平均方法 EWA，而 EWA 本身又优于单个机器学习算法的预测性能，因此可以得出结论，与传统机器学习方法相比，深度学习模型得由于其自适应特征提取的出色表现以及良好的学习效果，其在农作物产量预测等回归领域问题研究上表更出色。CNN-BiLSTM-Attention 模型相较于另外两个深度学习对比算法，其展现了更低的预测误差与更高的 R^2 系数，这得益于注意力机制的引入，注意力机制通过对时间序列数据的动态权重分配，使模型更加关注重要特征，抑制无用特征提高了模型对时间序列预测任务的准确性和可解释性。

4.3.3 地域差异预测分析

上述产量预测实验论证了本文所构建的 CNN-BiLSTM-Attention 模型在处理玉米产量预测问题时的优越性能。对比试验是从模型本身出发，探索模型在处理特定时间序列问题时的算法性能，而未考虑到问题本身。本文探讨的是美国玉米带八个州的玉米产量预测问题，所选取的研究区域范围较广。在实际农业生产中，由于每个地区的经纬度、地区种植习惯等不同，实际产量可能受到一些较为潜在因素的影响。因此，本文将研究区域八个州的数据进行单独划分，并对每个州进行单独的产量预测实验，尝试获取精度更高的产量预测结果，并分析造成不同预测精度的原因，具体实验结果如表 4.3 所示。

表 4.3 不同州的产量预测结果

Tab4.3 Yield prediction results for different states

州名	State	RMSE(mg/ha)	R^2	MSE(mg ² /ha ²)
明尼苏达州	MN	1.015	0.862	1.030
威斯康星州	WI	0.945	0.794	0.893
密歇根州	MI	1.170	0.685	1.369
爱荷华州	IA	0.860	0.870	0.739
伊利诺伊州	IL	1.191	0.788	1.419
印第安纳州	IN	1.130	0.719	1.278
俄亥俄州	OH	0.968	0.762	0.938
密苏里州	MO	1.415	0.607	2.000
整个玉米带	ALL	0.957	0.916	0.850

由表可知,相较于考虑预测整个玉米带的玉米产量,对各州单独的预测实验表现了不同的预测结果。其中,爱荷华州与威斯康星州的产量预测精度超过了整体预测精度,最优结果比整体预测结果误差减少了 0.097 吨/公顷;而剩余的六个州的预测精度均低于整体预测结果,最差结果为密苏里州,预测结果误差增加了 0.458 吨/公顷。这些单个预测结果的误差增减可以通过一种局部模式来解释^[25]。

以 2020 年密歇根州的天气情况为例,该地区的年平均降水量为 881.4 毫米,低于长期平均水平。该地区存在全年降水分布不均匀的情况,上半年降水偏多,下半年降水偏少。这导致了部分地区在春季的洪水,但在下半年一些地区的干旱情况,干旱会导致了这些地区农作物产量下降和农民的经济损失。




图 4.4 不同州的产量预测线性拟合图

Fig4.4 Plot of linear fit of yield forecasts for different states

通过整体产量预测,模型很难捕捉这种小范围地区的异常情况;而通过对密歇根

州的单独实验，模型预测精度获得了极大的提升，这印证了局部产量预测实验的必要性。通过这种局部产量预测实验，模型可以捕捉不同地区的不同气候特征，例如降雨过多、干旱、极端高温等因素，以此达到提高产量预测精度的目的。

如图 4.4 展示了密苏里州、爱荷华州、明尼苏达州和威斯康星州单独进行预测实验得到的预测值与真实产量值拟合图。其中，密苏里州州的线性拟合情况较差，离群值相较于其他三个州的预测结果明显偏多，且离群值大多分布在函数上方，这意味着在明尼苏达州的预测实验中，模型高估了实际产量值。而在整体预测时，模型中和了部分灾害数据所带来的影响，没有体现出极端天气下导致的产量异常情况。

爱荷华州、明尼苏达州和威斯康星州表现了较好的线性拟合效果。这三个州的 R^2 分别为 0.870、0.862 和 0.794，而其对应的误差值，例如 RMSE: 0.860 吨/公顷、1.015 吨/公顷与 0.945 吨/公顷，为八个州中预测结果最好的三组值。这三个州都位于美国的上中西部地区，在气候特征方面有许多相似之处。爱荷华州、明尼苏达州和威斯康星州全年都经历了丰富的降水，夏季降水最多。年平均降水量在爱荷华州和威斯康辛州南部约 760-890 毫米，在明尼苏达州和威斯康辛州北部约 640-760 毫米，都属于湿润的大陆性气候，其特点是冬季寒冷，夏季温暖。总的来说，爱荷华州、明尼苏达州和威斯康星州的气候特点是全年温度常规，降水较多，属于高温与干旱灾害较少的区域，因此能够获得较好的产量预测结果。

综上所述，虽然本文所构建的 CNN-BiLSTM-Attention 模型能够整体预测玉米带的玉米产量，但是难以捕捉部分地区存在的灾害等极端天气所带来的影响。通过对各州进行单独的实验，模型能够对不同地区的独特气候特征进行特征提取，更容易捕捉极端天气对玉米产量带来的影响，从而获得更高的预测结果。

4.4 影响因素分析

4.4.1 雨养玉米带玉米产量波动趋势

本文主要的研究方向是挖掘气象因素与玉米生长及产量之间的关联信息，由于实验过程主要为了构建一个最优的深度学习模型，而没有考虑到特征本身对玉米产量的影响，而是将玉米整个生长期的三个特征参数 GDD、KDD、PRCP 全部作为特征输入模型，而实际种植中，不同时期和不同种类的特征对玉米生长的影响程度不容忽视。

因此本节就三种特征参数的不同取值及组合，对玉米产量的影响因素进行了探讨。如图 4.6 为 GDD、KDD、PRCP 三种特征参数在玉米生长周期时不同月份的分布情况，其中，GDD、KDD 参数明显呈波段式起伏，而 PRCP 的变化趋势并不明显。




图 4.6 不同时期 GDD、KDD、PRCP 分布图

Fig4.6 Distribution of GDD, KDD and PRCP for different periods

如图 4.7 为研究区域 1981 年—2020 年的年度产量与气候因素走势图，四条折线分别为产量、GDD、KDD 和降水量。由于随着时代发展，农业种植技术提升，且化肥和管理条件也逐步优化，自 1981 年起，雨养玉米带平均玉米产量整体呈缓步上升趋势。但由于每年的气候与种植条件影响，玉米种植也会受到如极端天气等不可抗力因素的影响，产量存在一定的周期性波动^[62]。




图 4.7 1981 年—2020 年玉米产量与气候趋势图

Fig4.7 Maize production and climate trends 1981-2020

仔细研究气候因素与产量之间的走势可以看出，GDD 整体无明显上升或下降趋势，

但其周期性波动规律与产量基本保持一致，如 2012 年产量下降明显，而后稳步上升，而对应的 GDD 累计值也呈下降再增长趋势。由此可以判断，玉米生长和产量与其生长环境的 GDD 参数呈正相关。其次是 KDD 参数与产量之间的走势，其对应关系很明显，在产量下降的年份，KDD 年度累积值有明显上升趋势；而产量上升的年份，KDD 年度累积值明显呈下降趋势，这与 KDD 本身的定义和计算方法符合。上文提及，KDD 是用来衡量植物受到热害的程度的累积值，玉米对温度敏感，遇到极端天气的年份，生长受到影响极大，会出现减产现象。因此可以得出结论，玉米生长和产量与其生长环境的 KDD 参数呈负相关。由于产量与 GDD 呈正相关，而 GDD 与 KDD 也呈负相关。

最后是降水量参数 PRCP，由于上图是将四个参数的数值可视化在同一坐标系，单位无法做到一致，而降水量的数值相较于产量和另外两个累计参数很小，波动幅度很难在一个坐标系展现，因此下一段单独对降水量与产量之间的关系进行分析。




图 4.8 1981 年—2020 年玉米产量趋势图

Fig4.8 Maize production trends 1981-2020

图 4.8 为 1981 年—2020 年研究区域的产量走势图，图 4.9 为 1981 年—2020 年研究区域的降水走势图，由前文可知，由于生产技术的发展，玉米产量整体呈上升趋势。但由于极端天气等不可抗力因素的影响，玉米产量也存在短暂的骤升与骤降现象，而降水量则可作为天气好坏的一个反应因素。




图 4.9 1981 年—2020 年降水量趋势图

Fig4.9 Precipitation trends 1981-2020

由于本文所选研究区域为雨养玉米带，当地玉米的水分汲取主要靠雨水，极少甚至没有灌溉工作，因此当地玉米生长对降水量多少极为敏感。如图中 1988 与 2012 年份，这两年的降水量极少，降水量指数在 3.0 周围，相较于正常年份的 3.5—4.0，属于干旱年份，而对应年份的玉米年平均产量也达到 40 年内最低。此外，我们可以关注 1993 年，降水累积了达 40 年最高值，但当年的玉米产量却出现了反常的骤降现象。1993 年美国中西部受到极端湿润影响的县玉米平均减产达到 30%^[63]。上文提到，研究区域农民对于种植区水分管理工作较少，玉米生长对自然水分依赖性极高，已有研究表示，在极端湿润条件下，玉米会出现严重减产现象。此外，研究人员还提出，玉米生长季前期和中期遭受极端湿润对产量的影响更大。因此，本章后续内容将就玉米生长时期和不同环境因素对玉米产量的影响进行分析。

4.4.2 不同生长期对玉米产量的影响分析

美国雨养玉米是一种重要的农作物，其生长周期较长，一般需要 90—120 天才能完成生长。美国雨养玉米的生长周期可以分为三个阶段：种子萌发、苗期和成熟期。种子萌发阶段：种子萌发是美国雨养玉米生长周期的第一阶段，一般需要 2—3 天。在这个阶段，种子会吸收土壤中的水分，并开始发芽，形成种子芽。苗期：苗期是美国雨养玉米生长周期的第二阶段，一般需要 30—45 天。在这个阶段，种子芽会发育成苗，并开始生长，形成叶片和茎。此外，美国雨养玉米在苗期也会产生穗，但是穗上还没

有籽粒。成熟期：成熟期是美国雨养玉米生长周期的第三阶段，一般需要 60—75 天。在这个阶段，穗上会产生籽粒，籽粒会逐渐变硬，最终成熟。此外，美国雨养玉米在成熟期也会产生籽粒，但是籽粒会慢慢变硬，最终成熟。总的来说，美国雨养玉米的生长周期一般需要 90—120 天，可以分为种子萌发、苗期和成熟期三个阶段^[63]。在这三个阶段，美国雨养玉米会经历不同的生长过程，最终完成生长。

显著性检验是一种通过比较样本数据和总体数据之间的差异，来判断样本数据是否代表整个总体的统计方法，常用于某个因素对样本或总体的影响是否显著。显著性 P 值的分界线通常是 0.05，也就是说，当 P 值小于 0.05 时，通常认为差异具有统计学显著性，否则认为差异不具有统计学显著性。本文通过 ForStat 统计学方法对选取的生长期 4-11 月的三个累积参数进行了显著性检验，结果 α 均小于 0.05，说明累积参数与产量之间均存在显著性差异。




图 4.10 特征与产量值相关性分析热力图

Fig4.10 Heat map of correlation analysis between characteristics and yield values

图 4.10 为各参数与产量值的相关性分析热力图，其中参数后的数字代表月份。基于玉米作物特定的生长周期，将每年的 4 月—11 月定义为玉米的生长周期。可以看出，GDDm6 与 PRCPm6 与产量的相关性最高，而此时的 KDDm6 值为 0.01。6 月对应玉米的出苗期，作物出苗期间需要丰富的雨水进行滋养。此外，幼苗较为脆弱，初期在高温情况下存活难度大，适宜的温度区间对初期幼苗的生长至关重要。因此在这一阶段 GDD、KDD、PRCP 参数对产量预测影响最大。

为进一步提升玉米产量预测精度，将气象输入数据划分为 8 个子集，对应玉米生长的 8 个月。通过置换测试，每次去除一个月的数据输入，评估其对产量预测的影响。去除后实验相比于全部输入，预测结果误差越大，说明此周期对玉米生长影响越大，实验结果如表 4.4 所示。

表 4.4 不同月份气象数据对产量的影响

Tab4.4 Effect of meteorological data on yield in different months				
月份	MSE(mg ² /ha ²)	RMSE(mg/ha)	MAE(mg/ha)	R ²
4 月	1.008	1.004	0.073	0.835
5 月	1.014	1.007	0.074	0.834
6 月	1.016	1.008	0.073	0.834
7 月	0.976	0.988	0.072	0.840
8 月	1.019	1.009	0.075	0.833
9 月	1.000	1.000	0.073	0.836
10 月	0.986	0.993	0.073	0.839
11 月	1.013	1.007	0.074	0.834

实验结果表明，RMSE 在去除 5、6 和 8 月最高，分别对应玉米的出苗和抽穗阶段。这反映玉米在这两个阶段受外界因素影响的程度最大，该结果映射到实际种植中是有据可依的。出苗对于任何一种作物都是至关重要的一个生长阶段，若出苗阶段出现天气异常情况导致出苗率降低，产量一定会受到很大影响。当玉米生长到抽穗期，天气的好坏直接影响玉米结果的数量与玉米粒的饱满程度，即玉米产量。因此，这三个月

为玉米生长期最重要的时期,此时期数据的缺失会对产量预测精度造成较大的影响。

4.4.3 不同环境因素对玉米产量的影响分析

为评估不同数据源的产量预测性能,实验对几种数据源单独进行分析。通过置换测试,每次去除三种累积参数中的一种进行实验,以判断对产量预测影响最大的数据源。实验结果如表 4.5 所示。

表 4.5 不同数据对产量的影响

Tab4.5 Effect of different data on yield

数据	MSE(mg ² /ha ²)	RMSE(mg/ha)	MAE(mg/ha)	R ²
GDD	1.037	0.069	0.050	0.830
KDD	1.048	0.069	0.050	0.828
PRCP	1.075	0.070	0.051	0.824

与 GDD、KDD 两种气温累积数据相比,单独去除降水量数据对模型预测影响最大。基于上述结果,可以看出降水对玉米生长的影响大于温度对玉米生长的影响。由于降水量对玉米生长的重要性,而降水是无法人为操控的,因此,需要更为精准的判断。对降水量进行单独的相关性分析实验,以判断不同月份降水量对玉米产量的重要性。实验结果如图 4.11 所示。




图 4.11 降水量与产量值相关性分析热力图

Fig.4.11 Heat map for correlation analysis of precipitation and yield values

可以看出，6—7 月的降水量对产量预测的影响最大，相关系数分别为 0.14，0.11。由于降水的不可操控性，在实际种植阶段，如果遇到干旱少雨年份，生产者可以在这两个月加强水分监测。一旦出现土壤水分过低情况，应及时进行人为浇灌。如在人力有限的情况下，也能最大限度保障玉米的健康生长。

4.5 本章小结

本章主要基于构建的 CNN-BiLSTM-Attention 玉米产量预测模型，完成了美国雨养玉米带的玉米产量预测实验与分析工作。本章首先介绍了研究区域的玉米生长特性及数据，并通过消融实验证明了本文所提模型中各模块对预测实验的必要性和有效性。此外采用构建的模型进行了玉米产量预测工作，实验结果表明，该模型预测结果优于已有研究算法。最后，本章就雨养玉米生长的环境因素开展了影响因素分析工作，实验结论能够为实际玉米种植提供智能决策依据。

第五章 玉米产量预测分析原型系统的设计与实现

上文基于深度学习技术构建了一个玉米产量预测模型，并通过实验验证了该模型在研究区域参量预测工作的有效性与优越性。然而在实际农业生产中，种植及管理人员普遍缺乏计算机类专业知识，无法独立完成产量预测模型的训练与预测，以及数据处理工作，因此，一个便于使用，能通过简单操作完成实际玉米数据的管理与预测工作的玉米产量预测分析原型系统具有很强的实际意义。

一个好的农作物产量预测分析原型系统可以帮助农民和农业公司更好地管理农作物生产，为他们更好地规划和管理农作物生产、为政府制定农业政策提供依据减少浪费和损失，提高资源利用效率，从而促进农业可持续发展。在充分调研和分析玉米产量预测需求基础上，明确了玉米产量预测分析原型系统的面向用户群体和功能模块需求，完成了玉米产量预测分析原型系统的系统架构设计和数据库表设计，最后完成了系统的实现并进行了系统测试。

5.1 需求分析

（1）系统用户分析

通过对种植玉米用户、科研机构以及农业相关部门的走访调研，梳理该预测系统共有三类用户：

第一类是实验记录人员，该类人员主要从事农作物生长过程中各类生长数据的实时记录工作，通过系统的数据收集工作，其结果能为玉米产量预测等后续工作提供有力支撑；

第二类农业技术人员，该类用户主要基于系统上传的数据从事产量预测和分析工作，并对实验结果进行可视化呈现，得出智能决策结论；

第三类是农户，在实际种植中，农户可以根据产量预测分析原型系统产生的成果，进行实时的辅助决策。

（2）系统功能分析

通过对系统不同用户、不同权限、不同需求进行分析，确定了玉米产量预测分析原型系统需具备用户注册、登录和修改信息功能，还需具备数据总览、数据录入功能，

最后还需满足玉米产量预测功能和相关数据的可视化功能。

（3）系统非功能性分析

1) 安全性需求

产量预测和分析用到的实验数据较为敏感，有的为机密数据，所以需要对系统的安全进行设计，如采用用户身份认证，对于不同用户设置不同级别权限，防止数据泄露。另外针对敏感数据进行加密处理。

2) 规范性需求

系统的稳定运行是基于数据的标准化输入与使用的，因此，本系统需对用户录入的实验数据进行核验，当用户进行非法输入时，需要进行阻止并提醒。同时，需要设置权限，禁止用户通过非法 SQL 语句进行数据库操作，防止 SQL 注入式攻击。

5.2 系统设计

5.2.1 系统架构设计

本文所构建系统架构主要分为数据层、算法层、业务逻辑层和表示层，具体系统设计如图 5.1 所示。

1) 数据存储层为整个系统提供数据的存储支撑，实现系统用户与系统的信息交互，用户也可通过业务层发来请求，进而调用数据库中的数据。本文通过 mysql 数据库建玉米产量预测分析原型系统数据库，开发人员可以通过 SQL 语句对深度学习产量预测分析以及系统录入的用户数据、系统生成数据等所需要的数据进行增删改查。

2) 算法层：该部分主要使用 Python 语言实现，其中，玉米产量预测模型主要使用 tensorflow 和 Keras 深度学习库进行构建与训练，数据处理主要使用 Pandas、Numpy 和 sklearn 库，实验的损失函数及预测结果可视化主要采用 matplotlib 库进行绘制。该部分支持将数据库存储的数据进行调用，作为模型预测的输入，并将预测结果返回至后端，并在前端系统界面进行展示。

3) 业务逻辑层：业务逻辑层是一种软件架构模式，它将应用程序的业务逻辑或规则与其他组件（如用户界面、数据存储）分离开来。它是位于表示层（用户界面）和数据访问层（数据存储和检索）之间的一层。业务逻辑层的主要目的是处理应用程序的业务规则，并以独立于用户界面和数据访问层的方式实现它们。本文的业务逻辑层

采用 Java 开发语言，并搭载 SpringBoot 框架，利用自带的 Web 开发组件进行开发。相较于传统的 SSM 框架，自动集成组件及版本自动管理的优势更为明显。为实现后端与前端的交互，系统采用基于 MVC 设计模式的 SpringMvc 轻量级 Web 框架，以 FastJson 作为数据交互的处理工具。此外，为了实现 Java 对深度学习模型的调用，系统使用了 Runtime 工具。在权限管理方面，则采用更加轻量化的 Shiro 框架。




图 5.1 玉米产量预测分析原型系统整体架构图

Fig5.1 Overall architecture of the maize yield forecasting and analysis system

4) 表示层：系统表示层是与用户交互的软件应用程序的最顶层。它负责以易于理解和使用的方式向用户呈现数据和信息。表示层可以是图形用户界面（GUI）、命令行界面或基于 web 的界面，这取决于应用程序的类型和使用的技术。表示层的主要目的是提供一个用户友好的界面，使用户能够与底层系统进行交互。表示层负责处理用户输入，验证输入，并将其传递给底层进行处理。它还从底层接收数据和信息，并以易于理解和使用的方式呈现给用户。本文的表示层通过 html5 与 css 完成前端页面的基本构建，采用目前主流框架 Vue 进行开发。

5.2.2 系统模块组成

本系统总共划分为四大模块，分别为系统管理模块、个人中心模块、产量预测模

块和可视化图表模块。

系统管理模块主要包括展示系统主要模块功能、可视化用户信息数据和展示系统总体运行情况。

1) 个人中心模块主要分为两个部分，首先是账户信息管理功能，用户可以本模块确认账号信息，并拥有更改相关账户信息的权限。修改密码模块则为用户提供修改密码服务，用户只需要填写正确的旧密码，再输入新密码，并通过新密码验证即可完成密码的更改。

2) 产量预测模块主要分为两个部分，一个是数据录入功能，此部分用户可手动在系统上传新获取的数据，此功能支持上传 csv 格式的数据，更新的数据为产量预测模型的提供数据输入支撑。另一个为产量预测功能，用户同样是上传 csv 格式的数据，数据内容为某站点近 40 年的气象数据，系统将获取的本地数据传入后端，完成产量预测工作，并将预测结果展现在系统前端。

3) 可视化图表模块主要完成气象数据、模型输入数据等的可视化，将数据以图表的形式展现给用户，能够更直观地分析玉米生长的影响因素。




图 5.2 功能模块设计图

Fig5.2 Functional module design diagram

5.2.3 数据库表设计

数据库表设计是构建数据库驱动应用程序的关键方面。一个设计良好的数据库表可以确保数据被有效地组织、存储和检索。其对于系统的设计与实现起到至关重要的作用。数据库表要确保数据的准确、一致和完整。它强制执行数据完整性规则，如唯

一约束、主键和外键以及数据类型。并通过减少表扫描次数和优化索引来提高查询性能。它有助于改善应用程序的响应时间和用户体验。它使向应用程序添加新特性和功能变得更容易。它保证了数据完整性，提高了性能、可扩展性、可维护性和安全性。设计不良的数据库表可能导致数据不一致、性能低下和安全漏洞。因此，投入时间和精力设计一个健壮、高效的数据库表是非常必要的。

本文开发的玉米产量预测分析原型系统数据库表名如表 5.1 所示，主要包含：注册信息表、用户信息表、系统实时数据表和实验信息记录表。

表 5.1 数据库表清单

Tab5.1 List of database tables

序号	名称	表名
1	注册信息表	auth_user
2	用户信息表	auth_permission
3	系统实时数据表	sys_info
4	实验信息记录表	pre_record

数据库实体关系图（E-R 图）如图 5.3 所示：




图 5.3 系统 E-R 图

Fig5.3 System E-R diagram

注册信息表 auth_user：该表记录着该系统所有注册用户的注册信息，包含了用户注册 id、用户名、账户密码和账户创建时间。主键为 user_id，账户与密码由用户自己

填写，注册成功后在数据库存档。注册时会触发系统字符长度验证，长度应保持在 8 字符到 20 字符，并且密码要求至少包含数字、字母与符号中的两种。具体信息如表 5.2 所示。

表 5.2 注册信息表

Tab5.2 Registration information form

序号	字段名	类型	长度	允许为空	描述	主键
1	user_id	bigint	64	否	用户主键 id	是
2	user_name	varchar	32	否	用户名	否
3	user_password	varchar	32	否	用户密码	否
4	create_time	timestamp	255	否	账户创建时间	否

用户信息表 auth_permission：该表是在用户注册成功时生成，包含了用户账号的相关信息，并且相关信息可以通过前端修改，并在数据库实时更新。用户信息表包括主键 id、注册信息表外键 id、用户名、用户密码、账户创建时间、用户权限、职业和工作经验。其中，用户权限，0 代表实验人员，1 代表科研人员，2 代表农户。

表 5.3 用户信息表

Tab5.3 User information table

序号	字段名	类型	长度	允许为空	描述	主键
1	sys_id	bigint	64	否	主键 id	是
2	user_id	bigint	64	否	外键	否
3	user_name	varchar	32	否	用户名	否
4	user_password	varchar	32	否	用户密码	否
5	create_time	timestamp	255	否	账户创建时间	否
6	user_authority	int	64	否	用户权限	否
7	user_job	varchar	32	是	职业	否
8	user_ex	varchar	32	否	工作经验	否
9	user_aim	varchar	255	是	系统用途	否
10	user_unit	varchar	255	否	所属机构	否
	user_photo	image	102400	否	用户头像	否

系统实时数据表 sys_info: 系统对于自身的运营及使用情况进行了统计, 统计信息保存在系统实时数据表中, 该表包含了注册用户数统计、实时样本总数统计和预测次数统计四类信息, 每当有用户使用系统, 都会触发该数据库表的更新。

表 5.4 系统实时数据表

Tab5.4 System real-time data tables

序号	字段名	类型	长度	允许为空	描述	主键
1	id	int	64	否	主键 id	是
2	regist_num	int	64	否	注册用户数	否
3	data_view	int	64	否	数据样本总数	否
4	sys_view	int	64	否	系统浏览量	否
5	pred_num	int	64	否	预测次数	否

实验信息记录表 pre_record: 该表记录了用户在系统进行玉米产量预测的相关信息, 其中包含主键实验 id、实验所选取的种植区域, 具体区分到州、线和站点, 并且每个站点都有唯一的站点 id, 也同样作为表格信息记录备案, 此外, 实验信息记录表还记录了实验日期、实验用户外键 id 和预测结果值, 具体信息如表 5.5 所示。

表 5.5 实验信息记录表

Tab5.5 Experimental information log sheet

序号	字段名	类型	长度	允许为空	描述	主键
1	id	int	64	否	主键 id	是
2	state_name	varchar	255	否	州名	否
3	county_name	varchar	255	否	县名	否
4	site_name	varchar	255	否	站点名	否
5	site_id	int	64	否	站点 id	否
6	exp_time	timestamp	20	否	实验日期	否
7	user_id	int	64	否	实验用户外键	否
8	pred_value	varchar	255	否	预测值	否

5.3 系统实现

(1) 登录界面

该模块作为用户登录以及用户注册，对于新接触系统的研究人员及农户，需要通过下方“用户注册”按钮进行注册，注册信息主要包括用户名、密码、职位、系统用途、所属机构。注册成功后，用户即可返回登录界面，输入用户名以及密码完成登录，登录界面如图 5.4 所示。




图 5.4 系统注册登录界面

Fig5.4 System registration and login screen

(2) 系统首页界面

本模块主要显示了用户登录后的系统首页信息及主要功能展示，具体系统首页界面如图 5.5 所示。用户登录成功后，会展示登录用户信息、系统主要功能、系统用户信息以及网站实时数据统计模块。登录用户信息包括头像和用户名；系统主要功能包括首页、个人中心、数据统计和可视化图表；系统用户信息包括用户创建时间饼状图、最新注册用户信息；网站实时数据主要包括注册用户统计、实时样本总数统计、实时系统流量统计和预测次数统计等。此外，用户可以点击系统界面右上角退出登录按钮即可退出系统并跳转到登录界面，下文介绍的几个模块同样可实现此功能。




图 5.5 系统首页界面

Fig5.5 System home screen

(3) 个人中心界面

当用户登录成功后，可以在个人中心界面查看到自己的注册信息，并且可以对部分信息进行修改，主要用户信息包括用户名、职位、工作经验、系统用途、所属机构以及头像。其中，用户名无法更改，职位、工作经验、系统用途、所属计划以及头像可更改。具体页面展示如图 5.6 所示。




图 5.6 用户个人信息界面

Fig5.6 User personal information screen

个人中心的第二个功能是密码修改功能，用户可以通过点击个人中心第二个按钮

可以进行修改密码操作，用户只需填写正确的原始密码，并填写合规的新密码并核验即可完成修改，具体功能展示如图 5.7 所示。




图 5.7 用户密码修改界面

Fig5.7 User password change screen

(4) 产量预测界面

该模块主要包括玉米气象数据的录入和产量预测结果的输出。用户可以通过第一个功能，点击选择文件按钮，从本地上传 csv 数据，完成新数据的录入和数据库的更新，具体界面如图 5.8、图 5.9 所示。




图 5.8 选择数据文件界面

Fig5.8 Select data file screen



图 5.9 数据录入详情界面

Fig5.9 Data entry details screen

第二个功能为产量预测，初始化界面较为简洁，仅显示三个下拉框，分别选择州、县和站点。站点信息确定后，点击提交按钮，系统会向后端数据库发出请求，调用该站点近四十年气象数据，应用于深度学习模型，进行玉米产量预测，并输出最新一年的产量预测值，实现产量预测功能。具体界面如图 5.10、图 5.11 所示。




图 5.10 站点选择界面

Fig5.10 Site selection screen



图 5.11 产量预测输出界面

Fig5.11 Output screen for yield forecasting

(3) 数据分析可视化界面

该模块主要实现对数据气象数据以及相关分析结果进行可视化，具体界面如图 5.12 所示，用户通过点击该模块的各个功能，并通过三个下拉框选择具体的产量预测区域，完成对应区域的数据展示。




图 5.12 数据分析可视化界面

Fig5.12 Data analysis visualisation interface

如图 5.13 所示为可视化图表模块的玉米产量预测功能，通过下拉框选择站点信息，点击提交，下方将近 40 年的年度降水量以折线图的形式可视化，用户可以通过本折线

图观察历年降水量趋势，这一功能能够玉米种植用户提供科学指导。




图 5.13 玉米产量可视化界面

Fig5.13 Maize yield visualisation interface

如图为可视化图表模块的原始气象数据可视化功能，与玉米产量可视化功能相同，用户只需要点击对应的功能，并选择区域，单击“提交”按钮，即可对该区域近四十年的年平均最高温度、年平均最低温度和年度降水量可视化，具体展示如图 5.14、图 5.15 和图 5.16 所示。



图 5.14 最高温度可视化界面

Fig5.14 Maximum temperature visualisation screen



图 5.15 最低温度可视化界面

Fig5.15 Minimum temperature visualisation screen



图 5.16 年度降水量可视化界面

Fig5.16 Annual precipitation visualisation interface

如图 5.17 所示为系统的最后一个功能：特征参数分布，选择种植区域，以 IA-ADAMS-CORNING 为例，点击提交即可展示 GDD、KDD、PRCP 三个模型输入参数的分布情况，初始界面无法展示完全，下滑即可查看剩余部分，展示结果如图 5.18 所示。



图 5.17 特征参数可视化界面 1

Fig5.17 Visualisation interface for feature parameters 1




图 5.18 特征参数可视化界面首页 2

Fig5.18 Visualisation interface for feature parameters 2

5.4 系统测试

系统测试是软件开发生命周期的重要组成部分。它的主要目标是确保所开发的软件在其预期环境中正确地满足指定的需求和功能。系统测试验证和确认软件在其预期

环境中符合指定的要求和功能。系统测试最重要的是发现软件中的缺陷和 bug、提高软件的质量。系统测试确保软件在其预期环境中与其他系统和应用程序兼容。系统测试通过识别和修复可能影响软件可用性的问题来帮助增强用户体验。总之，系统测试在确保所开发的软件满足指定的需求、在其预期环境中正确的功能，以及可靠、高效和用户友好方面起着至关重要的作用。

(1) 用户注册与登录测试

表 5.6 用户注册功能测试结果

Tab5.6 User registration fun

测试用例与测试方法	预期结果	测试结果
输入合规的账户与密码	注册成功	通过
输入已存在账户	注册失败，提示“用户已存在”	通过
输入用户名字符数过长	注册失败，提示“用户名过长”	通过
不输入密码	注册失败，提示“密码未填写”	通过
输入密码过于简单	注册失败，提示“密码至少包含数字、字母、符号中的两种”	通过

用户注册测试分为两个方向，首先测试用户使用合规的输入，看用户能否正常注册；如显示用户注册成功，还需测试注册账号是否录入数据库，即测试用户能否正常登录。第二个方向应测试用户使用违规的输入进行注册，看是否会弹出违规提示，并引导用户使用合规的输入继续完成注册，测试结果如下：

表 5.7 用户登录功能测试结果

Tab5.7 User login test results

测试用例与测试方法	预期结果	测试结果
输入正确的用户名与密码	登录成功	通过
输入错误的用户名与密码	登录失败，提示“用户名或密码错误”	通过
输入用户名字符数过长	登录失败，提示“用户名过长”	通过
空密码登录	登录失败，提示“密码未填写”	通过

用户登录测试分为两个方向，首先输入正确的账户密码，测试用户是否能够正常登入系统，查看 session 中是否保存了 userId，确认存在则后退出，并确认 userId 是否

删除。第二个方向是尝试输入错误的账户密码、过长的用户名和空密码登录，验证是否登录失败并提示错误信息，具体测试结果如表 5.7 所示。

(2) 个人中心模块测试

该模块主要包含个人信息与修改密码两部分，分别测试个人信息修改功能与修改密码功能是否正确，并测试输入错误信息时，系统是否会有错误信息提示。例如，当用户在修改密码时，输入简单的数字密码，而系统规则时至少输入数字、字母和符号中的两种，此时，系统应该提示并报错，提醒用户重新输入新密码。具体测试结果如下图 5.8 所示。

表 5.8 个人中心功能测试结果

Tab5.8 Test results of the Personal Centre function

测试用例与测试方法	预期结果	测试结果
修改个人信息界面，输入正确的信息，点击“修改”按钮	修改成功，且左侧菜单栏头像发生变化	通过
修改个人信息界面，尝试修改用户名	修改失败，用户名无法修改	通过
修改个人信息界面修改用户头像，尝试上传错误格式头像	修改失败，提示“头像格式错误，请重新选择”	通过
修改密码界面，输入正确的数据，点击“修改”按钮	修改成功	通过
修改密码界面，输入错误的原始密码	修改失败，提示“原始密码输入错误”	通过
修改密码界面，输入格式错误的新密码	修改失败，提示“密码至少包含数字、字母、符号中的两种”	通过
修改密码界面，只输入一遍新密码，不重复输入，点击“修改”按钮	修改失败，提示“请确认新密码”	通过

(3) 产量预测模块测试

本部分主要包含数据录入与产量预测两个功能，测试分为数据录入部分测试与产量预测功能测试。首先为数据录入功能测试，测试方向为区域选择测试和文件导入测试。其次为产量预测部分，测试方向为文件导入测试和产量预测测试。具体测试结果

如下表 5.9 所示。

表 5.9 产量预测功能测试结果

Tab5.8 Test results of the personal centre function

测试用例与测试方法	预期结果	测试结果
按照顺序依次正确选择，并点击“提交”按钮	正确显示区域信息，数据上传成功	通过
点击“选择文件”按钮，选择正确文件	“选择文件”右侧出现文件信息	通过
点击“选择文件”按钮，选择文件类型错误	“选择文件”右侧不显示文件信息，提示“文件类型错误”	通过
点击“选择文件”按钮，选择文件类型正确，文件维度错误的 csv 文件	“选择文件”右侧显示文件信息，提示“数据维度错误”	通过
点击“选择文件”按钮，选择正确文件，点击“产量预测”按钮	显示预测结果“当前区域为 xx-xx-xx，玉米产量预测结果为 xxx”	通过

（4）可视化图表模块测试

表 5.10 可视化功能测试结果

Tab5.9 Yield prediction function test results

测试用例与测试方法	预期结果	测试结果
按照顺序依次正确选择，并点击“提交”按钮	正确显示区域信息，并获取可视化结果	通过
先进行县级区域选择	选取失败，下拉框无法显示县级名称	通过
先进行站点区域选择	选取失败，下拉框无法显示站点名称	通过
只选择州、线信息，而不选取站点信息，并点击“提交”按钮	获取失败，数据可视化失败，提示“区域信息错误”	通过

本部分主要测试区域选择与数据可视化结果。首先测试该模块三个下拉框部分进行测试，即测试州、县、站点的选择框能否正常获取区域信息与优先级问题。其次测试数据可视化是否能够正常进行，具体测试结果如表所示。

5.5 本章小结

本章完成了玉米产量预测分析原型系统的设计与实现。首先对该系统进行了需求分析，讨论了本系统需要实现的功能，满足实际使用需求。完成了系统的整体架构设计，从而保障了系统的完整性。基于需求分析实现了玉米产量预测分析原型系统的系统设计，将系统功能分为四大模块，介绍了每个模块完成的各项功能。最后，本章还完成了系统的各项细节测试，保障了系统的正常运行。

总结与展望

一、论文总结

本文基于当前玉米种植产业中产量预测与分析工作的实际需求，针对玉米生长预测分析原型系统空缺，产量预测研究预测精度较低，尚未考虑到长时间序列造成的数据间相关性下降等问题，以美国雨养玉米种植区的气候数据与历年产量数据为研究对象，构建了基于 CNN-BiLSTM 融合注意力机制的玉米产量预测模型，完成了玉米产量预测分析实验，并按照软件工程化要求，设计并开发了一套用于玉米产量预测生长分析原型系统。主要成果如下：

（1）构建了玉米产量预测模型

针对研究区域的气候特性以及玉米作物本身的生长特性，分析了对玉米生长影响最大的三个影响因素，最高温度、最低温度与降水量，并转化为气候累积参数作为模型输入。并根据已有研究的模型方法，优化并提出了一种 CNN-BiLSTM 融合注意力机制的产量预测模型，并验证了 BiLSTM 模型的有效性和准确性。

（2）完成了玉米产量预测实验与影响因素分析

产量预测实验部分主要分为消融实验、对比试验。消融实验主要验证了模型中各个模块的有效性与必要性；对比试验将本文所构建的产量预测模型与 CNN-RNN、EWA、DeepCropNet 三种模型进行对比，实验结果均优于以上模型；实验通过对各个州进行单独的产量预测分析，预测精度得到提升。针对不同地区，不同的气候条件会对模型的预测性能产生影响。实验还通过置换法逐个分析了不同气候数据和不同生长期对玉米生长与产量的影响关系，以此探讨对玉米生长最重要的特征与时期。

（3）实现了玉米产量预测生长分析原型系统

按照软件工程化要求，设计并研发了玉米产量预测分析原型系统，系统主要功能包括：个人信息的查看与修改、玉米生长环境数据的录入、玉米产量预测以及各类气候数据与模型输入数据的可视化展现。基于 MySQL 搭建了玉米产量预测数据库，数据库存储了用户信息、系统实时数据和实验信息记录等信息。最后通过 Java 开发语言、SpringBoot 框架和自带的 Web 开发组件进行实现了前后端的独立开发，并以 FastJson 作为数据交互的处理工具、通过 Runtime 工具实现深度学习模型的调用，完成了数据

的交互，并最终完成玉米产量预测分析原型系统的研发。

二、研究展望

本文提出的 CNN-BiLSTM 融合注意力机制模型在使用气象数据作为输入的情况下，对于玉米的产量预测取得了较好的效果。研究还存在一些可优化的地方，将作为未来工作的主要方向：

（1）由于当前中国相关数据获取难度较大，本文所选取的研究区域为美国八个州的雨养玉米带玉米种植区，此区域存在开源数据集，并已有相近主题的研究成果可供学习。目前正在收集与处理中国玉米种植区相关天气与产量数据，下一步工作将尝试在中国玉米种植区域开展实验。

（2）本文选取的输入数据为最高温度、最低温度和降水量，考虑因素相对简单，可以尝试添加遥感数据和土壤数据，丰富模型输入的特征维度，以此达到更精确的预测结果。

参考文献

- [1] 罗锡文, 张泰岭, 洪添胜. “精细农业”技术体系及其应用[J]. 农业机械学报, 2001(02):103-106.
- [2] 汪懋华. “精细农业”发展与工程技术创新[J]. 农业工程学报, 1999(01):7-14.
- [3] 徐权, 郭鹏, 祁佳峰, 等. 基于无人机影像的 SEGT 棉花估产模型构建[J]. 农业工程学报, 2020,36(16):44-51.
- [4] 丛佳慧, 田兴帅, 赵向阳, 等. 基于 DSSAT 模型和天气预报策略预测农户当季玉米产量[J]. 玉米科学, 2022,30(04): 62-72.
- [5] 姜明宇. 不同空间尺度下的美国大豆估产方法研究[D]. 山东农业大学, 2022.
- [6] Yann L, Yoshua B, Geoffrey H. Deep learning[J]. Nature: International weekly journal of science, 2015,521(7553).
- [7] 司亚超, 孙皓月, 徐小君. 新工科背景下多学科交叉融合的人才培养模式研究——以计算机学科为例[J]. 中国多媒体与网络教学学报（上旬刊）, 2021(04):77-79.
- [8] Klompenburg T V, Kassahun A, Catal C. Crop yield prediction using machine learning: A systematic literature review[J]. Computers and Electronics in Agriculture, 2020,177:105709.
- [9] Li, Y, Yu K, Albert P, et al. Toward building a transparent statistical model for improving crop yield prediction: Modeling rainfed corn in the U.S[J]. Field Crops Research, 2019, 234.
- [10] 贾梦琦, 蔡振江, 胡建, 等. 基于机器学习的粮食产量预测模型研究[J]. 河北农业大学学报, 2021,44(03):103-108.DOI:10.13320/j.cnki.jauh.2021.0055.
- [11] 李远斌, 卜祥峰, 丁云鸿, 等. 小麦产量预测模型综述[J]. 智慧农业导刊, 2023,3(05):13-19.
- [12] Thomas v, Ayalew K, Cagatay C. Crop yield prediction using machine learning: A systematic literature review[J]. Computers and Electronics in Agriculture, 2020,177.
- [13] 张向君, 陈优良, 肖钢. 基于机器学习的农作物产量预测研究综述[J]. 安徽农学报, 2021,27(03):117-119+134.

- [14] Yann L, Yoshua B, Geoffrey H. Deep learning[J]. Nature: International weekly journal of science, 2015,521(7553).
- [15] 周亮, 慕号伟, 马海姣, 等. 基于卷积神经网络的中国北方冬小麦遥感估产[J]. 农业工程学报, 2019,35(15):119-128.
- [16] Ren, Y, Li, Q, Du, X, et al. Analysis of Corn Yield Prediction Potential at Various Growth Phases Using a Process-Based Model and Deep Learning[J]. Plants 2023, 12, 446.
- [17] 龚红菊, 姬长英. 基于图像处理技术的麦穗产量测量方法[J]. 农业机械学报, 2007(12):116-119.
- [18] 龚红菊, 於海明, 姬长英. 基于分形理论的水稻单产计算机视觉预测技术[J]. 农业机械学报, 2010,41(08):166-170.
- [19] Avinash K, Bikash R. Paddy acreage mapping and yield prediction using sentinel-based optical and SAR data in Sahibganj district, Jharkhand (India)[J]. Spatial Information Research, 2019,27(4).
- [20] 程伟, 张燕平, 赵姝. 商空间理论框架下的 SVM 产量预测模型研究[J]. 中国农业大学学报, 2009,14(05):135-139.
- [21] 汪小寒, 张燕平, 赵姝, 等. 作物产量预测的粒度分析法[J]. 计算机工程与应用, 2012,48(25):224-228.
- [22] Kawsar A, Mohammad N, Leonid R, et al. Using artificial neural network and satellite data to predict rice yield in Bangladesh[P]. SPIE Optical Engineering + Applications, 2015.
- [23] 匡奕敦. 基于 neuralnet 人工神经网络的农作物预测模型研究[J]. 湖北农业科学, 2022,61(14):178-182.
- [24] Jiang H, Hu H, Zhong R, et al. A deep learning approach to conflating heterogeneous geospatial data for corn yield estimation: A case study of the US Corn Belt at the county level[J]. Global Change Biology, 2020,26(3).
- [25] Lin T, Zhong R, Yu W, et al. DeepCropNet: a deep spatial-temporal learning framework for county-level corn yield estimation[J]. Environmental Research, 15, 034016.
- [26] Khaki S, Wang L, Archontoulis S. A CNN-RNN Framework for Crop Yield Prediction[J]. Frontiers in Plant Science, 2020.

- [27] Saeed K, Wang L. Crop Yield Prediction Using Deep Neural Networks[J]. *Frontiers in Plant Science*, 2019,10.
- [28] 刘峻明, 和晓彤, 王鹏新, 等. 长时间序列气象数据结合随机森林法早期预测冬小麦产量[J]. *农业工程学报*, 2019,35(06):158-166.
- [29] Shahhosseini M, Hu G, Archontoulis S. Forecasting Corn Yield With Machine Learning Ensembles[J]. *Front. Plant Sci.* 11:1120.
- [30] 郑静, 佟玲, 赵金淼, 等. 基于田间调查数据分析漳河灌区水稻灌溉水生产力分布异质性及其影响因素[J]. *中国农业气象*, 2022,43(08):612-621.
- [31] 成林, 刘荣花. 农学模式在冬小麦产量动态预报中的应用[J]. *气象与环境科学*, 2017,40(02):28-32.
- [32] 赵娟, 彭彦昆. 基于高光谱图像纹理特征的牛肉嫩度分布评价[J]. *农业工程学报*, 2015,31(07):279-286.
- [33] 金飞. 玉米产量农业气象预测预报的基本模型[J]. *黑龙江科技息*, 2010(16):19.
- [34] 徐建军, 王硕昌. 基于 VMD-分形理论的短期电力负荷预测[J]. *吉林大学学报(信息科学版)*, 2022,40(05):744-751.DOI:10.19292/j.cnki.jdxxp.2022.05.018.
- [35] 张琦锦, 郭映映, 李素文, 等. 基于主成分分析的 RBF 神经网络预测 SO₂ 浓度[J]. *大气与环境光学学报*, 2022,17(05):550-557.
- [36] 陈锡康, 潘晓明. 从农作物产量预测看发展交叉科学研究的重要性[J]. *中国科学院院刊*, 2000(01):47-48.
- [37] 姜新. 河南省粮食产量影响因素和预测方法研究 [J]. *中国农学通报*, 2019,35(01):154-158.
- [38] Rojas O . Operational maize yield model development and validation based on remote sensing and agro-meteorological data in Kenya[J]. *International Journal of Remote Sensing*, 2007, 28(17-18):3775-3793.
- [39] Ruan G , Li X , Yuan F , et al. Improving wheat yield prediction integrating proximal sensing and weather data with machine learning[J]. *Computers and Electronics in Agriculture*, 2022, 195:106852-.
- [40] 许德刚, 邢奎杰, 李凡, 等. 粮食产量影响因素分析及预测方法研究[J]. *粮食与油*

脂, 2022,35(10):46-50.

[41] Leo B. Random Forests[J]. Machine Learning, 2001,45(1).

[42] Corinna C, Vladimir V. Support-Vector Networks[J]. Machine Learning, 1995,20(3).

[43] 杜树新, 吴铁军. 用于回归估计的支持向量机方法[J]. 系统仿真学报, 2003(11):1580-1585+1633.

[44] Landahl H, McCulloch W, Walter P. A statistical consequence of the logical calculus of nervous nets[J]. The Bulletin of Mathematical Biophysics, 1943,5(4).

[45] 卢宏涛, 张秦川. 深度卷积神经网络在计算机视觉中的应用研究综述[J]. 数据采集与处理, 2016,31(01):1-17.

[46] 张润, 王永滨. 机器学习及其算法和发展研究[J]. 中国传媒大学学报(自然科学版), 2016,23(02):10-18+24.

[47] 杨丽, 吴雨茜, 王俊丽, 等. 循环神经网络研究综述[J]. 计算机应用, 2018,38(S2):1-6+26.

[48] 王余宽, 谢新连, 马昊, 等. 基于滑动窗口 LSTM 网络的船舶航迹预测[J]. 上海海事大学学报, 2022,43(01):14-22.

[49] 樊继慧, 滕少华, 金弘林. 基于改进 Sigmoid 卷积神经网络的手写体数字识别[J]. 计算机科学, 2022,49(12):244-249.

[50] Joshi V, Kazula M, Coulter J , et al. In-season weather data provide reliable yield estimates of maize and soybean in the US central Corn Belt[J]. International Journal of Biometeorology, 2021:1-14.

[51] Butler E , Huybers P . variations in the sensitivity of us maize yield to extreme temperatures by region and growth phase variations in the sensitivity of us maize yield to extreme temperatures by region and growth phase[J]. 2018.

[52] 孙黎霞, 白景涛, 周照宇等. 基于双向长短期记忆网络的电力系统暂态稳定评估[J]. 电力系统自动化, 2020,44(13):64-72.

[53] 刘建伟, 赵会丹, 罗雄麟, 许望. 深度学习批归一化及其相关算法研究进展[J]. 自动化学报, 2020,46(06):1090-1120.

[54] 马兆骏, 帅艳民, 邵聪颖, 等. 基于 WOFOST 模型分析不同气候情景对辽宁典型

雨养春玉米产量的影响[J]. 中国农业气象, 2021,42(11):939-950.

[55] 宋彦, 汪小中, 赵磊, 等. 基于近红外光谱技术的眉茶拼配比例预测方法[J]. 农业工程学报, 2022,38(02):307-315.

[56] 闫政旭, 秦超, 宋刚. 基于 Pearson 特征选择的随机森林模型股票价格预测[J]. 计算机工程与应用, 2021,57(15):286-296.

[57] 江知航, 王艳霞, 颜家均, 等. 基于 BILSTM 的棉花价格预测建模与分析[J]. 中国农机化学报, 2021,42(08):151-160.

[58] 倪水平, 李慧芳. 基于一维卷积神经网络与长短期记忆网络结合的电池荷电状态预测方法[J]. 计算机应用, 2021,41(05):1514-1521.

[59] Schwalbert R, Amado T, Nieto L, et al. Mid-season county-level corn yield forecast for US Corn Belt integrating satellite imagery and weather variables[J]. Crop Science, 2020, 60.

[59] 李锋. 2020 年中国和美国玉米生产成本差异预估及技术需求预估分析[J]. 安徽农业科学, 2019,47(15):220-223.

[60] High Plains Regional Climate Center, 2020: County Level Data[R]. Access 17 June 2020, <https://hprcc.unl.edu/datasets.php?set=CountyData>.

[61] United States Department of Agriculture.NASS U 2017 Quick stats[R]. National Agricultural Statistics Service, 1980-2020. <http://quickstats.nass.usda.gov>

[62] Shahhosseini M , Hu G , Khaki S , et al. Corn Yield Prediction with Ensemble CNN-DNN[J]. 2021.

[63] Si A, Rs B, Msk A. Multi-model projections of trade-offs between irrigated and rainfed maize yields under changing climate and future emission scenarios. 2021.