

基于 CNN-RNN 网络的中国冬小麦估产

赫晓慧¹, 罗浩田¹, 乔梦佳², 田智慧^{1*}, 周广胜³

(1. 郑州大学地球科学与技术学院, 郑州 450001; 2. 郑州大学信息工程学院, 郑州 450001;
3. 中国气象科学研究院郑州大学生态气象联合实验室, 郑州 450001)

摘要: 在大范围内快速、准确地预估作物产量, 对作物管理、粮食安全、粮食贸易和决策有重要意义。遥感为大规模作物估产提供了便利, 大多数研究者结合深度学习和遥感影像取得了较好的结果。然而, 农作物生长状态随时间变化, 其产量具有非线性时空特征, 单一的深度学习方法无法充分利用影像信息。因此, 该研究提出了一种基于卷积神经网络 (Convolutional Neural Networks, CNN) 和门控循环单元 (Gated Recurrent Unit, GRU) 混合神经网络估产模型 (CNN-GRU), 利用 CNN 从多光谱遥感影像中提取丰富的空间-光谱特征, 在此基础上, 结合 GRU 从多时相遥感影像中自适应学习冬小麦生育期各阶段之间的时间依赖, 从多尺度融合冬小麦的生长特征并对其产量进行回归预测。该研究以全国冬小麦主产区为研究区, 选取 2001—2018 年 MODIS 影像和冬小麦产量数据, 构建了冬小麦估产数据集, 并验证了 CNN-GRU 估产模型的性能。结果表明: 1) 以 2016—2018 年估产样本作为测试集, CNN-GRU 估产模型的均方根误差 (Root Mean Square Error, RMSE) 年平均值为 818.3 kg/hm², 相较于 CNN、GRU、支持向量回归 (Support Vector Regression, SVR)、随机森林 (Random Forest, RF) 和决策树 (Decision Tree, DT) 模型分别降低了 20.13%、18.81%、29.51%、34.84% 和 36.57%; 2) 将冬小麦整个生育期划分为 6 个时间窗, CNN-GRU 估产模型在灌浆-成熟期时精度最高, RMSE 为 817 kg/hm², 而抽穗-开花期的 RMSE 为 823 kg/hm², 相较于灌浆-成熟期低 0.7%。因此, 该估产模型有能力提前 2 个月预测全国冬小麦主产区产量。

关键词: 产量; 模型; 卷积神经网络; 循环神经网络; 冬小麦; 预测; 多时相遥感影像

doi: 10.11975/j.issn.1002-6819.2021.17.014

中图分类号: TP79

文献标志码: A

文章编号: 1002-6819(2021)-17-0124-09

赫晓慧, 罗浩田, 乔梦佳, 等. 基于 CNN-RNN 网络的中国冬小麦估产[J]. 农业工程学报, 2021, 37(17): 124-132.

doi: 10.11975/j.issn.1002-6819.2021.17.014 <http://www.tcsae.org>

He Xiaohui, Luo Haotian, Qiao Mengjia, et al. Yield estimation of winter wheat in China based on CNN-RNN network[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(17): 124-132. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.2021.17.014 <http://www.tcsae.org>

0 引言

农业是人类社会发展和稳定的基础, 而中国是人口大国, 粮食安全尤为重要^[1]。小麦是中国的主要粮作物之一, 据统计, 2020 年小麦播种面积为 23.38 万 hm², 总产量 13 425 万 t, 占全国粮食总产量的 1/5, 因此, 准确、及时地预测中国小麦产量对全国粮食安全乃至世界农业发展至关重要^[2-3]。

近几十年来, 国内外学者围绕着作物产量预测、粮食安全等问题展开了深入而广泛的研究。许多学者基于经验统计模型^[4]和作物生长模拟模型^[5]等传统的估产模型预测作物产量, 这些模型通常对于某一区域的特定农作物产量预测精度较高, 但很难推广到拥有大规模种植区域以及需要进行多农作物产量预估的地区和国家^[6-8]。

随着传感器的发展, 遥感卫星可以获得大量高质

量、高时空分辨率的图像, 为大尺度农作物产量预测提供了可能。遥感卫星捕获的光谱信息能充分反映农作物的生长状态, 以往的研究者大多倾向于从影像中提取作物相关指标来建立与作物产量之间的关系^[9-11], 如归一化差异植被指数 (Normalized Difference Vegetation Index, NDVI)、增强植被指数 (Enhanced Vegetation Index, EVI) 等^[12-14], 由于农作物生长环境复杂, 植株状态多变, 仅依靠植被指数可能无法完全反映影像中农作物的生长特征。

为了充分利用遥感图像中的光谱信息, 提升农作物估产的准确性, 研究者逐渐将深度学习应用到了农作物估产中。如 Qi 等^[15-16]通过构建两个独立分支的卷积神经网络 (Convolutional Neural Networks, CNN) 结构分别处理高分辨率 RGB 图像和多光谱影像, 整合了影像中的空间-光谱信息进行估产, 并发现水稻成熟期有较高精度的产量预测; Nevavuori 等^[17]构建了基于无人机获取的 NDVI 和 RGB 图像的 CNNs 作物产量预测模型, 结果表明基于 RGB 图像的 CNN 模型优于 NDVI 数据。尽管基于 CNN 的方法取得了较好的结果, 但是这些研究仅仅基于农作物某个特定生长期的影像对产量进行预测, 如 Son 等^[18-20]发现在农作物的生育后期的预测精度最高。然而,

收稿日期: 2021-06-16 修订日期: 2021-08-20

基金项目: 河南省重大科技专项—面向超算的黄河模拟器构建与服务关键技术研究 (201400210900)

作者简介: 赫晓慧, 博士, 教授, 博士生导师, 研究方向为遥感大数据智能挖掘。Email: hexh@zzu.edu.cn

*通信作者: 田智慧, 博士, 教授, 博士生导师。研究方向为高性能地理计算。Email: iezhtian@zzu.edu.cn

农作物的生长是一个生物量长时间累积的过程, 包括多个生育期。已有研究表明, 在作物生长期内的不同时相遥感图像中, 作物信息与其产量关系的显著性具有较大差别^[21-25]。因此, 综合利用农作物生长过程中的多时相遥感影像进行估产, 有助于掌握不同时间阶段的农作物生长状况, 提升产量预测精度^[26-30]。虽然 CNN 被广泛用于从遥感影像中提取光谱特征^[31]。但是由于结构的限制, CNN 无法对时间序列进行建模^[32-34]。因此, 仅利用 CNN 无法从多时相影像提取中作物生长的特征。因此, 如何在提取遥感影像空谱特征的基础上, 为长时间序列的遥感影像进行建模, 是提升农作物产量预测的关键问题。

为解决上述问题, 本文将全国冬小麦主产区作为研究区域, 并选取研究区 2001—2018 年县级冬小麦生育期的时间序列遥感影像作为数据源, 同时设计了一个端到端的深度学习估产网络从多时相遥感影像中自动学习空间-光谱-时间联合特征。具体来说, 首先将每个时间节点的冬小麦影像独立地嵌入卷积子网模块, 在卷积子网充分提取影像中的空间-光谱特征之后, 将其按时间序列传递到递归子网单元, 整合冬小麦整个生育期的时间信息。本文所提出的农作物产量预测网络旨在能够从时间序列遥感影像中多尺度、全方位地挖掘作物生长特征与冬小麦产量之间的复杂关系, 以实现大尺度的冬小麦产量预测。

1 研究区及数据

1.1 研究区

本文选取全国冬小麦主产区作为研究区域, 包括 14 个省和自治区: 河北、陕西、江苏、浙江、安徽、山东、河南、湖北、四川、云南、陕西、甘肃、宁夏回族自治区和新疆维吾尔自治区, 共 1 713 个区县。

1.2 数据源

1.2.1 MODIS 影像

本文采用中等分辨率成像光谱仪 (MODIS) 卫星图像, 该卫星影像有较高的时间分辨率, 能获取足够多检测冬小麦产量的多时相影像。数据下载自 Google Earth Engine (<https://earthengine.google.com/>)。本文主要使用 3 种 MODIS 产品数据, 其时间覆盖为 2001—2018 年。MOD09A1 V6 产品提供了 500 m 和 8 d 的地表反射率, 包括 7 个波段, 如红波段、蓝波段和近红外波段等, 其采集的地表反射率影像可以反映作物的生长状态和环境^[35-36]; MOD11A2 V6 产品可在 1 km×1 km 的网格中提供每 8 d 的昼夜地表温度影像, 昼夜地表温度与作物冠层温度联系紧密, 有利于进行产量预测^[37]。MCD12Q1 V6 产品以年为单位提供全球土地覆盖类型, 其中包括草原、农田、城市、水体等 17 类土地类型, 其空间分辨率为 500 m; 数值比例表示把原始光谱值从整型转化为浮点型的比例系数; 数值范围表示原始数据中光谱值的最大值和最小值范围, 超出数值范围的则是无效数据。

1.2.2 产量数据

冬小麦产量数据是以区县为单位的统计数据, 其中 2001—2008 年的冬小麦各区县年平均产量及播种面积数

据来源于中国科学院资源学科创新平台^[38] (<http://www.data.ac.cn>), 2009—2018 年数据收集自各省、市、区县统计年鉴。

1.3 数据预处理

为统一影像分辨率, 将 MOD11A2 的空间分辨率重采样为 500 m, 再利用 MCD12Q1 中农作物掩膜数据提取各区县的农作物种植面积, 由于农作物掩膜不能区分具体的农作物类型, 因此需要结合作物产量数据, 剔除产量较低和影像中农作物像素点较少的县, 即将县域作物像素小于 2×2 的影像剔除, 当影像中作物像素点太少, 估产网络难以从中提取有用信息, 反而会被当成噪声数据, 进而影响网络的性能。对 MOD09A1 和 MOD11A2 各个波段进行提取、融合, 即利用 GDAL 库分别读取 MOD09A1 和 MOD11A2 影像, 将其波段按顺序排列, 共计 9 个波段, 包括 MOD09A1 的 7 个波段和 MOD11A2 的 2 个波段, 最后输出融合后的影像。

2 研究方法

2.1 估产样本构建

本文选取 2001—2018 年的冬小麦影像数据作为样本。一般来说, 冬小麦在 10 月中旬播种, 次年 7 月初收获, 由此确定影像数据的时间范围从每年的第 289 天到次年的第 180 天, 共 30 个时间步。冬小麦生育期包括: 播种期、出苗期、分蘖期、越冬期、返青期、起身期 (生物学拔节)、拔节期、孕穗期、抽穗期、开花期、灌浆期、成熟期, 每个生育期约 21 d, 把每两个生育期划分一个时间节点, 即每两个生育期对应 5 个时间步: 播种-出苗期 (0~5)、分蘖-越冬期 (5~10)、返青-起身期 (10~15)、拔节-孕穗期 (15~20)、抽穗-开花期 (20~25)、灌浆-成熟期 (25~30)。结合县边界数据, 裁剪每个县所有时间步长 $t \in (0, 30)$ 的影像 $M_{id,y}^{t,b}$, 其中, b 代表参与农作物估产的波段数, id 代表区县的国家行政区划代码, y 代表预测年份。由于各县级单位冬小麦种植面积不同, 为统一网络的输入, 统计影像内农作物像素点个数, 取 32×32 作为阈值。当县域作物像素小于阈值时, 将除作物像素的其余点填充为 0; 当县域作物像素大于阈值时, 剔除零星分布的农作物像素, 这部分像素点可能会被当成噪声, 取农作物比较集中的像素作为网络输入; 以确保影像整体信息完整。为提升模型精度和收敛速度, 对冬小麦数据集进行标准化。

$$x_n = \frac{x_i - \mu}{\sigma} \quad (1)$$

式中 μ 表示均值, σ 表示方差。计算出整个数据集的均值和方差, 并应用上述公式对影像中每个像素点进行标准化。

2.2 CNN-GRU 融合网络

如图 1 所示, 所提出的 CNN-GRU 估产模型由卷积子网、递归子网和全连接层组成。为提取多时相影像的联合光谱-空间-时间特征, 卷积子网从每个时间步的影像中提取空间-光谱特征映射, 最终得到 30 个时间步的特征向量。在卷积子网的基础上, 递归子网以卷积层的特征

作为输入,利用门控循环单元(Gated Recurrent Unit, GRU)挖掘不同层次的特征间的依赖关系,整合 CNN 框架部分输出的特征向量。最后利用全连接层进行产量预测。




图 1 CNN-GRU 估产模型体系结构

Fig.1 Architecture of Convolutional Neural Network-Gated Recurrent Unit (CNN-GRU) yield estimation model

2.2.1 基于卷积子网的空间光谱特征提取

农作物的生长主要伴随光谱变化,因此从遥感影像中准确地挖掘光谱信息是农作物产量预测地关键。同时,由于农作物分布通常呈现聚集性,农作物像素之间的空间相关性也十分重要,而 CNN 作为深度学习的一个重要分支,其独特的卷积结构能提取遥感影像中丰富的光谱-空间特征^[39-40]。

卷积子网包括 4 个卷积层、4 个池化层和一个全连接层,如图 2 所示。输入数据为每个时间步的冬小麦影像。在每一张影像上利用 3×3 的卷积核的点积之和来提取固定大小的光谱特征,并利用窗口滑动以覆盖整个空间维度,以提取冬小麦的空间-光谱信息。本文选择线性整流函数(Rectified Linear Unit, ReLu)作为激活函数,不仅能加速网络收敛,还能避免梯度爆炸或梯度消失。最后输出特征图表示为

$$x_{i+1} = f(\sum x_i \odot w_i + b_i) \quad (2)$$

式中 $f(\cdot)$ 表示 ReLu 激活函数, x_i 表示上一个卷积层的输出, w_i 表示第 $i-1$ 层和第 i 层之间的权重, b_i 表示贝叶斯偏置项。



注: Conv、Pool、FC 分别代表卷积层、池化层、全连接层。
Note: Conv, Pool, FC represent convolution, pooling, full connection layer, respectively.

图 2 卷积子网模型结构

Fig.2 Convolution subnet model structure

通过卷积层提取特征后,为减少计算量,本文选择最大池化函数来处理从卷积运算中获得的特征映射结果,其中池化窗口为 2×2 ,池化步长为 2。

$$x_{\text{pool}} = \text{Max}(x_{i+1}) \quad (3)$$

式中 x_{pool} 表示池化层的输出。卷积子网最终将每个时间步的冬小麦影像映射为高维的空间-光谱特征 $\{f_1, f_2, \dots, f_{30}\}$, 并将其作为递归子网的输入。

2.2.2 基于递归子网的时间相关性建模

在农作物生长过程中,其植株形特征会随生育期变化而改变,卷积神经网络(CNN)仅能提取单一生育期的农作物生长特征,而通过农作物不同生育期植株状态的变化来挖掘深层次的时序特征尤为重要。循环神经网络(Recurrent Neural Network, RNN)可以很好地关联上下文信息,尤其擅长针对时间序列数据建模^[41-42]。但传统 RNN 面临着梯度消失的问题,难以对长时间序列数据建模。因此,本文使用 GRU 代替传统 RNN 网络,GRU 是循环神经网络的变体,适用于挖掘长时间序列数据的内在联系,并且有效解决了梯度消失的问题^[43]。

因此,在 CNN 的基础上,本文进一步使用 GRU 网络构建农作物生长过程中的时间关系。GRU 由重置门 r_t 、更新门 z_t 和隐藏状态 h_t 组成,将从不同时间步获取的高维空谱特征 x_t 作为输入,其中隐藏状态 h_t 用来处理连续的冬小麦时间特征,在考虑先前冬小麦生长状态的情况下学习当前的特征;重置门用于控制前一时刻的隐藏单元 h_{t-1} 对当前输入 x_t 的影响;更新门确定在当前隐藏状态 h_t 之前,保留多少先前时刻的状态信息。第 $t \in (0, 30)$ 时间步各个门的迭代参数 (r_t 、 z_t 、 $\tilde{h}_t$ 和 h_t) 可表示为

$$r_t = \sigma(W_{xr}x_t + W_{hr}h_{t-1} + b_r) \quad (4)$$

$$z_t = \sigma(W_{xz}x_t + W_{hz}h_{t-1} + b_z) \quad (5)$$

$$\tilde{h}_t = \tanh(W_{xh}x_t + r_t \odot (W_{hh}h_{t-1})) \quad (6)$$

$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tilde{h}_t \quad (7)$$

式中 x_t 为第 t 时间步的输入, r_t 、 z_t 、 $\tilde{h}_t$ 、 h_t 分别表示更新门、重置门、候选状态、隐藏状态, σ 是 sigmoid 激活函数, $W_{\cdot\{\cdot\}}$ 和 $b_{\{\cdot\}}$ 表示权重矩阵和偏执向量, $\odot$ 表示矩阵运算。这种结构使 GRU 能够根据冬小麦先前的生长信息,结合新的输入进行自我更新。因此,GRU 可以充分挖掘各个时间步之间的内在联系,从而有效反映农作物生长过程中的相互关系。

2.3 loss 函数和评价指标

在网络最后,将所有的时间输出展平成一个向量,利用一个神经元的全连接层输出冬小麦预测产量,并在每个池化层和全连接层添加比例为 0.5 的 dropout 结构,以避免模型出现过拟合现象。本文使用自适应矩估计(adaptive moment estimation, Adam)优化器训练网络,并通过 L_2 损失函数^[44]来计算预测产量(pre_{id})与真实产量($real_{id}$)之间的训练损失值,如公式所示:

$$L_2 = \frac{1}{2} \sum_{i=1}^n (pre_{id} - real_{id})^2 \quad (8)$$

本文使用均方根误差(RMSE)、平均绝对误差(Mean Absolute Error, MAE)和决定系数(R^2)来评估模型预测精度^[45-47]。

2.4 模型训练

本文使用 python 对影像数据进行预处理，在基于 TensorFlow 的深度学习框架下进行模型的搭建、训练和测试，并安装 CUDA 等运算平台以搭建 GPU 加速环境。实验的硬件仿真环境为 Intel(R) Core(TM) i7-6900K CPU，使用 NVIDIA GeForce GTX 1080 GPU 对模型进行加速，显存大小为 8G。

为实现全国冬小麦主产区的产量预测，本文对 CNN-GRU 估产模型进行训练。在训练阶段，以全国冬小麦主产区整个生育期的遥感影像作为训练数据，年平均产量为标签，年份为 2001—2015 年，时间步 $t \in (0, 30)$ 。为确保无偏性，每个批次从训练集中随机抽取 32 个样本进行训练。初始学习率为 0.000 1，分阶段逐步递减为初始值的 10 倍，达到迭代次数时，训练停止。在测试阶段以 2016—2018 年全国冬小麦主产区的年平均产量和影像作为测试数据。

3 结果与分析

3.1 数据贡献度分析

为评估 MODIS 影像中地表反射率（7 个波段）和地

表昼夜温度数据对农作物估产的影响程度。本文对温度数据和反射率数据分别进行训练，并将反射率 7 个波段依次去除一个，使用其余波段进行训练。如表 1 所示（以 RMSE 为例，单位 kg/hm^2 ），其中删除波段 1 表示删除第一个波段，仅使用第 2~7 个波段，以此类推，最后一列波段 1~7 表示使用地表反射率的所有波段。结果表明：1）只利用反射率训练的 CNN-GRU 估产模型 RMSE 年平均值分别为 $841 \text{ kg}/\text{hm}^2$ ，优于仅使用温度数据的预测结果，说明反射率数据相较于温度数据包含了更多的农作物信息，如红光波段对绿色植被具有强吸收性，对农作物的覆盖度、生长状态比较敏感。2）使用反射率所有波段训练的模型效果最好，说明反射率 7 个波段均对农作物产量预测起决定性作用。在分别删除第 1、2、7 个波段后，RMSE 下降了 8% 左右，而删除第 3 个波段时，RMSE 仅下降了 3%，说明第 1（红光波段）、2（近红外波段）、7（短波红外波段）相较于其他波段对农作物估产更为重要，而第 3 个波段（蓝光波段）主要反映植被的下垫面土壤与植被之间的差异，可能相较于其他波段不能更直接的反映作物的生长状态。

表 1 地表反射率（7 个波段）和地表昼夜温度数据对农作物估产的影响

Table 1 The effect of surface reflectance (7 bands) and surface day and night temperature data on crop yield estimation

年份 Year	地表昼夜温度 Day and night surface temperature	地表反射率 Surface reflectance								kg hm^{-2}
		删除波段 1 Delete band 1	删除波段 2 Delete band 2	删除波段 3 Delete band 3	删除波段 4 Delete band 4	删除波段 5 Delete band 5	删除波段 6 Delete band 6	删除波段 7 Delete band 7	波段 1~7 Band 1-7	
2018	990	927	880	874	895	913	896	909	852	
2017	1 087	890	891	848	849	834	854	856	830	
2016	1 101	876	890	839	880	860	881	904	842	
平均值 Average	1 059	897	887	853	874	869	877	889	841	

注：1~7 个波段分别为红光、近红外、蓝光、绿光、短波红外、中短波红外、长短波红外波段。表中数值为均方根误差值。

Note: 1-7 bands are: red, near infrared blue, green, short wave infrared, early short-wave infrared and far short-wave infrared bands, respectively. The data in the table is root mean square error.

3.2 估产模型性能检测

为验证 CNN-GRU 估产模型的优越性，将其与使用最广泛的多个农作物产量预测模型进行比较，如深度学习框架下的 CNN、GRU 和传统机器学习算法中的 SVR、DT 和 RF。其中所有估产模型均使用同一个数据集。但 CNN 难以处理长时间序列数据，则将时间序列和波段相叠加作为 CNN 的输入，即 $(32, 32, 30 \times 9)$ 。而 GRU 网络需要将输入数据展平为时间序列向量 $(30, 32 \times 32 \times 9)$ 。此外，由于传统机器学习模型本身的结构限制，在输入之前需要把输入数据展平为一维向量，但 $30 \times 32 \times 32 \times 9 = 276480$ 维度太高，容易导致“维度灾难”，因此，使用影像的 NDVI 作为传统机器学习模型的输入。各个模型的关键参数设置如下：

1) 卷积神经网络：包含 4 个卷积层、4 个池化层、1 个全连接层，批处理大小为 32，初始学习率为 0.000 1。

2) 门控循环单元模型：由 128 个神经元的 GRU 和全连接层组成，批处理大小为 32，初始学习率为 0.001。

3) 支持向量回归：使用径向基 (RBF) 作为 SVR 的核函数，惩罚因子 $C=2, 5, 10, 100$ ，松弛变量 $\gamma=10^{-1}, 10^{-2}, 10^{-3}$ 。

4) 决策树：包括树的最大深度 $\text{max_depth}=3, 4, 5, 6, 7$ ，叶子节点最少样本数 $\text{min_samples_leaf}=10, 15, 20, 30$ ，内部节点再划分所需最小样本数 $\text{min_samples_split}=5, 8, 10$ 。

5) 随机森林：包括子树的数量 $\text{num_estimators}=50, 80, 100$ ，每棵树的最大深度 $\text{max_depth}=3, 6, 9$ 。

在本节中，使用不同的估产模型分别预测 2016—2018 年冬小麦产量，为确保比较的公平性，所有估产模型均在相同的软硬件环境下训练和测试。分析表 2 可知：1) 所提出的 CNN-GRU 估产模型年平均 RMSE 为 $818.3 \text{ kg}/\text{hm}^2$ ，相较于 CNN、GRU、SVR、RF 和 DT 分别降低了 20.13%、18.81%、29.51%、34.84% 和 36.57%，年平均 MAE 为 $560 \text{ kg}/\text{hm}^2$ ，相较于其他模型分别降低了 25.46%、22.39%、37.09%、39.95% 和 42.26%。表明 CNN-GRU 模型能准确地预测冬小麦产量。但对于部分低产量的区县（如新疆维吾尔自治区的伊宁县和和硕县）和部分高产量的区县（陕西省西安市的灞桥区和河南省南阳市的新野县）CNN-GRU 模型预测误差偏大（如图 3 所示）。产生这种误差的原因可能是冬小麦数据集中低产量和高产量的样本数占偏低，导致模型对于部分

低产量和高产量的地区泛化能力较差, 预测的误差较高; 对于低产量的新疆维吾尔自治区海拔高、环境复杂等不确定性因素导致预测精度降低; 对于高产量的漏桥区和新野县来说, 地处平原, 均为冬小麦气候适宜区, 种植面积较大, 而模型输入中没有表达区域异质性的参数, 导致低估了部分高产量地区的冬小麦产量。2) CNN 和 GRU 的性能相当, 年平均 RMSE 分别为 920、996 kg/hm², 均高于所提出的 CNN-GRU 估产模型, 表明单一的神经网络在作物估产领域效果不佳。CNN 能有效地提取影像中空间-光谱特征, 但作物生长随时间变化, 农作物在不同的生育期有不同的形态特征, 时间信息的缺失严重影响了 CNN 的整体性能; 而 GRU 能整合长时间序列的作物生长信息, 但不能捕捉复杂的空间关系。因此所提出的 CNN-GRU 估产模型可以有效地提取冬小麦生长期的空间-光谱-时间信息, 并将其应用于冬小麦产量预测中。3) 深度学习网络在性能上均优于传统的机器学习模型, 在冬小麦产量预测这一复杂问题的研究中, 深度学习网络更能挖掘冬小麦影像中的时空特征。

表 2 不同估产模型性能对比

Table 2 Performance comparison of different yield estimation models

年份 Year	模型 Model	RMSE/ (kg hm ⁻²)	MAE/ (kg hm ⁻²)	R ²
2018	CNN-GRU	829	572	0.735
	CNN	924	624	0.671
	GRU	1 008	749	0.609
	SVR	1 200	898	0.443
	RF	1 289	976	0.341
	DT	1 232	929	0.356
2017	CNN-GRU	816	566	0.777
	CNN	911	677	0.727
	GRU	1 010	749	0.658
	SVR	1 113	870	0.592
	RF	1 220	910	0.489
	DT	1 295	973	0.452
2016	CNN-GRU	810	542	0.790
	CNN	926	593	0.724
	GRU	965	691	0.701
	SVR	1 170	903	0.557
	RF	1 259	912	0.403
	DT	1 344	1 008	0.351

注: CNN、GRU、SVR、RF、DT 分别为卷积神经网络、门控循环单元、支持向量回归、随机森林、决策树模型, RMSE 为均方根误差, MAE 为平均绝对误差, R² 为决定系数。

Note: CNN, GRU, SVR, RF, DT represent convolutional neural network, gated recurrent unit, support vector regression, random forest, decision tree model respectively. RMSE is the root mean square error, MAE is the mean absolute error, and R² is the coefficient of determination.




图 3 基于 CNN-GRU 估产模型的全国冬小麦主产区空间分布图 (2016 年为例)

Fig.3 The spatial distribution map of the main winter wheat producing areas in China based on the CNN-GRU production estimation model (2016 as an example)

3.3 不同生育期冬小麦预测


本节分别对作物累计生育期的时间步 (0~5, 0~10, 0~15, 0~20, 0~25, 0~30) 和单一生育期的时间步 (0~5, >5~10, >10~15, >15~20, >20~25, >25~30) 进行单产预测, 以评估 CNN-GRU 网络模型预测冬小麦产量的最佳时间窗。

如图 4 所示, CNN-GRU 估产模型在生育期初期性能较差, 2016—2018 年平均 RMSE 和 MAE 分别为 1 109、840.6 kg/hm², 这是由于估产模型在生育期初期缺乏足够的作物生长信息和环境信息, 但随着时间的推移, 越来越多的影像信息被整合到估产网络中, 模型的性能逐步提高。1) 单一生育期的预测精度很低, 相较于

于全生育期影像 (0~30) 低了 25%至 28%, 这是由于单一生育期仅使用了部分时间步的影像数据, 缺乏前后生育期冬小麦的生长状态, 不能充分发挥 CNN-GRU 估产网络整合长时间序列影像时空特征的优势。2) 返青-起身期和拔节-孕穗期两个时间步的 RMSE 相差最大, 约 10%左右, 拔节-孕穗期相较于返青-起身期预测精度明显提升。在返青-起身期时, 麦苗开始生长春生第一叶, 茎部第一节开始伸长但为完全露出地面。而在拔节期, 冬小麦植株茎部露出地面 1.5~2 cm, 生长特征明显。表明 CNN-GRU 模型能有效地捕捉冬小麦的各个生育期的特点及其生长状态的变化。3) 在灌浆-成熟期时, CNN-GRU 估产模型精度最高, 2016—2018

年的平均 RMSE 和 MAE 分别为 817、556 kg/hm², R^2 为 0.76, 均优于其他各个生育期。在冬小麦生育期后期, 所有的作物生长信息均被整合到 CNN-GRU 估产模型中, 该估产模型能精确地预测全国冬小麦主产区产量。4) 2016—2018 年冬小麦拔节-孕穗期和抽穗-开花

期估产模型预测精度相当, 年平均 RMSE 分别为 849、823 kg/hm², 仅比成熟期低 3.9% 和 0.7%, 说明 CNN-GRU 估产模型在冬小麦生育期的中后期已经能准确地预测其产量, 即所提出的估产模型有能力提前 2 个月预测全国冬小麦主产区产量。



注: 每个生育期约 21 d, 定义每两个生育期划分一个时间节点, 对应 5 个时间步: 播种-出苗期 (0~5)、分蘖-越冬期 (5~10)、返青-起身期 (10~15)、拔节-孕穗期 (15~20)、抽穗-开花期 (20~25)、灌浆-成熟期 (25~30)。

Note: Each growth period is about 21 d. It is defined that every two growth periods is divided into a time node, corresponding to 5 time steps: sowing-emergence period (0-5), tillering-overwintering period (5-10), green-getting period (10-15), jointing-booting period (15-20), heading-flowering period (20-25), filling-maturity period (25-30).

图 4 各生育期 CNN-GRU 估产模型精度

Fig.4 Accuracy of CNN-GRU yield estimation model for different growth stages

3.4 CNN-GRU 模型鲁棒性检验

为对提出的 CNN-GRU 估产模型进行鲁棒性检验, 将 2008—2018 年估产样本逐年作为验证集, 其余年份作为训练集进行训练, 如表 3 所示。结果表明, 2008—2018 年 CNN-GRU 估产模型的 RMSE 和 MAE 平均值为 727、534 kg/hm², R^2 为 0.805。在不同训练集和验证集下, 预测产量与统计产量值离散程度基本一致, 表明 CNN-GRU 估产模型有较高的鲁棒性。

表 3 CNN-GRU 模型逐年精度评估

Table 3 Annual accuracy evaluation of CNN-GRU model

年份 Year	RMSE/(kg hm ⁻²)	MAE/(kg hm ⁻²)	R^2
2008	669	500	0.826
2009	650	481	0.833
2010	982	752	0.617
2011	639	472	0.842
2012	604	446	0.867
2013	647	501	0.859
2014	653	506	0.865
2015	699	546	0.843
2016	810	542	0.790
2017	816	566	0.777
2018	829	572	0.735
平均值 Average	727	534	0.805

综合分析发现, 2010 年产量预测误差最大, RMSE 和 MAE 分别为 982、752 kg/hm², R^2 仅 0.617; 2012 年模型精度最高, RMSE 和 MAE 分别为 604、446 kg/hm², R^2 为 0.867。2009、2011、2013 和 2014 年模型预测精度较高, RMSE 和 MAE 在 650、500 kg/hm² 左右; 2016—2018 年预测效果一般, RMSE 在 820 kg/hm² 左右。不同

年份模型性能不同的主要原因有: 1) 在 2010 年, 中国西南地区遭遇特大干旱, 北方冬小麦主产区出现持续低温天气, 在极端天气情况下, 统计数据极值差异较大^[41]。如图 5a 所示, 2010 年全国冬小麦主产区县级尺度产量预测出较多离群值, 而多数离群值的预测产量都大于统计产量, 导致模型整体精度降低。2) 2012 年的 RMSE 和 MAE 分别为 604、446 kg/hm², R^2 为 0.867。如图 5b 所示, 预测产量与统计产量接近, 仅有零星几个离群值。3) 2016—2018 年的收集的产量数据较少, 可用于训练和测试的区县数量仅约 650 个, 而其余每年的区县数据约 1 500 个。并且随着基因技术和种植技术的发展, 近年来作物单产飞速提升, 2016—2018 年的低产量地区数量较少, 导致数据分布不均衡。而 2009、2011、2013 和 2014 年的产量分布比较均衡, 导致模型在不同年份预测的精度不同。




图 5 2010 和 2012 年模型精度

Fig.5 Model accuracy in 2010 and 2012

4 结 论

作物产量预测在农业管理中具有重要意义。近年来的研究表明, 遥感是一种有效的估产方法。本文提出了

一种基于多时相遥感影像的 CNN-GRU 估产模型, 利用 CNN 从多时相遥感影像中提取丰富的空间-光谱特征, 在此基础上, GRU 自适应学习冬小麦生育期各阶段之间的时间依赖。试验证明该模型能从多时相遥感影像中提取联合空间-光谱-时间特征, 挖掘作物生长特征与产量之间的复杂关系, 并能够对收获前期的冬小麦产量进行准确预测。结论如下:

1) 深度学习技术在产量预测上有巨大潜力, 对比结果表明深度学习的方法优于传统机器学习方法。同时, 与单一的深度学习网络 CNN 和 GRU 相比, 本文所提出的 CNN-GRU 估产模型精准预测了 2016—2018 年中国冬小麦主产区的产量, 其精度均优于其他估产模型。说明该模型能有效地提取反映作物生长信息的空间-光谱-时间特征, 解决了单一神经网络提取作物生长特征不充分问题, 进一步提高了大范围冬小麦单产估算效率。

2) 基于混合神经网络的遥感估产模型鲁棒性较高。本文对 2008—2018 年数据集逐年样本训练, 所提出的 CNN-GRU 估产模型 RMSE 和 MAE 平均值分别为 727、534 kg/hm², R² 平均值为 0.805。该模型在不同数据集上预测产量与统计产量值离散程度基本一致, CNN-GRU 估产模型性能稳定, 预测精度高, 可以作为一种高效的方法为全国提供常规可行的冬小麦产量监测和预报。

3) 在冬小麦成熟期 CNN-GRU 估产模型性能最高, 但拔节-孕穗期和抽穗-开花期同样取得较高精度, RMSE 分别为 849、823 kg/hm², R² 均高于 0.7, 与成熟期预测结果几乎没有差异。说明本文提出的 CNN-GRU 估产模型有能力提前 2 个月预测县级尺度的全国冬小麦主产区产量, 为冬小麦生育早期产量预测提供了新的思路和方法。

[参 考 文 献]

- [1] 吴炳方, 蒙继华, 李强子. 国外农情遥感监测系统现状与启示[J]. 地球科学进展, 2010, 25(10): 1003-1012.
Wu Bingfang, Meng Jihua, Li Qiangzi. Review of overseas crop monitoring system with remote sensing[J]. Advances in Earth Science, 2010, 25(10): 1003-1012. (in Chinese with English abstract)
- [2] 邢素丽, 张广录. 我国农业遥感的应用现状与展望[J]. 农业工程学报, 2003, 19(6): 174-178.
Xing Suli, Zhang Guanglu. Application status and prospect of agriculture remote sensing in China[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2003, 19(6): 174-178. (in Chinese with English abstract)
- [3] Weiss M, Jacob F, Duveiller G. Remote sensing for agricultural applications: A meta-review[J]. Remote Sensing of Environment, 2020, 236: 111402.
- [4] 彭京伦, 王娟, 金玟主, 等. 基于生长度日和降水量的韩国饲用玉米产量预测模型构建[J]. 草业科学, 2018, 35(4): 857-866.
Peng Jinglun, Wang Juan, Jin Yongzhu, et al. Construction of a yield prediction model for whole crop maize on the basis of climate data in South Korea[J]. Pratacultural Science, 2018, 35(4): 857-866. (in Chinese with English abstract)
- [5] 王涛, 吕昌河, 于伯华. 基于 WOFOST 模型的京津冀地区冬小麦生产潜力评价[J]. 自然资源学报, 2010, 25(3): 475-487.
Wang Tao, Lü Changhe, Yu Bohua. Assessing the productivity of winter wheat using WOFOST in the Beijing-Tianjing-Hebei Region[J]. Journal of Natural Resources, 2010, 25(3): 475-487. (in Chinese with English abstract)
- [6] Filippi P, Jones E J, Wimalathunge N S, et al. An approach to forecast grain crop yield using multi-layered, multi-farm data sets and machine learning[J]. Precision Agriculture, 2019, 20(5): 1015-1029.
- [7] Lobell D B. The use of satellite data for crop yield gap analysis[J]. Field Crops Research, 2013, 143: 56-64.
- [8] Aghighi H, Azadbakht M, Ashourloo D, et al. Machine learning regression techniques for the silage maize yield prediction using time-series images of Landsat 8 OLI[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2018, 11(12): 4563-4577.
- [9] 陶惠林, 徐良骥, 冯海宽, 等. 基于无人机高光谱遥感数据的冬小麦产量估算[J]. 农业机械学报, 2020, 51(7): 146-155.
Tao Huilin, Xu Liangji, Feng Haikuan, et al. Winter wheat yield estimation based on UAV hyperspectral remote sensing data[J]. Transactions of the Chinese Society for Agricultural Machinery, 2020, 51(7): 146-155. (in Chinese with English abstract)
- [10] 韩文霆, 彭星硕, 张立元, 等. 基于多时相无人机遥感植被指数的夏玉米产量估算[J]. 农业机械学报, 2020, 51(1): 148-155.
Han Wenting, Peng Xingshuo, Zhang Liyuan, et al. Summer maize yield estimation based on vegetation index derived from multi-temporal UAV Remote Sensing[J]. Transactions of the Chinese Society for Agricultural Machinery, 2020, 51(1): 148-155. (in Chinese with English abstract)
- [11] 陶惠林, 冯海宽, 杨贵军, 等. 基于无人机数码影像和高光谱数据的冬小麦产量估算对比[J]. 农业工程学报, 2019, 35(23): 111-118.
Tao Huilin, Feng Haikuan, Yang Guijun, et al. Comparison of winter wheat yields estimated with UAV digital image and hyperspectral data[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2019, 35(23): 111-118. (in Chinese with English abstract)
- [12] Haghverdi A, Washington-Allen R A, Leib B G. Prediction of cotton lint yield from phenology of crop indices using artificial neural networks[J]. Computers and Electronics in Agriculture, 2018, 152: 186-197.
- [13] Fernandes J L, Ebecken N F F, Esquerdo J C D M. Sugarcane yield prediction in Brazil using NDVI time series and neural networks ensemble[J]. International journal of Remote Sensing, 2017, 38(16): 4631-4644.
- [14] Panda S S, Ames D P, Panigrahi S. Application of vegetation indices for agricultural crop yield prediction using neural network techniques[J]. Remote Sensing, 2010, 2(3): 673-696.
- [15] Qi Yang, Liangsheng Shi, Jinye Han, Yuanyuan, et al. Deep convolutional neural networks for rice grain yield estimation at the ripening stage using UAV-based remotely sensed

- images[J]. *Field Crops Research*, 2019, 235: 142-153.
- [16] Qi Yang, Liangsheng Shi, Lin Lin. Plot-scale rice grain yield estimation using UAV-based remotely sensed images via CNN with time-invariant deep features decomposition[C]//IGARSS 2019-2019 IEEE International Geoscience and Remote Sensing Symposium. Yokohama: IEEE, 2019: 7180-7183.
- [17] Nevavuori P, Narra N, Lipping T. Crop yield prediction with deep convolutional neural networks[J]. *Computers and Electronics in Agriculture*, 2019, 163: 104859.
- [18] Son N T, Chen C F, Chen C R, et al. Prediction of rice crop yield using MODIS EVI-LAI data in the Mekong Delta, Vietnam[J]. *International Journal of Remote Sensing*, 2013, 34(20): 7275-7292.
- [19] 林滢, 邵怀勇. 基于随机森林算法的河南省冬小麦产量预测最佳时间窗和影响因子研究[J]. *麦类作物学报*, 2020, 40(7): 874-880.
- Lin Ying, Shao Huaiyong. Study on optimal time and influencing factors for winter wheat yield prediction in henan based on random forest algorithm[J]. *Journal of Triticeae Crops*, 2020, 40(7): 874-880. (in Chinese with English abstract)
- [20] 刘峻明, 和晓彤, 王鹏新, 等. 长时间序列气象数据结合随机森林法早期预测冬小麦产量[J]. *农业工程学报*, 2019, 35(6): 158-166.
- Liu Junming, He Xiaotong, Wang Pengxin, et al. Early prediction of winter wheat yield with long time series meteorological data and random forest method[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2019, 35(6): 158-166. (in Chinese with English abstract)
- [21] Van Klompenburg T, Kassahun A, Catal C. Crop yield prediction using machine learning: A systematic literature review[J]. *Computers and Electronics in Agriculture*, 2020, 177: 105709.
- [22] Wang Y, Zhang Z, Feng L, et al. Combining multi-source data and machine learning approaches to predict winter wheat yield in the conterminous united states[J]. *Remote Sensing*, 2020, 12(8): 1232.
- [23] Kussul N, Mykola L, Shelestov A, et al. Crop inventory at regional scale in Ukraine: developing in season and end of season crop maps with multi-temporal optical and SAR satellite imagery[J]. *European Journal of Remote Sensing*, 2018, 51(1): 627-636.
- [24] Wang H, Huo Z, Zhou G, et al. Monitoring and forecasting winter wheat freeze injury and yield from multi-temporal remotely sensed data[J]. *Intelligent Automation & Soft Computing*, 2016, 22(2): 255-260.
- [25] Khaki S, Pham H, Wang L. Simultaneous corn and soybean yield prediction from remote sensing data using deep transfer learning[J]. *Scientific Reports*, 2021, 11(1): 1-14.
- [26] Khaki S, Wang L, Sotirios V Archontoulis. A CNN-RNN framework for crop yield prediction[J]. *Frontiers in Plant Science*, 2019, 10: 1750.
- [27] Sun J, Di L P, Sun Z H, et al. County-level soybean yield prediction using deep CNN-LSTM model[J]. *Sensors*, 2019, 19(20): 4363.
- [28] Mou L, Bruzzone L, Zhu X X. Learning spectral-spatial-temporal features via a recurrent convolutional neural network for change detection in multispectral imagery[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2018, 57(2): 924-935.
- [29] Gong L, Yu M, Jiang S, et al. Deep learning based prediction on greenhouse crop yield combined TCN and RNN[J]. *Sensors*, 2021, 21(13): 4537.
- [30] Haider S A, Naqvi S R, Akram T, et al. LSTM neural network based forecasting model for wheat production in Pakistan[J]. *Agronomy*, 2019, 9(2): 72.
- [31] 周亮, 慕号伟, 马海蛟, 等. 基于卷积神经网络的中国北方冬小麦遥感估产[J]. *农业工程学报*, 2019, 35(15): 119-128.
- Zhou Liang, Mu HaoWei, Ma Haijiao, et al. Remote sensing estimation on yield of winter wheat in North China based on convolutional neural network[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2019, 35(15): 119-128. (in Chinese with English abstract)
- [32] Sun J, Lai Z, Di L, et al. Multilevel deep learning network for county-level corn yield estimation in the us corn belt[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2020, 13: 5048-5060.
- [33] Wang X, Huang J, Feng Q, et al. Winter wheat yield prediction at county level and uncertainty analysis in main wheat-producing regions of China with deep learning approaches[J]. *Remote Sensing*, 2020, 12(11): 1744.
- [34] Yue Y, Li J H, Fan L F, et al. Prediction of maize growth stages based on deep learning[J]. *Computers and Electronics in Agriculture*, 2020, 172: 105351.
- [35] Vermote E. MOD09A1 MODIS/terra surface reflectance 8-day L3 global 500 m SIN grid V006[J]. *NASA EOSDIS Land Processes DAAC*, 2015, 10.
- [36] Tang H, Yu K, Hagolle O, et al. A cloud detection method based on a time series of MODIS surface reflectance images[J]. *International Journal of Digital Earth*, 2013, 6(Sup1): 157-171.
- [37] Idso S B, Jackson R D, Reginato R J. Remote-sensing of crop yields[J]. *Science*, 1977, 196(4285): 19-25.
- [38] 中国科学院“十三五”信息化专项 科学大数据工程[J]. *中国科学院院刊*, 2018, 33(8): 893.
- The 13th five year plan informatization project of Chinese Academy of Sciences[J]. *Journal of Chinese Academy of Sciences*, 2018, 33(8): 893. (in Chinese with English abstract)
- [39] He J, Li D, Yang B, et al. Multi view facial action unit detection based on CNN and BLSTM-RNN[C]//2017 12th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2017). Washington: IEEE, 2017: 848-853.
- [40] Bhimra M A, Nazir U, Taj M. Using 3d residual network for spatio-temporal analysis of remote sensing data[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Brighton: IEEE, 2019: 1403-1407.
- [41] Jin X B, Yang N X, Wang X Y, et al. Hybrid deep learning predictor for smart agriculture sensing based on empirical

- mode decomposition and gated recurrent unit group model[J]. *Sensors*, 2020, 20(5): 1334.
- [42] 林靖皓, 秦亮曦, 苏永秀, 等. 基于自注意力机制的双向门控循环单元和卷积神经网络的芒果产量预测[J]. *计算机应用*, 2020, 40(S1): 51-55.
- Lin Jinghao, Qin Liangxi, Su Yongxiu, et al. Prediction of mango yield based on self-attention CNN and bidirectional GRU[J]. *Journal of Computer Applications*, 2020, 40(S1): 51-55. (in Chinese with English abstract)
- [43] Lee K, Kim J K, Kim J, et al. CNN and GRU combination scheme for bearing anomaly detection in rotating machinery health monitoring[C]//2018 1st IEEE International Conference on Knowledge Innovation and Invention (ICKII). Jeju: IEEE, 2018: 102-105.
- [44] Lee C P, Lin C J. A study on L2-loss (squared hinge-loss) multiclass SVM[J]. *Neural Computation*, 2013, 25(5): 1302-1323.
- [45] Chai T, Draxler R R. Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature[J]. *Geoscientific Model Development*, 2014, 7(3): 1247-1250.
- [46] Dennison P E, Roberts D A. Endmember selection for multiple endmember spectral mixture analysis using endmember average RMSE[J]. *Remote Sensing of Environment*, 2003, 87(2/3): 123-135.
- [47] Willmott C J, Matsuura K. Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance[J]. *Climate Research*, 2005, 30(1): 79-82.

Yield estimation of winter wheat in China based on CNN-RNN network

He Xiaohui¹, Luo Haotian¹, Qiao Mengjia², Tian Zhihui^{1*}, Zhou Guangsheng³

(1. School of Earth Science and Technology, Zhengzhou University, Zhengzhou 450001, China; 2. School of Information Engineering, Zhengzhou University, Zhengzhou 450001, China; 3. Ecometeorology Joint Laboratory of Zhengzhou University and Chinese Academy of Meteorological Science, Zhengzhou 450001, China)

Abstract: A rapid and accurate evaluation of crop yield at large scale is very critical to the planning and management of crop market. The prediction of crop yield includes the extensive manual sampling or the use of remote sensing images at present. Particularly, the remote sensing is preferred to predict the large-scale crop yield, providing a large number of satellite images with long time and high spatial resolution. Much effort has been made on the crop yield prediction using remote sensing images and deep learning. However, the yield generally presents nonlinear spatio-temporal characteristics, due mainly to the growth status of crops changes with the time. A single deep learning cannot make full use of crop growth characteristics in multi-temporal images. In this study, a Convolutional Neural Networks - Gated Recurrent Unit (CNN-GRU) estimation model was proposed to extract rich spatial-spectral features from multi-spectral remote sensing images. The time dependence in the phase remote sensing image was also adaptively learned among the various stages in the growth period of winter wheat. As such, the growth characteristics of winter wheat were integrated from multiple scales, further to predict the yield. Furthermore, the main production areas of winter wheat in the country were taken as the research area, including 1 713 districts and counties. The forecast dataset of winter wheat production was finally constructed using the statistical output of winter wheat, MODIS surface reflectance, day and night surface temperature images, and land cover data from 2001 to 2018, thereby to verify the performance of CNN-GRU production estimation model. The results showed that: 1) The annual average root mean square error (RMSE) and mean absolute error (MAE) of the CNN-GRU production estimation model from 2016 to 2018 were 818.3 and 560 kg/hm², respectively, where the annual average RMSE was reduced by 20.13%, 18.81%, 29.51%, 34.84%, and 36.57%, respectively, compared with the CNN, GRU, Support Vector Regression (SVR), Random Forest (RF), and Decision Tree (DT). Therefore, the CNN-GRU yield estimation model can be expected to accurately predict the winter wheat yield, further to effectively extract the space-spectrum-time information in the entire growth period of winter wheat from multi-temporal remote sensing images. 2) Six time windows were divided during the whole growth period of winter wheat, including the sowing-emergence, tillering-overwintering, green-rising, jointing-booting, heading-flowering, and filling-maturity period. Among them, the highest accuracy of CNN-GRU estimation model was found in the filling-maturation period. Specifically, the annual averages of RMSE and MAE were 817 and 556 kg/hm², respectively, and R^2 was greater than 0.7. However, the annual averages of RMSE and MAE during the heading-flowering period were 823 and 560 kg/hm², respectively, where the annual average RMSE was 0.7% lower than the filling-maturation period. Therefore, the proposed CNN-GRU yield estimation model can accurately predict the output of winter wheat in the middle and late stages of growth period, particularly for the national yield of winter wheat two months in advance.

Keywords: yield; models convolutional neural network models; recurrent neural network models; winter wheat; estimation; multi temporal remote sensing image