

西安电子科技大学

硕士学位论文



基于MODIS遥感图像和神经网络的农作物
产量预测研究

作者姓名 贾静

学校导师姓名、职称 李靖 教授

企业导师姓名、职称 韩春雷 研究员

申请学位类别 工程硕士

学校代码 10701

分 类 号 TN391.75

学 号 19011210414

密 级 公开

西安电子科技大学

硕士学位论文

基于MODIS遥感图像和神经网络的农作物产量预测研究

作者姓名：贾静

领 域：电子与通信工程

学位类别：工程硕士

学校导师姓名、职称：李靖 教授

企业导师姓名、职称：韩春雷 研究员

学 院：通信工程学院

提交日期：2022 年 6 月

Research on Crop Yield Forecasting Based on MODIS Remote Sensing Images and Neural Network

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Engineering

By
Jia Jing

Supervisor: Li Jing Title: Professor
Supervisor: Han Chunlei Title: Research Fellow

June 2022

摘要

对于世界各国而言，农业都是国民经济的重要组成部分，维持社会的稳定和经济长期发展都需要农作物的稳定生产。多年以来，农作物产量预测对于政府部门指导农业生产、保证农业及相关贸易的良性运转乃至国家的经济发展都具有关键作用。然而，影响农作物产量的因素是复杂多变的，实现产量的精准预估一直是农业领域中的一个难题。神经网络在处理大规模复杂非线性问题时具有突出优势，能够契合产量预测的需求。因此，本文围绕组合神经网络方法构建了一种农作物产量预测模型，并利用高斯过程优化对预测结果进行优化。主要从以下几方面开展研究：

本文以美国中部 11 个州县的大豆产量作为研究对象，所使用的产量数据源自中分辨率成像仪（Moderate-resolution Imaging Spectroradiometer, MODIS）遥感图像，并简要介绍了 MODIS 数据的基本概念、获取方法、有关作物估产的产品以及数据预处理方法。

针对传统线性拟合产量预测模型预测精度不高的问题，本文提出一种将卷积神经网络（Convolutional Neural Networks, CNN）和长短期记忆网络（Long Short-Term Memory, LSTM）组合的产量预测模型，该模型结合了两神经网络的优点，并且添加了高效通道注意力机制（Efficient Channel Attention Networks, ECANet）模块，将 MODIS 数据中学习到的特征值权重进行优化分配。所组成的 CNN+ECANet+LSTM 模型对复杂非线性关系的学习能力更强。仿真结果表明，相比于单一神经网络模型，本文所设计的组合网络模型具有更高的预测精度。

针对神经网络中无法直接加入年份和地理位置信息相关性因素导致预测精度降低的问题，本文提出一种基于高斯过程优化的组合网络产量预测模型，将 MODIS 数据集中的年份信息和地理位置通过高斯过程的协方差加入到模型训练中，优化 CNN+ECANet+LSTM 组合产量模型的输出结果，利用模拟退火-人工鱼群算法改进高斯过程回归中的超参数选择，解决了超参数寻优过程中易陷入局部最优解的缺陷，提高了模型的泛化能力。仿真结果表明，优化后的产量预测模型在选定区域上的整体预测精度有进一步提升，并且预测稳定性有较好的改善。

关键词：产量预测，MODIS 遥感图像，CNN，LSTM，注意力机制，高斯过程

ABSTRACT

For all countries in the world, agriculture is an important part of the national economy. Maintaining social stability and long-term economic development requires the stable production of crops. For many years, the crop yield prediction has played a key role in guiding agricultural production by government departments, ensuring the sound operation of agriculture and related trade, even the national economic development. However, the factors affecting crop yield are complex and changeable, the accurate estimation of crop yield has always been a difficult problem in the field of agriculture. Neural network has outstanding advantages in solving massive complex nonlinear problems, and can meet the needs of yield prediction. Therefore, this thesis constructs a crop yield prediction model based on the combined neural network method, and uses the Gaussian process optimization to optimize the prediction results. The thesis is mainly carried out from the following aspects.

This dissertation takes the soybean yield of 11 states and counties in the central of United States as the research object. The yield data are derived from Moderate-resolution Imaging Spectroradiometer(MODIS) remote sensing images. The basic concept, acquisition method, crop yield estimation products and data preprocessing method of MODIS data are briefly introduced.

Aiming at the problem that the traditional linear fitting yield prediction models are difficult to accurately predicting yield, this dissertation proposes a combined neural network model combining Convolutional Neural Network(CNN) and Long Short-Term Memory Network(LSTM), an Efficient Channel Attention Networks(ECANet) module is added to optimize the distribution of eigenvalue weights learned from MODIS data. The designed CNN+ECANet+LSTM network model has stronger learning ability in fitting complex nonlinear relationships. The simulation results show that the combined network model designed in this paper has higher prediction accuracy than the single neural network model.

Aiming at the problem that the correlation factors of year and geographical location information cannot be directly added to the neural network, which leads to the reduction of prediction accuracy. This dissertation proposes a combined network yield prediction model

based on Gaussian processes, which adds the year information and geographical location in MODIS data set to the model training through the covariance of Gaussian process, and optimizes the output result of CNN+ECANet+LSTM combined yield model. The Simulated Annealing-Artificial Fish Swarm Algorithm is used to improve the hyper-parameter selection in Gaussian process regression, solve the defect that it is easy to fall into local optimal solution in the process of hyper-parameter optimization, and improve the generalization ability of yield prediction model. The simulation results show that the overall prediction accuracy of the optimized yield prediction model in the selected area is further improved, and the prediction stability is well improved.

Keywords: crop yield prediction, MODIS remote sensing images, CNN, LSTM, attention mechanism, Gaussian process

插图索引

图 1.1	本文总体技术路线图	5
图 2.1	美国 2019 年大豆种植分布变化	9
图 2.2	MOD09A1 光谱图像	14
图 2.3	MOD11 光谱图像	15
图 2.4	掩膜量化后的土地覆盖光谱图像	17
图 2.5	GADM 数据下载页面	18
图 2.6	按年份划分的叠加光谱通道	19
图 2.7	添加掩膜前、后的光谱图像	20
图 2.8	通道数组合与掩膜处理示意图	20
图 3.1	全连接和局部连接示意图	23
图 3.2	卷积神经网络结构示意图	24
图 3.3	卷积过程示意图	24
图 3.4	2×2 的最大池化和平均池化示意图	25
图 3.5	全连接层的链接示意图	26
图 3.6	激活函数作用于神经网络的过程	26
图 3.7	Sigmoid 函数图像	27
图 3.8	Tanh 双曲正切激活函数图像	27
图 3.9	RELU 函数的图像	28
图 3.10	RNN 单元网络结构示意图	28
图 3.11	LSTM 单元结构示意图	29
图 3.12	SENet 模块原理示意图	31
图 3.13	获得权重步骤	32
图 3.14	ECANet 模块的工作原理示意图	33
图 3.15	本文构建的组合神经网络示意图	35
图 3.16	一维度下的损失函数 loss 的变化	35
图 3.17	实验流程图	43
图 3.18	不同网络的收敛效果	44
图 3.19	预测结果与真实结果对比热度图	46
图 3.20	2016-2020 年不同网络对大豆产量预测的 RMSE	47
图 4.1	一元高斯分布概率密度曲线	50
图 4.2	不同参数下 SE 核的形状	55

图 4.3	人工鱼群算法流程图.....	57
图 4.4	模拟退火算法流程图.....	59
图 4.5	模拟退火-人工鱼群优化高斯过程流程图.....	60
图 4.6	美国气候类型分布.....	61
图 4.7	2017 年大豆产量预测精度热度图.....	61
图 4.8	基于高斯过程优化的组合网络结构图.....	64
图 4.9	添加高斯过程前、后预测结果对比图.....	67
图 4.10	高斯过程超参数优化收敛曲线.....	68

表格索引

表 2.1	MODIS 波段分布特征与应用	12
表 2.2	MOD09A1 波段分布	14
表 2.3	MOD11 产品分类	15
表 2.4	不同的土地覆盖分类系统.....	16
表 2.5	马里兰大学植被分类方案.....	16
表 2.6	土地类型重分类后空间分布情况.....	19
表 3.1	本文实验基础环境.....	41
表 3.2	本文使用的网络结构参数.....	42
表 3.3	2016-2020 年不同网络对大豆产量预测的 RMSE	47
表 4.1	本文实验基础环境.....	65
表 4.2	高斯过程的超参数.....	66
表 4.3	模拟退火的人工鱼群算法相关参数.....	66
表 4.4	高斯过程添加前、后对大豆产量预测的 RMSE.....	67
表 4.5	高斯过程添加前、后及优化后对大豆产量预测的 RMSE.....	68

符号对照表

符号	符号名称
$ \cdot $	复数的模
$\lfloor \cdot \rfloor$	向下取整
$\odot$	同或运算
$\sum$	累加求和
$\mathbb{R}$	空间维度
$\prod$	累积相乘
$E[\cdot]$	期望
$\ \cdot\ _2$	2-范数
$\text{cov}(\cdot)$	协方差
$[\cdot]^T$	矩阵转置
$[\cdot]^{-1}$	矩阵求逆
$\exp$	自然常数 e 为底的指数函数
$*$	卷积

缩略语对照表

缩略语	英文全称	中文对照
ARIMA	Autoregressive Integrated Moving Average	整合移动平均自回归
BP	Back Propagation	反向传播算法
CNN	Convolutional Neural Networks	卷积神经网络
DNN	Deep Neural Networks	深度神经网络
ECANet	Efficient Channel Attention Networks	高效通道注意力模块
EOS	Earth Observation System	地球同步观测系统
EVI	Enhanced Vegetation Index	增强型植被指数
GADM	Database of Global Administrative Areas	全球行政区域数据库
GEE	Google Earth Engine	谷歌地球引擎
GIS	Geographic Information System	地理信息系统
LSTM	Long Short-Term Memory	长短期记忆网络
MIR	Mid-infrared	中红外光
MLP	Multilayer Perceptron	多层感知器
MODIS	Moderate-resolution Imaging Spectroradiometer	中分辨率成像仪
MSE	Mean Squared Error	均方根误差
NASA	National Aeronautics and Space Administration	国家航天局
NASS	National Agricultural Statistics Service	农业统计局
NDVI	Normalized Difference Vegetation Index	归一化植被指数
NIR	Near Infrared	近红外光
RMSE	Root Mean Square Error	均方根误差
RNN	Recurrent Neural Network	循环神经网络
SE	Squared Exponential	平方指数核
SENet	Squeeze-and-Excitation Networks	挤压和激励注意力模块
SVR	Support Vector Regression	支持向量回归
SR	Surface Reflectance	地表反射率
TM	Thematic Mapper	专题制图仪
USDA	United States Department of Agriculture	美国农业部

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.3 主要内容和结构安排.....	5
1.3.1 主要内容与创新点.....	5
1.3.2 章节安排.....	6
第二章 MODIS 数据与产量预测模型简介	9
2.1 研究区域概况.....	9
2.2 遥感估产基本原理.....	10
2.3 MODIS 数据基本原理.....	11
2.3.1 MODIS 简介.....	11
2.3.2 MODIS 植被指数产品.....	13
2.3.3 MODIS 地表反射率.....	14
2.3.4 MODIS 地表温度.....	15
2.3.5 MODIS 土地覆盖类型.....	16
2.4 数据来源.....	17
2.5 数据预处理.....	18
2.5.1 按年份划分数据集.....	18
2.5.2 光谱通道的提取及掩膜处理.....	19
2.5.3 光谱通道组合.....	20
2.5.4 直方图转化.....	21
2.6 农作物产量预测模型简介	21
2.7 本章小结.....	22
第三章 基于注意力机制的组合产量预测模型研究	23
3.1 卷积神经网络的产量预测模型	23
3.2 长短期记忆网络的产量预测模型	28
3.3 注意力机制基本原理.....	30
3.3.1 SENet 注意力机制	31
3.3.2 ECANet 注意力机制.....	33
3.4 基于 ECANet 的 CNN 与 LSTM 组合产量预测模型	34
3.4.1 组合模型的建立.....	34
3.4.2 组合模型的结构.....	34
3.4.3 组合模型的超参数设置.....	35
3.4.4 组合模型的训练.....	37

3.4.5 组合模型评价标准.....	40
3.5 仿真实验及结果分析.....	40
3.5.1 实验数据选择及环境.....	40
3.5.2 实验过程及仿真参数设置.....	41
3.5.3 实验结果及分析.....	43
3.6 本章小结.....	47
第四章 基于高斯过程的产量预测模型研究	49
4.1 高斯过程基本原理.....	49
4.1.1 高斯过程基本概念	49
4.1.2 高斯过程应用于回归问题.....	52
4.2 高斯过程中超参数优化.....	55
4.2.1 人工鱼群算法简介	56
4.2.2 模拟退火算法简介	58
4.2.3 模拟退火-人工鱼群算法简介	59
4.2.4 优化高斯过程超参数.....	59
4.3 高斯过程应用于产量预测模型	60
4.3.1 高斯过程优化产量预测研究.....	60
4.3.2 高斯过程优化产量预测建模.....	62
4.4 仿真实验及结果分析.....	64
4.4.1 基于高斯过程优化的组合网络结构.....	64
4.4.2 实验数据、环境及评价标准.....	65
4.4.3 实验过程及仿真参数设置.....	66
4.4.4 实验结果及分析.....	66
4.5 本章小结.....	69
第五章 总结与展望	71
5.1 本文工作总结.....	71
5.2 未来工作展望.....	71
参考文献.....	73

第一章 绪论

1.1 研究背景及意义

纵观人类文明史，粮食始终是人类社会发展的根本所在。世界各国都把保障农业的良好发展作为首要工作之一。农业作为国民经济的根基，其重要性不言而喻。虽然世界经济水平越来越高，但仍有很多人食不果腹，当前世界整体的粮食产量增长速度低于消耗的速度，也就是说，未来世界粮食资源的缺口将进一步扩大，饥饿问题也将更加显著。尤其，在当今新冠肺炎肆虐全球、地缘纷争不断的情况下，世界各国在粮食安全方面的担忧更甚以往，很多国家已经宣布禁止粮食出口，加上近年出现很多极端天气给粮食作物的生长带来了负面干扰，使得粮食减产，甚至绝产。因此，粮食问题正成为各个国家亟需解决的难题之一，关系到人民的健康生活、社会的和谐稳定以及国家和地区的安全等^[1]。

粮食问题的核心在于粮食安全问题，主要涉及粮食的供给保障，包括确保充足稳定的生产力与粮食的合理分配等。粮食安全关系到国计民生，是现代化国家建设与发展的首要任务之一。当前，世界的总耕地面积增长幅度较小，人均耕地面积持续萎缩，尤其是在一些城市化程度较高的发达国家，人均耕地面积相对更低。为保证粮食供应，一方面专家们致力于研究如何提高农作物的单位面积产量，另一方面，对农作物生长状况的监测和产量预测也是世界农业聚焦的重点之一，精准地预测出粮食产量对于政府部门进行农业生产指导、维持农业的持续良好发展等具有重要作用^[2]。

农作物的生长是一个复杂的过程，包含土壤、水文、日照、肥料、病虫害等多个复杂变量，对农作物产量的预测需要综合上述变量，分析其历史情况，推测未来的生长趋势。因此，对农作物产量预测的困难主要有两点：一是农作物的生长数据繁多，难以获取；二是多个复杂变量的影响使得难以对粮食产量预测做精准的数学建模，如果其中一个环节出问题，预测的结果将会出现很大偏差^[3]。卫星遥感和人工智能技术在农业领域的大力推广，为上述问题的解决带来了新思路。卫星遥感技术是一种近年来兴起的空间信息获取技术，可以在大尺度时间和空间范围内获取丰富信息，且成本相对较低。农作物的生长过程需要时间、空间等多维度的信息，尤其是大尺度、高时效性的信息，因此在农作物的生长数据获取方面，卫星遥感技术凭借其优势可以发挥相当重要的作用，通过遥感影像可以快速、无损地获取农作物全生长周期对应的变化信息，并结合上述信息以量化农作物的生长过程^[4]。同时，农业领域中新兴人工智能技术应用逐渐成为关键因素，主要应用在改善天气预报提

供实时信息帮助农民及时做出各种决策、田间管理协助农民调整耕作计划以及农作物产量预测确保粮食产量需求等方面^[5,6]。传统的预测模型多是利用纯数学方法对农作物的生长数据进行拟合,拟合的精度完全取决于特征值的好坏,且线性的数学方法难以准确反映复杂的农作物生长过程^[7]。人工智能算法对非线性拟合具有相对优势,能够弥补这些缺点,基于人工智能算法的产量预测模型以遥感影像数据为基础,能快速精确地对农作物的长势和产量进行预估,可为粮食政策的制定、国家农业贸易决策等提供重要参考信息,及时掌握农田面积、农作物生长状况、预期产量等关键信息,能有效保障国家粮食安全,对于农产品市场的宏观调控、粮食进出口贸易、政府农业政策的制定等都具有重要的意义。

1.2 国内外研究现状

随着技术的日新月异,农作物的预测方法从单一变量预测模型逐渐发展为组合变量预测模型,包括灰度预测模型 GM(1,1)、多元线性回归等模型。随着遥感和高分辨率卫星技术的发展,出现了许多基于遥感数据的粮食预测方法,机器学习和神经网络的方法也逐渐被引入到粮食产量预测中。

灰度预测模型 GM(1,1) 主要利用灰色信息进行预测,所谓灰色信息,即部分已知、部分未知的信息。灰度预测模型可充分利用贫信息进行有效预测,常用以小范围、短期的预测^[8]。郝妙等根据 2001—2015 年间四川省粮食产量的相关数据,基于灰度理论建立 GM(1,1) 模型,并通过多种维度验证了模型的精确度,最终应用模型预测了四川省 2015 年至 2018 年间的粮食产量同比增长分别为-2.10%、-0.38%和 1.20%^[9]。Li 等根据江苏省 1978-2004 年粮食生产数据和农业统计数据,提出基于灰度预测的粮食损失模型,研究自然灾害对江苏省粮食生产的影响^[10]。

上述估产模型的预测范围都是省级区域,且输入数据较少。国内外众多学者的研究表明,灰度预测模型适合于进行小尺度范围的预测,在大尺度预测时精度会有所下降^[11,12]。针对此问题出现了多元线性回归模型,将影响农作物生长的多种因素作为多元变量进行建模,准确反映了各个变量在作物生长过程中的影响。Chen 等利用中国 1986 年至 2019 年的数据建立了粮食产量的多元回归模型,探讨粮食产量与其影响因素的关系,最终得到粮食播种面积、有效灌溉面积和化肥施用量与粮食产量呈正相关的结论^[13]。F. Jafari 等基于 2007 年至 2014 年的加利福尼亚州的草莓产量和天气数据集,利用时间序列建模与线性和非线性机器学习模型对未来两年产量进行预测,并比较了预测结果,结果表明支持向量回归模型的精度最高^[14]。

结合灰度预测和多元线性回归模型的优点,有学者将灰度预测模型 GM(1,1)和多元线性回归模型进行耦合,建立组合模型,以达到更高的预测精度。李军成等提

出了一种灰色多元线性回归模型，利用该模型与灰色 GM(1,1)模型、多元线性回归模型预测了南宁市的粮食产量，结果表明灰色多元线性回归模型精度最高，预测误差为 0.11%左右^[15]。

此外，也有学者尝试在粮食产量预测中引入整合移动平均自回归模型（Autoregressive Integrated Moving Average, ARIMA），M. Abdollahian 等使用了多种预测模型，根据收获面积和产量估算预测印度尼西亚两个省的湿地水稻产量，分析预测数据的误差以评估模型的有效性，误差分析表明 ARIMA 模型和贝叶斯模型是预测收获面积和产量的最佳模型^[16]。J. A. Putra 等分别使用自回归（AR）方法，移动平均（MA）方法和 ARIMA 方法根据印度尼西亚某公司 2002 年到 2019 年的糖产量数据预测下一个生产周期的生产量，结果表明在三种方法中，ARIMA 方法的平均绝对百分比误差最低，为 15%^[17]。M. Sikalubya 等使用 ARIMA 模型预测了赞比亚大豆产量，使用了自相关、部分自相关与规范贝叶斯信息准则，基于赞比亚 1973 年到 2016 年的时间序列数据，预测结果表明 2020 年赞比亚的大豆产量将增加到 23430.3 hg/ha^[18]。

以上方法都是基于纯数学方法对数据进行拟合处理，建立模型进行产量预测，这些模型若要在大尺度时间及空间内实现精确预测，需要建立非常复杂的数学模型，且其拟合方法多数为线性拟合，和农作物生长情况不符。基于神经网络的预测模型可弥补传统数学模型难以拟合非线性系统的缺点，能处理大尺度范围内复杂的多元变量非线性问题，同时还具有良好的学习、组织和适应能力^[19,20]，在产量预测方面具有突出优势。

在近年来出现的粮食产量预测模型中，神经网络得到了愈加广泛的关注。Wen 等基于反向传播（Back-propagation, BP）网络和灰色系统构建了中国粮食产量多指标组合预测模型，从农业生产条件中选取 7 个指标，以 1980-2006 年多因素原始数据，预测了中国 2007-2015 年的粮食产量^[21]。Xu 等选取吉林省 1970-2011 年粮食生产数据为研究对象，以影响农业生产的 7 个因素为影响因素，分别采用了回归分析和 BP 神经网络两种方法。最终结果，BP 神经网络分析的预测平均准确率为 91.4%，比回归分析的预测平均准确率高约 8.7%^[22]。

针对神经网络收敛较慢和易于陷入局部极小值的问题，有学者将 BP 神经网络和其他算法相结合，以获得更好的鲁棒性和更高精度。宗宸生等提出了一种结合粒子群算法的 IPSO-BP 神经网络模型，相比于单 BP 神经网络模型，其预测结果的精度和稳定性得到了大幅提高，其相对误差小于 0.05^[23]。Wang 等设计了将主成分分析与 BP 神经网络相结合的新型产量预测模型。通过线性变换将大输入变量转换为包含原始输入变量信息最多的较少独立输入变量，所得到的模型在运算速度上和精度上都优于一般的 BP 神经网络^[24]。罗梦森等利用 1951—2010 年期间江苏省水稻产

量及期间该地的天气、水文等资料,采用因子膨化及相关分析,建立了逐步回归、PCA-BP 神经网络以及 PCA-GA-BP 神经网络 3 种产量预测模型。结果表明 PCA-GA-BP 神经网络的训练速度提高了 70%左右,预测精度也有所提高^[25]。

基于卫星遥感数据的机器学习方法,特别是深度学习方法的产量预测模型近年来取得了很大进展,包括卷积神经网络(Convolutional Neural Networks, CNN)、循环神经网络(Recurrent Neural Network, RNN)和深度神经网络(Deep Neural Networks, DNN)等。CNN 可以探索更多的空间特征,因而在产量预测中常用以特征提取。周亮等提出了一种用于冬小麦估产的 CNN 模型,该模型基于中分辨率成像仪(Moderate-resolution Imaging Spectroradiometer, MODIS)遥感数据,对 2006-2016 年中国北方冬小麦核心区的 60 个市进行模型训练,结果表明所设计模型的均方根误差的平均值 772.03 kg/hm^2 ,在较大尺度范围内具有较高的预测精度^[26]。M. Shahhosseini 等基于 1980-2019 年间美国玉米带的产量相关数据,提出了一种 CNN-DNN 的玉米产量预测模型,考虑了两种网络的同质集成和异构集成,对比了所设计网络和五种机器学习方法的预测精度,结果表明两种集成的模型均优于其他模型,相对均方根误差约 8.5%^[27]。S. Khaki 等提出了一种 CNN-RNN 的产量预测模型,使用历史数据计算了 2016-2018 年期间美国玉米带的玉米和大豆产量,结果表明所设计模型的均方根误差约 8%,优于随机森林(Random Forests, RF)方法^[28]。长短期记忆网络(Long Short-Term Memory, LSTM)具有揭示物候特征的能力,在作物产量预测中发挥着重要作用。H. Mo 等基于广西省 81 个县的三年水稻产量数据,建立了对应的 LSTM 模型以预测气象因素影响下的水稻产量,结果表明 LSTM 模型性能优于 RNN 网络,解决了 RNN 模型的梯度分散和梯度爆炸问题^[29]。考虑到 CNN 网络和 LSTM 网络的优点,戴建国等构建了一种 CNN+BiLSTM 的组合网络预测模型对棉花产量进行预测,提高了单一网络在时空维度方面的特征提取能力,结果表明所设计模型的绝对百分比误差仅 6.7%^[30]。

上述文献报道的方法中还存在以下几点不足:有些模型过度简化了影响粮食产量的相关因素;有些模型忽略了粮食产量和部分影响因素之间的关系;有些模型对粮食产量的影响因素进行了分析,但是忽略了模型中可能存在的多重共线性导致模型失真等问题;有些模型的空间和时间扩展性欠佳;有些模型精确度相对不足。

总的来说,基于纯数学方法的预测模型具有简单方便,运行速度快,可解释性强等优点,在一些产量预测的应用中也取得了不错的效果。而神经网络模型相对来说复杂度较高,模型表达不够简单直观,但其能更好地捕捉各种内在关联,例如和作物生长相关的变量间的线性和非线性关系,因而其在大尺度范围内的拟合效果、预测精度、鲁棒性等都具有明显优势,在农作物产量预测领域具有广泛的前景和大规模应用潜力。

1.3 主要内容和结构安排

1.3.1 主要内容与创新点

本文基于农作物产量预测的相关背景，以美国大豆产量作为研究对象，选取美国 11 个大豆总产量占全国产量 75% 以上州的 MODIS 卫星遥感图像数据，建立组合神经网络预测模型 CNN+ECANet+LSTM，使用高斯过程对其预测结果进行优化，所设计模型预测精度较高，具有良好应用价值。本文的总体研究思路与内容如下图 1.1 所示：




图1.1 本文总体技术路线图

本文创新点主要为：

(1) 针对传统线性拟合产量预测模型预测精度不足的问题，本文提出将 CNN 与 LSTM 组合的产量预测模型。单一的 CNN 在提取特征值方面有突出优势但缺乏时间相关性，而 LSTM 适合处理时间序列数据但不能有效扩充通道数量，二者组合可以取长补短。在该模型基础上添加高效通道注意力机制（Efficient Channel Attention Networks, ECANet）模块以优化特征值的权重分配，解决了 MODIS 数据中各个光谱

之间独立计算的问题。仿真结果表明相较于传统的单一神经网络模型，本文所提出的 CNN+ECANet+LSTM 组合网络预测模型的整体预测精度得到有效提高。

(2) 针对上述组合网络产量预测模型中缺乏年份和地理位置信息相关性因素导致预测精度降低的问题，本文提出基于高斯过程优化的 CNN+ECANet+LSTM 产量预测模型，将 MODIS 数据集中的年份与地理位置信息通过协方差的参数加入到高斯过程的建模中，对输入信息的维度进行扩张，从而建立时空相关模型。由于高斯过程回归中凭经验选择的超参数会限制模型的泛化能力，利用模拟退火-人工鱼群算法对高斯过程进行优化。仿真结果表明优化超参数的高斯过程提高了组合产量预测模型预测精度，并且预测稳定性有较好的改善。

1.3.2 章节安排

第一章是绪论部分。首先介绍了农作物产量预测的背景和意义，分析了粮食安全的重要性；接着分析了国内外粮食预测相关的进展和研究成果；随后概括了本文的主要内容和创新点；最后给出了本文的技术路线和章节安排。

第二章介绍了 MODIS 数据概念与预处理方法。首先介绍了本文的研究区域——美国 11 个大豆主要生产州县的基本情况；接着从遥感估产的理论入手，简要介绍了 MODIS 遥感数据的相关概念、产品及获取方法等；之后重点讨论了 MODIS 数据中关于遥感估产的相关产品，研究了其计算方法以及在作物生长过程中的变化；最后经过分析基于植被指数的预测模型特点，因其存在需手动提取特征值、模型泛化能力不强的劣势，本文决定选取地表反射率、地表温度以及土地覆盖类型三种 MODIS 产品，组成用来确定特征值的光谱组合；最后介绍了光谱组合的处理方法和数据的降维方法。

第三章介绍了基于注意力机制优化的 CNN+ECANet+LSTM 组合网络。首先分别介绍了基础的 CNN 网络和 LSTM 网络基本原理，通过分析各自优缺点将两者相结合；接着简要介绍了注意力机制的原理，选取本文所用到 ECANet 模块；之后将注意力机制模块应用到上述组合网络模型中，通过网络学习主动获取每个特征值不同的重要程度，从而完成特征重标定，达到提升重要特征并抑制不重要特征的效果；最后通过仿真结果进行对比分析，表明组合网络加注意力机制模块组成的预测模型表现更优。

第四章介绍了基于高斯过程优化的粮食产量预测模型。首先简要介绍了高斯过程的基本原理，探讨了其应用在机器学习中回归问题的可行性；在此基础上，就高斯过程回归中超参数选择的关键问题进行探索，分别介绍了模拟退火、人工鱼群两种全局寻优方法；然后将两者结合在一起，对高斯过程回归的超参数选择进行优化；接着利用高斯过程在上一章的组合模型中添加神经网络学习时无法添加的时空相关

因素，提高模型的泛化能力；最后进行仿真，结果表明优化后的混合模型预测误差最小。

第五章总结了全文主要研究内容，在本文的研究基础上对进一步工作提出建议。

第二章 MODIS 数据与产量预测模型简介

本文以美国大豆产量作为研究对象，在本章中介绍了研究区域的整体情况，从遥感理论出发，介绍了所使用 MODIS 数据的基本情况、估产相关产品和获取方法等；因遥感图像数据不能直接导入至神经网络模型中，需进行预处理，因此本章介绍了相应的预处理方法。最后介绍了现有的农作物产量预测模型。

2.1 研究区域概况

大豆是一种粮油兼用作物，是食品工业中油脂和植物蛋白的主要来源之一，也是畜牧业所需的主要饲料之一。大豆在国家粮食战略和世界农作物贸易中占据着重要地位。美国的大豆产量连续多年稳居第一，占据世界大豆总产量的三分之一，是全世界大豆供应的中心。美国 2019 年大豆种植分布变化如图 2.1 所示，主要分布在以伊利诺伊州为中心的中部种植带。本文以美国大豆产量作为预测对象，对美国中部 11 个占全国大豆产量 75%以上的州的县级产量进行建模，提取 2003-2020 年的相关数据以获得预测结果。




图2.1 美国 2019 年大豆种植分布变化

2.2 遥感估产基本原理

遥感是指远距离的非直接接触的探测技术。遥感技术运用高精度的传感器，从远距离非接触地对目标进行实时探测，以实现为目标的信息获取。遥感估产是通过资源卫星收集农作物在不同条件下反映的光谱特征，根据光谱特征可辨别作物种类、监测农田状态、收集和农作物生长相关的外部信息，并根据所监测到的农作物生长情况，结合农作物的历史收成，就可实现对产量的预估。遥感估产的主要内容包括作物识别与播种面积提取、长势监测与产量预测等^[31]。

作物类型的精准识别是遥感估产的重要环节之一，由于农作物在近红外（Near Infrared, NIR）波段的反射波主要取决于其叶片结构，不同种类植物具有其特定的叶片结构，根据其反射的不同就可以确定农作物的种类^[32]。且农作物在不同的天气、地理条件下播种、生长、收割的时间上存在差异，这种差异可以在遥感图像中精确体现^[33]。农作物种植面积提取的主要原理在于农作物的光谱反射曲线和外部环境不同，因此可以在遥感图像中提取农作物的光谱反射特征^[34]。水在 NIR 和中红外（Mid-infrared, MIR）波段几乎无法反射，因此很容易识别。土壤的光谱反射曲线在可见光和 NIR 波段的差值较小，而农作物在可见光与 NIR 两波段光谱值的反差较大，二者反射曲线区分度明显。因此，可以根据以上差值大小来区分农作物和土壤。基于上述原理可对农作物进行精准识别，识别方法主要包括航天遥感方法、航空遥感方法、遥感与统计学相结合、遥感与地理信息系统（Geographic Information System, GIS）相结合的方法等。

作物长势监测是对作物的生长、营养、病虫害等方面的监测，由于光照、温度、水文、土壤、肥料、病虫害等条件的区别，农作物的生长状况各不相同，在卫星图像中得到的光谱数据也不同，根据光谱数据的差异对比可以对作物的生长状况进行掌握，以监测农作物的长势^[35]。

利用卫星遥感的方法获取农作物生长的相关信息虽然方法便利，数据可靠，但仍存在诸如容易受天气状况影响、获取精确数据的成本过高、传感器空间和时间分辨率难以兼得、大尺度监测的数据量庞大难以处理等问题。卫星传感器技术水平限制了遥感图像的尺度范围和空间分辨率，比如陆地卫星专题制图仪（Landsat TM）、中巴地球资源卫星电荷耦合相机（CBERS CCD）等获取的图像都具有空间范围小、时间分辨率差的缺点。而 MODIS 可以获取大范围且高时间分辨率的卫星图像，被广泛应用在农业遥感卫星平台中。

2.3 MODIS 数据基本原理

2.3.1 MODIS 简介

在 20 世纪 90 年代, 为研究气候变化、生态变化、自然灾害原因以及人类对自然环境的影响等问题, 准确地获取地球的实时变化情况, 美国国家宇航局 (National Aeronautics and Space Administration, NASA) 建立了地球同步对地观测系统 (Earth Observation System, EOS) 卫星平台, EOS 系列卫星中所搭载的最重要的仪器之一即为中分辨率成像光谱仪 MODIS, MODIS 主要通过捕捉不同的光谱波段数据, 以获取自然界和生态圈的动态变化, 应用于各项自然科学的研究^[36,37]。

MODIS 共包含了 36 个分布在 $0.4 \sim 1.4\mu\text{m}$ 的电磁波谱范围内的光谱通道, 每个光谱通道都有各自的用途, 分别对应不同的观测信息, 可用于对陆表、生物圈、固态地球、大气和海洋的全球长期观测, 能够完成土地利用和土地覆盖研究、气候变化研究与自然灾害分析、海洋生态变化监测等^[38]。MODIS 的主要测量任务为: 全球陆地和海洋表面特性; 海洋沉积物和叶绿素; 全球植被测绘和变化探测; 云层和大气特征表征; 气溶胶浓度和特性; 大气温度和湿度; 雪层覆盖; 海洋洋流等方面的数据。MODIS 各个波段分布特征和参数如表 2.1 所示。上述数据为作物估产提供了丰富的研究资料, 相比于其他传感器如 TM、CCD 等, MODIS 数据在作物估产领域的产品更为丰富, 其具有如下突出优势:

(1) 全球免费: MODIS 数据是面向全世界免费获取的, 相关数据可直接在 NASA 官网上下载, 这种廉价可靠的数据资源对个人用户和学生用户来说十分宝贵;

(2) 光谱范围广、分辨率高: MODIS 数据分布在 $0.4 \sim 1.4\mu\text{m}$ 波段内的 36 个光谱通道, 辐射分辨率达 12bits, 地面分辨率分别为 250m、500m 和 1000m。这些光谱通道可以获取到大量地球生态圈内的丰富、详尽的数据;

(3) 数据接收简单: MODIS 接收相对简单, 它利用 X 波段向全球免费发送, 接收者使用 3m 的天线就可以接收卫星信号, 我国在 21 世纪初就已建立了多个接收站;

(4) 扫描范围广: 搭载 MODIS 的 TERRA 和 AQUA 卫星为太阳同步卫星, 最高扫描范围可达 2330km, 扫描角度最高可达 $\pm 55^\circ$, 单次扫描就可以覆盖全球的多数区域, 覆盖范围非常广泛, 并且其可对很多较难探测的区域进行覆盖^[39]。

(5) 更新频率高: TERRA 和 AQUA 卫星运行在太阳同步轨道上, 同一地点一天内可衔接交替过境。对于 MODIS 数据接收者来说, 每天昼夜最少可以通过 TERRA 和 AQUA 卫星更新两次数据。快速更新的数据对地球实时观测等信息时效性要求较高的学科有重要意义。

表2.1 MODIS 波段分布特征与应用

波段	波段光谱范围 (nm) 反射	波段光谱范围 (nm) 发射	主要用途	分辨率
1	620-670		地表覆盖, 植被叶绿素	250
2	841-876		云量, 植被	250
3	459-479		土壤 / 植被	500
4	545-565		绿色植被	500
5	1230-1250		叶 / 冠层	500
6	1628-1652		雪 / 云	500
7	2105-2155		云, 陆地特征	500
8	405-420		叶绿素	1000
9	438-448		叶绿素	1000
10	483-493		叶绿素	1000
11	526-536		叶绿素	1000
12	546-556		沉积物	1000
13	662-672		大气, 沉积物	1000
14	673-683		叶绿素荧光	1000
15	743-753		气溶胶特征	1000
16	862-877		气溶胶特征, 大气特征	1000
17	890-920		大气特征, 云特征	1000
18	931-941		大气特征, 云特征	1000
19	915-965		大气特征, 云特征	1000
20		3.660-3.840	海洋表面温度	1000
21		3.929-3.989	森林火灾和火山	1000
22		3.929-3.989	云温度, 地表温度	1000
23		4.020-4.080	云温度, 地表温度	1000
24		4.443-4.498	云分量, 对流层温度	1000
25		4.482-4.549	云分量, 对流层温度	1000
26	1360-1390		云分量 (薄卷云), 对流层温度	1000
27		6.535-6.895	中对流层湿度	1000
28		7.175-7.475	上对流层湿度	1000
29		8.400-8.700	地表温度	1000
30		9.580-9.880	臭氧	1000

31		10.780-11.280	云温度, 森林火灾和火山, 地表温度	1000
32		11.770-12.270	云高, 森林火灾和火山, 地表温度	1000
33		13.185-13.485	云分量, 云高	1000
34		13.485-13.785	云分量, 云高	1000
35		13.785-14.085	云分量, 云高	1000
36		14.085-14.385	云分量, 云高	1000

2.3.2 MODIS 植被指数产品

植被指数是对植被生长情况的度量。因为健康的绿色植被在 NIR 波段和红光 (RED) 波段的吸收和反射差异比较大, 植被指数即是反应上述差异的指标, 由于不同的应用场景和情况, 发展出了不同的植被指数。植被指数和绿色植被中的叶绿素含量息息相关, 而叶绿素是体现作物生长状况的非常重要的指标之一, 所以通常植被指数是农作物产量预测的重要指数之一。

目前常用的植被指数包括归一化植被指数 (Normalized Difference Vegetation Index, NDVI)、增强型植被指数 (Enhanced Vegetation Index, EVI) 等。归一化植被指数 NDVI 应用最为广泛, 其计算方法为:

$$NDVI = \frac{\rho_{NIR} - \rho_{RED}}{\rho_{NIR} + \rho_{RED}} \quad (2-1)$$

其中, ρ_{NIR} 和 ρ_{RED} 分别表示 NIR 波段反射率和 RED 波段反射率, 由上式可知 NDVI 的取值越接近 1, 说明其植被覆盖率越高, 取值在 0 以下则为无植被覆盖的裸石、冰雪地貌^[40]。NDVI 数据获取便利、计算方法简单, 但其容易在计算植被覆盖较高的地区事出现分辨率不足的状况, 因此专家在 NDVI 中引入环境参数进行约束, 再使用土壤背景信息进行校正, 得到增强型植被指数 EVI, 计算方法为:

$$EVI = 2.5 \times \frac{\rho_{NIR} - \rho_{RED}}{L + \rho_{NIR} + C_1 \rho_{RED} - C_2 \rho_{BLUE}} \quad (2-2)$$

其中, ρ_{RED} 、 ρ_{BLUE} 、 ρ_{NIR} 分别表示农作物在 RED 波段、蓝光 (BLUE) 波段和 NIR 波段的反射率, BLUE 波段提高了农作物识别率, L 为土壤调节系数, C_1 、 C_2 为拟合系数。相比 NDVI, EVI 提高了生物量群体的敏感度, 充分考虑了土壤和大气对植物的影响, 解决了 NDVI 指数易饱和的缺陷^[41]。

2.3.3 MODIS 地表反射率

TERRA 卫星提供的型号为MOD09A1的MODIS数据产品，其中 1-7 个对地观测波段类似于 TM 的波段，带宽较窄，因此可以减弱大气效应的影响，数据质量更佳。同时还可以从反射率数据中提取各种指数信息如水体指数、植被指数、亮度指数等分类特征指数参与到各个分类方法中。不同土地利用/土地覆盖之间反射光谱差异明显，植被、土壤和水体在可见光和 NIR 波段范围的光谱特征差异较大，植被与土壤在 RED 波段(0.60~0.67 μm)部分的反射率低于在 NIR 波段(0.7~1.1 μm)的反射率。在 BLUE 波段(0.459~0.479 μm)，反映出土壤与植被的差异；在 RED 波段(0.620~0.670 μm)处，对植被的覆盖度及生长状况敏感，在影像上可以表现出明显的植被特征；而在 NIR 波段(0.841~0.876 μm)处具有高反射于绿色指标的特点。水体的反射主要在绿光、BLUE 波段，在 NIR、MIR 范围内，水体吸收所有光波，而土壤对所有入射均能吸收或反射。

表2.2 MOD09A1 波段分布

MOD09A1 第 1-7 波段（记为 refl-7）	TM 对应的波段（记为 TM1-7）
sur_refl_b01（0.62-0.67 μm ）	TM4（红 Red）
sur_refl_b02（0.841-0.876 μm ）	TM3（近红外 NIR）
sur_refl_b03（0.459-0.479 μm ）	TM1（蓝 Blue）
sur_refl_b04（0.545-0.565 μm ）	TM2（绿 Green）
sur_refl_b05（1.230 -1.250 μm ）	
sur_refl_b06（1.628-1.652 μm ）	TM5（短红）
sur_refl_b07（2.105-2.135 μm ）	TM7（短红）




图2.2 MOD09A1 光谱图像

2.3.4 MODIS 地表温度

温度在植物生长过程中起到重要作用，TERRA 卫星提供的型号为 MYD11A2 的 MODIS 数据产品中关于温度的产品主要是地表温度。地表温度是表征地面温度的参数，其反映了陆地表面的能量平衡，其在农作物生长阶段产生重要影响，直接关系到农作物的最终产量。地表温度在不同区域的具体表现不相同，MODIS 地表温度产品包含了丰富的地表温度相关数据。影响地表温度的因素有很多，包括光照时间、光照强度、当地气温、大气湿度等，而植物的覆盖面积也会对地表温度产生直接影响，无植被覆盖的区域一般来说地表温度要高于有丰富植被覆盖的区域。MOD11 产品就是 MODIS 数据中关于地表温度的监测数据，根据时间和空间分辨率的不同，MOD11 又可细分为以下几个数据产品，如表 2.3 所示：

表2.3 MOD11 产品分类

产品名称	时间分辨率	空间分辨率
MOD11A1	1D	1km
MOD11A2	8D	1km
MOD11L2	5MIN	1km
MOD11B1	1D	6km
MOD11C1	1D	5deg
MOD11C2	8D	5deg
MOD11C3	MONTH	5deg




图2.3 MOD11 光谱图像

2.3.5 MODIS 土地覆盖类型

TERRA 卫星提供的型号为MCD12Q1的MODIS 土地覆盖类型产品主要提供每年全球土地覆盖地图，本文所使用的 MODIS 土地覆盖类型产品MCD12Q1包括由五种不同分类系统的土地覆盖数据和 12 个科学数据集，以及基于联合国粮食及农业组织土地覆盖分类系统的新三层图例和质量控制层及产品使用的二元水陆层掩膜，用于以 500 米的空间分辨率绘制六种不同土地覆盖图例的全球土地覆盖地图，五种分类系统如下表所示。MODIS 土地覆盖类型数据是根据当前世界土地覆盖信息，并利用修正算法校正处理后所得，据验证 MODIS 土地覆盖类型的数据精度在 70%以上。

表2.4 不同的土地覆盖分类系统

分类系统类型	数据类型	有效范围	填充值
IGBP 分类方案	8 bit	[1,17]	255
UMD 分类方案	8 bit	[0,15]	255
LAI 分类方案	8 bit	[0,10]	255
BGC 分类方案	8 bit	[0,8]	255
PFT 分类方案	8 bit	[0,11]	255

表2.5 马里兰大学植被分类方案

属性值	类型
0	水
1	常绿针叶林
2	常绿阔叶林
3	落叶针叶林
4	落叶阔叶林
5	混交林
6	稠密灌丛
7	稀疏灌丛
8	木本热带稀树草原
9	热带稀树草原
10	草地
12	耕地
13	城建区
16	裸地




图2.4 掩膜量化后的土地覆盖光谱图像

本文选择马里兰大学植被分类方案（UMD Land Cover Classification）。美国马里兰大学根据 AVHRR 卫星获得影像制作了此分类方案，如表 2.5 所示，该数据集共分为 14 个不同的土地覆盖类型，同时，有三个维度的空间分辨率：1deg，8000km 和 1000m 像素分辨率。其中耕地的属性值为 12。

2.4 数据来源

本文中所使用的数据均下载于谷歌地球引擎（Google Earth Engine, GEE），GEE 平台是由谷歌公司开发的新一代基于云的地球科学数据和分析应用行星尺度平台，该平台涵盖了丰富的遥感影像数据，支持数据的在线分析和处理，是当前世界上功能最齐全的云计算平台。通过上传脚本到 GEE 服务器上可下载到 NASA 关于 MODIS 产品的与本文研究相关的数据，包括从 2003-2020 年美国 11 个占全国大豆产量 75%以上的州的卫星遥感图像数据。具体做法如下：

本文设计的神经网络是针对某州中某县的农作物产量估计，这样针对小范围内的环境特征训练网络来预测产量的方案，既能使得数据集提供更加精准、有效的特征，又能使得农作物产量预测方案更有针对性，且预测结果更加准确，减少了神经网络过拟合情况的发生。

由于 GEE 上提供的卫星遥感 MODIS 数据默认为整个地球的区域，并没有适配的行政划分，但需要根据每个州、县的产量及周边环境预测，经过查阅相关文献及资料，通过在全球行政划分数据库（Database of Global Administrative Areas, GADM）中下载美国地区的行政边界划分数据，并将其上传至 GEE 的服务器，在 GEE 中调用相应的函数对整个地图的边界进行划分，形成一个数据库，通过脚本实现了根据

行政区划自动将每个州或者每个县的遥感地图上传至谷歌服务器 Google Drive 选择某州、某县、某年、某光谱组合的 MODIS 数据集的下载。

图 2.5 所示为 GADM 中选定区域划分的界面，以及已经下载完成的某区域卫星遥感数据集。



图2.5 GADM 数据下载页面

2.5 数据预处理

任何实际获取的遥感图像，都在不同程度上与实际地物的辐射能量分布有差异。由于下载得到的三种产品（地表反射率、地表温度、土地覆盖类型）的数据集是多年份混合，且不同产品的采样周期不同，不同地区的区域大小也不同，所以在将数据集送入神经网络训练之前，还需要对其进行预处理，其过程主要分为：按年份划分数据，光谱通道组合，通过掩膜筛选耕地区域，将数据转换为直方图。

2.5.1 按年份划分数据集

下载到的数据集是自 2003 到 2020 年共 18 年的数据混合叠加起来的，在数据预处理阶段，首先将混合数据集按年份划分，其中地表反射率和地表温度的采集频率为 8 天/次，土地覆盖类型的采集频率为 365 天/次，设叠加的总通道数为 B ，光谱产品每次采集的通道数为 N ，采集频率为 M 天/次，这样就可以计算出每个年份所占的光谱数 bands 为：（其中 $\lfloor \cdot \rfloor$ 表示向下取整）

$$bands_{1year} = N \times \left\lfloor \frac{365}{M} \right\rfloor \quad (2-3)$$

叠加光谱通道按年份划分后结果如图 2.6 所示：




图2.6 按年份划分的叠加光谱通道

根据以上划分结果可完成对多年叠加通道的数据集的年份划分工作。

2.5.2 光谱通道的提取及掩膜处理

由于所下载的原始数据是从 2003 年到 2020 年所有光谱数据叠加在一起的结果，其中地表反射率和地表温度的获取周期是 8 天一次，土地覆盖率的获取周期是每年一次，据此按照年份计算出每年具体的光谱数量，从中提取所需要的对应地表反射率的 7 个光谱和对应地表温度的 2 个光谱，然后按照大豆的生长周期（从每年的第 49 天到 305 天为大豆的一整个生长周期）过滤掉无用信息。

表2.6土地类型重分类后空间分布情况

属性值	类型	属性值	类型
0	水	0	
1	常绿针叶林	0	
2	常绿阔叶林	0	
3	落叶针叶林	0	
4	落叶阔叶林	0	
5	混交林	0	
6	稠密灌丛	0	
7	稀疏灌丛	0	
8	木本热带稀树草原	0	
9	热带稀树草原	0	
10	草地	0	
12	耕地	1	大豆
13	城建区	0	
16	裸地	0	

经过分析，需要将上述按年份分类提取所需光谱处理以后的数据中的土地覆盖数据进行预处理和重分类，MODIS 遥感影像在美国马里兰大学的土地分类方案的基础上，为便于处理和分析土地覆盖类型的变化，将原始的土地覆盖类型按照 0-1 的方式进行重分类，空间分布情况由表 2.6 所示。

基于以上结果形成特定的作物掩膜，具体做法为：判断图片上对应值为 12 的，将其量化为 1，其余的均量化为 0，量化结果如下图所示：




图2.7 添加掩膜前、后的光谱图像

2.5.3 光谱通道组合

本文中下载得到的三种产品所包含的通道数分别为：地表反射率 7 个、地表温度 2 个、土地覆盖类型 1 个，先将经过上述年份划分处理后同一区域的地表反射率和地表温度对应的通道数进行叠加，即形成一个通道数为 9 的组合光谱通道，再经过上一小节中的掩膜处理，即如图 2.8 所示：




图2.8 通道数组合与掩膜处理示意图

2.5.4 直方图转化

通过将图片转换为直方图来解决不同区域的长宽参差不齐与训练数据不足的问题，并对直方图使用归一化处理，利用神经网络体系训练这些直方图，从变换后的归一化直方图中学习特征，以预测作物产量。

鉴于标记训练数据的稀缺性，直接训练模型是不可行的。基于计算机视觉方法进行预训练也不合适，因为遥感图像是多光谱的，并且是从鸟瞰的角度拍摄的。因此，在置换不变性的假设下设计了一种降维技术，此方法基于以下几点：忽略在一个区县（即很小范围内）农田地理位置对产量的影响，因为在同一个区县范围内，土壤的类型、海拔及一系列影响农作物生产的因素变化并不明显。将光谱图片转变为直方图的方法为在每个光谱上统计规定区间内的像素点数量，针对不同的区县采用相同的规定区间，从而完成对长宽不同数据集的统一，更方便其进入神经网络。

2.6 农作物产量预测模型简介

节 2.3 中介绍的 MODIS 数据产品中，植被指数在估产模型中的使用较多，大多使用的特征包括 NDVI、EVI 等。这些基于植被指数的估产模型大多使用纯数学方法建模，虽然在特征工程方面投入了大量精力，但现有的特征依然相当粗糙，通常依赖于少量（通常是两个）可用波段。例如前文介绍的公式（2-1）与（2-2）中可以发现其只针对红外波段 NIR、红光波段 RED 与蓝光波段 BLUE 进行运算。而且针对不同地区，不同年份的特征计算时使用相同的特征计算公式，不能体现模型的泛用性。所以这种利用波段直接进行运算从而手动提取特征的估产模型并不能充分挖掘 MODIS 提供的光谱数据中的有效信息。

受深度学习快速发展的启发，出现很多基于神经网络的产量预测模型：基于 BP 神经网络产量预测模型；基于 CNN 的产量预测模型；基于 RNN 的产量预测模型；基于 DNN 的产量预测模型；或者将神经网络与灰度算法、多元线性回归算法等方法相结合的模式。

相比于利用纯数学方法对数据进行拟合处理、建立模型进行产量预测，基于神经网络的预测模型可弥补传统数学模型难以拟合非线性系统的缺点，能够处理大尺度范围内复杂的多元变量非线性问题，此类模型可将原始数据集经过预处理后直接送入神经网络中，根据预测结果与实际产量的反馈更新网络状态，进而从原始数据中自动发现相关特征，即将上述介绍的 MODIS 地表反射率、MODIS 地表温度以及 MODIS 土壤覆盖类型等原始图像数据进行预处理后直接利用神经网络挖掘其中的相关特性，这样的数据处理方法既能将多种 MODIS 产品运用到特征提取，又能针对不同年份不同地区建立模型，从而使学习的特征更有效。同时还具有更

高效的学习、组织和适应能力，在产量预测方面具有突出优势。

2.7 本章小结

本章首先介绍了所研究区域的整体情况，从遥感估产基本原理入手，介绍了 MODIS 基本理论及其在观测范围和观测精度上的优势；接着介绍了本文中 MODIS 数据获取的来源、方法以及罗列了 MODIS 数据中影响农作物产量的主要产品；接着，对本文中所使用的光谱通道的选取以及降维优化方法进行了简要介绍。最后，简要介绍了现有的农作物产量预测模型。

第三章 基于注意力机制的组合产量预测模型研究

神经网络在处理复杂非线性问题中具有突出优势，因而可使用神经网络方法对农作物产量进行预测。本文考虑 CNN 网络预测模型和 LSTM 网络预测模型各有其优点和缺点，而将 CNN 和 LSTM 组合得到的预测模型能达到取长补短的效果，同时采用注意力机制优化卷积过程中不同特征值之间的权重分配，提升网络的预测性能。本章围绕上述问题开展研究。

3.1 卷积神经网络的产量预测模型

在深度学习领域中，CNN 以其局部权值共享的特殊结构在目标检测、图像识别与处理方面有着独特的优越性，正成为深度学习领域应用最成功的算法之一^[42]，因此适合用作农作物产量预测模型。

卷积神经网络是依据人类局部感知的认知模式构造，布局接近生物神经网络，其本质是在模式已知的情况下，不需要精确的数学表达式网络就具有能够学习到大量输入到输出间映射的能力。CNN 因其越往输入权值越小，越往输出权值越多的特性，从而有效避免了 BP 神经网络中反向传播时梯度损失太快的缺点^[43]。同时，CNN 属于前向神经网络的一种，在 CNN 提出前，算法工程师们最常使用的是多层感知器（Multilayer Perceptron, MLP）。MLP 是一个典型的全连接神经网络，即每一层的神经元都与下一层的所有神经元连接，导致数据易出现过拟合问题，同时参数数量过多会导致计算量庞大，如图 3.1 所示。卷积神经网络以局部连接和权值共享的思想解决了多层感知机面临的问题。局部连接即每层的神经元不再和下层的所有神经元相连接，该部分局部神经元称为局部感受野。权值共享是指一组连接中可共享同一个权重（即为卷积核中数值）而不是每个连接都有一个权重，这样可进一步减少参数，特别在处理多维输入向量时能有效避免特征提取和分类，达到降低网络复杂度的目的。引入下采样层能进一步减少参数数目，提高整体性能。




图3.1 全连接和局部连接示意图

通常卷积神经网络模型是在前馈神经网络模型基础上，添加卷积层、池化层和全连接层，并且还包括重要组成部分：激活函数^[44]。卷积神经网络的整体结构如图 3.2 所示：




图3.2 卷积神经网络结构示意图

(1) 卷积层

卷积层主要通过卷积神经网络的权值共享和局部连接特性，从原始输入中提取特征，卷积层的计算公式为：

$$a_{i,j} = f \left(\sum_{m=0}^2 \sum_{n=0}^2 w_{m,n} x_{i+m,j+n} + w_b \right) \quad (3-1)$$

式中 $w_{m,n}$ 表示图像的第 m 行第 n 列权重， $x_{i,j}$ 表示图像的第 i 行 j 列元素， w_b 表示滤波器偏置项， $a_{i,j}$ 表示特征图的第 i 行 j 列元素， $f(\cdot)$ 表示激活函数。

如图 3.3 所示为卷积层通过卷积核从左向右、自上而下滑动将特征图进行卷积操作而输出特征图的过程。




图3.3 卷积过程示意图

(2) 池化层

池化层用于缩减模型大小，提高计算速度，是对上层卷积结果的一个采样处理。池化的结果是使得特征减少，参数减少。常用的池化操作主要用来处理非叠加区域，主要有平均池化和最大池化两种常用方式。平均池化通过对范围内特征值求平均来计算，主要用以抑制估计值方差的异常增大，其优点在于较多地保留了原始数据。通常最大池化方法用的更多些，在卷积神经网络中，使用最大池化层时，是取 $n \times n$ 输入区域中的最大特征点作为采样后的样本数据，池化出来的特征图计算公式为：

$$W_2 = \frac{(W_1 - F + 2P)}{S} + 1 \quad (3-2)$$

$$H_2 = \frac{(H_1 - F + 2P)}{S} + 1 \quad (3-3)$$

其中， W_1 和 W_2 指特征图池化前后的宽度， H_1 和 H_2 指特征图池化前后的高度， F 代表滤波器宽度， P 代表零填充数量， S 表示步幅。

图 3.4 为 2×2 的最大池化和平均池化：




图3.4 2×2 的最大池化和平均池化示意图

(3) 全连接层

全连接层是指层中的每个神经元节点都会连接它下一层的所有节点，通常在若干个卷积和池化层之后，其作用是防止局部连接的特征丢失，将经过卷积和池化后的结果进行组合，最后将结果输出，在整个卷积神经网络中起到“分类器”的作用，全连接层是在卷积层、池化层等将原始数据映射到隐层特征空间的操作之后将学习到的特征表示映射到样本的标记空间，它大大减少了特征位置对分类带来的影响，把特征整合到一起从而高度提纯特征，方便交给最后的分类器或者回归。全连接层的链接如图 3.5 所示：




图3.5 全连接层的链接示意图

(4) 激活函数

卷积神经网络里卷积层和池化层对特征图做线性变化，激活函数则在其基础上引入非线性因素，从而填补了线性模型表达力不够的劣势，加强网络的学习能力^[45]。假如没有激活函数，神经网络只能完成从输入 X 到输出 Y 的线性映射，这样前向传播过程中唯一的数学操作就是输入向量和权重矩阵之间的点乘。为了增加网络的泛化能力和训练时计算梯度所需要的可微性，神经网络必须能够接近从输入特征到输出标签的非线性关系。下图为激活函数作用于神经网络的过程。常用的激活函数有：Sigmoid 激活函数、Tanh 双曲正切激活函数、RELU 激活函数等。




图3.6 激活函数作用于神经网络的过程

Sigmoid 函数的图像如图 3.7 所示：




图3.7 Sigmoid 函数图像

其输出范围从 0 到 1，对每个神经元输入归一化处理，较适合于输出为预测概率的模型，公式为：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (3-4)$$

$$f'(x) = f(x)(1 - f(x)) \quad (3-5)$$

Sigmoid 激活函数倾向于梯度消失，函数输出范围为 (0,1)，这会导致权重更新速度下降，并且执行指数运算，计算效率较低。

Tanh 双曲正切激活函数的图形也为 S 型，如图 3.8 所示：




图3.8 Tanh 双曲正切激活函数图像

其公式为：

$$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (3-6)$$

Tanh 函数和 Sigmoid 函数的曲线相对相似。Tanh 函数的输出更平滑，梯度较小，相比 Sigmoid 函数，它能加速网络收敛，但仍然具有梯度爆炸问题，即梯度呈指数

级增长。

RELU 函数的图形如下图所示：




图3.9 RELU 函数的图像

相较于前两个使用更为广泛，其数学表达式为：

$$f(x) = \max(0, x) \quad (3-7)$$

由式（3-7）可知，其只有线性关系，因此运行速度更快。

3.2 长短期记忆网络的产量预测模型

LSTM 是一种特殊的 RNN。RNN 在 1986 年由 David Rumelhart 提出，是一种以利用序列信息为中心思想的人工神经网络^[46]。RNN 可以利用内部状态处理输入序列，在时间相关序列中 RNN 表现优异，而农作物生长阶段会受到许多与时间相关的因素影响，因此 RNN 以及 LSTM 都适合用作农作物产量预测模型。

RNN 是一个短期记忆的神经网络，适合对序列进行预测，主要用来处理语音识别、机器翻译等序列性问题。RNN 的核心思想是根据输入的历史信息以处理后序输出数据^[47]。其网络结构如图 3.10 所示：




图3.10 RNN 单元网络结构示意图

一个 RNN 单元主要由三部分组成：

输入部分： x_t 是网络时间步骤 t 时的输入，比如， x_t 可以是对应输入的自然语言语句中的第 t 个词汇的单向量。

隐状态： s_t 是 RNN 网络在时间步骤 t 时的隐状态。 s_t 是网络的“记忆”，保存在 t 时刻前的输入序列信息。 s_t 的计算不仅依赖于当前输入，还依赖 RNN 网络在 $t-1$ 时刻的“记忆”，即 s_{t-1} ，其计算方法为：

$$s_t = f(Ux_t + W_{t-1}) \quad (3-8)$$

输出： o_t 是 RNN 网络在时间步骤 t 时的输出。比如，如果模型的网路的目标是预测一串数组的下个数字组合，输出就是可能出现所有数字组合的输出概率：

$$o_t = \text{softmax}(Vs_t) \quad (3-9)$$

其中，参数 V 将 s_t 转换为一个维数与目标数组大小相同的向量 s' ，但其每一维都是一个任意实数， softmax 函数用来将此向量的所有维都转换为一个概率值：

$$p_j = \frac{\exp(s'_j)}{\sum_i \exp(s'_i)} \quad (3-10)$$

通过此公式，向量 s' 的所有维都被转化为所有数字组合的概率值，每个值的取值都在 0 和 1 之间，所有值的和为 1。

通常 RNN 只用于处理短距离的序列信息，普通 RNN 在处理过长序列时往往会导致信息的丢失，在训练时存在所谓的梯度爆炸和梯度消失问题^[48]。为了解决 RNN 的训练问题，学者采用模拟退火对 RNN 进行训练，或是对输入序列进行层次性的压缩等方法^[49]。1997 年，Schmidhube&Hochreiter 等提出长短时记忆网络 LSTM^[50]。

相比前馈神经网络，LSTM 有着更强大的功能，它既可以处理视频、音频这类时间序列数据，又可以处理文字、图像等单点型数据。它基于有效的反馈机制解决了 RNN 的长期依赖问题，是深度学习领域中的经典神经网络之一^[51]。

LSTM 是 RNN 的变体，采用记忆单元记录历史信息，它和传统 RNN 总体结构类似，但传统 RNN 的网络单元仅有 1 层，而 LSTM 单元有 4 层，如图 3.11 所示。




图3.11 LSTM 单元结构示意图

LSTM 神经网络单元通过门结构来控制从细胞状态中丢弃或添加某些信息，这些门由一个 Sigmoid 神经层和一个点乘操作组成。Sigmoid 神经层的输出是一个取值在 0 或 1 之间的数，以控制信息的通过程度。当其输出为 0 时，表示门结构关闭，此时信息无法通过；而当输出为 1 时所有的信息都可以通过。LSTM 用“遗忘门”、“输入门”和“输出门”来完成信息的更新和遗弃。

“遗忘门”用来控制细胞状态中的遗弃信息，“遗忘门”根据上个时间步骤的隐状态 h_{t-1} 和当前输入 x_t 计算得到一个 0 或 1 的值，具体操作为：

$$f_t = \sigma(W_f \times [h_{t-1}, x_t] + b_f) \quad (3-11)$$

当“遗忘门”的取值为 1 时表示允许 C_{t-1} 中所有信息被传递到 C_t ，若取值为 0，则舍弃 C_{t-1} 中的所有信息。

对时间步骤 t 时的输入，决定何种信息被加入到细胞状态中的过程为由一个非线性的神经层根据当前输入 x_t 和上个时刻的隐状态 h_{t-1} 计算得到临时细胞状态 $\tilde{C}_t$ ，具体为：

$$i_t = \sigma(W_i \times [h_{t-1}, x_t] + b_i) \quad (3-12)$$

$$\tilde{C}_t = \tanh(W_c \times [h_{t-1}, x_t] + b_c) \quad (3-13)$$

接着， t 时刻细胞状态由 $\tilde{C}_{t-1}$ 变为 $\tilde{C}_t$ 的过程为： $\tilde{C}_{t-1}$ 与 f_t 相乘，表示“遗忘”的部分信息；临时细胞状态 $\tilde{C}_t$ 与 i_t 相乘，表示将细胞信息更新的过程，计算如下：

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (3-14)$$

最后，“输出门”用来控制输出的信息，它同样是根据 x_t 和 h_{t-1} 计算而来。接着，细胞状态 $\tilde{C}_t$ 在经过 $\tanh$ 后，与“输出门”的值相乘即得到 t 时刻的隐状态 h_t ，具体计算为：

$$o_t = \sigma(W_o \times [h_{t-1}, x_t] + b_o) \quad (3-15)$$

$$h_t = o_t \odot \tanh(C_t) \quad (3-16)$$

3.3 注意力机制基本原理

CNN 网络的核心计算是卷积算子，通过卷积核从输入特征图学习到输出新特征图。卷积操作本质上是对一个局部区域进行特征融合，这包括空间上（图像的高 H

和宽维度 W) 以及通道间 (通道维度 C) 的特征融合。前面章节介绍的 CNN 网络主要缺点就是其局部操作导致了其范围比较小, 无法得到全局的信息, 全局表达能力不好, 所以要增大感受野, 即空间上融合更多特征, 或者是提取多尺度空间信息, 因此这里引入注意力机制。注意力机制源自于人类视觉的选择性注意力, 核心是在众多信息中定位到最需要的信息, 提高信息处理的准确度和效率^[52]。

3.3.1 SENet 注意力机制

本文中主要通过建模在 9 个光谱通道上提取特征值, 因此引入通道注意力机制获取各特征通道的重要程度, 然后针对不同的任务增强或者抑制不同的通道得到每一个特征通道的权重之后, 将该权重应用于原来的每个特征通道, 从而进行特征分配。其中最常用的 SENet (Squeeze-and-Excitation Networks), 由 Momenta 公司开发^[53], 其模块如图 3.12 所示:

其中输入 X 大小为 $H \times W \times C$ 的特征图, C 为输入通道数, $\tilde{X}$ 为经过 SENet 处理后的输出结果。图 3.12 中所示, SENet 对输入特征进行四步运算: 映射 (Transformation)、挤压 (Squeeze)、激励 (Excitation) 和赋权 (Scale)^[54]。




图3.12 SENet 模块原理示意图

首先 Transformation (F_{tr}), 给定一个 input: $X \in \mathbb{R}^{H' \times W' \times C'}$, 让其经过 F_{tr} 做一次映射, 得到一个 output: $U \in \mathbb{R}^{H \times W \times C}$, 即 $U = F_{tr}$ 。在传统的 CNN 网络中这一步其实就是一次普通的卷积操作。以卷积为例, 卷积核为 $V = [v_1, v_2, \dots, v_c]$, 其中 v_c 表示第 c 个卷积核, 那么输出 $U = [u_1, u_2, \dots, u_c]$, 其中:

$$u_c = v_c * X = \sum_{s=1}^C v_c^s * x^s \quad (3-17)$$

该操作中的 $*$ 代表卷积操作, 其中 v_c^s 代表一个 S 通道的二维卷积核, 将一个通道的空间特征输入用来学习特征空间关系, 然而该操作会将通道特征关系与卷积核学习到的空间关系相互混淆。SENet 模块的作用就是将这种混合分离开, 直接学习到通道特征关系。

接着 Squeeze (F_{sq}) 操作采用全局平均池化将每个通道上对应的通道信息 ($H \times W$) 压缩到对应的通道中变为一个数值, 此时一个像素表示一个通道, 最终维度为 $1 \times 1 \times C$, 成为一个向量, 这步操作对 U 进行全部低维嵌入, 将全局进行挤压相当于拥有了全局感受视野。给定一个 input: $U \in \mathbb{R}^{H' \times W' \times C'}$, 让其经过 F_{sq} 做一次变换, 得到一个 output: $Z \in \mathbb{R}^{1 \times 1 \times C}$, 即:

$$Z = F_{sq}(U) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W U(i, j) \quad (3-18)$$

第三步 Excitation (F_{ex}) 给定一个 input: $Z \in \mathbb{R}^{1 \times 1 \times C}$, 让其经过 F_{ex} 做一次变换, 得到一个 output: $S \in \mathbb{R}^{1 \times 1 \times C}$, 即:

$$S = F_{ex}(Z, W) = \delta(g(z, w)) = \delta(w_2 \sigma(w_1 z)) \quad (3-19)$$

其中通过两个全连接层 w_1 、 w_2 和 δ (激活函数 RELU) 整合了不同通道的特征, 获取不同特征之间的相关性, 再通过 σ (激活函数 Sigmoid), 来归一化相关性权重, 最后得到的 S 就是需要得到的权重值。图 3.13 为操作示意图, 其中涉及到的超参数 reduction ratio 设为 16, 是相关学者多次实验得到的最优值^[53]。




图3.13 获得权重步骤

最后一步 Scale (F_{scale}), 利用上一步得到的权重值, 对原始的特征图进行操作, 得到一个 output: $\tilde{X} \in \mathbb{R}^{1 \times 1 \times C}$, 即:

$$\tilde{X} = F_{scale}(U, S) = S \times U \quad (3-20)$$

具体操作为将权重施加到 U 上面的每一个通道, 即对于 U , 每一个位置上的所有 $H \times W$ 上都乘上对应通道的权重值, 至此, 完成特征图的重校准。

以上为整个 SENet 基本原理介绍，可以得出 SENet 易于实现，对效果有明显的提升，然而值得注意的是：SENet 在初始步骤中要对通道进行压缩，利用两个全连接层进行维度缩减，很明显这种操作会破坏通道间的关联关系，性能上会带来一定的副作用。

3.3.2 ECANet 注意力机制

为解决此问题，多数基于 SENet 的扩展为得到更优性能，都把工作重点放在开发复杂的注意力模型中。ECANet 在 SENet 的基础上实现了不降维的跨通道交互策略，只涉及少量参数，可以达到两个目的：（1）避免特征维度的缩减；（2）增加通道间信息的交互，在保证性能的前提下简化模型^[55]。




图3.14 ECANet 模块的工作原理示意图

ECANet 模块的工作原理如图 3.14 所示：通过卷积对特征图进行压缩，将压缩结果经过全局平均池化（Global Average Pooling, GAP）从而削减参数量，使得空间信息得到压缩。ECANet 在 SENet 的基础上，不直接把压缩得到的空间特征信息传给全连接层，而采用一维卷积提取通道域特征，模型在训练时，能自适应卷积核大小。具体做法为：（1）GAP 得到一个 $1 \times 1 \times C$ 的向量；（2）计算自适应一维卷积核大小，计算公式为：

$$k = \varphi(C) = \left\lceil \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma} \right\rceil \quad (3-21)$$

其中 $\gamma=2$ ， $b=1$ ，该自适应卷积核表明了局部跨信道交互的覆盖率，即该通道附近

有多少相邻通道参与了它的注意力预测；(3) 将自适应卷积核使用到一维卷积中，得到各通道的权重，使得通道数较大的层可以更多地进行相邻通道间的交互。

3.4 基于 ECANet 的 CNN 与 LSTM 组合产量预测模型

3.4.1 组合模型的建立

本文所完成的工作为通过处理 MODIS 数据来预测美国某区某县某年的粮食产量。而根据第二章的描述，MODIS 数据集格式为 $I \in \mathbb{R}^{C \times W \times H}$ ，其中 C 、 W 、 H 分别代表图像数据集的光谱通道数、图片长度和图片宽度。对于多光谱的图像来说，从图片中提取能作用于粮食产量的特征是预测的必要步骤之一。而卷积神经网络 CNN 通过设定尺寸不同的卷积层，可以将原始数据集中的通道数扩展，从而通过卷积过程中不断挖掘新的图片特征。因此，本文在网络前端首先使用 CNN 来对图片进行特征提取。

在 CNN 中，图片的通道数不断变大，从刚开始的个位数，到最后几百甚至上千。大量的通道数将原始输入数据集中的特征不断提取，但是在逐步提取的过程中，通道之间的重要程度也是需要被考虑的。参考节 3.3 中对注意力机制的描述，在 CNN 中加入了 ECANet 注意力机制模块来实现卷积过程中不同通道之间的权重分配，通过预测结果的迭代优化权重。

通过对美国大豆产量的观察，不难发现其与一年中的时间有很密切的关联。因为不同的时间段，植物所接收到的光照、水分、温度等条件都会变化。所以在分析大豆产量时，将 MODIS 数据集的采样时间考虑进来会让网络预测的结果更加准确。而参考节 2.5.1 中对 MODIS 数据集的时间堆叠性质的描述，可以将其数据集看作时间序列，也就是将一年中不同时期采集到的数据信息融入网络模型的建立中。由节 3.2 可知，LSTM 是一种可以有效的针对时间序列来进行回归预测的神经网络结构，因此，本文在 CNN 提取了数据特征后，将其送入 LSTM 网络中进行针对时间的训练。最后通过全连接层完成对大豆产量的预测。

3.4.2 组合模型的结构

根据节 3.4.1 的描述，本文所构建的基于 ECANet 的 CNN 与 LSTM 组合神经网络模型（以下简称 CNN+ECANet+LSTM 模型）如图 3.15。

其中通过 CNN 神经网络模块提取特征值，将 CNN 模块最后一层卷积层输出作为 ECANet 的输入，在 ECANet 模块中完成特征值权重的计算，将计算的权重结果与 CNN 的各个通道相乘，至此就完成了注意力机制的添加，之后将数据送入 LSTM 网络模块进行训练，最后通过全连接层将数据整合为产量数据输出。




图3.15 本文构建的组合神经网络示意图

3.4.3 组合模型的超参数设置


在神经网络模型的搭建过程中，除了在网络不断向最优状态迭代过程中更新的神经元之间的权重 w ，偏置 $bias$ 这些参数，还需要针对一些超参数进行设置，从而在训练之前对精度、收敛速度等进行初步的调整。

(1) 学习率

通过前面的叙述，在网络进行参数更新的过程中，通常需要使用一些使得参数向最优点移动的收敛方法，例如其中最常用的梯度下降法，其参数更新的方法如下：

$$w^{t+1} = w^t - \eta \frac{\partial L(w)}{\partial w^t} \quad (3-22)$$

其中 t 代表第 t 次参数迭代更新，从公式 (3-22) 中可知，学习率 η 设置的大小会直接影响到每一次参数更新的步长。这里以一维度下的损失函数 $loss$ 的变化作为参考，如图 3.16 所示：

图3.16 一维度下的损失函数 $loss$ 的变化

其中，蓝色代表学习率过小，收敛过程较慢，迭代时间较长；绿色与黄色代表学习率过大，参数更新的过程会越过损失函数的极小点，使得模型难以收敛；红色代表学习率得当，模型在参数不断更新迭代下，达到损失函数的极小点，模型得以收敛。所以在调整网络的过程中，可以根据训练集的结果判断目前设置的学习率是否合适来更改学习率超参数。

(2) epoch 及 mini-batch

在参数更新的过程中，如果数据集很大，一次将所有数据集输入到网络中进行训练，并根据输出的结果不断迭代更新参数进行寻找极小点的过程将会十分漫长，因为在每一次计算梯度的过程中，计算一阶偏导数的过程是十分耗时的。并且如果学习率选择不得当，经过长时间训练得到的网络模型可能最终也不会达到收敛的结果，这对神经网络的训练会造成很大程度上的不便。

针对这种困扰，最小批梯度下降法将所有数据集都放入神经网络进行计算的过程变更为：设定一个超参数 `batch_size`，并将数据集按照此参数随机划分为 N 个 batch（其中每个 batch 大小等于 `batch_size`），称之为 1 个 epoch。训练过程中将每个 batch 的数据集打包送入神经网络中训练，并对最终得到的损失 `loss` 进行平均。当全部 N 个 batch 都已经训练完成后，即 1 个 epoch 训练完成后，再重新在数据集中随机划分为 N 个 batch 并继续进行网络训练，直到神经网络收敛或达到一定的迭代次数。

所以，设定好的网络迭代次数 K ，epoch 的数目 num_{epoch} 和 batch 数目 N 存在着以下关系：

$$num_{epoch} = \frac{K}{N} \quad (3-23)$$

在训练过程中，设定的 `batch_size` 大小如果过小，就会使得损失函数 `loss` 在迭代的过程中因不断引入随机性而出现震荡，对结果有所影响。而 `batch_size` 设定过大，则会加重 CPU、GPU 的负担，且使得网络容易陷入局部极小点而非全局极小点。

(3) 卷积核

卷积核在超参数的调整范畴主要分两种：一是卷积核的大小，二是卷积核的移动步长。卷积核的大小直接决定了卷积的过程中每一次卷积可以提取到的图片信息范围。卷积核的尺寸如果太小，则会减弱卷积过程中的感受野。而卷积核的尺寸太大，则会使其每次移动时的运算量加大，带来更多的训练参数。卷积核移动的步长在训练过程中默认为 1，当将其设置为 n 时，在使用 `same_valid` 卷积的情况下，可以实现对当前图片的 $n \times n$ pooling。原始的 pooling 池化层方法，即最大值池化 `max_pooling` 与平均值池化 `avg_pooling`，都是一种在规定法则下的池化。针对于任何图片，池化的方法全部一样。而采用步长为 n 的卷积层代替池化，即将池化的规则设定交付予

卷积核中参数的大小，不再是选择多个数据中最大或者取平均的下采样，而是在网络迭代过程中不断更迭，不断优化的池化方法。

3.4.4 组合模型的训练

神经网络的训练，可以概括为网络中的参数不断更新，即在训练的过程中，通过前向传播得到网络的最终输出，然后将其结果与正确结果进行比对，通过针对损失函数使用优化算法，再通过反向传播层层调整参数，之后再进行一次的前向传播，直至网络收敛，达到最优模型。

(1) 损失函数

本文涉及到的粮食产量预测问题属于回归问题。常见的 loss 函数主要有：L1loss（平均绝对值误差）、L2loss（均方误差）。

其中 L1loss 的表达式如下：

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (3-24)$$

L2loss 的表达式如下：

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (3-25)$$

上式中 N 为每一批次的样本数， y_i 表示产量预测的真实值， $\hat{y}_i$ 表示产量预测的估计值。其中 L1 损失函数的稳健性强，具有较好的鲁棒性，且由于计算的过程中的梯度固定，不会导致梯度爆炸的问题。而 L2 损失函数的曲线光滑、连续、处处可导，有利于收敛，但不利于处理数据中的异常点。

(2) 优化算法

控制网络中每次迭代中参数更新方向的方法有很多种，经典的优化算法有 Gradient Decent、RMSprop、Momentum 以及 Adam 法。

经典的梯度下降法在章节 3.4.3 中已经描述，而针对梯度下降中的学习率固定问题，RMSprop 方法将梯度下降法中与梯度部分相乘的固定学习率加入与之前时刻计算得到的梯度相关的变量 σ 。其表达式如下：

$$w^{t+1} = w^t - \frac{\eta}{\sigma^t} g^t \quad (3-26)$$

其中：

$$\sigma^t = \sqrt{\alpha (\sigma^{t-1})^2 + (1-\alpha) (g^t)^2} \quad (3-27)$$

其中 g^t 表示在当前的梯度。

Momentum 算法针对参数更新过程中的移动方向进行优化，其中心思想为：参数的移动方向不应该只由当前的梯度大小决定，还需要加入当前参数“运动”方向的影响，可以将此过程形象的理解为物体运动过程中的惯性。其表达式如下：

$$w^{t+1} = w^t - \eta v^{t+1} \quad (3-28)$$

其中：

$$v^{t+1} = \beta v^t + (1 - \beta) g^t \quad (3-29)$$

根据这种算法，当参数移动到梯度很小的局部极小点时，由于参数的更迭需要考虑到参数当前的运动方向，所以模型不会因小梯度而停留在局部极小点止步不前，而是会受到当前参数运动方向而离开局部极小点。这样使得神经网络模型可以不断更新，向全局最优点移动。

Adam 算法结合了 RMSprop 与 Momentum 两种算法的优点。既能考虑到参数当前的运动状态，又能使得每次更新参数时使用自适应学习率，是目前应用比较广泛的一种优化算法，其表达式如下：

$$\begin{cases} m^t = \beta_1 m^{t-1} + (1 - \beta_1) g^t \\ v^t = \beta_2 v^{t-1} + (1 - \beta_2) (g^t)^2 \\ \hat{m}^t = \frac{m^t}{1 - \beta_1} \quad \hat{v}^t = \frac{v^t}{1 - \beta_2} \\ w^{t+1} = w^t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \varepsilon}} \end{cases} \quad (3-30)$$

其中， β_1 、 β_2 和 ε 均为 Adam 优化算法引入的超参数。

(3) 神经网络前向、后向传播

神经网络的前向传播算法主要描述了从输入数据到输出损失函数值的过程，根据节 3.2 中所描述的神经网络前向传输模型，隐藏层中神经元不断的前向传播，网络在最后一层输出损失函数值。

神经网络的后向传播思想完成了从输出损失函数到层层调整参数的过程。设神经网络中某一层 k 中第 i 个神经元激活函数的梯度为 g_i^k ，则有：

$$g_i^k = \frac{\partial L(w, b)}{\partial v_i^k} = \frac{\partial L(w, b)}{\partial a_i^k} \frac{\partial a_i^k}{\partial v_i^k} \quad (3-31)$$

其中 a_i^k 代表第 k 层的第 i 个神经元激活函数的输出。根据这个神经元的梯度表示，可以推导出第 $k-1$ 层的第 i 个神经元的梯度公式如下：

$$\begin{aligned} g_i^{k-1} &= \frac{\partial L(w, b)}{\partial v_i^{k-1}} \\ &= \sum_{j=1}^N \left[\frac{\partial L(w, b)}{\partial v_j^k} \frac{\partial v_j^k}{\partial a_i^{k-1}} \frac{\partial a_i^{k-1}}{\partial v_i^{k-1}} \right] \\ &= \sum_{j=1}^N g_j^k \times w_{ji}^k \times f'_{k-1}(v_i^{k-1}) \end{aligned} \quad (3-32)$$

式中 w_{ji} 表示第 k 层中的第 j 个与第 $k-1$ 层中第 i 个所连接的神经元间的权重， $f(\bullet)$ 表示激活函数。这样前一层的神元的参数更新方向就可以被最后输出得到的损失函数影响。以此类推，从神经网络的最后一层向前传播，更新每一层神经元上的参数，使整个网络上的参数趋向最优。

(4) 过拟合处理方法

在神经网络训练的过程中，先通过训练集来更新网络参数。然后将训练好的网络模型保存状态，再将测试集数据加入网络进行预测。而在训练的过程中，如果发生训练集上的结果十分优秀，但是当测试集数据放在已经训练好的网络模型后，得到的结果很差的情况。则说明网络出现了过拟合现象，即网络的参数过于适配训练集数据。当测试集数据输入时，神经网络的性能会有所下降。而神经网络需要完成的功能是保证对测试集数据预测的准确，所以针对过拟合现象，需要在网络中做一些调整，包括采用正则化、dropout、batchnorm 以及 early stopping 等方法。

正则化从损失函数的部分进行优化，目前常用的算法有 $L1$ 正则与 $L2$ 正则，其表达式如下：

$$L1: L(w, b) = L_o(w, b) + \sum_i |w_i| \quad (3-33)$$

$$L2: L(w, b) = L_o(w, b) + \sum_i w_i^2 \quad (3-34)$$

其中 $L1$ 正则化会使得解更加稀疏，可以从结果中选择更有意义的特征。 $L2$ 正则化会使得每次更新得到的新参数 w 更小，降低了复杂度，提高模型泛化能力。

dropout 方法从神经元角度进行优化，通过在网络的每一层神经元进行 forward 的过程中，以一定概率 p 随机删除掉一些神经元^[56]（概率为超参数，由外部调整）。每次训练都只有未被删除的神经元参与，从而使得每次都只有部分神经元参与了网络训练，但最后经过测试集时，所有神经元都变为正常工作状态，以保证神经网络在测试集上的表现。这种方法有效的减弱了神经元之间的相互依赖性，从而增加了网络的泛化能力。

batchnorm 方法从 mini-batch 的角度进行优化。如节 3.4.3 中所描述, 每次将一个 batch 的数据集放入网络中进行训练。由于每个 batch 的数据分布有所差异, 会导致下一层的学习有困难, 所以在经过激活函数之前, batchnorm 方法可以将所有 batch 的数据归化到一个均值为 0、方差为 1 的正态分布上。它可以降低数据间的差异, 加快训练速度, 增加网络的泛化能力。

early stopping 方法从训练迭代次数的角度进行优化。当网络迭代到一定次数, 训练集上的效果会逐渐变好^[57], 但与此同时, 网络在测试集的效果可能会开始变差。early stopping 方法是指, 在使用验证集对训练集训练的网络进行验证时, 如果验证集上的误差比前一次小, 则更替网络状态。如果误差比前一次迭代时更大, 则保持原网络状态不变, 且当连续 n 个 epoch 中网络结果都不如原网络状态 (n 为超参数, 训练时提前设置), 就停止网络训练, 从而增加网络的泛化能力。

3.4.5 组合模型评价标准

为了对预测结果进行定量分析, 本文采用均方误差 (Mean Square Error, MSE) 作为损失函数, 并使用 Adam 的优化算法不断更新网络中的参数, 找到最优解。而针对最后测试集上的训练结果, 采用均方根误差 (Root Mean Square Error, RMSE) 表示最终预测结果的偏差, 作为凭借指标对各个网络的性能进行对比、评价。表达式如下:

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (3-35)$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{N}} \quad (3-36)$$

其中, y_i 为大豆产量的预测值, $\hat{y}_i$ 为大豆产量的真实值。MSE 与 RMSE 代表预测值与真实值之间的偏差, 值越小代表偏差越小, 即模型的预测性能越好。

3.5 仿真实验及结果分析

3.5.1 实验数据选择及环境

(1) MODIS 遥感图像产品选择: 根据节 2.5 的描述, 本文选择 MOD09A1、MYD11A2 和 MCD12Q1 三种 MODIS006 号产品来描述大豆产品的地表反射率、地表温度和植被类型, 其遥感图像获取时采用的分辨率为 500m。

(2) 作物产量数据及州县选择: 通过美国农业统计局 (National Agricultural Statistics Service, NASS) 提供的农作物产量信息, 历年来的大豆产量信息都可以在

美国农业部（United States Department of Agriculture, USDA）查看。该网站涵盖了可统计范围内，美国各个县的各种农作物产量（单位为：bushel/acre，音译为：浦式耳/英亩，是英美大豆贸易结算中习惯计量单位）。从 USDA 提供的大豆产量表格中选取了其中产量最高的 11 个州，其大豆总产量约占到全美产量总数的 75%以上。本文选取这些州县从 2003 年到 2020 年共 18 年的大豆产量数据作为本文研究的原始数据。

本文实验基础环境如下表：

表3.1 本文实验基础环境

网络搭建框架	Pytorch
开发语言	Python、CUDA 10.0、CUDNN v7
CPU	AMD Ryzen 7 3700X 8-Core @3.60GHz
内存	32G/DDR4
GPU	GTX 2060 (8GB)
操作系统	Windows10(64 位)

3.5.2 实验过程及仿真参数设置

实验过程主要分为以下步骤：

Step1：数据预处理。利用第二章描述的方法对原始数据完成按年份划分、光谱通道组合、通过掩膜筛选耕地区域、转换为直方图等一系列处理。同时，将预处理之后的数据集分成训练集、测试集，其中划分训练集的 10%为验证集用来评估模型的性能。

具体做法为，预测 2016 年的产量数据，将 2003-2015 年的数据作为训练集，同时将其划分出 10%作为验证集，用于在网络训练达到最优时的预测性能，防止过拟合问题。以此类推。划分出每个预测年份的训练集与测试集。

Step2：搭建 CNN+ECANet+LSTM 组合网络模型。初始化模型参数，经过多次实验尝试、调整，最终确定各个模块中的具体参数，见下表 3.2；

Step3：训练阶段。利用节 3.4.3 与节 3.4.4 中介绍的模型超参数设计方法以及训练方法，训练数据集经过层层前向、反向传播以及损失函数的优化，不断调整参数，直至网络收敛，然后利用验证集验证模型是否达到最优。

在仿真过程中，CNN、LSTM 以及 ECANet 的参数均设置相同，并保证网络的超参数部分统一。

Step4：测试阶段。将测试数据输入至训练好的最优模型中得到大豆的预测产量，对比预测产量与真实产量之间的误差，验证预测模型的准确性。

表3.2 本文使用的网络结构参数

网络结构	网络参数设置
输入层	输入数据格式： $B, C, W, H = 32, 9, 32, 32$ ($batch_size = 32$) 训练集与验证集大小关系： training set:90% validation set: 10% 迭代次数： $iteration_step = 25000$ 优化算法： Adam 初始学习率： $\eta = 0.001$
CNN	CNN 层数=6 Conv1(128,3x3,stride=1), Conv1(128,3x3,stride=2) Conv3(256,3x3,stride=1), Conv1(256,3x3,stride=2) Conv5(512,3x3,stride=1), Conv1(512,3x3,stride=2) 激活函数: RELU Dropout=0.5
ECANet	Squeeze 层输入格式： $B, C, W, H = 32, 512, 4, 4$; 采用 avg_pool 卷积层设置： 1dConv(kernel_size=5, padding=2) 激活函数: Sigmoid
LSTM	LSTM 输入格式： $B, H, T = 32, 2048, 4$ LSTM 层数=1 隐藏层大小： $Hidden_size = 128$ 全连接层大小： $Dense_feature = 256$

实验过程流程图如下：




图3.17 实验流程图

3.5.3 实验结果及分析

在仿真过程中，为了通过与其他传统网络结构对比体现本文基于注意力机制的组合神经网络模型的性能提升，在此选择了以下网络对照组进行对比实验：

- (1) CNN
- (2) LSTM
- (3) CNN+LSTM
- (4) CNN+ECANet
- (5) CNN+ECANet+LSTM

其中，采用（1）、（2）的传统单一网络结构做对比实验是为了证明通过 MODIS 采集到的数据集经过预处理后，可以完成对目标区域大豆产量的有效预测。而采用组合网络结构（3）的原因是证明 CNN 与 LSTM 可以互相弥补各自传统单网络结构的缺陷，即 CNN 无法学习数据集中的时间相关性，而 LSTM 无法有效扩充通道数，证明组合网络结构思想的正确性。采用（4）则是为了与（1）形成对照组实验，说明 CNN 网络结构中各个通道数的权重在经过通道注意力机制的调整下能更好的预测产量，体现了通道注意力机制 ECANet 对产量预测模型的优化。而（5）则是本文提出的组合网络模型。

首先，为了验证网络训练过程中的差异及结果，利用训练集不断迭代逐渐让网络模型收敛，记录使得网络的损失函数逐渐减小到趋于稳定的过程。利用网络的损失函数由最开始比较高耸的值降低至拐点处的先后顺序用来评定网络模型的收敛速度，以此表征网络模型的复杂度，从而判定其计算复杂度。将拐点后随着迭代次数逐渐加大损失函数趋于稳定的值作为网络训练过程中收敛效果的评定标准，以此判定该网络模型的预测性能，值越小预测性能越优。

从下图 3.18 的结果可以看到，首先与 CNN 相比，LSTM 的收敛速度较快，因为本文的 LSTM 隐藏层数设定为 1，网络结构相对于其他部分比较简单。CNN 与 LSTM 在收敛效果方面比较近似，由于 LSTM 学习到了数据集中的时间相关性，所以 LSTM 的收敛效果会略微优于 CNN。而将两种单一网络模型组合后，CNN+LSTM 模型的收敛效果优于单一网络。从结果中看，可以确定 CNN 与 LSTM 互相弥补了单网络结构的缺点，收敛效果有优化，但由于网络结构更加复杂，导致计算复杂度增加，收敛速度会有所下降，这里可做为后期研究优化的方向。通过 CNN 网络结构与 CNN+ECANet 网络结构的对比可以看出，注意力机制的加入使得网络收敛效果得到提升，由于 ECANet 的轻量化以及运算量小的优点，其收敛速度与 CNN 相比并无太大影响。经过对比可以确定本文所引入的通道注意力机制对网络收敛效果有一定的优化。而从最后的 CNN+ECANet+LSTM 的组合网络效果来看，其收敛速度与 CNN+LSTM 组合网络模型几乎无差别，而收敛效果优于 CNN+LSTM 的组合网络模型。





图3.18 不同网络的收敛效果

综上,可以得出本文提出的 CNN+ECANet+LSTM 组合网络模型对比其他网络模型的优势在于收敛效果最好。

而在训练数据后,网络参数固定,将测试集数据经过训练好的网络模型,并根据其预测输出与真实输出对比,可以得到网络的真实预测性能。预测结果通过下列热度图呈现,图中标注的位置为所选定 11 个州中可被 USDA 统计相应年份产量的州县位置,而其颜色的深浅代表网络预测结果与真实结果的差别大小,颜色越深表明预测结果和真实结果的差值越大,颜色越浅表明预测结果越接近真实结果,即浅黄色与浅紫色区域的预测结果较准确。其具体标注见图右方标尺。

以 2019 年份大豆产量(单位为: bushel/acre)预测结果为例,图 3.19 示出了 CNN、LSTM、CNN+LSTM、CNN+ECANet 以及 CNN+ECANet+LSTM 模型的预测结果热度图,各网络预测结果 RMSE 依次为: 6.31、6.59、6.28、5.34、4.72。由图看出, CNN 与 LSTM 的预测结果相近。CNN+LSTM 由于结合了两种单一网络的优点,预测结果略有提升,相比单一的 CNN 或 LSTM 网络, CNN+LSTM 组合网络的预测精度分别提高了约 0.4%和 4.7%。CNN+ECANet 网络相较于单一的 CNN 做了特征值的权重优化,预测精度相比单一 CNN 网络提升了 15.3%,可见注意力机制的加入能显著提高预测精度。而最后的组合网络产量模型 CNN+ECANet+LSTM 的精度达到最优,相比于单一的 CNN 或 LSTM 网络,其预测精度分别提高了约 25.2%和 28.4%;相比于 CNN+LSTM 的组合网络,其预测精度提高了约 24.8%。上述分析表明,所设计的 CNN+ECANet+LSTM 模型在单一年份的美国大豆产量预测方面具有较好的性能。






图3.19 预测结果与真实结果对比热度图

表 3.3 和图 3.20 示出了 2016 年-2020 年间 CNN、LSTM、CNN+LSTM、CNN+ECANet 以及 CNN+ECANet+LSTM 模型的大豆产量预测结果 RMSE。可以看出，随着年份的变化，各模型的预测精度有一定的波动，因此采用对 2016 年-2020 年期间每个网络模型的 RMSE 求均值的方法来研究各网络的预测性能。可以看出，在相同条件下，CNN+LSTM 的组合网络要比单一的 CNN 网络或者 LSTM 网络的 RMSE 更小，但精度提升比较有限，几乎都在 5%以内。而添加了注意力机制后的 CNN+LSTM 组合网络因为可以将特征值进行重定向，突出重要的特征值，抑制不重要的特征值，增强了模型的泛化能力，所以在大多数年份的预测中都表现出明显的低 RMSE 特性，其各年份的 RMSE 均值要比未添加注意力机制的 CNN+LSTM 组合网络低约 8.7%。上述分析表明，本文所设计的 CNN+ECANet+LTSM 模型在 2016 年-2020 年期间的美国大豆产量预测方面具有较好的性能。

表3.3 2016-2020 年不同网络对大豆产量预测的 RMSE (单位: bushel/acre)

年份\网络模型	CNN	LSTM	CNN+LSTM	CNN+ECANet	CNN+ECANet+LSTM
2016	7.89	7.22	7.12	7.68	7.09
2017	4.95	5.27	4.91	5.13	5.01
2018	5.73	6.30	5.79	5.69	5.45
2019	6.31	6.59	6.28	5.34	4.72
2020	6.57	6.63	6.35	6.54	5.52
均值	6.29	6.40	6.09	6.08	5.56




图3.20 2016-2020 年不同网络对大豆产量预测的 RMSE (单位: bushel/acre)

综上, 本文提出的注意力机制以及组合网络模型能够对 MODIS 采集到的数据集进行有效的处理并分析其带来的光谱图像信息, 在准确率上有一定的提高, 可为大豆产量预测问题提供一种有效的解决方案。

3.6 本章小结

本章在基于卷积神经网络 CNN 和循环神经网络 LSTM 基本原理, 研究将两种网络结合, 旨在取长补短, 相较各自单独网络的预测结果, 组合网络在预测结果准

确度方面得到了提高。本章内容在上述组合网络的基础上进行改进，结合注意力机制基本理论，提出将典型的通道注意力机制：ECANet 应用到 CNN+LSTM 组合网络模型中，同时利用 Adam 优化算法进行网络优化以及 dropout 等方法防止网络过拟合，调整设置各种超参数，从而设计出结果较优的农作物产量预测模型。最后将 CNN 网络模型、LSTM 网络模型、CNN+LSTM 组合网络模型以及加入 ECANet 注意力机制模块的 CNN+LSTM 组合网络模型进行仿真对比和结果分析。

第四章 基于高斯过程的产量预测模型研究

前一节所设计的组合神经网络模型中，输入遥感图像中潜在的许多与作物生长相关的特征并未显示，例如特定位置固有的土壤类型或者施肥的多寡等，这些特征可能不会随着时间发生显著改变，也有可能同时受到时间、空间等多种因素的影响，因此本章在前一章设计的神经网络模型之上通过高斯过程添加年份和地理位置信息相关性因素来减少预测结果的误差。

4.1 高斯过程基本原理

4.1.1 高斯过程基本概念

高斯过程是随机过程理论的重要分支，被广泛应用于诸多领域。高斯过程是一种强大的模型，它能方便地处理复杂的高维度问题，使用无限维多变量高斯分布对函数进行建模，具有很强的表征能力^[58]。

高斯过程因其结合先验知识对数据做出预测的优势而广泛应用于回归问题领域。回归问题通常可以总结为用函数拟合数据，即给定一组数据点，找到一个函数来尽可能准确地将其描述出来。在机器学习中，利用训练数据来学习一组定义一个函数的参数，这种参数化方法就是训练回归参数，其学习能力是有限的，因为对于任何训练数据，可能存在不计其数个函数都可以将其拟合，这是参数化方法存在的缺点^[59]。而高斯过程就是一种非参数方法，它为每个函数分配一个概率值，这个概率分布的均值代表了数据可能性最大的表征。而且，基于概率的方法可以将对预测的置信度结合到回归的结果中去，这样不仅能模拟任何黑盒函数，还能模拟不确定性^[60]。依靠高斯过程，能探索难以实现高效训练的数据区域。

以最简单的一元高斯分布为例，其概率密度函数为：

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (4-1)$$

其中 μ 和 σ 分别表示均值和标准差，这个概率密度函数曲线是典型的钟形曲线，其形状由 μ 和 σ 决定。如图 4.1 所示：




图4.1 一元高斯分布概率密度曲线

由此可以把高斯分布从一元推广到多元，并假设各维度间是相互独立的，则有：

$$\begin{aligned}
 p(x_1, x_2, \dots, x_n) &= \prod_{i=1}^n p(x_i) \\
 &= \frac{1}{(2\pi)^{\frac{n}{2}} \sigma_1 \sigma_2 \dots \sigma_n} \exp \left(-\frac{1}{2} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} + \dots + \frac{(x_n - \mu_n)^2}{\sigma_n^2} \right] \right)
 \end{aligned} \quad (4-2)$$

其中 $\mu_1, \mu_2, \dots$ 和 $\sigma_1, \sigma_2, \dots$ 分别是第 1 维、第 2 维...的均值和方差。令

$$x - \mu = [x_1 - \mu_1, x_2 - \mu_2, \dots, x_n - \mu_n]^T \quad (4-3)$$

$$K = \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \sigma_n^2 \end{bmatrix} \quad (4-4)$$

有

$$\sigma_1 \sigma_2 \dots \sigma_n = |K|^{\frac{1}{2}} \quad (4-5)$$

$$\frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} + \dots + \frac{(x_n - \mu_n)^2}{\sigma_n^2} = (x - \mu)^T K^{-1} (x - \mu) \quad (4-6)$$

代入上述公式，得到

$$p(x) = (2\pi)^{-\frac{n}{2}} |K|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (x - \mu)^T K^{-1} (x - \mu) \right) \quad (4-7)$$

其中 $\mu \in \mathbb{R}^n$ 是均值向量， $K \in \mathbb{R}^{n \times n}$ 为协方差矩阵，由于假设了各维度之间相互独立，

故 K 是一个对角矩阵。在各维度变量相关时，上式不变，而 K 不再是对角矩阵，只具有半正定和对称的性质。上式也简写为：

$$x \sim \mathcal{N}(\mu, K) \quad (4-8)$$

在多元高斯分布的基础上进一步推广至无限多维的情况，原本的概率密度函数从点分布变成了函数分布，该分布称高斯过程。对所有

$$x = [x_1, x_2, \dots, x_n], f(x) = [f(x_1), f(x_2), \dots, f(x_n)] \quad (4-9)$$

都服从多元高斯分布，则称 $f(x) \sim \mathcal{N}(\mu(x), k(x, x))$ 是一个高斯过程：

$$K(x_i, x_j) = \sigma^2 \exp\left(-\frac{\|x_i - x_j\|_2^2}{2l^2}\right) \quad (4-10)$$

其中 $\mu(x): \mathbb{R}^n \rightarrow \mathbb{R}^n$ 表示均值函数（Mean function）返回到各个维度的均值； $k(x, x): \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}^{n \times n}$ 为协方差函数（Covariance Function）返回两个向量各维度之间的协方差矩阵 K 。一个均值函数和协方差函数可以定义一个高斯过程，且高斯过程的有限维子集都服从多元高斯分布。高斯过程就是所有时域或空间域随机变量的联合，且每个随机变量都服从高斯分布。

基于上述理论，为得到所需分布，要先对 μ 和 K 进行定义。通常假设 $\mu=0$ ，这样可以进行一定程度的简化，即使出现 $\mu \neq 0$ 的情况，也可以在预测结束后手动添加 μ 到结果中。因此 μ 的配置没有难度。协方差矩阵 K 界定了分布的结构和函数的特性。通过求核函数 k 的值来生成 K ，这个核函数也叫协方差函数，作用在所有两两成对的测试点上。在此引入核函数的概念：

一个高斯过程通常可以描述为 $\xi_t \sim \mathcal{GP}(m(t), K(s, t))$ 。其中 $K(\cdot)$ 代表的是高斯过程中的协方差函数，其描述了不同输入点之间的关系且反应在了样本的位置上。正是因为协方差函数可以通过点与点之间的关系来完成从输入的已知训练数据到针对未知输入的预测，所以协方差部分又被称为核函数^[61]。这种函数的选择直接决定了高斯过程的性能。不同的核函数决定了不同的数据关联方法，其超参数的配置也不相同。所以确定了一个协方差矩阵的计算方法，也就确定了一个高斯过程，因为其呈现了对函数模型先验知识的表达，并且赋予了超强拟合能力。

同时核函数也简化了基于复杂的非线性变换 $\phi(x)$ 与 $\phi(x')$ 之间的内积计算，此过程也被称作核技巧(Kernel Trick)，即如果需要将输入 x 变换到高维度空间，不需要将其变换后结果 $\phi(x)$ 计算出来，也可以得到不同的输出点 x 与 x' 之间的协方差^[62]。常用的核函数类型有常数核(Constant)、线性核(Linear)、平方指数核(Squared

Exponential, SE)等。其中 SE 核的协方差表达式如下:

$$K_{SE}(x, x') = \sigma^2 \exp\left(-\frac{\|x - x'\|_2^2}{2l^2}\right) \quad (4-11)$$

其中 $\|\cdot\|_2$ 表示 2-范数, 而 σ 与 l 都是 SE 核带来的超参数。

4.1.2 高斯过程应用于回归问题

根据机器学习中的理论, 预测回归问题的原理可以大致概括为: 目前拥有的训练样本为 $\{X, Y\}$, 有 $X = (x_1 \ x_2 \ \cdots \ x_{N-1} \ x_N)^T \in \mathbb{R}^{N \times P}$, $Y = (y_1 \ y_2 \ \cdots \ y_{N-1} \ y_N)^T \in \mathbb{R}^{N \times 1}$ 。其中 $x_i \in \mathbb{R}^P$, $y_i \in \mathbb{R}^1$, 分别表示 P 维的输入向量与 1 维的输出向量。而针对回归问题的建模就是通过建立一个函数模型 $f(x) = x^T w$, 根据表达式 $y = f(x) + \varepsilon$, 就可以实现利用已知的训练数据进行建模, 从而得到一个预测值。其中 $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ 属于估计中的噪声分量, 而 x, y 和 ε 都是随机变量。

在点估计讨论的范畴中, 如果将 w 看作一个未知的参数, 而将预测的结果与真实结果偏差最小作为优化目标, 就可以通过优化偏差表达式来得到一个最优的参数合集, 进而通过这些针对目前训练数据最优的参数对新进入模型的数据进行预测。这类方法如: 最小二乘估计法和最大似然估计法。但是这种估计方法只利用了目前拥有的已知数据, 且在估计的过程中, 用抽样指标去代替了全体指标, 不可避免地会产生误差。所以在解决像粮食产量预测这种需要得到准确估计结果的问题时, 更多地使用贝叶斯统计估计理论对问题进行分析。

在贝叶斯估计理论中不再认为 w 是一组参数, 而是认为其是一个随机变量、一个分布^[63]。所以在贝叶斯方法的模型中基于贝叶斯公式进行分析。

$$p(w|X, Y) = \frac{p(w, Y|X)}{p(Y|X)} = \frac{p(Y|X, w)p(w)}{\int wp(Y|X, w)p(w)dw} \quad (4-12)$$

式中 $p(Y|X, w)$ 为似然函数, $p(w)$ 为先验函数, 假设 $p(w) \sim \mathcal{N}(0, \Sigma_p)$ 。首先针对 $y_i \in Y$ 进行推导, 根据预测形式可得, $y = w^T x + \varepsilon$ 而 $\varepsilon \in \mathcal{N}(0, \sigma^2)$ 。所以似然函数可以表示为:

$$p(Y|X, w) = \prod_{i=1}^N p(y_i|x_i, w) \sim \prod_{i=1}^N \mathcal{N}(w^T x_i, \sigma^2) \quad (4-13)$$

由式 (4-13), 在针对参数 w 进行推导的过程中, $p(Y|X)$ 作为一个只与训练数据分布有关的数据, 与参数 w 的分布无关, 因此可以看作一个常数。这样可以将初步得到似然函数改写成:

$$p(Y|X, w) \propto p(Y|X, w)p(w) \quad (4-14)$$

而结合前面对 $p(w)$ 分布的假设, 可以将上式进一步表达为:

$$p(w|X, Y) \sim N(\mu_w, \Sigma_w) \propto \prod_{i=1}^N \mathcal{N}(w^T x_i, \sigma^2) \mathcal{N}(0, \Sigma_p) \quad (4-15)$$

经过这种变换, 贝叶斯理论就将原本针对一个参数的优化问题, 变成了对 w 概率分布中均值 μ_w 和方差 Σ_w 的求解。将 $p(Y|X, w)$ 中 N 个高斯分布相乘的结果展开得到:

$$\begin{aligned} p(Y|X, w) &= \prod_{i=1}^N \frac{1}{(2\pi)^{\frac{1}{2}} \sigma} \exp\left\{-\frac{1}{2\sigma^2} (y_i - w^T x_i)^2\right\} \\ &= \frac{1}{(2\pi)^{\frac{N}{2}} \sigma^N} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - w^T x_i)^2\right\} \end{aligned} \quad (4-16)$$

将式中的 $\sum_{i=1}^N (y_i - w^T x_i)^2$ 改写成 X , Y 和 W 的矩阵形式并对其进行化简, 可得:

$$p(Y|X, w) \sim N(WX, \sigma^2 I) \quad (4-17)$$

$$p(w|Y, X) \sim N(\mu_w, \Sigma_w) \propto N(WX, \sigma^2 I) N(0, \Sigma_p) \quad (4-18)$$

所以根据高斯分布的推导, 最终可以得到均值 μ_w 和方差 Σ_w 的表达式如下:

$$\mu_w = \sigma^{-2} A^{-1} X^T Y \quad (4-19)$$

$$\Sigma_w = A^{-1} = (\sigma^{-2} X^{-1} X + \Sigma_p^{-1})^{-1} \quad (4-20)$$

至此就可以得到训练数据中参数 w 后验概率分布的均值和方差。当向模型中输入新数据 x^* 时, 其函数的概率分布就可通过 $f(x^*)$ 得到。所以针对新数据产生的预测结果 y^* 的概率分布就为:

$$p(y^*|X, Y, x^*) \sim N(x^{*T} \mu_w, x^{*T} \Sigma_w x^*) \quad (4-21)$$

以上就将寻找参数的单一最佳值的过程转变为确定模型参数的后验分布, 响应变量和假设模型参数都来自于概率分布。

根据节 4.1.1 的描述, 一个高斯过程常被描述为 $\xi_t \sim GP(m(t), K(s, t))$ 。同时形同以上描述的贝叶斯方法, 设 $f(x)$ 为一随机变量且满足 $f(x) = \phi(x)^T w$, 其中 $\phi(\cdot)$ 表示对输入数据 x 进行的线性-非线性转换。所以 $f(x)$ 的均值可以表示为:

$$E[f(x)] = E_w[\phi(x)^T w] = \phi(x)^T E_w[w] = 0 \quad (4-22)$$

而针对在输入数据中的 $\forall x, x' \in \mathbb{R}^p$ ，同样可以计算 $f(x)$ 的协方差表达式：

$$\begin{aligned} \text{cov}(f(x), f(x')) &= E[(f(x) - E[f(x)])(f(x') - E[f(x')]))] \\ &= E[\phi(x)^T w \phi(x')^T w] \\ &= E[\phi(x)^T w w^T \phi(x')] \end{aligned} \quad (4-23)$$

针对公式中的 w ，由于其属于一个 0 均值的高斯分布，所以：

$$E[ww^T] = E_w[(w-0)(w-0)^T] = \Sigma_p \quad (4-24)$$

经过替换后，式中的 $E[\phi(x)^T w w^T \phi(x')]$ 部分可以化简为 $E[\phi(x)^T \Sigma_p \phi(x')]$ 。而如果设 $\varphi(x) = \Sigma_p^{-\frac{1}{2}} \phi(x)^T$ ，不难看出 $f(x)$ 的协方差矩阵表达式就是一个核函数，即

$$\text{cov}(f(x), f(x')) = \langle \varphi(x), \varphi(x') \rangle = K(x, x') \quad (4-25)$$

至此，就得到 $f(x)$ 的期望为 0，协方差矩阵为一个核函数。所以 $f(x)$ 可以被看做一个高斯过程。所以回归问题可被描述为：

训练数据： $\{(x_i, y_i)\}_{i=1}^N$ ， $f(x)$ 符合一个高斯过程，即 $f(x) \sim \mathcal{N}(\mu(x), K(x, x'))$ 。同时 $Y = f(x) + \varepsilon$ ，可以得到 Y 的分布为 $Y \sim \mathcal{N}(\mu(x), K(x, x') + \sigma^2 I)$ ，而针对新输入 $X^* = (x_1^* \ x_2^* \ \cdots \ x_{N-1}^* \ x_N^*)$ ，预测输出为 $Y^* = f(x^*) + \varepsilon$ 。

通过将高斯过程 $f(x)$ 带回到贝叶斯理论描述的预测问题中，可得根据已知训练数据的分布 Y 和输出预测 $f(x^*)$ 的联合概率密度分布如下：

$$\begin{bmatrix} Y \\ f(x^*) \end{bmatrix} \sim N \left(\begin{bmatrix} \mu(x) \\ \mu(x^*) \end{bmatrix}, \begin{bmatrix} K(X, X) + \sigma^2 I & K(X^*, X) \\ K(X^*, X) & K(X^*, X^*) \end{bmatrix} \right) \quad (4-26)$$

最后，根据联合概率密度求其边缘概率密度的相关方法和理论，可得出 $p(f(x^*)|Y) \sim \mathcal{N}(\mu^*, \Sigma^*)$ 预测的输出期望 μ^* 与方差结果 Σ^* 的表达式如下：

$$\mu^* = K(X^*, X)(K(X, X) + \sigma^2 I)^{-1}(Y - \mu(X)) + \mu(X^*) \quad (4-27)$$

$$\Sigma^* = K(X^*, X^*) - K(X^*, X)(K(X, X) + \sigma^2 I)^{-1} K(X, X^*) \quad (4-28)$$

综上所述，高斯过程应用与回归问题可以分解为基于贝叶斯理论的预测问题以及核函数的技巧两个部分。根据理论推导，高斯过程可以通过其核函数的强大功能完成对回归问题的结果优化。

4.2 高斯过程中超参数优化

将高斯过程应用于回归问题时，需要引入超参数来确定高斯核等部分的表达式。例如在式(4-11)表达式中，引入了 σ ， l 这些超参数来组成SE核的表达式。随着超参数选择的不同，核函数的功能也会发生变化。其形状会随着超参数的不同而改变。如下图4.2所示：




图4.2 不同参数下 SE 核的形状

在常用的高斯过程应用于回归问题的场景下，确定超参数的方法主要分两种^[64]，一是根据经验与数据预分析，直接在模型中使用常用的高斯核超参数，这种方法虽然快捷方便，但是由于在不同模型中，要处理的数据集的情况不同，完成的预测功能也不同，使用统一的超参数会减弱模型的泛化能力。二是针对超参数定义一个边

似然概率表达式，根据训练数据的分布找到使得似然函数最大的超参数值，为方便处理，一般将其表示为负对数形式如下：

$$L = -\ln p(y|X, \theta) = \frac{1}{2} y^T \Sigma_{\theta}^{-1} y + \ln |\Sigma_{\theta}| + \frac{n}{2} \ln 2\pi \quad (4-29)$$

通过求 $\mathcal{L}$ 的最小值，就可以将寻找超参数的值变成一个最优化问题。将其负对数形式的似然概率对超参数 θ 求偏导，其表达式如下：

$$\frac{\partial \mathcal{L}}{\partial \theta} = \frac{1}{2} \text{tr} \left(\Sigma_{\theta}^{-1} \frac{\partial \Sigma_{\theta}}{\partial \theta} \right) - \frac{1}{2} y^T \Sigma_{\theta}^{-1} \frac{\partial \Sigma_{\theta}}{\partial \theta} \Sigma_{\theta}^{-1} y \quad (4-30)$$

其中 $\text{tr}(\bullet)$ 表示矩阵的迹。但这个寻找最优解的问题并不是一个凸问题，所以即使通过最优化方法（如梯度下降法，拟牛顿法等）来得到一个超参数的解，这个解也无法保证是全局最优解，而取决于所选择的初始状态。

4.2.1 人工鱼群算法简介

针对寻找全局最优解的方法中，人工鱼群算法不依赖模型的初始值分布，且有着跳出局部极小点的能力，适用于多个超参数寻优^[65,66]。其算法具体过程模拟了鱼群的几种行动模式：

（1）觅食行为：鱼群在池中通过视觉感知周围的食物浓度，即 X_i 随机选择一个 X_j 位置。

$$X_j = X_i + \text{Visual} \times \text{Rand}(\) \quad (4-31)$$

其中 $\text{Rand}(\)$ 表示 $\mathcal{N}(0,1)$ 的随机数。如果 X_j 食物浓度 Y_j 高于自身 Y_i ，则自身趋向该处，其移动保持规律如下：

$$X_i^{t+1} = X_i^t + \frac{X_j - X_i^t}{\|X_j - X_i^t\|_2} \times \text{Step} \times \text{Rand}(\) \quad (4-32)$$

若自身食物浓度较高，则不移动，重新选择寻找另一处食物浓度高的地方。直到超过最大寻找次数 Max_try 后放弃寻找，选择随机移动一次。

（2）聚群行为：鱼群在池中会周期性的扫描周围目标位置，并计算其他目标的中心位置，若其他目标食物浓度高于现位置，且该目标不拥挤，则自身向中心位置移动，否则进入觅食行为。判断拥挤方法如下：

$$\frac{Y_c}{nf} > \delta Y_i \quad (4-33)$$

其中 n_f 为扫描到的鱼个数， δ 为拥挤数因子，通过初始化设定。

(3) 追尾行为：鱼群发现周围所有鱼中的最优位置，并与其进行比较，若寻找到的最优位置 x_j 的食物浓度 Y_j 优于自身食物浓度，且其周围不太拥挤，则朝向最优位置移动，否则进入觅食行为。

算法的流程图如下：




图4.3 人工鱼群算法流程图

从流程图可以发现，鱼群在觅食行为的过程中，如果鱼群一直寻找不到食物浓度比较低的点，其将一直循环搜寻 Max_try 次，即最大搜寻次数会影响鱼群算法的收敛速度，太小的搜寻次数不利于跳出局部最优解，而太大的次数则会使得算法的收敛速度变慢^[67]。所以针对人工鱼群算法的这种缺陷，将模拟退火算法引用到人工鱼群算法的迭代过程中，可以优化算法收敛过程，同时提高最优解的精度。

4.2.2 模拟退火算法简介

模拟退火算法起源于对晶体加热后，当温度下降过快，晶体能量未达到最低态，将其重新加热增加能量，就对应了局部极小点的跳出。直到晶体形成低能量的晶体，也就对应了得到全局最优解^[68,69]。退火算法主要分为两个部分，状态选择态与退火态：

(1) 状态选择态：当判断物体最新一次能量 E_j 小于等于原有能量 E_i 时，物体接受此状态。而当其大于原有能量时，则以概率 p 接受此状态，其表达式如下：

$$p = e^{\frac{E(i)-E(j)}{KT}} \quad (4-34)$$

其中 T 代表当前状态的温度。

(2) 退火态：当在某一温度 T 迭代超过一定次数 L 后，若得到的解仍未满足系统条件，则将温度降低。在新的温度下重新进行迭代。

$$T_{new} = 0.7 \times T_{old} \quad (4-35)$$

当连续 Max_stay 次解未被接受或者温度达到最小值 T_{min} ，则输出当前解为最优解，算法结束。算法流程图如下：




图4.4 模拟退火算法流程图

4.2.3 模拟退火-人工鱼群算法简介

将模拟退火算法应用于人工鱼群算法主要从两个部分进行改进：

(1) 将人工鱼群觅食行为过程中通过最大搜寻次数控制的寻找-移动模式更改为以概率 P 向目前能搜寻到的最优位置移动，其表达式为：

$$P = \begin{cases} 1 & Y_i \leq Y_j \\ e^{-\frac{i}{N}} & Y_i > Y_j \end{cases} \quad (4-36)$$

其中 i 表示当前迭代次数， N 表示鱼群最大更新代数。若不接受当前解，则执行原算法中随机行动移动行为。针对概率 P 的设计理念为，当鱼群刚开始更新换代时，会有更大的概率执行随机移动，来跳出局部极小点。而随着鱼群代数的增多，鱼个体更倾向于向更优方向移动来代替随机移动，加快高鱼群代数时的收敛速度。

(2) 当每一代鱼群迭代完成后，将当代最优值做退火算法，在空间内选择完成对当代最优解的状态，实现进一步寻找全局极小点。

综上所述，本文所设计的模拟退火-人工鱼群算法整体步骤如下：

Step1: 初始化退火算法的初始温度 T_0 ，同一温度下的迭代次数 L ，最大尝试次数 Max_stay 。人工鱼群个数 N_{Fish} 及人工鱼群初始位置 $X = \{X_1, X_2, X_3, \dots, X_{N_{Fish}}\}$ ，其中每个鱼群位置维度 n_{dim} 由算法寻优参数维度而定，人工鱼设定视野 $Visual$ ，人工鱼群移动步长 $Step$ ，拥挤度指数 δ ，鱼群最大更新代数 N 。

Step2: 在不超过最大更新代数的前提下，每条鱼依次进行聚集行为、追尾行为，并根据自身及周边情况选择进入觅食行为。之后更新自己的位置及食物浓度，若达到当前时刻最优，则替换之。

Step3: 整个鱼群更新状态完毕后，将此代鱼群中最优值放入退火算法进行进一步优化，返回结果对比，若有优化则替换之。

Step4: 当鱼群达到最大更新代数时，输出最优解，否则进行 Step2。

4.2.4 优化高斯过程超参数

将上述算法应用于高斯过程的超参数寻优的迭代过程，本文结合节 4.2.3 中描述的高斯过程回归过程与模拟退火-人工鱼群算法，给出如下方案：

Step1: 将输入高斯过程回归的训练集划分出 10% 作为验证集，用于超参数寻优；

Step2: 将需要寻优的超参数维数输入到模拟退火-人工鱼群模型中，同时将训练集作为高斯回归过程的 X 、 Y ，将验证集作为高斯回归过程预测中的 X^* 。经过高斯

过程预测的 Y^* 与验证集中的真实值 Y 的 $RMSE$ 作为模型中的食物浓度&当前能量数值，用于反馈迭代算法；

Step3: 通过模拟退火-人工鱼群算法得到超参数迭代结果，完成超参数寻优过程；

Step4: 将超参数结果输入到高斯过程回归模型中，利用训练集与测试集输入到模型中进行预测；

Step5: 得到高斯过程回归的预测结果，模型功能结束。




图4.5 模拟退火-人工鱼群优化高斯过程流程图

4.3 高斯过程应用于产量预测模型

4.3.1 高斯过程优化产量预测研究

对于大豆的生长而言，除了本文之前描述的 MODIS 采集地面特征（地表反射率、地表温度以及土地覆盖类型等）以外，还有许多与作物生长有关的因素是遥感影像不能揭示的，如土壤类型、施肥量等。这些特征可能是特定地点(如土壤类型)

固有的，不会随着时间而发生显著变化，而是与预测地点的经度、纬度这些地理位置因素息息相关。图 4.6 为美国地区的气候类型分布：



图4.6 美国气候类型分布

可以看出，美国多数地区为温带和亚热带气候，不同地区有一定气候差异决定了土壤条件以及降水分布有所差异。本文提出的大豆产量预测模型是针对美国区域内的某州、某县级别的预测，所以地理位置信息是十分重要的。同时，由于全球气候变化的规律，相邻几年内气候类型变化也比较大，也会影响大豆生长。因此，将大豆生长的地理位置信息（经度、纬度）以及统计的生长年份加入组合产量预测模型中是必不可少的。




图4.7 2017 年大豆产量预测精度热度图

从热度图 4.7 中可以看出，靠近中心位置州县接触比较密集的地区大豆产量预

测结果相对准确。而处于边角的地区预测精度较中心位置有所下降，如图中红色线圈圈出的区域。这是因为边角地区与大部分州县不相邻且地理位置间隔很远。对于在一个州内的各个县来说，相邻县的距离差异并不是很大，所以其土壤类型，气温变化，气候种类甚至一年内的月降水分布都是类似的。这些因素只有在很大的经纬度差异上才会变得有所不同。而基于上一章提出的 CNN+ECANet+LSTM 组合预测模型的预测过程中，当年份相同，且两个县在地理位置上差别不大时预测误差很小。而当训练集的州县数据大部分所在地理位置与测试集中州县位置很远时，预测的结果误差会有所增大。同样，采用某一年份的训练数据进行网络训练，而用与此年份差别很远的测试数据去测试产量结果，其误差也会有所增大。这说明在大豆生长的过程中，年份和州县的地理位置（经度、纬度）都是影响大豆产量的重要因素。

在神经网络进行训练的过程中，由于随机分配的 mini batch 策略，网络输入的训练集中不同县、不同年份的数据混合在一起，这在一定程度上将 MODIS 数据中的地理位置以及年份信息之间存在的对产量的影响关系抹除了。所以在之前的训练中将每个县中每个年份的原始图像以及产量都看作是没有关联的，忽略了数据集中存在的时空相关性，导致出现一系列误差现象。而这些时空信息不同于光谱图像的信息，不能将其直接放入神经网络进行训练，因为就地理位置信息（经度、纬度）而言，每个州县的位置以及其相邻州县固定，而时间年份的变化是线性的，这两种因素都不适用于神经网络的学习过程，所以需要找到其他方法让时空信息融入到产量预测的结构中去。

通过节 4.1 介绍的高斯过程对回归问题的优化方法，可以将训练集中的州县的地理位置信息（经度、纬度）以及年份信息整合，作为回归问题的输入 X ，将其输入的真实产量信息作为 Y 。将测试集中的年份及地理位置，可以看作输入 X^* 。这样就可以将训练集、测试集中的州县地理信息及年份信息整合到高斯过程中，也就完成了添加时空相关性的产量预测模型的初步建立^[70]。

4.3.2 高斯过程优化产量预测建模

将高斯过程应用于上一章中组合网络预测模型输出结果的优化，也就是将地理位置信息与年份信息加入到高斯过程的建模中。本文中对高斯过程的建模如下：

$$g(x) = h(x)^T \beta + f(x) \quad (4-37)$$

其中 $h(\bullet)$ 为一组基函数，是组合网络模型最后一层全连接层的输入，通过对输入 x 进行的维度扩张来保证其与公式中 $f(x)$ 的维度相同。 β 表示组合网络模型最后一层全连接层的参数，是满足高斯分布的随机变量，即 $\beta \in \mathcal{N}(b, B)$ ，其中 b 与 B 分别代表这个高斯分布的均值与协方差矩阵。本文试图将神经网络中与最终产量预测输出

相关的部分信息融入到高斯过程的建模中。因为组合网络预测模型中，数据经过 LSTM 模块，将最后一层全连接层输入转化为预测的大豆产量值，所以从网络结构层面来看，与产量输出相关性最强的网络参数就为最后一层全连接层中的参数。

因此通过组合神经网络输出层的最后一层（全连接层）的输出特征值来影响基函数分布，利用该层的参数 w 和 $bias$ 来确定 $\beta \in \mathcal{N}(b, B)$ 中的 b ，对于 B ，通过一个超参数 σ_b 来表征其协方差矩阵中值的大小，整体 $h(x)^T \beta$ 表征这个模型的均值由最后一层连接层的输入与参数决定，即将神经网络中的参数用于高斯过程的建模。最后一层全连接层的计算公式如下：

$$y_{pred} = \sum_{i=1}^N w_i x_i + bias \quad (4-38)$$

由于是本文属于回归问题，从组合神经网络最后一层的表达式中可以看出，回归问题得到预测结果的最后一步近似于一个线性问题。从过程上来看，通过将最后一层全连接层的输入及其权重 w 与偏差 $bias$ 加入到高斯过程的建模中，完成了本文提出的组合神经网络模型与高斯过程的联合。

而对于式 (4-37) 中 $f(x) \sim \mathcal{GP}(0, K(x, x'))$ ， $f(x)$ 代表将美国州县区域的地理位置及年份信息融入到协方差矩阵中的一个高斯过程。根据节 4.1.2 中所描述的高斯核函数种类，本文选择的高斯核为平方指数核 SE。针对地理位置信息 $g_{loc} \in \mathbb{R}^2$ ， $g_{year} \in \mathbb{R}^1$ ，本文对高斯核的建模如下：

$$K_{SE}(x, x') = \sigma^2 \exp \left[-\frac{g_{loc} - g'_{loc}}{2r_{loc}^2} - \frac{g_{year} - g'_{year}}{2r_{year}^2} \right] + \sigma_e^2 \delta_{g, g'} \quad (4-39)$$

其中 σ 、 σ_e 、 r_{loc} 与 r_{year} 为 SE 高斯核引入的超参数，而 $\sigma_e^2 \delta_{g, g'}$ 表示为在高斯建模的过程中引入的噪声分量 noise，其噪声功率大小通过 σ_e^2 控制。

通过节 4.1.1 对高斯过程的描述以及 4.1.2 中从贝叶斯理论的角度延伸到高斯过程回归，可以将本文对高斯过程的建模看作为一个全局线性模型，其残差部分通过高斯过程建模，即将原本直接通过全连接层输出的组合神经网络结构改变为：将组合网络预测模型最后一层全连接层的输入、参数权重 w 与偏差 $bias$ 作为基函数，控制模型均值。根据式 (4-39) 中描述， $f(x)$ 作为一个 0 均值的高斯过程，其协方差由地理位置信息、年份信息高斯核表征，最终得到最后的全局线性模型。构建的高斯过程模型 $g(x)$ 的分布如下：

$$g(x) \sim \mathcal{GP}(h(x)^T b, K_{SE}(x, x') + h(x)^T B h(x')) \quad (4-40)$$

通过贝叶斯理论，对大豆产量预测结果的优化就相当于根据测试集输入的参数，

即测试集中的地理位置、时间信息、组合神经网络的最后一层全连接层的输入特征、权重以及偏差，经过高斯过程的建模，得到一个输出结果：预测的均值 μ^* ，作为本文预测产量的结果。根据公式（4-40）的推导以及高斯过程建模的表达式（4-39），可以得到本文建立的高斯过程模型中预测结果的均值表达式为：

$$\bar{\mu}^* = H^{*T} \bar{\beta} + K_*^T K_y^{-1} (y - H^T \bar{\beta}) \quad (4-41)$$

$$\bar{\beta} = (B^{-1} + H K_y^{-1} H^T)^{-1} (H K_y^{-1} y + B^{-1} b) \quad (4-42)$$

其中 H^* 表示测试集中组合神经网络最后一层全连接层的输入，表征神经网络对输入的维度扩展， $\bar{\beta}$ 表示其分布的均值^[71]， $H^{*T} \bar{\beta}$ 代表测试集均值 $\mu(X^*)$ 。 $K_*^T = K(X^*, X)$ ，表示训练集 X 与测试集 X^* 的协方差。 $K_y^{-1} = K(X, X) + \sigma_e^2 \delta_{g,g}$ ，其中 $K(X^*, X^*)$ 代表测试集数据的协方差矩阵。 y 表示训练集中的真实产量。 $H^T \bar{\beta}$ 总体表征训练集数据的预测均值， H 表示训练集中最后一个全连接层的输入，表征神经网络对输入的维度扩展。

至此，基于高斯过程的大豆产量预测模型建立完成，其中共引入五个超参数，分别为： σ ， σ_b ， σ_e ， r_{year} ， r_{loc} ，如果按经验初始化这些超参数的值，会降低上述模型的泛化能力，可能会使模型的预测性能不稳定，因此，本文按节 4.2.4 中介绍的模拟退火-人工鱼群算法优化以上超参数。本章后续实验内容会分为超参数优化前、后两部分对比展开，用来验证前面理论部分的推导。

4.4 仿真实验及结果分析

4.4.1 基于高斯过程优化的组合网络结构




图4.8 基于高斯过程优化的组合网络结构图

参考节 4.3 对高斯过程建模的描述, 将 CNN+ECANet+LSTM 组合网络结构中最后一个全连接层的输出、权重与偏差参数以及地理信息与年份信息输入到高斯模型中, 最后得出经过优化的产量预测结果。

本章中提出的基于高斯过程优化的组合网络模型结构图如下图 4.8 所示:

4.4.2 实验数据、环境及评价标准

实验数据同节 3.6.1 中选择的数据集, 选择 MOD09A1、MYD11A2 和 MCD12Q1 三种 MODIS006 号产品来描述大豆产品的地表反射率、地表温度和植被类型, 其遥感图像获取时采用的分辨率为 500m。从 USDA 提供的大豆产量表格中选取了其中大豆总产量约占到全美产量总数的 75%以上的 11 个州, 选取这些州县从 2003 年到 2020 年共 13 年的大豆产量数据作为本实验的原始数据。

实验环境同节 3.6.2, 为方便阅读, 再次给出表 4.1:

表4.1 本文实验基础环境

网络搭建框架	Pytorch
开发语言	Python、CUDA 10.0、CUDNN v7
CPU	AMD Ryzen 7 3700X 8-Core @3.60GHz
内存	32G/DDR4
GPU	GTX 2060 (8GB)
操作系统	Windows10(64 位)

实验评价标准同节 3.6.3 中所选, 继续以 MSE 作为损失函数, 以 RMSE 表示最终预测结果的偏差。利用该评价指标对网络性能进行验证。为了方便阅读, 本节再次给出公式:

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (4-43)$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{N}} \quad (4-44)$$

其中, y_i 为大豆产量的预测值, $\hat{y}_i$ 为大豆产量的真实值。MSE 与 RMSE 代表预测值与真实值之间的偏差, 值越小代表偏差越小, 即模型的预测性能越好。

CNN+ECANet+LSTM 组合神经网络模型参数设置如节 3.6.4 中表 3.2 所示。

4.4.3 实验过程及仿真参数设置

本章的实验过程分两步：

Step1: 将 CNN+ECANet+LSTM 组合神经网络模型的输出放入超参数固定的高斯过程中进行产量预测结果优化。高斯过程的建模中所使用的超参数如表 4.2 所示：

表4.2 高斯过程的超参数

参数名	数值
σ	1
σ_b	0.01
σ_e	0.32
r_{year}	1.5
r_{loc}	0.5

Step2: 利用模拟退火-人工鱼群算法对高斯过程中的超参数进行优化。将需要寻优的超参数维数输入到模拟退火-人工鱼群模型中，同时将输入高斯过程回归的训练集划分出 10%作为验证集，用于超参数全局寻优。通过上述步骤完成超参数寻优过程。最后将组合神经网络的输出放入新的高斯模型中进行产量预测结果优化。

表4.3 模拟退火的人工鱼群算法相关参数

参数名	数值
人工鱼群参数	$n_{dim} = 5, N_{Fish} = 30, Visual = 0.85, Step = 0.5, \delta = 0.5, N = 40$
模拟退火参数	$T_0 = 100, T_{min} = 0.001, L = 10, Max_stay = 7$

根据节 4.2.4 的描述，算法相关参数设置如表 4.3 所示，算法中初始鱼群位置设置为 0 到 1 之间均匀分布的随机数。

实验 step1 的目的在于证明高斯过程的加入成功将预测州县的地理位置信息与年份信息融入到其粮食产量预测过程中，并优化预测结果。

实验 step2 的目的在于证明本文使用的基于模拟退火的人工鱼群算法实现了高斯过程中超参数的寻优过程，使得针对不同种类的数据集，高斯过程都可以根据其提供的数据特征有效选取合适的超参数，提高了模型的泛化能力，从而使高斯过程的优化效果更加稳定。

4.4.4 实验结果及分析

为验证高斯过程对神经网络的优化，本章采用上章提出的 CNN+ECANet+LSTM

组合产量预测模型作为参考网络。将其结果通过高斯核进行优化，同样采用 RMSE 来表示最终预测结果的偏差。

首先，实验第一步，使用超参数预设定好的高斯过程针对大豆产量预测结果进行优化。图 4.9 是 2020 年份大豆产量预测结果热度图，左图为未添加高斯过程优化的预测结果，右图为添加高斯过程优化的预测结果，可以看出，经过高斯过程优化的产量预测结果基本有所改善。图中红色圆圈标注区域，能够较为明显地显示，高斯过程的加入优化了选定 11 个州中边角地区的预测精度。这是因为通过高斯过程的协方差参数，将年份信息和地理位置信息加入预测的过程，在模型中建立了时空相关性。所以结果显示高斯过程对大豆产量预测是有良好改善的。




图4.9 添加高斯过程前、后预测结果对比图

但是，在下表 4.4 的实验结果中可以发现，2017 年份大豆产量的预测结果 RMSE 优化的程度并不明显，甚至出现了预测结果倒退的现象。这说明，高斯过程模型中选择固定的超参数，但是每次预测过程中给出的训练数据不同，其数据的性质也有所不同，使用同一种超参数会使得高斯过程预测模型的泛化性下降。

表4.4 高斯过程添加前、后对大豆产量预测的 RMSE（单位：bushel/acre）

年份\网络模型	CNN+ECANet+LSTM	CNN+ECANet+LSTM+高斯过程
2016	7.09	6.43
2017	5.01	5.09
2018	5.45	5.29
2019	4.72	4.43
2020	5.52	5.43
均值	5.56	5.33

因此进行实验第二步，采用模拟退火-人工鱼群算法对高斯过程的超参数进行优化，以 2017 年份的预测为例，其收敛曲线如下图 4.10 所示，可以看出，随着迭代次数的增加，模型的预测性能不断提升最后趋于稳定，收敛结果优于未优化超参数的模型。




图4.10 高斯过程超参数优化收敛曲线

经过模拟退火-人工鱼群算法对高斯过程的超参数进行优化后，将其用于组合产量预测模型，实验结果数据如下表 4.5 所示。可以看出在预测结果倒退的年份中，预测结果得到了改善。

表4.5 高斯过程添加前、后及优化后对大豆产量预测的 RMSE（单位：bushel/acre）

年份\网络模型	CNN+ECANet+LSTM	CNN+ECANet+LSTM+高斯过程	模拟退火+人工鱼群
2016	7.09	6.43	6.41
2017	5.01	5.09	4.88
2018	5.45	5.29	5.30
2019	4.72	4.43	4.39
2020	5.52	5.43	5.42
均值	5.56	5.33	5.28

综上，在第三章提出的 CNN+ECANet+LSTM 组合产量预测模型的基础上添加高斯过程，其对大豆产量预测的 RMSE 更小，整体的平均结果有所优化。而基于模拟退火-人工鱼群算法优化高斯过程超参数使得高斯过程预测模型的泛化性有所上升，从而整体的平均结果有了更进一步的优化，预测的稳定性得到了提升，符合理论分析。

4.5 本章小结

本章首先介绍高斯过程基本原理，在此基础上讨论了高斯过程应用于回归问题的可行性，考虑到本文所研究的农作物产量预测模型属于回归类问题，因此，将高斯过程应用于上一章介绍的组合神经网络中，添加地理位置与年份信息等因素，建立时间空间相关模型，并且利用模拟退火算法结合人工鱼群算法将高斯过程回归问题中超参数的选择进行优化，在整体上对第三章所设计的组合神经网络预测农作物产量结果进一步优化。

第五章 总结与展望

5.1 本文工作总结

粮食安全关乎国家根本。粮食产量预测是保障粮食安全的重要环节之一，如何进行精准的粮食预测一直是农业发展的难题之一。传统的线性预测模型大多是采用纯数学方法对数据进行拟合，必须手动提取特征值，难以准确反映复杂的粮食生产过程。机器学习能处理复杂的非线性问题，很适合应用在农作物产量预测中。因此，本论文针对农作物产量预测问题，以美国大豆产量作为研究对象，将 MODIS 遥感图像作为原始数据，设计了 CNN+ECANet+LSTM 结合的神经网络，并利用高斯过程添加时空相关性，优化高斯过程的超参数选择，最终实现了本文的农作物产量预测模型。

首先，本文研究了基础的 CNN 和 LSTM，提出一种 CNN+LSTM 的组合模型，利用 CNN 网络在提取特征值方面出色的表现，结合 LSTM 网络有时间相关性的优势，取长补短得到更具竞争力的组合网络模型，并在此基础上加入注意力机制，具体操作为：将 CNN 模块的最后一层卷积层输出作为 ECANet 的输入，在 ECANet 中进行学习，从而将其输入值做了权重的重分配后再输出至 LSTM 模块进行训练及预测，进一步提高最后的预测性能。仿真表明，本文提出的 CNN+ECANet+LSTM 组合网络模型能够对 MODIS 采集到的数据集进行有效的处理并较为准确的预测出大豆的产量信息，为粮食产量预测问题提出了有效的解决方案。

考虑到以上提出的组合网络模型并没有显示 MODIS 图像中潜在的许多与大豆生长相关特征，无法将地理位置和年份信息直接输入至神经网络进行训练。因此，利用高斯过程将时空相关性因素加入从而优化预测结果。首先研究了高斯过程基本原理以及其用于回归问题的原理。接着，将高斯过程应用于本文的组合神经网络中，添加地理位置与年份信息等因素，建立时间空间相关模型，并且利用模拟退火算法结合人工鱼群算法将高斯过程回归问题中超参数的选择进行优化。仿真结果表明，基于退火的人工鱼群算法优化超参数选择可以实现高斯过程优化性能的稳定化，符合理论分析，在实际预测中具有较好的应用价值。

5.2 未来工作展望

作为粮食安全的重要环节之一，农作物产量预测仍具有广阔的发展空间，相较于传统的预测模型，基于深度学习的产量预测在精度和应用范围等方面都具有突出优势。在本文研究成果的基础上，可在如下方面开展进一步研究：

1、本文所提出农作物产量预测模型只针对美国大豆这种单一农作物，不具备同时估计多种农作物产量的能力。下一步可考虑实现一种能够预测多种农作物产量并同时考虑它们之间相互作用的模型，可以从新颖的深度学习框架入手，以及设计新的损失函数能够考虑多目标响应变量，从而实现大豆和其他农作物产量预测之间的迁移学习，进一步提高预测模型的竞争力；

2、本文所描述的基于高斯过程优化神经网络预测结果的模型存在计算量大的瓶颈，其非参数性质直接导致计算复杂度较大的问题，下一步可以考虑从以下三个方面降低计算的时间复杂度：（1）数据子集近似法，即在原维训练集中寻找低维度子集进行训练，在保证精度要求的同时可有效节省计算资源；（2）降秩近似法，即对高斯过程的协方差矩阵做近似降秩，从而减少矩阵求逆的时间复杂度；（3）稀疏伪输入法，即寻找原数据集的子集来表征所有数据点，或者仅利用测试点附近的训练数据点集进行预测。以上述方法为出发点进一步研究降低高斯过程计算的时间复杂度。

参考文献

- [1] SU S. Study on China Food Security Issues from the Perspective of the World Grain Trade[J]. Regional Economic Review, 2015 (04):65-71.
- [2] LIU Y, ZHOU Y. Reflections on China's Food Security and Land Use Policy under Rapid Urbanization[J]. Land Use Policy, 2021, 11(4):1-25.
- [3] LV F, DENG L, ZHANG Z, ET AL. Multiscale Analysis of Factors Affecting Food Security in China, 1980–2017[J]. Environmental Science Pollution Research, 2021, 29(5):1-15
- [4] MAH A, MYA B, ARA E, et al. A Rapid Monitoring of NDVI across the Wheat Growth Cycle for Grain Yield Prediction Using A Multi-spectral UAV Platform[J]. Plant Science, 2019, 282: 95-103.
- [5] WU X, WASHAYA P, LIU L, et al. Rice Yield Estimation Based on Spaceborne SAR: A Review from 1988 to 2018[J]. IEEE Access, 2020, 8: 157462-157469.
- [6] SISHODIA R P, RAY R L, SINGH S K. Applications of Remote Sensing in Precision Agriculture: A Review[J]. Remote Sensing 2020, 12 (19): 3136.
- [7] 郑建安. 主成分和 BP 神经网络在粮食产量预测中的组合应用[J]. 计算机系统应用, 2016, 25(11): 274-278.
- [8] XINGMEI X, LIYING C, JING Z, et al. Study and Application of Grain Yield Forecasting Model[C]. International Conference on Computer Science & Network Technology, 2016, 1: 652-656.
- [9] 郝妙. 基于 GM(1,1)模型的四川粮食产量预测研究[J]. 农学学报, 2017, 7(10): 96-100.
- [10] CHUN-HUA L I, NING L I, MENG Z Q. Estimation of Grain Yield Loss in Jiangsu Province Based on Grey Prediction Model[J]. Journal of Natural Disasters, 2008, 17(1): 104-108.
- [11] CHENG M, SHI G, XIANG M. On the Improvement of the Parameter Estimation of the Grey Model GM(1,1) and Model Application[J]. Communications in Statistics: Simulation Computation, 2020. 49(5): 1367-1384.
- [12] XIAO L, WANG H, DUAN M. The Optimization of Grey Model GM (1,1) Based on Posterior Error[C]. 2020 5th International Conference on Control, Robotics and Cybernetics (CRC), IEEE, 2020: 87-91
- [13] CHEN Z, JIANG H, YANG X. Study on the influencing factors of grain yield in China based on multiple linear regression[C]. 2nd International Conference on Big Data Economy and Information Management (BDEIM), IEEE, 2021: 229-233.
- [14] JAFARI F, PONNAMBALAM K, MOUSAVI J, et al. Yield forecast of California strawberry:

- Time-series Models vs. ML Tools[C]. IEEE International Conference on Systems, Man, and Cybernetics (SMC), IEEE, 2020: 3594-3598.
- [15] 李军成, 陈国华, 石小芳. 基于灰色多元线性回归的粮食产量预测[J]. 安徽农业科学, 2010 38(16): 8281-8282.
- [16] ABDOLLAHIAN M, LASMINI L. Forecasting Wet Land Rice Production for Food Security[C]. Tenth International Conference on Information Technology: New Generations, IEEE, 2013:602-607.
- [17] PUTRA J A, BASBETH F, BUKHORI S. Sugar Production Forecasting System in PTPN XI Semboro Jember Using Autoregressive Integrated Moving Average (ARIMA) Method[C]. 6th International Conference on Electrical Engineering, Computer Science and Informatics (EECSI), IEEE, 2019: 448-453.
- [18] SIKALUBYA M, XU S, YU W, et al. Study on Forecasting Soybean Production: An Application of ARIMA Model[C]. International Conference on Intelligent Computing, Automation and Systems (ICICAS), IEEE, 2019: 447-452.
- [19] ELAVARASAN D, DURAI R. Crop Yield Prediction using Deep Reinforcement Learning Model for Sustainable Agrarian Applications[J]. IEEE Access, 2020, 8: 86886-86901.
- [20] LI B, ZHANG Y, ZHANG S, et al. Prediction of Grain Yield in Henan Province Based on Grey BP Neural Network Model[J]. Discrete Dynamics in Nature Society, 2021, 2021, 1-13
- [21] 姚作芳, 刘兴土, 杨飞, et al. 几种方法在粮食总产量预测中的对比[J]. 干旱地区农业研究, 2010, 28(04): 264-268.
- [22] XINGMEI X, HE W. Research on the prediction method of grain yield basing on the BP network in Jilin province[C]. Proceedings of 2013 3rd International Conference on Computer Science and Network Technology, IEEE, 2013: 413-416.
- [23] 宗宸生, 郑焕霞, 王林山. 改进粒子群优化 BP 神经网络粮食产量预测模型[J]. 计算机系统应用, 2018, 27(12): 204-209.
- [24] ZHILIANG W, BINBIN L, LEI C. Application of BP Neural Network Based on Principal Component Analysis in Grain Yield Prediction[C]. The 2nd International Conference on Information Science and Engineering, IEEE, 2010: 1011-1013.
- [25] 罗梦森, 景元书, 熊世为. 基于遗传优化 BP 神经网络的水稻气象产量预报模型[J]. 气象科学, 2012, 32(06): 665-670.
- [26] 周亮, 慕号伟, 马海娇. 基于卷积神经网络的中国北方冬小麦遥感估产[J]. 农业工程学报, 2019, 35(15): 119-128.
- [27] SHAHHOSSEINI M, HU G, KHAKI S, et al. Corn Yield Prediction with Ensemble CNN-DNN[J]. Frontiers in Plant Science, 2021, (05), 1-22.

- [28] KHAKI S, WANG L, ARCHONTOULIS S V.A CNN-RNN Framework for Crop Yield Prediction[J]. *Frontiers in Plant Science*, 2019, 10(01): 1750-1764.
- [29] MO H, ZHANG Y, LIU Y, et al.Prediction of Rice Yield Based on LSTM Long Short Term Memory Network[J]. *Journal of Physics: Conference Series*, 2021,1952: 42033-42033.
- [30] 戴建国, 蒋楠, 薛金利, et al. 基于 CNN-BiLSTM 的棉花产量预测方法[J]. *农业工程学报*, 2021, 37(17): 152-159.
- [31] FERNANDEZ-ORDONEZ, YM, SORIA-RUIZ, et al.Maize Crop Yield Estimation with Remote Sensing and Empirical Models[J]. *Int Geosci Remote Se*, 2017, (07):3035-3038.
- [32] P. H. 斯韦恩, S. M. 戴维. 遥感定量方法[M]. 遥感定量方法, 科学出版社, 1984.
- [33] XIAJIONG S, YAN J, KE Z, et al. Application Analysis and Prospect of Deep Learning in Remote Sensing Image Classification[C].MIPPR 2019: Remote Sensing Image Processing, Geographic Information Systems, and Other Applications, SPIE, 2020:17-19.
- [34] LIU X. Large-Scale Crop Mapping From Multisource Remote Sensing Images in Google Earth Engine [J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2020, 13: 414-427.
- [35] HE M, KIMBALL J S, MANETA M P, et al.Regional Crop Gross Primary Productivity and Yield Estimation Using Fused Landsat-MODIS Data[J]. *AGU Fall Meeting Abstracts*, 2018, 10(3), 372-377.
- [36] JUSTICE C O, TOWNSHEND J, VERMOTE E F, et al.An Overview of MODIS Land Data Processing and Product Status[J]. *Remote Sensing of Environment*, 2002, 83 (1-2): 3-15.
- [37] SALOMONSON V V, BARNES W, XIONG J, et al. An Overview of the Earth Observing System MODIS Instrument and Associated Data Systems Performance[C]. *IEEE International Geoscience and Remote Sensing Symposium*, IEEE, 2002, 2: 1174-1176.
- [38] KING M D, KAUFMAN Y J, MENZEL W P, et al.Remote Sensing of Cloud, Aerosol, and Water Vapor Properties from the Moderate Resolution Imaging Spectrometer (MODIS)[J]. *IEEE Transactions on Geoscience Remote Sensing of Environment*, 1992, 30 (1): 2-27.
- [39] BENDIX J, THIES B, NAUß T, et al.A Feasibility Study of Daytime Fog and Low Stratus Detection with TERRA/AQUA - MODIS over Land[J].*Meteorological Applications*, 2006, 13 (2): 111-125.
- [40] SULLA-MENASHE D, GRAY J M, ABERCROMBIE S P, et al.Hierarchical Mapping of Annual Global Land Cover 2001 to Present: The MODIS Collection 6 Land Cover Product[J]. *Remote Sensing of Environment*, 2019, 222: 183-194.
- [41] DUMKA U C. A Long-Term Spatiotemporal Analysis of Vegetation Greenness over the Himalayan Region Using Google Earth Engine[J]. *Climate*, 2021, 9(7): 109-130.

- [42] ZARANDY A, REKECZKY C, SZOLGAY P, et al. Overview of CNN Research: 25 Years History and the Current Trends[C].2015 IEEE International Symposium on Circuits and Systems (ISCAS), IEEE, 2015: 401-404.
- [43] SHIN H C, ROTH H R, GAO M, et al.Deep Convolutional Neural Networks for Computer-Aided Detection: CNN Architectures, Dataset Characteristics and Transfer Learning[J]. IEEE Transactions on Medical Imaging, 2016, 35 (5): 1285-1298.
- [44] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(6): 1229-1251.
- [45] HU J, XU L, WANG X, et al.Effects of BP Algorithm-based Activation Functions on Neural Network Convergence[J]. 電腦學刊, 2018, 29(1): 76-85.
- [46] 杨丽, 吴雨茜, 王俊丽, et al.循环神经网络研究综述[J]. 计算机应用, 2018, 38(S2): 1-6+26.
- [47] TSOI A C.Recurrent Neural Network Architectures: An Overview[J]. Adaptive Processing of Sequences Data Structures Lecture Notes in Computer Science, 1998, 1387: 1-26.
- [48] HOCHREITER S.The Vanishing Gradient Problem During Learning Recurrent Neural Nets and Problem Solutions[J].International Journal of Uncertainty, Fuzziness Knowledge-Based Systems, 1998, 06 (2): 107-116.
- [49] 胡新辰. 基于 LSTM 的语义关系分类研究[D]. 哈尔滨工业大学, 2015.
- [50] HOCHREITER, SEPP, SCHMIDHUBER, et al.Long short-term memory[J]. Neural Computation, 1997, 9(8):1735-1780.
- [51] SAK H, SENIOR A, BEAUFAYS F. Long Short-Term Memory Recurrent Neural Network Architectures for Large Scale Acoustic Modeling[J]. Computer Science, 2014, (01), : 338-342.
- [52] 李敏学. 基于注意力机制的图像显著区域提取算法分析与比较[D]. 北京交通大学, 2011.
- [53] JIE H, LI S, GANG S, et al. Squeeze-and-Excitation Networks[J].IEEE Transactions on Pattern Analysis Machine Intelligence, 2020, 42(8): 2011-2023.
- [54] YANG M, MA T, TIAN Q, et al.Aggregated Squeeze-and-excitation Transformations for Densely Connected Convolutional Networks[J].The Visual Computer, 2020, 32(9):5285-5302.
- [55] WANG Q, WU B, ZHU P, et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks[C]. 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), IEEE, 2020: 11531-11539.
- [56] 高岩, 于治楼, 姜凯, et al. 一种适合卷积神经网络模型的 dropout 方法[P]. 中国: CN110070180A, 2019-07-30.
- [57] RASKUTTI G, WAINWRIGHT M J, YU B. Early Stopping and Non-parametric Regression: An Optimal Data-dependent Stopping Rule[J]. Journal of Machine Learning Research, 2013, 15: 1318-1325.
- [58] SEEGER, MATTHIAS.Gaussian Processes for Machine Learning[J].International Journal of

- Neural Systems, 2008, 14 (02): 69-106.
- [59] 何志昆, 刘光斌, 赵曦晶, et al. 高斯过程回归方法综述[J]. 控制与决策, 2013, 28(8): 1121-1129+1137.
- [60] CAMPOS-TABERNER M, GARCIA-HARO F J, MORENO A, et al. Mapping Leaf Area Index With a Smartphone and Gaussian Processes[J]. IEEE Geoscience Remote Sensing Letters, 2015, 12(12): 2501-2505.
- [61] 王芳黎. 基于高斯过程回归方法的研究及应用[J]. 工业控制计算机, 2015, 28(11): 76-78+81.
- [62] KWAK N. Nonlinear Projection Trick in Kernel Methods: An Alternative to the Kernel Trick[J]. IEEE Transactions on Neural Networks Learning Systems, 2013, 24(12): 2113-2119.
- [63] ALSPACH D, SORENSON H. Nonlinear Bayesian Estimation Using Gaussian Sum Approximations[J]. IEEE Transactions on Automatic Control, 2003, 17(4): 439-448.
- [64] LIN S L, LIU Z. Parameter Selection in SVM with RBF Kernel Function[J]. Journal of Zhejiang University of Technology, 2007, 02: 163-167.
- [65] 李晓磊, 邵之江, 钱积新. 一种基于动物自治体的寻优模式: 鱼群算法[J]. 系统工程理论与实践, 2002, 22(11): 32-38.
- [66] ZHU Y, GAO H. Improved Binary Artificial Fish Swarm Algorithm and Fast Constraint Processing for Large Scale Unit Commitment[J]. IEEE Access, 2020, 8: 152081-152092.
- [67] ZOU L, LI H, JIANG W, et al. An Improved Fish Swarm Algorithm for Neighborhood Rough Set Reduction and Its Application[J]. IEEE Access, 2019 (99): 90277-90288.
- [68] BANGERT P. Optimization: Simulated Annealing[M]. Optimization for Industrial Problems, 2012.
- [69] BANDYOPADHYAY S, SAHA S, MAULIK U, et al. A Simulated Annealing-Based Multiobjective Optimization Algorithm: AMOSA[J]. IEEE Transactions on Evolutionary Computation, 2008, 12(3): 269-283.
- [70] YOU J, LI X, LOW M, et al. Deep Gaussian Process for Crop Yield Prediction Based on Remote Sensing Data[C]. Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence, AAAI, 2017: 4559-4565.
- [71] RASMUSSEN C E, WILLIAMS C. Gaussian Processes for Machine Learning[M]. MIT Press, 2005.



西安电子科技大学
XIDIAN UNIVERSITY

地址：西安市太白南路2号

邮编：710071

网址：www.xidian.edu.cn