



分类号 S512

学 号 2020101018

南京农业大学

硕 士 学 位 论 文

基于多源信息融合的冬小麦氮肥智能推荐算法研究

阮国杰

指导教师 曹强 副教授

学科门类 农学

一级学科 作物学

二级学科 作物栽培学与耕作学

研究方向 作物精确管理

答辩日期 二〇二三年五月三十日

**Winter Wheat Smart Nitrogen Recommendation
Algorithms Based on Multi-source Data Fusion**

By

RUAN GUOJIE

A Thesis

Presented to Nanjing Agricultural University

in Partial Fulfillment of the Requirements

for the Degree of

Master of Agronomy

in

Crop Cultivation and Farming

Supervised by

Professor CAO QIANG

Nanjing Agricultural University

Nanjing, China

June 2023

学位论文答辩委员会成员名单

姓名	职称	博导/硕导	所在单位	成员类别
田永超	教授	博导	南京农业大学	答辩主席
朱艳	教授	博导	南京农业大学	答辩委员
刘小军	教授	博导	南京农业大学	答辩委员
江冲亚	教授	博导	南京农业大学	答辩委员
黄涛	副教授	硕导	南京师范大学	答辩委员

目 录

第一章 文献综述	1
1 研究背景.....	1
2 作物产量预测研究进展.....	3
3 作物氮素营养监测与诊断研究进展	5
4 作物氮肥推荐算法研究进展.....	8
5 待研问题的提出.....	12
6 研究思路与技术路线.....	12
6.1 研究思路.....	12
6.2 技术路线.....	13
7 本研究的目的与意义.....	13
第二章 基于多源信息融合的冬小麦产量早期预测	15
引言.....	15
1 材料与方法.....	18
1.1 研究区域.....	18
1.2 历史试验设计.....	19
1.3 近端传感数据获取.....	19
1.4 气象数据获取.....	21
1.5 产量数据获取.....	21
1.6 数据分析.....	23
2 结果与分析.....	29
2.1 产量的变化特征.....	29
2.2 特征选择结果.....	29
2.3 模型表现与分析.....	32
3 讨论.....	37
3.1 早期产量预测在作物精确管理中的可行性	37
3.2 产量预测中不同统计和机器学习方法的对比	38
3.3 高贡献度特征与作物生长之间的联系	39
3.4 特征选择方法与特征聚合区间的对比	40
3.5 田块尺度冬小麦产量预测模型的潜力	40
4 结论.....	41
第三章 基于多源信息融合的冬小麦氮素营养监测	42
引言.....	42
1 材料与方法.....	44
1.1 试验设计	44

1.2 近端传感与气象数据.....	44
1.3 氮营养数据.....	44
1.4 深度学习.....	45
1.5 进化算法.....	46
1.6 模型评估.....	48
1.7 模型解释.....	49
2 结果与分析.....	49
2.1 不同氮指标和特征的变异性.....	49
2.2 深度学习与进化算法的模型性能.....	51
2.3 不同氮营养指标间的模型性能.....	52
2.4 基于 SHAP 值的模型解释	55
3 讨论.....	56
3.1 深度学习与进化算法框架的可行性.....	56
3.2 智慧作物管理中的模型可迁移性.....	57
3.3 模型重要特征的贡献度.....	58
4 结论.....	59
第四章 基于多源信息融合的冬小麦氮肥推荐算法构建	60
引言.....	60
1 材料与方法.....	62
1.1 试验设计与数据获取.....	62
1.2 直接型冬小麦追氮推荐算法的构建.....	62
1.3 间接型冬小麦追氮推荐算法的构建.....	63
1.4 冬小麦追肥验证试验设计.....	64
1.5 追肥量的多目标优化.....	65
2 结果与分析.....	67
2.1 最优施氮量与最优追氮量.....	67
2.2 数据驱动型氮肥推荐算法的模型性能	70
2.3 最优追氮量的主要驱动因子.....	71
2.4 冬小麦拔节期氮肥推荐的效益评估.....	72
2.5 追氮量的多目标优化.....	77
3 讨论.....	78
3.1 多源数据驱动氮肥推荐算法的可行性	78
3.2 产量预测法(间接型)与最优追氮量法(直接型)的异同	79
3.3 施氮量的多目标优化.....	80
4 结论.....	81
全文讨论与结论、创新点及研究展望	82
1 全文讨论.....	82
1.1 冬小麦生长监测与氮肥推荐的影响因素	82

1.2 模型复杂度与模型性能的权衡.....	83
1.3 作物氮肥推荐算法的可行性.....	84
2 创新点.....	84
3 研究展望.....	85
4 全文结论.....	86
参考文献.....	87

基于多源信息融合的冬小麦氮肥智能推荐算法研究

摘要

精确氮素管理对保障粮食安全,实现农业绿色发展至关重要。针对氮肥推荐算法的准确性、实用性和时空普适性不强,缺乏田块精准与区域优化的协同,忽视多目标效益的权衡等问题,本研究围绕冬小麦产量预测、氮素监测、施肥决策的关键模型,构建了基于多源信息融合的冬小麦间接型(基于产量预测与氮素监测)与直接型(基于追氮量预测)氮肥智能决策与评估的技术框架。主要包括:

(1)首先基于多年多点的田间历史试验数据、本研究通过整合冠层光谱和气象数据,建立田间小麦产量拔节期预测模型。通过构建 11 种统计和机器学习回归模型,分析两种特征聚合区间以及两种特征选择方法,全面评估产量预测的模型性能。结果表明,以随机森林算法为代表的集成学习模型取得了最高的模型精度,非线性的机器学习方法比传统的线性回归显著提高了预测精度。基于随机森林的特征重要性分析表明归一化差异红边指数、平均温度、最低温度和相对湿度对产量预测模型贡献最大,尤其是从种植日期到拔节期(就气象特征而言)。聚合方法和特征选择方法没有显著影响七种机器学习方法的产量预测性能,因此建议使用全生育期气象数据聚合并进行特征选择,以平衡模型性能与农户管理成本。

(2)其次本研究整合全生育期的时间序列信息(不同生育期的冠层光谱数据、播种至特定测试日期的气象数据),搭建深度学习与进化算法结合的冬小麦氮素估测(包括地上部生物量、植株氮浓度、植株氮吸收量和氮营养指数)简洁框架,为作物精确管理提供高效、智能化解决方案。本研究使用了长短期记忆、深度神经网络两种深度学习方法进行建模以提取作物生长累积信息,并以随机森林作为基准模型作比较。同时首次引入多任务学习对四种氮营养指标进行同时估测。基于进化算法的全局优化能力对深度神经网络分别尝试进行超参数、连接权重以及多任务学习损失权重的优化。从结果上,随机森林和深度神经网络取得较高的精度。但长短期记忆模型和进化算法的性能值得进一步探索。其中,氮营养指数的估测精度需要进一步提高。利用模型可解释性框架解析发现物候驱动因子对全生育期氮素监测至关重要,水分相关特征对植株氮浓度和氮营养指数估测具有特别贡献。

(3)最后本研究提出了耦合田块精准与区域优化的最优追氮量的概念,融合多源信息构建基于随机森林的最优追氮量的直接预测模型。基于随机森林的特征重要性分析表明,植被指数、最高温和有效太阳辐射是最优追氮量模型的主要驱动因子。田间验证试验中,整合本研究的产量预测与氮素监测模型构建间接型氮肥推荐策略,与基于

最优追氮量预测的直接型氮肥推荐策略、农户常规追氮量和区域专家推荐追氮量进行对比和效益评估。结果表明最优追氮法能在不减少产量和经济利润的前提下，动态调整肥料的投入，减少环境污染。通过多目标进化算法求解追氮量的合理性验证，证明间接型和直接型精准追氮策略都能在合理阈值范围内进行决策。

综上，本研究基于数据驱动的技术，贯通了基于产量预测与氮素监测的间接型追氮决策链条，创新性地提出了协同田块精准与区域优化的直接型最优追氮策略，通过两种策略的并行优化与对比评估，形成相辅相成的可持续性精确氮素管理体系。本研究为氮肥智能推荐算法的模型构建、模型解释与评估优化提供了新范式，为作物对环境的响应和适应性管理提供了新见解，为保障粮食安全和应对气候变化提供了新方案。

关键词： 冬小麦；产量预测；氮素营养监测；氮肥推荐算法；机器学习

WINTER WHEAT SMART NITROGEN RECOMMENDATION ALGORITHMS BASED ON MULTI- SOURCE DATA FUSION

ABSTRACT

Accurate nitrogen management is crucial for ensuring food security and achieving green agricultural development. In response to the lack of accuracy, practicality, and spatiotemporal universality of nitrogen recommendation algorithms, the lack of coordination between on-farm precision and regional optimization, and the neglect of balancing multi-objective benefits, this study focused on key models for winter wheat yield prediction, nitrogen monitoring, and fertilization decision-making, a technical framework has constructed for intelligent decision-making and evaluation of nitrogen recommendation for winter wheat based on multi-source information fusion, including indirect type (based on yield prediction and nitrogen monitoring) and direct type (based on nitrogen topdressing prediction). Mainly including:

(1) Firstly, based on historical field experimental data from multiple site-years, this study established a field-scale wheat yield prediction model at the jointing stage by integrating canopy spectra and meteorological data. By constructing 11 statistical and machine learning regression models, analyzing two feature aggregation intervals and two feature selection methods, the model performance of yield prediction was comprehensively evaluated. The results revealed that the ensemble learning model represented by the Random Forest (RF) algorithm obtained the highest model accuracy, and the nonlinear machine learning method significantly outperformed traditional linear regression. The RF-based feature importance analysis indicated that the normalized difference red edge index, average temperature, minimum temperature, and relative humidity contributed the most to yield prediction, particularly from the planting date to the jointing stage (in terms of meteorological features). The yield prediction performance of the seven machine learning methods was unaffected by the aggregation method and feature selection method. Therefore, it was recommended to use full growth period meteorological data aggregation and feature selection to balance model performance and on-farm management costs.

(2) Secondly, this study integrated time series information of the entire growth period

(canopy spectral data from different growth periods, meteorological data from planting to a specific sensing date), and established a concise winter wheat nitrogen estimation (including aboveground biomass, plant nitrogen concentration, plant nitrogen uptake, and nitrogen nutrient index) framework by integrating deep learning and evolutionary algorithm, thus provided efficient and intelligent solutions for crop precision management. In this study, two deep learning methods, Long Short-Term Memory (LSTM) and Deep Neural Network (DNN), were employed for modeling to extract the cumulative information of crop growth, with RF serving as the benchmark model for comparison. At the same time, multi-task learning was firstly introduced to estimate four nitrogen nutrition indicators simultaneously. Based on the global optimization ability of evolutionary algorithm, it was attempted to optimize hyperparameters, connection weight, and multi-task learning loss weight of DNN, respectively. In terms of results, RF and DNN have achieved high accuracy. However, the performance of LSTM and evolutionary algorithm were worth further investigation. Among them, the estimation accuracy of nitrogen nutrition index required to be explored further. Using the model interpretability framework, it was discovered that phenological drivers were crucial for nitrogen monitoring throughout the growth period, and water related features have a special contribution to estimating plant nitrogen concentration and nitrogen nutrition index.

(3) Finally, this study proposed the concept of the optimal topdressing nitrogen rate, which was coupled with on-farm precision and regional optimization. Multi-source information was fused to build a direct prediction model of the optimal topdressing nitrogen rate based on RF. The RF-based feature importance analysis showed that vegetation index, maximum temperature and effective solar radiation were the main driving factors of the optimal nitrogen rate model. In the field validation experiment, an indirect nitrogen recommendation strategy was constructed by integrating the yield prediction and nitrogen monitoring models of this study. The strategy was compared with the direct nitrogen fertilizer recommendation strategy based on the optimal nitrogen topdressing rate prediction, the farmer's conventional nitrogen application, and the regional optimal nitrogen rate recommended by experts, then each benefit was evaluated. The results indicated that the optimal topdressing nitrogen method can dynamically adjust fertilizer input and reduce environmental pollution without reducing yield and economic profits. The rationality verification of solving nitrogen topdressing rate through multi-objective evolutionary algorithm proved that both indirect and direct precision nitrogen application strategies can make decisions within a reasonable threshold.

In summary, this study was based on data-driven technology and connected the indirect nitrogen application decision-making chain based on yield prediction and nitrogen monitoring. It innovatively proposed a direct optimal nitrogen application strategy for collaborating on-farm precision and regional optimization. Through parallel optimization and comparative evaluation of the two strategies, a sustainable and precise nitrogen management system was produced that complemented each other. This study provided a new paradigm for the model construction, model interpretation, and evaluation optimization of nitrogen fertilizer intelligent recommendation algorithms, offered new insights for crop response to the environment and adaptive management, as well as new solutions for ensuring food security and addressing climate change.

KEY WORDS: winter wheat; yield prediction; nitrogen nutrition monitoring; nitrogen recommendation algorithm; machine learning

符号及缩略语的说明

英文缩写	英文全称	中文全称
30d-P	Before 30 days-Planting	播种前 30 天至播种期
A1/2	Aggregation 1/2	聚合 1/2
ABN	Actual base nitrogen rate	实际基肥量
AGB	Above ground biomass	地上部生物量
AGDD	Accumulated growing degree days	累积生长度日
AK	Available potassium	速效钾
AP	Available phosphorus	速效磷
AWDR	Abundant and well-distributed rainfall	降水均匀度
cEOTN	Close to Economical topdressing nitrogen rate	靠近经济最优追氮量比例
CI _{RE}	Red edge chlorophyll index	红边叶绿素指数
CNN	Convolution neural network	卷积神经网络
DAP	Days after planting	种植后天数
DNN	Deep neural network	深度神经网络
DT	Decision trees	决策树
EA	Evolutionary algorithm	进化算法
ENR	Elastic-net regression	弹性网络回归
EONR	Economical optimal nitrogen rate	经济最优施氮量
EOTN	Economical optimal topdressing nitrogen rate	经济最优追氮量
FNR	Farmer nitrogen rate	农户常规施氮量
GA	Genetic algorithm	遗传算法
GBDT	Gradient boosting decision tree	梯度增强决策树
ha	hectare	公顷
ISR	Inverse simple ratio	简单反比
kg	kilogram	千克
KNN	K-nearest neighbors	K 近邻
Lasso	Least absolute shrinkage and selection operator regression	套索回归
LR	Linear regression	线性回归
LSTM	Long short-term memory	长短期记忆神经网络
MDI	The mean decrease of impurity	平均减少不纯度
MLP	Multilayer perceptron	多层感知器
MTL	Multi-task learning	多任务学习
NDRE	Normalized difference red edge	归一化差异红边指数
NDVI	Normalized difference vegetation index	归一化差异植被指数
NFOA	Nitrogen optimization algorithm	氮肥优化算法
NNI	Nitrogen nutrition index	氮营养指数
OTN	Optimal topdressing nitrogen rate	最优追氮量

续表

英文缩写	英文全称	中文全称
PCCfs	Feature selection based on Pearson Correlation coefficient	基于皮尔逊相关系数的特征选择
PFP	Nitrogen Partical factor productivity	氮肥偏生产力
PNC	Plant nitrogen concentration	植株氮浓度
PNU	Plant nitrogen uptake	植株氮吸收量
PPT-sum	Total precipitation	总降水量
P-S	Planting-Stem elongation stage	播种至拔节期
R ²	The coefficient of determination	决定系数
RERVI	Red edge ratio vegetation	红边比值植被指数
RESAVI	Red edge soil adjusted vegetation index	红边土壤调节植被指数
RF	Random forest	随机森林
RFE	Recursive feature elimination	递归特征消除
RH-avg	Average relative humidity	平均相对湿度
RI	Response index	响应指数
RMSE	Root mean squared error	均方根误差
RONR	Regional optimal nitrogen rate	区域最优施氮量
RR	Ridge regression	岭回归
rRMSE	Relative root mean squared error	相对均方根误差
SDI	Shannon diversity index of precipitation evenness	香农多样性指数
S-F	Stem elongation stage-Flowering stage	拔节期至开花期
SHAP	SHapley Additive exPlanation	沙普利加法解释
SI	Sufficient index	充足指数
SOM	Soil organic matter	土壤有机质
SR-avg	Average solar radiation	平均太阳辐射
SR-sum	Total solar radiation	总太阳辐射
SVR	Support vector regression	支持向量回归
t	ton	吨
TBN	Theoretical base nitrogen rate	理论基肥量
T-max-avg	Average maximum temperature	最高温度平均值
T-max-max	Maximum maximum temperature	最高温度最大值
T-min-avg	Average minimum temperature	最低温度平均值
T-min-min	Minimum minimum temperature	最低温度最小值
TN	Total nitrogen	全氮
XGBoost	eXtreme gradient boosted	极端梯度提升
YONR	Optimal nitrogen rate for yield	产量最优施氮量
YOTN	Optimal topdressing nitrogen rate for yield	产量最优追氮量
YP	Yield prediction	产量预测法

第一章 文献综述

摘要：精确氮素管理技术对于保障粮食安全、提高肥料利用率、节约经济成本和减少环境污染具有重要意义。本章从课题研究背景、数据来源、建模方法等方面概述了精确氮素管理的国内外研究现状及存在的科学问题，并系统分析了精确氮素管理在我国的应用前景及面临的挑战，有助于加深对精确农业的见解，促进精准施肥技术的推广应用，赋能农业绿色发展。

关键词：冬小麦；产量预测；氮素监测；氮肥推荐；精确农业

1 研究背景

小麦(*Triticum aestivum* L.)是我国主要的粮食作物之一，对保障粮食供给、满足食品加工需求、维持粮价稳定具有重要意义。2021 年全国小麦播种面积为 3.53 亿亩(占粮食总面积的 20.0%)，总产 13694 万吨(占粮食总产的 20.1%)(数据来源于国家统计局)。1981-2017 年，我国小麦产量以平均每年 3.5%的速率增长，其中化肥、品种和灌溉为三大驱动因素，化肥的贡献率超过 50%(Liu et al., 2021a)。1982-2017 年，中国的粮食产量增加了 74%，而化肥使用同期增长三倍(Cui and Shoemaker, 2018)。2017 年，全国农用化肥施用量达 5859 万吨，氮肥和复合肥的施用量分别为 2221 和 2220 万吨。然而水稻、小麦和玉米三大粮食作物的氮肥利用率只有 28%左右,远低于国际水平(张福锁 等, 2008)。以上数据表明中国的粮食增长依赖于不合理的资源投入，主要是过量的氮肥投入。一方面，过量施氮增加了生产成本和逆境胁迫风险(如贪青晚熟、倒伏)，降低经济效益。另一方面，大量氮素损失到农田环境中，会造成空气污染(PM_{2.5}、臭氧)、水污染(富营养化、硝酸盐淋洗)、土壤酸化(H⁺释放)、生物多样性丧失(氮沉降)和全球变暖(N₂O 排放)等一系列环境和气候问题(Guo et al., 2020)。因此，如何科学合理进行氮素资源管理与决策，助力实现小麦乃至粮食作物生产的绿色高产高效，是亟待解决的实际问题。

值得注意的是，传统的粗放式、经验式田间管理措施正面临着新的挑战。随着我国人口老龄化进程加快、城镇化推进以及年轻人劳动力就业观念的改变，农业劳动力日益短缺，农村土地大规模流转，“谁来种地、如何种地”已成为严峻的社会问题(刘成良 等, 2020)。与此同时，农业机械和智能装备技术快速发展，互联网、物联网、大数据、人工智能、云计算等新一代信息技术在农业领域的加速渗透和广泛应用，现代农业必然朝着机械化、信息化、智能化的方向发展，农业智能革命已经到来(赵春江，

2019)。在这样的背景下,精确农业可以较好地协调农业生产中的挑战和机遇,在提高农业生产效率和资源利用效率、协调经济效益和环境可持续性上具有良好的发展前景(赵春江, 2010)。近年来,我国先后发布的《数字乡村发展战略纲要》、《乡村振兴战略规划》、《数字农业农村发展规划》和《中共中央关于制定国民经济和社会发展第十四个五年规划和 2035 年远景目标的建议》等一系列文件更是为智慧农业发展提供了战略方向和政策保障。综上所述,以智慧农业的蓬勃发展为契机,探索小麦精确氮素管理的“智慧”模式,是实现小麦增产稳产与资源高效利用的有效途径。

精确氮素管理是精确农业技术中的重要应用。精确氮素管理技术是依据土壤养分状况、气候条件、作物需肥规律和目标产量,结合作物实时生长信息的监测与诊断,实现不同时空尺度下肥料的变量投入,达到提高化肥利用率、最大限度地利用土地资源、以合理的肥料投入量实现最高产量和最佳经济效益、减少环境污染的目的(陈桂芬 等, 2013)。然而作物目标产量或需氮量会受到土壤特性、气候条件、农户管理措施、作物品种遗传特性、病虫害胁迫等多重因素的影响,具有复杂的非线性关系(Qin et al., 2018; van Klompenburg et al., 2020)。随着遥感技术的发展,卫星、航空和近地面平台为植被、土壤、气候的信息获取提供了丰富的遥感数据(Sishodia et al., 2020)。大量田间氮素管理试验也能提供关于产量、氮肥响应等宝贵的数据(Bullock et al., 2019)。如何从大量农业数据中挖掘有价值的信息,解析作物-环境-施氮量之间的复杂关系,融合多源信息建立一个具有时空普适性的模型,真正实现当季氮素管理的动态、精准、智能仍然十分具有挑战性(Shi et al., 2020)。

根据精准农业“土壤-作物系统的变异性评估—变异管理策略—效率和效益评估”的研究框架,小麦氮素精确管理可以分为氮素监测与诊断、氮肥推荐/管理分区(管理决策)、可持续性评价三个主要环节(Diacono et al., 2013)。建立准确、普适的氮素营养监测与诊断模型、产量预测模型、氮肥推荐模型等“智慧”监测与决策模型是精确管理的核心,可从不同的策略为施肥决策提供支持。农业复杂系统具有很强的非线性、随机性和动态特征。作为人工智能的分支,机器学习算法(如人工神经网络、支持向量机、集成学习和深度学习等)能够处理大量的数据输入,解决非线性问题,因此机器学习建模往往能够获得较高的准确度与鲁棒性,特别适用于解决农业系统的复杂决策问题(Chlingaryan et al., 2018)。在作物生产管理上,机器学习已经在产量预测、病害识别、杂草识别、作物识别以及品质预测上有广泛应用(Benos et al., 2021)。使用机器学习方法融合多源信息(在机器学习领域,变量也称为特征),综合考虑作物自身生长发育情况以及作物生长环境中的气候、土壤、栽培措施因子构建具有时空普适性的决策模型,并尝试挖掘与解析隐藏在信息中的农学规律,是精确氮素管理的前沿方向之一。

华北平原和长江中下游平原地区是我国重要的冬小麦主产区,该区域是实施农田

精确管理技术的理想区域与重点区域。以江苏省为例，一方面农业生产面临着作物争地、劳动力成本高、环境保护压力大等诸多突出矛盾，一方面则具有发展智慧农业所需的经济、人才资源和技术优势。然而该农业生产区域幅员辽阔，依据不同的种植品种、气候土壤条件和栽培技术又可划分为不同的亚区。在不同地理生态条件下构建的氮素管理决策模型会存在特异性，导致区域范围内精确管理技术的推广应用难度大幅增加，迫切需要一个准确、普适、方便使用的模型与系统框架，进而提升精确管理的智慧化水平。综合考虑数据量、数据源、时空尺度、管理成本、效益回报等因素的影响，构建精准普适、用户友好的精准氮素管理策略，对冬小麦的绿色高效可持续生产至关重要。

2 作物产量预测研究进展

作物产量预测对保障国家粮食安全具有重要的意义。从国家和地区的需求来看，大尺度范围内的粮食产量提前预测、准确预测有助于为农业生产的宏观决策提供数据支持(比如政策干预、农产品调度、进出口策略)；发现不同区域间的产量差异，了解供需水平，进行耕作制度、农业区划的调整；针对产量的实时评估进行相关农作技术的推广。从市场的需求来看，作物产量预测为稳定粮食市场价格、农业灾害经济损失的量化、农业保险的理赔工作提供依据。从作物生产过程的栽培管理来看，作物产量的实时动态预测，是作物的精准管理(施肥、灌溉、施药)不可或缺的指标，基于产量信息生成管理处方，实现资源投入的数字化调控，可达到节本增效的目的。

鉴于作物产量预测的重要性，国内外学者对粮食作物产量预测的理论、模型和应用进行了大量研究与探索。从数据源来看，作物产量作为一个综合性指标，是基因(G)、环境(E)、管理因素(M)及其交互作用($G \times E \times M$)的结果，自然因素(植株、气象、土壤)和社会经济因素(土地、资本、劳动力、技术)均可用于产量预测。对于栽培管理而言，如何快速准确无损地预测产量是关注的重点。遥感技术可以实时、无损、广泛地获取高精度、高分辨率的地表信息，反演作物关键生长参数，因此特别适合用于作物产量的高效和准确预测。卫星(MODIS, Sentinel-2, Landsat-8 等)、无人机(高光谱、多光谱、RGB 影像等)、冠层(多光谱、LiDAR 等)等手段均可获取作物植被指数等实时生长信息，成为产量预测可靠的数据源。气象、土壤环境等信息则会显著影响作物产量的时空变化，栽培和育种等科技手段会对中长期的作物产量增长趋势有显著影响。纵观前人在作物产量预测上的研究，既有单纯地使用遥感数据(Ji et al., 2022)、气象数据(Lin et al., 2020)、土壤数据(Burdett and Wellen, 2022)对作物产量进行预测，也有通过两两组合或多源信息融合进行预测，如遥感+气象(Tian et al., 2021)，遥感+土壤(Pantazi et

al., 2016), 气象+土壤(Crane-Droesch, 2018), 以及遥感+气象+土壤(Wang et al., 2020b)。也有部分研究将管理措施(Shahhosseini et al., 2021)、作物品种或基因信息(Khaki and Wang, 2019)、社会经济信息(Cao et al., 2020)纳入特征范围, 或是将遥感信息与作物模型信息耦合(Zhao et al., 2020b)。不同研究使用的遥感信息、气象和土壤指标等不尽相同, 但总体而言, 多源信息融合已成为新的发展趋势。当然, 在多源信息融合的基础上, 不同来源的特征对模型性能的影响是不一致的, 在不同预测尺度上(如田块尺度或县级尺度)也有不同的合适数据。因此根据具体问题选择数据源, 设计关键指标, 对产量预测是十分重要的。

从统计分析方法来看, 经验模型(时间序列分析法、灰色系统理论、回归分析法和机器学习方法等)和作物生长模型均可用于作物产量预测(Basso et al., 2019)。作物生长模型(如 DASST, APSIM 模型)具有较强的机理性和预测能力, 但大量复杂的环境与管理变量输入以及参数本地化的要求会大大限制其在小农户系统的推广应用。尽管基于机器学习的模型缺乏机理性, 但凭借其强大的数据驱动能力, 机器学习方法在作物产量预测上的应用广泛, 许多学者利用机器学习方法建立了融合多年多点光谱、环境或管理信息的作物产量预测模型(Kang et al., 2020; Maya Gopal and Bhargavi, 2019; Zhang et al., 2020)。其中, 随机森林(Random Forest, RF)、卷积神经网络(Convolution neural network, CNN)、长短期记忆神经网络(Long short-term memory, LSTM)等机器学习及深度学习已经成为常见的建模技术, 大量的研究对主流算法在产量预测中进行分析对比(Wang et al., 2020d)、组合(Sun et al., 2019)、优化(Tian et al., 2020)等, 或是通过作物模型与机器学习结合互补提升性能(Maestrini et al., 2022)。综合来说, 无论是从数据源或统计分析方法的角度进行突破, 都可以提高产量预测模型的性能, 且可以根据问题的需求灵活变通, 相辅相成, 选择最优的解决方案。

产量预测时期也是一个重要问题, 提早准确预测作物产量可以为管理决策预留充分的时间。最佳的产量预测时期是作物生殖生长后期(Corti et al., 2018), 然而对追氮推荐而言, 需要在拔节期追肥前准确预测作物产量, 进一步也根据产量信息计算施肥量或构建管理处方图。在以往基于机器学习的产量预测模型中, 特征聚合缺乏与关键生育期节点相匹配的时间间隔, 且往往使用全生育期的数据(Han et al., 2020)。因此在特征的处理上, 考虑时间窗口和时间跨度是值得关注的问题, 比如能否使用更少的特征, 在关键的时间节点准确预测产量, 以及衡量使用不同生育期的特征对模型准确度的影响。Han 等(2020)和 Cao 等(2020)的研究发现使用全生育期的信息构建小麦产量预测模型能获得最高的准确度。Li 等(2019)的研究发现使用月度时间间隔聚合特征来构建玉米的产量预测模型, 比使用全生育期聚合表现更佳。Li 等(2021a)使用关键生育期节点划分特征的时间间隔, 构建小麦、水稻和玉米的产量预测模型, 结果表明融合所有

时间段的模型表现最好。以上研究表明,使用数量更多、更细化的特征可能会获得更高的模型准确度。但在实际应用中,需要考虑计算复杂度、信息获取的难度、信息的准确度、特征冗余、模型过拟合等问题。因此进行必要的特征选择,减少冗余和高度自相关的特征,可以降低计算开销,提升模型的表现与可解释性(Elavarasan et al., 2020; Gopal Maya and Bhargavi, 2019),平衡实际应用中的便利性与准确度。以小麦的拔节期的产量预测为例,由于追肥后土壤状况和天气变化会对氮肥损失和植株对氮肥的吸收有较大影响,如果这类信息具有较大的不确定性,则会影响产量预测的准确度;如果或者这类信息获取需要耗费大量人力和时间成本,则会耽误施肥的最佳时间和管理效率。

如何在众多特征中识别重要的贡献因子,是数据挖掘的关键目标。在机器学习领域,衡量多源信息融合中各种特征对目标值的贡献,常见的一种方法是比较不同特征组合方式的模型性能,另一种方法是通过模型的可解释性进行分析(如计算基于集成学习方法特征重要性)。以小麦的产量预测为例,Cao 等(2020)通过不同特征组合的模型性能比较,发现气候数据比植被指数贡献更大,而返青期-抽穗期的植被指数比生长前、后期的植被指数贡献更大。Han 等(2020)则根据随机森林的相对重要性发现增强植被指数、最低温和降水量等因子对小麦产量预测最为重要。Tian 等(2021)利用带有注意力机制的 LSTM 模型预测小麦产量,发现抽穗-灌浆期的叶面积指数尤为重要,并证明注意力机制在提取关键特征和识别关键生育期、提高模型可解释性的作用。此外,还有灰色关联分析(杨玮 等,2013)、主成分分析(李楠楠 等,2021)等方法解析不同因子的贡献度。综合来看,基于不同的过程或视角进行解释,都能为作物-环境-管理及其交互形成新的见解,挖掘新的知识。在全球气候变暖、太阳辐射变暗、极端气象灾害事件频发的大背景下,量化遥感、天气或土壤因素对产量变异的限制或贡献,可以提高模型的可解释性,进一步为隐藏在数据背后的生理生态规律挖掘与生产管理措施的适应性调整提供启示,共建“气候智慧型”农业。

3 作物氮素营养监测与诊断研究进展

氮素是植物体内蛋白质、核酸、叶绿素等重要化合物的组成元素,素有“生命元素”之称。作物缺氮会出现植株矮小、叶片黄化等症状,而作物氮素过多则会导致贪青晚熟、抗病抗倒伏能力下降等。植物体内存在氮素的吸收转运、同化、分配等关键生理代谢过程,并受到基因、环境、管理因素的密切作用。因此氮素营养的监测与诊断对于实时了解作物生长状态、指导精准施肥决策至关重要。

与产量预测不同,由于氮素营养监测与精准管理密切相关,因此研究尺度一般为

冠层、田块或农场尺度。传统的作物氮素监测方法是田间植物组织采样和实验室化学分析(凯式定氮法、流动分析法),具有破坏性,且试验时间较长、测试成本较高。随着高精度、高通量的植物表型获取技术成为植物表型研究的新兴热点方向,快速准确地评估氮素营养状态成为重要挑战。利用近地面遥感技术对作物氮素进行原位无损测定,可以方便快速地获取作物信息,因此具有十分明显的优势。国内外的研究人员已经研制出多种应用于作物氮素检测的商用传感器,主要有叶绿素传感器(吸收型和荧光型)、反射光传感器(被动式和主动式)、类黄酮传感器和图像传感器几种类型(Padilla et al., 2018)。Li 等(2020)综述了这些传感器在作物氮素诊断的进展与挑战。作物冠层传感器(表 1-1)属于反射光传感器,在科研和生产中应用广泛。作物冠层传感器的测量范围在冠层尺度,因此具有比一般卫星影像更高的空间分辨率,较好地反映田块内的空间变异。同时作物冠层传感器可以直接返回各测量波段的反射率或植被指数,不需要进行复杂的影像/图像预处理。主动式作物传感器(Active canopy sensor, ACS)因自带光源,能够克服云雨天气的影响,在作物关键生育期进行全天候快速测定,适合用于构建田块尺度的实时精准氮素管理策略(Zhang et al., 2019b)。

表 1-1 典型的作物冠层传感器

Table 1-1 Typical crop canopy sensors				
设备名称 Device name	生产商 Manufacturer	波长/nm Wave length	光源 Light source	测量尺度 Measurement scale
GreenSeeker	Trimble Inc. (Sunnyvale, CA, USA)	650, 770	主动	冠层
GreenSeeker- Handheld	Trimble Inc. (Sunnyvale, CA, USA)	660, 780	主动	冠层
N-sensor ALS	Yara International (Oslo, Norway)	670, 730, 760	主动	冠层
Crop Circle ACS 430	Holland Scientific (Lincoln, NE, USA)	670, 730, 780	主动	冠层
Crop Circle ACS 470	Holland Scientific (Lincoln, NE, USA)	450, 550, 650 670, 730, 760	主动	冠层
RapidScan CS-45	Holland Scientific (Lincoln, NE, USA)	670, 730, 780	主动	冠层
CropSpec	Topcon Positioning Systems, Inc. (Livermore, CA, USA)	730-740, 800-810	被动	冠层
CGMD302	国家信息农业工程技术中心	730, 815	主动	冠层

作物冠层传感器获取冠层反射光谱的工作原理可用朗伯余弦定律解释(Shi et al., 2020)。作物表型信息定量反演的依据是作物特性(冠层几何结构、叶片生化组分、含

水量、细胞结构等)与冠层光谱反射特征(主要是可见光和近红外波段)的内在联系(赵春江, 2014)。常用的氮素营养状况监测指标有氮营养指数、植株氮浓度和植株氮积累量等。在小麦上, Aranguren 等(2020)建立了基于 RapidScan CS-45 的氮营养指数预测模型。Cao 等(2018)比较了 Crop Circle ACS-470 和 Crop Circle ACS-430 在不同测量高度与不同生育时期估测冬小麦氮素营养状况(植株氮吸收与氮营养指数)的表现。Zhang 等(2019b)建立了基于 GreenSeeker 的冬小麦氮素营养监测模型(叶片氮浓度和叶片氮积累量)。然而上述研究都是基于单一的植被指数与氮素营养指标进行建模, 且并未考虑不同年际间或不同生态点间环境变化对模型泛化能力的影响。

与产量预测类似, 氮素营养监测与诊断同样可以通过多源信息融合与机器学习建模的策略提高精度。例如, Cummings 等(2021)使用 Crop Circle 传感系统收集植被指数、冠气温差和光合有效辐射信息, 利用 XGBoost (eXtreme gradient boosted)算法融合传感信息与管理措施数据构建玉米的氮素诊断模型, 结果表明融合所有变量的 XGBoost 模型与简单回归相比, 在预测植株氮浓度、植株氮吸收和氮营养指数上表现最好。Wang 等(2021b)使用 Lasso 回归和随机森林融合植被指数(基于 GreenSeeker 传感器)、土壤、天气和管理数据, 构建玉米的氮营养指数预测模型; 与使用单一植被指数的简单回归相比, 两种机器学习方法显著提高了模型的准确度。以上研究充分利用了机器学习算法的优势, 挖掘了多源多年信息融合构建普适氮营养诊断模型的潜力。Chlingaryan 等(2018)综述了机器学习算法在基于遥感的产量预测与氮素营养状态估测上的研究进展, 并指出了结合不同的时空分辨率的传感信息、不同的机器学习算法对于氮素管理决策的重要性。综上可见, 为了提升基于作物冠层传感器的氮素营养监测与诊断方法的准确性和普适性, 不能停留在评价不同传感器和不同植被指数的层面, 而应该探究融合多源数据、多年多点数据、多种建模方法的可行性。

随着技术的发展, 氮素监测朝着快速化、自动化、智能化的方向发展。一方面, 农业无人机、高分辨率卫星等遥感技术被应用到作物氮素监测、乃至作物精准表型的研究上来, 提升信息获取的效率。例如, 基于无人机的多光谱影像(Jiang et al., 2022)、RGB 图像(Xu et al., 2021)、高光谱影像(Wang et al., 2021a)已经成功运用在作物的氮素监测上。另一方面, 由于作物生长是实时变化的, 因此如何捕捉氮素状态在全生育期的变化规律, 实现氮素状态的动态估测是十分关键的。Zhao 等(2022)指出, 光谱信息不足以捕捉冬小麦氮积累的过程, 并探讨了是否有必要加入物候信息(如生育期)来提高全生育期估测的精度。Xu 等(2021)则提出了使用 LSTM 来自动捕捉作物生长时间变化信息的思路。综合来说, 不同生育期、不同地点、不同年份的作物氮素状态的差异是巨大的, 如何建立一个高效简便的模型值得进一步探索。

4 作物氮肥推荐算法研究进展

氮素优化管理一直是学者们热切关注的科学问题，因为它涉及到粮食安全、人类健康、环境保护与气候变化等重要命题。对精确氮素管理而言，如何从氮素监测的“信息感知”阶段走向氮肥决策的“智慧决策”阶段，如何让技术落地取得成效，是当前研究的重点。氮肥推荐算法也是精确氮素管理的核心内容之一，因为获取的农业信息数据必须转化为生产上能实际利用的工具，才能真正发挥数据的价值。

氮肥推荐算法的目标是准确估计土壤供氮和作物植株需氮量之间的差距，然后计算弥补差距所需的氮肥施用量。根据数据来源，现行的氮肥推荐算法大致可以分为基于土壤/农学测试的推荐算法、基于肥料效应函数的区域优化推荐算法、基于作物生长模型的氮肥推荐以及基于遥感/传感器的氮肥推荐四类。Guerrero 等(2021)总结了基于土壤氮传感测试的氮肥推荐算法研究进展，特别强调结合土壤数据、气象数据、作物数据对于变量施肥的重要性。而在基于作物模型的推荐施肥研究中，研究者们开始结合作物模型、近端传感/遥感数据、气象数据进行推荐(Gobbo et al., 2022; Jin et al., 2017; Morari et al., 2020)，或是基于作物模型生成的数据拟合肥料效益函数，弥补田间试验数据量的不足(Mandrini et al., 2021; Sela et al., 2018)。从建模方法来看，研究者们开始大量使用智能算法，如机器学习(Ransom et al., 2019)、进化计算(Ahmed et al., 2021)、模糊逻辑(Tremblay et al., 2010)来构建或优化算法。可见不同氮肥推荐算法之间的界限变得模糊，不同的技术和策略纷纷涌现。

美国的 Dr. Kitchen 课题组注意到以往的氮肥推荐算法研究多局限于某一区域，缺少在广泛的土壤和气候条件下进行统一试验比较算法优劣的研究，因此该课题组联合美国玉米带范围内的八所大学、美国农业部和杜邦先锋公司，共同开展一项在不同土壤和环境条件下标准化评估和提升玉米氮肥推荐算法的项目(Kitchen et al., 2017)。试验为期三年(2014-2016)，试验地点分布在美国中西部玉米带 49 个研究点，研究人员做了大量关于作物、土壤和气象要素的测定。Ransom 等(2019)系统评估了六大类氮肥推荐算法的表现，结果表明不同生态区域间，没有一种氮肥推荐算法是普遍可靠的，说明算法需要进一步优化来更好地面向区域水平上的推广应用。Bean 等(2018a)专门评估了三种基于作物冠层传感器的经典氮肥推荐算法(表 1-2)的表现，类似地，算法的普适性较差，在特定条件下开发的算法，至少在没有修改的情况下，在开发区域之外的区域表现不佳。三种基于作物冠层传感器的算法中，ISR 算法较少考虑土壤和气象的影响。为此 Bean 等(2018b)进一步利用多元线性回归方法融合土壤(土壤质地、容重、有机质含量等)和气象(温度、降水量等)信息优化 ISR 算法。Ransom 等(2019)则比较了八种统计和机器学习算法融合土壤和气象信息在三种氮肥决策方法中的表现

(农户施用量、目标产量法、SI 算法); 结果表明机器学习算法的表现各有优劣, 尽管性能提升效果不是很明显, 但使用机器学习方法优化氮肥推荐算法具有很大的潜力。为此 Ransom 等(2021)进一步使用弹性网络回归和决策树算法融合土壤与气象信息, 对 21 个氮肥推荐算法(包括 SI 算法)进行优化提升。该合作项目的一系列工作证明氮肥推荐算法的准确性和普适性在大范围应用上有很大的提升空间。

表 1-2 基于作物冠层传感器的氮肥推荐算法(Bea et al., 2018a)

Table 1-2 Nitrogen recommendation algorithms based on crop canopy sensors

算法 Algorithms	公式 Formula
ISR 算法 University of Missouri Algorithm	$ISR = \frac{R}{NIR}; \quad (\text{简单反比; inverse simple ratio})$ $NRec = (280 \text{ kg N ha}^{-1} \times \frac{ISR_{\text{target}}}{ISR_{\text{reference}}}) - 224 \text{ kg N ha}^{-1}$
SI 算法 Holland-Schepers Algorithm	$NDVI = \frac{(NIR-R)}{(NIR+R)}; NDRE = \frac{(NIR-RE)}{(NIR+RE)};$ $SI_{NDVI} = \frac{NDVI_{\text{target}}}{NDVI_{\text{reference}}}; SI_{NDRE} = \frac{NDRE_{\text{target}}}{NDRE_{\text{reference}}};$ (充足指数; sufficiency index) $NRec = [MZ_i \times (N_{\text{OPT}} - \sum N_{\text{CRD}} + N_{\text{COMP}})] \times \sqrt{\frac{1-SI}{\Delta SI}}$
RI 算法/氮肥优化算法 Nitrogen fertilization optimization algorithm, NFOA Oklahoma State University Algorithm	$RI = (\frac{NDVI_{\text{reference}}}{NDVI_{\text{target}}}) \times 1.64 - 0.53;$ (响应指数; response index) $GDD = \frac{T_{\text{max}} + T_{\text{min}}}{2} - T_{\text{Base}}; \quad (\text{growing degree days})$ $INSEY = \frac{NDVI}{\sum GDD}; \quad (\text{in-season estimated yield})$ $YP_0 = 1.291^{(INSEY \times 2649.9)}; \quad (\text{without N fertilizer})$ $YP_N = YP_0 \times RI; \quad (\text{with N fertilize})$ $NRec = \frac{(YP_N - YP_0) \times 56 \times \text{grainN}}{NUE}.$

相关参数说明:

R: 红光波段; RE: 红边波段; NIR: 近红外波段; NRec: 氮肥推荐量; MZ_i : 管理或土壤样品标量/调整; N_{OPT} : 管理者施用的最大氮肥量或预期经济最优施氮量; N_{CRD} : 传感器测试前施用的肥料、有机肥中的氮、土壤水和灌溉水的硝酸盐、或前茬豆科作物固定的氮; N_{COMP} : 满足土壤限制条件所需的超过 N_{OPT} 的量; ΔSI : SI 等于 1 和响应曲线与 y 轴相交点之间的差值; grainN: 籽粒氮浓度; NUE: 氮肥利用率

Description of relevant parameters:

R: Red light band; RE: Red edge band; NIR: Near infrared band; NRec: Recommended amount of nitrogen fertilizer; MZ_i: Management or soil sample scaling/adjustment; N_{OPT}: The maximum rate of nitrogen fertilizer applied by the manager or the expected economic optimal nitrogen application rate; N_{CRD}: Fertilizer applied before sensor testing, nitrogen in organic fertilizer, nitrate in soil water and irrigation water, or nitrogen fixed by previous leguminous crops; N_{COMP}: The amount of excess N_{OPT} required to meet soil limitations; Δ SI: SI equals 1 and the difference between the intersection point of the response curve and the y-axis; grainN: Grain nitrogen concentration; NUE: Nitrogen use efficiency.

除了在已有氮肥推荐算法的基础上进行优化,也可以融合多源信息预测最优施氮量,构建数据驱动的氮肥推荐算法(Colaço et al., 2021)。例如,Qin 等(2018)使用四种统计和机器学习方法融合管理、气象与土壤信息,预测玉米的经济最优施氮量。Lawes 等(2019)使用随机森林算法融合历史产量、作物氮素和土壤信息预测玉米的经济最优施氮量。除了直接预测最优施氮量构建模型,也可以通过预测作物氮素营养状况或产量,间接指导变量施肥。例如,Iatrou 等(2021)使用四种机器学习方法融合光谱、土壤和管理信息预测水稻产量,并根据肥料效应函数设置施肥处方。Wang 等(2021b)使用随机森林算法融合冠层光谱、天气、土壤和管理措施预测产量,再根据肥料效应函数确定玉米的最优施氮量。以上研究的共同点都是利用多年多点的田间实验数据,构建当季的追肥推荐策略。在田块尺度上最优施氮量与产量最大的不同,是最优施氮量在一个生态点/试验点是一个相同的理论值,而产量在田块内存在空间变异。因此使用直接法预测最优施氮量,主要是为了挖掘不同年份间、不同地点间的环境变异,再根据推荐量与最优施氮量的差距调整实际施氮量,即“少增多减”;而使用间接法推荐施肥,则可根据目标产量精准调整实际施氮量,即“低减高增”。Wang 等(2020c)的研究发现,在产量限制因子为水分而不是养分的地方,在土壤肥沃的地方的施用更多的氮肥并不能实质性提高作物产量。可见综合考虑多源信息,避免单一的氮肥管理措施,实现氮肥的动态、灵活调整是科学的且有必要的。

在冬小麦氮肥推荐上,Cao 等(2017b)建立了一种基于 Crop Circle ACS-470 的 NFOA 算法;Ji 等(2021)提出了一种基于无人机估测地上部生物量的推荐算法;Chen 等(2019)建立了一种基于无人机遥感的田块尺度和村级尺度的推荐施氮算法。这些研究都是在 NFOA 算法(表 1-2)的框架下进行的优化和本地化,具有较好的农学机理性,但普遍缺乏多年多点数据的验证,且未充分考虑天气和土壤信息的影响。综上可见,整合多源多年多点数据,建立一种基于我国冬小麦主产区的氮肥智能推荐算法尚缺乏研究与验证。

精确氮素管理到底能不能带来真正的经济和生态效益,是需要考虑的实际问题。以作物冠层传感器为例,Cao 等(2017b)建立了一种华北平原地区的冬小麦精准氮素管理策略,三种精确氮素管理方案与农户管理措施相比,能够在不损失产量的前提下,将氮肥偏生产力平均提高 61~67%。Zhou 等(2017)建立了一种基于 Crop Circle 传感器的冬小麦的氮素精确管理策略,与农户常规管理措施相比,氮肥偏生产力提高了 29%。Aula 等(2020)综述了 26 项基于作物冠层传感器的冬小麦氮素精确管理研究,发现氮肥利用率平均为 42%,与农户传统管理方法相比提升了 10.4%,同时节省了 53(±16) kg/ha 氮肥。Jovarauskas 等(2021)通过五年的田间试验精确量化了基于传感器的变量施肥技术的环境效益,与传统氮肥管理相比,变量施肥可以减少 12.3%的间接能量投入和 9.4%的温室气体排放。可见,精确氮素管理的效益主要在于减少化肥投入和提高氮肥利用率,从而减少生产成本和氮排放对环境的污染,但增产效益有限。在实际生产中,减少化肥投入所节省的成本可能很容易被其他支出抵消,对环境保护的贡献则较难定量评估(如量化 N_2O 排放)和获得经济回报,农民采用精确管理措施的意愿会因此削弱,这是精确农业推广的障碍。综上所述,进一步优化作物生长监测和推荐算法,挖掘提高氮肥利用率的潜力,量化与权衡精确氮素管理的经济和环境效益,才能提高精确氮素管理的可持续性。

有学者认为由于气候和农田管理措施的不可预见性和随机性,即使在一个较均匀的田块上,施肥也无法“精准”,也不需要所谓的“精准”,仅需要将施氮量控制在合理范围(巨晓棠,张翀,2020)。对此,笔者更认同何山等(2017)提出的观点:针对田间养分精确管理的痛点(如重研究、轻应用、农户体验差等),提出“基准+精准”模式的田间养分管理方案,即结合数据挖掘技术对现有数据进行综合分析,更新制定当季作物养分管理“基准”施肥方案;以无损诊断作为技术支撑,通过机器学习融合特征参数来建立营养诊断模型,进而实现对田间“基准”施肥方案特别是追肥施用的“精准”修正。因此,精确氮素管理方案需要注意区域优化与田块精准调整的协同。

为了推进智慧农业技术的发展和应用,需要实施智慧农业关键核心技术攻关,建立差异化的智慧农业补贴机制,统筹智慧农业与数字乡村发展,培养应用型人才队伍(赵春江 等,2021)。因此建立可持续性的精确氮素管理策略,不是单一学科能解决的问题,更需要加强多学科的交叉融合。借力大数据、物联网、云计算、人工智能等前沿信息技术,在作物传感、土壤传感、作物模型、田间作业装备、决策支持系统、经济和环境效益评估、推广示范应用等多方面共同推进,才能真正取得成效。

5 待研问题的提出

前人对作物产量预测、作物氮素营养监测和诊断、作物氮肥推荐算法三大方面都做了大量而系统的研究,围绕不同作物、不同遥感平台或传感器、不同地区、不同方法等构建了相应的数学模型,为精确氮素管理提供了坚实的理论基础和技术支撑。然而对田块尺度的冬小麦氮素精确管理而言,已有研究缺乏多源多年多点信息的融合,这意味着模型的准确性和普适性有进一步提高的空间,以适应大范围推广应用中的动态、精准调控,更好地应对来自气候变化的挑战。提高作物产量预测与氮素营养监测的准确性,可以更好地指导间接施肥决策;构建基于数据驱动的直接型氮肥推荐算法,有望突破传统氮肥推荐的思路,提升施肥决策的准确性和普适性。同时,已有研究主要聚焦于提升模型的表现,忽略决策场景的多目标需求,缺少区域优化与田块精准的协同策略,缺乏对模型的解释与知识发现。

6 研究思路与技术路线

6.1 研究思路

本研究遵循的整体思路是数据整合-建模分析-知识发现,最终形成从传感器到知识的良性循环,以多学科交叉的视角为精确氮肥管理决策提供智慧化、绿色化的解决方案。本研究首先是收集整理氮肥梯度试验中多年多点多生育期的冠层光谱数据,对应的气象数据以及农学数据。然后探索合适的数据驱动策略以构建准确度高且泛化能力强的冬小麦生长监测模型与氮肥推荐算法,实现监测诊断-决策链条的贯通,指导精准施肥决策。与此同时结合模型的可解释性从数据中挖掘知识,为作物对环境的响应和适应性管理提供见解。在此基础上,利用构建的生长监测模型与氮肥推荐算法于2022年冬小麦拔节期进行多点实地验证试验评估精准施肥效果。具体包括以下内容:

(1)构建基于多源信息融合的冬小麦生长监测模型。为了提高冬小麦生长监测的准确性与普适性,本研究通过两种策略提升模型表现:一是选择最佳的监测模型;而是进行多源信息融合。因此本研究分别比较了不同的特征选择方法、机器学习回归算法对监测结果的影响。其一是构建冠层光谱与天气数据融合的冬小麦田块尺度产量预测模型,弥补县级尺度模型的不足,为拔节期实时精准施肥提供产量预测信息。其二是构建冬小麦氮素监测模型,搭建深度学习与进化算法结合的框架,实现全生育期和多目标的作物氮素营养无损监测与诊断。相关模型为间接型追氮决策(产量预测法)提供支撑。

(2)构建基于多源信息融合的冬小麦追氮推荐算法。为了综合考虑作物实时生长状

态、作物生长环境以及社会经济效益，在遵守养分平衡原理的基础上打破传统氮肥推荐算法的思路，本研究探究基于多源信息融合的数据驱动型冬小麦追氮算法的可行性。首先是通过肥料效应函数确定特定地点特定年份的经济最优/产量最优施氮量，然后通过拔节期植株吸氮量确定作物的理论基肥量，进而确定能体现田块内空间变异的经济最优/产量最优追氮量。在此基础上，通过机器学习算法与多源数据融合对最优追氮量进行一步直接预测，实现田块尺度的氮肥精准动态推荐。

(3)验证冬小麦精确追氮策略的可持续性。本研究结合前期最优的冬小麦生长监测以及追氮算法的模型，于 2022 年小麦季拔节期进行江苏省内多点的验证试验与经济环境效益分析。通过比较农户传统施氮量、区域专家推荐施氮量、产量预测法以及最优追氮量法四种不同的追肥调控方案，以农艺-经济-环境效益评估及多目标优化验证不同精准施肥策略的可行性，为农户应用提供完整的数字化解决方案。

6.2 技术路线

在整合多年多点冠层光谱数据、气象数据与农学数据的基础上，通过比较不同机器学习回归方法的预测精度，确定最优的冬小麦拔节期产量预测模型；探究不同的特征选择方法、特征聚合尺度对模型性能的影响，权衡模型性能与管理成本；在此基础上，进一步探究深度学习与进化算法在提升冬小麦全生育期的氮素营养监测与诊断精度的表现，提高模型的智能化水平；结合最佳的产量预测模型与氮素监测模型，建立基于产量预测的间接型追氮推荐算法；综合考虑作物实时生长状态、环境条件和肥料效应，建立直接型的最优追氮量推荐算法；通过验证试验比较不同追氮调控方案的效益与合理性，最终集成基于多源信息融合的冬小麦生长监测诊断与精准施氮的一体化技术。具体技术路线如图 1-1 所示。

7 本研究的目的是与意义

本研究针对小麦生长监测与氮肥推荐算法模型准确性和时空普适性有待提高的难题，通过获取多年多点不同氮素水平下小麦农学指标和冠层光谱的系统测试数据，利用机器学习方法融合多源信息(冠层光谱、气象、土壤)，构建田块尺度冬小麦生长监测模型和氮肥推荐算法，并通过特征组合、特征选择和特征重要性评估，解析冠层光谱和农业气象信息对模型的贡献度大小，从而为小麦生产中的氮素生长监测诊断和精准追氮提供准确、实用、普适的智慧决策模型及数字化解决方案。预期结果将有助于解决田块尺度小麦生长监测与精准施肥这一重要难点问题，并适用于大范围的推广应用，协同实现氮素管理的农艺、经济与环境效益，助力农业绿色发展与碳中和。




图 1-1 本研究技术路线图

Fig. 1-1 Technical route of this study

第二章 基于多源信息融合的冬小麦产量早期预测

摘要：作物产量是反映作物生长状况的综合表现指标。如何利用遥感数据快速无损地估测作物产量一直是农情遥感监测领域的研究热点。同时作物产量会受到生长环境、农艺管理措施和遗传特性的复杂影响。如何捕捉影响作物产量的复杂非线性关系，实现作物产量的早期(拔节期)准确预测，成为精准农业中备受挑战的科学问题。本研究旨在通过整合冠层光谱和气象数据，建立田间小麦产量预测模型。基于长江中下游平原与华北平原多年多点的田间历史试验数据、构建 11 种统计和机器学习回归模型，分析两种特征聚合区间(分生育期或全生育期聚合气象数据)以及两种特征选择方法(基于皮尔逊相关系数或递归特征消除)，全面评估产量预测的模型性能。结果表明，以随机森林算法为代表的集成学习模型取得了最高的模型精度($R^2 = 0.74 \sim 0.78$, $RMSE = 0.78 \sim 0.85 \text{ t ha}^{-1}$)，非线性的机器学习方法比传统的线性回归显著提高了预测精度。基于随机森林的特征重要性分析表明归一化差异红边指数、平均温度、最低温度和相对湿度对产量预测模型贡献最大，尤其是从种植日期到拔节期(就气象特征而言)。聚合方法和特征选择方法没有显著影响七种机器学习方法的产量预测性能，因此建议使用全生育期气象数据聚合并进行特征选择，以平衡模型性能与农户管理成本。这项研究引入了一个有前景的产量预测框架，弥补了县级尺度模型不适用于田间精准管理的缺点，为理解产量对环境的响应提供了见解。表现最佳的产量预测模型可用于指导基于传感器的冬小麦拔节期精准追肥。

关键词：冬小麦；产量预测；机器学习；作物冠层传感器

引言

冬小麦(*Triticum aestivum* L.)是中国产量最高的粮食作物之一，为大量人口提供碳水化合物和蛋白质。准确、及时和具有成本效益的小麦产量预测对粮食生产有着举足轻重的作用。在区域尺度上，作物产量预测对于制定宏观调控经济政策以确保粮食安全至关重要(Han et al., 2020)。在田块尺度上，作物产量预测在精准农业中也发挥着越来越重要的作用，因为需要通过基于目标产量水平的变量投入和农业资源的优化应用来提高盈利能力和环境可持续性(Kent Shannon et al., 2018)。

作物产量的早期预测可以与作物的营养状况/表型一起估计，以调整当季施肥决策。以往的研究发现，在拔节期的归一化差异植被指数(Normalized difference vegetation index, NDVI)的早期测量与最终产量和生物量合理相关(Marti et al., 2007)，尽管一些研

究如 Broge 和 Mortensen (2002)强调, 当小麦冠层未关闭时, 土壤背景暴露降低了利用反射率估算作物氮状况的可靠性。然而, 基于遥感的产量预测总是在生长季节后期(例如开花期前后)获得最佳结果(Corti et al., 2018; Zhang et al., 2019b)。因为追肥后的天气条件和潜在的土壤氮供应会极大地影响氮损失和植物氮胁迫(Ransom et al., 2021)。在抽穗和灌浆阶段, 热胁迫会显著影响结实率, 并最终影响籽粒产量(Farooq et al., 2011)。此外, 冬季霜害会降低穗率和穗数, 从而降低了产量(Zheng et al., 2018)。这些与作物生长和氮素损失相关的环境信息需要通过某种建模解决方案来捕捉, 以提高早期产量预测模型的准确性和泛化性, 从而帮助关键生长阶段的管理决策。

在过去的几十年里, 已经开发了两种主要方法, 经验统计模型和作物生长模型, 以改善作物产量预测(Basso and Liu, 2019)。就作物生长模型而言, 如 DSSAT(Decision Support System for Agrotechnology Transfer)和 APSIM(Agricultural Production Systems sIMulator), 它们具有较高的预测分析能力, 但对环境和农学管理数据的输入要求限制了它们在大规模应用中的可行性(Wang et al., 2020b; Zhang et al., 2020)。传统的统计模型(如线性回归)通过在任意数量的变量和实测产量之间建立回归方程来预测产量, 是相对简单的建模方法(Basso and Liu, 2019)。然而, 作物产量是复杂非线性相互作用的结果, 包括天气、土壤肥力、农艺管理、基因型、病虫害和杂草等多方面因素影响(Carew et al., 2009)。一方面, 作物产量在农业生态区和生长季节之间的变化降低了线性回归模型的时空泛化能力(Laurent et al., 2021)。另一方面, 当输入变量较多时, 线性回归可能会导致过拟合(Wang et al., 2020b)。

与传统的统计模型相比, 机器学习可以通过其数据驱动的能力构建鲁棒的非线性回归模型(Elavarasan et al., 2018)。随着来自众多来源的数据不断增加, 机器学习已经证明了其在精准作物管理方面的巨大潜在应用, 包括产量预测、疾病和杂草检测、作物识别和作物质量检测(Genze et al., 2020; Grinblat et al., 2016; Moshou et al., 2006; Pantazi et al., 2016; Pantazi et al., 2016)。具体而言, 产量预测是最具吸引力和挑战性的主题之一(Benos et al., 2021; Liakos et al., 2018)。许多研究人员使用机器学习技术, 通过结合遥感、环境和管理因素来提高产量预测(Kang et al., 2020; Maya Gopal and Bhargavi, 2019; Zhang et al., 2020)。通过构建各种植被指数, 如 NDVI 和增强植被指数, 可以使用遥感光谱波段的数学组合可靠地评估作物氮状况的时空变异性(Corti et al., 2018)。天气特征(例如气温和降水量)和土壤特征(例如容重和有机质含量)提供了有关驱动季节性氮矿化和氮损失的环境因素信息, 并为了解作物-环境相互作用提供新的见解(Ransom et al., 2021)。

近年来几项在国内进行的研究开发了县级尺度小麦产量预测模型, 使用不同的机器学习算法来集成来自遥感数据、气候数据和土壤性质的特征(Cao et al., 2020; Han et

al., 2020; Wang et al., 2020b)。然而, 县级尺度产量预测模型无法满足特定地点精确管理的空间分辨率要求(Evans and Shen, 2021; Sagan et al., 2021)。也有一些研究使用多源数据和机器学习方法估计了田块尺度的作物产量(Cao et al., 2021; Filippi et al., 2019; Sagan et al., 2021)。这些研究充分证明了建立基于机器学习的田间规模产量预测模型和指导当季管理决策的可行性, 但他们的研究使用了基于卫星的遥感数据。相对粗糙的时空分辨率、复杂的图像预处理过程、云层覆盖等因素限制了卫星遥感数据在实时田间精准管理的应用潜力(Cammarano et al., 2020; Huang et al., 2015)。

对中国和印度等发展中国家的小规模土地耕作系统而言, 需要开发一个低成本、高效和用户友好型的可行性预测框架。主动式作物冠层传感器(简称作物传感器)是基于手持式或车载式的近端传感设备, 可以提供实时植被指数作为一种非破坏性的田间氮素监测方法(Padilla et al., 2018)。作物传感器受云量和外部光照条件的影响较小, 因为它们有主动光源(Padilla et al., 2018)。因此, 近端传感特征被认为更适合于田间产量预测建模。一些类型的作物传感器, 如 GreenSeeker (Trimble Navigation Limited, Sunnyvale, CA, USA), RapidSCAN CS-45 传感器(Holland Scientific Inc., Lincoln, Nebraska, USA)和 Crop Circle 系列(Holland Scientific, Inc., Lincoln, NE, USA), 已被普遍用于开发基于植被指数的产量潜力模型(Cao et al., 2017b; Lu et al., 2020a; Wang et al., 2019)。这些基于作物传感器的产量预测通常在拔节期进行, 并用于指导追肥推荐(例如, 氮肥优化算法)。

利用机器学习技术有助于实现作物产量的智能预测和精准栽培。Aula 等(2021)通过 Lasso 回归方法在基于 GreenSeeker 传感器测量的特征中加入天气特征, 提高了当季冬小麦产量潜力预测的准确性。Abbas 等(2020)使用四种机器学习算法, 包括线性回归、弹性网络回归、k-最近邻和支持向量回归, 从近端传感收集的土壤和作物特征数据中预测马铃薯块茎产量。虽然他们的研究结果强调了通过整合机器学习、近端传感和环境数据进行当季产量预测的可行性, 但对于这种解决方案如何在中国集约化种植制度下的田间(小农场)尺度冬小麦早期产量预测中发挥作用, 还有待进一步研究。

本研究旨在整合来自多个地点和年份的田间实验的近端传感数据, 以及公开可用的天气数据, 以评估机器学习算法用于预测大田规模的冬小麦产量。特征选择可以减少计算时间, 增强预测性能, 提高数据和结果的可解释性(Elavarasan et al., 2020; Gopal Maya and Bhargavi, 2019)。此外, 动态特征(例如, 平均温度)的适当时间聚合间隔(例如, 每周、每月和分生育期聚合)也有助于平衡模型复杂性、过拟合风险以及与天气数据的适用性(Li et al., 2019)。因此, 本章将探讨以下问题: 1) 哪种机器学习方法在基于田间作物传感器的冬小麦产量预测中表现最佳? 2) 最具贡献度的特征是什么? 3) 哪些特征选择方法和哪些聚合区间提供了信息价值量最大的特征子集?

1 材料与方法

1.1 研究区域

研究区域包括位于中国河北和江苏两个省份的五个试验点(图 2-1)。这两个省份都是冬小麦生产的重要省份,涵盖了广泛的地理和气候条件。曲周(115.0°E, 36.9°N)位于河北省南部。泗洪(118.3°E, 33.4°N)和淮安(118.9°E, 33.6°N)位于苏北。上述县均位于华北平原地区,属温带季风气候。兴化(119.9°E, 33.1°N)和如皋(120.8°E, 32.3°N)分别位于江苏省中部和南部,处于长江中下游平原地区,属亚热带季风气候。邢台市(114.5°E, 37.1°N, 曲周相邻城市),淮南市(118.9°E, 33.6°N)、如皋市(120.8°E, 32.3°N) 2010-2020 年小麦生长季节内的月平均气温和降水量如图 2-2 所示(因曲周县该时期气象数据未更新,使用邢台市代替)。总的来说,随着纬度的增加,冬季和春季的气候变得更加干燥和寒冷。




图 2-1 研究区域与试验地点的地理位置

Fig.2-1 The geographic location of the study area and the experimental sites

注: 农业区域划分数据来源于中国科学院资源环境科学与数据中心

Note: Agricultural regional division data comes from Geographical data from Resource and Environment Science and Data Center, <https://www.resdc.cn/>




图 2-2 试验地点的月平均气温与降水量 (2010-2020 年小麦生长季)

Fig.2-2 Monthly average temperature and precipitation at the experimental sites (winter wheat growing season from 2010-2020)

1.2 历史试验设计

根据试验的地理位置,收集了 9 个不同地点、年份、种植日期、品种和施氮量的大田试验数据(表 2-1)。试验 1~4 在中国农业大学曲周实验站进行,试验 5~9 由南京农业大学国家信息农业工程技术中心团队在江苏省内各试验站进行。所有试验均遵循完全随机区组设计,试验重复 3 次或 4 次。氮肥(尿素)一般分两次施用:种植前 50% 作为基肥,在拔节期 50% 作为追施(对照组和变量施肥试验组除外)。曲周试验田块在播种前分别施用适量的三磷酸过磷酸钠($60\sim 120\text{ kg P}_2\text{O}_5\text{ ha}^{-1}$)和氯化钾($60\sim 100\text{ kg K}_2\text{O ha}^{-1}$)。其他试验田块施用 $105\text{ kg ha}^{-1}\text{ P}_2\text{O}_5$ 和 $120\text{ kg ha}^{-1}\text{ K}_2\text{O}$ 作为基肥。曲周的前茬作物是玉米,其他试验点的前茬作物是水稻。在小麦生长季节内没有观察到明显的水、杂草、害虫或疾病胁迫。

1.3 近端传感数据获取

使用 Crop Circle ACS-470 (Holland Scientific, Lincoln, NE)多光谱作物传感器在小麦冠层上方约 $0.7\sim 0.9\text{ m}$ 处以 10 Hz (每秒 10 个读数)在关键生育期收集每个地块的

表 2-1 历史试验设计

Table 2-1 The historical experimental design

试验 Experiment	地点 Site	年份 Year	播种日期 Planting date	拔节期 Jointing stage	收获日期 Harvest date	小区数量 Plot number	小区面积 Plot area (m ²)	品种 Cultivar	施氮量 Nitrogen fertilizer rate (kg N ha ⁻¹)
试验 1	曲周	2010	2009/10/9	2010/4/18	2010/6/13	20	300	良星 99	0, 300, 137.5, 178.75, 96.25
		2011	2010/10/10	2011/4/15	2011/6/12	20		良星 99	
		2012	2011/10/14	2012/4/10	2012/6/12	40		良星 99, 天农 18	
		2013	2012/10/8	2013/4/8	2013/6/13	40		良星 99, 天农 18	
试验 2	曲周	2011	2010/10/10	2011/4/10	2011/6/12	28	50	良星 99	0, 89, 150, 180, 300
试验 3	曲周	2010	2009/10/9	2010/4/27	2010/6/18	42	40	衡 4399, 科农 9204	0, 60, 120, 180, 240, 300, 360
		2011	2010/10/10	2011/4/5	2011/6/12	42			
试验 4	曲周	2010	2009/10/9	2010/4/17	2010/6/13	24	40	良星 99, 石麦 18	0, 137.5, 300
试验 5	如皋	2015	2014/11/5	2015/3/8	2015/6/7	36	30	宁麦 13, 扬辐麦 4, 淮麦 20	0, 120, 225, 330
试验 6	淮安	2015	2014/10/27	2015/3/31	2015/6/6	36	30	宁麦 13, 扬辐麦 4, 淮麦 20	0, 120, 225, 330
试验 7	泗洪	2016	2015/10/23	2016/3/24	2016/6/4	30	30	淮麦 20, 徐麦 30	0, 90, 180, 270, 360
试验 8	兴化	2018	2017/11/8	2018/3/22	2018/5/30	45	63	镇麦 12, 扬麦 23, 宁麦 13	0, 90, 180, 270, 360
		2019	2018/11/1	2019/3/7	2019/5/29	45			
试验 9	兴化	2019	2018/11/1	2019/3/6	2019/5/29	30	30	扬麦 23	0, 180, 240, 300
		2019	2018/11/24	2019/3/17	2019/6/3	30			
		2019	2018/12/1	2019/3/24	2019/6/3	30			
		2020	2019/11/1	2020/3/13	2020/5/28	30			
		2020	2019/11/15	2020/3/13	2020/6/3	30			
		2020	2019/12/4	2020/4/1	2020/6/4	30			

冠层反射率。Crop Circle ACS-470 传感器提供了三种可选滤波片的组合。本研究选择绿光(550 ± 20 nm, Green, G)、红边(730 ± 10 nm, Red edge, RE)和近红外($760 \text{ nm} \pm 10$ nm, Near-infrared, NIR)或红光(670 ± 11 nm, Red, R)、RE 和 NIR 波段组合的滤波片。计算平均反射率值来表示每个小区的近端传感特征值。之前的一项研究表明, 基于红边波段的植被指数具有克服 NDVI 饱和问题的优势(Cao et al., 2016)。因此, 本研究利用红边波段和近红外波段的反射率计算归一化差异红边指数(Normalized difference red edge, NDRE), 红边比值植被指数(Red edge ratio vegetation, RERVI), 红边叶绿素指数(Red edge chlorophyll index, CI_{RE})以及红边土壤调节植被指数(Red edge soil adjusted vegetation index, RESAVI), 如公式(2-1) ~ (2-4)所示:

$$NDRE = \frac{NIR-RE}{NIR+RE} \quad (2-1)$$

$$RERVI = NIR/RE \quad (2-2)$$

$$CI_{RE} = (NIR/RE)-1 \quad (2-3)$$

$$RESAVI = 1.5 \times \frac{NIR-RE}{NIR+RE+0.5} \quad (2-4)$$

为了实现冬小麦产量的早期预测, 同时为了产量模型能够应用于指导追肥推荐, 本章使用的近端传感数据仅为拔节期。为了防止模型过拟合, 本章仅使用 NDRE 值。最终获得 623 个 NDRE 值(628 个小区), 因试验 2 中存在 4 个异常值($NDRE < 0$)被去除, 试验 3 中有 1 个缺失值。

1.4 气象数据获取

表 2-2 列出了本研究中收集的气象数据集。如皋、泗洪、淮安的天气数据来自中国气象数据服务中心(<http://data.cma.cn/>)。兴化市气象资料由当地气象部门提供。曲周的天气数据是利用田间气象站采集的, 其中将 2012 年 9 月至 2013 年 6 月的部分缺失值(日照时数、相对湿度和降水量)替换为曲周相邻城市邢台气象站的数据。在曲周试验站直接记录了太阳有效辐射值, 而在试验点只有日照时数值。由于太阳辐射的数据与作物的蒸散发和光合作用更相关, 因此采用 Zou 等(2017)改进的 IBC 模型(Improved Bristow-Campbell model)将日照时数转换为太阳有效辐射。

1.5 产量数据获取

为了确定小麦收获产量, 在成熟时人工收割三个面积为 1m^2 的小麦样方, 然后干燥、脱粒和称重。籽粒产量统一调整到含水率为 14% 时的质量。此外, 还计算了重复试验间产量和 NDRE 值的变异系数以排除异常值。当变异系数大于 30% 时, 必要时将异常值替换为其他重复的平均值。

表 2-2 气象数据汇总

Table 2-2 Summary of meteorological data

天气变量 Weather variable	缩写 Abbreviation	单位 Unit	计算公式 Formula
日值气象数据 Daily meteorological data			
平均温度, Average temperature	AT	°C	
最高温度, Maximum temperature	MaxT	°C	
最低温度, Minimum temperature	MinT	°C	
降水量, Precipitation	PPT	mm	
相对湿度, Relative humidity	RH	%	
日照时数, Sunshine duration	SD	hours	
太阳有效辐射, Solar radiation	SR	$\text{MJ m}^{-2} \text{ day}^{-1}$	$\text{SR}/H_0 = (b_0 + b_1 \sin(M) + b_2 \cos(M) + b_3 \text{RH} + b_4 \text{PPT} + b_5 \text{SD}) \times [1 - \exp(-b_6 (\text{MaxT} - \text{MinT})^{b_7})]$ 其中 H_0 是地外太阳辐射量, $M = 2\pi(j-1)/365$, j 是儒略日。
生长度日, Growing degree days	GDD	°C	$\text{GDD} = (\text{MaxT} + \text{MinT})/2 - \text{Tbase}$, $\text{Tbase} = 0^\circ\text{C}$.
气象特征 Meteorological features			
平均太阳辐射, Average solar radiation	SR-avg	$\text{MJ m}^{-2} \text{ day}^{-1}$	给定日期内的 SR 平均值
总太阳辐射, Total solar radiation	SR-sum	MJ m^{-2}	给定日期内的 SR 总和
平均温度, Average temperature	T-avg	°C	给定日期内的 AT 平均值
最高温度, Maximum temperature	T-max	°C	给定日期内的 MaxT 最大值
	T-max-avg	°C	给定日期内的 MaxT 平均值
最低温度, Minimum temperature	T-min	°C	给定日期内的 MinT 最小值
	T-min-avg	°C	给定日期内的 MinT 平均值
总降水量, Total precipitation	PPT-sum	mm	给定日期内的 PPT 总和
平均相对湿度, Average relative humidity	RH-avg	%	给定日期内的 RH 平均值
累积生长度日, Accumulated Growing degree days	AGDD	°C	给定日期内的 GDD 总和
香农多样性指数, Shannon diversity index of precipitation evenness	SDI	-	$\text{SDI} = [-\sum p_i \frac{\ln(p_i)}{\ln(n)}]$ 其中 $p_i = \text{PPT}/\text{PPT-sum}$, n 为给定日期内的天数
降水均匀度系数, Abundant and well-distributed rainfall	AWDR	-	$\text{AWDR} = \text{SDI} \times \text{PPT-sum}$

1.6 数据分析

1.6.1 经典统计分析方法

本研究使用经典描述性统计分析方法对试验数据的分布和变化特征进行分析,以充分了解和检查数据并剔除异常值,使用的统计参数包括平均值、最大值、最小值、标准差和变异系数。在进行单因素方差分析与多重比较时,若满足方差齐性假设,使用 Tukey 检验进行组间两两比较;若不满足方差齐性假设,则使用 Games-Howell 检验进行组间两两比较。以上统计分析均采用 IBM SPSS Statistics 25 软件完成。

1.6.2 特征预处理

本研究涉及的特征预处理包括特征提取和特征标准化。由于气象数据是一种动态特征,可以在不同的时间尺度内进行聚合。气象特征在特定区域内具有同质性,但在时间和生态区域内存在差异。为了提取有效的天气信息,在不同的模型构建过程中根据实际情况和研究进度进行了调整,具体的操作如下:

在拔节期产量预测模型中使用了从播种前 30 天到开花期(大约在收获前一个月)的每日天气数据。这是出于两方面的考虑。一方面,种植前的天气条件被认为决定着种植时间、土壤氮和土壤水分状况,进而影响种子萌发和早期根系生长(Qin et al., 2018)。另一方面,生殖生长期的天气数据对最终的产量变化有显著影响,而拔节期的 NDRE 无法提供关于作物生长后期的信息。为了进一步细化研究天气特征的影响,天气数据在两个不同的时间区间内进行聚合。在第一种情况下,天气数据被聚合成 3 个时间段来匹配重要生育期(Aggregation 1, A1): 即播种前 30 天(30d-P, before 30 days-planting), 播种期到拔节期(P-S, planting-stem elongation), 拔节期到开花期(S-F, stem elongation stage-flowering, 包括了抽穗期和开花期两个阶段)。在第二种情况下,天气数据直接从播种前 30 天计算到开花期(Aggregation 2, A2)。该章节创建了 11 个天气特征(表 2-2), 包括平均太阳辐射(SR-avg)、总太阳辐射(SR-sum)、平均温度(T-avg)、最高温度(T-max)、最低温度(T-min)、降水量(PPT-sum)、平均相对湿度(RH-avg)、累积生长度日(AGDD)、降水量香农多样性指数(SDI)(Tremblay et al., 2012)、降水量分布均匀系数(AWDR)(Tremblay et al., 2012)。SDI 取值范围为 0~1。当 SDI 接近 0 时,说明降水的时间分布极不均匀或无降水。但当 SDI 接近 1 时,代表降水事件分布均匀。种植后天数(Days after planting, DAP)作为辅助特征,提供作物生长发育过程的信息。最后生成两个具有不同聚合时间间隔的气象特征子集(即 A1, A2)。

在特征提取完成后,使用分层抽样法(StratifiedShuffleSplit)根据 NDRE 的分布将训练集和测试集(80%:20%)进行划分,或对所有数据进行随机打乱后进行随机采样。目

的是为了让训练集和测试集产生类似的数据分布,确保模型的泛化能力。根据生长年份或地理位置对数据集进行划分(留一交叉验证)可能更具独立性,更有利于对测试集的时空变化特征进行分析。但是,为了充分利用数据,同时增强泛化能力,减少过拟合,本研究未采用留一交叉验证。接下来,使用 *StandardScaler* 对所有特征(包括训练和测试集)进行标准化,目的是消除特征之间单位和尺度差异的影响。并不是所有机器学习算法都对特征缩放敏感,但为了简便起见,本研究对所有特征进行了缩放。

1.6.3 特征选择方法

在基于多源信息融合的建模过程中,可以通过增加特征数量提高性能。比如不同的光谱波段或植被指数、土壤属性、天气状况、栽培管理措施、品种遗传特性等因素均能用于训练模型,提高作物监测和管理的精度。然而,过多的变量会导致计算开销加大、模型过拟合、数据获取难度加大等问题。因此,模型性能与模型复杂度之间需要权衡。特征选择技术可以剔除不相关和冗余的特征,得到合适的特征子集,发现重要的特征。本研究使用两种特征选择方法用于去除共线和冗余特征,即基于皮尔逊相关系数(feature selection based on Pearson Correlation Coefficient, PCCfs)的特征选择和基于递归特征消除(Recursive Feature Elimination, RFE)的特征选择(Chen and Chen, 2015)。在第一种方法中,计算特征与产量之间的皮尔逊相关系数(r)。皮尔逊相关系数是衡量两个特征之间线性关系强度的一种统计量,取值范围是 $[-1, 1]$ 。选择与产量显著相关但与其他特征不高度相关($-0.85 < r < 0.85$)的特征。如果两个特征之间高度相关,则选择与产量关系更密切的特征。在第二种方法中,RFE 通过递归地考虑越来越小的特征集来选择特征。首先,在初始特征集上训练估计器,并通过任何特定属性或可调用属性获得每个特征的重要性。然后,从当前特征集中删除最不重要的特征。在修剪集上递归地重复该过程,直到最终达到要选择的特征的期望数量。本研究选用基于支持向量回归(线性核, $C=1$)的估计器进行消除。参数 *n_features_to_select* 用来设定特征保留的数量,是一个可以自定义的参数,本研究通过 *RFECV*(带有交叉验证的 RFE)确认,从而选择最佳的保留特征数量。

因此,本章构建了 6 个特征子集:将天气数据聚合为 3 个时间段的完整特征子集(特征子集 1)、从播种前 30 天至开花期聚合的完整特征子集(特征子集 2)、基于子集 1 的 PCCfs(特征子集 3)、基于子集 1 的 RFE(特征子集 4)、基于子集 2 的 PCCfs(特征子集 5)和基于子集 2 的 RFE(特征子集 6)。

1.6.4 统计与机器学习回归算法

本章所有机器学习算法都基于 Python(3.8)编程语言(Python Software Foundation,

Wilmington, DE, USA)在 PyCharm(JetBrains, Prague, Czechia)开发环境下进行构建。本研究涉及的机器学习算法使用 Scikit-learn (<https://scikit-learn.org/>)算法库进行拟合, Scikit-learn 是一个支持监督学习或无监督学习的开源机器学习库, 提供大量封装的算法与数据处理工具。构建产量预测模型中选用了 11 种常用的算法进行综合分析, 包括线性回归(Linear regression, LR)、岭回归(Ridge regression, RR)、Lasso 回归(Least absolute shrinkage and selection operator regression)、弹性网络回归(Elastic-net regression, ENR)、支持向量回归(Support vector regression, SVR)、k-近邻(K-nearest neighbors, KNN)、决策树(Decision trees, DT)、随机森林(Random forest, RF)、梯度增强决策树(Gradient boosting decision tree, GBDT)、极端梯度增强树(eXtreme gradient boosting, XGBoost)和多层感知器(Multilayer perceptron, MLP)。

LR 即普通最小二乘线性回归(等式 2-12), 被设为基准比较模型。LR 拟合系数 $w=(w_1, \dots, w_p)$ 的线性模型, 以最小化数据集中观察到的目标与线性近似预测的目标之间的残差平方和。

$$\hat{y}(w, x) = w_0 + w_1x_1 + \dots + w_px_p \quad (2-12)$$

RR 是具有 L2 正则化的线性回归(Hoerl and Kennard, 1970)。Lasso 是具有 L1 正则化的线性回归(Tibshirani, 1996)。RR 和 Lasso 通过最小化过拟合和收缩不太重要的系数来解决 LR 的不足。不同的是, L2 正则化会使系数 w 变小,但不为零,不会形成稀疏解; L1 正则化则可以让一部分特征的系数缩小到零。ENR 是 RR 和 Lasso 的组合, 它对预测因子之间的极端相关性具有鲁棒性(Zou and Hastie, 2005)。RR, Lasso 和 ENR 要最小化的目标函数分别为:

$$\min_w \|Xw - y\|_2^2 + \alpha \|w\|_2^2 \quad (2-13)$$

$$\min_w \frac{1}{2n} \|Xw - y\|_2^2 + \alpha \|w\|_1 \quad (2-14)$$

$$\min_w \frac{1}{2n} \|Xw - y\|_2^2 + \alpha \rho \|w\|_1 + \frac{\alpha(1-\rho)}{2} \|w\|_2^2 \quad (2-15)$$

其中 α 为复杂度系数, $\alpha \geq 0$, 控制收缩量, α 越大收缩量越大, 系数对共线性也越鲁棒。 ρ 用来控制 L1 和 L2 惩罚项的比率。

SVR 在高维或无限维空间中构造超平面或超平面集合, 可用于分类、回归或其他任务(Smola and Schölkopf, 2004)。直观地说, 通过与任何类别的最近训练数据点具有最大距离的超平面(所谓的函数间隔)实现了良好的分离, 因为通常间隔越大, 分类器的泛化误差越低。当问题不是线性可分时, “支持向量” 是间隔边界内的样本。SVR 在高维空间表现良好; 在数据维度大于样本点数时, 依然可以起作用; 同时 SVR 支持灵活使用多种“核函数”来解决不同情况下的问题。SVR 的损失函数可以表示为:

$$\min_{w,b,\zeta,\zeta^*} \frac{1}{2} w^T w + C \sum_{i=1}^n (\zeta_i + \zeta_i^*) \quad (2-16)$$

其中，第一项表示模型的复杂度，第二项为惩罚项，C 是一个超参数，用于调整惩罚项的权重， ζ_i, ζ_i^* 是松弛变量。

最近邻方法背后的原理是找到距离新点最近的预定义数量的训练样本，并根据这些样本预测标签，它不需要显式地建立模型(Aha et al., 1991)。样本的数量可以是用户定义的常数(KNN)，或者基于点的局部密度而变化(基于半径的近邻学习)。通常，距离可以是任何度量标准：标准欧几里德距离是最常见的选择。基于邻居的方法被称为非泛化机器学习方法，因为它们只需“记住”所有训练数据。在数据标签是连续变量而不是离散变量的情况下，可以使用基于邻居的回归。KNN 回归基于每个查询点的 K 个最近邻居进行学习，其中 K 是用户指定的整数值。

DT 是一种用于分类和回归的非参数监督学习方法(Breiman et al., 2017)。目标是通过学习从数据特征推断出的简单决策规则来创建一个预测目标变量值的模型。树可以看作是一个分段常数近似。DT 是一种白盒模型，易于理解和解释，如果给定的情况在模型中是可观察的，则该条件的解释很容易用布尔逻辑来解释。但是，DT 会生成过于复杂的树导致过拟合，为了避免这个问题，需要诸如剪枝、设置叶节点所需的最小样本数或设置树的最大深度等机制。另一方面，DT 可能不稳定，因为数据的微小变化可能导致生成完全不同的树。DT 衡量模型拟合优度的损失函数通常是均方误差或平均绝对误差，而在树模型的建立过程中，通过计算特征的信息增益或基尼系数来实现对每个节点选择最优的特征进行划分。

RF, GBDT 和 XGBoost 是以 DT 为基础的集成学习方法。集成方法的目的是结合使用给定学习算法构建的几个基本估计器的预测，以提高单个估计器的泛化能力/鲁棒性。集成方法大致分为两类，一类是平均方法，一类是提升方法。平均方法在强模型和复杂模型(如完全开发的决策树)中效果最好，而增强方法通常在弱模型(如浅决策树)下效果最好。RF 是基于平均方法的一种集成学习技术，集合中的每个树都是从训练集中抽取的替换样本(bootstrap)构建的(Breiman, 2001)。单个决策树通常表现出较高的方差，并倾向于过度拟合。森林中注入的随机性产生了具有某种解耦预测误差的决策树。通过这些预测的平均值，一些误差可以抵消。随机森林通过组合不同的树木来实现减少的差异，有时以偏差的轻微增加为代价。在实践中，方差减少通常是显著的，因此产生了总体上更好的模型。GBDT 和 XGBoost 是基于提升方法的集成学习技术，即通过迭代地训练决策树模型并逐步调整损失函数的梯度来提高模型的预测性能。GBDT 是提升方法对任意可微损失函数的推广(Friedman, 2001)。XGBoost 是一个在 GBDT 基础上优化的、更加高效灵活的分布式梯度提升库(Chen and Guestrin, 2016)。

以上集成学习方法可以有效提升模型的准确度和泛化能力,但也存在训练时间相对较长的问题,且需要调整许多关键超参数。

MLP 是一种简单的人工神经网络,包含三层,即输入层、隐藏层和输出层(Murtagh, 1991)。输入层,由一组神经元组成,表示输入特征。隐藏层中的每个神经元通过加权线性求和变换前一层的值,然后再通过非线性激活函数变换。输出层从最后一个隐藏层接收值,并将其转换为输出值。MLP 的训练一般采用反向传播算法,对于回归问题,MLP 常用的损失函数是均方误差。

对于每种机器学习算法,使用网格搜索 *GridSearchCV* 的 5 折交叉验证来优化超重要参数(表 2-3),并使用最优超参数来拟合模型。各超参数的具体含义请参考 *Scikit-learn* (<https://scikit-learn.org/>)相关算法的解释。通过以上经典机器学习方法的系统比较,找出表现最优最稳定的机器学习算法,为后续建模提供基础。

1.6.5 模型评估

不同的特征选择方法及机器学习回归算法会直接影响预测结果,确定最优的特征选择方法和机器学习算法对优化作物生长监测与精准施氮具有重要意义。在回归分析中,常用预测值与观测值之间的决定系数(R^2)和均方根误差(RMSE)作为模型评估的指标(公式 2-18, 2-19)。一般而言, R^2 越高, RMSE 越小表明模型精度越高。

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2} \quad (2-18)$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}} \quad (2-19)$$

其中, y_i 和 $\hat{y}_i$ 分别表示观测值和预测值的大小, $\bar{y}_i$ 表示 y_i 的平均值, n 代表样本数。

模型评估时比较了基于训练集 5 折交叉验证的结果与基于测试集的结果。

1.6.6 模型解释

通过模型解释,可以发现隐藏在大数据中的有价值的知识,进而为特征设计、模型优化、实际应用等提供启示,这是数据挖掘生命周期循环中不可或缺的一步。

特征重要性是一种用于衡量每个特征在模型中的重要性的指标。特征重要性是通过计算每个特征在随机森林中被用来分裂数据的次数来确定的。因此,特征被用于分裂数据的次数越多,其重要性就越高。随机森林中有两种主要的特征重要性衡量方法:基尼重要性和平均减少不纯度(the mean decrease of impurity, MDI)。本研究使用 *scikit-learn* 库中的 *feature_importance* 属性来计算特征重要性。该属性计算每个特征的重要性得分,该得分基于 MDI 计算(Louppe, 2014)。

表 2-3 不同算法的超参数搜索网格

Table 2-3 The grids for hyperparameters search in different algorithms

算法 Algorithms	超参数 Hyperparameters
LR	无
RR	'alphas': [0.01, 0.1, 1.0, 2.0, 3.0, 4.0, 5.0, 6.0]
Lasso	'alphas' 自动调整
ENR	'l1_ratio': (0.1, 0.9)
SVR	'kernel': ['linear', 'rbf', 'sigmoid'], 'gamma': ['scale', 'auto'] 'C': [1, 10, 50, 100, 250, 500, 750, 1000, 2000, 3000, 4000, 5000]
KNN	'n_neighbors': (2, 10), 'weights': ['uniform', 'distance']
DT	'max_depth': (5, 10), 'min_samples_split': (2, 15), 'min_samples_leaf': (1, 5)
RF	'n_estimators': (100, 1000, 50), 'max_depth': (5, 10), 'min_samples_split': (5, 15), 'min_samples_leaf': (1, 5), 'max_features': (0.1, 0.9)
GBDT	'n_estimators': (50, 150), 'loss': ['ls', 'huber']
XGBoost	'n_estimators': [30, 40, 50, 60, 70, 80] 'max_depth': [3, 4, 5, 6, 7, 8, 9, 10], 'min_child_weight': [1, 2, 3, 4, 5, 6], 'gamma': [0.1, 0.2, 0.3, 0.4, 0.5, 0.6], 'subsample': [0.6, 0.7, 0.8, 0.9], 'colsample_bytree': [0.6, 0.7, 0.8, 0.9], 'reg_alpha': [0.05, 0.1, 1, 2, 3], 'reg_lambda': [0.05, 0.1, 1, 2, 3], 'learning_rate': [0.01, 0.05, 0.07, 0.1, 0.2]
MLP	'hidden_layer_sizes': (50, 500, 50), 'solver': ['sgd', 'adam'], 'activation': ['tanh', 'identity', 'logistic', 'relu']

注：超参数搜索范围可根据经验进行合理调整

Note: The search range of hyperparameters can be adjusted reasonably according to experience

2 结果与分析

2.1 产量的变化特征

2009-2020 年实测冬小麦产量的描述性统计结果如图 2-3 所示。不同生态点的冬小麦产量差异较大。所有变异系数均大于 15%。各试验点冬小麦产量在 $1.93\sim 9.21\text{ t ha}^{-1}$ 之间变化。如皋数据集平均产量最低(5.35 t ha^{-1})，标准差最低(1.04 t ha^{-1})，变异系数最低(19.50%)。兴化数据集平均产量最高，为 6.87 t ha^{-1} 。曲周数据集的标准差最高，为 1.85 t ha^{-1} ，变异系数最高，为 31.28%，这可能是由于不同气候条件、作物品种和施氮量下的多年田间试验所致。




图 2-3 冬小麦产量的描述性统计

Fig.2-3 Descriptive statistics of winter wheat yield

2.2 特征选择结果

特征子集 1 的皮尔逊相关分析结果如图 2-4 所示。根据热图显示，NDRE 与产量的相关性最高($r = 0.62$)。值得注意的是，NDRE 与天气特征不是高度相关的，这表明，通过捕获当前作物生长状况的信息，NDRE 是产量变化的一个重要而独特的因素。T-avg (P-S)、T-min (P-S)和 RH-avg (P-S)与产量呈正相关($r > 0.2$)，说明从播种到测试期(拔节期)的天气信息是影响产量变异的主要因素。SR-avg (30d-P)、SR-sum (30d-P)、SR-sum (P-S)、T-avg (30d-P)、T-min (30d-P)、AGDD (30d-P)和 DAP 与产量呈负相关($r < -0.2$)，表明冬小麦产量与种植前 1 个月关键天气条件(如太阳辐射和温度)的影响呈负相关。此外，三个时期的天气特征与产量之间存在不同的相关性。SR-avg 和 T-max 在各时期与产量呈负相关，反映出这些特征表征着热胁迫条件。相反，各时期 RH-




图 2-4 特征子集 1 的皮尔逊相关分析热图

Fig.2-4 Pearson correlation analysis heatmap of feature subset 1

注：空白处表示相关性不显著($p > 0.05$)

Note: The blank indicates that the correlation is not significant ($p > 0.05$)

avg 与产量呈正相关，说明相对湿度高有利于冬小麦生长。SDI、AWDR 与产量的相关性高于 PPT-sum，说明降水均匀度更能反映水分状况。T-avg (30d-P) ($r = -0.23$)和 T-avg (P-S) ($r = 0.32$)结果相反，说明适宜的种植日期对冬小麦产量至关重要。去除共线性后，选取 13 个特征作为特征子集 3(图 2-5)。

特征子集 2 的皮尔逊相关分析结果如图 2-6 所示。NDRE 与产量的相关性最高($r = 0.62$)。T-avg、T-min 和 RH-avg 与产量呈正相关($r > 0.2$)，SR-sum 和 DAP 与产量呈负相关($r < -0.2$)。光温条件相关特征 SR-avg、SR-sum、T-max、T-min(负数)和 AGDD 对产量变化具有负影响。然而，与水分相关的特征(包括 PPT-sum、RH-avg、SDI 和 AWDR)则相反。这两种相反的关系可以进一步解释为什么最干旱的曲周地区冬小麦的平均产量低于江苏试验点(最南端的如皋市除外)，尽管冬小麦是一种长日低温作物。去除共线性后，选取 6 个特征作为特征子集 5(图 2-5)。




图 2-5 特征选择结果的韦恩图

Fig.2-5 The Venn diagram of feature selection result




图 2-6 特征子集 2 的皮尔逊相关分析热图

Fig.2-6 Pearson correlation analysis heatmap of feature subset 2

基于特征子集 1 和特征子集 2 的 *REECV* 交叉验证 R^2 如图 2-7 所示。当特征数量增加时, 交叉验证的 R^2 先急剧增加, 然后保持相对稳定。交叉验证 R^2 曲线证明, 天气特征确实有助于提高产量预测的准确性。同时, 曲线也表明在完整子集中存在冗余特征。根据图 2-7 所示的拐点, 子集 4 和子集 6 的最佳特征数分别为 10 和 8(图 2-5)。有趣的是, 子集 4 中没有选取 P-S 时期的天气特征, 而选取了 S-F 时期的 6 个天气特征和 30d-P 时期的 3 个天气特征。




图 2-7 基于特征子集 1(a)和特征子集 2(b)的 *RFECV* 的最佳特征选择数量

Fig.2-7 The best feature numbers of feature subset 1(a) and feature subset 2(b) based on *RFECV*

采用两种不同方法选择特征后, 共创建 6 个特征子集(图 2-5)。通过比较特征子集 3 和 4, 同时被选择的特征有 NDRE、SR-avg (S-F)、SR-sum (S-F)、T-max (S-F)、AGDD (S-F)和 SDI (S-F)。通过比较特征子集 5 和 6, 同时被选择的特征有 NDRE、T-avg、T-max 和 RH- avg。降水特征只出现在子集 4 中, 表明降水相关特征在产量预测中的作用可能不如温度相关特征。最重要的是, NDRE 是产量预测的一个主要潜在因素, 天气特征也有望提供可以解释产量变化的环境信息。

2.3 模型表现与分析

基于训练集 5 折交叉验证的 R^2 和 RMSE 的箱须图如图 2-8 所示。LR, RR, Lasso 和 ENR 与其他估计器相比具有相似但较低的精度。DT 的性能略好于基准模型(LR)。SVR 和 KNN 进一步提高了产量预测的准确性, 但它们的四分位距(箱须图箱体部分)很大, 这表明这两个模型在拟合我们的数据时并不稳定。三种基于树的集成学习估计器(RF, GBDT, XGBoost)表现优于 DT, 同时四分位距的不确定性也较低。RF 的综合性能最好(平均 $R^2 = 0.74 \sim 0.76$, 平均 RMSE = $0.83 \sim 0.85 \text{ t ha}^{-1}$), 表明 RF 比其他机器学习方法更能捕捉年际和区域间的产量变化。MLP 也表现出了合理的精度, 但运行时间相对较慢。基于上述信息, 集成学习算法被证明是最优的预测方法。




图 2-8 不同特征子集与算法的模型性能(训练集)

Fig. 2-8 The model performance of different feature subsets and algorithms (training set)

值得注意的是,在每种算法中,特征子集 1 和特征子集 2 之间的模型性能相似(除了 ENR),这表明时间聚合间隔的整体影响不显著。当采用两种基于特征子集 1 的特征选择方法时,精度变化不明显。然而,当使用基于特征子集 2 的两种特征选择方法时,四种线性回归模型的预测精度都有所下降。潜在的原因可能是特征数量不足导致的欠拟合。在 7 个机器学习模型(即不包括线性回归)中观察到子集间模型性能的波动较小,表明这些估计器可以在不影响模型性能的情况下降低特征数量。因此,在实际产量预测中进行特征选择有助于平衡模型性能与数据获取成本。

测试集数据的验证 R^2 和 RMSE 值如图 2-9 所示。




图 2-9 不同特征子集与算法的模型性能(测试集)

Fig. 2-9 The model performance of different feature subsets and algorithms (test set)

模型的平均性能排名为 XGBoost > MLP > GBDT > SVR > RF > DT > KNN > RR > LR > Lasso > ENR。所有最佳模型解释了 76% 以上的产量变化。基于特征子集 6 的 MLP 具有最高的精度($R^2 = 0.78$)和最小的误差($RMSE = 0.77 \text{ t ha}^{-1}$)。总体而言, 四种线性回归模型对聚合 1 上产量变化的贡献率约为 60%, 且表现优于聚合 2。KNN 和 DT 回归模型表现相似, R^2 值在 0.67 到 0.68 之间。RF 实现了稳定的 R^2 值 0.74, 而 SVR 和 GBDT 表现略好于 RF, R^2 在 0.73~0.76 之间。XGBoost 和 MLP 的综合性能最佳($R^2 = 0.75 \sim 0.78$, $RMSE = 0.77 \sim 0.82 \text{ t ha}^{-1}$)。7 种机器学习方法在聚合 1 和聚合 2 之间的预测精度相似。上述信息进一步证实了 5 折交叉验证的结果, 表明本研究建立的预测模型具有良好的鲁棒性和泛化能力。

在特征选择方面, PPCfs 在 LR、RR、Lasso、KNN、DT、RF、GBDT 和 XGBoost 中 R^2 最高, RMSE 最低。RFE 在 SVR 和 MLP 中表现最佳。综上所述, PPCfs 是一种更好的特征选择方法, 它可以保留更显著的产量变化信息, 并能更好地理解不同特征的贡献。

在 RF、GBDT 和 XGBoost 三种集成学习模型中, 特征子集 5 的准确率最高。因此, 为了进一步研究实测产量与预测产量之间的关系, 生成了基于特征子集 5 的散点图, 如图 2-10 所示。结果表明, 在 7 个机器学习模型中, 散点更多地聚集在 1:1 线上, 特别是在中低产量水平下($2 \sim 6 \text{ t ha}^{-1}$)。换句话说, 线性回归模型则高估了中低产田块的产量。最有可能的解释是机器学习方法可以更好地捕捉有关环境胁迫导致低产的气信息。

为了进一步分析特征对产量预测的贡献, 我们计算了基于特征子集 1 和 2 的 RF 的特征重要性(图 2-11)。在特征子集 1 中, 排名前五的特征为 NDRE > T-min (P-S) > T-avg (P-S) > RH-avg (P-S) > DAP, 说明 NDRE 是 RF 预测模型的主要贡献者, P-S 时期的天气特征也在产量预测中发挥了关键作用。对于特征子集 2, 排名前 5 位的特征依次为 NDRE > T-min > RH-avg > T-avg > SR-sum。因此, NDRE、T-min、T-avg 和 RH-avg 是产量预测模型的重要特征, 尤其是在 P-S 期, 这与先前 PPCfs 的分析结果一致。




图 2-10 实测产量与预测产量关系的散点图

Fig. 2-10 The scatter plots of the relationship between the observed yield and predicted yield

注：六边形颜色深浅代表散点数量；RMSE 的单位为 t ha^{-1} 。

Note: The hexagonal color depth represents the number of scattered points; The unit of RMSE is t ha^{-1} .




图 2-11 基于特征子集 1(a)和特征子集 2(b)的随机森林特征重要性

Fig. 2-11 Random Forest feature importance based on feature subset 1 (a) and feature subset 2 (b)

3 讨论

3.1 早期产量预测在作物精确管理中的可行性

不同特征子集的最佳模型解释了 76%以上的产量变化,而 NDRE 与产量的相关 r 值仅为 0.62,表明天气数据提高了早期产量预测模型的准确性。类似地, Aula 等(2021)发现,通过将温度和降水信息纳入模型,可以提高小麦当季产量预测的准确性。然而,在他们的研究中只涉及到一个生态点。虽然在当前的研究中开发的是田块尺度模型,但由多地点和多年的农场实验提供的时空变化提高了大规模应用的可行性。本研究发现线性回归会高估中低产田的预测精度。以往一些研究也指出,产量预测模型往往会出现低估高产,高估低产的现象(Cao et al., 2021; Evans and Shen, 2021)。早期冠层光谱监测有助于缓解植被指数的饱和,避免对高产的低估。如果利用本研究的预测框架(RF

等)指导追肥决策,可以有效避免低产田块或田块内部低产区域高估潜在产量,进而避免过量施肥,减少氮素损失。

3.2 产量预测中不同统计和机器学习方法的对比

在本研究中,非线性的机器学习方法(SVR、KNN、DT、RF、GBDT、XGBoost 和 MLP)在冬小麦产量预测方面的性能优于传统线性回归方法(LR、RR、Lasso、ENR)(图 2-8),这与以往的研究结果一致(Cai et al., 2019; Fu et al., 2020; Wang et al., 2020b; Zhou et al., 2021)。需要再次提到的是,交叉验证的训练结果和测试结果具有相似性,说明本研究数据划分是合理的。四种基于线性回归的方法具有相似但较差的性能($R^2 = 0.5 \sim 0.6$, $RMSE \approx 1.0 \text{ t ha}^{-1}$),表明 LR 本身没有过拟合,因此用 L1/L2 正则化优化目标函数并不能提高预测精度。同样地, Ransom 等(2019)发现线性统计模型(逐步线性回归 SLR、RR、Lasso、ENR、主成分回归和偏最小二乘回归)在改进玉米氮肥推荐算法方面没有显著差异,表明线性回归没有考虑复杂的非线性关系(Srivastava et al., 2021)。然而, LR、RR、LASSO、ENR 和 DT 更容易运行和解释。参数化公式输出(用于线性模型)或决策树可视化(用于 DT)可以提供关于特征重要性的直观信息。

以往使用 SVR 和 KNN 进行的作物产量预测研究一致指出, SVR 比 KNN 表现更好(Abbas et al., 2020; Han et al., 2020; Kamir et al., 2020; Maya Gopal and Bhargavi, 2019)。KNN 的性能较差和不稳定可能与 KNN 对冗余和不相关特征的高敏感性有关(Srivastava et al., 2021),因此在特征或维度较少的 A2 中, KNN 模型的性能略好于 A1(图 2-9)。RF 是最常用的机器学习算法之一,可以处理高维数据集,避免过拟合。正如预期的那样,在本研究的结果中, RF 在产量预测方面优于 DT(图 2-9),这之前的一些研究一致(Bocca and Rodrigues, 2016; Elavarasan et al., 2020; Han et al., 2020; Suruliandi et al., 2021)。此外,之前的一些研究表明,与 GBDT 相比, RF 在实测和预测产量之间提供了更强的一致性(Elavarasan et al., 2020; Leo et al., 2021; Nesarani et al., 2020)。在本研究中, GBDT 的准确性略低于 RF。可能的解释是由于 GBDT 中使用了较少的集成预测器(超参数 $n_estimators$)。另一个可能的因素是 Leo 等(2021)提及的解释,即本研究中使用的数据集显示出高度的时空变异性。与之前的研究一致(Kang et al., 2020; Zhang et al., 2020), XGBoost 实现了与 RF 相当的产量预测性能。LightGBM 作为一种更先进的梯度增强树基集成方法(Ke et al., 2017),在中国冬小麦产量预测中整体表现最好,值得进一步研究(Cao et al., 2020)。而 MLP 模型显示出良好的泛化能力,与以往的研究一致(Ballesteros et al., 2020; Eugenio et al., 2020),但神经网络的训练时间慢和可解释性差可能会限制其发展。总的来说,集成学习是在田间规模上预测冬小麦产量最有前景的方法。

3.3 高贡献度特征与作物生长之间的联系

特征选择结果和基于 RF 方法的特征重要性分析有助于了解哪些特征对产量变异性影响最大,进而挖掘对作物管理有意义的知识。然而,特征的重要性可能因作物、地点和年份而显著不同。结果表明,在田间尺度上,近端传感特征 NDRE 比天气特征(如 T-avg、T-min 和 RH-avg)对冬小麦产量预测的贡献更大,而降雨相关特征(如 PPT-sum、AWDR 和 SDI)对产量预测的贡献较小。植被指数更重要的原因可能是其较高的分辨率,可以反映田块内部植株氮状态的变化。较高的植被指数值通常与较快的生长速度和较高的生物量积累有关。此外,在作物生长早期,红边位置光谱更多地与营养状况的变化有关,受到土壤背景反射和叶片结构的影响较小(Kanke et al., 2012)。环境特征的空间分辨率较低,主要反映生态点与年际间的变化,因此贡献度也相对削弱。但需要注意的是,本章中只使用了一个植被指数,可能会使植被指数的首位度过高,掩盖了环境特征的贡献。播种至分蘖阶段的干旱胁迫会影响小麦的潜在分蘖能力(Li et al., 2021a)。然而,降雨相关特征的贡献较小,这表明水分不是该地区小麦生长和产量的主要限制因素。T-avg 和 RH-avg 是本研究小麦产量预测的重要特征,且与产量呈正相关。温度通过改变光合作用、呼吸作用、结实率和生长期/物候时长等生理过程来影响作物产量(Das et al., 2018)。然而,较高的温度和较高的相对湿度(特别是在开花期间)与大气蒸汽压差相关的综合效应被发现会对水稻产量产生负面影响(Das et al., 2018; Ekanayake et al., 2021)。本研究中冬小麦的相反发现可能暗示着冬春季低温和干燥空气才是冬小麦生长和产量的限制因素。较高的湿度导致蒸散量减少,从而降低蒸发产生的冷却效果,避免低温对种子产生冷害(Das et al., 2018)。

植被指数 > T-min > T-max 的重要性排序与前人研究建立的中国县级尺度冬小麦产量预测模型一致(Han et al., 2020)。T-min 对冬小麦产量的影响较大,而 T-max/PPT 对冬小麦产量的影响较小,这与 Tao 等(2017)的研究结果一致,他们发现在我国黄淮海平原地区冬季休眠期到返青期最低温的增加总体上有利于大面积的小麦生产。最低温的升高减少了对幼苗/小穗数量的冷害和霜害,导致作物产量增加和增温诱导的粒重增加(Han et al., 2020; Srivastava et al., 2021)。温度升高导致的水分和热胁迫会缩短物候期和灌浆期,导致产量下降(Xu et al., 2021)。T-max 在我们研究中的重要性不高,可能是由于缺乏灌浆期的天气特征,而灌浆期对温度高度敏感(Han et al., 2020)。后续研究应该补充开花期至成熟期的气象数据,尤其注意该时期的极端气候相关特征。

此外,营养生长期的天气信息(P-S)提供了最重要的生长季节内信息。需要注意的是,在 RF、GBDT、XGBoost 和 MLP 过程中性能最差的子集 4 中没有选择 P-S 的特征。潜在的原因可能是子集 4 在 P-S 期间丢失了重要信息。然而,Cao 等(2020)发现,

整个生长季节的天气特征，而不是某个特定阶段，在决定小麦最终产量方面起着至关重要的作用。他们发现的差异可能归因于数据集在大空间尺度上的粗分辨率。

3.4 特征选择方法与特征聚合区间的对比

特征选择方法没有显著降低 7 种机器学习方法的产量预测性能，但 PPCfs 的性能略好于 RFE。先前的研究得出结论，特征选择可以改善或可能不会影响模型性能(Elavarasan et al., 2020; Whitmire et al., 2021)，但仍然建议实现特征选择，因为这将减少计算时间并简化模型。从这个角度来看，特征子集 5 优于其他特征数量最少的子集，这对于平衡复杂性和准确性的季节田间产量预测是可行的。在将特征聚合到三个时间间隔后，就可以获得更多的季节信息。在本研究中，不同时间尺度的特征在 7 种机器学习方法中没有显著差异。然而，Li 等(2019)发现，分解方法(如每月)比聚合方法(即整个生长季节)更好。可以认为，分解方法有助于模型解释，理解特征与产量之间的响应，而聚合方法有利于提高模型的实用性。

3.5 田块尺度冬小麦产量预测模型的潜力

虽然本研究使用的是历史天气数据，但在实际应用中仍有必要使用 S-F 期的天气预报来预测当季的产量。气象预报数据的主要问题是，它们可能无法在如此长时间内提供准确的信息。在这项研究中，使用了一系列覆盖大空间和时间尺度的田间试验数据来预测小麦产量，但未来的验证试验应该特别关注这种方法是否可以应用于新的田块、经历极端天气事件的年份、以及在不同的传感器上。

最佳模型对产量变化的贡献率为 74%~78%，仍有提高的空间。需要进一步努力探索更多数据源的整合，如冠层光谱、结构、热和纹理指数、土壤性质特征、社会经济和管理因素等，因为这些特征在产量预测方面显示出较大潜力(Maimaitijiang et al., 2020; Rigden et al., 2020; Zhang et al., 2019a)。在过去的几年里，无人机平台已经在农场和村级尺度的商业应用中流行起来，有效克服了作物传感器耗时费力的缺点。此外，基于无人机的遥感特征已被大量精准农业相关研究采用(Feng et al., 2020; Zhou et al., 2021)。安装在无人机上的作物传感器可能会整合双方的优势(Jiang et al., 2020)。

随着大量遥感和天气数据的公开，许多研究都集中在使用深度学习技术(如卷积神经网络、长短期记忆神经网络)进行冬小麦产量预测，并取得了很好的准确性(Cao et al., 2021; Wang et al., 2020d)。较高的空间分辨率能够准确获取植被指数的田间与内部变化。在制作田间目标产量图或选择育种目标性状时，可能需要更高空间分辨率的数据。高时间分辨率数据对于及时的农业管理决策也是必要的，例如追肥推荐。因此，空间分辨率的选择应根据使用目的和操作可行性进行平衡。鉴于上述进展，后期研究

应努力开发更准确、更普适的田块规模模型，将更大的数据集与深度学习方法集成在一起。随着先进的人工智能技术的发展，未来可能会开发出一种集实时传感数据采集、数据共享、实时管理处方生成为一体的用户友好型系统，它将改变精准农业的面貌。

4 结论

本章提出了一种基于多年多点近端遥感和气象数据的冬小麦早期产量预测模型。结果表明，集成学习方法(RF, GBDT, XGBoost)取得了最好的性能。此外，特征选择应用于平衡复杂性和准确性。不同的聚合时间间隔可以深入了解生长季节内的天气贡献，尽管在聚合方法之间没有观察到模型性能差异。NDRE、T-avg、T-min和RH-avg是冬小麦产量预测最重要的特征，尤其在播种至拔节期(对气象特征而言)。未来的研究有必要探索更多公开可用的数据源与深度学习算法的集成。最后，应进一步努力验证最佳田间尺度冬小麦产量预测方法的可行性。

第三章 基于多源信息融合的冬小麦氮素营养监测

摘要：植株地上部生物量、植株氮浓度、植株氮积累量和氮营养指数是作物氮素营养监测和诊断的重要指标，作物氮素营养监测模型可以为间接型追氮决策提供支撑。目前冬小麦氮素监测与诊断主要存在时空可迁移性不强的问题，缺乏多生态点、全生育期、多目标的普适性模型。本研究旨在整合全生育期的时间序列信息(不同生育期的冠层光谱数据、播种至特定测试日期的气象数据)，搭建深度学习与进化算法结合冬小麦氮素估测简洁框架，为作物动态监测和精确管理提供高效、智能化解决方案。长短期记忆神经网络特别适用于提取有关作物生长累积的时间序列特征。因此我们使用了长短期记忆、深度神经网络两种深度学习方法进行建模，并以随机森林作为基准模型作比较。基于进化算法的全局优化能力，我们对深度神经网络尝试进行超参数优化、网络训练。同时引入多任务学习对四个指标进行同时预测，希望同时捕捉生物量积累和氮浓度稀释的信息，并对损失权重进行进化优化。从结果上，随机森林和深度神经网络取得较高的精度。但长短期记忆模型和进化算法的性能值得进一步探索。最佳模型没有出现低估和高估现象，说明模型实现了跨生育期、跨年份与生态点、多任务的可靠氮素估测。其中，氮营养指数的估测精度需要进一步提高。利用模型可解释性框架解析发现物候驱动因子对全生育期氮素监测至关重要，水分相关特征对植株氮浓度和氮营养指数估测具有特别贡献。

关键词：冬小麦；氮素监测；深度学习；进化算法

引言

随着人口的增长和对气候变化的担忧，实现联合国可持续发展目标中的粮食安全和环境管理已成为农业面临的挑战(Zhang et al., 2015)。氮肥在作物生产和蛋白质供应中起着至关重要的作用，但氮肥的流失也对环境质量和人类健康造成了巨大的压力(Ren et al., 2022)。通过作物氮素监测和诊断提高氮素利用效率已成为植物表型分析和精准农业研究的前沿。

遥感为估算作物氮素状况提供了一种无损的动态监测手段。基于氮与叶绿素/蛋白质之间的生理相互关系，可以从叶片/冠层光谱反射率中提取氮状态。近几十年来，基于遥感数据开发了两类统计方法种估算作物氮素状况的方法，包括种物理方法和经验方法(Fu et al., 2020)。辐射传输模型(如 PROSPECT、SAIL，即利用物理定律描述冠层反射率光谱变化)具有良好的可解释性和可迁移性，但其在精准农业生物物理变量估

计中的应用可能受到高计算成本和病态反演问题(不同输入参数的反射率光谱相似)的限制(Fu et al., 2020)。基于植被指数的传统经验模型(参数回归)由于其简单性和可接受的性能而被广泛用于作物氮的反演(Fu et al., 2021)。然而,在不同的作物生育期、生态地点和年份中,表现最好的植被指数会有所不同(Li et al., 2014b)。环境条件(天气、土壤)、管理措施、遗传多样性及其相互作用是影响模型可迁移性的潜在因素。一个通用的模型可以为利益相关者提供更方便的解决方案。因此,改善氮营养状态估计模型的时空可迁移性对于支持不同情况下的管理决策和技术推广是必要的。

随着数据收集、数据处理、预测分析和人机交互方面的创新,数据驱动技术在捕捉作物生长与环境之间复杂非线性关系方面的潜力不断扩大。在玉米(Li et al., 2022a)、小麦(Li et al., 2022b)和水稻(Zha et al., 2020)的研究中,多源数据驱动方法已被证明是有效的氮营养监测方法。然而,提高全生育期氮素状态估测的可迁移性仍然十分具有挑战性(Dong et al., 2022)。深度学习技术是目前最先进的智能算法之一,前人研究已用于提高地上生物量估算(Jin et al., 2020)、氮胁迫诊断(Chang et al., 2021)和产量预测(Cao et al., 2021)的精度。长短期记忆(Long short-term memory, LSTM)模型是递归神经网络(即一类具有短期记忆的神经网络)的特定变体。LSTM 模型可以通过其独特的结构捕获长期依赖关系来促进时间序列分析,并提取动态时间特征(Lin et al., 2020)。以往的研究表明,LSTM 在作物管理方面表现良好,如作物制图(Lin et al., 2022)、氮营养诊断(Chang et al., 2021)和产量预测(Lin et al., 2020)。但据我们所知,基于时间序列数据结合深度学习算法的作物生长动态监测和营养状态诊断尚处于起步阶段。

开发一个高效且用户友好的框架对于从表型大数据中挖掘知识至关重要。机器学习和深度学习算法的特征工程和超参数调优依赖于专业知识和经验。进化算法(Evolutionary algorithm, EA),如遗传算法(Genetic algorithm, GA)、蚁群优化算法,已用于优化作物生长监测(Wang et al., 2020a)、叶绿素含量估测(Liu et al., 2021b)和产量预测(Bi and Hu, 2021)的工作流程,能够自动找到最优解。此外,多任务学习(Multi-task learning, MTL)提供了一种同时学习任务(如分类、回归等)的机制,从而事半功倍。在之前的研究中,多任务学习增强了作物产量预测(Lin et al., 2020)和产量与籽粒蛋白质含量同时预测(Sun et al., 2022)时不同任务之间的可转移性。总之,一个结合深度学习、进化算法和多任务学习的精心设计的框架可以简化模型开发的复杂性,并促进知识挖掘和模型解释。

在第三次绿色革命的背景下,作物氮素营养监测需要更加方便、可靠、和智能。如何在中国集约化种植系统中应用智能算法提高小麦氮素动态监测诊断的可迁移性,目前尚存在知识空白。本研究的主要目的是:1)利用多源数据驱动评估深度学习和进化算法在小麦氮营养监测中的可行性;2)在单一模型中同时捕捉生物量积累和氮浓度

稀释在整个生长季的效应；3)为作物适应性管理策略、决策优化和特征工程设计提供见解。

1 材料与方法

1.1 试验设计

本章节的试验设计参见论文第二章 2.2 节试验设计。

1.2 近端传感与气象数据

参见论文第二章 2.3、2.4 节。主要包括近端传感数据、气象数据的获取。本章使用在分蘖期(Tillering)、返青期(Regreening)、起身期(Standing)、拔节期(Jointing)、孕穗期(Booting)、抽穗期(Heading)、开花期(Flowering)和灌浆期(Filling)收集的冠层光谱数据。最终获得了 3054 行植被指数(包括 NDRE, RERVI, ClRE, RESAVI 四种)。

1.3 氮营养数据

以地上部生物量(Above ground biomass, AGB)、植株氮吸收量(Plant nitrogen uptake, PNU)、植株氮浓度(Plant nitrogen concentration, PNC)和氮营养指数(Nitrogen nutrition index, NNI) 4 个与氮素相关的生化或表型性状为氮营养指标。在测试区域测量冠层反射率后,在相同小区的取样区域收割 0.3 m² 的地上部植株(或 20 株代表性的小麦植株)。然后根据小麦的生长阶段将植株分为茎、叶和穗三部分。每个茎、叶和穗样品在 105°C 下烤箱干燥半小时,以迅速停止生理代谢过程,然后在 75°C 下干燥至恒重。样品干燥后的质量即为干物重。子样品研磨后过筛(1mm),用 H₂SO₄-H₂O₂ 消化,然后使用标准凯氏定氮法测定氮浓度。

各氮营养指标的计算公式如下:

$$\text{器官氮吸收量(kg/ha)} = \text{器官氮浓度(\%)} \times \text{干物重(kg/ha)} \quad (3-1)$$

$$\text{植株氮吸收量(kg/ha)} = \text{各器官氮吸收量之和} \quad (3-2)$$

$$\text{地上部生物量(kg/ha)} = \text{各器官干物重之和} \quad (3-3)$$

$$\text{植株氮浓度(\%)} = \text{植物氮吸收量(kg/ha)} / \text{地上部生物量(kg/ha)} \quad (3-4)$$

进行氮素营养诊断时,需要使用临界氮浓度稀释曲线。本研究使用的临界氮浓度稀释曲线为:

$$N_{c1} = 4.15 \times W^{-0.38} \quad (3-5)$$

$$N_{c2} = 4.16 \times W^{-0.41} \quad (3-6)$$

其中, N_c 表示临界植物氮浓度(表示氮充足状态下的氮浓度)。W 表示地上部生物

量(t/ha)。N_{c1} 曲线用于曲周(华北平原地区适用)(Yue et al., 2012a), N_{c2} 曲线用于其他试验点(江苏省适用)(王晓玲, 2017)。江苏省内地点的氮素营养诊断也可以参考 Zhang 等(2022b)最新构建的基于叶面积比的氮浓度稀释曲线。

氮营养指数的计算方法如下:

$$NNI = \frac{N_a}{N_c} \quad (3-7)$$

其中, N_a 表示实测的植物氮浓度。

为了可靠性考虑, 以大于 30%的重复试验间的变异系数作为剔除异常值的标准, 必要时用其他重复的平均值代替异常值。

1.4 深度学习

经典统计分析和特征预处理参见论文第二章 2.6 节数据分析部分。在全生育期氮素监测与诊断的估测模型中, 由于产量预测的研究结果表明特征聚合区间对模型性能影响不显著, 为简便起见, 该章节使用从播种期至特定光谱测试日期的气象数据(即特定生育期前的气象信息)以提取气象特征。与产量预测不同的是, 光谱测试日期之后的气象条件没有计算在内, 因为其后的天气条件并不会影响当前的作物氮营养状态。该章节使用了 12 个气象特征, 其中包括 6 个与温度相关的特征(T-avg:平均气温, T-max-avg:平均最高气温, T-max-max:极端最高气温, T-min-avg:平均最低气温, T-min-min:极端最低气温, AGDD:累积生长长度日), 4 个与水分相关的特征(PPT-sum:总降水量, SDI:降水量的香农多样性指数, AWDR:降水均匀度系数, RH-avg:平均相对湿度), 以及 2 个太阳辐射相关特征(SR-avg:平均太阳有效辐射, SR-sum:总太阳有效辐射)。时间信息可能对全生育期的估计特别重要。因此, 利用从播种期到测试日期的种植后天数(DAP)提供关于小麦生长发育过程的补充信息。即本章共有 17 个特征用于建模。

由于第三章中随机森林算法(Random forest, RF)对产量预测模型的表现较好, 因此本章中 RF 被用作基准模型。同时本章不再进行特征选择与特征聚合区间的比较。

在全生育期的氮素营养监测与诊断模型中, 由于数据量的增加, 同时为了提取有关作物生长累积的时间序列特征, 加入了 LSTM、深度神经网络(Deep neural network, DNN)两种深度学习方法进行建模, 并以 RF 作为基准模型作比较。深度学习在计算机视觉、语音识别、自然语言处理和推荐系统等领域已有广泛应用。然而, 深度学习在作物精确管理上的研究和应用有待进一步探索。

深度学习是由多个处理层组成的计算模型, 能够学习具有多重抽象的数据表示, 具有自动特征提取的关键优势(LeCun et al., 2015)。该章节首先构建一个 5 层(1 个输入层、3 个隐藏层和 1 个输出层)的 DNN, 对小麦氮素状况进行估测。DNN 可以通过

利用多层神经元进行特征学习和信息处理,通过前向传播和反向传播来调整权重值,最终提高预测模型的准确性(Bouwman et al., 2019)。通过门和记忆细胞之间的协作(门控制模式的信息流,记忆细胞回忆神经网络的时间状态),LSTM 可以避免梯度消失问题,在预测具有长期依赖性的时间序列时具有强大的功能(Hua et al., 2019)。该章节构建了简单的 LSTM 神经网络(含一个隐层),从而学习不同生育期积累的生长信息。学习率(控制权重更新速度)、最大迭代数、隐藏层的隐藏单元个数和激活函数(引入非线性因素)是深度学习算法中的主要超参数,通过随机搜索调优。优化器选择的是 *Adam*。自相关分析和序列相关分析在时间序列建模中非常重要。然而,与未知序列不同的是,气象和近端传感时间序列数据具有已知的自相关性(如趋势和季节变化)。因此,我们不再分析时间序列中是否存在自相关性,而是直接使用神经网络来捕捉时间序列中的自相关和其他高级特征。本研究搭建了一个简洁、高效且灵活的框架用于建模分析(<https://github.com/RuanGuojie/Nitrogen-status-estimation>)。为了方便地构建和修改模型架构,而不是重复发明轮子,本研究使用并组装封装良好的包。神经网络模型(DNN, LSTM)是基于 *skorch* 构建的,它是一个可以让 *PyTorch* 像 *scikit-learn* 一样方便使用的库(<https://github.com/skorch-dev/skorch>)。

1.5 进化算法

进化算法是一种基于自然进化原理设计的智能计算方法,包括遗传算法、进化策略和进化规划等(Vikhar, 2016)。这些算法均基于群体智能和适应度选择的思想,通过对种群适应度(Fitness)评估、选择(selection)、交叉(Crossover)和变异(Mutation)等操作,逐步优化种群的适应度,从而找到问题的最优解。进化算法具有全局搜索能力和自适应性,但也存在搜索速度慢的缺点。遗传算法方法是一种广泛使用的模拟达尔文生物进化的遗传和自然选择原则的进化算法(Katoch et al., 2021)。遗传算法包括三个基本组成部分:染色体表示、适应度函数和生物启发式算子(选择、突变和交叉)。本研究使用遗传算法对超参数、神经网络连接权重以及多任务学习损失函数的权重进行优化,以尝试提高模型的智能化程度。遗传算法的使用场景与基本步骤如图 3-1 所示。

利用遗传算法对超参数进行调优时,使用 *Sklearn-genetic-opt* 的 *GAsearchCV* (<https://github.com/rodrigo-arenas/Sklearn-genetic-opt>)来替代 *scikit-learn* 中流行的网格搜索和随机搜索等方法。*PyGAD* 是一个开源的用户友好的 Python 库(<https://github.com/ahmedfgad/GeneticAlgorithmPython>),用于开发遗传算法和优化机器学习算法,本研究使用 *PyGAD* 代替梯度下降法训练神经网络,优化神经网络的连接权重。多任务学习能够实现同时预测 AGB, PNU, PNC 和 NNI。本研究利用 *skorch* 构建了多任务神经网络框架。多任务学习本质上是一个多目标问题,因为不同的任务可

能会冲突，需要权衡(Sener and Koltun, 2018)。恰当地分配不同任务的损失权重成为多任务中的关键问题，因为不同的方法可能产生不同的结果。因此，本研究利用 *Scikit-opt* (<https://github.com/guofei9987/scikit-opt>)的遗传算法进一步优化不同任务的均方误差(MSE)损失权值(λ)(等式 3-8)。 λ 值在(0,10]范围内优化，增量为 1。为方便起见，本研究所使用的遗传算法超参数均为默认值。遗传算法的运行情况示例如图 3-2 所示。

Total loss = λ_1 MSE_{AGB} + λ_2 MSE_{PNC} + λ_3 MSE_{PNU} + λ_4 MSE_{NNI}

(3-8)




图 3-1 遗传算法的使用场景与具体流程

Fig. 3-1 Application scenario and specific process of genetic algorithm

AGB: 地上部生物量; PNC: 植株氮浓度; PNU: 植株氮吸收量; NNI: 氮营养指数; RF: 随机森林; DNN: 深度神经网络; LSTM: 长短期记忆神经网络

AGB: Above ground biomass; PNC: Plant nitrogen concentration; PNU: Plant nitrogen uptake; NNI: Nitrogen nutrition index; RF: Random forest; DNN: Deep neural network; LSTM: Long short-term memory




图 3-2 遗传算法的运行示例

Fig. 3-2 Operation examples of genetic algorithm

DNN-GA: 基于遗传算法优化神经网络超参数; DNN-PyGAD: 基于遗传算法训练神经网络; DNN-MTL: 基于遗传算法优化多任务学习任务权重

DNN-GA: optimization of neural network hyperparameter based on genetic algorithm; DNN-PyGAD: training neural networks based on genetic algorithms; DNN-MTL: Optimizing multi-task learning task weights based on genetic algorithms

1.6 模型评估

本章使用决定系数(R^2)和均方根误差(RMSE)来评估回归模型的性能(参见第二章 2.6.5 节)。在氮素监测与诊断模型的评估中, 因为不同氮素营养指标之间的单位不相同, 为了能够互相比较, 加入相对均方根误差(rRMSE)(公式 3-9)来评估模型表现。与此同时, 氮素营养的诊断是分类问题, 为了评估氮素诊断的精度, 计算分类评估指标: 准确度和 Kappa 系数(公式 3-10~3-12)。用 NNI 值诊断小麦氮素状况时, 诊断阈值为 $NNI < 0.95$ (氮亏缺), $0.95 \leq NNI \leq 1.05$ (氮充足), $NNI > 1.05$ (氮盈余)(Cao et al., 2018)。

Kappa 统计值 < 0.4, 0.4-0.6 和 > 0.6 分别表示弱, 中等和强一致性。

$$rRMSE = \frac{RMSE}{\bar{y}} \times 100\% \quad (3-9)$$

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (3-10)$$

$$Kappa = \frac{Accuracy-P_e}{1-P_e} \quad (3-11)$$

$$P_e = \frac{(TP+FN) \times (TP+FP) + (FN+TN) \times (TN+FP)}{n^2} \quad (3-12)$$

其中 $\bar{y}$ 为指标的平均值, P_e 是期望一致性。缩写 TP, TN, FP 和 FN 分别代表真正类, 真假类, 真负类和假负类。

1.7 模型解释

特征重要性分析在不同的时空尺度和输入特征中会产生很大变化, 因此关键任务是实现稳定可信的模型可解释性。一种被称为 SHAP (SHapley Additive exPlanation) 的博弈论方法可以解释任何机器学习模型的结果(<https://github.com/slundberg/shap>)。它使用来自博弈论及其相关扩展的经典 Shapley 值链接最佳信用分配与本地解释 (Lundberg and Lee, 2017)。SHAP 值是解释机器学习模型的强力工具, 因为它们提供了每个特征如何对模型输出做出贡献的清晰直观的解释。本研究使用 SHAP 值来解释最优模型, 同时与基于随机森林的特征重要性 (参见第二章 2.6.6 节模型解释) 进行比较, 从不同视角解释模型。

2 结果与分析

2.1 不同氮指标和特征的变异性

对于完整数据集 ($n=3054$), AGB、PNC、PNU、NNI 和 NDRE (此处视为光学表型) 之间的关系如图 3-3 所示。总体而言, AGB 与 PNC 呈负相关 ($r = -0.86 \sim -0.36$), 与 PNU ($r = 0.79 \sim 0.93$)、NNI ($r = 0.06 \sim 0.61$) 呈正相关。NDRE 与 AGB ($r = 0.34 \sim 0.79$)、PNU ($r = 0.57 \sim 0.84$)、NNI ($r = 0.25 \sim 0.79$) 呈正相关, 与 PNC ($r = -0.62 \sim 0.08$) 无正相关或负相关。散点图显示了 NDRE 与氮指标之间的复杂非线性关系, 表明基于植被指数的简单模型在反演不同地点、年份、施氮量处理和生长阶段的氮状况时是不可靠的。作物生长过程中存在 AGB 升高、PNC 降低的现象。在完整数据集中, AGB 的变异程度最高, CV 为 75.33% (Mean=6114.64 kg/ha), 其次是 PNU (CV=62.43%, Mean=109.87 kg/ha)、PNC (CV=40.89%, Mean=2.20%) 和 NNI (CV=31.49%, Mean=0.94)。氮指标的显著变异




图 3-3 氮素指标与 NDRE 之间的关系

Fig. 3-3 The relationship between wheat nitrogen indicators and NDRE

性使数据集能够很好地用于估测小麦氮素状况。

图 3-4 显示了不同生育期(测试期)和施氮量对小麦氮素状况变化的影响。其中将施氮量划分成 5 个水平:对照(0 kg N ha⁻¹)、低施氮量(0~50 kg N ha⁻¹)、中施氮量(50~100 kg N ha⁻¹)、高施氮量(100~150 kg N ha⁻¹)和超高施氮量(>150 kg N ha⁻¹)。由于没有足够的数据来量化基因型因素(如面筋类型、产量构成要素和氮肥利用率),因此没有单独考虑小麦品种的影响。从图 4 可以看出,AGB、PNU 和 NDRE 随着生长过程的增加而增加,PNC 随着生长过程的降低而降低,而 NNI 没有明显变化。NDRE 在生长后期和高氮水平时出现明显饱和。在生殖生长阶段,除 PNC 外,各表型波动较大,这可能与复杂的天气和土壤条件对小麦生长的影响有关。当有更多的变化时,氮营养状态的可预测性增加,但同时也需要更多的特征来提供信息。施氮量对 AGB、PNC、PNU 和 NNI 均有显著的正向影响,证明施氮对小麦生长和营养状况的重要性。

5 个代表性气象特征(T-avg、AGDD、SR-avg、PPT-sum、DAP)的描述性统计如表 3-1 所示。虽然变异程度较低(一般小于 30%),但能很好地补充生态地点、生长阶段和年份差异所带来的环境变异信息。




图 3-4 不同生育期和施氮量对小麦氮素状况变化的影响

Fig.3-4 Effects of different growth stages and nitrogen application rates on nitrogen status of wheat

2.2 深度学习与进化算法的模型性能

氮营养状态估测在测试集上的模型性能如图 3-5 所示(由于本研究侧重于模型泛化, 因此没有显示训练集的模型性能)。RF 在小麦氮素状态估计中表现最好($R^2 = 0.83 \sim 0.97$, $rRMSE = 11.65\% \sim 19.27\%$)。DNN 与 RF 具有相似性能($R^2 = 0.83 \sim 0.96$, $rRMSE = 12.17\% \sim 20.34\%$)。LSTM 表现较 RF 和 DNN 差, R^2 值为 $0.76 \sim 0.93$, $rRMSE$ 值为 $14.87\% \sim 25.65\%$ 。为了测试深度学习和进化算法集成的性能, 选择 DNN 进行进一步研究。DNN-PyGAD(基于 PyGAD 的进化神经网络)的性能较 DNN 有所下降($R^2 = 0.62 \sim 0.89$, $rRMSE = 19.61\% \sim 31.44\%$), 这表明进化算法可能不适合代替梯度下降法用于训练神经网络。在用遗传算法优化超参数时, DNN-GA 与 DNN 的性能相似($R^2 =$

表 3-1 五个代表性气象特征的描述性统计

Table 3-1 The descriptive statistics of five representative meteorological features

地点 Site	指标 Indicators	T-avg (°C)	AGDD (°C)	SR-avg (MJ m ⁻²)	PPT-sum (mm)	DAP (day)
曲周 Quzhou (n=444)	平均值 Mean	3.73	1108.95	9.30	66.86	189
	最大值 Max	5.40	1478.31	10.39	104.90	213
	最小值 Min	2.17	789.77	7.87	17.40	167
	变异系数 CV	23%	17%	8%	42%	7%
淮安 Huai'an (n=216)	平均值 Mean	6.29	1183.93	8.46	132.55	158
	最大值 Max	7.65	1639.10	9.49	204.70	191
	最小值 Min	5.33	784.70	7.56	85.10	118
	变异系数 CV	13%	24%	7%	31%	15%
泗洪 Sihong (n=270)	平均值 Mean	7.15	1390.46	9.21	223.18	168
	最大值 Max	8.66	1878.15	10.19	271.10	196
	最小值 Min	5.85	938.45	8.11	157.70	133
	变异系数 CV	13%	21%	7%	17%	11%
兴化 Xinghua (n=1800)	平均值 Mean	7.14	1193.81	8.34	261.90	150
	最大值 Max	9.76	2000.30	10.16	405.10	194
	最小值 Min	4.56	662.10	6.07	147.90	114
	变异系数 CV	17%	26%	12%	22%	13%
如皋 Rugao (n=324)	平均值 Mean	6.79	1062.86	8.60	250.01	141
	最大值 Max	8.23	1348.35	9.84	354.90	183
	最小值 Min	5.93	547.80	7.91	99.90	68
	变异系数 CV	11%	25%	7%	34%	23%
总计 Total (n=3054)	平均值 Mean	6.55	1184.27	8.59	219.71	156
	最大值 Max	9.76	2000.30	10.39	405.10	213
	最小值 Min	2.17	547.80	6.07	17.40	68
	变异系数 CV	24%	25%	11%	41%	16%

0.81~0.97, rRMSE = 12.46%~21.35%)。究其原因,可能是本研究构建的 DNN 只包含较少的超参数,因此随机搜索足够应对。DNN-MTL 也具有与 DNN 相当的性能($R^2 = 0.81\sim0.96$, rRMSE = 12.42%~22.11%)。这一结果证明了同时预测四个不同氮指标的可行性。

2.3 不同氮营养指标间的模型性能

如图 3-5 所示,氮营养估测模型的平均性能为 AGB > PNC > PNU > NNI。NNI 估测性能相对较低可能与其低变异性有关。另一个可能的解释是,不同生长阶段对 NNI 的影响较小(图 3-4)。损失权重可以影响 DNN-MTL 中不同任务的性能。优化前,损

失权重设置为相同值[1,1,1,1]。经过 5 次遗传算法优化, AGB、PNC、PNU 和 NNI 的平均最优损失权重分别为[9.8, 9, 9.2, 9.8]。然而, 权重优化后, 整体模型的性能并没有提高。虽然 AGB 和 PNC 的变化趋势不一致, 但相似的权重比例可能表明四个指标之间几乎没有冲突。因此, 为了方便起见, 建议使用相同的权重, 但如果需要(遇到差异较大的不同任务), 本研究的框架是可以自定义或自动优化损失权重的。




图 3-5 基于测试集的小麦氮素状况估计模型性能

Fig. 3-5 Effects of different growth stages and nitrogen application rates on nitrogen status of wheat

RF: 随机森林; DNN: 深度神经网络; LSTM: 长短期记忆神经网络; DNN-PyGAD: 基于 PyGAD 的进化神经网络; DNN-GA: 基于遗传算法优化超参数的神经网络; DNN-MTL: 基于多任务学习的神经网络。

RF: Random Forest; DNN: Deep neural network; LSTM: Long short-term memory neural network; DNN-PyGAD: Evolutionary neural network based on PyGAD; DNN-GA: Neural network based on genetic algorithm to optimize hyperparameters; DNN-MTL: A neural network based on multi-task learning

基于 NNI 的氮营养诊断混淆矩阵如图 3-6 所示。基于 RF 的氮营养诊断准确率 (accuracy = 0.81, Kappa = 0.69) 略优于 DNN (accuracy = 0.81, Kappa = 0.68), 诊断结果与实际结果显著一致 (Kappa > 0.60)。从诊断结果来看, 由于试验中设置了不同的氮素处理, 大部分小区处于氮亏缺和氮盈余状态。由于处于氮充足状态下的样本较少, 这可能导致样本不平衡, 影响实际应用中的诊断结果。




图 3-6 基于 NNI 的氮营养诊断混淆矩阵(基于 RF 和 DNN)

Fig. 3-6 Confusion matrix of NNI diagnosis based on Random Forest and Deep Neural Network.

注：图中数字表示样本数

Note: The numbers in the figure represent the number of samples

为进一步分析氮营养指标实测值与预测值之间的关系，生成了基于 RF 模型的散点图，如图 3-7 所示。在不同施氮状态下，没有出现显著高估或低估的现象，表明 RF 能很好地捕捉到整个生育期、不同施氮处理和不同品种的氮营养状态时空变化。




图 3-7 氮营养指标预测值与实测值关系的散点图(基于 RF)

Fig. 3-7 Scatter plots of measured and predicted nitrogen indicators based on Random Forest models

2.4 基于 SHAP 值的模型解释

基于 SHAP 值的 RF 模型的模型可解释性如图 3-8 所示。对于 AGB 估测，贡献最大的特征是 AGDD、SR-sum、DAP、T-min-min 和 SDI，而对于 PNC 估测，贡献最大的特征是 AGDD、AWDR、NDRE、CI_{RE} 和 RERVI。对于 PNU 估测，贡献最大的特征是 AGDD、RESAVI、CI_{RE}、NDRE 和 RERVI，而对于 NNI 估测，贡献最大的特征是 T-min-avg、AWDR、RESAVI、RERVI 和 NDRE。这些结果表明，AGDD 是一个信息价值量最大的气象特征。有趣的是，AWDR 对 PNC 和 NNI 估计的解释有显著贡献，这表明氮浓度估计受到水分条件的影响。RESAVI 是最重要的光谱特征。具有累积效应的特征(如 AGDD、SR、DAP)对小麦氮素状态估计有较大影响(除 NNI 外)，表明 RF 成功捕获了代表不同作物生育期的关键信息。总体而言，温度相关特征和植被指数比降水相关特征更为重要。




图 3-8 基于 SHAP (SHapley Additive exPlanations)的随机森林模型可解释性

Fig. 3-8 Model interpretability of the Random Forest model based on SHapley Additive exPlanations

注：SHAP 值离零越远(正或负)，相应的特征贡献越大。点的蓝色越深，特征值越高；橙色越深，特征值越低。

Note: The farther the SHAP value was from zero, the greater (positive or negative) the corresponding feature contribution. The darker the blue of the dot, the higher the feature value; the darker the orange, the lower the feature value.

为了与基于 SHAP 值的模型可解释性作对比，本章继续分析了估测四个指标时的随机森林特征重要性(图 3-9)。有趣的是，AGDD 仍然是估测 AGB、PNC 和 PNU 最重要的特征，AWDR 是估测 NNI、PNC 的重要特征。充分说明 SHAP 值和特征重要性都是分析特征贡献度的有力工具。而部分相关性较高的特征(如 T-max-avg)对模型预测的贡献不高，说明这些因素可能不是氮素营养状态的限制因子。综合来说，多视角的分析可以提高模型可解释性的准确度和可信任度。




图 3-9 特征重要性与相关性热图

Fig. 3-9 Feature importance and correlation heatmap

3 讨论

3.1 深度学习与进化算法框架的可行性

本章建立了基于机器学习和深度学习的小麦氮素状态估测模型。最主要的 4 个模型解释了氮营养状态 80%以上的变化，表明机器学习和深度学习是一种很有前途的氮状态估测建模技术。RF 的优势与先前报道的小麦(Li et al., 2022b)、水稻(Zha et al., 2020)和玉米(Li et al., 2022a)上氮营养监测和诊断的研究结果一致。然而，DNN 和 LSTM 在本研究中并没有优于 RF。Khaki 等(2019)提出了用于作物产量预测的 CNN-LSTM 框架，该框架优于 RF 和 DNN。在基于 LSTM 的县级尺度作物产量预测研究中，也观察到了类似的结果(Lin et al., 2020)。更重要的是，LSTM 在极端气候年份等更复杂的环境条件下表现更好。相反地，也有一些研究表明 LSTM 并没有改善模型性能(Liu et al.,

2021c; Sun et al., 2022)。深度学习的不确定性能需要通过合适的神经网络架构、输入特征和关键超参数等因素来进一步研究。虽然 LSTM 在氮素监测中的应用不如在产量预测中的应用普遍,但其性能值得进一步探索,因为 LSTM 的工作机制特别适合提取生育期内作物生理特性的规律性变化。

基于进化算法的全局搜索能力和深度学习的自动特征提取能力,将这两种智能算法结合起来已经成为一个有潜力的课题。Wang 等(2020a)开发了一种基于混合遗传算法的反向传播神经网络来提高玉米生长和产量监测的精度,其中展现了比纯神经网络更可靠的性能。Bi 和 Hu (2021)提出了一种遗传算法辅助的深度学习方法用于作物产量预测,并称该方法在收敛速度和预测精度方面优于基于梯度的方法。遗传算法在优化 LSTM 超参数方面也表现良好(Kara, 2021)。本研究采用遗传算法分别优化神经网络的超参数、连接权重(用于训练)和损失函数权重(用于多任务学习)。总的来说,遗传算法并没有为我们的数据提供一个寻找最优解决方案的好的替代方案。一方面,遗传算法将增加操作成本和时间。另一方面,遗传算法在小规模数据集上可能无法提高性能。然而,遗传算法可以作为一种新的尝试,可以在追求模型性能的同时,探索合适的应用场景。更重要的是,遗传算法可以帮助非计算机科学专家(如农学家和气象学家)从复杂的参数优化中解放出来,专注于挖掘有价值的领域专家知识。遗传算法是解决农业管理中常见的大规模、多目标优化问题的理想方法。因此,遗传算法有望可以快速解决多目标优化场景,参数化复杂的科学问题,从而提供更深入的见解。

3.2 智慧作物管理中的模型可迁移性

由于冠层结构和氮素分配的动态变化,以往的研究确定了不同的最佳时期来监测作物生长和氮素状况。如 Wang 等(2022)发现抽穗期是 AGB 预测的最佳阶段。Qiu 等(2021)研究发现,NNI 的估测在灌浆期和拔节早期表现最好。但是,氮素监测的最佳时间窗口可能随地点、年份、作物品种、植被指数等因素而变化。为了克服特定生长阶段和特定地点的氮素状况估测模型的缺点,本研究将不同生长阶段和不同年份地点的近端遥感和气象数据集成到小麦氮素状况监测和诊断模型中。结果表明,信息融合是提高不同空间和时间氮状态估测可迁移性的有效策略,与 Wang 等(2022)的研究结果一致。拔节期是冬小麦追肥推荐的关键生育期。但拔节期持续时间长,不同生态区小麦的物候过程也不一致。本研究提出的氮估测模型具有较高可迁移性,可以适用于不同空间和时间内的大规模应用,使其能够更好地指导精准施肥。

不同氮素指标的预测精度在以往研究中存在差异。本研究中 AGB 估计的准确率优于 NNI,这与玉米(Li et al., 2022a)和水稻(Zha et al., 2020)氮诊断的相关研究一致。一致的发现表明,直接估计 NNI 是相当具有挑战性的。潜在的影响因素包括氮浓度稀

释曲线的不确定性、样品不平衡和数据质量。PNC 和 AGB 的估算精度较高,表明间接氮诊断策略可能是较好的选择(即先估算 AGB 和 PNC,再计算 NNI)。值得注意的是,本研究发现大部分模型中 PNC 的估测精度略高于 PNU,可能是因为 PNC 存在比 PNU 更明显的动态变化,因此可估测性更高。本研究首次采用多任务方法估算小麦氮素状况。多任务学习不仅能同时估测四个氮素指标,而且性能可靠,较好地提升了模型的实用性。多任务学习的优势也在之前的植物表型研究中也得到了充分的体现(Sun et al., 2022)。

模型性能和复杂性之间的权衡是植物表型监测和实时作物管理的主要问题。一方面,一些研究通过多源数据融合改进了氮状态估测的精度(Huang et al., 2019; Li et al., 2022a),与此同时也增加了信息获取(如土壤、荧光和管理数据)的成本。另一方面,非参数化模型较难开发和广泛应用。因此,开发一个简洁高效的框架/工具似乎更有价值。通过更新数据(数量和来源)和模型架构(如为无人机图像增加卷积神经网络层),可以扩展框架以面对其他研究领域的挑战,更有利于促进作物科学与人工智能的跨学科交叉融合。

3.3 模型重要特征的贡献度

在相关研究中,经常使用特征重要性来分析特征的贡献。Li 等(2022a)报道 SDI 是估测玉米 PNU 和 NNI 最重要的气象特征,而 AWDR 和 PPT 分别被认为是估测 PNC 和 AGB 最重要的气象特征。Li 等(2022b)发现温度相关特征对小麦 AGB 估算更为重要,而水分相关特征对 PNU 和 NNI 估算更为重要。在这两项研究中,GDD 的贡献较小,这可能是因为只使用了单一生长期的数据。虽然不同研究中特征的贡献不同,但令人惊讶的是,与水相关的特征(特别是 AWDR)对于估计 PNC 和 NNI 的重要性在本研究中再次得到了证明。大量研究表明,水分胁迫可以提高小麦籽粒蛋白含量(Zhao et al., 2020a),后者取决于灌浆期植株氮的积累及其向籽粒的转移。可以推测,在较湿润的地区或年份,充足的降水增加了土壤微生物生物量,从而加快了氮矿化、硝化和反硝化的速度,加剧了氮损失,最终降低了小麦 PNC 和氮素利用率(Hou et al., 2021)。换句话说,小麦 PNC 或籽粒蛋白质含量可以通过作物灌溉调度来调节。

在 AGB 估测中,AGDD 和 SR-sum 的重要作用证实了温度和太阳有效辐射是生物量积累的主要驱动因素。温度和光周期是控制小麦物候发育的两个主要因素。因此,正如 Li 等(2022c)所强调的,建议将反映物候信息的特征纳入到全生育期生物量中估算模型以捕捉季节碳动态。热或冷胁迫会降低光合速率和绿叶面积指数,导致生物量增长下降(Liu et al., 2019)。水分亏缺降低了植物的蒸腾效率和土壤水分有效性,从而降低了生物量的积累(Fang et al., 2021)。然而,本研究中 T-min、T-max 和 AWDR 对

AGB 估测影响较小。其根本原因可能是小麦对环境胁迫的反应有一个特定的敏感时期。在生殖生长后期,由于氮素从营养器官转移到生殖器官,叶绿素与氮素之间的关系解耦。因此,植被指数在全生育期氮状态估测中的重要性下降。SAVI 可以在生长早期缓解土壤背景的影响(Yao et al., 2014)。红边波段可以防止冠层闭合后光谱指数饱和现象(Li et al., 2014a)。因此,建议 RESAVI 作为跨生长阶段氮估测模型的首选植被指数。

作为更大的数据科学生命周期的一部分,模型解释提供了来自机器学习模型的见解。它不仅增强了利益相关者对风险和投资管理的认识,而且为易于理解的规划和决策提供了信息。值得一提的是,特征的贡献包括作物的地理适应(内在的)和对气候变化的响应(随机的)。在区分气候趋势、波动和多种胁迫相互作用对氮素状况的影响方面的预期进展将为适应管理策略提供信息(例如,改变种植日期,选择短生育期品种)。进一步研究应探索数据驱动预测与领域专家知识的整合,如将深度学习与知识图谱相结合,以更好地解决深度学习的“黑箱”问题。最后,将形成一个良性循环,促进精确表型研究和气候智能型农业管理。

4 结论

本章基于深度学习-进化算法框架估测 AGB, PNC, PNU 和 NNI。将小麦关键生育期近端传感数据和相应气象特征输入模型。结果表明, DNN、RF 和 DNN-MTL 在估算冬小麦氮营养状态方面都具有良好的准确性。生物量积累和氮浓度稀释在整个生长季的效应可以在一个单一模型中成功捕捉。SHAP 值显示,累积效应特征对 AGB、PNC 和 PNC 估计有显著影响,AWDR 对 PNC 和 NNI 估计有显著影响。综上所述,本研究系统分析了数据融合、深度学习、进化算法和多任务学习框架对小麦全生育期氮素状态可迁移性估计的影响。这些发现可能为基于数据驱动方法的作物氮监测和诊断提供更准确、智能和可解释的解决方案。相关模型可以为基于产量预测与氮素营养估测的追氮决策提供支撑。

第四章 基于多源信息融合的冬小麦氮肥推荐算法构建

摘要：最优施氮量是指导作物精确氮素管理的重要指标，但如何结合最优施氮量、作物生长状态、气象与土壤多源信息做出动态精准施肥决策仍然存在知识空白。本研究提出了作物最优追氮量的概念，并基于随机森林对最优追氮量进行预测，从而构建直接型的氮肥推荐算法。进一步基于多点实地验证试验评估该算法的农艺、经济与环境效益，并与农户常规施氮量、区域专家推荐施氮量、基于产量预测与氮素监测的间接型氮肥推荐算法进行对比。最后，通过多目标进化优化分析氮肥推荐算法的合理性。研究结果表明，最优追氮量算法具有良好的模型性能（随机森林预测 $R^2=0.59\sim0.72$, $RMSE=39.63\sim40.48\text{kg/ha}$ ），植被指数、最高温和太阳辐射是预测最优追氮量的重要特征。验证试验结果表明，与农户管理措施相比，最优追氮量算法能够在不造成产量与经济损失的前提下，减施氮肥 18.9%~48.4%，提高偏生产力 12.99%~46.09%，同时分别减少活性氮损失与温室气体排放 20.56~47.24%、16.34%~40.45%。最优追氮量的平均推荐值为 96kg/ha，位于多目标优化追氮量的合理阈值 32~118 kg/ha 内，且能够随基肥量进行智能调整，充分验证了最优追氮概念的准确性与普适性。本章形成了从追氮推荐算法到实地验证评估与决策优化的一体化框架，为作物精准管理提供了可持续性解决方案。

关键词：最优追氮量；氮肥推荐算法；效益评估；多目标优化；冬小麦

引言

氮是作物生长必需的三大营养元素之一，氮肥对于作物产量、品质形成有关键影响。然而，传统的氮肥管理策略面临过量施氮、社会经济问题复杂、环境污染严重等一系列问题，制约着农业绿色高效发展(巨晓棠，谷保静，2014)。精确氮素管理技术是在作物-环境-管理的多学科知识交叉与农业信息技术赋能下，在作物生长发育过程中对氮素需求进行精准调控的技术，旨在提高资源利用效率与生产效率，实现经济与生态环境效益的双赢。精确氮素管理对于保障粮食安全，助力实现农业生产现代化、智慧化、绿色化具有广阔的前景和意义。

作物精确氮素管理具有不同的路径和策略。基于作物营养需求和养分平衡原理，前人已经发展出不同的氮肥推荐方法指导管理决策，主要包括目标产量法、肥料响应函数法、基于土壤测试的氮素管理、基于植株测试的氮素管理、基于生长模型的氮素管理、基于遥感和作物传感器的氮素管理等几种类型(Morris et al., 2018; 李克亮，周

志艳, 2019)。其中基于遥感和作物传感器的氮肥推荐算法具有无损监测、省时省力的特点, 在实时实地的作物精确管理中发挥着重要作用。Raun 等(2002)最初根据基于近端传感的响应指数(Response Index, RI)提出了著名的氮肥优化算法(Nitrogen Fertilization Optimization Algorithm, NFOA), Holland 和 Schepers (2010)提出基于充足指数(Sufficiency Index, SI)的推荐算法, 弥补了 NFOA 算法需要设置参考条带的不足。在这两种主流算法的基础上, 后续的研究进行了改进和优化, 将算法的使用场景拓展到不同的传感器、遥感平台和作物类型(Lu et al., 2020b; Thompson and Puntel, 2020; Wang et al., 2019; Yang et al., 2022; Zhang et al., 2022a)。然而, 两种基于植被指数的推荐算法虽然简单实用, 但没有充分考虑气象、土壤等环境因素对施氮量的影响, 尤其是施肥之后的环境状况。降水量、温度、土壤质地等多方面因素会影响作物对氮肥的吸收、土壤氮循环等关键的生理生化过程, 直接影响肥料利用率与最终产量(Ransom et al., 2021)。因此, 如何综合作物、气象与土壤的多源信息进行管理决策, 成为精准施肥领域的热点与难点问题。

提高氮肥推荐算法的准确性与普适性, 主要有纳入重要特征变量与提高建模技术两种思路。在冬小麦(Walsh et al., 2013)、玉米(Bea et al., 2018b; Fassa et al., 2022)等重要作物上, 前人的研究通过在原有算法的基础上引入土壤、天气特征, 初步改进了算法的性能。得益于人工智能技术在农业领域的加速渗透与应用, 机器学习被越来越多地应用到施肥决策领域, 以帮助施肥量的动态精准调整。施氮量的精准推荐存在间接型和直接型两种策略。间接型策略是指先预测一个中间变量(如产量、氮营养指数), 然后通过定量关系计算出施氮量。直接型策略则是指直接估测最优施氮量。机器学习技术在两种策略的使用都取得了一定的研究成果。在间接型策略上, Wen 等(2021)和 Wang 等(2021b)通过随机森林预测作物产量, 再通过情景分析计算特定地点的经济最优施氮量(Economical optimal nitrogen rate, EONR); Dong 等(2020)基于反向传播神经网络预测产量, 进一步通过非线性规划计算精准施肥量。在直接型策略上, 前人使用了不同的机器学习方法融合多源信息对油菜(Wen et al., 2022)、玉米(Qin et al., 2018; Ransom et al., 2019)的 EONR 进行直接预测。Colaço 等(2021)系统地对比了目标产量法、响应函数法、基于机器学习的直接型与间接型推荐算法的表现。尽管以上的研究都证明了信息融合和机器学习技术支持下的数据驱动策略在氮肥推荐算法上的可行性, 但如何结合最优施氮量与田块内部的作物生长差异进行精准施肥仍有待研究。

精确氮素管理技术到底能不能兼得社会效益与生态环境效益, 是多领域备受关注的问题。以往的研究对基于传感器的氮肥推荐算法在产量与氮肥利用率(Cao et al., 2017a; Cordero et al., 2019)、温室气体排放(Lapidus et al., 2022)、活性氮损失(Li et al., 2016)、生命周期评估(Zhang et al., 2023)、经济可行性与风险(Karatay and Meyer-Aurich,

2020; Pedersen et al., 2021)等多种视角进行了大量验证与分析。研究大都表明,与常规管理方式相比,精确氮素管理能够在不影响作物产量与经济利润的前提下,显著降低氮肥投入,提高氮肥利用率,并减少氮污染。此外,研究者们常用多目标进化优化(Khoshnevisan et al., 2020; Kropp et al., 2019; Mousavi-Avval et al., 2017; Zheng et al., 2013)、模糊线性规划(Ji et al., 2020)等方法对资源消耗、经济和环境效益等多目标进行权衡,协同实现优化施肥量。多目标进化优化作为强有力的优化工具,在农业资源配置、农业区划等复杂决策问题上具有明显优势(West, 2019)。因此,综合氮肥推荐算法的效益评估与多目标优化的框架,可以从自下而上与自上而下两个不同方向上判断管理方案的可行性,为精准氮素管理的可持续发展提供新范式。

综上,本章节的研究目标是:1) 构建基于机器学习融合作物、气象与土壤信息的新型氮肥推荐算法;2) 开展直接型与间接性追氮策略的验证试验与效益评估;3) 对验证试验追氮量进行多目标优化求解与合理性验证。

1 材料与方法

1.1 试验设计与数据获取

本章节的试验设计参见论文第二章 2.2 节试验设计。数据获取参见论文第二章 2.3、2.4 节。用于建模的数据主要包括近端传感数据和气象数据。本章使用拔节期的冠层光谱数据。为了方便计算,历史气象数据根据月份划分,计算从 10 月至来年 5 月(大致为冬小麦生长季)的统计值。考虑到施氮量与土壤肥力状况密切相关,本章加入试验点土壤基础属性数据,分析土壤因素对优化施氮量的影响,主要包括土壤有机质含量(Soil organic matter, SOM)、总氮(Total nitrogen, TN)、速效磷(Available phosphorus, AP)和速效钾(Available potassium, AK)含量。本章用到的土壤数据仅反映基本地力水平,并不能提供田块内部的土壤变异信息。

1.2 直接型冬小麦追氮推荐算法的构建

本章节构建了基于随机森林算法(参见第二章 5.4 节)的直接型预测最优追氮量(Optimal topdressing nitrogen rate, OTN)的推荐算法。具体步骤如下:

第一步是通过肥料效应函数确定每年每试验点的最优施氮量,包括经济最优施氮量(EONR)和产量最优施氮量(Optimal nitrogen rate for yield, YONR)。肥料效应函数以施氮量为横坐标,经济收益(公式 4-1~4-3)或产量为纵坐标,分别采用线性加平台函数(Linear-plateau)和二次函数(Quadratic)拟合。线性加平台函数利用 IBM SPSS Statistics 25 拟合,拐点所对应的施氮量确定为最优施氮量。二次函数利用 Microsoft Excel 拟

合, 最高点所对应的横坐标确定为最优施氮量。同时将 300kg/ha 设定为上限值。

$$\text{氮肥成本} = \text{施氮量} \times \text{氮肥单价} \quad (4-1)$$

$$\text{收入} = \text{小麦产量} \times \text{籽粒单价} \quad (4-2)$$

$$\text{经济收益} = \text{收入} - \text{氮肥成本} \quad (4-3)$$

其中 2013 年之前的小麦价格数据来源于《中国农产品价格年鉴》, 2013 年之后的小麦价格结合《中国统计年鉴》的价格指数计算; 氮肥的价格数据来源于《中国物价年鉴》和《中国价格统计年鉴》。

注: 其他成本投入如人工成本、农药、农业机械因素并未纳入考虑。

第二步是确定每个小区的理论基肥量(Theoretical base N rate, TBN), 计算公式为:

$$\text{TBN} = (\text{PNU}_J - \text{PNU}_0) / \text{NUE}_B \quad (4-4)$$

其中 PNU_J 为拔节期植株吸氮量, PNU_0 为对照组平均植株吸氮量, NUE_B 为基肥的氮肥利用率, 计算方法为:

$$\text{NUE}_B = (\text{PNU}_E - \text{PNU}_0) / \text{ABN} \quad (4-5)$$

其中 PNU_E 为实验组平均植株吸氮量, ABN 为实际基肥量(Actual base N rate), 即每个试验小区播种前施下的基肥量。对照组的理论基肥量设置为 0。每一组试验都有对应的基肥利用率, 计算后所有试验的平均基肥氮肥利用率为 42%。

第三步是确定每个小区的最优追氮量, 即最优施氮量减去理论基肥量。基于线性加平台函数拟合的经济和产量最优追氮量分别记为 EOTN-L , YOTN-L ; 基于二次函数拟合的经济和产量最优追氮量分别记为 EOTN-Q , YOTN-Q 。

第四步是通过机器学习方法直接预测最优追氮量, 并进行模型评估。以随机森林回归(RF)为建模方法, 线性回归做基准模型。决定系数(R^2)和均方根误差(RMSE)作为模型评估的指标。由于优化施氮量是一个理论值, 存在合理的阈值范围。为了更客观地评估模型性能, 以 $\text{OTN} \pm 30\text{kg N ha}^{-1}$ 为阈值, 计算阈值范围内的数据点占全部测试数据的百分比(close to OTN, cOTN)作为额外的评估指标。

1.3 间接型冬小麦追氮推荐算法的构建

除了直接型预测最优追氮量的推荐算法, 本章还基于第三章、第四章构建的产量预测和氮素监测模型, 构建间接型的追氮推荐算法, 即产量预测法。具体步骤如下:

第一步是构建基于随机森林的冬小麦产量拔节期预测模型。

第二步是根据目标产量(Yield, Y)计算收获期植株吸氮量(PNU_H):

$$\text{PNU}_H = Y \times \text{NR} \quad (4-6)$$

其中 NR 表示籽粒需氮量(N requirement), 在 $<4.5\text{t/ha}$, $4.5\sim6.0\text{t/ha}$, $6.0\sim7.5\text{t/ha}$,

7.5~9.0t/ha, 9.0~10.5t/ha 以及>10.5t/ha 六个产量水平下每生产一吨籽粒的平均需氮量分别为 27.1, 25.0, 24.5, 23.8, 22.8 以及 22.5 kg (Yue et al., 2012b)。

第三步是构建拔节期的冬小麦 PNU 估测模型。为简单起见, 本章使用的模型为最优的植被指数模型:

$$\text{PNU}_j = 9.4572e^{2.7724x} \quad (x = \text{NDVI}, R^2 = 0.59) \quad (4-7)$$

需要强调的是, PNU 拔节期估测模型可以更换为第三章构建的机器学习模型。

第四步是计算追氮量:

$$\text{追氮量} = C \times (\text{PNU}_H - \text{PNU}_j) / \text{NUE}_T \quad (4-8)$$

其中 $C=0.5$, 表示化肥供氮约占 50% (Ladha et al., 2016)。其余供氮来自土壤、有机肥和前茬作物秸秆等。 NUE_T 表示氮肥的追肥利用率, 设置为 40% (Zhang et al., 2022a)。

1.4 冬小麦追肥验证试验设计

为了对不同的追氮推荐算法进行比较和验证, 本章设置了实地验证试验进行评估分析。追肥验证试验于 2022 年 3 月上旬(冬小麦拔节期)在江苏省徐州市睢宁县梁集镇(117.9°E, 33.9°N)、泰州市兴化市钓鱼镇(119.9°E, 33.1°N)、南通市如皋市白蒲镇(120.8°E, 32.3°N)选取普通田块进行, 追肥在小麦拔节期输入。睢宁的小麦品种为烟农 19, 前期施氮量为 108kg/ha; 如皋的小麦品种为扬麦 23, 前期施氮量为 244kg/ha, 兴化的小麦品种为扬麦 25, 前期施氮量为 222kg/ha。在每个试验地点选取三个田块作为试验田, 小区面积为 20~60m²。每个试验田设置 4 种追肥方案(随机区组设计), 其中两种为统一施肥方案, 包括农户常规施氮量(Farmer nitrogen rate, FNR)和区域最优施氮量(Regional optimal nitrogen rate, RONR), 另外两种为精准追肥方案, 根据本研究构建的氮肥推荐算法计算, 即产量预测法(Yield prediction, YP)和经济最优追氮量法(Economically optimal topdressing nitrogen rate, EOTN)。具体流程如图 4-1 所示。

考虑到模型复杂度与模型性能的权衡, 在验证试验中, 基于皮尔逊相关分析对特征进行了选择。在追氮量的计算中, 产量预测法输入特征为: NDRE, AGDD; 经济最优追氮量法输入特征: NDRE, PPT-sum, T-avg。由于模型使用了拔节期至成熟期的历史气象数据, 而在应用时需要输入该时间段的天气预报信息。考虑到长时间天气预报信息获取难度高与准确性低的问题, 未来气象数据用该试验点过去三到五年的平均值代替天气预报。

验证试验的社会经济与生态环境效益评估方法如表 4-1 所示。其中环境效益评估的计算参考自 He 等(2022)的研究。




图 4-1 追肥验证试验流程

Fig. 4-1 The workflow of topdressing nitrogen validation experiments

1.5 追肥量的多目标优化

在验证试验的基础上，本章基于施氮量与产量、社会经济效益、生态环境效益的定量关系，对追氮量进行多目标优化与权衡。本章利用 NSGA-II (Non-dominated sorting genetic algorithm-II, 二代非支配排序遗传算法) 对施氮量进行多目标优化。NSGA-II 是一种多目标优化算法，其主要思想是将非支配排序和拥挤距离的组合用于改进算法获得的帕累托前沿的多样性(帕累托前沿是帕累托最优解形成的曲线，帕累托最优解是多目标优化问题的最优解，其中每个解是非支配的)。本章使用 *pymoo* 框架(<https://github.com/anyoptimization/pymoo>)实现 NSGA-II 算法并对最优施氮量进行求解。

具体的流程为：1) 确定需要优化的目标函数与个数，即施氮量(待优化变量)与指标参数之间的定量模型。2) 确定施氮量的阈值范围，即变量的上界和下界。3) 确定模型边界，设置约束条件。4) 调用和运行遗传算法优化目标。5) 设置不同目标的权重，进行多准则决策确定决策解。

本研究优化的目标函数选用产量、经济利润与活性氮损失。追氮量与小麦产量的定量关系模型是根据历史试验数据建立的，使用二次函数进行拟合，公式如下：

$$Y = -0.0002 \times N^2 + 0.0474 \times N + 3.6886 \quad (4-9)$$

其中 Y 表示小麦产量(Yield)，N 表示追氮量(N topdressing rate)。R²=0.5771。

此外，考虑到施氮量与作物产量的复杂关系，即普通田块作物产量对肥料的响应

表 4-1 效益评估方法

Table 4-1 The benefit evaluation methods

评价指标	计算公式
Evaluation indicators	Formula
氮肥偏生产力	PFP=产量/施氮量
Partial factor productivity, PFP	
经济利润	EP=产量×小麦价格(3.2¥/kg)－施氮量×氮肥价格(5.6¥/kg)
Economical profitability, EP	
氧化亚氮排放	$0.59e^{0.0060NR}$
N ₂ O emission (kg ha ⁻¹)	
氨挥发	$-0.61+0.13NR$
NH ₃ volatilization (kg ha ⁻¹)	
硝酸盐淋溶	$1.64e^{0.0078NR}$
NO ₃ -N leaching (kg ha ⁻¹)	
活性氮损失	N ₂ O 排放+NH ₃ 挥发+NO ₃ -N 淋溶
Reactive N losses (kg ha ⁻¹)	
活性氮损失强度	活性氮损失/产量
Reactive N losses intensity	
CO ₂ eq-N ₂ O 直接排放量	(N ₂ O 排放+NH ₃ 挥发×0.01+NO ₃ -N 淋溶×0.0075)×44/28×298
CO ₂ eq-N ₂ O direct emission (kg ha ⁻¹)	
二氧化碳间接排放量	施氮量×8.30+施磷量×0.79+施钾量×0.55
CO ₂ indirect emission (kg ha ⁻¹)	
温室气体排放量	CO ₂ eq-N ₂ O 直接排放量+二氧化碳间接排放量
Greenhouse gas (GHG) emission (kg CO ₂ eq ha ⁻¹)	
温室气体排放强度	温室气体排放量/产量
GHG emission intensity	

与小区试验不一致,因此根据本章实地验证试验的数据,建立另一个追氮量与小麦产量的定量关系模型,代表验证试验的产量效益评估分析结果,与公式 4-9 的模型进行对比。验证试验中建立的模型为线性,公式如下:

$$Y = 0.0136 \times N + 6.2584 \quad (4-10)$$

其中 Y 表示小麦产量(Yield), N 表示追氮量(N topdressing rate)。 $R^2=0.3725$ 。

经济利润与活性氮损失与追氮量的定量关系根据表 4-1 设置,其中活性氮损失包括氧化亚氮排放、氨挥发和硝酸盐淋溶三个目标函数,因此一共有 5 个待优化目标。产量和经济利润的优化目标为最大化,活性氮损失的优化目标为最小化。

追氮量的取值范围设定在 0~300 kg/ha 之间;约束条件假定为:产量大于 5t/ha,利润大于 10000 ¥/ha,氧化亚氮排放小于 2kg/ha。

NSGA-II 的种群大小设置为 200,迭代次数为 50,每代后代数为 10。

在 NSGA-II 得到非支配解后,为每个目标设定权重,然后使用增广尺度函数分解方法从解集中选择解。本章设定的目标权重为[0.3, 0.3, 0.2, 0.1, 0.1],即产量目标权重为 0.3,经济收益目标权重为 0.3,活性氮损失目标权重之和为 0.4。此权重可以根据实际情况调整(权重之和需为 1)。

2 结果与分析

2.1 最优施氮量与最优追氮量

本研究确定的各年各试验点的最优施氮量如表 4-2 所示。其中兴化试验点 2019 年播期 1 的肥料效应函数拟合失败,因此未纳入统计。由图可知,线性加平台函数拟合的最优施氮量较二次函数拟合的最优施氮量低。线性加平台函数拟合的经济和产量最优施氮量平均值分别为 162.33kg/ha 和 173.01kg/ha,二次函数拟合经济和产量最优施氮量分别为 261.76kg/ha 和 273.43kg/ha,即二次函数拟合的结果约高出 100kg/ha,但两种拟合方法的相关性相差不大。产量最优施氮量比经济最优施氮量的拟合结果稍高,说明农户不能盲目追求产量最大化,需要考虑投入成本和经济收益的影响。在不同地点中,由于泗洪、淮安和如皋只有一年的数据,因此最优施氮量差异较大。从曲周和兴化的最优施氮量中可以看出,河北地区(华北平原)比江苏地区(长江中下游平原)的优化施氮量要低,这可能与降水量、区域经济发展水平等因素密切相关。

将最优施氮量转化为最优追氮量之后,不同指标之间的相关关系如图 4-2 所示。其中理论基肥量与实际基肥量是高度正相关的,说明基于植株吸氮量的理论基肥量计算是合理的。而理论基肥量与最优追氮量之间是高度负相关的,即基肥水平越高,需

表 4-2 经济最优与产量最优施氮量

Table 4-2 Economical optimal nitrogen rate (EONR) and optimal nitrogen rate for yield (YONR)

地点 Site	年份 Year	氮肥价格 N fertilizer cost (¥/kg)	小麦价格 Wheat price (¥/kg)	经济最优施氮量 EONR kg/ha (线性加平台)	决定 系数 R ²	经济最优施氮量 EONR kg/ha (二次函数)	决定 系数 R ²	产量最优施氮量 YONR kg/ha (线性加平台)	决定 系数 R ²	产量最优施氮量 YONR kg/ha (二次函数)	决定 系数 R ²
曲周 Quzhou	2010	4.16	2.07	105.14	0.39	219.87	0.40	137.38	0.50	238.48	0.49
	2011	4.93	2.26	108.78	0.51	241.71	0.47	129.60	0.60	267.03	0.58
	2012	5.23	2.34	84.37	0.96	202.92	0.92	102.61	0.98	211.43	0.94
	2013	4.82	2.50	105.95	0.97	211.39	0.94	109.39	0.97	218.24	0.94
淮安 Huai'an	2015	4.07	2.61	162.53	0.71	300.00	0.71	172.87	0.76	300.00	0.78
如皋 Rugao	2015	4.07	2.61	178.48	0.47	279.01	0.47	193.51	0.60	300.00	0.60
泗洪 Sihong	2016	3.70	2.46	216.65	0.89	300.00	0.90	224.11	0.91	300.00	0.99
兴化 Xinghua	2018	3.85	2.56	271.45	0.87	300.00	0.88	283.41	0.91	300.00	0.91
	2019			186.62	0.76	279.35	0.77	197.64	0.81	297.44	0.82
	2019_S1	3.92	2.56	-	-	-	-	-	-	-	-
	2019_S2			166.31	0.81	254.22	0.82	168.38	0.83	268.99	0.85
	2019_S3			158.16	0.24	300.00	0.29	163.11	0.33	300.00	0.40
	2020_S1	3.86	2.58	167.49	0.86	260.34	0.86	169.37	0.87	274.93	0.88
	2020_S2			168.12	0.89	246.10	0.88	169.99	0.90	259.52	0.90
	2020_S3			192.52	0.59	269.70	0.59	200.78	0.66	291.90	0.67

注：S 表示不同的播期

Note: S represents different sowing dates




图 4-2 不同指标之间的关系

Fig. 4-2 Relationship between different indicators

注：左半角的散点图表示不同指标之间的关系；对角线的直方图表示频率分布；右半角的数字和颜色表示 Pearson 相关系数的大小和正负。

Note: The scatter plot of the left half triangle represented the relationship between different indicators, the histogram of the diagonal represented the frequency distribution, while the numbers and colors of the right half triangle represented the size and positive or negative values of the Pearson correlation coefficient.

要追施的氮肥水平就越低。值得注意的，在本研究中最优追氮量存在负值，这是因为在氮肥梯度试验中，部分高氮水平试验的基肥量已经超过该区域的最优施氮量理论值。而本研究开发的氮肥推荐算法是针对普通田块精准施肥使用的，因此在实际应用中，只要田块内的小麦长势正常，算法会得出正常的施肥量。产量与最优追氮量(此处为线性加平台拟合)之间的相关性较差，说明两者存在复杂的非线性关系，因此有必要

单独建立最优追氮量的预测模型，分析影响追氮量的驱动因子。

2.2 数据驱动型氮肥推荐算法的模型性能

本研究利用植被指数、气象数据和土壤数据的多源信息融合对最优追氮量进行直接预测，模型性能如图 4-3a, b 所示。仅基于植被指数预测时，模型的性能较差。而在加入气象数据进行预测后，模型的性能得到显著提升，在线性回归中 R^2 提高 0.15~0.37，在随机森林中 R^2 提高 0.11~0.20。然而在加入土壤数据后，模型的性能提高不明显。这可能是由于各地区之间的土壤属性差异不大，且没有测定不同年际间的土壤属性差异，因此土壤数据并未充分发挥作用。随机森林算法的整体模型性能比线性回归略好，但两种建模方法的 R^2 均未超过 0.75，说明最优追氮量的预测仍然十分具有挑战性。在四种最优追氮量的预测中，EOTN-L 和 YOTN-L 的性能比 EOTN-Q 和 YOTN-Q 好，其次，在相同的拟合方法下，经济最优比产量最优的预测效果要好。以上的结果表明，施氮量较低的方案，模型的表现更佳。为了进一步分析模型的差异，绘制了基于随机




图 4-3 数据驱动型氮肥推荐算法的模型性能

Fig. 4-3 The model performance of data-driven based N recommendation algorithms

森林的经济最优追氮量的理论值与预测值之间的散点图(图 4-3,c,d)。从图中可以看出,模型倾向于高估低需氮水平的施氮量,而低估高需氮水平的施氮量。值得注意的是,在 EOTN-Q 的预测模型中,在中高需氮水平下,散点图呈现发散状态有大量的点在理论值的合理阈值之外,再次说明在较高的氮水平下,模型的预测性变差。

2.3 最优追氮量的主要驱动因子

为了分析影响最优追氮量的主要驱动因子,本章首先分析了最优追氮量(选取经济最优施氮量)与特征之间的相关性(图 4-4)。由图可知,最优追氮量与植被指数之间存在较强的负相关性,说明植株的生长状况越好,需要的追肥量越少,这是符合作物生理规律的。另一方面,降水量相关指标、温度相关指标均与最优追氮量存在较高的正相关性。这可能是由于充足的降水和温度条件会促进作物的生长,进而需要更多的氮肥供应。另一种可能是较多的降水和较高的气温会加速氮肥向环境的流失,因此作物需要更多的氮肥保障正常生长。有趣的是,太阳辐射与最优追氮量呈现负相关性。这是因为在冬小麦的生长季内,南方的太阳辐射量仍然比北方低。尽管在预测模型中,




图 4-4 特征与最优施氮量之间的相关性

Fig. 4-4 Correlation between optimal nitrogen rate and features

注：左边的热图表示不同指标(最优追氮量和特征)之间的 Pearson 相关性(用颜色梯度显示)；通过 Mantel 检验，OTN、ONR、氮营养指标(包括地上生物量、植物氮浓度、植物氮吸收和氮指数)和产量与每一个特征进行相关。线宽表示对应距离相关性的 Mantel 检验的 r 统计量，线颜色表示统计显著性。

Note: The heatmap on the left represented the Pearson correlation (shown with a color gradient) between different indicators (optimal topdressing nitrogen rate and features); OTN, ONR, nitrogen indicators (including above ground biomass, plant nitrogen concentration, plant nitrogen uptake, and nitrogen index), and yield was related to each feature by Mantel tests. Line width corresponds to the Mantel's r statistic for the corresponding distance correlations, and the line color denotes the statistical significance.

土壤属性的贡献不大，但土壤属性与最优追氮量具有较高正相关性，说明融入更多更精细的土壤数据依然具体很大潜力。矩阵间的曼特尔检验(Mantel test，两个或多个矩阵相关关系的检验)结果(图 4-4)表明，植被指数与最优追氮量之间的相关性显著($p < 0.01$)，而与最优施氮量之间不显著。此结果是符合预期的，因为植被指数代表了不同氮肥梯度试验之间的作物生长变异情况，不同的生长状况直接对应不同的最优追氮量，而最优施氮量是综合施氮量、产量与经济响应的最优值，与单一植株或田块的作物生长状态没有直接对应关系。Mantel 检验的结果证明，最优施氮量更能反映不同地点，不同年份之间环境因素的影响，其中降水量(PPT-sum, AWDR)、土壤(SOM, TN, AP)因素与最优施氮量的相关性很高($r > 0.6$)，而且最优施氮量与大部分环境因素之间相关性比最优追氮量高。

进一步基于随机森林的特征重要性分析不同最优追氮量情况下的特征贡献(图 4-5)。对不同的最优追氮量而言，植被指数均为重要的特征，其中 NDRE 是最重要的特征。说明作物自身的生长和氮营养状况对于预测追氮量是至关重要的。综合来看，最高温和太阳辐射是比较重要的气象因子，而且在基于线性加平台和二次函数拟合的最优追氮量两者对比中发现，最高温和太阳辐射在 EOTN-L 和 YOTN-L 中的特征重要性均比 EOTN-Q 和 YOTN-Q 要高。联系前文中模型的性能对比可以推测，正是最高温和太阳辐射提供的信息，从而使模型的性能有所提高。换言之，在需氮水平较高的情形下，最高温和太阳辐射的重要性下降。从图 4-4 同样可以发现，最高温与太阳辐射相关特征与 EOTN-L 的相关性比 EOTN-Q 要高。结果的一致性充分说明，最高温和太阳辐射是预测最优追氮量的重要驱动因子，但在高需氮水平下的可预测性下降。

2.4 冬小麦拔节期氮肥推荐的效益评估

验证试验中不同地点、不同追氮调控方法的追氮量和小麦产量如图 4-6 所示。




图 4-5 预测最优追氮量的特征重要性

Fig. 4-5 Feature importance of OTN prediction

由于不同地点的前期施氮量存在差异, 因此不同地方的农户常规追氮量(FNR)和区域优化追氮量(RONR)根据情况进行调整, 追氮水平差异为睢宁>如皋>兴化。值得注意的是, 不同地点之间基于随机森林产量预测法(YP)的推荐追氮量均为 125kg/ha 左右。兴化试验点的 YP 推荐追氮量结果偏高, 可能是由于该点的预测产量出现高估。而不同地点之间的经济最优追氮量(此处为 EOTN-Q 模型计算得出)则存在明显差异,

即呈现随着前期施氮量增加而减少的趋势，同时维持在比 FNR 低，比 RONR 高的范围内。

与农户施氮量相比，EOTN 平均减少施氮量 18.2~67.6kg/ha (18.9%~48.4%)。与区域优化施氮量相比，EOTN 则平均增加 16.0~31.8kg/ha (11.4%~40.8%)。尽管如此，以上结果表明，在同样没有基肥量作为模型输入提供信息的情况下，直接型与间接型的追氮推荐算法相比，前者更能根据作物和气象信息做出“智能”调整，使决策结果更加合理可靠。在相同的地点内，不同追氮调控策略的追肥水平差异未呈现明显规律，说明针对特定地点的精准氮素管理策略需要因地制宜，也说明追氮推荐算法具有捕捉优化施氮量时空差异的潜力，但其普适性仍然需要更多试验数据进行提高和验证。

在小麦产量上，最终的平均产量水平为睢宁>如皋>兴化。这与追氮水平的趋势一致，说明追氮量对作物最终产量有很大影响。而在相同的试验点内，四种不同追氮调控策略下的小麦产量并没有显著差异($p<0.05$)。这是非常关键的，说明追氮量较高并不会显著增加产量(比如 FNR 的产量仅比 EOTN 高 4.12%~8.64%)，减少追氮量也不会导致产量显著下降。因此，精准施氮策略是可以在保证作物产量的前提下，减少化肥的投入。




图 4-6 验证试验的追氮量与产量

Fig. 4-6 The topdressing N rate and yield of validation experiment

注：小写字母表示多重比较结果，有一个相同字母的，为差异不显著；凡无相同字母的，为差异显著。（下同）

Note: Lowercase letters indicate multiple comparison results, and if there is one identical letter, the difference is not significant; If there are no identical letters, the difference is significant. (The same below)

基于施肥量与小麦产量，本研究进一步分析了各追氮调控方法的氮肥利用率(偏生产力)和经济效益(图 4-7)。平均的氮肥利用率水平差异为睢宁<如皋<兴化，此趋势与追氮量和产量的趋势正好相反。尽管兴化试验点的平均小麦产量较低，但降低了化肥的投入，提高了肥料利用率。原因可能是该地点的前期施氮水平过高，其作物的前




图 4-7 验证试验的氮肥偏生产力与经济利润

Fig. 4-7 The Partial factor productivity and economical profitability of validation experiment

期生长阶段里肥料利用率偏低，导致过量的氮损失到农田环境中，最终影响产量。类似地，睢宁试验点的追氮量偏高，尽管获得了较高的平均产量，但也导致了追肥的利用率下降，因此存在较大的减氮潜力。以上问题可以通过栽培管理中的氮肥后移或前移技术解决。值得注意的是，在验证试验中，睢宁的光谱测试与施肥时间偏早，这可能导致推荐算法出现高估施氮量。

与农户常规追氮量相比，EOTN 的氮肥偏生产力平均提高 7.26~54.62 kg/kg (12.99%~46.09%)，充分说明直接型的追氮推荐算法的应用潜力。在考虑经济因素之后，各试验点的经济利润水平为睢宁>如皋>兴化，但不同追氮调控方法之间的利润水平差别不大。与农户常规追氮量相比，EOTN 的经济利润平均仅减少了 3.12%~9.33%。由此可见，在经济效益的评估中，产量因素占主导作用。在实际生产中，农户更重视的可能是经济利润的提升而不是化肥利用率的提高。验证试验的结果表明，尽管化肥的投入成本增加不会抵消增产带来的经济效益，减少肥料的投入也不会带来影响经济收益的风险，这对于提高农户使用精准农业技术的意愿是有帮助的。

最后，本研究根据各追氮调控方法的施肥量进行了环境效益的评估(图 4-8、4-9)。由图可知，施氮量因素在环境效益评估中占主导作用。在不同的试验点之间，活性氮损失与损失强度的水平差异为睢宁>如皋>兴化，温室气体排放与排放强度的水平差异为睢宁>如皋>兴化。其中，与 FNR 相比，EOTN 的活性氮损失平均降低了 2.86~11.22




图 4-8 验证试验的活性氮损失评估

Fig. 4-8 The reactive N losses assessment of validation experiment




图 4-9 验证试验的活性氮损失评估

Fig. 4-9 The greenhouse gases emission assessment of validation experiment

kg/ha (20.56~47.24%), 活性氮损失强度平均降低了 0.28~1.25kg/t (13.63~44.83%), 温室气体排放平均减少了 208.80~820.82 kg/ha (16.34%~40.45%), 温室气体排放强度减

少了 16.41~89.94 kg/t (8.32~37.71%)。环境污染减少的幅度与施氮量减少的幅度相当，说明减氮是可以带来实际的环境效益的。

2.5 追氮量的多目标优化

基于多目标优化追氮量的帕累托前沿与决策解如图 4-10 所示。




图 4-10 多目标优化追氮量的帕累托前沿

Fig. 4-10 Pareto frontier of multi-objective optimal topdressing nitrogen rate

注: (a)基于历史氮肥梯度试验数据的最优追氮量; (b)基于验证试验(普通田块)数据的最优追氮量

Note: (a) The optimal nitrogen topdressing rate based on historical nitrogen fertilizer gradient experiments data; (b) The optimal nitrogen topdressing rate based on validation experiments (common field) data

当施氮量与作物产量的模型为二次函数时(图 4-10, a), 优化追氮量的阈值为 32~118 kg/ha(记为阈值 1), 其中决策解为 73 kg/ha(记为决策解 1)。当施氮量与作物产量的模型为线性函数时(图 4-10, b), 优化追氮量的阈值为 0~203 kg/ha(记为阈值 2), 其中决策解为 133 kg/ha(记为决策解 2)。由此可见, 在阈值 2 的情形下, 即在普通田块进行氮素管理的实际情况下, 优化追氮量的阈值较大, 甚至阈值 1 的两倍, 说明在实际生产中存在很大的减氮空间。决策解 2 与 YP 的平均推荐值接近, 一定程度上证明了 YP 的普适性。然而阈值 2 存在 0 值, 即表示不追肥的情况下也能实现既定产量和经济利润。这种情况说明普通田块存在较高氮盈余, 但从长期来看, 不追施氮肥可能会导致土壤氮库的过量消耗, 破坏土壤氮平衡, 同时影响作物的后期生长, 加剧产量的不确定性, 因此是不够合理的。相比之下, 阈值 1 有着更合理的阈值范围, 其决策解 1 与 RONR 的平均推荐量 (72kg/ha) 是相当接近的, EOTN 的平均推荐量 (96kg/ha) 则介于决策解 1 和 2 之间。综合来说, 在产量、经济与环境多重效益的权衡下, YP、EOTN 和 RONR 都处在合理范围内。然而, 多目标优化施氮量只是一个适用于农场或区域尺度的理论值, EOTN 和 YP 才能给出捕捉田块内部的时空差异, 进行精准氮素管理, 充分提高肥料的利用率与生产效率。多目标优化追氮量的检验进一步证明了精准施肥策略的潜力与合理性。

3 讨论

3.1 多源数据驱动氮肥推荐算法的可行性

本章基于最优追氮量的概念, 首先构建了融合了作物光谱指数、气象与土壤信息的氮肥推荐算法, 其中随机森林预测 $R^2=0.59\sim0.72$, $RMSE=39.63\sim40.48\text{kg/ha}$, 可以有效地指导精准施肥。在特征的组合中发现, 土壤数据虽然与最优追氮量相关, 但对模型的贡献不大。类似地, 前人的研究发现基于土壤硝酸盐测试的数据预测 EONR 表现不佳(Clark et al., 2019, 2020)。可能的解释是, 土壤因素并不是该地点的产量限制因子(Wang et al., 2020c)。从特征的重要性来看, 本研究发现植被指数、最高温和太阳辐射对预测最优追氮量有关键作用。在相关研究中, Qin 等(2018)特别建议将土壤水分和作物状况纳入 EONR 的预测模型中, Puntel 等(2019)则发现降水事件、土壤水分和前茬作物残留量等是预测 EONR, YONR 的重要特征, 而且总体上动态特征(随时间变化)

比静态特征(随时间变化很慢或不变)的重要性更高。由此可以推测,与植物吸氮、土壤氮损失等过程密切相关的因子对于施氮量的估测更为重要。在全球气候变暖、太阳辐射变暗、极端气象灾害频发的背景下,氮素的气候智慧型管理将会面临更多的挑战。

在本章的模型中,并没有考虑把栽培管理因素(如基肥量,播种密度,灌溉方式)等作为模型的特征,这是因为在实际管理中,这些因素需要通过调查记录等方式获取,这无疑增加了实地管理的复杂度。类似地,作物品种遗传特性、植物病虫害发生情况等难以快速获取的属性也没有考虑在内。但在实际应用中,作物品种、植株健康状况、栽培管理方式会出现远比小区控制变量试验更复杂的变化,这会降低模型的准确性和普适性。尽管植被指数能够综合反映作物的实时状态,未来的研究也可以考虑将栽培、遗传等因素转化为分类特征,以便模型更好地完善。另一方面,与作物表型参数相关的其他传感器数据,如叶绿素荧光(Dong et al., 2022)、热成像数据(Pancorbo et al., 2021),可在综合模型性能与数据获取成本的情况后设计特征,更全面地评估作物实时生长状态。

本章基于前两章的研究结果,将随机森林选为建模方法。然而,相关的研究也指出因果森林法在预测 EONR 的表现优于随机森林(Kakimoto et al., 2022),也有研究使用贝叶斯更新(McFadden et al., 2018)、概率贝叶斯框架(Lawrence et al., 2015)等新颖的方法优化氮肥推荐算法,更有研究指出先进的强化学习在氮素管理上的潜力(Wu et al., 2022)。可见,未来的研究中更多适合于推荐决策的智能算法应该进行尝试与应用,进一步提高氮肥推荐的准确性与科学性。

3.2 产量预测法(间接型)与最优追氮量法(直接型)的异同

尽管本研究的数据来源于多年多点的试验,但因为每个试验对应的最优施氮量只有一个,因此数据量是不足以建立最优施氮量的直接预测模型的。也正因为于此,最优施氮量常常作为一个静态的区域推荐值用于指导施肥调控,比如 MRTN 工具(Maximum return to nitrogen) (Morris et al., 2018)。若要建立数据驱动型的动态最优追氮量模型,则需要在广泛的地理条件下,开展规模性的试验获取充足的数据。在美国玉米种植带范围内开展的一项评估和优化氮肥推荐算法的项目是其中一个范例(Kitchen et al., 2017)。这也意味着数据驱动型推荐算法的构建有赖于跨学科、跨领域的密切交流与合作。在最优施氮量的基础上,本章创新性地提出了最优追氮量的概念,该模型实际上是基于养分平衡原理将最优施氮量转化为最优追氮量,在转化的过程中,作物的生长变异信息被纳入,因此最优追氮量成为反映作物与环境差异,并考虑肥料响应的值。最优追氮量得以应用于田块内部的变量施肥,并体现“优化”施氮量的思想。这个概念有效弥补了数据不足的问题,并为田块尺度的精准施肥开辟了新的可能。

与此同时,本研究在验证试验中将最优追氮量算法与基于产量预测的追氮推荐算法进行对比和评估,发现最优追氮量法有着更合理的阈值范围,并能够进行动态调整。表明直接预测不会没有掩盖掉重要的机理,并且更加方便和准确。在 Colaço 等(2021)的研究中同样发现,直接型策略预测最优施氮量的表现要比间接型策略好。因此,建议后续研究中对直接型策略进行更多的探索和验证。但无论是直接型还是间接型的推荐算法,都属于考虑作物与环境时空变化的“动态”推荐,具有实际的减氮潜力。然而 Mandrini 等(2021)在研究中指出,复杂的动态推荐算法虽然提高了预测 EONR 的准确度,但比一定比简单的静态推荐工具提高利润和降低氮淋溶损失,这是因为 EONR 两侧的经济利润响应是不一样的,而且静态推荐可以在阈值低侧实现减少污染的目的。可见在决策管理中,准确性不能成作为唯一追求的目标,如何在合理阈值内进行优化决策以及如何兼顾模型的准确性与效益是十分重要的。

需要指出的是,在两种氮肥推荐策略中,均存在诸多的不确定性。比如在基于产量预测的氮肥推荐算法中,产量预测模型、植株吸氮量估测模型、化肥供氮比例、追肥利用率均存在较大的不确定性。在最优追氮量推荐算法的构建中,则存在肥料效应函数拟合方式、理论基肥量计算等不确定性。直接型策略的优越性,可能是由于直接建模减少了中间模型的不确定性。但无论如何,两种策略可以通过提高数据量、进行贝叶斯统计等方法分析和优化(Correndo et al., 2021)。

3.3 施氮量的多目标优化

本章验证试验的结果说明,精确施氮是可以带来实际的农艺和环境效益的,这与前人大部分的研究结论是一致的(Colaço and Bramley, 2018)。但是,仅仅停留在效益评估上是不够的,能够找到兼顾农艺、经济与环境效益的阈值和平衡点,对于评估追氮策略的合理性与进一步的决策优化具有重要意义。因为追氮推荐算法计算出来的的是一个具体数值,而且是一个不真实存在的理论值,对决策管理而言,更关注的应该是如何设定合理的阈值范围,粗略地设定阈值区间显然是不够合理的。基于此思路,本研究利用多目标进化优化的框架计算了在产量、经济和氮污染约束下的追氮量合理阈值(帕累托前沿),其中阈值 1 为 32~118 kg/ha(最优解为 73 kg/ha),阈值 2 为 0~203 kg/ha(最优解为 133 kg/ha)。在前人优化施氮量的研究中,华北平原地区小麦的优化施氮量(总施氮量)的数值有 202 kg/ha (Zhang et al., 2018), 185 kg/ha (Wang et al., 2017), 240~268 kg/ha (Duan et al., 2019)。也就是说,优化追氮量(按照基追比 1: 1 换算)约为 92~134kg/ha,此阈值与两种最优解之间的阈值 73~133kg/ha 相近,说明本章提出的优化施氮量范围是合理的。需要再次强调的是,验证评估试验中 EOTN 的平均推荐量为 96kg/ha, YP 的平均推荐量为 125kg/ha,均位于 92~134kg/ha 或 73~133 kg/ha 范围内,

说明区域优化施氮与田块精准施氮是可以协同实现的。最优追氮算法设计本身就通过引入肥料响应函数来体现区域优化的思想,实现“高产减氮,低产增氮”,而产量预测法则根据产量水平进行调整,实现“高产增氮,低产减氮”,两种策略都有望在宏观尺度上达到区域优化的要求,这和朱兆良与金继运(2013)提出的“区域用量控制与田块微调相结合”的推荐施肥的理念相吻合。与此同时,多目标优化施氮量也可以在田块尺度的施肥决策中发挥作用,比如设置参考区间、评估特定地点变量施肥的方案等,由此对最终的施肥处方进行校准和优化。

正如 Khoshnevisan 等(2020)所设想的,在多目标优化施氮量框架中,目标函数、参数、目标权重、约束条件等可以根据实际情况进行制定和更新,从而为氮素管理提供一个灵活、简便可行的工具。首先目标函数及其数量,即施氮量与多种参数指标之间的定量关系,会极大地影响模型运行的结果。以本研究为例,通过切换不同的施氮量-产量函数就获得了截然不同的结果。此外,目标函数中同样可以引入除施氮量以外的变量,如灌溉量、播种量、施肥时间等决策相关因素,进一步增强模型的泛化能力。在最新的一项研究中,Cai 等(2023)构建了我国不同稻区水稻产量/活性氮排放与施氮量的定量关系模型,确定不同稻区的区域优化施氮量,同时发现不同地区对经济或环境收益有所偏重。也就是说,目标函数权重的设置是可以因地制宜的。如果在框架中加入氮平衡(Roy et al., 2021)、氮足迹与氮边界(Liang et al., 2021)、氮信用(Gu et al., 2023)等约束条件,则可以为政策制定、氮污染治理、农户激励等提供更多解决方案。综合来说,多目标优化框架可以作为连接田块精准氮素管理与区域优化施氮的支点,为实现农业可持续发展创造更多可能。

4 结论

基于最优追氮量的概念,本章构建了基于多源信息融合的冬小麦氮肥推荐算法。并在验证中将最优追氮量算法、产量预测法、农户常规施氮量与区域专家推荐施氮量进行对比和效益评估。最后通过多目标进化优化分析追氮推荐算法的合理性。最优追氮量法不仅能够具有良好的预测性能,而且在实际验证中能够提高氮肥利用率,减少氮污染,而不造成产量和经济利润损失。与此同时,最优追氮法能够进行动态调整,在多目标优化施氮量的合理阈值范围内给出精准推荐。最优追氮量预测的重要驱动因子为植被指数、最高温和太阳辐射。综上所述,本章提出的氮肥推荐算法成功融合了多源信息与“最优”理念,为兼顾农艺、经济与环境效益的田间精确氮素管理开辟了新的可持续性路径。同时,本章贯通了冬小麦产量预测、氮素监测与施肥决策的技术链条,可为精确氮素管理的关键模型优化、策略选择与效益评估流程提供借鉴。

全文讨论与结论、创新点及研究展望

摘要：本章综合讨论了冬小麦生长监测与氮素推荐的影响因素、模型复杂度与模型性能的权衡、作物氮肥推荐算法的可行性。并简要总结了本文的研究特色和创新之处，反思了本研究存在的不足之处，进而提出了今后的研究展望。最后对本研究的重要结论进行概括。

关键词：冬小麦；氮肥推荐；驱动因子；多目标权衡

1 全文讨论

作物的精确管理是一个从作物信息感知、作物生长诊断、作物管理决策、田间精确作业的完整策略，涉及作物生产全供应链的过程，需要多学科交叉融合与创新，共同应对粮食安全、碳中和与气候变化等与人类命运息息相关的可持续发展问题。聚焦作物的精确氮素管理，本研究具体对冬小麦的生长监测(包括产量预测、氮素营养监测与诊断)、氮肥推荐算法进行了研究与探讨，遵循数据整合-建模评估-知识发现的总体思路，并取得了预期的研究结果。下面对本研究进行综合讨论。

1.1 冬小麦生长监测与氮肥推荐的影响因素

众所周知，作物生长受到基因、环境、管理的共同作用，具有复杂性、系统性的特点。面对复杂的关系，如何从混沌随机的系统中捕捉重要的驱动因子，发展简洁优美的框架是众多研究者的共同追求。在传统的农学研究中，往往可以通过控制变量试验分析特定因素对特定作物生长特性的影响。然而对于不同的作物特性，不同的时间，不同的地点，各种因素都在发生随机变化与交互作用，对微观-宏观尺度形成不同效应大小的影响。在本研究中，希望通过多年多点多源的信息融合，从大数据中挖掘隐藏的、有价值的信息，解析冬小麦生长监测与氮肥推荐的重要驱动因子。其中，冠层光谱信息代表了不同作物管理与品种的变化差异，气象、土壤数据代表了不同时空变化下的环境差异。针对日值气象特征的动态变化特性，还根据具体情况考虑了特征时间聚合区间的问题。从结果来看，不同的模型中重要的驱动因子大有不同。对拔节期产量预测最重要的贡献因子有植被指数、平均温度、最低温度和平均相对湿度；对全生育期的氮素监测而言，积温、植被指数、太阳辐射、天数对 AGB、PNC 和 PNU 估测贡献很大，降水均匀度则对 PNC、NNI 的估测尤为重要；在最优追氮量的预测中，植被指数、太阳辐射和最高温的重要性比较突出。在 Puntel 等(2019)的研究中，对比了

预测 EONR 与产量(包括 EONR 下的产量与对照组产量)的特征重要性, 同样发现预测不同的指标特征重要性有较大的差异。Bönecke 等(2020)发现, 小麦产量对于灌浆期的平均温度和热胁迫高度敏感, Tack 等(2015)则发现, 秋季的低温和春季的极端热害事件是小麦产量损失的驱动因子。类似地, 作物的叶面积指数(Chen et al., 2018)、优化施氮量(Liu et al., 2022)、土壤氮循环(Li et al., 2021b)的环境驱动力各有差别。因此, 根据具体的研究得出可解释、可信任的结果才是关键。而结论的可靠性, 是建立在数据量的基础上(即数据量越多结论越可靠), 还是建立在模型性能的基础上(即模型越准确结论越可靠), 仍需进一步探讨。另一方面, 依据数据挖掘中发现的关键驱动因子, 进一步提出新的见解, 设计综合、可靠、简便的新指标或框架, 形成从特征-模型-知识-新特征的良性循环, 是值得努力的方向(Tardieu et al., 2017)。

1.2 模型复杂度与模型性能的权衡

大量的研究已经证明, 通过多源信息融合以及先进的建模方法可以有效地提高模型的性能(Benos et al., 2021)。本研究通过融合冠层光谱、可获得的气象数据及土壤数据进行模型构建, 并取得了较好的模型性能。对于研究使用的模型, 可以在不考虑模型复杂度的情况下追求模型的最佳性能, 但对于需要实地应用的模型, 则必须对模型性能与模型复杂度进行权衡, 也就是希望用更少、更简便的特征实现可接受的准确度。本研究探究了过滤式(基于皮尔逊相关系数)、包裹式(递归特征消除)的特征选择方法、特征组合方法(不同气象特征聚合尺度、特征叠加)对模型性能的影响, 发现可以在不损失模型精度的基础上, 用最佳的特征和特征数量实现。在相关的研究中也已经发现特征选择流程具有提高运算效率、增强可解释性的优势, 尤其是在高维数据中(Elavarasan et al., 2020; Gopal Maya and Bhargavi, 2019)。也有研究使用进化算法来选择最优特征(Liu et al., 2021b; Thorp et al., 2017)。需要指出的是, 简化后的模型输入会出现不一致的结果, 因此最理想的情况是, 无论输入什么特征组合(包含基本关键特征的基础上), 都能给出可靠的预测。

对多年多点多源信息融合的过程, 本身就是一种模型的简化。另外, 本研究还涉及多任务学习、全生育期预测, 旨在保证模型准确性的基础上, 搭建简洁、普适的模型。这是因为在实际应用中, 若在不同地点不同时间都需要使用特定的模型, 则会降低效率, 带来诸多不确定性, 因此一个普适通用的模型是十分重要的。类似地, Fu 等(2023)建立了一个统一的水稻临界氮浓度稀释曲线模型, 以降低其不确定性, 适用于区域范围内的使用。Li 等(2022c)建立了全生育期的小麦地上部生物量估测模型, Ma 等(2022)利用多任务学习估测小麦的叶片氮含量。可见, 建立统一的、简化的模型提升泛化能力, 已经成为众多研究者的共识。尽管机器学习模型作为非参数化模型, 需

要借助一定的平台才能使用，但普适性提升带来的回报会是巨大的。

1.3 作物氮肥推荐算法的可行性

本研究突破经典氮肥优化算法的框架，融合肥料响应的“优化”思想与田块尺度时空变异的“变量”思想，提出了最优追氮量的概念，并基于多源信息构建了最优追氮量的直接预测模型。需要再次强调的是，在作物的管理决策过程中，模型性能不再是唯一追求的目标，而是需要权衡多目标之间的效益。本研究提出的最优追氮量可以视为单目标优化追氮量，经过多目标优化的检验，证明在实地验证中计算出来的施氮量是合理的。在相关研究中，Kropp 等(2022)结合作物模型与多目标优化辅助灌溉与施肥管理的决策，Mandrini 等(2022)基于作物模型与田间试验数据探讨了氮肥调控中利润-产量-环境的权衡。可以预见，施氮量的多目标优化将成为氮肥推荐算法新的发展方向。这是因为，优化施氮量是一个理论值，如何把这个理论值算清楚，比用什么特征和算法的问题更重要。当然，优化施氮量的计算可以放在整个流程的不同位置，因此存在直接型与间接型策略之分、田块尺度优化与区域尺度优化之分等。无论如何，基于事前优化概念的管理决策比单纯事后验证评估更具可行性。

对比本研究构建的三种模型可以发现，模型的整体性能排序为氮素监测>产量预测>最优追氮量预测。也就是说，作物生长状态的实时监测比未知状态(产量、最优施氮量)的预测更加简单、可靠。尽管监测-诊断-决策已经成为一体化的技术路线，但从生长监测落实到管理决策上，仍存在着更多的挑战。本研究已经证明，在推荐算法中融合气象数据能够在一定程度上捕捉“未来”的信息，提高预测性能。作物的实时生长监测不受后期环境因素的影响，因此能够更加准确地估量。与此同时，不同生育期的环境信息也会随着作物生长规律的变化而产生不同程度的影响。有趣的是，在验证试验中发现，即使最优追氮量模型的理论预测性能相对较差，但其推荐的追氮量是更加合理的。因此，不同策略的氮肥推荐算法之间没有绝对的优劣之分，可以有机融合，相辅相成，让管理方案的制定更加科学、更加智能。氮肥推荐算法需要更多的实地验证与试点推广，进行因地制宜的调整，匹配当地的科技发展水平、农户知识水平等，打通“最后一公里”，真正实现精准、高效、绿色的氮素管理模式。

2 创新点

(1)构建了基于多源信息融合的冬小麦产量预测模型与全生育期氮素监测模型，提高了冬小麦生长监测的准确性、实用性与时空普适性。本研究通过使用机器学习、深度学习、进化算法等智能算法，成功在冠层光谱上融入气象数据，并挖掘出重要贡献

因子。同时将产量预测与氮素监测推向追肥决策,为间接性追氮策略优化了关键模型。

(2)构建了基于多源信息融合的直接型冬小麦氮肥推荐算法并进行效益评估与多目标优化。本研究提出了协同田块精准与区域优化的最优追氮量概念,基于最优追氮量的氮肥推荐算法能够实现追氮量的动态精准调整,并取得产量-经济-环境效益的多目标权衡。该研究思路为精确氮素管理提供了新选择。

3 研究展望

本研究对冠层光谱与气象信息融合构建数据驱动型的产量预测模型、氮素监测与诊断模型、氮肥推荐算法进行了系统评估与验证,形成了数据整合、建模评估、知识发现、效益评估与优化的完整框架,为精准氮素管理技术的优化提供了技术支撑。但本研究在数据选择、建模方法和验证评估方面均存在不足之处,需要在未来的研究中进一步检验完善,在此提出本研究的设想:

(1)数据是建立模型的基础,本研究仅使用了五个生态点的多年氮肥试验数据,并且仅探讨了冠层光谱、气象和土壤等特征的融合。因此,在未来的研究中,可以通过整合更大数据量、更多数据源、更高数据质量的数据,提升模型普适性,挖掘重要规律。与此同时,通过知识图谱与深度学习结合、遥感与作物模型耦合等手段,形成知识驱动与数据驱动的框架,让管理决策更加科学合理,有迹可循。

(2)建模工具的进步让模型更加智能,本研究初步探究了机器学习、深度学习、进化算法在精确氮素管理领域的可能性。未来的研究需要对优秀的算法进行研究和设计,使其与作物管理决策问题更加匹配,或者针对作物管理设计简洁可行的框架与平台,助力自动化、智能化数据分析。此外,也特别需要加强作物栽培管理与计算机科学技术、人工智能技术的交叉融合,共谋智慧农业的发展。

(3)氮肥推荐算法的应用任重而道远。本研究仅对氮肥推荐算法进行了一年的验证与评估,尽管证明了精准追氮可以兼得产量、经济与环境效益,但算法如何实现气候异常年份(如严重的干旱、冻害)的预测,如何获得当季精准气象数据、如何与农机作业更好地融合,如何协同区域优化与田块尺度优化,如何提高农户使用精确管理技术的意愿,这些问题都存在很大的研究空白。本研究中曲周位于半湿润易旱区,而江苏省内四点位于湿润区/雨养农区,生态区域跨度较大,因此统一的模型可能无法满足鼓励推行水肥一体化的灌区小麦生产复杂氮素运筹需求。总之,未来的研究需要广泛开展氮肥推荐算法的验证与推广工作,为农业高效绿色发展贡献力量。

4 全文结论

本研究构建了基于冠层光谱与气象数据的田块尺度冬小麦拔节期产量预测模型。针对田块尺度冬小麦产量预测模型在外推的情况下普适性不强的问题,结合机器学习建模、特征选择、特征聚合全面评估算法性能。从结果上看,非线性的机器学习方法比传统线性回归显著提高了预测精度。特征选择和特征聚合尺度之间的模型性能则没有明显差异。以随机森林为代表的集成学习方法取得了整体最佳性能,说明随机森林可以很好地捕捉影响小麦产量的复杂非线性关系。

其次构建了基于冠层光谱与气象数据的田块尺度冬小麦全生育期氮素监测模型。针对小麦氮素监测与诊断的时空可迁移性不强的问题,本研究搭建了深度学习与进化算法结合冬小麦氮素估测简洁框架。估测的指标包括地上部生物量,植株氮浓度,植株氮积累量以及氮营养指数。本研究使用了长短期记忆、深度神经网络两种深度学习方法进行建模,并以随机森林作为基准模型作比较。同时基于进化算法对深度神经网络尝试进行超参数优化、网络训练。引入多任务学习对四个指标进行同时预测,同时捕捉生物量积累和氮浓度稀释的信息,并对损失权重进行进化优化。从结果上,随机森林和深度神经网络取得较高的精度。但长短期记忆神经网络和进化算法的性能值得进一步探索。其中,氮营养指数的估测精度需要进一步提高。

最后构建了基于多源信息融合的氮肥推荐算法与多目标优化框架。针对氮肥推荐算法时空变异大与多目标权衡的问题,本研究提出了协同田块精准与区域优化的最优追氮量概念,并基于多源信息构建了最优追氮量的直接预测模型。在验证试验中对比了基于产量预测与氮素监测的间接型追氮策略与基于最优追氮量的直接型追氮策略。证明精准追氮可以减少氮投入并提高氮肥利用率,减少环境污染,同时维持产量和利润。基于多目标进化优化求解最优追氮量验证了精准追氮算法的合理性。

针对机器学习模型与农学知识关联性不够的问题,本研究根据模型解释评估小麦产量的驱动因子。从结果来看,NDRE,最低温度,平均温度,平均相对湿度对产量预测表现出一致的高贡献度,尤其是播种到拔节期的特征。植被指数、最高温和太阳辐射则对预测最优追氮量贡献最大。利用模型可解释性框架SHAP评估小麦氮素监测的关键特征表明,AGDD是估测AGB,PNC,PNU的重要特征,但是对预测AGB与PNC的作用是相反的。一个与降水均匀度相关的特征AWDR对PNC和NNI的估测贡献很大。总体来说,物候驱动因子对全生育期氮素监测至关重要。

参考文献

- 陈桂芬, 马丽, 陈航 (2013). 精准施肥技术的研究现状与发展趋势. *吉林农业大学学报* 35, 253-259.
- 何山, 孙媛媛, 沈掌泉, 王珂 (2017). 大数据时代精准施肥模式实现路径及其技术和方法研究展望. *植物营养与肥料学报* 23, 1514-1524.
- 巨晓棠, 谷保静 (2014). 我国农田氮肥施用现状、问题及趋势. *植物营养与肥料学报* 20, 783-795.
- 巨晓棠, 张翀 (2020). 论合理施氮的原则和指标. *土壤学报*, 1-14.
- 李克亮, 周志艳 (2019). 水稻氮肥精准管理技术研究进展. *江苏农业科学* 47, 18-25.
DOI: <http://doi.org/10.15889/j.issn.1002-1302.2019.12.004>
- 李楠楠, 杜晓宇, 韩玉林, 邹少奎, 李顺成, 王丽娜, 张倩, 吕永军, 杨光宇 (2021). 中国四大冬小麦主产区品种农艺性状的综合性分析. *种子* 40, 94-101.
DOI: <http://doi.org/10.16590/j.cnki.1001-4705.2021.12.094>
- 刘成良, 林洪振, 李彦明, 贡亮, 苗中华 (2020). 农业装备智能控制技术研究现状与发展趋势分析. *农业机械学报* 51, 1-18.
- 王晓玲 (2017). 长江中下游稻麦两熟区冬小麦植株器官临界氮浓度模型构建及氮素诊断调控研究. *南京农业大学*.
- 杨玮, 孙红, 郑立华, 李民赞 (2013). 基于土壤参数的冬小麦产量预测模型. *农业工程学报*, 118-123. DOI: <http://doi.org/10.3969/j.issn.1002-6819.2013.23.016>
- 张福锁, 王激清, 张卫峰, 崔振岭, 马文奇, 陈新平, 江荣风 (2008). 中国主要粮食作物肥料利用率现状与提高途径. *土壤学报*, 915-924.
- 赵春江 (2010). 对我国未来精准农业发展的思考. *农业网络信息*, 5-8.
- 赵春江 (2014). 农业遥感研究与应用进展. *农业机械学报* 45, 277-293.
- 赵春江 (2019). 智慧农业发展现状及战略目标研究. *智慧农业* 1, 1-7.
DOI: <http://doi.org/10.12133/j.smartag.2019.1.1.201812-SA005>
- 赵春江, 李瑾, 冯献 (2021). 面向2035年智慧农业发展战略研究. *中国工程科学* 23, 1-9.
DOI: <http://doi.org/10.15302/J-SSCAE-2021.04.001>
- 朱兆良, 金继运 (2013). 保障我国粮食安全的肥料问题. *植物营养与肥料学报* 19, 259-273.
- Abbas, F., Afzaal, H., Farooque, A.A., and Tang, S. (2020). Crop yield prediction through proximal sensing and machine learning algorithms. *Agronomy* 10, 1046.
DOI: <http://doi.org/10.3390/agronomy10071046>
- Aha, D.W., Kibler, D., and Albert, M.K. (1991). Instance-based learning algorithms. *Machine Learning*

- 6, 37-66. DOI: <http://doi.org/10.1007/BF00153759>
- Ahmed, U., Lin, J.C., Srivastava, G., and Djenouri, Y. (2021). A nutrient recommendation system for soil fertilization based on evolutionary computation. *Computers and Electronics in Agriculture* 189, 106407. DOI: <http://doi.org/10.1016/j.compag.2021.106407>
- Aranguren, M., Castellón, A., and Aizpurua, A. (2020). Crop sensor based non-destructive estimation of nitrogen nutritional status, yield, and grain protein content in wheat. *Agriculture* 10, 148. DOI: <http://doi.org/10.3390/agriculture10050148>
- Aula, L., Omara, P., Nambi, E., Oyebiyi, F.B., Dhillon, J., Eickhoff, E., Carpenter, J., and Raun, W.R. (2021). Active optical sensor measurements and weather variables for predicting winter wheat yield. *Agronomy Journal* 113, 2742-2751. DOI: <http://doi.org/10.1002/agj2.20620>
- Aula, L., Omara, P., Nambi, E., Oyebiyi, F.B., and Raun, W.R. (2020). Review of active optical sensors for improving winter wheat nitrogen use efficiency. *Agronomy* 10, 1157. DOI: <http://doi.org/10.3390/agronomy10081157>
- Ballesteros, R., Intrigliolo, D.S., Ortega, J.F., Ramírez-Cuesta, J.M., Buesa, I., and Moreno, M.A. (2020). Vineyard yield estimation by combining remote sensing, computer vision and artificial neural network techniques. *Precision Agriculture* 21, 1242-1262. DOI: <http://doi.org/10.1007/s11119-020-09717-3>
- Basso, B., and Liu, L. (2019). Seasonal crop yield forecast: methods, applications, and accuracies. *Advances in Agronomy* 154, 201-255. DOI: <http://doi.org/10.1016/bs.agron.2018.11.002>
- Bean, G.M., Kitchen, N.R., Camberato, J.J., Ferguson, R.B., Fernandez, F.G., Franzen, D.W., Laboski, C.A.M., Nafziger, E.D., Sawyer, J.E., Scharf, P.C., Schepers, J., and Shanahan, J.S. (2018a). Active-optical reflectance sensing corn algorithms evaluated over the United States Midwest corn belt. *Agronomy Journal* 110, 2552-2565. DOI: <http://doi.org/10.2134/agronj2018.03.0217>
- Bean, G.M., Kitchen, N.R., Camberato, J.J., Ferguson, R.B., Fernandez, F.G., Franzen, D.W., Laboski, C.A.M., Nafziger, E.D., Sawyer, J.E., Scharf, P.C., Schepers, J., and Shanahan, J.S. (2018b). Improving an active-optical reflectance sensor algorithm using soil and weather information. *Agronomy Journal* 110, 2541-2551. DOI: <http://doi.org/10.2134/agronj2017.12.0733>
- Benos, L., Tagarakis, A.C., Dolias, G., Berruto, R., Kateris, D., and Bochtis, D. (2021). Machine learning in agriculture: a comprehensive updated review. *Sensors* 21, 3758. DOI: <http://doi.org/10.3390/s21113758>
- Bi, L., and Hu, G. (2021). A genetic algorithm-assisted deep learning approach for crop yield prediction. *Soft Computing* 25, 10617-10628. DOI: <http://doi.org/10.1007/s00500-021-05995-9>
- Bocca, F.F., and Rodrigues, L.H.A. (2016). The effect of tuning, feature engineering, and feature selection

- in data mining applied to rainfed sugarcane yield modelling. *Computers and Electronics in Agriculture* 128, 67-76. DOI: <http://doi.org/10.1016/j.compag.2016.08.015>
- Bönecke, E., Breitsameter, L., Brüggemann, N., Chen, T.W., Feike, T., Kage, H., Kersebaum, K.C., Piepho, H.P., and Stützel, H. (2020). Decoupling of impact factors reveals the response of german winter wheat yields to climatic changes. *Global Change Biology* 26, 3601-3626. DOI: <http://doi.org/10.1111/gcb.15073>
- Bouwman, T., Javed, S., Sultana, M., and Jung, S.K. (2019). Deep neural network concepts for background subtraction: a systematic review and comparative evaluation. *Neural Networks* 117, 8-66. DOI: <http://doi.org/10.1016/j.neunet.2019.04.024>
- Breiman, L. (2001). Random forests. *Machine Learning* 45, 5-32. DOI: <http://doi.org/10.1023/A:1010933404324>
- Breiman, L., Friedman, J., Olshen, R., and Stone, C. (2017). *Classification and regression trees*. DOI: <http://doi.org/10.1201/9781315139470>
- Broge, N.H., and Mortensen, J.V. (2002). Deriving green crop area index and canopy chlorophyll density of winter wheat from spectral reflectance data. *Remote Sensing of Environment* 81, 45-57. DOI: [http://doi.org/10.1016/S0034-4257\(01\)00332-7](http://doi.org/10.1016/S0034-4257(01)00332-7)
- Bullock, D.S., Boerngen, M., Tao, H., Maxwell, B., Luck, J.D., Shiratsuchi, L., Puntel, L., and Martin, N.F. (2019). The data-intensive farm management project: changing agronomic research through on-farm precision experimentation. *Agronomy Journal* 111, 2736-2746. DOI: <http://doi.org/10.2134/agronj2019.03.0165>
- Burdett, H., and Wellen, C. (2022). Statistical and machine learning methods for crop yield prediction in the context of precision agriculture. *Precision Agriculture* 23, 1553-1574. DOI: <http://doi.org/10.1007/s11119-022-09897-0>
- Cai, S., Zhao, X., Pittelkow, C.M., Fan, M., Zhang, X., and Yan, X. (2023). Optimal nitrogen rate strategy for sustainable rice production in china. *Nature* 615, 73-79. DOI: <http://doi.org/10.1038/s41586-022-05678-x>
- Cai, Y., Guan, K., Lobell, D., Potgieter, A.B., Wang, S., Peng, J., Xu, T., Asseng, S., Zhang, Y., You, L., and Peng, B. (2019). Integrating satellite and climate data to predict wheat yield in Australia using machine learning approaches. *Agricultural and Forest Meteorology* 274, 144-159. DOI: <http://doi.org/10.1016/j.agrformet.2019.03.010>
- Cammarano, D., Zha, H., Wilson, L., Li, Y., Batchelor, W.D., and Miao, Y. (2020). A remote sensing-based approach to management zone delineation in small scale farming systems. *Agronomy* 10, 1767. DOI: <http://doi.org/10.3390/agronomy10111767>

- Cao, J., Zhang, Z., Luo, Y., Zhang, L., Zhang, J., Li, Z., and Tao, F. (2021). Wheat yield predictions at a county and field scale with deep learning, machine learning, and google earth engine. *European Journal of Agronomy* 123, 126204. DOI: <http://doi.org/10.1016/j.eja.2020.126204>
- Cao, J., Zhang, Z., Tao, F., Zhang, L., Luo, Y., Han, J., and Li, Z. (2020). Identifying the contributions of multi-source data for winter wheat yield prediction in China. *Remote Sensing* 12, 750. DOI: <http://doi.org/10.3390/rs12050750>
- Cao, Q., Miao, Y., Feng, G., Gao, X., Liu, B., Liu, Y., Li, F., Khosla, R., Mulla, D.J., and Zhang, F. (2017a). Improving nitrogen use efficiency with minimal environmental risks using an active canopy sensor in a wheat-maize cropping system. *Field Crops Research* 214, 365-372. DOI: <http://doi.org/10.1016/j.fcr.2017.09.033>
- Cao, Q., Miao, Y., Li, F., Gao, X., Liu, B., Lu, D., and Chen, X. (2017b). Developing a new Crop Circle active canopy sensor-based precision nitrogen management strategy for winter wheat in North China Plain. *Precision Agriculture* 18, 2-18. DOI: <http://doi.org/10.1007/s11119-016-9456-7>
- Cao, Q., Miao, Y., Shen, J., Yu, W., Yuan, F., Cheng, S., Huang, S., Wang, H., Yang, W., and Liu, F. (2016). Improving in-season estimation of rice yield potential and responsiveness to topdressing nitrogen application with Crop Circle active crop canopy sensor. *Precision Agriculture* 17, 136-154. DOI: <http://doi.org/10.1007/s11119-015-9412-y>
- Cao, Q., Miao, Y., Shen, J., Yuan, F., Cheng, S., and Cui, Z. (2018). Evaluating two Crop Circle active canopy sensors for in-season diagnosis of winter wheat nitrogen status. *Agronomy* 8, 201. DOI: <http://doi.org/10.3390/agronomy8100201>
- Carew, R., Smith, E.G., and Grant, C. (2009). Factors influencing wheat yield and variability: evidence from Manitoba, Canada. *Journal of Agricultural and Applied Economics* 41, 625-639. DOI: <http://doi.org/10.1017/S1074070800003114>
- Chang, L., Li, D., Hameed, M.K., Yin, Y., Huang, D., and Niu, Q. (2021). Using a hybrid neural network model DCNN-LSTM for image-based nitrogen nutrition diagnosis in muskmelon. *Horticulturae* 7, 489. DOI: <http://doi.org/10.3390/horticulturae7110489>
- Chen, G., and Chen, J. (2015). A novel wrapper method for feature selection and its applications. *Neurocomputing* 159, 219-226. DOI: <http://doi.org/10.1016/j.neucom.2015.01.070>
- Chen, T., and Guestrin, C. (2016). XGBoost: a scalable tree boosting system. In: *In Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining* 785-794. DOI: <http://doi.org/10.1145/2939672.2939785>
- Chen, Y., Zhang, Z., Tao, F., Palosuo, T., and Rötter, R.P. (2018). Impacts of heat stress on leaf area index and growth duration of winter wheat in the North China Plain. *Field Crops Research* 222, 230-237.

- DOI: <http://doi.org/10.1016/j.fcr.2017.06.007>
- Chen, Z., Miao, Y., Lu, J., Zhou, L., Li, Y., Zhang, H., Lou, W., Zhang, Z., Kusnierek, K., and Liu, C. (2019). In-season diagnosis of winter wheat nitrogen status in smallholder farmer fields across a village using unmanned aerial vehicle-based remote sensing. *Agronomy* 9, 619. DOI: <http://doi.org/10.3390/agronomy9100619>
- Chlingaryan, A., Sukkarieh, S., and Whelan, B. (2018). Machine learning approaches for crop yield prediction and nitrogen status estimation in precision agriculture: a review. *Computers and Electronics in Agriculture* 151, 61-69. DOI: <http://doi.org/10.1016/j.compag.2018.05.012>
- Clark, J.D., Fernández, F.G., Veum, K.S., Camberato, J.J., Carter, P.R., Ferguson, R.B., Franzen, D.W., Kaiser, D.E., Kitchen, N.R., Laboski, C.A.M., Nafziger, E.D., Rosen, C.J., Sawyer, J.E., and Shanahan, J.F. (2019). Predicting economic optimal nitrogen rate with the anaerobic potentially mineralizable nitrogen test. *Agronomy Journal* 111, 3329-3338. DOI: <http://doi.org/10.2134/agronj2019.03.0224>
- Clark, J.D., Fernández, F.G., Veum, K.S., Camberato, J.J., Carter, P.R., Ferguson, R.B., Franzen, D.W., Kaiser, D.E., Kitchen, N.R., Laboski, C.A.M., Nafziger, E.D., Rosen, C.J., Sawyer, J.E., and Shanahan, J.F. (2020). Soil-nitrogen, potentially mineralizable-nitrogen, and field condition information marginally improves corn nitrogen management. *Agronomy Journal*. DOI: <http://doi.org/10.1002/agj2.20335>
- Colaço, A.F., Richetti, J., Bramley, R.G.V., and Lawes, R.A. (2021). How will the next-generation of sensor-based decision systems look in the context of intelligent agriculture? A case-study. *Field Crops Research* 270, 108205. DOI: <http://doi.org/10.1016/j.fcr.2021.108205>
- Colaço, A.F., and Bramley, R.G.V. (2018). Do crop sensors promote improved nitrogen management in grain crops? *Field Crops Research* 218, 126-140. DOI: <http://doi.org/10.1016/j.fcr.2018.01.007>
- Cordero, E., Longchamps, L., Khosla, R., and Sacco, D. (2019). Spatial management strategies for nitrogen in maize production based on soil and crop data. *Science of the Total Environment* 697, 133854. DOI: <http://doi.org/10.1016/j.scitotenv.2019.133854>
- Correndo, A.A., Tremblay, N., Coulter, J.A., Ruiz-Diaz, D., Franzen, D., Nafziger, E., Prasad, V., Rosso, L.H.M., Steinke, K., Du, J., Messina, C.D., and Ciampitti, I.A. (2021). Unraveling uncertainty drivers of the maize yield response to nitrogen: a bayesian and machine learning approach. *Agricultural and Forest Meteorology* 311, 108668. DOI: <http://doi.org/10.1016/j.agrformet.2021.108668>
- Corti, M., Cavalli, D., Cabassi, G., Marino Gallina, P., and Bechini, L. (2018). Does remote and proximal optical sensing successfully estimate maize variables? A review. *European Journal of Agronomy* 99, 37-50. DOI: <http://doi.org/10.1016/j.eja.2018.06.008>

- Crane-Droesch, A. (2018). Machine learning methods for crop yield prediction and climate change impact assessment in agriculture. *Environmental Research Letters* 13, 114003.
DOI: <http://doi.org/10.1088/1748-9326/aae159>
- Cui, K., and Shoemaker, S.P. (2018). A look at food security in China. *Npj Science of Food* 2, 4. DOI: <http://doi.org/10.1038/s41538-018-0012-x>
- Cummings, C., Miao, Y., Paiao, G.D., Kang, S., and Fernández, F.G. (2021). Corn nitrogen status diagnosis with an innovative multi-parameter Crop Circle phenom sensing system. *Remote Sensing* 13, 401. DOI: <http://doi.org/10.3390/rs13030401>
- Das, B., Nair, B., Reddy, V.K., and Venkatesh, P. (2018). Evaluation of multiple linear, neural network and penalised regression models for prediction of rice yield based on weather parameters for west coast of India. *International Journal of Biometeorology* 62, 1809-1822.
DOI: <http://doi.org/10.1007/s00484-018-1583-6>
- Diacono, M., Rubino, P., and Montemurro, F. (2013). Precision nitrogen management of wheat. A review. *Agronomy for Sustainable Development* 33, 219-241.
DOI: <http://doi.org/10.1007/s13593-012-0111-z>
- Dong, R., Miao, Y., Wang, X., Yuan, F., and Kusnierek, K. (2022). Combining leaf fluorescence and active canopy reflectance sensing technologies to diagnose maize nitrogen status across growth stages. *Precision Agriculture* 23, 939-960. DOI: <http://doi.org/10.1007/s11119-021-09869-w>
- Dong, Y., Fu, Z., Peng, Y., Zheng, Y., Yan, H., and Li, X. (2020). Precision fertilization method of field crops based on the wavelet-BP neural network in China. *Journal of Cleaner Production* 246, 118735. DOI: <http://doi.org/10.1016/j.jclepro.2019.118735>
- Duan, J., Shao, Y., He, L., Li, X., Hou, G., Li, S., Feng, W., Zhu, Y., Wang, Y., and Xie, Y. (2019). Optimizing nitrogen management to achieve high yield, high nitrogen efficiency and low nitrogen emission in winter wheat. *Science of the Total Environment* 697, 134088.
DOI: <http://doi.org/10.1016/j.scitotenv.2019.134088>
- Ekanayake, P., Rankothge, W., Weliwatta, R., and Jayasinghe, J.W. (2021). Machine learning modelling of the relationship between weather and paddy yield in Sri Lanka. *Journal of Mathematics* 2021, 1-14. DOI: <http://doi.org/10.1155/2021/9941899>
- Elavarasan, D., Vincent P M, D.R., Srinivasan, K., and Chang, C. (2020). A hybrid CFS filter and RF-RFE wrapper-based feature extraction for enhanced agricultural crop yield prediction modeling. *Agriculture* 10, 400. DOI: <http://doi.org/10.3390/agriculture10090400>
- Elavarasan, D., Vincent, D.R., Sharma, V., Zomaya, A.Y., and Srinivasan, K. (2018). Forecasting yield by integrating agrarian factors and machine learning models: a survey. *Computers and Electronics in*

- Agriculture* 155, 257-282. DOI: <http://doi.org/10.1016/j.compag.2018.10.024>
- Eugenio, F.C., Grohs, M., Venancio, L.P., Schuh, M., Bottega, E.L., Ruoso, R., Schons, C., Mallmann, C.L., Badin, T.L., and Fernandes, P. (2020). Estimation of soybean yield from machine learning techniques and multispectral RPAS imagery. *Remote Sensing Applications: Society and Environment* 20, 100397. DOI: <http://doi.org/10.1016/j.rsase.2020.100397>
- Evans, F.H., and Shen, J. (2021). Long-term hindcasts of wheat yield in fields using remotely sensed phenology, climate data and machine learning. *Remote Sensing* 13, 2435. DOI: <http://doi.org/10.3390/rs13132435>
- Fang, Y., Liang, L., Liu, S., Xu, B., Siddique, K.H., Palta, J.A., and Chen, Y. (2021). Wheat cultivars with small root length density in the topsoil increased post-anthesis water use and grain yield in the semi-arid region on the loess plateau. *European Journal of Agronomy* 124, 126243. DOI: <http://doi.org/10.1016/j.eja.2021.126243>
- Farooq, M., Bramley, H., Palta, J.A., and Siddique, K.H.M. (2011). Heat stress in wheat during reproductive and grain-filling phases. *Critical Reviews in Plant Sciences* 30, 491-507. DOI: <http://doi.org/10.1080/07352689.2011.615687>
- Fassa, V., Pricca, N., Cabassi, G., Bechini, L., and Corti, M. (2022). Site-specific nitrogen recommendations' empirical algorithm for maize crop based on the fusion of soil and vegetation maps. *Computers and Electronics in Agriculture* 203, 107479. DOI: <http://doi.org/10.1016/j.compag.2022.107479>
- Feng, L., Zhang, Z., Ma, Y., Du, Q., Williams, P., Drewry, J., and Luck, B. (2020). Alfalfa yield prediction using UAV-based hyperspectral imagery and ensemble learning. *Remote Sensing* 12, 2028. DOI: <http://doi.org/10.3390/rs12122028>
- Filippi, P., Jones, E.J., Wimalathunge, N.S., Somarathna, P.D.S.N., Pozza, L.E., Ugbaje, S.U., Jephcott, T.G., Paterson, S.E., Whelan, B.M., and Bishop, T.F.A. (2019). An approach to forecast grain crop yield using multi-layered, multi-farm data sets and machine learning. *Precision Agriculture* 20, 1015-1029. DOI: <http://doi.org/10.1007/s11119-018-09628-4>
- Friedman, J.H. (2001). Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 1189-1232. DOI: <http://doi.org/10.2307/2699986>
- Fu, Y., Yang, G., Li, Z., Li, H., Li, Z., Xu, X., Song, X., Zhang, Y., Duan, D., Zhao, C., and Chen, L. (2020). Progress of hyperspectral data processing and modelling for cereal crop nitrogen monitoring. *Computers and Electronics in Agriculture* 172, 105321. DOI: <http://doi.org/10.1016/j.compag.2020.105321>
- Fu, Y., Yang, G., Pu, R., Li, Z., Li, H., Xu, X., Song, X., Yang, X., and Zhao, C. (2021). An overview of

- crop nitrogen status assessment using hyperspectral remote sensing: current status and perspectives. *European Journal of Agronomy* 124, 126241. DOI: <http://doi.org/10.1016/j.eja.2021.126241>
- Fu, Z., Jiang, J., Gao, Y., Krienke, B., Wang, M., Zhong, K., Cao, Q., Tian, Y., Zhu, Y., Cao, W., and Liu, X. (2020). Wheat growth monitoring and yield estimation based on multi-rotor unmanned aerial vehicle. *Remote Sensing* 12, 508. DOI: <http://doi.org/10.3390/rs12030508>
- Fu, Z., Zhang, R., Zhang, J., Zhang, K., Cao, Q., Tian, Y., Zhu, Y., Cao, W., and Liu, X. (2023). Potential of establishing the universal critical nitrogen dilution curve for Japonica rice. *Plant Phenomics* 0. DOI: <http://doi.org/10.34133/plantphenomics.0036>
- Genze, N., Bharti, R., Grieb, M., Schultheiss, S.J., and Grimm, D.G. (2020). Accurate machine learning-based germination detection, prediction and quality assessment of three grain crops. *Plant Methods* 16, 157. DOI: <http://doi.org/10.1186/s13007-020-00699-x>
- Gobbo, S., De Antoni Migliorati, M., Ferrise, R., Morari, F., Furlan, L., and Sartori, L. (2022). Evaluation of different crop model-based approaches for variable rate nitrogen fertilization in winter wheat. *Precision Agriculture* 23, 1922-1948. DOI: <http://doi.org/10.1007/s11119-022-09957-5>
- Gopal Maya, P.S., and Bhargavi, R. (2019). Performance evaluation of best feature subsets for crop yield prediction using machine learning algorithms. *Applied Artificial Intelligence* 33, 621-642. DOI: <http://doi.org/10.1080/08839514.2019.1592343>
- Grinblat, G.L., Uzal, L.C., Larese, M.G., and Granitto, P.M. (2016). Deep learning for plant identification using vein morphological patterns. *Computers and Electronics in Agriculture* 127, 418-424. DOI: <http://doi.org/https://doi.org/10.1016/j.compag.2016.07.003>
- Gu, B., Zhang, X., Lam, S.K., Yu, Y., van Grinsven, H.J.M., Zhang, S., Wang, X., Bodirsky, B.L., Wang, S., Duan, J., Ren, C., Bouwman, L., de Vries, W., Xu, J., Sutton, M.A., and Chen, D. (2023). Cost-effective mitigation of nitrogen pollution from global croplands. *Nature* 613, 77-84. DOI: <http://doi.org/10.1038/s41586-022-05481-8>
- Guerrero, A., De Neve, S., and Mouazen, A.M. (2021). Current sensor technologies for in situ and on-line measurement of soil nitrogen for variable rate fertilization: a review. *Advance in Agronomy*, 168. DOI: <http://doi.org/10.1016/bs.agron.2021.02.001>
- Guo, Y., Chen, Y., Searchinger, T.D., Zhou, M., Pan, D., Yang, J., Wu, L., Cui, Z., Zhang, W., Zhang, F., Ma, L., Sun, Y., Zondlo, M.A., Zhang, L., and Mauzerall, D.L. (2020). Air quality, nitrogen use efficiency and food security in China are improved by cost-effective agricultural nitrogen management. *Nature Food* 1, 648-658. DOI: <http://doi.org/10.1038/s43016-020-00162-z>
- Han, J., Zhang, Z., Cao, J., Luo, Y., Zhang, L., Li, Z., and Zhang, J. (2020). Prediction of winter wheat yield based on multi-source data and machine learning in China. *Remote Sensing* 12, 236. DOI:

- <http://doi.org/10.3390/rs12020236>
- He, P., Xu, X., Zhou, W., Smith, W., He, W., Grant, B., Ding, W., Qiu, S., and Zhao, S. (2022). Ensuring future agricultural sustainability in China utilizing an observationally validated nutrient recommendation approach. *European Journal of Agronomy* 132, 126409.
DOI: <http://doi.org/10.1016/j.eja.2021.126409>
- Hoerl, A.E., and Kennard, R.W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics* 12, 55-67. DOI: <http://doi.org/10.1080/00401706.1970.10488634>
- Holland, K.H., and Schepers, J.S. (2010). Derivation of a variable rate nitrogen application model for in-season fertilization of corn. *Agronomy Journal* 102, 1415-1424.
DOI: <http://doi.org/10.2134/agronj2010.0015>
- Hou, P., Jiang, Y., Yan, L., Petropoulos, E., Wang, J., Xue, L., Yang, L., and Chen, D. (2021). Effect of fertilization on nitrogen losses through surface runoffs in Chinese farmlands: a meta-analysis. *Science of the Total Environment* 793, 148554. DOI: <http://doi.org/10.1016/j.scitotenv.2021.148554>
- Hua, Y., Zhao, Z., Li, R., Chen, X., Liu, Z., and Zhang, H. (2019). Deep learning with long short-term memory for time series prediction. *IEEE Communications Magazine*, 57(6), 114-119.
DOI: <http://doi.org/10.1109/MCOM.2019.1800155>
- Huang, S., Miao, Y., Yuan, F., Cao, Q., Ye, H., Lenz-Wiedemann, V.I.S., and Bareth, G. (2019). In-season diagnosis of rice nitrogen status using proximal fluorescence canopy sensor at different growth stages. *Remote Sensing* 11, 1847. DOI: <http://doi.org/10.3390/rs11161847>
- Huang, S., Miao, Y., Zhao, G., Yuan, F., Ma, X., Tan, C., Yu, W., Gnyp, M., Lenz-Wiedemann, V., Rascher, U., and Bareth, G. (2015). Satellite remote sensing-based in-season diagnosis of rice nitrogen status in Northeast China. *Remote Sensing* 7, 10646-10667.
DOI: <http://doi.org/10.3390/rs70810646>
- Iatrou, M., Karydas, C., Iatrou, G., Pitsiorlas, I., Aschonitis, V., Raptis, I., Mpetas, S., Kravvas, K., and Mourelatos, S. (2021). Topdressing nitrogen demand prediction in rice crop using machine learning systems. *Agriculture* 11, 312. DOI: <http://doi.org/10.3390/agriculture11040312>
- Ji, J., Liu, J., Chen, J., Niu, Y., Xuan, K., Jiang, Y., Jia, R., Wang, C., and Li, X. (2021). Optimization of topdressing for winter wheat by accurate growth monitoring and improved production estimation. *Remote Sensing* 13, 2349. DOI: <http://doi.org/10.3390/rs13122349>
- Ji, L., Zheng, Z., Wu, T., Xie, Y., Liu, Z., Huang, G., and Niu, D. (2020). Synergetic optimization management of crop-biomass coproduction with food-energy-water nexus under uncertainties. *Journal of Cleaner Production* 258, 120645. DOI: <http://doi.org/10.1016/j.jclepro.2020.120645>
- Ji, Z., Pan, Y., Zhu, X., Zhang, D., and Wang, J. (2022). A generalized model to predict large-scale crop

- yields integrating satellite-based vegetation index time series and phenology metrics. *Ecological Indicators* 137, 108759. DOI: <http://doi.org/10.1016/j.ecolind.2022.108759>
- Jiang, J., Atkinson, P.M., Zhang, J., Lu, R., Zhou, Y., Cao, Q., Tian, Y., Zhu, Y., Cao, W., and Liu, X. (2022). Combining fixed-wing UAV multispectral imagery and machine learning to diagnose winter wheat nitrogen status at the farm scale. *European Journal of Agronomy* 138, 126537. DOI: <http://doi.org/10.1016/j.eja.2022.126537>
- Jiang, J., Zhang, Z., Cao, Q., Liang, Y., Krienke, B., Tian, Y., Zhu, Y., Cao, W., and Liu, X. (2020). Use of an active canopy sensor mounted on an unmanned aerial vehicle to monitor the growth and nitrogen status of winter wheat. *Remote Sensing* 12, 3684. DOI: <http://doi.org/10.3390/rs12223684>
- Jin, X., Li, Z., Feng, H., Ren, Z., and Li, S. (2020). Deep neural network algorithm for estimating maize biomass based on simulated sentinel 2A vegetation indices and leaf area index. *The Crop Journal* 8, 87-97. DOI: <http://doi.org/10.1016/j.cj.2019.06.005>
- Jin, Z., Jin, Z., Prasad, R., Prasad, R., Shriver, J., Shriver, J., Zhuang, Q., and Zhuang, Q. (2017). Crop model- and satellite imagery-based recommendation tool for variable rate N fertilizer application for the US corn system. *Precision Agriculture* 18, 779-800. DOI: <http://doi.org/10.1007/s11119-016-9488-z>
- Jovarauskas, D., Steponavičius, D., Kemzūraitė, A., Zinkevičius, R., and Venslauskas, K. (2021). Comparative analysis of the environmental impact of conventional and precision spring wheat fertilization under various meteorological conditions. *Journal of Environmental Management* 296, 113150. DOI: <http://doi.org/https://doi.org/10.1016/j.jenvman.2021.113150>
- Kakimoto, S., Mieno, T., Tanaka, T.S.T., and Bullock, D.S. (2022). Causal forest approach for site-specific input management via on-farm precision experimentation. *Computers and Electronics in Agriculture* 199, 107164. DOI: <http://doi.org/10.1016/j.compag.2022.107164>
- Kamir, E., Waldner, F., and Hochman, Z. (2020). Estimating wheat yields in Australia using climate records, satellite image time series and machine learning methods. *ISPRS Journal of Photogrammetry and Remote Sensing* 160, 124-135. DOI: <http://doi.org/10.1016/j.isprsjprs.2019.11.008>
- Kang, Y., Ozdogan, M., Zhu, X., Ye, Z., Hain, C., and Anderson, M. (2020). Comparative assessment of environmental variables and machine learning algorithms for maize yield prediction in the US Midwest. *Environmental Research Letters* 15, 64005. DOI: <http://doi.org/10.1088/1748-9326/ab7df9>
- Kanke, Y., Raun, W., Solie, J., Stone, M., and Taylor, R. (2012). Red edge as a potential index for detecting differences in plant nitrogen status in winter wheat. *Journal of Plant Nutrition* 35, 1526-1541. DOI: <http://doi.org/10.1080/01904167.2012.689912>

- Kara, A. (2021). Multi-step influenza outbreak forecasting using deep LSTM network and genetic algorithm. *Expert Systems with Applications* 180, 115153.
DOI: <http://doi.org/10.1016/j.eswa.2021.115153>
- Karatay, Y.N., and Meyer-Aurich, A. (2020). Profitability and downside risk implications of site-specific nitrogen management with respect to wheat grain quality. *Precision Agriculture* 21, 449-472. DOI: <http://doi.org/10.1007/s11119-019-09677-3>
- Katoch, S., Chauhan, S.S., and Kumar, V. (2021). A review on genetic algorithm: past, present, and future. *Multimedia Tools and Applications* 80, 8091-8126.
DOI: <http://doi.org/10.1007/s11042-020-10139-6>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T. (2017). LightGBM: a highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems* 30, 3146-3154.
- Kent Shannon, D., Clay, D.E., and Sudduth, K.A. (2018). An introduction to precision agriculture. *Precision agriculture basics* 1-12. DOI: <https://doi.org/10.2134/precisionagbasics.2016.0084>
- Khaki, S., Wang, L., and Archontoulis, S.V. (2019). A CNN-RNN framework for crop yield prediction. *Frontiers in Plant Science* 10, 1750. DOI: <http://doi.org/10.3389/fpls.2019.01750>
- Khaki, S., and Wang, L. (2019). Crop yield prediction using deep neural networks. *Frontiers in Plant Science* 10. DOI: <http://doi.org/10.3389/fpls.2019.00621>
- Khoshnevisan, B., Rafiee, S., Pan, J., Zhang, Y., and Liu, H. (2020). A multi-criteria evolutionary-based algorithm as a regional scale decision support system to optimize nitrogen consumption rate; A case study in North China Plain. *Journal of Cleaner Production* 256, 120213.
DOI: <http://doi.org/10.1016/j.jclepro.2020.120213>
- Kitchen, N.R., Shanahan, J.F., Ransom, C.J., Bandura, C.J., Bean, G.M., Camberato, J.J., Carter, P.R., Clark, J.D., Ferguson, R.B., Fernández, F.G., Franzen, D.W., Laboski, C.A.M., Nafziger, E.D., Qing, Z., Sawyer, J.E., and Shafer, M. (2017). A public-industry partnership for enhancing corn nitrogen research and datasets: project description, methodology, and outcomes. *Agronomy Journal* 109, 2371-2389. DOI: <http://doi.org/10.2134/agronj2017.04.0207>
- Kropp, I., Nejadhashemi, A.P., Deb, K., Abouali, M., Roy, P.C., Adhikari, U., and Hoogenboom, G. (2019). A multi-objective approach to water and nutrient efficiency for sustainable agricultural intensification. *Agricultural Systems* 173, 289-302. DOI: <http://doi.org/10.1016/j.agsy.2019.03.014>
- Kropp, I., Nejadhashemi, A.P., Jha, P., and Hernandez-Suarez, J.S. (2022). Agricultural innovization: an optimization-driven solution for sustainable agricultural intensification in michigan. *Computers and Electronics in Agriculture* 199, 107143. DOI: <http://doi.org/10.1016/j.compag.2022.107143>

- Ladha, J.K., Tirol-Padre, A., Reddy, C.K., Cassman, K.G., Verma, S., Powlson, D.S., van Kessel, C., de B. Richter, D., Chakraborty, D., and Pathak, H. (2016). Global nitrogen budgets in cereals: a 50-year assessment for maize, rice and wheat production systems. *Scientific Reports* 6.
DOI: <http://doi.org/10.1038/srep19355>
- Lapidus, D., Salem, M.E., Beach, R.H., Zayed, S., and Ortiz-Monasterio, I. (2022). Greenhouse gas mitigation benefits and profitability of the Greenseeker handheld NDVI sensor: evidence from Mexico. *Precision Agriculture* 23, 2388-2406. DOI: <http://doi.org/10.1007/s11119-022-09925-z>
- Laurent, C., Oger, B., Taylor, J.A., Scholasch, T., Metay, A., and Tisseyre, B. (2021). A review of the issues, methods and perspectives for yield estimation, prediction and forecasting in viticulture. *European Journal of Agronomy* 130, 126339. DOI: <http://doi.org/10.1016/j.eja.2021.126339>
- Lawes, R.A., Oliver, Y.M., and Huth, N.I. (2019). Optimal nitrogen rate can be predicted using average yield and estimates of soil water and leaf nitrogen with infield experimentation. *Agronomy Journal* 111, 1155-1164. DOI: <http://doi.org/10.2134/agronj2018.09.0607>
- Lawrence, P.G., Rew, L.J., and Maxwell, B.D. (2015). A probabilistic bayesian framework for progressively updating site-specific recommendations. *Precision Agriculture* 16, 275-296.
DOI: <http://doi.org/10.1007/s11119-014-9375-4>
- LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *Nature* 521, 436-444.
DOI: <http://doi.org/10.1038/nature14539>
- Leo, S., De Antoni Migliorati, M., and Grace, P.R. (2021). Predicting within-field cotton yields using publicly available datasets and machine learning. *Agronomy Journal* 113, 1150-1163. DOI: <http://doi.org/10.1002/agj2.20543>
- Li, A., Duval, B.D., Anex, R., Scharf, P., Ashtekar, J.M., Owens, P.R., and Ellis, C. (2016). A case study of environmental benefits of sensor-based nitrogen application in corn. *Journal of Environmental Quality* 45, 675-683. DOI: <http://doi.org/10.2134/jeq2015.07.0404>
- Li, D., Miao, Y., Ransom, C.J., Bean, G.M., Kitchen, N.R., Fernández, F.G., Sawyer, J.E., Camberato, J.J., Carter, P.R., Ferguson, R.B., Franzen, D.W., Laboski, C.A.M., Nafziger, E.D., and Shanahan, J.F. (2022a). Corn nitrogen nutrition index prediction improved by integrating genetic, environmental, and management factors with active canopy sensing using machine learning. *Remote Sensing* 14, 394.
DOI: <http://doi.org/10.3390/rs14020394>
- Li, D., Zhang, P., Chen, T., and Qin, W. (2020). Recent development and challenges in spectroscopy and machine vision technologies for crop nitrogen diagnosis: a review. *Remote Sensing* 12, 2578. DOI: <http://doi.org/10.3390/rs12162578>
- Li, F., Miao, Y., Feng, G., Yuan, F., Yue, S., Gao, X., Liu, Y., Liu, B., Ustin, S.L., and Chen, X. (2014a).

- Improving estimation of summer maize nitrogen status with red edge-based spectral vegetation indices. *Field Crops Research* 157, 111-123. DOI: <http://doi.org/10.1016/j.fcr.2013.12.018>
- Li, F., Mistele, B., Hu, Y., Chen, X., and Schmidhalter, U. (2014b). Reflectance estimation of canopy nitrogen content in winter wheat using optimised hyperspectral spectral indices and partial least squares regression. *European Journal of Agronomy* 52, 198-209.
DOI: <http://doi.org/10.1016/j.eja.2013.09.006>
- Li, L., Wang, B., Feng, P., Wang, H., He, Q., Wang, Y., Liu, D.L., Li, Y., He, J., Feng, H., Yang, G., and Yu, Q. (2021a). Crop yield forecasting and associated optimum lead time analysis based on multi-source environmental data across China. *Agricultural and Forest Meteorology* 308-309, 108558. DOI: <http://doi.org/10.1016/j.agrformet.2021.108558>
- Li, Y., Guan, K., Yu, A., Peng, B., Zhao, L., Li, B., and Peng, J. (2019). Toward building a transparent statistical model for improving crop yield prediction: Modeling rainfed corn in the U.S. *Field Crops Research* 234, 55-65. DOI: <http://doi.org/10.1016/j.fcr.2019.02.005>
- Li, Y., Miao, Y., Zhang, J., Cammarano, D., Li, S., Liu, X., Tian, Y., Zhu, Y., Cao, W., and Cao, Q. (2022b). Improving estimation of winter wheat nitrogen status using random forest by integrating multi-source data across different agro-ecological zones. *Frontiers in Plant Science* 13.
DOI: <http://doi.org/10.3389/fpls.2022.890892>
- Li, Z., Zeng, Z., Song, Z., Wang, F., Tian, D., Mi, W., Huang, X., Wang, J., Song, L., Yang, Z., Wang, J., Feng, H., Jiang, L., Chen, Y., Luo, Y., and Niu, S. (2021b). Vital roles of soil microbes in driving terrestrial nitrogen immobilization. *Global change biology* 27, 1848-1858.
DOI: <http://doi.org/10.1111/gcb.15552>
- Li, Z., Zhao, Y., Taylor, J., Gaulton, R., Jin, X., Song, X., Li, Z., Meng, Y., Chen, P., Feng, H., Wang, C., Guo, W., Xu, X., Chen, L., and Yang, G. (2022c). Comparison and transferability of thermal, temporal and phenological-based in-season predictions of above-ground biomass in wheat crops from proximal crop reflectance data. *Remote Sensing of Environment* 273, 112967.
DOI: <http://doi.org/10.1016/j.rse.2022.112967>
- Liakos, K., Busato, P., Moshou, D., Pearson, S., and Bochtis, D. (2018). Machine learning in agriculture: a review. *Sensors* 18, 2674. DOI: <http://doi.org/10.3390/s18082674>
- Liang, X., Lam, S.K., Zhang, X., Oenema, O., and Chen, D. (2021). Pursuing sustainable nitrogen management following the “5 ps” principles: production, people, planet, policy and partnerships. *Global Environmental Change* 70, 102346. DOI: <http://doi.org/10.1016/j.gloenvcha.2021.102346>
- Lin, T., Zhong, R., Wang, Y., Xu, J., Jiang, H., Xu, J., Ying, Y., Rodriguez, L., Ting, K.C., and Li, H. (2020). DeepCropNet: a deep spatial-temporal learning framework for county-level corn yield

- estimation. *Environmental Research Letters* 15, 34016.
DOI: <http://doi.org/10.1088/1748-9326/ab66cb>
- Lin, Z., Zhong, R., Xiong, X., Guo, C., Xu, J., Zhu, Y., Xu, J., Ying, Y., Ting, K.C., Huang, J., and Lin, T. (2022). Large-scale rice mapping using multi-task spatiotemporal deep learning and sentinel-1 SAR time series. *Remote Sensing* 14, 699. DOI: <http://doi.org/10.3390/rs14030699>
- Liu, D., Song, C., Xin, Z., Fang, C., and Liu, Z. (2022). Spatial patterns and driving factor analysis of recommended nitrogen application rate for the trade-off between economy and environment for maize in China. *Journal of Environmental Management* 322, 116099.
DOI: <http://doi.org/10.1016/j.jenvman.2022.116099>
- Liu, H., Xiong, W., Mottaleb, K.A., Krupnik, T.J., Burgueño, J., Pequeno, D.N.L., and Wu, W. (2021a). Contrasting contributions of five factors to wheat yield growth in China by process-based and statistical models. *European Journal of Agronomy* 130, 126370.
DOI: <http://doi.org/10.1016/j.eja.2021.126370>
- Liu, L., Ji, H., An, J., Shi, K., Ma, J., Liu, B., Tang, L., Cao, W., and Zhu, Y. (2019). Response of biomass accumulation in wheat to low-temperature stress at jointing and booting stages. *Environmental and Experimental Botany* 157, 46-57. DOI: <http://doi.org/10.1016/j.envexpbot.2018.09.026>
- Liu, T., Xu, T., Yu, F., Yuan, Q., Guo, Z., and Xu, B. (2021b). A method combining ELM and PLSR (ELM-P) for estimating chlorophyll content in rice with feature bands extracted by an improved ant colony optimization algorithm. *Computers and Electronics in Agriculture* 186, 106177. DOI: <http://doi.org/10.1016/j.compag.2021.106177>
- Liu, Y., Zhang, S., Zhang, J., Tang, L., and Bai, Y. (2021c). Assessment and comparison of six machine learning models in estimating evapotranspiration over croplands using remote sensing and meteorological factors. *Remote Sensing* 13, 3838.
DOI: <http://doi.org/10.3390/rs13193838>
- Louppe, G. (2014). Understanding random forests: from theory to practice. *Arxiv Preprint Arxiv:1407.7502*. DOI: <https://doi.org/10.48550/arXiv.1407.7502>
- Lu, J., Miao, Y., Shi, W., Li, J., Hu, X., Chen, Z., Wang, X., and Kusnierek, K. (2020a). Developing a proximal active canopy sensor-based precision nitrogen management strategy for high-yielding rice. *Remote Sensing* 12, 1440. DOI: <http://doi.org/10.3390/rs12091440>
- Lu, J., Miao, Y., Shi, W., Li, J., Hu, X., Chen, Z., Wang, X., and Kusnierek, K. (2020b). Developing a proximal active canopy sensor-based precision nitrogen management strategy for high-yielding rice. *Remote Sensing* 12, 1440. DOI: <http://doi.org/10.3390/rs12091440>
- Lundberg, S.M., and Lee, S. (2017). A unified approach to interpreting model predictions. *Advances in*

- Neural Information Processing Systems* 30.
- Ma, X., Chen, P., and Jin, X. (2022). Predicting wheat leaf nitrogen content by combining deep multitask learning and a mechanistic model using UAV hyperspectral images. *Remote Sensing* 14, 6334. DOI: <http://doi.org/10.3390/rs14246334>
- Maestrini, B., Mimić, G., van Oort, P.A.J., Jindo, K., Brdar, S., Athanasiadis, I.N., and van Evert, F.K. (2022). Mixing process-based and data-driven approaches in yield prediction. *European Journal of Agronomy* 139, 126569. DOI: <http://doi.org/10.1016/j.eja.2022.126569>
- Maimaitijiang, M., Sagan, V., Sidike, P., Hartling, S., Esposito, F., and Fritschi, F.B. (2020). Soybean yield prediction from UAV using multimodal data fusion and deep learning. *Remote Sensing of Environment* 237, 111599. DOI: <http://doi.org/10.1016/j.rse.2019.111599>
- Mandrini, G., Bullock, D.S., and Martin, N.F. (2021). Modeling the economic and environmental effects of corn nitrogen management strategies in Illinois. *Field Crops Research* 261, 108000. DOI: <http://doi.org/10.1016/j.fcr.2020.108000>
- Mandrini, G., Pittelkow, C.M., Archontoulis, S., Kanter, D., and Martin, N.F. (2022). Exploring trade-offs between profit, yield, and the environmental footprint of potential nitrogen fertilizer regulations in the US Midwest. *Frontiers in Plant Science* 13. DOI: <http://doi.org/10.3389/fpls.2022.852116>
- Mandrini, G., Pittelkow, C.M., Archontoulis, S.V., Mieno, T., and Martin, N.F. (2021). Understanding differences between static and dynamic nitrogen fertilizer tools using simulation modeling. *Agricultural Systems* 194, 103275. DOI: <http://doi.org/10.1016/j.agsy.2021.103275>
- Marti, J., Bort, J., Slafer, G.A., and Araus, J.L. (2007). Can wheat yield be assessed by early measurements of normalized difference vegetation index? *Annals of Applied Biology* 150, 253-257. DOI: <http://doi.org/https://doi.org/10.1111/j.1744-7348.2007.00126.x>
- Maya Gopal, P.S., and Bhargavi, R. (2019). A novel approach for efficient crop yield prediction. *Computers and Electronics in Agriculture* 165, 104968. DOI: <http://doi.org/10.1016/j.compag.2019.104968>
- McFadden, B.R., Brorsen, B.W., and Raun, W.R. (2018). Nitrogen fertilizer recommendations based on plant sensing and bayesian updating. *Precision Agriculture* 19, 79-92. DOI: <http://doi.org/10.1007/s11119-017-9499-4>
- Morari, F., Zanella, V., Gobbo, S., Bindi, M., Sartori, L., Pasqui, M., Mosca, G., and Ferrise, R. (2020). Coupling proximal sensing, seasonal forecasts and crop modelling to optimize nitrogen variable rate application in durum wheat. *Precision Agriculture* 22, 75. DOI: <http://doi.org/10.1007/s11119-020-09730-6>
- Morris, T.F., Murrell, T.S., Beegle, D.B., Camberato, J.J., Ferguson, R.B., Grove, J., Ketterings, Q.,

- Kyveryga, P.M., Laboski, C.A.M., McGrath, J.M., Meisinger, J.J., Melkonian, J., Moebius-Clune, B.N., Nafziger, E.D., Osmond, D., Sawyer, J.E., Scharf, P.C., Smith, W., Spargo, J.T., van Es, H.M., and Yang, H. (2018). Strengths and limitations of nitrogen rate recommendations for corn and opportunities for improvement. *Agronomy Journal* 110, 1-37.
DOI: <http://doi.org/10.2134/agronj2017.02.0112>
- Moshou, D., Bravo, C., Wahlen, S., West, J., McCartney, A., Baerdemaeker, J.D., and Ramon, H. (2006). Simultaneous identification of plant stresses and diseases in arable crops using proximal optical sensing and self-organising maps. *Precision Agriculture* 7, 149-164.
DOI: <http://doi.org/10.1007/s11119-006-9002-0>
- Mousavi-Avval, S.H., Rafiee, S., Sharifi, M., Hosseinpour, S., Notarnicola, B., Tassielli, G., and Renzulli, P.A. (2017). Application of multi-objective genetic algorithms for optimization of energy, economics and environmental life cycle assessment in oilseed production. *Journal of Cleaner Production* 140, 804-815. DOI: <http://doi.org/10.1016/j.jclepro.2016.03.075>
- Murtagh, F. (1991). Multilayer perceptrons for classification and regression. *Neurocomputing* 2, 183-197.
DOI: [http://doi.org/10.1016/0925-2312\(91\)90023-5](http://doi.org/10.1016/0925-2312(91)90023-5)
- Nesarani, A., Ramar, R., and Pandian, S. (2020). An efficient approach for rice prediction from authenticated block chain node using machine learning technique. *Environmental Technology & Innovation* 20, 101064. DOI: <http://doi.org/10.1016/j.eti.2020.101064>
- Padilla, F.M., Gallardo, M., Peña-Fleitas, M.T., de Souza, R., and Thompson, R.B. (2018). Proximal optical sensors for nitrogen management of vegetable crops: a review. *Sensors* 18, 2083. DOI: <http://doi.org/10.3390/s18072083>
- Pancorbo, J.L., Camino, C., Alonso-Ayuso, M., Raya-Sereno, M.D., Gonzalez-Fernandez, I., Gabriel, J.L., Zarco-Tejada, P.J., and Quemada, M. (2021). Simultaneous assessment of nitrogen and water status in winter wheat using hyperspectral and thermal sensors. *European Journal of Agronomy* 127, 126287. DOI: <http://doi.org/10.1016/j.eja.2021.126287>
- Pantazi, X., Moshou, D., and Bravo, C. (2016). Active learning system for weed species recognition based on hyperspectral sensing. *Biosystems Engineering* 146, 193-202.
DOI: <http://doi.org/https://doi.org/10.1016/j.biosystemseng.2016.01.014>
- Pantazi, X.E., Moshou, D., Alexandridis, T., Whetton, R.L., and Mouazen, A.M. (2016). Wheat yield prediction using machine learning and advanced sensing techniques. *Computers and Electronics in Agriculture* 121, 57-65. DOI: <http://doi.org/10.1016/j.compag.2015.11.018>
- Pedersen, M.F., Gyldegren, J.G., Pedersen, S.M., Diamantopoulos, E., Gislum, R., and Styczen, M.E. (2021). A simulation of variable rate nitrogen application in winter wheat with soil and sensor

- information - An economic feasibility study. *Agricultural Systems* 192, 103147.
DOI: <http://doi.org/10.1016/j.agsy.2021.103147>
- Puntel, L.A., Pagani, A., and Archontoulis, S.V. (2019). Development of a nitrogen recommendation tool for corn considering static and dynamic variables. *European Journal of Agronomy* 105, 189-199.
DOI: <http://doi.org/10.1016/j.eja.2019.01.003>
- Qin, Z., Myers, D.B., Ransom, C.J., Kitchen, N.R., Liang, S., Camberato, J.J., Carter, P.R., Ferguson, R.B., Fernandez, F.G., Franzen, D.W., Laboski, C.A.M., Malone, B.D., Nafziger, E.D., Sawyer, J.E., and Shanahan, J.F. (2018). Application of machine learning methodologies for predicting corn economic optimal nitrogen rate. *Agronomy Journal* 110, 2596-2607.
DOI: <http://doi.org/10.2134/agronj2018.03.0222>
- Qiu, Z., Ma, F., Li, Z., Xu, X., Ge, H., and Du, C. (2021). Estimation of nitrogen nutrition index in rice from UAV RGB images coupled with machine learning algorithms. *Computers and Electronics in Agriculture* 189, 106421. DOI: <http://doi.org/10.1016/j.compag.2021.106421>
- Ransom, C.J., Kitchen, N.R., Camberato, J.J., Carter, P.R., Ferguson, R.B., Fernández, F.G., Franzen, D.W., Laboski, C.A.M., Myers, D.B., Nafziger, E.D., Sawyer, J.E., and Shanahan, J.F. (2019). Statistical and machine learning methods evaluated for incorporating soil and weather into corn nitrogen recommendations. *Computers and Electronics in Agriculture* 164, 104872. DOI: <http://doi.org/10.1016/j.compag.2019.104872>
- Ransom, C.J., Kitchen, N.R., Sawyer, J.E., Camberato, J.J., Carter, P.R., Ferguson, R.B., Fernandez, F.G., Franzen, D.W., Laboski, C., Myers, D.B., Nafziger, E.D., and Shanahan, J.F. (2021). Improving publicly available corn nitrogen rate recommendation tools with soil and weather measurements. *Agronomy Journal* 113, 2068-2090. DOI: <http://doi.org/10.1002/agj2.20627>
- Raun, W.R., Solie, J.B., Johnson, G.V., Stone, M.L., Mullen, R.W., Freeman, K.W., Thomason, W.E., and Lukina, E.V. (2002). Improving nitrogen use efficiency in cereal grain production with optical sensing and variable rate application. *Agronomy Journal* 94, 815-820.
DOI: <https://doi.org/10.2134/agronj2002.8150>
- Ren, K., Xu, M., Li, R., Zheng, L., Liu, S., Reis, S., Wang, H., Lu, C., Zhang, W., Gao, H., Duan, Y., and Gu, B. (2022). Optimizing nitrogen fertilizer use for more grain and less pollution. *Journal of Cleaner Production* 360, 132180. DOI: <http://doi.org/10.1016/j.jclepro.2022.132180>
- Rigden, A.J., Mueller, N.D., Holbrook, N.M., Pillai, N., and Huybers, P. (2020). Combined influence of soil moisture and atmospheric evaporative demand is important for accurately predicting us maize yields. *Nature Food* 1, 127-133. DOI: <http://doi.org/10.1038/s43016-020-0028-7>
- Roy, E.D., Hammond Wagner, C.R., and Niles, M.T. (2021). Hot spots of opportunity for improved

- cropland nitrogen management across the United States. *Environmental Research Letters* 16, 35004. DOI: <http://doi.org/10.1088/1748-9326/abd662>
- Sagan, V., Maimaitijiang, M., Bhadra, S., Maimaitiyiming, M., Brown, D.R., Sidike, P., and Fritschi, F.B. (2021). Field-scale crop yield prediction using multi-temporal worldview-3 and planetscope satellite data and deep learning. *ISPRS Journal of Photogrammetry and Remote Sensing* 174, 265-281. DOI: <http://doi.org/10.1016/j.isprsjprs.2021.02.008>
- Sela, S., van Es, H.M., Moebius-Clune, B.N., Marjerison, R., and Kneubuhler, G. (2018). Dynamic model-based recommendations increase the precision and sustainability of n fertilization in Midwestern US maize production. *Computers and Electronics in Agriculture* 153, 256-265. DOI: <http://doi.org/10.1016/j.compag.2018.08.010>
- Sener, O., and Koltun, V. (2018). Multi-task learning as multi-objective optimization. *Advances in Neural Information Processing Systems* 31.
- Shahhosseini, M., Hu, G., Khaki, S., and Archontoulis, S.V. (2021). Corn yield prediction with ensemble CNN-DNN. *Frontiers in Plant Science* 12. DOI: <http://doi.org/10.3389/fpls.2021.709008>
- Shi, Y., Zhu, Y., Wang, X., Sun, X., Ding, Y., Cao, W., and Hu, Z. (2020). Progress and development on biological information of crop phenotype research applied to real-time variable-rate fertilization. *Plant Methods* 16. DOI: <http://doi.org/10.1186/s13007-020-0559-9>
- Sishodia, R.P., Ray, R.L., and Singh, S.K. (2020). Applications of remote sensing in precision agriculture: a review. *Remote Sensing* 12, 3136. DOI: <http://doi.org/10.3390/rs12193136>
- Smola, A.J., and Schölkopf, B. (2004). A tutorial on support vector regression. *Statistics and Computing* 14, 199-222. DOI: <http://doi.org/10.1023/B:STCO.0000035301.49549.88>
- Srivastava, A.K., Safaei, N., Khaki, S., Lopez, G., Zeng, W., Ewert, F., Gaiser, T., and Rahimi, J. (2021). Comparison of machine learning methods for predicting winter wheat yield in germany. *Arxiv Preprint Arxiv:2105.01282*.
- Sun, J., Di, L., Sun, Z., Shen, Y., and Lai, Z. (2019). County-level soybean yield prediction using deep CNN-LSTM model. *Sensors* 19, 4363. DOI: <http://doi.org/10.3390/s19204363>
- Sun, Z., Li, Q., Jin, S., Song, Y., Xu, S., Wang, X., Cai, J., Zhou, Q., Ge, Y., Zhang, R., Zang, J., and Jiang, D. (2022). Simultaneous prediction of wheat yield and grain protein content using multitask deep learning from time-series proximal sensing. *Plant Phenomics* 2022, 1-13. DOI: <http://doi.org/10.34133/2022/9757948>
- Suruliandi, A., Mariammal, G., and Raja, S.P. (2021). Crop prediction based on soil and environmental characteristics using feature selection techniques. *Mathematical and Computer Modelling of Dynamical Systems* 27, 117-140. DOI: <http://doi.org/10.1080/13873954.2021.1882505>

- Tack, J., Barkley, A., and Nalley, L.L. (2015). Effect of warming temperatures on us wheat yields. *Proceedings of the National Academy of Sciences* 112, 6931-6936.
DOI: <http://doi.org/10.1073/pnas.1415181112>
- Tao, F., Xiao, D., Zhang, S., Zhang, Z., and Rötter, R.P. (2017). Wheat yield benefited from increases in minimum temperature in the Huang-Huai-Hai Plain of China in the past three decades. *Agricultural and Forest Meteorology* 239, 1-14. DOI: <http://doi.org/10.1016/j.agrformet.2017.02.033>
- Tardieu, F., Cabrera-Bosquet, L., Pridmore, T., and Bennett, M. (2017). Plant phenomics, from sensors to knowledge. *Current Biology* 27, R770-R783. DOI: <http://doi.org/10.1016/j.cub.2017.05.055>
- Thompson, L.J., and Puntel, L.A. (2020). Transforming unmanned aerial vehicle (UAV) and multispectral sensor into a practical decision support system for precision nitrogen management in corn. *Remote Sensing* 12, 1597. DOI: <http://doi.org/10.3390/rs12101597>
- Thorp, K.R., Wang, G., Bronson, K.F., Badaruddin, M., and Mon, J. (2017). Hyperspectral data mining to identify relevant canopy spectral features for estimating durum wheat growth, nitrogen status, and grain yield. *Computers and Electronics in Agriculture* 136, 1-12.
DOI: <http://doi.org/10.1016/j.compag.2017.02.024>
- Tian, H., Wang, P., Tansey, K., Han, D., Zhang, J., Zhang, S., and Li, H. (2021). A deep learning framework under attention mechanism for wheat yield estimation using remotely sensed indices in the Guanzhong Plain, PR China. *International Journal of Applied Earth Observation and Geoinformation* 102, 102375. DOI: <http://doi.org/10.1016/j.jag.2021.102375>
- Tian, H., Wang, P., Tansey, K., Zhang, S., Zhang, J., and Li, H. (2020). An IPSO-BP neural network for estimating wheat yield using two remotely sensed variables in the Guanzhong Plain, PR China. *Computers and Electronics in Agriculture* 169, 105180.
DOI: <http://doi.org/10.1016/j.compag.2019.105180>
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)* 58, 267-288.
DOI: <http://doi.org/10.1111/j.2517-6161.1996.tb02080.x>
- Tremblay, N., Bouroubi, M.Y., Panneton, B., Guillaume, S., Vigneault, P., and Bélec, C. (2010). Development and validation of fuzzy logic inference to determine optimum rates of N for corn on the basis of field and crop features. *Precision Agriculture* 11, 621-635.
DOI: <http://doi.org/10.1007/s11119-010-9188-z>
- Tremblay, N., Bouroubi, Y.M., Bélec, C., Mullen, R.W., Kitchen, N.R., Thomason, W.E., Ebelhar, S., Mengel, D.B., Raun, W.R., and Francis, D.D. (2012). Corn response to nitrogen is influenced by soil texture and weather. *Agronomy Journal* 104, 1658-1671.

- DOI: <https://doi.org/10.2134/agronj2012.0184>
- van Klompenburg, T., Kassahun, A., and Catal, C. (2020). Crop yield prediction using machine learning: a systematic literature review. *Computers and Electronics in Agriculture* 177, 105709. DOI: <http://doi.org/10.1016/j.compag.2020.105709>
- Vikhar, P.A. (2016). Evolutionary algorithms: a critical review and its future prospects. In *2016 International conference on global trends in signal processing, information computing and communication (ICGTSPICC)* 261-265. IEEE.
DOI: <http://doi.org/10.1109/ICGTSPICC.2016.7955308>
- Walsh, O.S., Klatt, A.R., Solie, J.B., Godsey, C.B., and Raun, W.R. (2013). Use of soil moisture data for refined Greenseeker sensor-based nitrogen recommendations in winter wheat (*Triticum aestivum* L.). *Precision Agriculture* 14, 343-356. DOI: <http://doi.org/10.1007/s11119-012-9299-9>
- Wang, F., Yang, M., Ma, L., Zhang, T., Qin, W., Li, W., Zhang, Y., Sun, Z., Wang, Z., Li, F., and Yu, K. (2022). Estimation of above-ground biomass of winter wheat based on consumer-grade multi-spectral UAV. *Remote Sensing* 14, 1251. DOI: <http://doi.org/10.3390/rs14051251>
- Wang, H., Zhang, Y., Chen, A., Liu, H., Zhai, L., Lei, B., and Ren, T. (2017). An optimal regional nitrogen application threshold for wheat in the North China Plain considering yield and environmental effects. *Field Crops Research* 207, 52-61. DOI: <http://doi.org/10.1016/j.fcr.2017.03.002>
- Wang, L., Chen, S., Li, D., Wang, C., Jiang, H., Zheng, Q., and Peng, Z. (2021a). Estimation of paddy rice nitrogen content and accumulation both at leaf and plant levels from UAV hyperspectral imagery. *Remote Sensing* 13, 2956. DOI: <http://doi.org/10.3390/rs13152956>
- Wang, L., Wang, P., Liang, S., Zhu, Y., Khan, J., and Fang, S. (2020a). Monitoring maize growth on the North China Plain using a hybrid genetic algorithm-based back-propagation neural network model. *Computers and Electronics in Agriculture* 170, 105238.
DOI: <http://doi.org/10.1016/j.compag.2020.105238>
- Wang, X., Huang, J., Feng, Q., and Yin, D. (2020b). Winter wheat yield prediction at county level and uncertainty analysis in main wheat-producing regions of China with deep learning approaches. *Remote Sensing* 12, 1744. DOI: <http://doi.org/10.3390/rs12111744>
- Wang, X., Miao, Y., Dong, R., Chen, Z., Guan, Y., Yue, X., Fang, Z., and Mulla, D. (2019). Developing active canopy sensor-based precision nitrogen management strategies for maize in Northeast China. *Sustainability* 11, 706. DOI: <http://doi.org/10.3390/su11030706>
- Wang, X., Miao, Y., Dong, R., Chen, Z., Kusnierek, K., Mi, G., and Mulla, D.J. (2020c). Economic optimal nitrogen rate variability of maize in response to soil and weather conditions: implications for site-specific nitrogen management. *Agronomy* 10, 1237.

- DOI: <http://doi.org/10.3390/agronomy10091237>
- Wang, X., Miao, Y., Dong, R., Zha, H., Xia, T., Chen, Z., Kusnierek, K., Mi, G., Sun, H., and Li, M. (2021b). Machine learning-based in-season nitrogen status diagnosis and side-dress nitrogen recommendation for corn. *European Journal of Agronomy* 123, 126193. DOI: <http://doi.org/10.1016/j.eja.2020.126193>
- Wang, Y., Zhang, Z., Feng, L., Du, Q., and Runge, T. (2020d). Combining multi-source data and machine learning approaches to predict winter wheat yield in the conterminous United States. *Remote Sensing* 12, 1232. DOI: <http://doi.org/10.3390/rs12081232>
- Wen, G., Ma, B., Vanasse, A., Caldwell, C.D., Earl, H.J., and Smith, D.L. (2021). Machine learning-based canola yield prediction for site-specific nitrogen recommendations. *Nutrient Cycling in Agroecosystems* 121, 241-256. DOI: <http://doi.org/10.1007/s10705-021-10170-5>
- Wen, G., Ma, B., Vanasse, A., Caldwell, C.D., and Smith, D.L. (2022). Optimizing machine learning-based site-specific nitrogen application recommendations for canola production. *Field Crops Research* 288, 108707. DOI: <http://doi.org/10.1016/j.fcr.2022.108707>
- West, J. (2019). Multi-criteria evolutionary algorithm optimization for horticulture crop management. *Agricultural Systems* 173, 469-481. DOI: <http://doi.org/10.1016/j.agsy.2019.03.016>
- Whitmire, C.D., Vance, J.M., Rasheed, H.K., Missaoui, A., Rasheed, K.M., and Maier, F.W. (2021). Using machine learning and feature selection for alfalfa yield prediction. *AI* 2, 71-88. DOI: <http://doi.org/10.3390/ai2010006>
- Wu, J., Tao, R., Zhao, P., Martin, N. F., & Hovakimyan, N. (2022). Optimizing nitrogen management with deep reinforcement learning and crop simulations. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* 1712-1720. DOI: <http://doi.org/10.1109/CVPRW56347.2022.00178>
- Xu, H., Zhang, X., Ye, Z., Jiang, L., Qiu, X., Tian, Y., Zhu, Y., and Cao, W. (2021). Machine learning approaches can reduce environmental data requirements for regional yield potential simulation. *European Journal of Agronomy* 129, 126335. DOI: <http://doi.org/10.1016/j.eja.2021.126335>
- Xu, J., Yang, J., Xiong, X., Li, H., Huang, J., Ting, K.C., Ying, Y., and Lin, T. (2021). Towards interpreting multi-temporal deep learning models in crop mapping. *Remote Sensing of Environment* 264, 112599. DOI: <http://doi.org/10.1016/j.rse.2021.112599>
- Xu, X., Fan, L., Li, Z., Meng, Y., Feng, H., Yang, H., and Xu, B. (2021). Estimating leaf nitrogen content in corn based on information fusion of multiple-sensor imagery from UAV. *Remote Sensing* 13, 340. DOI: <http://doi.org/10.3390/rs13030340>
- Yang, M., Xu, X., Li, Z., Meng, Y., Yang, X., Song, X., Yang, G., Xu, S., Zhu, Q., and Xue, H. (2022).

- Remote sensing prescription for rice nitrogen fertilizer recommendation based on improved nfoa model. *Agronomy* 12, 1804. DOI: <http://doi.org/10.3390/agronomy12081804>
- Yao, X., Ren, H., Cao, Z., Tian, Y., Cao, W., Zhu, Y., and Cheng, T. (2014). Detecting leaf nitrogen content in wheat with canopy hyperspectrum under different soil backgrounds. *International Journal of Applied Earth Observation and Geoinformation* 32, 114-124. DOI: <http://doi.org/10.1016/j.jag.2014.03.014>
- Yue, S., Meng, Q., Zhao, R., Li, F., Chen, X., Zhang, F., Cui, Z. (2012a). Critical nitrogen dilution curve for optimizing nitrogen management of winter wheat production in the North China Plain. *Agronomy Journal* 104, 523-529. DOI: <https://doi.org/10.2134/agronj2011.0258>
- Yue, S., Meng, Q., Zhao, R., Ye, Y., Zhang, F., Cui, Z., and Chen, X. (2012b). Change in nitrogen requirement with increasing grain yield for winter wheat. *Agronomy Journal* 104, 1687-1693. DOI: <http://doi.org/10.2134/agronj2012.0232>
- Zha, H., Miao, Y., Wang, T., Li, Y., Zhang, J., Sun, W., Feng, Z., and Kusnierek, K. (2020). Improving unmanned aerial vehicle remote sensing-based rice nitrogen nutrition index prediction with machine learning. *Remote Sensing* 12, 215. DOI: <http://doi.org/10.3390/rs12020215>
- Zhang, A., Hochman, Z., Horan, H., Navarro, J.G., Das, B.T., and Waldner, F. (2019a). Socio-psychological and management drivers explain farm level wheat yield gaps in Australia. *Agronomy for Sustainable Development* 39. DOI: <http://doi.org/10.1007/s13593-019-0556-4>
- Zhang, J., Liu, X., Liang, Y., Cao, Q., Tian, Y., Zhu, Y., Cao, W., and Liu, X. (2019b). Using a portable active sensor to monitor growth parameters and predict grain yield of winter wheat. *Sensors* 19, 1108. DOI: <http://doi.org/10.3390/s19051108>
- Zhang, J., Wang, W., Krienke, B., Cao, Q., Zhu, Y., Cao, W., and Liu, X. (2022a). In-season variable rate nitrogen recommendation for wheat precision production supported by fixed-wing UAV imagery. *Precision Agriculture* 23, 830-853. DOI: <http://doi.org/10.1007/s11119-021-09863-2>
- Zhang, K., Ma, J., Wang, Y., Cao, W., Zhu, Y., Cao, Q., Liu X., and Tian, Y. (2022b). Key variable for simulating critical nitrogen dilution curve of wheat: leaf area ratio-driven approach. *Pedosphere*, 32, 12. DOI: [https://doi.org/10.1016/S1002-0160\(21\)60086-3](https://doi.org/10.1016/S1002-0160(21)60086-3)
- Zhang, K., Liang, X., Zhang, Y., Liu, X., Cao, Q., Zhu, Y., Cao, W., Chen, D., and Tian, Y. (2023). Unveiling the environmental and socioeconomic benefits of precision nitrogen management for paddy fields in subtropical China. *European Journal of Agronomy* 142, 126663. DOI: <http://doi.org/10.1016/j.eja.2022.126663>
- Zhang, L., Zhang, Z., Luo, Y., Cao, J., and Tao, F. (2020). Combining optical, fluorescence, thermal satellite, and environmental data to predict county-level maize yield in China using machine learning

- approaches. *Remote Sensing* 12, 21. DOI: <http://doi.org/10.3390/rs12010021>
- Zhang, X., Davidson, E.A., Mauzerall, D.L., Searchinger, T.D., Dumas, P., and Shen, Y. (2015). Managing nitrogen for sustainable development. *Nature* 528, 51-59. DOI: <http://doi.org/10.1038/nature15743>
- Zhang, Y., Wang, H., Lei, Q., Luo, J., Lindsey, S., Zhang, J., Zhai, L., Wu, S., Zhang, J., Liu, X., Ren, T., and Liu, H. (2018). Optimizing the nitrogen application rate for maize and wheat based on yield and environment on the Northern China Plain. *Science of the Total Environment* 618, 1173-1183. DOI: <http://doi.org/10.1016/j.scitotenv.2017.09.183>
- Zhao, W., Liu, L., Shen, Q., Yang, J., Han, X., Tian, F., and Wu, J. (2020a). Effects of water stress on photosynthesis, yield, and water use efficiency in winter wheat. *Water* 12, 2127. DOI: <http://doi.org/10.3390/w12082127>
- Zhao, Y., Meng, Y., Han, S., Feng, H., Yang, G., and Li, Z. (2022). Should phenological information be applied to predict agronomic traits across growth stages of winter wheat? *The Crop Journal* 10, 1346-1352. DOI: <http://doi.org/10.1016/j.cj.2022.08.003>
- Zhao, Y., Potgieter, A.B., Zhang, M., Wu, B., and Hammer, G.L. (2020b). Predicting wheat yield at the field scale by combining high-resolution sentinel-2 satellite imagery and crop modelling. *Remote Sensing* 12, 1024. DOI: <http://doi.org/10.3390/rs12061024>
- Zheng, D., Yang, X., Mínguez, M.I., Mu, C., He, Q., and Wu, X. (2018). Effect of freezing temperature and duration on winter survival and grain yield of winter wheat. *Agricultural and Forest Meteorology* 260-261, 1-8. DOI: <http://doi.org/10.1016/j.agrformet.2018.05.011>
- Zheng, Y., Song, Q., and Chen, S. (2013). Multiobjective fireworks optimization for variable-rate fertilization in oil crop production. *Applied Soft Computing* 13, 4253-4263. DOI: <http://doi.org/10.1016/j.asoc.2013.07.004>
- Zhou, L., Chen, G., Miao, Y., Zhang, H., Chen, Z., Xu, L., and Guo, L. (2017). Evaluating a Crop Circle active sensor-based in-season nitrogen management algorithm in different winter wheat cropping systems. *Advances in Animal Biosciences* 8, 364-367. DOI: <http://doi.org/10.1017/S2040470017000292>
- Zhou, X., Kono, Y., Win, A., Matsui, T., and Tanaka, T.S.T. (2021). Predicting within-field variability in grain yield and protein content of winter wheat using UAV-based multispectral imagery and machine learning approaches. *Plant Production Science* 24, 137-151. DOI: <http://doi.org/10.1080/1343943X.2020.1819165>
- Zou, H., and Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 67, 301-320. DOI: <http://doi.org/10.1111/j.1467-9868.2005.00503.x>

Zou, L., Wang, L., Xia, L., Lin, A., Hu, B., and Zhu, H. (2017). Prediction and comparison of solar radiation using improved empirical models and adaptive neuro-fuzzy inference systems. *Renewable Energy* 106, 343-353. DOI: <http://doi.org/10.1016/j.renene.2017.01.042>