



西北农林科技大学

硕士学位论文

基于多源数据融合的小麦产量估测模型
优化及关键因子比较

培 养 单 位 农 业 科 学 院
专业学位类别 农 业 硕 士
专业学位领域 农 艺 与 种 业
论 文 作 者 康 迪
指 导 教 师 宋 瑜 龙 副 教 授
合作指导教师 王 钧 强 高 级 农 艺 师

2025 年 6 月

Dissertation Submitted to Northwest A&F University
in Partial Fulfillment of the Requirements
for the Professional Degree of
Master of Agriculture

Optimization and Key Factor Comparison of Wheat Yield Estimation Model Based on Multi- source Data Fusion

Colleges: Northwest A&F University

Major: Agronomy and Seed Industry

Candidate: Kang Di

Supervisor: Associate Prof. Song Yulong

Co-Supervisor: Senior Agronomist Wang Junqiang

June, 2025

分类号: S512.1

UDC: 633.1

密级: 公开

学校代码: 10712

研究生学号: 2022055049

西北农林科技大学硕士学位论文

基于多源数据融合的小麦产量估测模型
优化及关键因子比较

论文作者: 康迪

指导教师: 宋瑜龙副教授

答辩委员会:

主席: 宋喜悦 教授 博导 西北农林科技大学农学院

委员: 高欣 研究员 山东省农业科学院

祁广 副研究员 硕导 山东省农业科学院作物研究所

秘书: 张悦 副教授 硕导 西北农林科技大学农学院

答辩日期: 2025 年 05 月 26 日

本研究得到：国家自然科学基金（No. 31701500）；国家小麦产业技术体系(CARS-03)；西北农林科技大学基本科研业务费（No. 1090322148）；国家科技创新 2030（No. 2023ZD040230306）；重金属低累积作物选育及其达标生产综合配套技术研发(2023YFD1700102)。

摘要

小麦是三大主要粮食作物之一,其安全生产对保障世界粮食安全具有重要意义。然而,近年来受自然灾害影响,小麦受灾面积较大,其产量较难估测,对政府制定精确的小麦调配政策造成一定程度影响。因此,精准预测小麦产量对优化小麦生产管理,灾后评估或制定贸易政策具有重要意义。随着遥感技术的发展,无人机遥感技术为小麦提供了一种非破坏性,快速,高效率的产量预测方法,但不同估测模型的准确性差异较大。基于此,本研究以小偃 22,伟隆 169,西农 059,西农 511 为材料,在陕西关中冬小麦主产区一周至县和扶风县设置试验区,三次生物学重复,分别于小麦孕穗期,抽穗期,灌浆期,乳熟期,成熟期用无人机搭载多光谱相机进行图像采集,并提取光谱数据,计算植被指数。同时,调查各生育期小麦株高,土壤含水量等。利用以上数据和随机森林(RF),支持向量回归(SVR)和岭回归(RR)模型构建冬小麦产量模型,并比较最优模型中各特征变量的贡献度,获得结果如下:

(1) 在周至、扶风两地,4 个不同冬小麦品种单生育期数据构建的最优估产模型不相同。周至地区小偃 22 的最优估产模型为利用灌浆期数据的岭回归模型($R^2=0.964$)模型;伟隆 169 为利用成熟期数据的随机森林($R^2=0.986$)模型;西农 059 为利用成熟期数据的支持向量回归($R^2=0.961$)模型;西农 511 为利用抽穗期数据的支持向量回归($R^2=0.937$)模型;综合所有供试品种为利用抽穗期数据的随机森林($R^2=0.934$)模型。扶风地区小偃 22 的最优估产模型为利用孕穗期数据的随机森林($R^2=0.612$)模型;伟隆 169 为利用抽穗期数据的岭回归($R^2=0.7572$)模型;西农 059 为利用乳熟期数据的支持向量回归($R^2=0.484$)模型;西农 511 为利用乳熟期数据的随机森林($R^2=0.606$)模型;综合所有供试品种为利用抽穗期数据的随机森林($R^2=0.844$)模型。

(2) 周至、扶风两地,利用多时相综合数据构建产量最优模型精度均高于利用单时相数据构建的产量估测模型。虽然各品种最优模型使用的大多是不同生育期数据,但各品种最优模型数据使用孕穗期,抽穗期,灌浆期数据的概率较高。其中,周至地区小偃 22 的最优估产模型为利用孕穗期,抽穗期,灌浆期数据的随机森林模型($R^2=0.977$);伟隆 169 为利用孕穗期,抽穗期,灌浆期数据的随机森林($R^2=0.99$);西农 059 为利用孕穗期,抽穗期,灌浆期数据的随机森林($R^2=0.965$);西农 511 为利用孕穗期,抽穗期,灌浆期数据的随机森林($R^2=0.984$);所有供试品种产量估测模型为利用孕穗期,灌浆期,成熟期数据构建的岭回归

($R^2=0.9432$) 模型。扶风地区小偃 22 的最优估产模型为利用孕穗期, 抽穗期, 乳熟期数据的岭回归 ($R^2=0.8716$) 模型; 伟隆 169 为利用孕穗期, 抽穗期, 乳熟期数据的支持向量回归 ($R^2=0.878$) 模型; 西农 059 为利用抽穗期, 灌浆期, 乳熟期数据的支持向量回归 ($R^2=0.99$) 模型; 西农 511 为利用抽穗期, 灌浆期, 成熟期数据的岭回归 ($R^2=0.8397$) 模型, 所有供试品种产量估测模型为利用孕穗期, 抽穗期, 灌浆期, 成熟期数据的随机森林 ($R^2=0.854$) 模型。

(3) 比较周至、扶风两地所有基于单时期和多时期影像数据构建的最优模型结果发现, 在构建模型时, 不同的小麦品种对最优模型的选取及最优模型精度都有影响。因此, 如果需要进一步提高现有估产模型精度, 可针对不同小麦品种构建相应的估产模型。

(4) 对最优模型中所有特征的贡献度进行分析, 按贡献度值由高至低选取前二十个特征变量, 作为高贡献度特征。其中, 株高、旗叶面积、土壤含水量及土壤含氮量等非植被指数特征成为高贡献度特征的概率高达 73.33%。

关键词: 无人机多光谱遥感; 冬小麦产量; 多生育期; 多源数据; 特征贡献度

Abstract

Wheat is one of the three major food crops, and its safe production is of great significance to ensuring global food security. However, in recent years, due to the influence of natural disasters, the area affected by wheat has been large, and its yield is difficult to estimate, which has a certain impact on the government's formulation of precise wheat allocation policies. Therefore, accurately predicting wheat yield is of great significance for optimizing wheat production management, post-disaster assessment or formulating trade policies. With the development of remote sensing technology, unmanned aerial vehicle (UAV) remote sensing technology provides a non-destructive, rapid and efficient method for wheat yield prediction. However, the accuracy of different estimation models varies greatly. Based on this, this study used Xiaoyan 22, Weilong 169, Xinnong 059 and Xinnong 511 as materials, and set up experimental areas in Zhouzhi County and Fufeng County, the main winter wheat production areas in the Guanzhong region of Shaanxi Province, with three biological replicates. Images were collected using a multi-spectral camera carried by a UAV at the booting stage, heading stage, filling stage, milk stage and maturity stage of wheat, and spectral data were extracted to calculate vegetation indices. At the same time, the plant height and soil moisture content of wheat at each growth stage were investigated. Using the above data and random forest (RF), support vector regression (SVR) and ridge regression (RR) models, winter wheat yield models were constructed, and the contribution of each feature variable in the optimal model was compared. The results are as follows:

(1) In Zhouzhi and Fufeng, the optimal yield estimation models constructed using single growth stage data for the four different winter wheat varieties were different. For Xiaoyan 22 in Zhouzhi, the optimal yield estimation model was the ridge regression model using filling stage data ($R^2 = 0.964$); for Weilong 169, it was the random forest model using maturity stage data ($R^2 = 0.986$); for Xinnong 059, it was the support vector regression model using maturity stage data ($R^2 = 0.961$); for Xinnong 511, it was the support vector regression model using heading stage data ($R^2 = 0.937$); for all tested varieties, it was the random forest model using heading stage data ($R^2 = 0.934$). For

Xiaoyan 22 in Fufeng, the optimal yield estimation model was the random forest model using booting stage data ($R^2 = 0.612$); for Weilong 169, it was the ridge regression model using heading stage data ($R^2 = 0.7572$); for Xinnong 059, it was the support vector regression model using milk stage data ($R^2 = 0.484$); for Xinnong 511, it was the random forest model using milk stage data ($R^2 = 0.606$); for all tested varieties, it was the random forest model using heading stage data ($R^2 = 0.844$).

(2) In Zhouzhi and Fufeng, the accuracy of the optimal yield models constructed using multi-temporal comprehensive data was higher than that of the models constructed using single-temporal data. Although the optimal models for each variety mostly used data from different growth stages, the probability of using data from the booting stage, heading stage and filling stage was relatively high. Among them, for Xiaoyan 22 in Zhouzhi, the optimal yield estimation model was the random forest model using data from the booting stage, heading stage and filling stage ($R^2 = 0.977$); for Weilong 169, it was the random forest model using data from the booting stage, heading stage and filling stage ($R^2 = 0.99$); for Xinnong 059, it was the random forest model using data from the booting stage, heading stage and filling stage ($R^2 = 0.965$); for Xinnong 511, it was the random forest model using data from the booting stage, heading stage and filling stage ($R^2 = 0.984$); for all tested varieties, it was the ridge regression model using data from the booting stage, filling stage and maturity stage ($R^2 = 0.9432$). For Xiaoyan 22 in Fufeng, the optimal yield estimation model was the ridge regression model using data from the booting stage, heading stage and milk stage ($R^2 = 0.8716$); for Weilong 169, it was the support vector regression model using data from the booting stage, heading stage and milk stage ($R^2 = 0.878$); Xinnong 059 is a support vector regression model ($R^2 = 0.99$) based on data from the heading stage, filling stage and milk stage; Xinnong 511 is a ridge regression model ($R^2 = 0.8397$) based on data from the heading stage, filling stage and maturity stage. The yield estimation model for all tested varieties is a random forest model ($R^2 = 0.854$) based on data from the booting stage, heading stage, filling stage and maturity stage.

(3) By comparing the results of the best models constructed based on single-period and multi-period image data in Zhouzhi and Fufeng, it was found that different wheat varieties have an impact on the selection of the best model and the accuracy of the best model when constructing the model. Therefore, if it is necessary to further improve the accuracy of the existing yield estimation models, yield estimation models can be constructed for different wheat varieties.

(4) The contribution of all features in the best model was analyzed, and the top twenty feature variables with the highest contribution values were selected as high-contribution features. Among them, non-vegetation index features such as plant height, flag leaf area, soil moisture content and soil nitrogen content have a high probability of becoming high-contribution features, reaching 73.33%.

Keywords: UAV multispectral remote sensing; Winter wheat yield; Multi-growth-stage; Multi-source data; Feature contribution

目录

第一章 文献综述.....	1
1.1 研究背景.....	1
1.2 国内外研究状况.....	3
1.2.1 遥感技术与机器学习结合的应用.....	3
1.2.2 多源数据融合与模型优化.....	4
1.2.3 区域化与精准化趋势.....	6
1.3 传统冬小麦产量估测.....	7
1.3.1 经验统计模型.....	7
1.3.2 农学调查法.....	8
1.3.3 作物生长模型.....	8
1.4 遥感手段冬小麦产量估测.....	8
1.5 研究内容.....	10
1.6 研究意义.....	10
1.7 技术路线.....	11
第二章 研究区域与方法.....	12
2.1 试验区概况.....	12
2.2 研究方法.....	13
2.2.1 试验布局.....	13
2.2.2 数据采集及预处理.....	13
2.2.3 植被指数计算.....	16
2.3 冬小麦产量估测模型.....	18
2.3.1 随机森林（Random Forest, RF）.....	18
2.3.2 支持向量回归（Support Vector Regression, SVR）.....	19
2.3.3 岭回归（Ridge Regression, RR）.....	19
2.4 模型精度验证.....	19
2.5 各模型中变量重要性的确定.....	20
第三章 不同生育时期各变量与产量的研究.....	21
3.1 生育期确定.....	21
3.2 试验区多光谱数据分析.....	22
3.3 波段信息与产量相关性分析.....	24
3.4 气象因子及作物表型与产量相关性分析.....	24

3.5 植被指数与产量相关性分析.....	25
3.6 小结.....	26
第四章 基于单时期数据构建冬小麦产量模型及其比较.....	28
4.1 基于周至冬小麦单时期数据的产量模型构建.....	28
4.1.1 基于各时期数据的周至地区不同小麦品种产量模型构建....	28
4.1.2 周至不同品种基于单个生育期数据的最优产量模型.....	31
4.1.3 周至地区不同冬小麦品种最优产量模型中各特征变量的重要性.....	32
4.2 基于扶风冬小麦单时期数据的产量模型构建.....	35
4.2.1 基于各时期数据的扶风地区不同小麦品种产量模型构建....	35
4.2.2 扶风不同品种基于单个生育期数据的最优产量模型.....	37
4.2.3 扶风地区不同冬小麦品种最优产量模型中各特征变量的重要性.....	38
4.3 讨论.....	41
4.3.1 不同模型适配度.....	41
4.3.2 表型差异对最优模型选择的影响.....	42
4.4 小结.....	42
第五章 基于多时期数据构建冬小麦产量模型及其比较.....	44
5.1 基于周至冬小麦多时期数据的产量模型构建.....	44
5.2 基于扶风冬小麦多时期数据的产量模型构建.....	57
5.3 讨论.....	69
5.3.1 多源数据特征变量对模型精度的影响.....	69
5.3.2 不同生育期组合对模型构建的影响.....	70
5.4 小结.....	70
第六章 结论.....	72
6.1 结论.....	72
6.2 创新点.....	72
第七章 展望.....	74
参考文献.....	76
致谢.....	82

第一章 文献综述

1.1 研究背景

冬小麦是世界三大主要种植作物之一，对保障世界粮食安全具有重要作用。近年来，随着全球人口增长（预计 2050 年达 97 亿）和气候变化加剧，小麦生产面临多重压力，如：极端天气频发、水资源短缺、土壤退化等。因此，精准预测小麦产量对优化农业管理、保障粮食供应和制定贸易政策具有重要意义。

传统的小麦产量预测方法主要依赖经验模型（如：基于历史产量的时间序列分析）和统计模型（如：多元线性回归）。然而，这些方法存在一定的局限性：（1）依赖历史数据的平稳性假设，难以适应气候变化下的非线性关系；（2）忽略作物生长过程中的动态环境响应（如：干旱胁迫）和品种遗传特性差异；（3）数据获取滞后性强，无法支持实时决策。因此，亟需开发高精度、高时效、可解释的产量预测新模型。

近年来，遥感技术、物联网传感器和表型组学的发展为农业数据获取提供了多维度、高分辨率的观测手段。通过整合不同来源的数据（环境、作物生理、遗传特性），可以构建更全面的产量驱动模型。其中，基础数据源一般包括：

（1）植被指数（Vegetation Indices, VIs）

基于遥感光谱的植被指数（如 NDVI、EVI、LAI）能够量化作物冠层的光合活性、生物量积累和胁迫状态。例如，NDVI 在灌浆期的动态变化与籽粒形成密切相关，但其单独应用易受传感器噪声、大气条件干扰，且难以区分品种间差异。

（2）气象因子

土壤含水量（SM）、累积降水量（AP）、温度胁迫指数（如：日较差）等气象参数直接影响作物生理过程。例如，拔节期至开花期的土壤水分亏缺可导致小花败育，显著降低穗粒数。然而，气象因子的时空异质性强，需结合田间微环境监测数据以提高模型泛化能力。

（3）表型参数

小麦品种的遗传特性（如：株高、旗叶面积、分蘖数）通过调控资源分配效率（光能截获、水分利用）影响产量潜力。例如，矮秆品种（如“矮抗 58”）的抗倒伏特性可提升密植条件下的产量稳定性，而旗叶面积较大的品种（如“济麦 22”）在光合有效辐射充足时更具优势。传统模型常忽略表型参数的动态贡献，导致跨品种预测误差较高。

同时，单一数据源难以全面表征“基因型—环境—管理”互作效应，而多源数

据协同可尽可能的揭示产量形成的复杂机制。例如,植被指数反映冠层表观状态,气象因子解释环境胁迫强度,表型参数则提供遗传响应基线,三者结合可显著提升模型解释力。

近年来飞速发展的遥感技术为作物生长提供了一种非破坏性,快速,高效率蝉联估测方法。遥感技术包括:地面遥感,航空遥感,航天遥感三类。与此同时,通过地面遥感收集的数据需要大量的人力和资源,数据收集过程也会对作物造成伤害,并且无法取得作物的正射影像。另一方面,航天遥感虽然可以无破坏和高效率的观测作物,但是航天遥感一般更适合观测大面积作物生长,并且会在其他方面出现些许不足,如较低的时空分辨率,过长的循环时间,像素混合等,这会限制对地区范围评估的准确性。不像航天遥感那样,低空无人机遥感有着低成本,易操作,高效率,高时空分辨率以及高灵活性等优点。基于无人机的遥感技术能搭载多种传感器,可以在精准农业中对水肥进行精确的管理。因此,尽管有时无无人机的航行需要被授权,但无人机遥感技术仍然被广泛的用于农业信息采集和作物管理。

近几年,无人机搭载的各类传感器被广泛用于精准农业领域。传统的传感器有三个波段的 RGB(红绿蓝)传感器,具有低成本、易操作、有较高的空间分辨率等优点。因此,大量研究采用这三种波段或基于色彩指数,如:绿叶指数(GLI),来估测小麦产量。现阶段研究发现,植物通常对近红外(NIR)波段有较强的反射率,因此,包含近红外波段的多光谱相机得到了越来越多的关注。一些植被指数,如:比值植被指数(RVI),归一化植被指数(NDVI),冠层叶绿素含量指数(CCCI),已经使用了 NIR 波段数据,并且成功的用于预测作物产量、确定土壤盐度构成、监控作物病虫害和评估作物水肥状态。无人机影像已经被证明是一种很有效地计算植被指数的方法。同时,许多研究已经证明植被指数和一些重要的作物特征,如:作物产量或地上生物量息息相关(Duan et al. 2019; Maimaitijiang et al. 2020; Shafiee et al. 2021; Fu et al. 2014; Lu et al. 2019; Yue et al. 2019)。然而,许多研究也发现植被指数和作物特点之间的联系与作物所处的物候期也有很大的关联。如:归一化植被指数(NDVI)被发现在作物的孕穗期和作物产量有更高的相关性,而绿色归一化植被指数(GNDVI)则在更早的生长期对于估测产量有更好的表现(Kyratzis et al. 2017)。此外,不同类型农作物处于不同物候期时会表现出不同的植被指数,一定程度会降低模型估测精度。因此,为了克服这一难题,机器学习和回归模型被逐渐用于产量估测模型构建,创建了非常有效的方法(Yue et al. 2019)。

通常,当开发一个机器学习模型的时候,特征的选择开始于选择数据集的相关子集,这样可以有效地避免维度灾难,减少噪声数据在预测模型中未知的不相

关或冗余特征的影响，减少计算时间，提升预测模型的表现力。同时，有助于更好的理解数据集。皮尔逊相关系数(PCC)，是两个变量之间的一种线性相关性，通过代理措施来评价特征的子集，同时也是一种基于过滤间接的评价回归问题的方法。故本文选取三大类特征来构建机器学习的特征集，分别为：植被指数，作物表型和气象因子。

机器学习算法能够在独立和非独立变量之间建立一种经验关系，同时有在预测产量时不会依赖于单独特殊作物个体参数的优点。现在用于估测产量的机器学习算法大多依赖单一的预测模型。应用型机器学习算法在训练小样本数据时，会产生一些潜在的问题，如：偏差，较弱的泛化能力，过拟合和较差的重复性。故本试验中会采用特点各不相同的多种机器学习算法（随机森林、支持向量机、岭回归）来尽量弱化各个模型可能产生的问题，同时比较不同算法模型之间的优劣性。

故本研究拟解决无人机估测产量时，由于变量参数单一或变量组合不完善、不合理导致的估测精度低或由于过拟合导致适用性不高问题。同时，探究气象因子及作物表型参数对估产最优模型的贡献度占比。试验利用搭载多光谱相机的无人机在冬小麦不同物候期进行拍摄，把典型植被指数（NDVI, RVI 等）、作物表型（株高、旗叶面积、分蘖数等）及气象因子（土壤水分、早晚温差、最高最低气温等）作为变量，运用不同的机器学习模型（RF、SVM 和 RR）构建精度最高，拟合程度优的各品种冬小麦产量估测模型，同时探究各特征变量对模型的贡献程度，为其他相似地区提供技术和经验参考。

1.2 国内外研究状况

1.2.1 遥感技术与机器学习结合的应用

国内外专家将遥感数据与机器学习进行融合对小麦估产模型进行了系统优化，同时持续深化了遥感技术与机器学习的交叉应用。例如：陈州等（2024）利用植被指数和多元线性回归模型评估了欧比特高光谱（Orbita Hyperspectral, OHS）影像在区域尺度上的小麦产量预测能力，结果表明该方法能够实现局部地区小麦的精准估测，同时能够基于 OHS 数据对小麦产量空间分布进行绘图。赵泽阳等（2025）利用无人机采集多时相小麦冠层光谱数据对小麦产量进行了估测，结果证明基于植被指数加纹理指数的 SVR 模型精度最佳， R^2 为 0.924。杨楠等（2023）利用无人机 RGB 影像信息对小麦叶面积指数和产量进行估测，筛选出不同生育期最优叶面积指数估测模型，进一步建立产量估测模型，结果表明随机森林模型的精确度最高。吴强（2023）利用无人机遥感技术与机器学习方法对河套灌区春

小麦的长势和产量进行估测,提取春小麦冠层 26 个多光谱和 25 个可见光植被指数作为特征变量,采用 25 个不同的机器学习模型,最终确定最优模型为 OMP (Orthogonal Matching Pursuit, 正交匹配追踪),精度 $R^2=0.820$ 。Maitiniyazi et al. (2017) 为了评估 RGB、多光谱和热成像相机在估算美国密苏里州哥伦比亚地区大豆生化参数(包括叶绿素含量和氮浓度)和生物物理参数(包括叶面积指数(LAI)、地上新鲜和干生物量)中的能力,利用无人机收集相关图像信息,提取植被指数,对作物生物物理生化参数进行建模和预测,结果显示在植物生物物理变量中,RGB 和热成像对 LAI 的预测效果最好,而多光谱和热成像对生物量的估计效果最好,说明在机器学习框架内融合低成本的多传感器数据可以提供相对准确的植物性状估计。Zhang et al. (2024) 研究了基于无人机多光谱图像的特征选择和机器学习回归三种组合技术在冬小麦关键生育期叶面积指数(LAI)、叶片叶绿素含量(LCC)和冠层叶绿素含量(CCC)等生物参数估算中的应用,结果表明,将支持向量回归(SVR)与序列前向选择(SFS)相结合的方法对冬小麦各时期的生物参数性状预测具有较好的准确性和稳健性。

上述研究表明遥感技术与机器学习的深度融合显著提高了小麦估产的精度。研究通过整合卫星高光谱、无人机多光谱/RGB/热成像等多源数据,结合植被指数、纹理特征等多维信息构建协同观测体系,突破了单一数据源的局限性。研究范畴从产量预测延伸至叶面积指数、叶绿素等多参数协同反演,为智慧农业提供决策支持。

1.2.2 多源数据融合与模型优化

近几年,关于小麦估产的研究方向从单一特征变量,如:植被指数,纹理指数等光谱特征逐渐向着多元数据靠拢,一些研究通过整合气象、土壤、植被指数等多维数据,提升模型对复杂农艺条件的适应性。此外,针对传统统计模型依赖历史数据平稳性假设的缺陷,一些研究提出基于动态环境响应(如:土壤含水量、温度胁迫)的机器学习模型(如:XGBoost、LSTM),以捕捉非线性关系。Cao et al. (2020) 将月度气候数据、卫星数据(即植被指数(VIs))和社会经济因子(SC)进行整合,然后对华北平原小麦产量进行预测,结果发现 VIs 和气候数据的组合比其他组合(如:气候和 SC 的组合,VIs 和 SC 的组合)更能有效地捕获年际产量变异,而 SC 与气候数据的组合比其他组合更能捕获空间产量变异。此外,将空间信息和土壤性质纳入基准模型,小麦产量预测分别提高 0.06 和 0.12。Juan et al. (2020) 整合了谷歌 Earth Engine (GEE) 平台上的公开数据(即:卫星植被指数、气象指数和土壤性质),构建出三种不同类型的回归模型(LASSO, Random Forest, Long Short Term Memory Networks)预测中国十六个省的水稻产

量,结果发现与仅使用增强型植被指数(EVI)或太阳诱导叶绿素荧光(SIF)作为单一输入相比,ESI(结合EVI和SIF)可以略微提高模型的性能。Zhou et al. (2022)探索了9个气候变量、3个遥感衍生指标和3种机器学习方法预测小麦产量的潜力,结果发现,小麦产量预测存在较大的空间差异,而气候数据对冬小麦种植区产量预测的额外贡献从播种到成熟呈下降趋势,而遥感数据则相反。冬小麦种植区的预测效果优于春小麦种植区。实验验证了气候与遥感数据相结合在中国县级作物产量预测中的有效性。曾健铭等(2024)通过随机森林算法对特征变量进行评价,采用BP神经网络对产量进行预测,结果表明相对湿度,NDVI,最低温度,土壤湿度和辐射照度为小麦估产预测的最重要影响因子。樊杰杰(2024)等建立了一种耦合连续小波变换(CWT)与机器学习预测小麦产量的方法,通过CWT提取三种小波特征(WFs),分别是基于Bortua的特征波段(Bortua-WFs),提取WFs与小麦产量确定系数的前1%以及所有WFs,采用随机森林,K最近邻和极端梯度提升三种机器学习的方法来进行产量估测模型构建,结果显示:三种WFs结合机器学习方法的模型都表现良好,且Bortua-WFs模型精度比光谱特征模型精度在开花期高出17.5%、4%和39.6%,在灌浆期高出8.4%、5.6%和16.9%。上述试验说明合理利用多源数据,如:气象因素,土壤因素等在构建小麦最优估产模型时,能够提升模型的精确度。Guan et al. (2017)使用来自不同光谱波段的卫星数据对美国玉米带进行产量估算,显著提高了区域作物产量预测能力,同时辅助气候数据(例如降水和温度)的使用进一步提高了模型的精确度,说明利用包含大范围光谱的卫星数据能够提升对大规模的作物生长和产量的监测水平,超越了单一传感器所能达到的效果。Keltoum et al. (2025)利用机器学习模型评估环境条件时空异质性对摩洛哥小麦产量预测的影响,其中涉及三组变量,光谱指数、气象资料以及光谱指数与气象资料相结合对2019-2020年和2020-2021年的结果进行比较,结果显示随机森林模型表现最好,且在相对干旱的2019至2020年间表现比相对湿润的2020至2021年间预测性能更好,说明这些准确性的差异是由于不同的环境条件造成的,为了做出更好和更可靠的产量预测,应将这些环境条件考虑在内。Engen et al. (2021)利用挪威多时相数据,如:Sentinel-2卫星图像、天气数据、农场数据、粮食交付数据和地籍特定数据,引入深度混合神经网络模型来训练这些多时相数据,用以预测农场规模的作物产量。此外,该模型能有效地进行目标预测且平均绝对误差为76kg/1000m²。Zhuang et al. (2024)提出了一个作物产量预测的混合框架模型,即:将叶面积指数和土壤水分同化到作物模型中,然后将数据同化的作物模型与机器学习技术相结合,以进一步提高预测性能,结果显示同化显著提高了小麦产量估测准确性。与此同时,结合天气预报,可以提前1-3个月开展相对可靠的冬小麦产量预测。

故当前小麦估产研究正经历从单一数据驱动向多源协同建模的范式转变,其核心突破聚焦于多源数据融合与模型架构优化的协同创新。多数研究摒弃传统依赖单一光谱特征或静态统计模型的局限,通过整合气象、土壤、植被指数等多维动态数据,构建复合特征体系以增强对复杂农艺环境(如水分胁迫、温度波动)的解析能力,这一研究路径不仅克服了历史数据平稳性假设的缺陷,更通过物理过程与数据驱动的耦合,推动估产模型向机理关联深化,为实现精准农业监测提供技术支撑。

1.2.3 区域化与精准化趋势

利用遥感技术进行小麦产量估测的研究主要可分为两大类,第一类为利用卫星数据进行大面积估测。例如,韩梦文(2023)利用谷歌 Earth Engine (GEE) 调取气象,遥感影像等信息对江苏省 2018-2020 年小麦产量进行估测,通过获得当年的评价指标因子来提前预测当年产量。狄艳(2023)以 2009 至 2020 为研究年份,华北平原为研究区,在冬小麦时序特征基础上,加入多源数据与深度学习网络模型,同时比较模型在正常年份与干旱年份的预测精度,结果显示融合多数数据源的估产精度为 $R^2=0.747$, $RMSE=426.2\text{kg/ha}$, 优于单一数据源的估产精度。同时,河南省因其获取的县级样本数量最多(794 个),故模型精度优于河北省(691 个)和山东省(647 个)。上述研究表明,利用估产模型,开展大面积估产是可行的,但是深度学习网络需要更多的数据支撑以获得较高的模型精确度。Han et al. (2020) 基于谷歌 Earth Engine (GEE) 平台,构建了气候数据、遥感数据和土壤数据相结合的冬小麦产量预测模型框架,将小麦整个生育期划分为四个时间窗,对中国 629 个县的小麦产量进行了估测,结果发现,该模型能较准确地预测中国县域采收期前 1~2 个月的产量, R^2 为 0.75, 产量误差小于 10%。第二类为利用无人机采集数据进行小范围区域化精准估产。朱志畅等(2025)利用无人机采集多光谱与 RGB 图像,从中提取 14 种光谱参数和 28 种形态参数作为特征变量,利用线性回归,随机森林等 10 余种机器学习来构建特定区域的小麦田间产量估测模型,同时对输入的特征变量进行重要性分析和筛选,从而提升预测精度,而利用作物生长模型,如: WOFOST 进行预测也在区域化精准估测中发挥着重要作用,如:胡玥明等(2024)利用 WOFOST 模型模拟七台河市春小麦的生长过程,建立了生长模型用于估测产量,其中,通过模拟当地气候,证明气温、日照时数、降水和相对湿度是影响春小麦生长和产量的最重要因子,预测精度是 88.7%,具有较高的可信度。王梦玥(2024)选用两种小麦模型,即小麦玉米节水省肥智能决策系统和 DSSAT 作物模型,结合历史天气数据对山东省潍坊市昌邑县的小麦产量进行动态测评,结果显示两套模型均有较好的预测能力,且

小麦玉米节水省肥智能决策系统在小麦开花期预测的产量精度最高，而 DSSAT 作物模型在灌浆期的产量预测精度最高。程天宇（2023）把小麦按照不同耐热基因型进行分类，分为耐热性小麦、中等耐热性小麦和高温敏感型小麦，利用无人机搭载的多光谱和 RGB 相机分别收集图像和估产模型构建，结果显示，区分耐热基因型的模型的产量估计效果比不区分基因型有较高的精确度，其中高温敏感型预测精度最高， R^2 达到 0.91。

上述试验证明利用遥感技术进行小麦估产在大面积领域（省级）和小面积领域（试验区）都有很好的应用前景。基于卫星平台的大尺度估产通过集成多源数据（气象、遥感、土壤）与深度学习网络，可以突破时空分辨率的限制，实现县域至省级尺度的动态预测，但其精度受样本规模与数据完备性制约；而无人机驱动的田间精准估产则依托多光谱、RGB 影像及作物表型特征，结合机器学习算法（如随机森林）或作物生长模型（如 WOFOST、DSSAT），通过基因型分类、生育期特异性建模等手段，降低单产预测误差，并揭示环境-基因互作机制。同时，对于精准化要求的小范围小麦估产模型，融合多数据源已成为不可缺少的环节。此外，两种不同尺度的估产手段共同推动产量预测向高精度、机理化、场景自适应方向发展。

1.3 传统冬小麦产量估测

传统的小麦产量估测方法主要依赖经验模型、统计分析和农学调查，其核心是通过历史数据、环境参数或作物生长特征建立线性或半经验关系。这些方法在小数据时代具有重要价值，但随着技术进步，其局限性逐渐显现。

1.3.1 经验统计模型

经验统计模型是基于历史产量数据与关键气象因子（如气象、土壤）的线性或非线性关系建立的预测方法，主要包括时间序列分析和多元回归模型。

（1）时间序列分析：假设产量随时间呈现趋势性变化（如：技术进步带来的年递增率），并通过分解趋势项、周期项和随机项进行预测。例如，中国农业农村部采用“趋势产量+气象修正”模型，将长期趋势产量（由线性拟合得到）与气象波动项（如生育期降水量偏差）叠加，预测年度产量。

（2）多元回归模型：选取与产量显著相关的因子（如拔节期积温、开花期降水、土壤有机质含量），建立线性方程。

这类模型有数据需求低，计算简单等优点，但局限性也非常明显，如：依赖历史数据的平稳性，无法适应气候变化或技术进步导致的非线性突变；且通常以县域或省域为单元，无法支持田块级精准管理。

1.3.2 农学调查法

农学调查法通过田间实测或目测评估小麦产量，是基层农业部门常用的传统方法。农学调查法直接基于田间生物学参数，结果易被农民接受，且在品种试验田中小范围应用时，误差可控制在 $\pm 5\%$ 以内。我国县级农业局常通过该方法快速汇总产量数据，指导粮食收购，但此法估产依赖个人经验，不同调查员对同一田块的评级差异有时很大，同时，需在灌浆后期至成熟期进行，无法提前预警。最重要的是，农学调查法需耗费大量人力物力。

1.3.3 作物生长模型

作物生长模型通过模拟光合作用、呼吸消耗、物质分配等生理过程预测产量，代表模型有：WOFOST、APSIM 和 DSSAT。

(1) WOFOST 模型：将作物生长分为潜在生产（仅受光温限制）与实际生产（受水分、养分限制）两个层次，逐日计算生物量积累。

(2) APSIM 模型：整合土壤-作物-大气系统，可模拟长期轮作效应。

(3) DSSAT 模型：采用模块化架构整合作物-土壤-气象数据库。其核心子模型（如 CERES-Wheat、CROPGRO-Soybean）通过逐日计算光合产物生成、器官发育及养分吸收过程，动态预测产量形成；独有的“基因型系数”量化品种特性差异，可精准评估新品种适应性。全球范围内广泛应用于气候变化响应分析、灌溉施肥方案优化及品种筛选试验。

此法可以揭示产量形成的生理生态机制，并支持气候变化情景模拟。同时，可评估土壤肥力下降或耕作制度变更对产量的长期影响，但对数据的需求比较苛刻。而且品种适应性较差，推广至其他遗传背景品种时需重新校准，耗时可能长达 2-3 年。

传统小麦产量估测方法在宏观预测和机理阐释方面具有重要价值，但其在分辨率、时效性和适应性上的缺陷，难以满足精准农业的需求。经验统计模型依赖历史数据平稳性假设，农学调查法受限于主观误差和高成本，作物生长模型面临参数校准难题。这些局限性推动了机器学习与多源数据融合技术的发展，但传统方法的机理解释性仍为模型优化提供理论支撑。未来需构建“机理-数据”双驱动的混合模型，以实现高精度与可解释性的统一。

1.4 遥感手段冬小麦产量估测

随着遥感技术的不断发展，利用遥感技术改变小麦产量成为了一种新的手段。遥感估测方法是利用遥感技术来测量或者观察作物生长状况，从而估测作物的各种农学参数，以综合评价不同地区或大面积种植条件下作物的生长变化情况。早

期的遥感估产方法是通过单个生育期或某些关键的物候期的光谱指数和产量直接进行回归分析 (Shibayama et al. 1991; Serrano et al. 2000), 然后, 近年来为了进一步提高估产的准确性, 侯英雨等 (2002) 通过积温和降雨等参数来建立复合模型进一步消除气象因素的影响。

国内外的研究中, 有主要从作物生长机理出发, 利用同化算法, 同化模型中的各种变量 (植被指数, 纹理指数和生理参数等), 从而建立气象、农学以及光谱的复合模型来进行估产 (陈鹏飞等 2013; 闫岩等 2006)。由于模型自身的机理性, 在运用中要综合考虑作物生长、气候、土壤、水分等气象因子, 所需参数比较复杂, 容易产生过拟合现象, 同时也为估产带来了一定的影响。现阶段的遥感技术有着覆盖范围广, 更新速度快, 获取信息简便等优势, 已经被广泛应用于小麦估产, 达到了实用化阶段 (Salazar et al. 2007; 侯学会等 2012; 李军玲等 2012; 唐建民等 2015; 赵春江等 2014), 并且取得了丰硕的成果 (Lu et al. 2020; Yang et al. 2020; Sahameh et al. 2023)。Bian et al. (2022) 使用六种机器学习方法 (包括 GPR, SVR 及 RF) 和无人机搭载的多光谱相机, 能够比较精确地预测农场范围的冬小麦产量, 同时 $R^2 = 0.87$, $RMSE = 49.22 \text{ g/m}^2$, $MAE = 42.74 \text{ g/m}^2$ 也能说明 GPR 在灌浆期是最优的机器模型。Yang et al. (2021) 为中国北方平原 (包括河南漯河市及北京市小汤山) 建立了一种名为 CW-RF 的新模型, 并且叶面积指数 (LAI) 和叶氮含量 (LNC) 的 RMSE 在拔节期只有 6.27% 和 12.17%。同时, 研究发现, 在使用近地高光谱和无人机高光谱获得的遥感数据时, 与单独使用植被指数相比, 结合植被指数和红边参数能够提高估产模型的精度, 故在构建模型估算作物产量时, 需要考虑合适的传感器 (Feng et al. 2022)。Tian et al. (2022) 进一步考虑土壤信息对预测产量产生的影响, 提出了一种基于良好点集的投影非负矩阵和交叉融合矩阵 (PNMF-MCF), 可以有效地提取, 融合作物以及土壤的特征来估测冬小麦产量, 同时在开花期取得了最高 $R^2 = 0.8516$ 和最低 $RMSE = 0.0744 \text{ kg/m}^2$ 的结果。Shen et al. (2022) 使用多光谱相机和热红外相机, 结合获取到的植被指数以及冠层水分胁迫指数, 提出了一种新的结合长短期记忆神经网络和随机森林 (LSTM-RF) 的框架, 既考虑到了小麦生长过程中时间序列的特征, 又考虑到了遥感数据与作物产量数据之间的非线性特征, 获得了更好的预测结果。而为了在育种早代能预测小麦的产量高低, Moritz et al. (2023) 选取了 19 个欧洲小麦品种, 利用多光谱相机提取了基于灰度矩阵的植被指数和纹理指数, 发现可见光波段尤其是红色波段能够在分蘖期区分出高产与低产品种, 总正确率为 76.7%。以上研究表明无人机搭载的各种相机 (RGB, 多光谱相机, 高光谱相机, 热红外相机) 可以完成图像的采集工作并有各自的适应条件, 同时利用提取到的各种植被指数, 纹理指数及测量得到的气象因子等都会对估测小麦产量产生或多或少的影响, 而

不同的机器学习算法在特征选择不同时，估测精度上也会有不小的差异。

1.5 研究内容

本研究采用多旋翼无人机平台，通过观测获取小麦冠层多光谱影像，构建包含植被指数、气象因子及作物表型的多维度特征体系。基于集成学习理论，系统评估不同生育期特征组合与多元机器学习算法的耦合效应，旨在探明不同小麦品种产量估测模型的最佳时相期及各特征对模型构建的贡献度，建立具有普适性的模型性能评价体系，为无人机遥感驱动的作物产量无损监测提供理论依据和技术范式。

本研究的具体研究内容包括：

(1) 建立基于光谱信息的小麦产量估测模型。利用多光谱相机获取小麦冠层光谱信息（NDVI, GNDVI, NDRE, SR, RDVI, CIRededge, CIGreen），分析小麦孕穗期，抽穗期，灌浆期，乳熟期和成熟期冠层光谱的变化规律，根据变化规律，尝试不同的机器学习算法。本研究使用皮尔逊相关系数（Pearson correlation coefficient）来衡量各个指数与产量之间的相关性。在相关系数的基础上，从中选出相关性较高的指数，构建模型进行估测。具体步骤为首先分析本研究选用的常用多光谱指数与产量之间的相关性。选取相关性较高的指数建立估测模型和生物量模型，并且计算模型的决定系数。

(2) 建立综合光谱信息，作物表型，气象因子的小麦产量模型。从小麦的孕穗期，抽穗期，灌浆期，乳熟期和成熟期，分别随机测量出小麦株高、分蘖数、小麦拥有旗叶时的旗叶面积和旗叶夹角度数，计算相关性。实地调查或查阅资料确定小麦在各个研究时期的多种气象因子，如：最大温差，土壤含水量，土壤温度，相对湿度，土壤含氮量等，建立综合所有特征变量且精度最高的小麦产量的估测模型。

(3) 对各品种各地区的最优模型进行分析，列出构建模型时重要性最高的20个特征变量。进一步分析解释作物表型和气象因子在构建模型时的重要性。

1.6 研究意义

如前所述，虽然精准、快速、无损估测我国的主要粮食作物小麦的产量，对科学、有效制定国家粮食安全政策和农业贸易策略具有重要指导价值，但迄今小麦产量估测研究还存在的问题有：（1）小麦产量评估模型指标选择时，大多基于植被指数或气象数据，忽略了对产量有直接重要影响的株高、旗叶面积等植株表型特征以及施肥、土壤水分含量等耕作措施或环境指标，也很少比较和探究最

优估测模型中各特征贡献度的高低，这样尽管可以达到减少数据采集，快速估测产量的目的，但极有可能会降低估测模型的精度和普适性；（2）为提升估测模型的普适性，皆以数个小麦品种群体而不是以单个品种为对象，可能会影响小麦产量估测精度。因此，本研究将基于无人机多光谱遥感技术，选定陕西关中冬小麦数个主栽品种，采集多个物候期的冬小麦图像和表型特征、土壤水分含量等数据，建立收获前高精度的冬小麦产量估测模型，同时分析各特征在构建最优模型时的贡献度占比，以增强模型的合理性，提高模型的解释能力，有助于揭示多源数据协同驱动产量形成的机制，建立可迁移、可解释的小麦产量预测模型。

1.7 技术路线




图 1-1 技术路线

Fig. 1-1 Technology Road

第二章 研究区域与方法

2.1 试验区概况

本研究试验区为：西安市周至县终南镇马蓬村和宝鸡市扶风县绛帐镇东西湾村；供试材料：小偃 22、西农 059、西农 169 和西农 511 小麦品种。

西安市周至县终南镇马蓬村位于周至县东部，地处渭河二级平原，地势平坦，土地肥沃，灌溉条件良好。气候属大陆性季风气候。春季暖气团逐渐变强，气温上升，降水增加。夏季天气炎热，多雷暴天气。秋季连阴多雨。冬季气候寒冷，少雨雪。

宝鸡市扶风县绛帐镇东西湾村。地处渭河二级平原，地势由西北向东南倾斜，北高南低。由北向南自然形成低山丘陵、山前洪积扇、黄土台塬和渭河阶地 4 个明显的地貌地形单元。气候为大陆性湿润季风气候。年平均气温 12.4°C ，年平均降水量 592mm，无霜期 209 天。境内主要自然灾害有干旱，连阴雨，洪水，滑坡等。




图 2-1 研究区示意图

Fig. 2-1 Schematic diagram of the study area

2.2 研究方法

2.2.1 试验布局

本研究于 2023 年 10 月冬小麦生产季布设田间试验。其中，周至县终南镇马篷村播种时间是 2023 年 10 月 29 日；扶风县绛帐镇东西湾村播种时间是 2023 年 10 月 25 日。试验品种有小偃 22，伟隆 169，西农 511，西农 059。种植密度为每亩 16 万基本苗；三个氮肥处理，分别为 15kg 每亩，7.5kg 每亩和 0kg 每亩，三次生物学重复。每个试验地 72 个试验小区，每个试验小区面积为 10 m²。

2.2.2 数据采集及预处理

2.2.2.1 数据采集

（1）试验小区测产

小麦成熟期，试验小区采取全部收割，脱粒，晾晒，并去除杂质，进行实际称重。

（2）土壤含水量的测定

用土钻取 0~20 cm，20~40 cm 土层土样装入铝盒，采用土壤干燥法在 105℃ 烘箱烘干至恒重，计算土壤样品含水率。

$$\text{土壤含水率}(\%) = (\text{原土重} - \text{烘干土重}) / \text{烘干土重} \times 100\%$$

（3）小麦株高的测定

用直尺测量自然状态下小麦植株顶部（不含芒）至土壤表面的距离，每个试验小区随机测量 20 株取平均值作为株高。

（4）旗叶面积测量

小麦孕穗期，抽穗期，扬花期，分别在各小区选取 3 株长势一致且生育期基本同步，无病虫害，无机械损伤，营养正常且旗叶完全展开的植株，测定其主茎旗叶长和宽，并计算旗叶面积，以 3 次重复的平均值作为最终结果。

$$\text{旗叶面积} = \text{旗叶长} \times \text{旗叶宽} \times 0.75 \text{（傅兆麟等，2001）}。$$

（5）无人机遥感数据采集

本研究使用大疆经纬 M300RTK 无人机（大疆创新科技有限公司，中国），搭载 RedEdge-MX 多光谱相机（MicaSense 公司，美国）。自 2024 年 4 月 12 日至 5 月 24 日间，每 7 天选择天气晴朗、阳光充足的正午采集田间小区光谱数据，此时太阳天顶角最小，光照最稳定。无人机航高设置为 30 米（赵泽阳等，2024）。




图 2-2 无人机平台(A)与多光谱传感器(B)

Fig. 2.2 UAV Platform (A) and Multispectral Sensors (B)

表 2-1 大疆经纬 M300 RTK 无人机性能参数

Table 2-1 UAV performance parameters	
参数	值
重量	空机重量（含双电池）： 6.3 kg
轴距	895 mm
最大速度	23 m/s
飞行时间	55 min
遥控信号有效距离	15 km
最大可承受风速	15 m/s（七级风）
工作温度	20℃ 至 50℃

表 2-2 RedEdge-MX 多光谱相机性能参数

Table 2-2 Sensor performance parameters	
参数	值
尺寸	8.7cm x 5.9cm 4.54cm
光谱波段	蓝（475nm, 32nm）
	绿（560nm, 27nm）
	红（668nm, 16nm）
	红边（717nm, 12nm）
	近红外（842nm, 57nm）
RGB 彩色输出	全局快门，多个通道配准
空间分辨率（GSD）	8cm-120m 飞行高度
帧率	最快 1fps, 12bit RAW
接口	串口，10/100/1000 ethernet, WI-FI, 外部触发接口，GPS，SDHC
视场角	47.2° HFOV
触发选项	时间模式，重叠模式，外部触发模式（PWM, GPIO, 串口或网口），手动拍摄

2.2.2 无人机多光谱数据预处理

本研究单次飞行所获原始数据为小麦田间多光谱影像，格式为 tiff 格式。然

后,对所选图像进行辐射校正、影像拼接、影像裁剪、选取感兴趣区域、计算植被指数及提取特征等处理,为后续研究提供数据基础(华启龙,2023)。

(1) 辐射校正

由于无人机搭载传感器的稳定性和无人机在飞行时易受不可控天气影响,获取的影像会存在一定程度的辐射畸变,故需要对影像进行辐射校正,本研究采用“白板定标法”对多光谱影像进行辐射校正(万余庆等,2006)。

(2) 影像拼接

无人机图像传感器的分辨率目前虽已达到千万像素级别,但由于相机镜头视角有限,且影像地面分辨率同覆盖面积成反比,在追求影像高分辨率的条件下,影像所覆盖的面积往往较小,因此需要进行影像拼接,即将同一地点拍摄的一系列有一定重叠度的影像经过算法步骤生成一幅较大影像的方法。本文使用 Pix4D 软件进行影像拼接,工作流程如下:原始影像→导入影像→影像初始化→生成密集点云→生成网络→生成正射影像→生成报告。

(3) 波段融合与裁剪

使用 ENVI5.6 软件的 layer stacking 功能对处理后的多光谱信息进行波段合成,之后将 5 个波段的影像合成一幅影像。

因本研究区域只占无人机拍摄影像的一部分,为了避免周围区域数据的影响,以及减少图像处理时间,故使用 ENVI5.6 软件中 SubsetData via ROIs 工具,对波段融合后的无人机影像进行裁剪。裁剪时,所选定的范围涵盖所有试验小区。

(4) 选取感兴趣区

裁剪后的研究区影像各小区间存在田垄裸地分隔,需要去除田垄裸地,获取小麦感兴趣区域(Region of Interest, ROI)。因此,在每个小区 ROI 大小相等并且尽可能的包含小麦植株前提下获得所有小区的 ROI,该区域中的数据用于与产量数据进行相关性分析,并构建产量估测模型。




图 2-3 影像裁剪及 ROI 选取示意图

Fig.2-3 Images' cropping and ROI selection

2.2.3 植被指数计算

为避免边缘效应带来影响，多光谱植被指数（下称多光谱指数）由 ROI（Region of Interest）工具标出的、位于每个试验小区中心位置的矩形框内数据进行计算。以矩形框内所有像素的平均反射率作为该小区的平均冠层反射率，计算获得植被指数。本研究选取 33 种常见的植被指数（表 2-4），用于小麦产量估测，各指数计算方法依据参考文献。

表 2-3 多光谱特征表

Table 2-3 Multispectral feature list				
序号	植被指数	全名	公式	文献
1	R	红光通道的反射率		-
2	G	绿光通道的反射率		-
3	B	蓝光通道的反射率		-
4	RedEdge	红边通道的反射率		-
5	NIR	近红外通道的反射率		-
6	ExR	Excess Red	$1.4R-G$	Meyer et al. (1999)
7	VDVI	Visible-band Difference Vegetation Index	$\frac{(2G-R-B)}{(2G+R+B)}$	Gago et al. (2015)
8	NGBDI	Normalized Green-Blue Difference Index	$\frac{(G-B)}{(G+B)}$	Hunt et al. (2005)

序号	植被指数	全名	公式	文献
9	NGRDI	Normalized Green-Red Difference Index	$(G-R)/(G+R)$	Hunt et al. (2005)
10	ExGR	Excess Green minus Red	$E \times G - E \times R$	Neto et al. (2004)
11	ExG	Excess Green	$2g-r-b$	Mao et al. (2003)
12	VARI	Visible Atmospherically Resistant Index	$(g-r)/(g+r-b)$	Gitelson et al. (2002)
13	NDVI	Normalized Difference Vegetation Index	$(RE-R)/(RE+R)$	Rouse et al. (1974)
14	GNDVI	Green normalized difference vegetation index	$(RE-G)/(RE+G)$	Gitelson et al. (1996)
15	RVI	Ratio Vegetation Index	RE/R	Major et al. (1990)
16	NDWI	Normalized Difference Water Index	$(G-RE)/(G+RE)$	Mcfeeters et al. (1996)
17	DVI	Different Vegetation Index	$RE-R$	Shimada et al. (2012)
18	CIVE	Color Index of Vegetation Extraction	$0.441R-0.811G+0.385B+18.787$	Kataoka et al. (2003)
19	SAVI	Soil Adjusted Vegetation Index	$1.5(RE-R)/(RE+R+0.5)$	Huete et al. (1988)
20	MSAVI	Modified Soil Adjusted Vegetation Index	$0.5\{2(RE+1)-\sqrt{[(2RE+1)^2-8(RE-R)]}\}$	Qi et al. (1994)
21	ARVI	Atmospherically Resistant Vegetation Index	$\{RE-[R-(B-R)]\}/\{RE+[R-(B-R)]\}$	Kaufman et al. (1992)
22	EVI	Enhanced Vegetation Index	$[2.5(RE-R)]/(RE+6R-7.5B+1)$	Huete et al. (2002)
23	NDRE	Normalized Difference Red Edge Index	$(NIR-REG)/(NIR+REG)$	Kanke et al. (2016)
24	SIPI	Structure Insensitive Pigment Index	$(Nir-B)/(Nir-R)$	Gupta et al. (2021)
25	SRPI	Simple Ratio Pigment Index	$RedEdge/Nir$	Peñuelas et al. (1995)
26	IPVI	Infrared Percentage Vegetation Index	$RE/(RE+R)$	Crippen (1990)
27	CIrededge	Chlorophyll Index Rededge	$Nir/Rededge-1$	Gitelson et al. (2003)
28	CIgreen	Chlorophyll index green	$(G-R)/(G+R-B)$	Hatfield et al. (2010)
29	MCARI	Modified Chlorophyll Absorption Ratio Index	$[(N-R)-0.2(N-G)](N/R)$	Daughtry et al. (2000)

序号	植被指数	全名	公式	文献
30	NPCI	Normalized Pigment Chlorophyll Index	$(\text{Nir}-\text{Rededge})/(\text{Nir}+\text{Rededge})$	Peñuelas et al. (1994)
31	TCARI	Transformed Chlorophyll Absorption in Reflectance Index	$3*[(\text{Rededge}-\text{R})-0.2(\text{Rededge}-\text{G})*(\text{Rededge}/\text{R})]$	Gitelson et al (1994)
32	SR	Simple Ratio	Nir/R	Broge et al (2001)
33	TVI	Triangular Vegetation Index	$0.5[120(\text{N}-\text{G})-200(\text{R}-\text{G})]$	Vogelmann et al (1993)
34	MSR	Modified Simple Ratio	$(\text{NIR}/\text{R}-1)/\sqrt{(\text{NIR}/\text{Red}+1)}$	Dash et al (2004)
35	WDRVI	Wide Dynamic Range Vegetation Index	$(\text{Nir}-\text{R})/(\text{Nir}+\text{R})$	Testa et al. (2018)
36	RDVI	Renormalized Difference Vegetation Index	$(\text{RE}-\text{R})/\sqrt{(\text{RE}+\text{R})}$	Roujean et al (1995)
37	OSAVI	Optimized Soil Adjusted Vegetation Index	$[1.5(\text{RE}-\text{R})]/(\text{RE}+\text{R}+0.16)$	Rondeaux et al (1996)
38	SAVI	Soil Adjusted Vegetation Index	$[(\text{NIR}-\text{R})/(\text{NIR}+\text{R}+0.5)]*(1+0.5)$	Huete et al. (1988)

注： $r=\text{R}/(\text{R}+\text{G}+\text{B})$, $g=\text{G}/(\text{R}+\text{G}+\text{B})$, $b=\text{B}/(\text{R}+\text{G}+\text{B})$

2.3 冬小麦产量估测模型

用上述方法获取不同试验地区、不同品种、不同时期小麦植被指数信息和相关气象因子及作物表型数据后，将这些数据作为特征值，即输入变量，实测产量为输出变量，探索构建基于不同机器学习算法的小麦产量估测模型，并评估气象因子和作物表型数据对最优模型的贡献度。本研究建模与数据分析代码均用 Python 语言，建模方法包括：随机森林（RF）、支持向量回归（SVR）和岭回归（RR）3 种算法。

2.3.1 随机森林（Random Forest, RF）

随机森林作为一种集成学习算法，通过构建多棵决策树，并对其结果进行投票（分类）或平均（回归）以提高预测精度和稳定性。其核心思想是“Bagging（Bootstrap Aggregating）”与“特征随机选择”，其中 Bagging 指每棵树基于由放回抽样的训练子集（Bootstrap 样本）构建，以降低模型方差。特征随机选择指每次分裂节点时随机选择部分特征，减少特征间相关性，以增强泛化能力。

随机森林模型的优点主要有 4 方面：一是高精度，即通过集成多棵树以降低过拟合风险，适合高维数据和非线性关系；二是鲁棒性强，即对噪声数据和缺失值不敏感，无需复杂的数据预处理；三是特征重要性评估直观，即通过计算特征

对模型预测的贡献度（如：Gini 指数或均方误差减少量），可直观了解各特征变量的重要性高低，同时支持变量筛选；四是并行化计算，即可分布式训练，适合大规模数据。然而，其也具有一定的缺点。随机森林模型的缺点主要是解释性低，难以直观解释单棵树或整体模型的决策逻辑；同时，计算复杂耗时长，树的数量较多时，训练和预测时间较长。与此同时，用高稀疏数据建模效果较差。

2.3.2 支持向量回归（Support Vector Regression, SVR）

支持向量回归是支持向量机（SVM）在回归问题中的扩展，核心思想是通过核函数将数据映射到高维空间，寻找一个间隔带（ ϵ -insensitive tube），使大部分样本落在带内，同时最小化间隔外误差。支持向量回归的优点主要有三个方面：一是高维适应性强，即核函数可灵活处理非线性关系，适合小样本高维数据；二是全局最优解，即基于优化理论，避免陷入局部最优；三是鲁棒性强，即对异常值和噪声的敏感度较低（通过调整 ϵ 参数）。然而，其也具有一定的缺点。其中支持向量回归的参数敏感度过高，如核函数类型、惩罚系数（C）、 ϵ 值等参数需精细调优，致使计算成本过高；计算效率低，难以处理超大规模数据，核函数映射后的特征空间难以直观解释。

2.3.3 岭回归（Ridge Regression, RR）

岭回归是一种处理线性回归中多重共线性问题的正则化方法，主要是通过引入 L2 正则化项，有效降低模型复杂度和提高泛化能力。岭回归主要优点有三方面：一是模型简单高效，即计算速度快，适合高维数据（如遥感波段数据）；二是可解释性强，即系数直接反映变量对输出的边际贡献；三是抗过拟合，即正则化项约束模型复杂度，提升泛化能力。与此同时，岭回归也存在自身的缺点，如：仅捕捉线性关系，无法建模非线性或交互效应（如温度与降水的协同影响）且需要手动调参，计算成本较高等。与此同时，采用普通最小二乘法（OLS）估计时系数方差较大，会导致模型不稳定且预测能力下降。

2.4 模型精度验证

本研究采用支持向量机（SVM）、随机森林（RF）和岭回归（RR）建模时，选择 70% 的数据作为建模集，其余 30% 的数据作为验证集，且所有模型均使用同一套建模集和验证集，以确保各模型之间精度的可比性。利用决定系数（ R^2 ）和均方误差（MSE）指标比较各回归模型的表现，确定最优模型（Bian et al. 2022）。

决定系数 R^2 表示估测值与实测值的拟合程度，范围在 $[-\infty, 1]$ ， R^2 越趋近 1，则表明模型的估测效果越好。与此同时，当 R^2 小于等于 0 时，模型预测样本效果差。表达式为：

$$R^2 = 1 - \frac{\sum_i (y_i - f_i)^2}{\sum_i (y_i - \bar{y})^2}$$

其中 f_i 表示第 i 个样本的预测值， $\bar{y}$ 为因变量均值， y_i 为因变量实测值。

均方误差 MSE 反映了估测值与实测值之间的误差，范围在 $[0, \infty]$ ，值越小，表明模型性能越好；值越大，表明模型性能越差，表达式为：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - f_i)^2$$

2.5 各模型中变量重要性的确定

为了探究试验中的气象因子及表型参数在各模型中的重要性，根据不同模型的特点确定特征贡献度（李远斌等，2023；李旭然和丁晓红，2019）：

（1）RF 中各参数重要性排序，依比较分析植被指数、表型参数、土壤水肥条件等对模型构建的贡献程度而定，贡献度（系数值）越大重要性越高，反之亦然；

（2）SVR 模型是非线性的，线性模型的系数方法不适用，无法直接获取系数。因此，本研究使用排列重要性的方法计算特征重要性，即通过打乱每个特征的值，观察模型性能下降程度，性能下降越多，说明该特征越重要；

（3）RR 模型根据标准化后指标特征系数绝对值排序，绝对值越大，变量重要性越高，反之重要性低。

第三章 不同生育时期各变量与产量的研究

3.1 生育期确定

本研究采用无人机多光谱遥感技术获取小麦关键物候期影像数据，因此需要依据作物发育规律，并结合田间表型监测结果进行生育期划分，以确保遥感数据与农学观测数据的时空匹配性。表 3-1 为各供试品种植株特点，表 3-2 为本试验小麦生育期分类依据。

产量形成关键物候期涉及孕穗期、抽穗期、灌浆期、乳熟期及成熟期。本研究基于 2023-2024 年度无人机平台获取的高分辨率多光谱影像，构建多生育期协同的估产模型。该模型在构建过程中不仅考虑单生育期光谱特征，还重点关注了不同物候阶段光谱参数及各不同时期的作物表型及气象因子。

表 3-1 供试品种植株特点

Table 3-1 Characteristics of the test varieties				
	小偃 22	伟隆 169	西农 059	西农 511
株高	75-80cm	70-75cm	70-75cm	65-70cm
株型	紧凑，茎秆弹性中等	直立，茎秆坚韧	松散，抗旱适应	极紧凑，茎秆粗壮
分蘖能力	中等，成穗率较高	中等偏强，成穗整齐	强，旱地成穗率高	中等，成穗稳定
叶片特点	宽大深绿	直立中等	窄浅绿	宽短浓绿

表 3-2 小麦关键生育期分类表

Table3-2 Classification of Key Growth Periods of Wheat	
小麦关键生育期	划分依据
孕穗期	幼穗在旗叶叶鞘内发育完成，茎秆顶部膨大形成"打苞"状态，但尚未抽出叶鞘。此时旗叶（最后一片叶）完全展开，叶鞘包裹的穗部膨大可见。
抽穗期	全田 50%以上麦穗（不包括芒）由叶鞘中露出 1/2 时。
灌浆期	营养物质迅速运往籽粒并累积起来，籽粒开始沉积淀粉、胚乳呈炼乳状，约在开花后 10 天左右。
乳熟期	籽粒体积达到最大，胚乳由炼乳状转为乳白色浆液，含水量下降至 50%左右。籽粒背部青绿开始消退，但指甲仍可掐出乳状液体。

成熟期 胚乳呈蜡状，籽粒开始变硬时，为成熟期。此时为最适收获期，接着籽粒很快变硬，为完熟期。

3.2 试验区多光谱数据分析

在小麦抽穗期、孕穗期、灌浆期、乳熟期和成熟期，利用无人机搭载含蓝（B）、绿（G）、红（R）、红边（Red Edge）和近红外（NIR）五个波段的多光谱相机，采集小麦冠层多光谱影像，并进行拼接，选取感兴趣区域（ROI），使用 ENVI 5.6 软件提取各波段、不同时期小麦冠层反射率数据，绘制周至和扶风小麦光谱折线图，结果发现：

不同地区小麦光谱曲线均呈现典型的植被光谱特征。孕穗期、抽穗期、灌浆期小麦叶片对不同波段光反射率（吸收率）变化趋势一致，即由 450nm 波段处升高至 550nm 波段处然后下降至 660nm 波段处，之后反射率呈现快速增长趋势。在可见光-近红外波段范围内，各光谱特征峰谷规律显著，其中 450 nm 波段对应类胡萝卜素吸收峰，平均反射率不足 10%；550 nm 附近形成叶绿素反射峰，呈现典型的"绿峰"特征；660 nm 波段显示叶绿素强吸收谷，部分反射率降至光谱曲线近乎最低；700 nm 处反射率陡升形成的红边区域，其斜率变化与叶绿素含量相关；750 nm 波段达到近红外高反射平台，反射率普遍超过 40%。




图 3-1 孕穗期光谱折线图

Fig. 3-1 Spectral line chart at booting stage




图 3-2 抽穗期光谱折线图

Fig. 3-2 Spectral line chart at heading stage




图 3-3 灌浆期光谱折线图

Fig. 3-3 Spectral line chart at filling stage




图 3-4 乳熟期光谱折线图

Fig. 3-4 Spectral line chart at milk stage




图 3-5 成熟期光谱折线图

Fig. 3-5 Spectral line diagram at maturity stage

多光谱数据对比分析发现，试验小区光谱分布特征主要集中在 550-680 nm 可见光波段与 700-850 nm 近红外高反射波段 2 个敏感区域，推测可能是因为小麦产量与叶绿素含量密切相关。同时，产量高的小麦植株一般长势旺，活性高，光会在小麦株间形成多次散射，表现为近红外波段反射率高。

3.3 波段信息与产量相关性分析

试验区孕穗期、抽穗期、灌浆期、乳熟期和成熟期小麦冠层无人机影像信息与小麦产量相关性分析结果，如表 3-2 所示。除红波段（R）外，周至和扶风小麦不同发育时期的其他波段信息和小麦产量之间存在较强的相关性。特别是 NIR 波段，在周至和扶风小麦各时期均表现出极显著相关（ $P<0.001$ ），周至乳熟期相关性值最高，为 0.765；扶风孕穗期相关性值最高，为 0.851。除去 R 波段数据后，不同波段信息与产量的相关性从孕穗期到成熟期平均下降 14.3%（ZZ）和 9.8%（FF），推测这可能与生殖生长后期叶片衰老致使冠层光谱反射率降低有关。

表 3-3 波段信息与试验区小麦产量的相关性

Table 3-3 Correlation between band information and wheat yield in experimental area

波段 信息	孕穗期		抽穗期		灌浆期		乳熟期		成熟期	
	ZZ	FF	ZZ	FF	ZZ	FF	ZZ	FF	ZZ	FF
B	0.387*	0.427*	0.372*	0.385*	0.352*	0.338	0.338	0.401*	0.361*	0.361
G	0.511**	0.612**	0.497**	0.554**	0.483**	0.503**	0.503**	0.587**	0.489**	0.489**
R	-0.352	-0.212	-0.328	-0.245	-0.297	-0.287	-0.287	-0.271	-0.314	-0.314
Red edge	0.682***	0.723***	0.651***	0.674***	0.634***	0.621***	0.621***	0.703***	0.658***	0.658***
Nir	0.729***	0.851***	0.732***	0.798***	0.718***	0.765***	0.765***	0.818***	0.742***	0.742***

注：ZZ（周至相关性），FF（扶风相关性）。*** $p<0.001$ ，极显著；** $p<0.01$ ，非常显著；* $p<0.05$ ，显著。

3.4 气象因子及作物表型与产量相关性分析

表 3-4 气象因子及作物表型与试验区小麦产量相关性

Table 3-4 Correlation between meteorological factors, crop phenotype and wheat yield in experimental area

波段 信息	孕穗期		抽穗期		灌浆期		乳熟期		成熟期	
	ZZ	FF	ZZ	FF	ZZ	FF	ZZ	FF	ZZ	FF
N	0.780***	0.560***	0.750***	0.550***	0.680***	0.500***	0.630***	0.440***	0.600***	0.410**
S	0.296	0.301*	0.404**	0.512**	-0.277	-0.354	-0.209	-0.21	0.296	0.273
Gao	-0.387	-0.276	-0.253	-0.152	0.128	0.021	-0.298	-0.174	-0.387	-0.247
Ye	0.521***	0.423**	0.492**	0.326*	0.289	0.234	0.567***	0.44**	0.41**	0.319*

注：ZZ（周至相关性），FF（扶风相关性），N（土壤氮含量），S（土壤含水量），Gao（小麦株高），Ye（小麦旗叶面积）。*** $p<0.001$ ，极显著；** $p<0.01$ ，非常显著；* $p<0.05$ ，显著。

气象因子、小麦表型与小麦产量相关分析结果表 3-4 显示，周至、扶风两地小麦五个生育期土壤含氮量（N）与小麦最终产量呈极显著相关（ $p<0.01$ ）。其

中, 周至最显著时期为孕穗期, 相关性达 0.78; 扶风地区孕穗期土壤含氮量(N)与小麦最终产量相关性是 0.56。与此同时, 除灌浆期外, 其他时期小麦株高均与最终产量呈现负相关, 其中成熟期时株高与小麦产量表现出最高负相关, 分别为 -0.387 与 -0.247。此外, 周至扶风两地土壤含水量均在抽穗期与最终小麦产量达到显著相关, 分别为 0.404 和 0.512; 周至扶风两地小麦旗叶面积与产量相关性最高时期分别为孕穗期 (0.521 和 0.423) 及乳熟期 (0.567 和 0.44)。

3.5 植被指数与产量相关性分析

对周至和扶风 2 个试验地孕穗期、抽穗期、灌浆期、乳熟期和成熟期多光谱影像数据计算获得的 33 种植被指数与小麦产量进行皮尔逊相关系数计算, 并将计算结果进行可视化。

周至扶风两地不同时期植被指数与小麦产量呈现极显著相关的类型不一致, 即使相同植被指数在不同时期与产量的相关性也存在较大差异。除扶风成熟期影像数据外, 其他时期两地植被指数与小麦产量呈极显著相关的植被指数共有 14 个, 分别为: CIG, CIRE, GNDVI, IPVI, MSRI, MVI, NDRE, NDVI, NDWI, OSAVI, RVI, SIPI, SR 和 WDRVI (图 3-6, 图 3-7)。




图 3-6 周至植被指数与产量的相关性

Fig. 3-6 Correlation between Vegetation Index and Yield at Zhouzhi




图 3-7 扶风植被指数与产量的相关性

Fig. 3-7 Correlation between Vegetation Index and Yield at Fufeng

3.6 小结

本章通过系统分析冬小麦不同生育期的多光谱数据、气象因子及作物表型参数与产量的定量关系，说明文中选择的多源数据在产量估测中都发挥着重要作用。主要结论如下：

(1) 生育期光谱特征与产量相关性。

多光谱数据研究发现，近红外（NIR）和红边（RedEdge）波段在各生育期均与产量呈极显著正相关，而红波段（R）与产量一直为负相关。两地波段相关性在孕穗期几乎都达到了峰值。

(2) 多源特征参数的重要性

土壤含氮量（N）和抽穗期土壤含水量（S）是影响产量的核心环境因子，周至孕穗期土壤氮含量相关性达 0.78。株高（Gao）在除灌浆期外各时期与产量呈负相关，表明过高株高可能导致倒伏风险；旗叶面积（Ye）在孕穗期和乳熟期对产量贡献显著，反映其光合能力对籽粒灌浆的持续影响。

(3) 植被指数重要性筛选

基于植被指数相关性分析,与小麦产量呈极显著相关的植被指数共有 14 个,分别为: CIG, CIRE, GNDVI, IPVI, MSRI, MVI, NDRE, NDVI, NDWI, OSAVI, RVI, SIPI, SR 和 WDRVI。

第四章 基于单时期数据构建冬小麦产量模型及其比较

随着遥感技术被逐步使用于精准农业领域中,农业相关数据的获取速率和范围都有了极大的提升。按照数据获取的时间段可将数据分为单时期数据与多时期数据。其中使用基于单时期数据构建的小麦估产模型有着数据获取简单,模型处理效率高,构建模型迅速的优点。但容易忽略小麦的生长动态过程,以及对环境干扰的过度敏感性,进而影响数据质量。故大多适合对精度要求不高或数据资源有限的场景。

4.1 基于周至冬小麦单时期数据的产量模型构建

基于周至试验区孕穗期、抽穗期、灌浆期、乳熟期、蜡熟期(成熟期)小麦多光谱影像数据和其他多源数据,分别针对小偃 22(a), 伟隆 169(b), 西农 059(c), 西农 511(d) 构建最佳产量预测模型,并计算小麦产量模型决定系数(R^2)及均方误差(MSE)对模型精度进行评价。

4.1.1 基于各时期数据的周至地区不同小麦品种产量模型构建

(1) 孕穗期

从表 4-1 可看出,基于周至试验区孕穗期各小麦品种数据构建不同品种的产量估测模型,并比较其决定系数和均方误差,结果发现:基于孕穗期数据的小偃 22 产量预估模型中支持向量回归模型决定系数值最高为 0.921、均方误差值最低为 0.155;伟隆 169 产量预估模型也是支持向量回归模型决定系数值最高为 0.957、均方误差值最低为 0.106;西农 059 产量预估模型中随机森林模型决定系数值最高为 0.874、均方误差值最低为 0.208。西农 511 产量预估模型和供试品种整体产量预估模型均是岭回归模型决定系数值最高,分别为 0.868 和 0.932;均方误差值最低,分别为 0.177 和 0.117。

表 4-1 基于孕穗期数据的周至试区不同小麦品种产量
模型决定系数 (R^2)、均方误差 (MSE)

Table 4-1 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for Different Wheat Varieties in the Zhouzhi Test Area Based on Booting Stage Data

品种	随机森林		支持向量回归		岭回归	
	R^2	MSE	R^2	MSE	R^2	MSE
小偃 22	0.907	0.215	0.921	0.155	0.522	0.379
伟隆 169	0.943	0.148	0.957	0.106	0.730	0.761
西农 059	0.874	0.208	0.855	0.224	0.848	0.358
西农 511	0.770	0.096	0.717	0.218	0.868	0.177
所有品种	0.916	0.137	0.527	0.764	0.932	0.117

(2) 抽穗期

从表 4-2 可看出, 周至试区基于抽穗期数据的不同冬小麦之间, 随机森林模型在除了西农 511 外, 其他品种的精度都优于其他两个模型。“小偃 22” 基于抽穗期无人机影像数据的产量预估模型, 随机森林模型决定系数值最高为 0.897; “伟隆 169” 也是随机森林决定系数值最高为 0.981 且均方误差值最低为 0.048; “西农 059” 随机森林模型决定系数值最高为 0.939、均方误差值最低为 0.1; “西农 511” 支持向量回归模型决定系数值最高为 0.937、均方误差值最低为 0.049; 供试品种整体随机森林模型决定系数值最高为 0.934、均方误差值最低为 0.107。

表 4-2 基于抽穗期数据的周至试区不同小麦品种
产量模型决定系数 (R^2)、均方误差 (MSE)

Table 4-2 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for Different Wheat Varieties in the Zhouzhi Test Area Based on Heading Stage Data

品种	随机森林		支持向量回归		岭回归	
	R^2	MSE	R^2	MSE	R^2	MSE
小偃 22	0.897	0.239	0.829	0.336	0.849	0.121
伟隆 169	0.981	0.048	0.937	0.156	0.979	0.057
西农 059	0.939	0.1	0.909	0.141	0.931	0.164
西农 511	0.783	0.091	0.937	0.049	0.843	0.211
所有品种	0.934	0.107	0.506	0.798	0.823	0.298

(3) 灌浆期

从表 4-3 可看出, 周至试区基于灌浆期数据的不同品种冬小麦之间, 岭回归模型在除了西农 511 品种外, 其他品种的精度都优于其他两个模型。“小偃 22” 基于灌浆期数据的产量预估模型, 岭回归决定系数值最高为 0.964、均方误差值最低为 0.029; “伟隆 169” 岭回归决定系数值最高为 0.980; “西农 059” 岭回归

模型决定系数值最高为 0.941；“西农 511”支持向量回归模型决定系数值最高为 0.835；供试品种整体岭回归模型决定系数值最高为 0.920、均方误差值最低为 0.138。

表 4-3 周至试区基于灌浆期数据的不同小麦品种
产量模型决定系数 (R^2)、均方误差 (MSE)

Table 4-3 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for
Different Wheat Varieties in the Zhouzhi Test Area Based on Filling Stage Data

品种	随机森林		支持向量回归		岭回归	
	R^2	MSE	R^2	MSE	R^2	MSE
小偃 22	0.914	0.199	0.859	0.277	0.964	0.029
伟隆 169	0.979	0.054	0.930	0.174	0.980	0.056
西农 059	0.889	0.184	0.920	0.125	0.941	0.138
西农 511	0.801	0.083	0.835	0.127	0.642	0.482
所有品种	0.827	0.281	0.544	0.736	0.920	0.138

(4) 乳熟期

从表 4-4 可看出，周至试区基于乳熟期数据的不同品种冬小麦之间，各品种的最佳模型都不尽相同。“小偃 22”基于乳熟期数据的产量预估模型，支持向量回归决定系数值最高为 0.921；“伟隆 169”随机森林决定系数值最高为 0.986；“西农 059”岭回归模型决定系数值最高为 0.959；“西农 511”支持向量回归模型决定系数值最高为 0.900；供试品种整体岭回归模型决定系数值最高为 0.898。

表 4-4 周至试区基于乳熟期数据的不同小麦品种
产量模型决定系数 (R^2)、均方误差 (MSE)

Table 4-4 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for
Different Wheat Varieties in the Zhouzhi Test Area Based on Milking Stage Data

品种	随机森林		支持向量回归		岭回归	
	R^2	MSE	R^2	MSE	R^2	MSE
小偃 22	0.900	0.232	0.921	0.154	0.875	0.100
伟隆 169	0.986	0.036	0.585	1.030	0.941	0.168
西农 059	0.882	0.195	0.881	0.184	0.959	0.102
西农 511	0.756	0.102	0.900	0.078	0.799	0.271
所有品种	0.786	0.349	0.323	1.093	0.898	0.176

(5) 成熟期

从表 4-5 可看出，周至试区基于成熟期数据的不同品种冬小麦之间，各品种的最佳模型也都不尽相同。“小偃 22”基于成熟期数据的产量预估模型，随机森林决定系数值最高为 0.895；“伟隆 169”随机森林决定系数值最高为 0.986；“西农 059”支持向量回归模型决定系数值最高为 0.961；“西农 511”支持向量回归模型

决定系数值最高为 0.913；供试品种整体岭回归模型决定系数值最高为 0.878。

表 4-5 周至试区基于成熟期数据的不同小麦品种产量模型
决定系数 (R^2)、均方误差 (MSE)

Table 4-5 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for Different Wheat Varieties in the Zhouzhi Test Area Based on Maturity Stage Data

品种	随机森林		支持向量回归		岭回归	
	R^2	MSE	R^2	MSE	R^2	MSE
小偃 22	0.895	0.242	0.875	0.246	0.634	0.293
伟隆 169	0.986	0.035	0.82	0.477	0.932	0.193
西农 059	0.94	0.099	0.961	0.06	0.951	0.116
西农 511	0.804	0.082	0.913	0.067	0.742	0.348
所有品种	0.693	0.499	0.411	0.951	0.878	0.211

4.1.2 周至不同品种基于单个生育期数据的最优产量模型

表 4-6 结果显示：小偃 22 单时期产量估测最优模型为利用灌浆期数据构建的岭回归模型 ($R^2=0.964$, $MSE=0.029$)；伟隆 169 单时期产量估测最优模型为利用成熟期数据构建的随机森林模型 ($R^2=0.986$, $MSE=0.035$)；西农 059 单时期产量估测最优模型为利用成熟期数据构建的支持向量回归模型 ($R^2=0.961$, $MSE=0.06$)；西农 511 单时期产量估测最优模型为利用抽穗期数据构建的支持向量回归模型 ($R^2=0.937$, $MSE=0.049$)。与此同时，不区分品种时，小麦单时期产量估测最优模型为利用抽穗期数据构建的随机森林模型 ($R^2=0.934$, $MSE=0.107$)。上述结果表明，基于单生育期光谱数据构建的 4 个品种产量最优模型所用的生育期数据和机器模型均不相同，且使用所有供试品种单时期光谱数据进行统一调试模型参数后，虽可以取得较好的模拟效果， R^2 为 0.934，但小麦品种差异对模型精度的影响仍是后续建模需要考虑的重要因素。

表 4-6 周至试区 4 个小麦品种基于不同单生育期的最佳产量评估模型

Table 4-6 The optimal yield evaluation model based on different growth stages for four wheat varieties in the Zhouzhi

品种	孕穗期	抽穗期	灌浆期	乳熟期	成熟期	全局最优解
小偃 22	SVR (0.921)	RF (0.897)	RR (0.964)	SVR (0.921)	RF (0.895)	灌浆期 RR (0.964)
伟隆 169	SVR (0.957)	RF (0.981)	RR (0.98)	RF (0.986)	RF (0.986)	成熟期 RF (0.986)
西农 059	RF (0.874)	RF (0.939)	RR (0.941)	RR (0.959)	SVR (0.961)	成熟期 SVR (0.961)
西农 511	RR	SVR	SVR	SVR	SVR	抽穗期 SVR

	(0.868)	(0.937)	(0.835)	(0.9)	(0.913)	(0.937)
所有供试品种	RR	RF	RR	RR	RR	抽穗期 RF
	(0.932)	(0.934)	(0.92)	(0.898)	(0.878)	(0.934)

注：SVR，支持向量回归；RF，随机森林；RR，岭回归。

4.1.3 周至地区不同冬小麦品种最优产量模型中各特征变量的重要性

(1) 小偃 22

图 4-1 显示，周至试区“小偃 22”产量最优估测模型中，特征贡献度最大的前 5 个特征指数分别是 shui、SPPI、NPCI、RI、CIRedEdge，表明这些指标在构建周至地区小偃 22 品种最佳估产模型时贡献程度最高。




图 4-1 周至小偃 22 (a) 最优解各特征重要性

Fig. 4-1 The importance of each feature of the optimal solution of Xiaoyan 22 in Zhouzhi

(2) 品种“伟隆 169”

图 4-2 显示，周至试区“伟隆 169”产量最优估测模型中，特征贡献度最大的前 5 个特征指数是 NPCI、TCARI、EXG、RI、NDWI，表明这些指标在构建周至地区伟隆 169 品种最佳估产模型时贡献程度最高。




图 4-2 周至伟隆 169 (b) 最优解各特征重要性

Fig 4-2 The importance of each feature of the optimal solution of Weilong 169 in Zhouzhi

(3) 品种“西农 059”

图 4-3 显示，周至试区“西农 059”产量最优估测模型中，特征贡献度最大的前 5 个特征指数是 MSRI、SR、RVI、SRPI、CIRedEdge，表明这些指标在构建周至地区西农 059 品种最佳估产模型时贡献程度最高。




图 4-3 周至西农 059 最优解各特征重要性

Fig. 4-3 The importance of each feature of the optimal solution of Xinong 059 in Zhouzhi

(4) 品种“西农 511”

图 4-4 显示, 周至试区“西农 511”产量最优估测模型中, 特征贡献度最大的前 5 个特征指数是 TCARI、TVI、DVI、EVI、SAVI, 表明这些指标在构建周至地区西农 511 品种最佳估产模型时贡献程度最高。




图 4-4 周至西农 511 最优解各特征重要性

Fig 4-4 The importance of each feature of the optimal solution of Xinong 511 in Zhouzhi

(5) 4 个供试品种整体

图 4-5 显示, 周至试区将所有供试品种作为整体的产量最优估测模型中, 特征贡献度最大的前 5 个特征指数是 RI、EXR、NPCI、NDWI、NGRDI, 表明这些指标在构建周至地区所有供试品种最佳估产模型时贡献程度最高。




图 4-5 周至全品种最优解各特征重要性

Fig. 4-5 The importance of each feature of the optimal solution of all varieties in Zhouzhi

利用本研究采用的 33 个植被指数,通过单生育期数据构建估产模型时,各个最优解模型中的各植被指数特征贡献度大多并不相同。其中,MSRI、RVI、NDRE、EVI、GI、shui、NPCI、SR、VARI、TVI、DVI、CIGreen、SAVI、RDVI、OSAVI、CIRedEdge 出现的频率较高,在多数最佳模型构建时都有较高的贡献度,可以认为是构建单时期周至冬小麦最佳估产模型的关键指标。

4.2 基于扶风冬小麦单时期数据的产量模型构建

基于扶风试验区孕穗期、抽穗期、灌浆期、乳熟期、成熟期小麦多光谱影像数据和其他多源数据,分别针对小偃 22 (a), 伟隆 169 (b), 西农 059 (c), 西农 511 (d) 构建最佳产量预测模型,并计算小麦产量模型决定系数 (R^2) 及均方误差 (MSE) 对模型精度进行评价。

4.2.1 基于各时期数据的扶风地区不同小麦品种产量模型构建

(1) 孕穗期

从表 4-7 可看出,扶风试区基于孕穗期数据的不同品种冬小麦之间、3 个产量预估模型之间的决定系数、均方误差存在一定差异,对“小偃 22”来说,基于孕穗期数据的产量预估模型,随机森林模型决定系数值最高为 0.612;“伟隆 169”岭回归模型决定系数值最高为 0.622;“西农 059”和“西农 511”在这个时期的数据拟合程度过差,无有效模型;供试品种整体支持向量回归模型决定系数值最高为 0.721。

表 4-7 扶风试区基于孕穗期数据的不同小麦品种产量
模型决定系数 (R^2)、均方误差 (MSE)

Table 4-7 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for Different Wheat Varieties in the Fufeng Test Area Based on Booting Stage Data

品种	随机森林		支持向量回归		岭回归	
	R^2	MSE	R^2	MSE	R^2	MSE
小偃 22	0.612	0.065	0.01	0.038	0	0.1454
伟隆 169	0.108	2.328	-0.218	0.620	0.622	0.034
西农 059	-0.493	0.005	-0.371	0.103	-4.838	0.0987
西农 511	-9.673	0.365	-0.088	0.203	-2.005	0.0687
所有品种	0.669	0.211	0.721	0.164	-1.362	0.1686

(2) 抽穗期

从表 4-8 可看出,扶风试区基于抽穗期数据的不同品种冬小麦之间,各模型表现优异程度差异较大。“小偃 22”基于抽穗期数据的产量预估模型,随机森林决定系数值最高为 0.612;“伟隆 169”岭回归决定系数值最高为 0.7572;“西农 059”

和“西农 511”在这个时期的数据拟合程度过差，无有效模型；供试品种整体随机森林模型决定系数值最高为 0.844。

表 4-8 扶风试区基于抽穗期影像数据的不同小麦品种
产量模型决定系数 (R^2)、均方误差 (MSE)

Table 4-8 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for Different Wheat Varieties in the Fufeng Test Area Based on Heading Stage Data

品种	随机森林		支持向量回归		岭回归	
	R^2	MSE	R^2	MSE	R^2	MSE
小偃 22	0.612	0.065	-0.166	0.045	0	0.147
伟隆 169	-1.509	0.226	0.374	0.319	0.7572	0.0218
西农 059	0.184	0.003	0.017	0.074	0.1187	0.0149
西农 511	-1.682	0.092	-0.281	0.239	-1.334	0.0525
所有品种	0.844	0.099	0.77	0.135	-1.334	0.3464

(3) 灌浆期

从表 4-9 可看出，扶风试区基于灌浆期数据的不同品种冬小麦之间，各模型精度差异较大。“小偃 22”基于灌浆期数据的产量预估模型，随机森林决定系数值最高为 0.566；“伟隆 169”支持向量回归决定系数值最高为 0.45；“西农 059”和“西农 511”在这个时期的数据拟合程度过差，无有效模型；供试品种整体支持向量回归模型决定系数值最高为 0.69。

表 4-9 扶风试区基于灌浆期数据的不同小麦品种
产量模型决定系数 (R^2)、均方误差 (MSE)

Table 4-9 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for Different Wheat Varieties in the Fufeng Test Area Based on Filling Stage Data

品种	随机森林		支持向量回归		岭回归	
	R^2	MSE	R^2	MSE	R^2	MSE
小偃 22	0.566	0.073	-0.747	0.067	0	0.1776
伟隆 169	-4.457	0.491	0.45	0.28	0.4427	0.0502
西农 059	-3.165	0.015	-0.125	0.169	-3.4128	0.0746
西农 511	-0.782	0.061	-0.199	0.224	-1.3637	0.0532
所有品种	0.63	0.213	0.69	0.182	0.0539	0.1404

(4) 乳熟期

从表 4-10 可看出，扶风试区基于成熟期数据的不同品种冬小麦之间，各品种的最佳模型不尽相同。“小偃 22”基于乳熟期数据的产量预估模型拟合效果较差，无有效模型；“伟隆 169”岭回归决定系数值最高为 0.677；“西农 059”支持向量回归模型决定系数值最高为 0.484；“西农 511”随机森林模型决定系数值最

高为 0.606；供试品种整体随机森林模型决定系数值最高为 0.748。

表 4-10 扶风试区基于乳熟期影像数据的不同小麦品种
产量模型决定系数（ R^2 ）、均方误差（MSE）

Table 4-10 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for
Different Wheat Varieties in the Fufeng Test Area Based on Milking Stage Data

品种	随机森林		支持向量回归		岭回归	
	R^2	MSE	R^2	MSE	R^2	MSE
小偃 22	-0.096	0.246	-1.788	0.107	0	0.0068
伟隆 169	0.196	0.136	-0.095	0.557	0.667	0.0291
西农 059	0.464	0.004	0.484	0.039	-4.8952	0.0996
西农 511	0.606	0.05	-0.107	0.207	-0.3985	0.0315
所有品种	0.748	0.145	0.594	0.238	0.2046	0.188

（5）成熟期

从表 4-11 可看出，扶风试区基于成熟期数据的不同品种冬小麦之间，几乎没有拟合效果理想的模型。所有品种单独进行拟合时，拟合结果都不理性，无有效模型；只有供试品种整体支持向量回归模型中决定系数值最高为 0.468。

表 4-11 扶风试区基于成熟期影像数据的不同小麦品种
产量模型决定系数（ R^2 ）、均方误差（MSE）

Table 4-11 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for
Different Wheat Varieties in the Fufeng Test Area Based on Maturity Stage Data

品种	随机森林		支持向量回归		岭回归	
	R^2	MSE	R^2	MSE	R^2	MSE
小偃 22	-0.485	0.333	-3.191	0.161	0	0.0544
伟隆 169	-2.535	0.597	0.079	0.469	-2.0884	0.2776
西农 059	-26.354	0.221	-1.77	0.208	-40.2885	0.6978
西农 511	0.135	0.11	0.072	0.173	-5.1443	0.1382
所有品种	0.386	0.353	0.468	0.312	0.1298	0.1291

4.2.2 扶风不同品种基于单个生育期数据的最优产量模型

表 4-12 扶风试区基于各生育期数据及 3 种模型方法的最优产量模型

Table 4-12 The optimal yield evaluation model based on different growth stages for four wheat
varieties in the Fufeng

品种	孕穗期	抽穗期	灌浆期	乳熟期	成熟期	全时期最优解
小偃 22	RF (0.612)	RF (0.612)	RF (0.566)	拟合结果 较差	拟合结果 较差	孕穗期抽穗期 RF (0.612)

品种	孕穗期	抽穗期	灌浆期	乳熟期	成熟期	全时期最优解
伟隆 169	RR (0.622)	岭回归 (0.7572)	SVR (0.45)	RR (0.667)	拟合结果 较差	抽穗期 RR (0.7572)
西农 059	拟合结果 较差	拟合结果 较差	拟合结果 较差	SVR (0.484)	拟合结果 较差	乳熟期 SVR (0.484)
西农 511	拟合结果 较差	拟合结果 较差	拟合结果 较差	RF (0.606)	拟合结果 较差	乳熟期 RF (0.606)
所有品种	SVR (0.721)	RF (0.844)	SVR (0.69)	RF (0.748)	SVR (0.468)	抽穗期 RF (0.844)

注：SVR，支持向量回归；RF，随机森林；RR，岭回归。

根据表格 4-12，小偃 22 的单时期最优模型为利用孕穗期数据的随机森林（ $R^2=0.612$ ， $MSE=0.065$ ）模型；伟隆 169 的单时期最优模型为利用抽穗期数据的岭回归（ $R^2=0.7572$ ， $MSE=0.0218$ ）模型；西农 059 的单时期最优模型为利用乳熟期数据的支持向量回归（ $R^2=0.484$ ， $MSE=0.039$ ）模型；西农 511 的单时期最优模型为利用乳熟期数据的随机森林（ $R^2=0.606$ ， $MSE=0.05$ ）模型；所有品种综合时单时期最优模型为利用抽穗期数据的随机森林（ $R^2=0.844$ ， $MSE=0.099$ ）模型。使用扶风冬小麦单时期数据进行估产模型构建时，得到的结果与周至类似，即小麦品种对估测模型的选择有很大的影响，且因为不同地区的环境因素差异过大，同时期数据构建的模型精度也存在较大的差异。扶风地区单时期数据出现拟合结果较差的情况，其原因可能是扶风地区小麦种植区域内有部分土地板结，导致部分品种发芽率受到影响，从而使得光谱数据在个别小区获取异常，而单时期数据由于数据量不大，更容易受因意外原因而导致的错误数据影响，从而出现拟合效果较差的现象。

4.2.3 扶风地区不同冬小麦品种最优产量模型中各特征变量的重要性

（1）小偃 22 贡献度较大特征指数

图 4-6 显示，扶风试区“小偃 22”产量最优估测模型中，特征贡献度最大的前 5 个特征指数是 CIVE、CIGreen、NDWI、RI、GNDVI，表明这些指标在构建扶风地区小偃 22 品种最佳估产模型时贡献程度最高。




图 4-6 扶风小偃 22 最优解各特征重要性

Fig. 4-6 The importance of each feature of the optimal solution of Xiaoyan 22 in Fufeng

(2) 伟隆 169 贡献度较大特征指数

图 4-7 显示, 扶风试区“伟隆 169”产量最优估测模型中, 特征贡献度最大的前 5 个特征指数是 CIRedEdge、NDRE、DVI、CIGreen、TVI, 表明这些指标在构建扶风地区伟隆 169 品种最佳估产模型时贡献程度最高。




图 4-7 扶风伟隆 169 最优解各特征重要性

Fig 4-7 The importance of each feature of the optimal solution of Weilong 169 in Fufeng

(3) 西农 059 贡献度较大特征指数

图 4-8 显示, 扶风试区“西农 059”产量最优估测模型中, 特征贡献度最大的前 5 个特征指数是 Shui, zhugao, N, CIVE, EXG, 表明这些指标在构建扶风地区西农 059 品种最佳估产模型时贡献程度最高。




图 4-8 扶风西农 059 最优解各特征重要性

Fig 4-8 The importance of each feature of the optimal solution of Xinong 059 in Fufeng

(4) 西农 511 贡献度较大特征指数

图 4-9 显示, 扶风试区“西农 511”产量最优估测模型中, 特征贡献度最大的前 5 个特征指数是 RI、NPCI、CIVE、NDWI、MCARI, 表明这些指标在构建扶风地区西农 511 品种最佳估产模型时贡献程度最高。




图 4-9 扶风西农 511 最优解各特征重要性

Fig 4-9 The importance of each feature of the optimal solution of Xinong 511 in Fufeng

(5) 4 个供试品种整体贡献度较大特征指数

图 4-10 显示, 扶风试区将所有供试品种作为整体的产量最优估测模型中, 特征贡献度最大的前 5 个特征指数是 TCARI、NGBDI、RI、NDRE、zhugao, 表明这些指标在构建扶风地区伟隆 169 品种最佳估产模型时贡献程度最高。




图 4-10 扶风四个供试品种整体最优解各特征重要性

Fig 4-10 The importance of each feature of the optimal solution of all varieties in Fufeng

扶风地区的特征重要性图中, CIVE, TCARI, NDWI, NGBDI, CIGreen, MCARI, GI, NDRE, EXR, MVI, RDVI, MSRI, shui, qiye 这些特征变量出现的频率较高, 在多数模型构建时都有较高的贡献度, 可以认为是构建单时期扶风冬小麦估产模型的关键指标。

4.3 讨论

4.3.1 不同模型适配度

近年来, 基于无人机遥感技术的冬小麦产量估测研究广泛探讨了不同机器学习算法的适应性。如陶惠林等(2019)通过多时相高光谱影像数据对比多元线性回归与随机森林算法, 发现偏最小二乘回归(PLSR)模型精度最优。Fei 等(2023)进一步融合 RGB、多光谱及热红外多模态数据, 验证了集成学习算法在多源信息协同下的优越性, 凸显非线性模型对复杂农艺特征的表征能力。杨楠等(2023)基于生育期特异性 RGB 影像构建叶面积指数(LAI)与产量估测模型, 结果显示随机森林(RF)算法的预测稳健性最佳, 印证了其在时序数据中的非线性拟合优势。Bian 等(2022)系统评估了 6 种机器学习算法对多时期植被指数的响应, 发现高斯过程回归(GPR)在灌浆期数据驱动下表现最优。Fu 等(2020)则针对不同生态区划, 证实抽穗期至灌浆期 NDVI 结合随机森林算法可显著提升区域尺度

估产精度，强调了生育期关键物候特征对模型泛化能力的影响。上述研究表明，机器学习算法的性能高度依赖于数据源的时空分辨率、特征及生育期选择，需通过多场景验证明确算法与数据的适配规律。

本研究也得到了类似的结果，在周至和扶风地区各品种小麦的最优模型并不一致，相同品种不同地区的最优模型也并不一致。说明最优模型在应用于不同品种不同环境时，需要对数据和模型适配度进行验证。同时由于周至及扶风地区，单时期的特征数据量都很匮乏，部分模型的训练因为数据量不足，或数据中有异常值而未能表现出模型应有的能力。同时，这也导致某些时期的模型训练集和测试集之间的差异过大，使得模型说服力不足。本研究中随机森林模型，由于其集成学习和特征随机选择机制，在多数情况下展现出较高的鲁棒性和精度，例如周至地区各时期各品种的随机森林模型都能展现出较高精度（最低 $R^2=0.693$ ，最高 $R^2=0.986$ ，且 80% 的模型 R^2 都大于 0.8）。然而，RF 模型因其计算复杂度较高，经常出现过拟合，或在数据量过少时，拟合精度较差，如扶风西农 511（d）成熟期 RF 的 R^2 仅为 -0.782，表明模型完全失效。

4.3.2 表型差异对最优模型选择的影响

因小麦品种不同而产生的表型差异，一直是影响小麦产量的重要因素。研究表明高秆、矮秆对小麦产量的影响尤其突出（吴懿鑫，2018）。同时，小麦品种的遗传特性显著影响表型参数与产量的关联，导致模型构建需考虑品种特异性。Shu et al.（2024）探究了基于无人机多光谱影像的机器学习模型对小麦氮含量进行估算，结果显示不同品种对应的最佳估测模型并不完全一致。

本试验也得到了相同的结果，株高与产量的负相关性在周至和扶风两地均表现显著。同时，因各品种植株、叶片和分蘖能力等特点差异，本次试验中多光谱相机在图像采集时，各品种植株的光谱反射程度也有一定差异。例如分蘖能力强或叶片宽大的品种会获取更高的光谱反射率，而在不同品种间进行产量比较时，这部分光谱反射差异会导致一些机器学习模型拟合能力受到影响，表现为植被指数表现相对较好，但最终产量却并没有明显差别。这种差异要求模型在特征选择时动态权衡株高的正向或负向贡献。故利用无人机多光谱影像来进行小麦估产时，品种差异应被考虑在内。

4.4 小结

本章基于周至和扶风两试验区的多光谱遥感数据，结合随机森林（RF）、支持向量回归（SVR）和岭回归（RR）三种机器学习算法，系统分析了不同生育期（孕穗期、抽穗期、灌浆期、乳熟期、成熟期）单时期数据对冬小麦产量估测模型的精度影响，并探讨了关键特征变量的贡献度。主要结论如下：

（1）模型性能与生育期选择

在周至地区，不同品种的最优模型生育期选择差异显著。例如，小偃 22 在灌浆期采用岭回归模型精度最高（ $R^2=0.964$ ），伟隆 169 在成熟期使用随机森林模型表现最佳（ $R^2=0.986$ ），西农 511 在抽穗期通过支持向量回归模型取得最优结果（ $R^2=0.937$ ）。综合所有品种时，抽穗期随机森林模型整体效果最优（ $R^2=0.934$ ）。而扶风地区模型精度普遍低于周至，且部分生育期数据拟合效果较差。例如，小偃 22 在孕穗期随机森林模型仅达到 $R^2=0.612$ ，西农 059 在乳熟期支持向量回归模型精度为 $R^2=0.484$ 。综合所有品种时，抽穗期随机森林模型精度最高（ $R^2=0.844$ ）。

（2）特征变量贡献度分析

对植被指数而言，NDWI、SIPI、RVI 等植被指数在多数模型中贡献度较高，尤其在孕穗期和抽穗期。对于非植被指数如土壤含氮量（N）、土壤含水量（S）、旗叶面积（Ye）等在各品种最优估产模型的高贡献度（前 20）出现概率占比达 73.33%，表明多源数据融合对提升模型解释力至关重要。另一方面，不同品种的最优模型中关键特征差异显著。例如，周至伟隆 169 对 NPCI 和 TCARI 指数敏感，而扶风西农 059 则更依赖土壤含水量（shui）和株高（zhugao）特征变量。

（3）环境因素的影响

周至地区土壤墒情明显优于扶风地区，模型精度普遍高于扶风地区；扶风部分生育期数据因土壤板结或异常光谱干扰导致模型失效，凸显环境异质性对模型泛化能力的挑战。

故单时期数据虽能构建较高精度的估产模型，但其表现受生育期选择、品种特性和环境因素显著影响。未来需结合多时期数据融合与特征优化，进一步提升模型的稳健性和适应性。

第五章 基于多时期数据构建冬小麦产量模型及其比较

传统单时相遥感数据因受环境噪声干扰显著,且缺乏对作物全生育期生长信息的系统性整合,在产量估算中存在明显局限性。由于未能充分利用各生育期信息,利用单一时期数据进行估产的可靠性及精度亟待提升。相比之下,多时序遥感技术通过动态监测作物关键物候特征,可有效量化不同生育期的生长参数,显著增强估产模型的特征表征能力。当前基于时间序列的估产研究已取得显著进展:孟令华等(2016)通过构建棉花全生育期 NDVI 时序曲线,发现花铃期植被指数达到光谱饱和阈值,并与产量呈现最大相关性;王雪等(2015)采用 MODIS-EVI 时序数据结合高分辨率影像,实现水稻和小麦秸秆量估算误差分别控制在 2.7% 和 1.1%;朱婉雪等(2018)系统比较了冬小麦不同物候期的植被指数响应,确定抽穗灌浆期结合 EVI 指数可建立最优估产模型($R^2=0.7$);韩文霆等(2021)融合牛顿-梯形积分与最小二乘法,基于夏玉米多生育期植被指数积分构建的估产模型,其决定系数突破 0.87。上述研究表明,时序影像数据通过整合作物完整生长周期信息,能够有效增强估产模型的特征维度与解释能力。

冬小麦冠层结构的表型可塑性导致其光谱异质性随生育进程显著改变,这种物候依赖的光谱响应机制直接影响产量模型的稳健性。为解析关键物候期对估产模型的影响阈值,本研究拟构建多生育期协同建模框架:基于孕穗期、抽穗期、灌浆期、乳熟期及成熟期五组独立实验集,通过系统比较不同生育期数据组合构建的模型,确定最优组合。基于此,本研究依据冬小麦 5 个关键生育期的多光谱时序影像,构建多生育期组合估产模型,旨在通过物候特征的系统耦合提升小麦产量预测精度以及提高特征变量对小麦产量估测的解释性。

具体实施中,将各生育期数据集按 7:3 比例分割为训练集与验证集,构建交叉验证框架。选用支持向量机(SVM)、随机森林(RF)及岭回归(Ridge Regression)三类机器学习算法,建立产量模型。通过决定系数(R^2)与均方误差(MSE)构建评估体系,量化算法性能差异,最终确定最优模型架构。进一步观察在最优模型里,各特征变量的贡献程度高低。

5.1 基于周至冬小麦多时期数据的产量模型构建

按照文章之前的生育期划分基础,利用周至孕穗期(A),抽穗期(B),灌浆期(C)乳熟期(D),成熟期(E)的冠层无人机影像植被指数数据及多源数据,构建基于 3 个及以上生育期的关中地区小麦品种小偃 22(a),伟隆 169(b),

西农 059 (c), 西农 511 (d) 的小麦产量模型。计算其最优模型的决定系数 (R^2) 和均方误差 (MSE) 值, 并可视化最优模型中的各特征变量贡献度。

(1) 小麦品种“小偃 22”

在周至试区, “小偃 22” 基于多个生育期影像数据的产量模型决定系数 (R^2)、均方误差 (MSE) 如表 5-1 所示。

表 5-1 周至试区小麦品种“小偃 22”基于多个生育期影像数据的
产量模型决定系数 (R^2)、均方误差 (MSE)

Table 5-1 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for

Xiaoyan 22 in the Zhouzhi Test Area Based on All Stage Data

生育期	RF		SVR		RR	
	MSE	R^2	MSE	R^2	MSE	R^2
A+B+C	0.042	0.977	0.104	0.937	0.1005	0.9534
A+B+D	0.273	0.854	0.077	0.954	0.1349	0.9375
A+B+E	0.556	0.704	0.113	0.932	0.3066	0.8579
A+C+D	0.34	0.781	0.871	0.483	0.1363	0.9093
A+C+E	0.528	0.659	1.638	0.026	0.4814	0.6796
A+D+E	0.955	0.384	1.504	0.106	0.125	0.9168
B+C+D	0.488	0.74	1.085	0.35	0.9005	0.5827
B+C+E	0.579	0.691	1.131	0.322	0.3979	0.8156
B+D+E	1.002	0.466	0.424	0.746	0.2035	0.9057
C+D+E	0.9654	0.3516	0.566	0.661	0.2035	0.9057
A+B+C+D	0.581	0.689	0.161	0.899	0.169	0.879
A+B+C+E	2.676	-0.433	0.225	0.859	0.0889	0.9364
A+B+D+E	2.194	-0.175	0.464	0.708	0.2058	0.8527
A+C+D+E	1.426	0.236	0.464	0.708	0.2058	0.8527
B+C+D+E	1.299	0.304	0.579	0.636	0.2422	0.8267
A+B+C+D+E	0.951	0.8	0.334	0.8	0.1615	0.9145

从表 5-1 可看出, 小偃 22 (a) 品种多时期各最优模型分别为基于孕穗期, 抽穗期, 灌浆期 (A+B+C) 的 RF, 其中 $R^2=0.977$; 基于孕穗期, 抽穗期, 乳熟期 (A+B+D) 的 SVR, 其中 $R^2=0.954$; 基于孕穗期, 抽穗期, 灌浆期 (A+B+C) 的 RR, 其中 $R^2=0.9534$ 。

构建周至小偃 22 最优模型时, 特征变量 NDWI, NPCI, CIGreen, NDVI, NDRE, GNDVI, SIPI, MVI, WDRVI, MSRI, RVI, IPVI, SRPI 为最关键特征, 在三个不同最优模型构建时, 都作为贡献度前 20 个特征出现。RI, SR, N, QIYE, ZHUGAO 作为次重要特征, 在 2 个最优模型构建时, 作为贡献度前 20 个特征出现, 但是, N (0.0292), QiYE (0.0285) 作为周至小偃 22 品

种 SVR 最优模型的贡献度排前两名。同时, N (0.111), zhugao (0.072), qiye (0.07), shui (-0.043) 对周至小偃 22 最优 RR 模型表现出较高的贡献度 (图 5-1, 图 5-2, 图 5-3)。




图 5-1 周至小偃 22 最优 RF 的特征重要性

Fig 5-1 The different importance of features in the optimal RF at Zhouzhi for Xiaoyan 22




图 5-2 周至小偃 22 最优 SVR 的特征重要性

Fig 5-2. The different importance of features in the optimal SVR at Zhouzhi for Xiaoyan 22




图 5-3 周至小偃 22 最优 RR 的特征重要性

Fig 5-3 The different importance of features in the optimal RR at Zhouzhi for Xiaoyan 22

(2) 小麦品种伟隆 “169”

在周至试区，小麦品种“伟隆 169”基于多个生育期影像数据的产量模型决定系数（ R^2 ）、均方误差（MSE）如表 5-2 所示。

表 5-2 周至试区小麦品种“伟隆 169”基于多个生育期影像数据的
产量模型决定系数（ R^2 ）、均方误差（MSE）

Table 5-2 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for
Weilong 169 in the Zhouzhi Test Area Based on All Stage Data

生育期	RF		SVR		RR	
	MSE	R ²	MSE	R ²	MSE	R ²
A+B+C	0.024	0.99	0.091	0.965	0.1866	0.9246
A+B+D	0.585	0.766	0.089	0.965	0.0887	0.9642
A+B+E	0.402	0.839	0.304	0.881	0.0823	0.9668
A+C+D	0.536	0.786	0.953	0.628	1.3308	0.4624
A+C+E	0.976	0.61	1.857	0.275	0.8713	0.648
A+D+E	0.995	0.602	1.994	0.221	0.0769	0.969
B+C+D	0.853	0.695	1.081	0.578	0.1105	0.9553
B+C+E	0.745	0.702	1.638	0.36	1.7076	0.3102
B+D+E	0.915	0.634	1.633	0.362	0.0841	0.966
C+D+E	0.251	0.9	1.075	0.58	0.2572	0.8961
A+B+C+D	0.316	0.857	0.25	0.877	0.1076	0.9531

生育期	RF		SVR		RR	
	MSE	R ²	MSE	R ²	MSE	R ²
A+B+C+E	1.556	0.296	0.102	0.95	0.441	0.808
A+B+D+E	1.657	0.25	0.164	0.919	0.1026	0.9553
A+C+D+E	1.935	0.124	0.313	0.846	0.0932	0.9594
B+C+D+E	1.79	0.19	0.386	0.81	1.2007	0.4773
A+B+C+D+E	0.997	0.552	0.433	0.756	0.0645	0.9759

从表 5-2 可看出, 小偃 22 (a) 品种多时期各最优模型分别为基于孕穗期, 抽穗期, 灌浆期 (A+B+C) 的 RF, 其中 $R^2=0.99$; 基于孕穗期, 抽穗期, 乳熟期 (A+B+D) 的 SVR, 其中 $R^2=0.965$; 基于孕穗期, 乳熟期, 成熟期 (A+D+E) 的 RR, 其中 $R^2=0.969$ 。

构建周至试区品种伟隆 169 最优模型时, 特征变量 NDWI, RI, NPCI, GNDVI, CIGreen, NDVI, NDRE, SIPI, CIRedEdge, NGRDI, VDMI, GI 为最关键特征, 在三个不同最优模型构建时, 都作为贡献度前 20 个特征出现。SRPI, RVI, IPVI, SR, MSRI, N, VARI 作为次重要特征, 在 2 个模型构建时, 作为贡献度前 20 特征出现。N 出现在最优 RF 及 SVR 中, 贡献度占比分别为 0.0114 和 0.0305 (图 5-4, 图 5-5, 图 5-6)。




图 5-4 周至伟隆 169 最优 RF 的特征重要性

Fig 5-4 The different importance of features in the optimal RF at Zhouzhi for Weilong 169




图 5-5 周至伟隆 169 最优 SVR 的特征重要性

Fig. 5-5 The different importance of features in the optimal SVR at Zhouzhi for Weilong 169




图 5-6 周至伟隆 169 最优 RR 的特征重要性

Fig. 5-6 The different importance of features in the optimal RR at Zhouzhi for Weilong 169

(3) 小麦品种“西农 059”

在周至试区,“西农 059”基于多个生育期影像数据的产量模型决定系数(R^2)、均方误差(MSE)如表 5-3 所示。

表 5-3 显示,品种西农 059(c)多时期各最优模型分别为基于孕穗期,抽穗期,灌浆期(A+B+C)的 RF,其中 $R^2=0.965$;基于孕穗期,抽穗期,乳熟期(A+B+D)

的 SVR, 其中 $R^2=0.837$; 基于孕穗期, 抽穗期, 灌浆期 (A+B+C) 的 RR, 其中 $R^2=0.8832$ 。

表 5-3 周至试区小麦品种“西农 059”基于多个生育期影像数据的
产量模型决定系数 (R^2)、均方误差 (MSE)

Table 5-3 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for
Xinong 059 in the Zhouzhi Test Area Based on All Stage Data

生育期	RF		SVR		RR	
	MSE	R^2	MSE	R^2	MSE	R^2
A+B+C	0.069	0.965	0.289	0.816	0.1735	0.8832
A+B+D	0.512	0.734	0.256	0.837	0.2283	0.8463
A+B+E	0.383	0.801	0.308	0.804	0.1424	0.09042
A+C+D	0.832	0.567	0.908	0.422	1.5021	-0.0133
A+C+E	0.632	0.671	1.065	0.321	1.0346	0.3035
A+D+E	0.54	0.719	1.095	0.302	0.8188	0.4488
B+C+D	0.471	0.755	0.832	0.47	0.5764	0.621
B+C+E	0.565	0.706	1.003	0.361	0.3204	0.7843
B+D+E	0.558	0.71	0.939	0.376	0.6332	0.5738
C+D+E	0.509	0.735	0.77	0.509	5.2907	-2.5618
A+B+C+D	0.804	0.374	0.58	0.471	0.456	0.7177
A+B+C+E	0.762	0.407	0.343	0.687	0.4335	0.7316
A+B+D+E	0.73	0.432	0.318	0.71	0.3077	0.8095
A+C+D+E	0.988	0.231	0.458	0.582	0.6216	0.6152
B+C+D+E	0.963	0.25	0.487	0.557	0.836	0.4825
A+B+C+D+E	0.642	0.481	0.406	0.53	0.291	0.84

构建周至西农 059 最优模型时, 特征变量 NDWI, NDRE, CIRedEdge, CIGreen, MVI, WDRVI, NDVI, GNDVI, IPVI, SR, RVI, SIPI 为最关键特征, 在三个不同最优模型构建时, 都作为贡献度前二十特征出现。RI, NPCI, SRPI, MSRI, VARI, NGRDI, N, zhugao 作为次重要特征, 在两个最优模型构建时, 作为贡献度前二十特征出现。N 出现在最优 RF 和最优 SVR 中, 贡献度分别为 0.0092 和 0.0438; zhugao 出现在最优 SVR 和最优 RR 中, 贡献度分别为 0.0233 和 0.096; shui 出现在最优 RR 模型中, 贡献度为 0.079 (图 5-7, 图 5-8, 图 5-9)。




图 5-7 周至西农 059 最优 RF 的特征重要性

Fig. 5-7 The different importance of features in the optimal RF at Zhouzhi for Xinong 059




图 5-8 周至西农 059 最优 SVR 的特征重要性

Fig. 5-8 The different importance of features in the optimal SVR at Zhouzhi for Xinong 059




图 5-9 周至西农 059 最优 RR 的特征重要性

Fig. 5-9 The different importance of features in the optimal RR at Zhouzhi for Xinong 059

(4) 小麦品种“西农 511”

在周至试区，小麦品种“西农 511”基于多个生育期影像数据的产量模型决定系数（ R^2 ）、均方误差（MSE）如表 5-4 所示。

表 5-4 周至试区小麦品种“西农 511”基于多个生育期影像数据的
产量模型决定系数（ R^2 ）、均方误差（MSE）

Table 5-4 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for
Xinong 511 in the Zhouzhi Test Area Based on All Stage Data

生育期	RF		SVR		RR	
	MSE	R^2	MSE	R^2	MSE	R^2
A+B+C	0.03	0.984	0.206	0.791	0.1567	0.7822
A+B+D	0.29	0.652	0.179	0.818	0.1783	0.7706
A+B+E	0.152	0.818	0.198	0.8	0.3296	0.5651
A+C+D	0.315	0.622	0.614	0.378	0.3747	0.5056
A+C+E	0.282	0.662	0.655	0.337	0.5478	0.2771
A+D+E	0.347	0.583	0.567	0.426	1.0573	-0.3952
B+C+D	0.318	0.618	0.605	0.387	0.4824	0.3634
B+C+E	0.271	0.675	0.625	0.367	0.514	0.3217
B+D+E	0.235	0.718	0.495	0.498	0.3724	0.5085
C+D+E	0.603	0.277	0.327	0.668	0.2842	0.625
A+B+C+D	0.485	0.096	0.344	0.542	0.2516	0.7117
A+B+C+E	0.581	-0.083	0.209	0.721	0.3393	0.6112

生育期	RF		SVR		RR	
	MSE	R ²	MSE	R ²	MSE	R ²
A+B+D+E	0.541	-0.009	0.206	0.725	0.2854	0.6729
A+C+D+E	0.7	-0.306	0.38	0.494	0.476	0.456
B+C+D+E	0.651	-0.214	0.367	0.51	0.1519	0.8259
A+B+C+D+E	0.241	0.578	0.212	0.53	0.1867	0.8411

从表 5-4 可看出, 西农 511 (d) 多时期各最优模型分别为基于孕穗期, 抽穗期, 灌浆期(A+B+C)的 RF, 其中 $R^2=0.984$; 基于孕穗期, 抽穗期, 乳熟期(A+B+D)的 SVR, 其中 $R^2=0.818$; 基于孕穗期, 抽穗期, 灌浆期, 乳熟期, 成熟期(A+B+C+D+E)的 RR, 其中 $R^2=0.8411$ 。

构建周至西农 511 最优模型时, 特征变量 NDWI, CIRedEdge, SRPI, NDRE, GNDVI, CIGreen, MSRI 为最关键特征, 在三个不同最优模型构建时, 都作为贡献度前二十特征出现。RI, NPCI, SIPI, WDRVI, IPVI, NDVI, MVI, RVI, SR, VARI, NGRDI, GI 作为次重要特征, 在两个最优模型构建时, 作为贡献度前二十特征出现。N 出现在最优最优 SVR 中, 贡献度为 0.0248; shui 出现在最优 RR 模型中, 贡献度为 0.359, 为负相关 (图 5-10, 图 5-11, 图 5-12)。




图 5-10 周至西农 511 最优 RF 的特征重要性

Fig. 5-10 The different importance of features in the optimal RF at Zhouzhi for Xinong 511




图 5-11 周至西农 511 最优 SVR 的特征重要性

Fig. 5-11 The different importance of features in the optimal SVR at Zhouzhi for Xinong 511




图 5-12 周至西农 511 最优 RR 的特征重要性

Fig. 5-12 The different importance of features in the optimal RR at Zhouzhi for Xinong 511

(5) 4 个供试小麦品种

在周至试区, 4 个供试小麦品种基于多个生育期影像数据的产量模型决定系数(R^2)、均方误差 (MSE) 如表 5-5 所示。

表 5-5 周至试区 4 个供试小麦品种基于多个生育期影像数据的
产量模型决定系数 (R^2)、均方误差 (MSE)

Table 5-5 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for
All Varieties in the Zhouzhi Test Area Based on All Stage Data

生育期	RF		SVR		RR	
	MSE	R^2	MSE	R^2	MSE	R^2
A+B+C	0.31	0.857	0.318	0.812	0.3838	0.7899
A+B+D	0.476	0.78	0.402	0.762	0.378	0.7931
A+B+E	0.515	0.762	0.392	0.768	0.4693	0.743
A+C+D	0.438	0.816	0.386	0.792	0.3091	0.8588
A+C+E	0.32	0.865	0.374	0.799	0.0339	0.9432
A+D+E	0.408	0.828	0.44	0.763	0.3544	0.8382
B+C+D	0.733	0.661	0.462	0.727	0.5745	0.6855
B+C+E	0.63	0.723	0.448	0.717	0.7763	0.6581
B+D+E	0.465	0.717	0.512	0.694	0.6211	0.6918
C+D+E	0.593	0.726	0.493	0.708	0.3981	0.7821
A+B+C+D	0.279	0.86	0.348	0.807	0.6031	0.7579
A+B+C+E	0.331	0.833	0.339	0.812	0.6067	0.7565
A+B+D+E	0.658	0.67	0.437	0.757	0.8052	0.6768
A+C+D+E	0.428	0.785	0.302	0.832	0.591	0.7628
B+C+D+E	0.301	0.849	0.324	0.82	0.7076	0.716
A+B+C+D+E	0.261	0.876	0.384	0.802	0.3676	0.8132

由表 5-5 数据可知, 4 个供试品种作为一个整体的多生育期各最优模型分别为基于孕穗期, 抽穗期, 灌浆期, 乳熟期, 成熟期 (A+B+C+D+E) 的 RF, 其中 $R^2=0.876$; 基于孕穗期, 灌浆期, 乳熟期, 成熟期 (A+C+D+E) 的 SVR, 其中 $R^2=0.832$; 基于孕穗期, 灌浆期, 成熟期 (A+C+E) 的 RR, 其中 $R^2=0.9432$ 。

构建周至全品种最优模型时, 特征变量 NGBDI, CIRedEdge, SIPI, 为最关键特征, 在三个不同最优模型构建时, 都作为贡献度前二十特征出现。NDWI, shui, GNDVI, zhugao, TVI, EVI, VDVI, DVI, MVI, IPVI, RDVI, SAVI, RVI 作为次重要特征, 在两个最优模型构建时, 作为贡献度前二十特征出现。N 出现在最优 RF 中, 贡献度最高, 为 0.5186; zhugao 出现在最优 RF 和最优 SVR 中, 贡献度分别为 0.0114 和 0.0164; qiye 出现在最优 RF 模型中, 贡献度为 0.011; shui 出现在最优 RF 模型和最优 SVR 模型中, 贡献度分别为 0.0365 和 0.0388 (图 5-13, 图 5-14, 图 5-15)。




图 5-13 周至综合所有品种最优 RF 的特征重要性

Fig. 5-13 The different importance of features in the optimal RF at Zhouzhi for all varieties




图 5-14 周至综合所有品种最优 SVR 的特征重要性

Fig. 5-14 The different importance of features in the optimal SVR at Zhouzhi for all varieties




图 5-15 周至综合所有品种最优 RR 的特征重要性

Fig. 5-15 The different importance of features in the optimal RR at Zhouzhi for all varieties

5.2 基于扶风冬小麦多时期数据的产量模型构建

扶风地区的生育期划分标准和周至地区相同，且模型构建时的处理也都相同。计算扶风地区最优模型的决定系数（ R^2 ）和均方误差（MSE）值，并可视化最优模型中的各特征变量贡献度。

（1）小麦品种“小偃 22”

在扶风试区，“小偃 22” 基于多个生育期影像数据的产量模型决定系数(R^2)、均方误差（MSE）如表所示。

表 5-6 扶风试区小麦品种 “小偃 22”基于多个生育期影像数据的
产量模型决定系数（ R^2 ）、均方误差（MSE）

Table 5-6 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for Xiaoyan 22 in the Fufeng Test Area Based on All Stage Data						
生育期	RF		SVR		RR	
	MSE	R^2	MSE	R^2	MSE	R^2
A+B+C	0.043	0.352	0.056	0.652	0.0636	0.8348
A+B+D	0.015	0.773	0.093	0.419	0.0494	0.8716
A+B+E	0.065	0.023	0.167	-0.035	0.1552	0.5964
A+C+D	0.067	-0.009	0.119	0.261	0.0604	0.8428

生育期	RF		SVR		RR	
	MSE	R ²	MSE	R ²	MSE	R ²
A+C+E	0.067	-0.012	0.212	-0.318	0.1251	0.6747
A+D+E	0.052	0.218	0.301	-0.869	0.2399	0.3762
B+C+D	0.056	0.056	0.105	0.347	0.0514	0.8664
B+C+E	0.075	-0.129	0.186	-0.156	0.18	0.5319
B+D+E	0.2624	-0.1377	0.286	-0.755	0.2147	0.4418
C+D+E	0.11	-0.661	0.232	-0.443	0.1308	0.6599
A+B+C+D	0.088	-0.382	0.181	-0.206	0.0699	0.3881
A+B+C+E	0.093	-0.467	0.237	-0.587	0.0499	0.5638
A+B+D+E	0.096	-0.503	0.274	-0.83	0.0388	0.6605
A+C+D+E	0.114	-0.79	0.282	-0.881	0.0462	0.5962
B+C+D+E	0.104	-0.632	0.306	-1.039	0.0664	0.4193
A+B+C+D+E	0.146	0.278	0.095	0.545	0.2725	0.3583

表 5-6 显示, 小偃 22 (a) 多时期各最优模型分别为基于孕穗期, 抽穗期, 乳熟期 (A+B+D) 的 RF, 其中 $R^2=0.773$; 基于孕穗期, 抽穗期, 灌浆期 (A+B+C) 的 SVR, 其中 $R^2=0.652$; 基于孕穗期, 抽穗期, 乳熟期 (A+B+D) 的 RR, 其中 $R^2=0.8716$ 。

对于构建扶风小偃 22 最优模型, 特征变量 DVI, TVI, SAVI, QIYE, WDRVI, NDVI 为最关键特征, 在三个不同最优模型中, 都作为贡献度前二十特征出现。EVI, RI, NPCI, EXR, N, RDVI, NGBDI, zhugao, OSAVI, MVI, IPVI 作为次要特征, 在两个最优模型构建时, 作为贡献度前二十特征出现。N 出现在最优 RF 和最优 SVR 中, 贡献度分别为 0.429 和 0.1060; zhugao 出现在最优 SVR 和最优 RR 中, 贡献度分别为 0.0245 和 0.062 (负相关); shui 出现在最优 RR 模型中, 贡献度为 0.053 (负相关); qiye 出现 RF, SVR, RR 全部三个最优模型中, 贡献度分别为 0.0202, 0.0171 和 0.041 (负相关) (图 5-16, 图 5-17, 图 5-18)。




图 5-16 扶风小偃 22 最优 RF 的特征重要性

Fig5-16. The different importance of features in the optimal RF at Fufeng for Xiaoyan 22




图 5-17 扶风小偃 22 最优 SVR 的特征重要性

Fig. 5-17 The different importance of features in the optimal SVR at Fufeng for Xiaoyan 22




图 5-18 扶风小偃 22 最优 RR 的特征重要性

Fig. 5-18 The different importance of features in the optimal RR at Fufeng for Xiaoyan 22

(2) 小麦品种“伟隆 169”

在扶风试区,“伟隆 169”基于多个生育期影像数据的产量模型决定系数(R^2)、均方误差(MSE)如表 5-7 所示。

从表 5-7 可看出,品种伟隆 169(b)多时期各最优模型分别为基于灌浆期,乳熟期,成熟期(B+C+D)的 RF,其中 $R^2=0.519$; 基于孕穗期,抽穗期,乳熟期(A+B+D)的 SVR,其中 $R^2=0.878$; 基于孕穗期,灌浆期,乳熟期(A+C+D)

的 RR，其中 $R^2=0.7128$ 。

表 5-7 扶风试区小麦品种“伟隆 169”基于多个生育期影像数据的
产量模型决定系数 (R^2)、均方误差 (MSE)

Table 5-7 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for
Weilong 169 in the Fufeng Test Area Based on All Stage Data

生育期	RF		SVR		RR	
	MSE	R^2	MSE	R^2	MSE	R^2
A+B+C	0.328	0.058	0.082	0.794	0.5043	0.2594
A+B+D	0.257	0.262	0.048	0.878	0.5426	0.203
A+B+E	0.243	0.302	0.235	0.406	0.4612	0.3227
A+C+D	0.169	0.515	0.157	0.602	0.1962	0.7128
A+C+E	0.259	0.254	0.37	0.064	0.6768	0.006
A+D+E	0.27	0.223	0.537	-0.537	1.2015	-0.7647
B+C+D	0.167	0.519	0.3	0.241	0.2205	0.6762
B+C+E	0.343	0.015	0.575	-0.455	0.6715	0.0138
B+D+E	0.22	0.5708	0.608	-0.539	1.7876	-0.7442
C+D+E	0.11	-0.661	0.589	-0.409	0.6849	-0.006
A+B+C+D	0.349	0.401	0.309	-0.135	0.3086	0.0245
A+B+C+E	0.431	0.26	0.469	-0.723	0.4043	-0.278
A+B+D+E	0.412	0.292	0.504	-0.851	0.4827	-0.5259
A+C+D+E	0.293	0.497	0.535	-0.967	0.3469	-0.0966
B+C+D+E	0.362	0.377	0.754	-1.77	0.4974	-0.4777
A+B+C+D+E	0.338	0.287	0.377	0.177	0.8248	-0.4759




图 5-19 扶风伟隆 169 最优 RF 的特征重要性

Fig. 5-19 The different importance of features in the optimal RF at Fufeng for Weilong 169




图 5-20 扶风伟隆 169 最优 SVR 的特征重要性

Fig. 5-20 The different importance of features in the optimal SVR at Fufeng for Weilong 169




图 5-21 扶风伟隆 169 最优 RR 的特征重要性

Fig. 5-21 The different importance of features in the optimal RR at Fufeng for Weilong 169

对于构建扶风试区品种“伟隆 169”最优模型时，特征变量 EXGR，SAVI，RDVI，TVI，EVI，DVI，MCARI，MVI，OSAVI 为最关键特征，在三个不同最优模型构建时，都作为贡献度前二十特征出现。SRPI，RI，NPCI，N，zhugao，qiye，shui，GI，RVI，MSRI，WDRVI，NDVI，IPVI，EXR 作为次重要特征，

在两个最优模型构建时，作为贡献度前二十特征出现。N 出现在最优 RF 和最优 SVR 中，贡献度分别为 0.094 和 0.0302；zhugao 出现在最优 RF 和最优 RR 中，贡献度分别为 0.0578 和 0.062（负相关）；shui 出现在最优 RF 模型和 RR 模型中，贡献度为 0.0152 和 0.053（负相关）；qiye 出现最优 RF 和 RR 模型中，贡献度分别为 0.0376 和 0.041（负相关）（图 5-19，图 5-20，图 5-21）。

（3）品种“西农 059”

在扶风试区，“西农 059”基于多个生育期影像数据的产量模型决定系数(R^2)、均方误差 (MSE) 如表 5-8 所示。

表 5-8 扶风试区小麦品种“西农 059”基于多个生育期影像数据的
产量模型决定系数 (R^2)、均方误差 (MSE)

Table 5-8 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for

Xinong 059 in the Fufeng Test Area Based on All Stage Data

生育期	RF		SVR		RR	
	MSE	R^2	MSE	R^2	MSE	R^2
A+B+C	0.031	0.924	0.121	0.839	0.2558	0.5848
A+B+D	0.117	0.712	0.375	0.501	0.3587	0.4177
A+B+E	0.401	0.013	0.743	0.011	0.7484	-0.2148
A+C+D	0.084	0.793	0.32	0.574	0.2665	0.5673
A+C+E	0.446	-0.098	0.616	0.18	0.8046	-0.3061
A+D+E	0.257	0.367	0.689	0.082	0.502	0.1821
B+C+D	0.006	0.986	0.008	0.99	0.0615	0.9002
B+C+E	0.571	-0.405	0.429	0.429	0.5807	0.0575
B+D+E	0.6066	0.275	0.804	-0.071	0.5682	0.0777
C+D+E	0.357	0.122	0.678	0.097	0.4876	0.2086
A+B+C+D	0.025	0.967	0.336	0.59	0.0167	0.5699
A+B+C+E	0.251	0.666	1.03	-0.255	0.2129	-4.5381
A+B+D+E	0.202	0.732	1.092	-0.33	0.1788	-3.6507
A+C+D+E	0.175	0.768	0.995	-0.212	0.1725	-3.4858
B+C+D+E	0.432	0.424	0.838	-0.021	0.157	-3.0833
A+B+C+D+E	0.436	0.393	0.39	0.383	0.6662	0.1025

表 5-8 显示，西农 059 (c) 多时期各最优模型分别为基于抽穗期，灌浆期，乳熟期 (B+C+D) 的 RF，其中 $R^2=0.986$ ；基于抽穗期，灌浆期，乳熟期 (B+C+D) 的 SVR，其中 $R^2=0.99$ ；基于抽穗期，灌浆期，乳熟期 (B+C+D) 的 RR，其中 $R^2=0.9002$ 。

构建扶风西农 059 最优模型时，NDWI, NPCI, RI, RDVI, CIGreen, CIRedEdge, MCARI, NDVI, SAVI, MVI, EVI, IPVI 等 12 个特征变量作为最关键特征，在 3 个不同的最优模型中，都作为贡献度前二十特征出现。MSRI, SRPI, OSAVI,

GNDVI, NDRE, WDRVI 等 6 个特征变量作为次重要特征, 在 2 个最优模型构建中, 作为贡献度前二十特征出现。N 出现在最优 RF 中, 贡献度为 0.0285; qiye 出现最优 RF 中, 贡献度分别为 0.0314 (图 5-22, 图 5-23, 图 5-24)。




图 5-22 扶风西农 059 最优 RF 的特征重要性

Fig. 5-22 The different importance of features in the optimal RF at Fufeng for Xinong 059




图 5-23 扶风西农 059 最优 SVR 的特征重要性

Fig. 5-23 The different importance of features in the optimal SVR at Fufeng for Xinong 059




图 5-24 扶风西农 059 最优 RR 的特征重要性

Fig. 5-24 The different importance of features in the optimal RR at Fufeng for Xinong 059

(4) 品种“西农 511”

在扶风试区，小麦品种“西农 511”基于多个生育期影像数据的产量模型决定系数（ R^2 ）、均方误差（MSE）如表 5-9 所示。

表 5-9 扶风试区小麦品种“西农 511”基于多个生育期影像数据的
产量模型决定系数（ R^2 ）、均方误差（MSE）

Table 5-9 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for

Xinong 511 in the Fufeng Test Area Based on All Stage Data

生育期	RF		SVR		RR	
	MSE	R ²	MSE	R ²	MSE	R ²
A+B+C	0.172	0.588	0.269	0.522	0.0897	0.6895
A+B+D	0.225	0.462	0.315	0.441	0.0693	0.7601
A+B+E	0.404	0.035	0.449	0.202	0.1381	0.5221
A+C+D	0.207	0.506	0.328	0.417	0.0926	0.6795
A+C+E	0.376	0.102	0.461	0.182	0.0772	0.7328
A+D+E	0.257	0.387	0.56	0.005	0.0766	0.7349
B+C+D	0.13	0.691	0.178	0.684	0.071	0.7544
B+C+E	0.254	0.393	0.315	0.441	0.0463	0.8397

生育期	RF		SVR		RR	
	MSE	R ²	MSE	R ²	MSE	R ²
B+D+E	0.3007	0.3799	0.569	-0.01	0.1005	0.6521
C+D+E	0.158	0.624	0.499	0.115	0.1244	0.5697
A+B+C+D	0.196	0.74	0.385	0.462	0.1924	-0.3649
A+B+C+E	0.389	0.484	0.581	0.188	0.1737	-0.2323
A+B+D+E	0.396	0.475	0.597	0.165	0.1381	0.02
A+C+D+E	0.308	0.592	0.556	0.223	0.1727	-0.2249
B+C+D+E	0.168	0.778	0.396	0.446	0.0553	0.6076
A+B+C+D+E	0.292	0.541	0.324	0.445	0.1291	0.4356

从表 5-9 可看出, 西农 511 (d) 多时期各最优模型分别为基于孕穗期, 灌浆期, 乳熟期, 成熟期 (B+C+D+E) 的 RF, 其中 $R^2=0.778$; 基于孕穗期, 抽穗期, 灌浆期 (A+B+C) 的 SVR, 其中 $R^2=0.522$; 基于抽穗期, 灌浆期, 成熟期 (B+C+E) 的 RR, 其中 $R^2=0.8397$ 。

对于构建扶风西农 511 最优模型时, 特征变量 SIPI, CIGreen 为最关键特征, 在三个不同最优模型构建时, 都作为贡献度前二十特征出现。CIVE, N, CIRedEdge, EXG, NDRE, TCARI, MCARI, VDMI, zhugao, shui, NSWI, OSAVI, qiye, MVI, DVI, EXGR, RI, NPCI, SRPI, NGRDI 作为次重要特征, 在两个最优模型构建时, 作为贡献度前二十特征出现。N 出现在最优 RF 和最优 RR 中, 贡献度分别为 0.0848 和 0.18 (负相关); zhugao 出现在最优 RF 和最优 RR 中, 贡献度分别为 0.0427 和 0.159 (负相关); shui 出现在最优 RF 模型和 RR 模型中, 贡献度为 0.0208 和 0.145 (负相关); qiye 出现最优 RF 和 RR 模型中, 贡献度分别为 0.0177 和 0.035 (负相关) (图 5-25, 图 5-26, 图 5-27)。




图 5-25 扶风西农 511 最优 RF 的特征重要性

Fig. 5-25 The different importance of features in the optimal RF at Fufeng for Xinong 511




图 5-26 扶风西农 511 最优 SVR 的特征重要性

Fig. 5-26 The different importance of features in the optimal SVR at Fufeng for Xinong 511




图 5-27 扶风西农 511 最优 RR 的特征重要性

Fig. 5-27 The different importance of features in the optimal RR at Fufeng for Xinong 511

(5) 4 个供试品种

在扶风试区, 4 个小麦供试品种基于多个生育期影像数据的产量模型决定系数(R^2)、均方误差 (MSE) 如表所示。

表 5-10 显示, 4 个供试品种作为一个整体的多生育期各最优模型分别为基于孕穗期, 抽穗期, 灌浆期, 成熟期 (A+B+C+E) 的 RF, 其中 $R^2=0.854$; 基于孕穗期, 抽穗期, 灌浆期 (A+B+C) 的 SVR, 其中 $R^2=0.649$; 基于孕穗期, 抽穗

期，乳熟期（A+B+D）的 RR，其中 $R^2=0.6149$ 。

表 5-10 扶风试区 4 个供试小麦品种基于多个生育期影像数据的
产量模型决定系数（ R^2 ）、均方误差（MSE）

Table 5-10 Coefficient of Determination (R^2) and Mean Squared Error (MSE) of Yield Models for
All Varieties in the Fufeng Test Area Based on All Stage Data

生育期	RF		SVR		RR	
	MSE	R^2	MSE	R^2	MSE	R^2
A+B+C	0.162	0.713	0.222	0.649	0.2077	0.4937
A+B+D	0.146	0.742	0.241	0.62	0.158	0.6149
A+B+E	0.176	0.688	0.295	0.534	0.215	0.4759
A+C+D	0.208	0.633	0.25	0.606	0.1949	0.5251
A+C+E	0.241	0.575	0.288	0.545	0.2709	0.3396
A+D+E	0.261	0.538	0.278	0.561	0.3126	0.238
B+C+D	0.224	0.604	0.224	0.647	0.2105	0.4869
B+C+E	0.322	0.431	0.297	0.531	0.2702	0.3413
B+D+E	0.2149	0.5774	0.293	0.398	0.2569	0.3949
C+D+E	0.203	0.641	0.281	0.557	0.2519	0.3859
A+B+C+D	0.147	0.754	0.248	0.558	0.1676	0.4753
A+B+C+E	0.086	0.854	0.361	0.358	0.1529	0.5121
A+B+D+E	0.16	0.731	0.385	0.316	0.174	0.4555
A+C+D+E	0.21	0.647	0.387	0.312	0.1934	0.3947
B+C+D+E	0.224	0.625	0.408	0.275	0.1376	0.5692
A+B+C+D+E	0.234	0.65	0.246	0.482	0.2188	0.5828

对于构建扶风全品种综合最优模型时，特征变量 CIRedEdge, SIPI, NDRE 为最关键特征，在三个不同最优模型构建时，都作为贡献度前二十特征出现。NDWI, MCARI, N, zhugao, GNDVI, CIGreen, shui, SRPI, VDMI, NPCI, RI, EXR, qiye, WDRVI, NDVI, IPVI, RVI, OSAVI 作为次重要特征，在两个最优模型构建时，作为贡献度前二十特征出现。N 出现在最优 RF 和最优 SVR 中，贡献度分别为 0.07 和 0.049；zhugao 出现在最优 RF 和最优 SVR 中，贡献度分别为 0.057 和 0.0618（负相关）；shui 出现在最优 RF 模型和 SVR 模型中，贡献度为 0.0392 和 0.0172；qiye 出现最优 RF 和 SVR 模型中，贡献度分别为 0.0202 和 0.0242（图 5-28，图 5-29，图 5-30）。




图 5-28 扶风所有品种综合最优 RF 的特征重要性

Fig. 5-28 The different importance of features in the optimal RF at Fufeng for all varieties




图 5-29 扶风所有品种综合最优 SVR 的特征重要性

Fig. 5-29 The different importance of features in the optimal SVR at Fufeng for all varieties




图 5-30 扶风所有品种综合最优 RR 的特征重要性

Fig. 5-30 The different importance of features in the optimal RR at Fufeng for all varieties

5.3 讨论

5.3.1 多源数据特征变量对模型精度的影响

随着机器模型和遥感技术的应用,如何更高效,准确的获取小麦产量成为众多学者的研究方向。而对于训练模型数据源的更新迭代进一步推进了精准农业的发展,多数据源融合成为提升模型精度的有效研究方向。陈一凡等(2024)为探究多数据源对于冬小麦估产预测可行性,研究了河南省冬小麦 28 个不同时间窗,使用 8 种不同机器学习方法,利用 2003 至 2018 年多种遥感数据、气象数据进行模型训练和预测。结果显示,引入日光诱导叶绿素荧光(solar-induced chlorophyll fluorescence, SIF)特征可以提升预测效果。邵洋琳等(2024)提出了一种综合利用多数据源的冬小麦估产模型,该模型考虑到地理环境和气象信息,例如土地覆盖类型,降水等结合时间序列数据来提升预测精度。实验结果表明,该模型相比于其他典型机器学习模型都有更好的预测精度和性能。王旭等(2023)利用 2001 至 2018 年国内多个省份的遥感数据、气象数据构建了一种基于长短期记忆的估产模型,并于传统模型做对比,结果显示在单一特征的基础上增加特征数量可以提高估产的准确性,而同时使用气象数据、多段反射率和植被指数时,估产准确性最高($R^2=0.866$)。总之,气象因子既是模型的关键输入,也是噪声来源,需通过多源数据融合混合建模平衡其贡献。

上述结论在本研究中也得到了证实。本试验结果表明气象因子通过直接调控作物生理过程间接影响光谱特征，是模型精度提升的关键修正方式。本研究通过对周至扶风两地的最优模型特征变量贡献度分析可知，N, shui, qiye, zhugao 这四个非植被指数特征变量出现在最优模型高贡献度的概率高达 73.33%，说明在构建周至扶风地区冬小麦估产模型时，多数据源融合对模型的影响已经不容忽视。

5.3.2 不同生育期组合对模型构建的影响

除了融合多数据源的方法之外，许多学者也将不同生育期进行组合，来测试模型精度的提升与否。王晶晶等（2022）采集了冬小麦生长的八个阶段，利用偏最小二乘法，随机森林和套索算法建立单时期和多时期的小麦估产模型，结果显示小麦多生育期的产量估算明显优于单生育时期。韩文霆等（2020）以内蒙古自治区种植的夏玉米为研究对象，构建基于多种植被指数和多种生育期的夏玉米产量预测模型，结果显示，不同生育期的玉米估产模型精度差异显著。单一生育期的估产精度明显低于多生育期的估产精度。刘钰（2023）利用 Sentinel-2 卫星图像对河南省冬小麦产量进行估测，采用偏最小二乘回归、反向传播神经网络、随机森林和支持向量回归构建冬小麦叶面积指数估算模型，在此基础上，构建一个具有多生长阶段的作物产量预测模型。结果说明对于单一生长期而言，产量估算模型使用多生育期的数据能够更好地反应有机质的积累，从而对产量估测有更高的精度。

上述结论在本试验中也得到了证实。通过小麦产量估测模型精度结果可知，本章所选用的三类模型在结合了生育期信息后，基于多时期数据的模型精度均高于单一时期的模型精度，同时，在结合不同生育期时，并不是选用的时期越多越好，根据多时期结果可知，数据分布于孕穗期（A），抽穗期（B），灌浆期（C）的模型精度普遍较高。模型最高精度时包含孕穗期（A）概率为 80%，包含抽穗期（B）概率为 86.67%，包含灌浆期（C）概率为 70%，包含乳熟期（D）概率为 60%，包含成熟期（E）概率为 26.67%。上述结果也都说明了基于多生育期数据的机器学习模型优于基于单时期数据的机器模型，且选择多时期数据时，包含孕穗期，抽穗期，灌浆期数据的拟合效果较好。

5.4 小结

本章聚焦于多生育期数据融合对冬小麦产量估测模型的优化效果，系统比较了不同生育期组合与机器学习算法的协同效应，揭示了多源时序数据在提升模型精度与解释力中的核心作用，主要结论如下：

（1）在周至扶风地区，本试验中收集的非植被指数特征变量在构建各品种的基于多时期数据的最佳估产模型时，发挥着关键作用。非植被指数特征出现在

最优模型高贡献度的概率高达 73.33%。

(2) 多时期数据显著提升模型性能

无论周至还是扶风地区,融合孕穗期、抽穗期、灌浆期等关键生育期数据后,模型预测精度显著优于单时期模型。周至地区各品种基于多时期数据的最优模型 R^2 分别为:小偃 22 (0.977)、伟隆 169 (0.99)、西农 059 (0.965)、西农 511 (0.984) 和全供试品种 (0.9432)。扶风地区各品种基于多时期数据的最优模型 R^2 分别为:小偃 22 (0.8716)、伟隆 169 (0.878)、西农 059 (0.99)、西农 511 (0.8397) 和全供试品种 (0.854)。

第六章 结论

6.1 结论

作物产量反演是精准农业与数字农业发展的核心技术,对保障粮食安全、优化资源利用及实现可持续农业发展具有重要意义。本研究以冬小麦为研究对象,融合多源遥感数据与机器学习算法,重点解析多光谱植被指数、作物表型参数及气象因子对产量形成的协同影响。试验采用大疆经纬 M300 四旋翼无人机平台搭载 RedEdge-MX 多光谱传感器,于 2023-2024 年度在周至县马篷村和宝鸡市东西湾村,提取小偃 22、伟隆 169、西农 059、西农 511 四个品种孕穗期(冠层快速扩展)、抽穗期、灌浆期、乳熟期及成熟期的高分辨率冠层多光谱影像。配合田间标准化测产方法,获取实测产量数据,构建基于时序多光谱特征与农艺参数的产量估测模型,为关中地区小麦估产系统开发提供理论依据和技术支撑。获得结论如下:

(1) 周至扶风两地 4 个不同品种的最优估产机器模型不尽相同。如周至地区小偃 22 的最优估产模型为利用灌浆期数据的岭回归模型($R^2=0.964$)模型,而扶风地区小偃 22 的最优估产模型为利用孕穗期数据的随机森林($R^2=0.612$)模型。这种情况在构建两个不同地区的所有品种的最优模型时均有出现。表明环境因素对估产模型的模拟存在较大影响,即使相同品种相同处理的小麦,在环境因素差异过大时,估产模型的参数也需要进一步调整。

(2) 对周至扶风两地的 4 个不同品种小麦单独处理数据和综合整体数据构建估产模型时,多时期估产模型精度总体高于单时期估产模型精度。例如周至地区小偃 22 的最优估产模型为利用孕穗期,抽穗期,灌浆期数据的随机森林模型($R^2=0.977$),扶风地区小偃 22 的最优估产模型为利用孕穗期,抽穗期,乳熟期数据的岭回归($R^2=0.8716$)模型。且多时期综合建立最优模型时,孕穗期,抽穗期和灌浆期的数据贡献程度最大,出现在数据集中的概率最高。

(3) 利用植被指数进行小麦估产时,部分作物表型特征和气象因子对最终结果有决定性的影响,如,株高、旗叶面积、土壤含水量及土壤含氮量等非植被指数特征成为高贡献度特征的概率高达 73.33%,这类特征在构建模型时不应被忽略。

6.2 创新点

(1) 创新性的将作物表型参数作为特征变量与常用的植被指数和气象数据

融合，提高模型精度的同时，通过最优模型中参数重要性分析说明作物表型对最优模型的构建发挥着举足轻重的作用。

（2）对四个不同品种，建立与之相对的最优估产模型，并与不区分小麦品种的整体最优估产模型进行对比。说明建立最优估产模型时，区分品种可明显提高模型精度。

第七章 展望

随着无人机遥感技术、机器学习算法与农业大数据的深度融合，冬小麦产量估测研究已取得显著进展。然而，面对气候变化加剧、资源约束趋紧及粮食安全需求提升的全球性挑战，未来研究仍需在多维度技术革新与应用拓展中寻求突破。基于本研究的成果与局限性，未来可重点围绕以下方向展开探索：

（1）算法与模型的双向驱动

当前机器学习模型虽能捕捉数据间的非线性关系，但缺乏对作物生理生态机制的显式表达，导致模型可解释性不足且跨区域泛化能力受限。未来需构建“数据-机理”混合驱动模型，例如将深度学习与作物生长模型（如 WOFOST、APSIM）动态耦合，通过同化无人机多光谱数据实时校准模型参数。同时，可引入图神经网络（GNN），量化品种遗传特性与环境胁迫的协同效应。此外，强化小麦在跨品种、跨区域估产时的稳定性，减少模型对特殊情况数据的依赖，提升其适应性也是必不可少的一环。

（2）多模态数据融合与边缘计算

现有研究主要依赖无人机光谱与气象数据，未来可进一步整合多源数据以增强特征表征能力。例如，利用热红外传感器监测冠层温度动态，结合叶绿素荧光数据量化光合效率；引入激光雷达（LiDAR）提取三维株型结构参数，弥补二维光谱信息对垂直冠层异质性捕捉的不足。此外，实现无人机端实时数据处理与产量预测，减少数据传输延迟，满足田间即时决策需求。通过构建一体化监测网络，协同卫星遥感的大范围覆盖与无人机的高分辨率优势，实现小麦产量多尺度精准反演。

（3）气候变化适应性与风险管理

全球变暖背景下，极端气候事件对小麦生产的威胁日益凸显。未来研究需强化气候情景模拟与产量预测的分析，例如利用气候模式数据驱动机器学习模型，评估干旱、高温等胁迫对小麦不同生育期的累积影响。同时，可开发虚拟农田系统，模拟不同管理措施（如调整播期、优化灌溉）在气候波动下的产量响应，为适应性种植策略提供量化依据。

（4）普惠化技术与农艺服务创新

当前技术应用多集中于科研场景，亟需推动成果向田间实践转化。一方面，开发低成本的轻便型无人机与开源算法库，降低中小农户的技术使用门槛；另一方面，构建智慧农业平台，集成产量预测、水肥推荐与病虫害诊断功能，通过移动终端为农民提供个性化农艺服务。

总之,冬小麦产量估测研究正从单一技术突破迈向系统化创新。未来需以“精准化、智能化、可持续化”为目标,深度融合前沿技术与农艺知识,构建覆盖“监测-预测-决策-服务”全链条的智慧农业解决方案,为全球粮食安全提供核心支撑。

参考文献

- 陈鹏飞, 杨飞, 杜佳. 2013. 基于环境减灾卫星时序归一化植被指数的冬小麦产量估测[J]. 农业工程学报, 29(11): 124-131.
- 陈一凡, 李璇, 王绍雯. 2024. 集成学习结合多源数据预测河南省冬小麦单产[J]. 农业工程学报, 40(4): 177-185.
- 傅兆麟, 马宝珍, 王光杰, 赵玉华, 李广科. 2001. 小麦旗叶与穗粒重关系的研究[J]. 麦类作物学报, 21(1): 92-94.
- 华启龙. 基于机器学习的冬小麦产量估测模型研究[D]. 西北农林科技大学, 2023. DOI:10.27409/d.cnki.gxbnu.2023.001861.
- 韩文霆, 彭星硕, 张立元, 牛亚晓. 2020. 基于多时相无人机遥感植被指数的夏玉米产量估算[J]. 农业机械学报, 51(1): 148-155.
- 韩文霆, 汤建栋, 张立元, 牛亚晓, 王彤华. 2021. 基于无人机遥感的玉米水分利用效率与生物量监测[J]. 农业机械学报, 52(5): 129-141.
- 侯学会, 牛铮, 黄妮, 许时光. 2012. 小麦生物量和真实叶面积指数的高光谱遥感估算模型[J]. 国土资源遥感, (4): 30-35.
- 侯英雨, 王石立. 2002. 基于作物植被指数和温度的产量估算模型研究[J]. 地理学与国土研究, 18(3): 105-107.
- 李军玲, 郭其乐, 彭记永. 2012. 基于 MODIS 数据的河南省冬小麦产量遥感估算模型[J]. 生态环境学报, 21(10): 1665-1669.
- 李旭然, 丁晓红. 2019. 机器学习的五大类别及其主要算法综述[J]. 软件导刊, 18(07): 4-9.
- 李远斌, 卜祥峰, 丁云鸿, 刘靖宇. 2023. 小麦产量预测模型综述[J]. 智慧农业导刊, 3(05): 13-19.
- 刘钰. 2023. 基于 Sentinel-2 多时相遥感影像的冬小麦区域产量估算[D]. 山西: 山西师范大学.
- 孟令华, 张新乐, 刘焕军, 郭栋, 宗杰贝. 2016. 基于 NDVI-NDWI 植被指数的棉花灌溉信息提取[C]. 第二十届中国遥感大会论文集, 75-75.
- 邵洋琳. 2024. 基于多源数据融合的区域冬小麦产量预测及时空特征分析[D]. 湖北: 湖北工业大学.
- 唐建民, 廖钦洪, 刘奕清, 杨贵军, 冯海宽, 王纪华. 2015. 基于 CASI 高光谱数据的作物叶面积指数估算[J]. 光谱学与光谱分析, 35(5): 1351-1356.
- 陶惠林, 冯海宽, 杨贵军, 杨小冬, 苗梦珂, 吴智超, 翟丽婷. 2019. 基于无人机数码影像和高光谱数据的冬小麦产量估算对比[J]. 农业工程学报, 35(23): 111-118.
- 万余庆, 谭克龙, 周日平. 2006. 高光谱遥感应用研究[M]. 北京: 科学出版社.
- 王晶晶, 李长硕, 卓越, 檀海斌, 侯永胜, 严海军. 2022. 基于多时相无人机遥感生育时期优选的冬小麦估产[J]. 农业机械学报, 53(9): 197-206.
- 王旭, 刘波, 陈正超. 2023. 基于多源数据和 LSTM 模型的县域冬小麦估产[J]. 农业现代化研究, 44(6): 1117-1126.

- 王雪, 常志州, 张恒敢, 王效华. 2015. 基于 MODIS 和天地图遥感数据的区域作物秸秆产量估算方法[J]. 农业工程学报, 31(19): 177-182.
- 闫岩, 柳钦火, 刘强, 李静, 陈良富. 2006. 基于遥感数据与作物生长模型同化的冬小麦长势监测与估产方法研究[J]. 遥感学报, 010(005): 804-811.
- 杨楠, 周萌, 陈欢, 曹承富, 杜世州, 黄正来. 2023. 基于无人机 RGB 影像的小麦叶面积指数与产量估算研究[J]. 麦类作物学报, 43(7): 920-932.
- 赵春江. 2014. 农业遥感研究与应用进展[J]. 农业机械学报, 12: 277-293.
- 赵泽阳, 李美玲, 徐伟, 等. 基于无人机多时相多特征的冬小麦产量预测模型研究[J/OL]. 麦类作物学报, 1-12[2025-03-19].
- 郑阳, 吴炳方, 张淼. 2017. Sentinel-2 数据的冬小麦地上干生物量估算及评价[J]. 遥感学报, (21): 318-328.
- 朱婉雪, 李仕冀, 张旭博, 李洋, 孙志刚. 2018. 基于无人机遥感植被指数优选的田块尺度冬小麦估产[J]. 农业工程学报, 34(11): 78-86.
- Bendig J, Yu K, Aasen H, Bolten A, Bennertz S, Broscheit J, Gnyp ML, Bareth G. 2015. Combining UAV-based plant height from crop surface models, visible, and near-infrared vegetation indices for biomass monitoring in barley[J]. *International Journal of Applied Earth Observation and Geoinformation*, 39: 79-87.
- Bian C, Shi H, Wu S, Zhang K, Wei M, Zhao Y, Sun Y, Zhuang H, Zhang X, Chen S. 2022. Prediction of Field-Scale Wheat Yield Using Machine Learning Method and Multi-Spectral UAV Data[J]. *Remote Sensing*, 14, 1474.
- Boegh E, Sogaard H, Broge N, Hasager C, Jensen N, Schelde K, Thomsen A. 2002. Airborne multispectral data for quantifying leaf area index, nitrogen concentration, and photosynthetic efficiency in agriculture[J]. *Remote sensing of Environment*, 81(2-3): 179-193.
- Broge N, Leblanc E. 2001. Comparing prediction power and stability of broadband and hyperspectral vegetation indices for estimation of green leaf area index and canopy chlorophyll density[J]. *Remote sensing of environment*, 76(2): 156-172.
- Camenzind M, Yu K. 2023. Multi temporal multispectral UAV remote sensing allows for yield assessment across European wheat varieties already in tillering stage[J]. *Frontiers in Plant Science*, 14, 1214931;
- Crippen R. 1990. Calculating the vegetation index faster[J]. *Remote sensing of Environment*, 34(1): 71-73.
- Dash J, Curran P. 2004. MTCI: the MERIS terrestrial chlorophyll index[J]. *International Journal of Remote Sensing*, 25(23): 10-13.
- Daughtry C, Walthall C, Kim M, Colstoun E, McMurtry III J. 2000. Estimating corn leaf chlorophyll concentration from leaf and canopy reflectance[J]. *Remote sensing of Environment*, 74(2): 229-239.
- Doughty C, Cavanaugh K. 2019. Mapping coastal wetland biomass from high resolution unmanned aerial vehicle (UAV) imagery[J]. *Remote Sensing*, 11: 540.
- Dong T, Liu J, Qian B, Zhao T, Shang J. 2016. Estimating winter wheat biomass by assimilating

- leaf area index derived from fusion of Landsat-8 and MODIS data[J]. *International Journal of Applied Earth Observation and Geoinformation*, 49: 63-74.
- Fei S, Hassan M, Xiao Y, Su X, Chen Z, Cheng Q, Duan F, Chen R, Ma Y. 2023. UAV-based multi-sensor data fusion and machine learning algorithm for yield prediction in wheat[J]. *Precision Agriculture*, 24, 187-212
- Feng H, Tao H, Fan Y, Liu Y, Li Z, Yang G, Zhao C. 2022. Comparison of Winter Wheat Yield Estimation Based on Near-Surface Hyperspectral and UAV Hyperspectral Remote Sensing Data[J]. *Remote Sensing*, 14(17), 4158.
- Fitzgerald G, Rodriguez D, Christensen L, Belford R, Sadras V O, Clarke T R. 2006. Spectral and thermal sensing for nitrogen and water status in rainfed and irrigated wheat environments[J]. *Precision Agriculture*, 7: 233-248.
- Fu Y, Yang G, Wang J, Song X, Feng H. 2014. Winter wheat biomass estimation based on spectral indices, band depth analysis and partial least squares regression using hyperspectral measurements[J]. *Computers and Electronics in Agriculture*, 100: 51-59.
- Fu Z, Jiang J, Gao Y, Krienke B, Wang M, Zhong K, Cao Q, Tian Y, Zhu Y, Cao W, Tian Y, Zhu Y, Cao W, Liu X. 2020. Wheat Growth Monitoring and Yield Estimation based on Multi-Rotor Unmanned Aerial Vehicle[J]. *Remote Sensing*, 12: 508.
- Ghamkhar K, Irie K, Hagedorn M, Hsiao J, Fourie J, Gebbie S, Hoyos-Villegas V, George R, Stewart A, Inch C, Werner A, Barrett B. 2019. Real-time, non-destructive and in-field foliage yield and growth rate measurement in perennial ryegrass (*Lolium perenne* L.) [J]. *Plant Methods*, 15: 72.
- Gitelson A, Gritz Y, Merzlyak M. 2003. Relationships between leaf chlorophyll content and spectral reflectance and algorithms for non-destructive chlorophyll assessment in higher plant leaves[J]. *Journal of Plant Physiology*, 160: 271-282.
- Gitelson A, Kaufman Y, Stark R, Rundquist D. 2002. Novel algorithms for remote estimation of vegetation fraction[J]. *Remote Sensing of Environment*, 80: 76-87.
- Gitelson A, Stark R, Grits U, Rundquist D, Kaufman Y, Derry D. 2002. Vegetation and soil lines in visible spectral space: a concept and technique for remote estimation of vegetation fraction[J]. *International Journal of Remote Sensing*, 23(13): 2537-2562.
- Gupta S, Pandey A. 2021. Spectral aspects for monitoring forest health in extreme season using multispectral imagery. *The Egyptian Journal of Remote Sensing and Space Science*, 24(3), 579-586.
- Hatfield J, Prueger J. 2010. Value of using different vegetative indices to quantify agricultural crop characteristics at different growth stages under varying management practices. *Remote Sensing*, 2(2), 562-578.
- Huete A. 1988. A soil-adjusted vegetation index (SAVI)[J]. *Remote Sensing of Environment*, 25:295-309
- Huete A, Didan K, Miura T, Rodriguez E, Gao X, Ferreira L, Huete A. 2002. Overview of the radiometric and biophysical performance of the MODIS vegetation indices[J]. *Remote sensing of environment*, 83(1-2): 195-213.
- Hunt E, Cavigelli M, Daughtry C, McMurtrey J, Walthall C. 2005. Evaluation of digital photography

- from model aircraft for remote sensing of crop biomass and nitrogen status[J]. *Precision Agriculture*, 6(4): 359-378.
- Jimenez-Berni J, Deery D, Rozas-Larraondo P, Condon A, Rebetzke G, James R, Bovill W, Furbank R, Sirault X. 2018. High throughput determination of plant height, ground cover, and above-ground biomass in wheat with LiDAR[J]. *Frontiers in Plant Science*, 9: 237.
- Kanke Y, Tubana B, Dalen M, Harrell D. 2016. Evaluation of red and red-edge reflectance-based vegetation indices for rice biomass and grain yield prediction models in paddy fields[J]. *Precision Agriculture*, 17(5) 507-530.
- Kataoka T, Kaneko T, Okamoto H, Hata S. 2003. Crop Growth Estimation System Using Machine Vision[C]. In Proceedings of the 2003 IEEE/ASME International Conference on Advanced Intelligent Mechatronics (AIM 2003), 2(b1079–b1083).
- Kaufman Y. J, Tanre D. 1992. Atmospherically resistant vegetation index (ARVI) for EOS MODIS[J]. *IEEE transactions on Geoscience and Remote Sensing*, 30(2): 261-270.
- Kyrtatzis A, Skarlatos D, Menexes G, Vamvakousis V, Katsiotis A. 2017. Assessment of Vegetation Indices Derived by UAV Imagery for Durum Wheat Phenotyping under a Water Limited and Heat Stressed Mediterranean Environment[J]. *Frontiers in Plant Science*, 2017, 8.
- Li B, Xu X, Zhang L, Han J, Bian C, Li G, Liu J, Jin L. 2020. Above-ground biomass estimation and yield prediction in potato by using UAV-based RGB and hyperspectral imaging[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 162: 161-172.
- Lu H, Fan T, Ghimire P, Deng L. 2020. Experimental Evaluation and Consistency Comparison of UAV Multispectral Minisensors[J]. *Remote Sensing*, 12(16):2542.
- Jordan C. 1969. Derivation of leaf-area index from quality of light on the forest floor[J]. *Ecology*, 50: 663-666.
- Ma Y, Wang S, Zhang L, Hou Y, Zhuang L, He Y, Wang F. 2008. Monitoring winter wheat growth in North China by combining a crop model and remote sensing data[J]. *International Journal of Applied Earth Observation and Geoinformation*, 10: 426-437.
- Mao W, Wang Y, Wang Y. 2003. Real-time detection of between-row weeds using machine vision[C]. In Proceedings of the 2003 ASAE Annual Meeting, Las Vegas, 1.
- Maimaitijiang M, Sagan V, Sidike P, Hartling S, Esposito F, Fritschi F. 2020. Soybean yield prediction from UAV using multimodal data fusion and deep learning[J]. *Remote Sensing Environment*, 237, 111599.
- Major D, Baret F, Guyot G. 1990. A ratio vegetation index adjusted for soil brightness[J]. *International Journal of Remote Sensing*, 11(5): 727-740.
- Mcfeeters S. 1996. The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features[J]. *International journal of remote sensing*, 17(7): 1425-1432.
- Meyer G, Hindman T, Laksmi K. 1999. Machine vision detection parameters for plant species identification[J]. *Proceedings of SPIE - The International Society for Optical Engineering*, 3543.
- Mutanga O, Skidmore A. 2004. Narrow band vegetation indices overcome the saturation problem

- in biomass estimation[J]. *International Journal of Remote Sensing*, 25: 3999-4014.
- Navarro J, Algeet N, Fernández-Landa A, Esteban J, Rodríguez-Noriega P, Guillén-Climent M. 2019. Integration of UAV, Sentinel-1, and Sentinel-2 data for mangrove plantation aboveground biomass monitoring in Senegal[J]. *Remote Sensing*, 11: 77.
- Neto J. 2004. A Combined Statistical-Soft Computing Approach for Classification and Mapping Weed Species in Minimum-Tillage Systems[D]. Lincoln, NE, USA, University of Nebraska.
- Peñuelas J, Frederic B, Filella I. 1995. Semi-Empirical indices to assess carotenoids/chlorophyll-a ratio from leaf spectral reflectance[J]. *Photosynthetica*, 31: 221-230.
- Peñuelas J, Gamon J, Fredeen A, Merino J, Field C. 1994. Reflectance indices associated with physiological changes in nitrogen- and water-limited sunflower leaves[J]. *Remote Sensing of Environment*, 48: 135-146.
- Potter C, Randerson J, Field C, Matson P, Vitousek P, Mooney H, Klooster S. 1993. Terrestrial ecosystem production: A process model based on global satellite and surface data[J]. *Global Biogeochemical Cycles*, 7: 811-841.
- Qi J, Chehbouni A, Huete A, Kerr Y, Sorooshian S. 1994. A modified soil adjusted vegetation index[J]. *Remote sensing of environment*, 48(2): 119-126.
- Rondeaux G, Steven M, Baret F. 1996. Optimization of soil-adjusted vegetation indices[J]. *Remote sensing of environment*, 55(2): 95-107.
- Roujean J, Breon F. 1995. Estimating PAR absorbed by vegetation from bidirectional reflectance measurements[J]. *Remote Sensing of Environment*, 51(3): 375-384.
- Rouse J, Haas R, Schell J, Deering D. 1973. Monitoring vegetation systems in the Great Plains with ERTS[C]. In: Proceedings 3rd Earth Resources Technology Satellite (ERTS) symposium, 1: 309-317. Washington, DC, USA: NASA SP-351, NASA.
- Sahameh S, Tomasz M, Ingunn B, Morten L. 2023. Evaluation of UAV multispectral cameras for yield and biomass prediction in wheat under different sun elevation angles and phenological stages[J]. *Computers and Electronics in Agriculture*, 210: 107874.
- Sahameh S, Lars M, Burud I, Dieseth J, Alsheikh M, Lillemo M. 2021. Sequential forward selection and support vector regression in comparison to LASSO regression for spring wheat yield prediction based on UAV imagery[J]. *Computers and Electronics in Agriculture*, 183: 106036.
- Salazar L, Kogan F, Roytman L. 2007. Use of remote sensing data for estimation of winter wheat yield in the United States[J]. *International Journal of Remote Sensing*, 28(17-18): 3795-3811.
- Serrano L, Filella I, Peuelas J. 2000. Remote Sensing of Biomass and Yield of Winter Wheat under Different Nitrogen Supplies[J]. *Crop Science*, 40: 723-731.
- Shen Y, Mercatoris B, Cao Z, Kwan P, Guo L, Yao H, Cheng Q. 2022. Improving Wheat Yield Prediction Accuracy Using LSTM-RF Framework Based on UAV Thermal Infrared and Multispectral Imagery[J]. *Agriculture*, 12: 892.
- Shibayama M, Akiyama T. 1991. Estimating grain yield of maturing rice canopies using high spectral resolution reflectance measurements[J]. *Remote Sensing of Environment*, 36(1): 45-53.
- Shimada S, Matsumoto J, Sekiyama A, Aosier B, Yokohana M. 2012. A new spectral index to detect Poaceae grass abundance in Mongolian grasslands[J]. *Advances in Space Research*, 50(9):

- 1266-1273.
- Shu M, Wang Z, Guo W, Qiao H, Fu Y, Guo Y, Wang L, Ma Y, Gu X. 2024. Effects of Variety and Growth Stage on UAV Multispectral Estimation of Plant Nitrogen Content of Winter Wheat[J]. *Agriculture*, 14(10): 1775.
- Song Y, Wang J, Shang J, Liao C. 2020. Using UAV-Based SOPC Derived LAI and SAFY Model for Biomass and Yield Estimation of Winter Wheat[J]. *Remote Sensing*, 12(15): 2378.
- Tao H, Feng H, Xu L, Miao M, Yang G, Yang X, Fan L. 2020. Estimation of the Yield and Plant Height of Winter Wheat Using UAV-Based Hyperspectral Images[J]. *Sensors*, 20(4): 1231.
- Testa S, Soudani K, Boschetti L, Borgogno E. 2018. MODIS-derived EVI, NDVI and WDRVI time series to estimate phenological metrics in French deciduous forests[J]. *International Journal of Applied Earth Observation and Geoinformation*, 64, 132-144.
- Tian Z, Zhang Y, Liu K, Li Z, Li M, Zhang H, Wu J. 2022. UAV Remote Sensing Prediction Method of Winter Wheat Yield Based on the Fused Features of Crop and Soil[J]. *Remote Sensing*, 14(19): 5054.
- Tucker C. 1979. Red and photographic infrared linear combinations for monitoring vegetation[J]. *Remote Sensing of Environment*, 8: 127-150.
- Vogelmann J, Rock B, Moss D. 1993. Red edge spectral measurements from sugar maple leaves[J]. *Remote Sensing*, 14(8): 1563-1575.
- Woebbecke D, Meyer G, Barga K, Mortensen D. 1995. Color indices for weed identification under various soil, residue, and lighting conditions[J]. *Transactions of the ASAE*, 38: 259-269.
- Yang G, Liu J, Zhao C, Li Z, Huang Y, Yu H, Xu B, Yang X, Zhu D, Zhang X, Zhang R, Feng H, Zhao X, Li Z, Li H, Yang H. 2017. Unmanned aerial vehicle remote sensing for field-based crop phenotyping: current status and perspectives[J]. *Frontiers in Plant Science*, 8.
- Yang S, Hu L, Wu H, Ren H. 2021. Integration of Crop Growth Model and Random Forest for Winter Wheat Yield Estimation from UAV Hyperspectral Imagery[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 3089203.
- Yue J, Yang G, Tian Q, Feng H, Xu K, Zhou C. 2019. Estimate of winter-wheat above-ground biomass based on UAV ultrahigh- ground-resolution image textures and vegetation indices[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 150:226-244.
- Zarco-Tejada P, Berjón A, López-Lozano R, Miller J, Martín P, Cachorro V, González M, Frutos A. 2005. Assessing vineyard condition with hyperspectral indices: Leaf and canopy reflectance simulation in a row-structured discontinuous canopy[J]. *Remote Sensing of Environment*, 99(3): 271-287.
- Zheng Y, Zhang M, Zhang X, Zeng H, Wu B. 2016. Mapping winter wheat biomass and yield using time series data blended from PROBA-V 100- and 300-m S1 products[J]. *Remote Sensing*, 8(10): 824.
- Zhuang H, Zhang Z, Cheng F, Han J, Luo Y, Zhang L, Cao Z, Zhang J, He B, Xu J, Tao F. 2004. Integrating data assimilation, crop model, and machine learning for winter wheat yield forecasting in the North China Plain[J]. *Agricultural and Forest Meteorology*, 347: 109909.