



西北农林科技大学

硕士学位论文

基于机器学习的冬小麦产量估测模型研究

专业学位类别	农 业 硕 士
领 域 名 称	农 艺 与 种 业
论 文 作 者	华 启 龙
指 导 教 师	宋 瑜 龙 副 教 授
合作指导教师	张 军 强 研 究 员
论文提交时间	2023 年 5 月 20 日

Thesis Submitted to Northwest A&F University
in Partial Fulfillment of the Requirements
for the Professional Degree of
Master of Master of Agricultural

Research on Winter Wheat Yield Estimation Model Based on Machine Learning

Degree Type: Master of Agricultural

Field: Agronomy and Seed Industry

Candidate: Hua Qilong

Supervisor: Associate Pro.Song Yulong

Co- Supervisor: Pro. Zhang Junqiang

Date of submission: 2023.05

Northwest A&F University

分类号: S512.1

UDC: 633

密级: 公开

学校代码: 10712

研究生学号: 2020055123

西北农林科技大学硕士学位论文

基于无人机多光谱遥感的冬小麦产量估测 模型研究

论文作者: 华启龙

指导教师: 宋瑜龙副教授

答辩委员会:

西北农林科技大学农学院

西北农林科技大学农学院

西北农林科技大学机械与电子工程学院

西北农林科技大学农学院

杨凌农业云服务有限公司

刘 杨 教 授

聂小军 副教授

吴婷婷 副教授

王 瑞 副教授

淡增光 农艺师

答辩日期: 2023 年 5 月 22 日

本研究得到:国家自然科学基金项目(NO.31701500), 杨凌示范区基地建设项目(A289021701), 中央高校基本科研业务费专项资金项目(Z1090322148), 陕西省重点研发计划一般项目(2022NY-176)资助。

摘要

对小麦育种高代系产量比较试验进行收获前无损估产,可以减少相对低产小区的无效收获,是提高小麦高代系选择效率的重要方法,因此随着遥感技术快速发展,对育种高代小区进行产量估测已逐渐受到小麦遗传育种领域师生的广泛关注。我们团队长期开展小麦遗传育种工作,每年需要对上百份小麦品种进行产量比较试验,但受农业机械装备和人员的限制,无法适度扩大选择规模,一定程度影响了育种效率(农作物品种选育是一个概率事件,因此在概率一定的基础上,群体选择规模越大,则出现优异新品系的几率越高)。因此,本研究利用无人机平台搭载五通道多光谱传感器,在 2021-2022 年度采集 290 个品种比较试验小区小麦 4 个生育期(拔节期、抽穗期、灌浆期、成熟期)12 个时段的多光谱数据,选取广泛应用的传统线性模型(Linear Regression, LR),采用机器学习模型中五种不同算法,包括:基于线性回归模型的偏最小二乘回归(Partial Least Squares Regression, PLSR),与适应于小样本训练的支持向量机(Support Vector Machine, SVM),还有三类基于决策树算法的模型[决策树(Decision Tree, DT)、随机森林(Random Forest, RF)和梯度提升树(Gradient Boosting Regression Tree, GBRT)],拟拟合一个科学精准的基于无人机多光谱遥感的冬小麦产量估测模型,结果如下:

(1) 选择大疆 M300RTK 四旋翼无人机,搭载 RedEdge-MX 多光谱传感器获取试验区冬小麦各小区四个关键生育期的多光谱数据,基于多种多光谱影像特征进行不同算法小麦估产模型的建立。首先,提取无人机影像五波段信息(Red、Green、Blue、Near-Infrared、RedEdge)、40 种纹理特征并计算与小麦生长及产量相关的植被指数 40 种,分析各特征与产量相关性与模型权重,R、B、G、N 波段组合、MCARI、RENDVI、VREI1、ARI2 植被指数组合与 N_Dis、N_Var、N_Con 纹理特征组合为优选特征组合,根据 LR、PLSR、SVM、DT、RF 和 GBRT 算法建立各时期冬小麦产量估测模型,其中,RF 模型精度最高($R^2=0.75$),且 RMSE 最低;结果表明灌浆期数据以 30m 为采样高度下 RF 小麦估产模型精度最高。

(2) 针对多生育期及不同模型输入参数,研究发现,抽穗期、灌浆期、成熟期数据信息结合后 RF 算法模型 $R^2=0.808$ 最高,且 RMSE 最低。其次,基于最佳生育期组合,结合三类特征参数的 GBRT 算法构建模型的决定系数最高($R^2=0.927$)同时 RMSE=0.091。最后,根据不同 ROI 尺度的选取对模型精度的影响研究,发现 80%采样尺度下模型性能最佳($R^2=0.934$, RMSE=0.085)。

关键词: 无人机多光谱遥感, 冬小麦产量, 机器学习, 多生育期产量预测

ABSTRACT

It is of great significance to conduct non-destructive yield estimation before harvest in wheat breeding high-generation plot yield comparison experiments which can improve wheat breeding efficiency. Therefore, with the rapid development of remote sensing technology, yield estimation in breeding high-generation plots based on this has gradually attracted widespread attention from teachers and students in the field of wheat genetics and breeding. Our team has been conducting long-term wheat genetic breeding work, requiring yield comparison experiments on hundreds of wheat varieties every year. However, due to limitations in agricultural machinery, equipment, and personnel, it is impossible to appropriately expand the selection quantity, which affects breeding efficiency somehow (crop variety selection is a probability event, so on a certain probability basis, the larger population selection range, the higher probability of excellent new strains appearing). Therefore, this study selected Agricultural Station 1 in Yangling Demonstration Area, Shaanxi Province as the research area, and used the UAV platform equipped with a five-channel multispectral sensor to collect data from 290 varieties in the experimental site from 2021 to 2022 for four growth stages (jointing, heading, filling, and maturity) of wheat in the experimental site. The widely used traditional linear model (LR) and five different algorithms in machine learning models, including Partial Least Squares Regression (PLSR) based on linear regression models and Support Vector Machine (SVM) adapted for small sample training, were selected. There are also three types of models based on decision tree algorithm [Decision Tree (DT), random forest (RF) and Gradient Boosting Regression Tree (GBRT)], which are intended to fit a scientific and accurate winter wheat yield estimation model based on UAV multispectral remote sensing. The test results are as follows:

(1) The DJI M300 RTK quadrotor UAV was selected to carry the Red-Edge MX multispectral sensor to obtain the multispectral data of four key growth periods in each plot of winter wheat in the test area, and the wheat yield estimation models with different algorithms were established based on the characteristics of multiple multispectral images. Firstly, extract five band information (Red, Green, Blue, Near Infrared, and Red-Edge) from UAV images, 40 texture features, and calculate 40 vegetation indices related to wheat growth and yield. Analyze the correlation between each feature and yield and model weights. Combine the R, B, G, N bands, MCARI, RE NDVI, VREI1, and ARI2 vegetation indices with N_Dis、N_Var、N_Con texture feature combination is the optimal feature combination, and winter wheat yield estimation models for each period are established

based on LR, PLSR, SVM, DT, RF, and GBRT algorithms. Among them, the RF model has the highest accuracy ($R^2=0.75$) and the RMSE is the lowest; The results showed that the RF wheat yield estimation model had the highest accuracy at a altitude of 30m with the filling period data.

(2) For multiple growth stages and different model input parameters, research has found that the RF algorithm model has the highest determination coefficient $R^2=0.808$ and the lowest RMSE when combined with data information on heading, filling, and maturity stages. Secondly, based on the optimal combination of growth stages and three types of feature parameters, the GBRT algorithm constructed the model with the highest coefficient of determination $R^2=0.927$ and $RMSE=0.091$. Finally, based on the impact of different ROI scales on model accuracy, it was found that the model performs best at 80% sampling scale($R^2=0.934, RMSE=0.085$).

KEY WORDS: UAV Multi-Spectral Remote Sensing, Winter Wheat Yield, Machine Learning, Multiple Growth Period Prediction

目 录

第一章 文献综述	1
1.1 研究背景.....	1
1.2 国内外研究进展.....	2
1.2.1 农作物产量估测方法研究.....	2
1.2.2 植被指数研究进展.....	4
1.2.3 无人机多光谱作物产量估测研究进展	5
1.3 研究意义.....	6
1.4 技术路线.....	7
第二章 研究数据与方法	8
2.1 研究区.....	8
2.2 数据获取.....	8
2.2.1 无人机数据获取.....	8
2.2.2 试验区小麦产量数据.....	10
2.3 多光谱数据预处理流程.....	11
2.3.1 波段配准	11
2.3.2 辐射定标	12
2.3.3 影像拼接.....	12
2.3.4 波段融合与裁剪.....	13
2.3.5 选取感兴趣区.....	13
2.3.6 植被指数计算与特征提取.....	14
2.4 研究方法.....	18
2.4.1 线性回归.....	18
2.4.2 偏最小二乘回归.....	18
2.4.3 支持向量机回归.....	19
2.4.4 决策树.....	19
2.4.5 随机森林.....	19
2.4.6 梯度提升回归树.....	19
2.4.7 评价方法.....	20
2.5 本章小结.....	20
第三章 研究内容与结果	22
3.1 试验区多光谱数据分析.....	22
3.1.1 波段信息分析.....	22
3.1.2 植被指数分析.....	24
3.1.3 纹理特征分析.....	26

3.2 特征筛选.....	28
3.2.1 波段信息与产量相关性及其重要性分析	28
3.2.2 植被指数与产量相关性及其重要性分析	30
3.2.3 纹理特征与产量相关性及其重要性分析	33
3.3 不同高度下冬小麦产量最佳单一时期模型构建	35
3.3.1 基于波段信息的冬小麦产量最佳单一时期模型构建	35
3.3.2 基于植被指数的冬小麦产量最佳单一时期模型构建	38
3.3.3 基于纹理特征的冬小麦产量最佳单一时期模型构建	40
3.4 生育期确定.....	43
3.5 不同生育期构建小麦产量估测模型	44
3.5.1 基于波段信息的冬小麦产量最佳生育期组合模型构建	44
3.5.2 基于植被指数的冬小麦产量最佳生育期组合模型构建	45
3.5.3 基于纹理特征的冬小麦产量最佳生育期组合模型构建	46
3.6 基于不同特征组合的小麦产量估测模型构建	47
3.7 小结.....	49
第四章 讨论.....	51
4.1 不同算法构建模型影响分析	51
4.2 不同高度对模型构建的影响分析	51
4.3 不同生育期组合对模型构建的影响分析	52
4.4 不同采样尺度对模型构建的影响	53
4.5 小结.....	54
第五章 结论.....	55
5.1 小结.....	55
5.2 展望.....	56
参考文献.....	57

第一章 文献综述

1.1 研究背景

小麦作为中国三大粮食作物之一，其产量关系到国计民生和国家经济增长。国家统计局的数据显示，2022 全年粮食种植面积 11763 万公顷，其中小麦种植面积约为 2357 万公顷，与 2021 年同比增加了 19 万公顷，扭转了连续 5 年小麦播种面积下滑的趋势，同年小麦产量约为 13695 万吨，增产约 2.0%^[1]。这主要是源于国家农业实施“以科技驱动农业，逐步引导中国农业进入数字化、自动化时代”政策，重点利用新一代信息技术监控小麦产量，以期望用好有限耕地资源，获得最大粮食产出，适应新时期下由于经济发展需求和人口上升对小麦产量的需求。因此，小麦成熟前的产量估算，不仅在精准农业的发展中显得尤为重要，同时对小麦遗传育种工作的推进也具有重要的指导意义。

遥感技术是地球观测的有效技术手段，其具有尺度较大、效率较高、无损伤的优点，在各类与精准农业有关的课题研究中得到了广泛应用^[2-4]。其中基于遥感技术获取农作物长势参数已成为目前最常用的方法之一。遥感技术是以远程操控的方式进行实时的，对作物的生长信息进行快速监控，使作物信息监测从“点”向“面”过渡^[5]。同时也为农作物种植管理提供了新的途径和手段。然而，遥感技术的应用有一个先决条件，即：作物生长差异，光谱上也随之发生相应改变。因此，利用光谱数据变化可对作物的信息进行有效的监测^[6]。遥感技术主要包括光学探测和光电探测 2 大类，其中光电探测又分为可见光探测、红外探测、激光探测以及热成像检测 4 大类。当前遥感技术根据空间尺度可以划分为卫星遥感、无人机遥感、近地面遥感。其中，卫星遥感因其覆盖面广，时效性强等特点已逐渐成为使用广泛的重要监测技术。卫星遥感是以不同国家发射的观测卫星为平台，单幅数据范围广泛、监测尺度较大，但因其所处位置，均易受天气影响且数据处理过程繁琐，如果监测区域被云层和浓雾所掩盖，那么传感器就无法获得可用的地物信息数据，且卫星遥感回访周期固定，无法确保数据的即时立即获得；与此同时，近地遥感可以获得高分辨率资料，但通常都要实现“点”监控，不能迅速方便实现对“面”的监控。

与空间遥感相比较，无人机具有很强的可操控性，能携带多种光谱仪器，不但对大气云层的扰动较少，同时具有时空分辨率高、机动灵活等优点，并能够对作物的生长状况进行成像可视化，同时兼具成本低廉和时效性强等特征^[7]，近年来，已经逐步成为作物长势监测的一种重要农情分析方法。无人机（Unmanned Aerial Vehicle, UAV）可以携带可见光、多光谱等遥感数据采集仪器，及高光谱或热红外数据采集器，从而

对距地面 10 m 甚至 1000 m 高度的生物进行监测, 如: 在杂草和病虫害的识别等方面的应用^[8]、农作物生长监测^[9]、产量预测^[10]、农作物种植信息提取^[11,12]、地物分类^[13-15]等。现阶段, 基于遥感技术获取农作物长势参数已成为常用的主流技术手段, 其中可见光与热红外传感器的相对光谱波段较小, 可用于监测作物的参数有限, 而高光谱传感器拥有更多光谱波段, 数据采集较为系统和详细, 但该传感器价格较高, 一定程度限制了其大面积应用。因此, 在综合考虑各因素情况下, 利用无人机多光谱遥感技术开展小麦产量反演, 对小麦产量进行高精度的收获前无损预测, 可以快速实现从大量样本中高效选择高产品系, 进而为小麦遗传育种工作提供技术支持。同时, 该研究结果也可为进一步利用高分辨率卫星数据进行大尺度、大区域小麦表型获取与产量预测模型等研究提供基础。

1.2 国内外研究进展

影响小麦产量的因素多样, 其中除常规光温水肥环境条件外, 耕作管理水平、小麦各关键生育期, 以及各生育期物候节律等因素表现尤为突出, 表明小麦产量主要受基因型和环境互作双重影响。因此, 对小麦产量估测而言, 数据采集方式及传感器就显得尤为重要。传统遥感技术主要以单一传感器为主, 如可见光传感器、热红外传感器, 但受技术限制上述二类传感器在小麦产量估测方面精度不足。小麦遥感估产的研究, 起步于上个世纪八十年代, 延续至本世纪, 随着遥感技术领域研究的深入, 遥感手段已深入农业领域, 其中小麦遥感估产的研究, 不论是在平台上、方法上或精度上逐年提高。因此, 当前大范围小麦产量估测主要是借助于现代农业遥感监测平台, 开展遥感影像数据反演小麦生长, 进而实现高精度小麦估产研究。

1.2.1 农作物产量估测方法研究

由于农业生产活动中, 地理条件以及环境因素的限制, 目前现有的各种作物单产量估计模型已有三类得到了广泛运用, 依据构建模型的算法不同, 主要有: 传统的统计模型、作物生长模拟模型和光能利用率模型。

经验统计模型是基于传统经验累积所得, 主观性强, 原理较简单, 应用广泛且成熟, 至今在各个领域与行业均有较好应用。随着计算机技术, 遥感技术等不断发展, 对数据分析过程中可以根据不同数据类型, 设计出多种经验统计模型。现阶段, 我国主要利用空间遥感技术来估算作物产量, 其中农业生产中应用最多的有田间抽样调查法、遥感技术估产法等。它们分别适用于对农作物生长状况的调查与监测, 以及作物长势分析评估两个方面。田间抽样调查法, 按照构建经验统计模型的思想, 首先设置随机抽样小区, 根据区域设置合适的样本量, 获取实际测量值。遥感技术估产法是根据一定时期内作物长势变化情况, 结合遥感影像数据来估测农作物产量。卫星数据在

获取使用成本上具有其他类型遥感数据无法比拟的优势，因此目前其应用领域仍最广泛。经验统计模型几乎在农作物估产的各个领域都有应用，然而，经验统计模型对采样小区的代表性与样本特征有较高的要求，一旦小区代表性不强或样本特征不明显，模型结果很难应用，因此会一定程度增加工作量，从而延长工作时长。基于此，如何选择合适的抽样小区，以及怎样利用这些小区样本提高产量估测模型的精度一直都是国内外研究人员关心的要点问题之一。

气象数据估产法是以遥感数据中的气象信息为基础，对农业生产的各个环节与数据进行估算，无需进行抽样调查，主要根据卫星数据获取与农作物生长发育相关的各类环境因子数据和分布情况，确定农作物生长情况并建立模型。我国现阶段主要以家庭种植模式为主，因此采用经验统计模型估产难度较大，且数据获取准确性有待商榷，而欧美等国的农场制度则广泛应用此方法，效果相对较好^[17]。因此，探索利用气象卫星数据开展作物生长动态模拟，实现作物生长状况预测和病虫害发生评估，受到相关领域专家的持续关注。例如，Wu 等^[18]使用全球农作物监测系统中气象模型开展作物产量估算；王蕾等^[19]根据气象因子数据进行建模，并对小麦产量进行估测，结果显示该方法在预测小麦单产方面具有明显的优势。Moriondo^[20]等在建立估产模型时，同样也考虑了气象因子与植被指数的综合影响，并结合 NDVI 时序与气象因子进行产量模型构建，最终获得了一个小麦高精度产量估测模型。与此同时，薛利红^[21]等重点分析了能够反应水稻各生育期作物长势因素，明确了多种植被指数与水稻产量的相关性，构建出了一个完善的水稻产量估测模型。上述研究表明，利用空间遥感数据虽然能够对不同作物产量进行较为精确的预测，但未将作物生育期及自身发育特征综合考虑，因此在模型建设过程中存在一定的局限性。

作物生长模型是实现作物高产、稳产的重要手段之一。在遥感技术蓬勃发展的今天，遥感估产法已经成熟应用，但是由于它本身具有许多不确定性因素，在实践中应用有一定的难度。例如，针对于土壤和作物的影响及关系，有 AquaCrop 模型，可以根据作物对营养因素的需要进行重点预测^[23]；WOFOST (world food studies, WOFOST) 在行业应用中发展成熟深入，其重点在于卫星遥感的气象因子分析，例如氧气二氧化碳对农作物的影响^[24]；作物产量跟光合作用有强相关性，部分研究者认为光合作用在农作物产量预测当中起主要作用，据此建立了 CERES 模型^[25]。由于遥感技术的速度快，效率高，高时空分辨率等优势，使遥感估产法在农业生产管理中的应用得以实现。在基于遥感平台建立农作物产量模型时，参数主要是影响农作物生长发育过程中所必须的各种环境条件及其相互作用关系，其中包括温度，光照等参量、湿度和其他物理因子，还有土壤水分含量和叶片气孔导度等生理因素。其中，土壤含水量是最重要的一个参数值，并且作物生长模拟模型生物学机理强，因此通常需要一些遥感数据作为辅助参数参与这些数据的推演，目前使用比较多的是植被指数和叶面积指数^[27]。

光能利用率模型强调植物干物质积累,创新性地提出了植物生产力的概念,综合了光合作用和植物生物量的因素,通过植物生产力的概念建立数学模型进行产量估算。根据此原理设计了一个适合于不同生态条件下农作物光能利用效率估算的通用模型。与其他模型相比,光能利用率模型具有原理清晰、运行成本低廉的优点。此外,该类模型可反应植物光合作用的相关参数,根据植被指数反演作物叶面积,已经能够高效精准的提取叶面积指数信息,并用于后续进一步研究^[28]。因此,它在农作物估产领域中得到了广泛应用。Kiniry 等^[29]根据光能利用率,计算夏玉米生长状况,预测产量;李宗南^[30]在光能利用率模型的基础上,兼顾遥感技术定量监测叶绿素,高效地进行了大范围省级区域夏玉米生产估算;在光能利用率模型建设过程中,Yuan^[31]等人增加了卫星标准产品 NDVI 指数来构建光能利用率模型。这些方法都是将遥感与地理信息系统相结合来实现农作物种植面积及产量估测的方法,为了增强模型的稳定性,有学者开始融合多元模型,克服单一模型的缺点,发掘各自模型优点。Huang 等^[32]综合 Landsat TM 和 MODIS 数据获取的 LAI (leaf area index, LAI) 加入 WOFOST 模型中探讨其对小麦产量估测的效果。Ma 等^[33]根据作物反射模型的差异,首先得到 LAI 定量估测数据,再根据滤波思想,在 WOFOST 模型上同化 LAI 指数,对作物产量估测模型进行了影响因素研究。

目前国内外许多学者将遥感技术作为一种新的研究方法来进行作物生长和发育的动态评估与预测。随着遥感技术广泛应用于农业领域,获取遥感数据进行作物生长发育监测是完全可行的,但由于遥感数据的准确性不高,使它在定量监测应用时受到一定限制。为提高作物产量估算结果的准确性和实用性,研究人员提出并验证了基于多源多时相卫星影像与地面调查相结合的作物长势评估方法。唐延林^[34]建立了多生育期水稻估产模型,综合了水稻在各时期的特征。李龙澍^[35]采用分级多次模糊,提出了一种估测小麦产量的模型。这些都是基于地面实测资料进行的研究,能够为各类作物模型的建立提供一个优良的数据源。目前利用多时相卫星遥感资料进行农业生产研究已成为当前国际上一项十分活跃的新领域。利用植被指数进行作物生长状况评价,是一种简单实用的方法。植被指数能容易地用来估计农作物长势,评价作物产量,能够更加直观的体现植物生理生态特性。许多学者都在进行遥感植被指数与产量相关性分析的深挖,目前植被指数的计算公式是一个重要深入领域,同时,植被指数作为一种重要特征参与模型构建也是重要成果^[36]。

1.2.2 植被指数研究进展

植被指数是由不同光谱数据获得的,根据光谱反射情况进行线性或者非线性组合运算的无单位辐射参数^[37,38],已经成为人们对植被进行定性、定量评价的普遍手段之

一。植被指数对作物的各类生长过程和生长因素的相关性要显著高于单波段波谱信息^[39-43], 并且大部分早期指数的计算并不复杂^[44]。在应用的过程中, 研究者发现植被指数对土壤、地形以及各类气候因素的影响反应并不灵敏^[45, 46]。为了消弱这种非生物因素的影响, 研究者们提出了一些基于土壤-植被-大气相互作用系统的植被指数^[47, 48], 如土壤调整植被指数 (soil adjusted vegetation index, SAVI)、大气阻抗植被指数 (atmospheric resistant vegetation index, ARVI) 及土壤和大气阻抗植被指数 (soil and atmospheric resistant vegetation index, SARVI) 等。

最早的植被指数是由 Jordan 提出的比值植被指数 (ratio vegetation index, RVI)^[49]。随着近几十年遥感光谱分辨率的不断提高, 按照植被指数的发展历程, 可分为三类: 第一类早期研究者依据自身经验研究出的植被指数, 受到研究者主观因素影响较大, 不包含其他因素的信息, 如 RVI 等; 第二类是将这 2 种或几种植被指数的影响因素与研究方法结合起来使用, 比如: 基于不同植被类型的分类植被指数; 第三类是根据不同目的对某些特定区域进行监测, 基于高光谱遥感与热红外遥感技术的综合研究, 如红边植被指数、温度植被指数等、生理反射植被指数等指标^[50]。第一类和第二类植被指数是简单结合了各类影响因素的结果, 均存在着自身的不足, 所以在实际应用中已经逐渐被淘汰。第三类植被指数可以实现对植物冠层结构变化的植被长势检测, 属于基于作物生长发育状况和农作物病虫害发生程度的作物产量估测。目前的植被指数更多基于绿色植被研究提出, 研究重心差异较大, 因此在模型应用中得到的结果有显著差异, 植被指数的确定需要结合具体区域及植株的特性来考虑。

1.2.3 无人机多光谱作物产量估测研究进展

多光谱相机优于其他传感器的两个重要特点是体积轻便, 安装简单, 并且各波段组合可计算出种类丰富涵盖因素广泛的遥感数据来参与作物产量估测模型的构建。作物长势和最终产量直接相关, 产量是评价作物生长好坏的依据, 进行产量估算和分析对于农业领域尤为重要。在单传感器作物产量反演方面, 陶惠林等^[51]利用无人机获取冬小麦挑旗期等生育期影像, 使用可见光植被指数估测产量, 多元线性回归模型决定系数达到 0.71, 精度较好。Mah 等^[52]基于采集的小麦冠层多个生育期多光谱影像提取归一化植被指数, 用于开展充分灌溉和缺水灌溉状态下小麦产量估测研究, 结果表明在充分灌溉情况下灌浆期估产模型精度最好, 决定系数为 0.49。Fei 等^[53]利用多光谱冠层数据构建集成学习小麦产量估测模型, 决定系数达到 0.63。Stroppiana 等^[54]选择大疆 S1000 八旋翼无人机搭载 ADC Air (美国, Tetracam) 冠层传感器获取了试验区水稻数据, 分析其各波段数据与水稻产量的相关性, 并根据波段指数发现其在产量估测上具有良好的效果, 决定系数最高达到 0.54。王妮等^[55]获取了小麦不同关键生育

期的冠层多光谱数据，基于关键生育期数据与小麦产量进行相关性分析，获得了一种效果很好的多元线性回归模型， $R^2=0.68$ 。朱婉雪等^[56]利用 SenseFly-eBee-Ag 无人机搭载 Multi-SPEC 4C 多光谱相机，根据小麦冠层数据计算了各类植被指数，采用 PLSR 算法建立了 9 种不同输入参数的模型，根据验证集对模型进行精度评价，分析了小麦长势与产量的数据获取关键生育期为抽穗灌浆期。

表 1.1 不同估产传感器对照表

Table. 1-1 Comparison of different yield estimation sensors

类型	卫星平台搭 载光学成像	卫星平台搭 载雷达	手持多光谱/ 高光谱仪	无人机载可见 光/多光谱	无人机载高 光谱
时空间分辨率	低	较低	较高	高	高
通道数量	少	少	多	较少	多
波段范围	较小	大	大	较小	大
光谱分辨率	低	低	高	较高	高
是否有空间信息	有	有	无	有	有

在多源传感器方面，张少华等^[57]基于无人机获取扬花期和灌浆期的多光谱数据、数码影像数据和热红外相机数据，分别建立单模态、双模态和三模态产量估算模型，结果表明利用随机森林构建的三模态模型效果最好，决定系数达到 0.893，估测小麦产量准确可靠；Maimaitijiang^[58]等基于可见光影像数据结合多光谱及热红外影像数据构建的 DNN 大豆产量估测模型决定系数达到 0.720，优于机器学习方法；Feng 等^[59]基于装备数码相机、多光谱相机和红外热像仪的无人机系统采集棉花影像数据用于估测棉花产量，结果表明开花期三模态模型精度最佳，决定系数在 0.92~0.94。Zhou 等^[60]对比分析了无人机搭载可见光数码相机和多光谱相机获取数据的区别，建立了两个系列的植被指数特征并分析其与小麦产量的相关性，根据综合比较结果选取 NDVI 作为最优小麦产量估测模型参数建立模型。

1.3 研究意义

本研究采用无人机多光谱遥感，采集 2021-2022 年度育种试验基地小麦数据，从生育期、高度两方面探究线性模型和 5 种常用机器学习估产模型的精确度，分析其应用性，获得最佳收获前产量预测模型。小麦新品种选育是一个概率事件，具有一定偶然性与不确定性，基于此必须要扩大品种选择范围，但同时严重增加了育种工作者的收获工作量，因此必须探索出一套科学精准的收获前产量估测模型，预先评价高代系产量，从大量的样本中选择高产基因型，有助于在常规育种工作中优化资源配置，科

学合理的扩大品比实验规模，帮助育种家更快捷的实现育种目标，同时，该研究结果也可为进一步利用高分辨率卫星数据进行大尺度、大区域小麦表型获取与产量预测模型等研究提供基础。

1.4 技术路线




图 1-1 技术路线

Fig. 1-1 Technology roadmap

第二章 研究数据与方法

2.1 研究区

本文研究区位于陕西省杨凌示范区西北农林科技大学农作一站试验基地。如图 2-1。全年平均气温 14.1℃，日照时间 2572.6h，无霜期 292 天，降水量 709.5mm。本研究于 2021 年开展田间试验，冬小麦于 10 月上旬播种，研究区 2021 年种植密度为每亩 16 万基本苗，按照每亩 15kg 尿素、20kg 二胺、5kg 油渣施肥，于返青期进行一次追肥，每亩追加 7.5kg 尿素。研究区冬小麦冬季统一喷灌灌溉，农作一站试验区小区面积 6.75m²（长 4.5 米，宽 1.5 米），田块设计为 16 行 17 列。




图 2-1 研究区

Fig. 2-1 Research area

2.2 数据获取

2.2.1 无人机数据获取

无人机遥感具有高时间空间分辨率优势，并且使用灵活方便，应用性价比高，对于农业信息获取适应性好^[61]。本试验采用大疆经纬 M300 无人机（大疆创新科技有限公司，中国），搭载 RedEdge-MX 多光谱相机（MicaSense 公司，美国）如图 2-2 所示。自 2022 年 4 月 12 日至 6 月 1 日每 4-5 天于陕西省杨凌示范区农作一站试验地进行数据采集工作，数据采集均选在天气晴朗阳光充足时进行，共进行 12 次作业，分别获取 30m、60m 高度多光谱数据，飞行拍摄均在北京时间 11:00--14:00 之间进行，此时太阳天顶角最小，拍摄数据详情表 2-3。



图 2-2 无人机平台与多光谱传感器

Fig. 2-2 UAV Platform and Multispectral sensors

表 2-1 无人机性能参数

Table 2-1 UAV Performance parameters

指标	大疆经纬 M300 RTK
重量	空机重量（含双电池）： 6.3 kg
轴距	895 mm
最大飞行速度	23 m/s
最长飞行时间	55 min
遥控信号最远距离	15 km
可承受风速	15 m/s
最佳工作温度	20°C 至 50°C

表 2-2 传感器性能参数

Table 2-2 Sensor performance parameters

类型	RedEdge-MX
尺寸	8.7cm x 5.9cm x 4.54cm
光谱波段	蓝 （475nm, 32nm）
	绿 （560nm, 27nm）
	红 （668nm, 16nm）
	红边 （717nm, 12nm）
	近红外 （842nm, 57nm）
空间分辨率	8cm（120m 飞行高度）
帧率	最快 1fps, 12bit RAW
接口	串口, 10/100/1000 ethernet, WI-FI, 外部触发接口, GPS, SDHC
视场角	47.2° HFOV
触发选项	时间模式, 重叠模式, 外部触发模式（PWM, GPIO, 串口或网口），手动拍摄

表 2-3 试验区获取数据时期详情列表

Table 2-3 List of details of the period for which data were obtained from the test area

2022 农作一站多光谱数据												
时期	4 月 9 日	4 月 12 日	4 月 18 日	4 月 23 日	5 月 1 日	5 月 6 日	5 月 11 日	5 月 16 日	5 月 21 日	5 月 24 日	5 月 28 日	6 月 1 日
天气	晴朗	晴朗	晴朗	晴朗	晴朗	晴朗	晴朗	晴朗	晴朗	晴朗	晴朗	晴朗
生育期	拔节期		抽穗扬花期				灌浆期			成熟期		

大疆经纬 M300 无人机为机身六面均配备双目视觉及红外传感器避障系统，最远支持 15 公里图传系统，性能强大。使用机身配备遥控器 pilot2 规划航线，飞行轨迹为固定航线轨迹飞行，高度分别设置 60m 和 30m，飞行速度根据相机参数设置为 5m/s 和 3m/s，旁向重叠度与航线重叠度均为 80%，航线完全覆盖试验小区进行飞行。

RedEdge-MX 是美国 Micasense 公司开发的新一代五镜头多光谱相机，可以同时采集蓝、绿、红、红边、近红外五个通道的光谱影像，窄带滤光片提供针对单一波段大图像分辨率，全局快门设计可消除各种平台上的图像失真。该款相机于飞行前通过 WiFi 连接控制页面进行飞行设置，试验采用重叠度触发拍照模式，重叠率设置 80%，触发高度为 25m，飞行高度分别设置 60m 和 30m，每次飞行前后均需手动拍摄定标版。无人机和传感器性能参数见表 2-1、2-2。

2.2.2 试验区小麦产量数据

各试验小区冬小麦产量（单位为 kg/hm^2 ）由陕西省西北农林科技大学小麦杂种优势利用实验室育种工作者在小麦成熟收获脱粒后测产获得（产量数据详情见图 2-3）。




图 2-3 试验区小麦产量结果分布情况

Fig. 2-3 Distribution of wheat yield results in the experimental area

2.3 多光谱数据预处理流程

本论文无人机影像数据是多光谱影像，一次飞行所得数据中含有多张照片。基于此，本文将主要介绍几种常见的用于监测农作物长势及产量预测情况的植被指数。原始的多光谱图像数据采用 tiff 格式。本论文在建立基于无人机影像反演小麦产量模型前，首先对多光谱图像实施有针对性的预处理，方便从多品种小麦中提取图像或光谱特征。为了提高遥感图像特征提取精度，需要对多光谱图像做相应的数据处理工作。无人机图像预处理具体流程见图 2-4。



图 2-4 多光谱影像预处理流程

Fig. 2-4 Multispectral image preprocessing process

2.3.1 波段配准

多光谱数据各波段间存在明显的位置偏移，在进一步处理之前，需要完成波段配准。常见的波段配准方法可分为几何精纠正方法、空中三角测量方法和虚拟摄影方法三类。

几何精纠正方法是遥感图像处理时最常用的一种实现影像配准的处理方法。首先，采用人工测量或者自动匹配算法在波段间量取一定数量的同名点，用作计算影像间几何变换参数的控制点。然后，根据影像间的几何变形特点，选取合适的几何变换模型，利用控制点经最小二乘法解算几何变换模型的参数。最后，采用反投法将目标影像坐标代入几何变换模型中，求解其在源影像上对应的像素坐标，经重采样得其灰度值。常见的几何模型有：一次多项式模型、二次多项式模型、以及小面元模型等。

当采用几何精纠正方法处理 RedEdge 相机拍摄的影像时，因像幅较小，覆盖一定地面范围需要大量影像，因此工作量巨大。除此之外，几何变换模型对控制点中的粗差比较敏感，很难保证处理结果具有均匀的配准精度。

空中三角测量方法是一种批量恢复摄影时影像对应光束在空间中位置和姿态的严密方法。采用此方法处理 RedEdge 相机拍摄的影像时，影像数量大和同一摄站不同波段间的强相关性是光束法平差算法面临的主要问题，容易出现不收敛或者平差精度差的现象。一种可行的改进方法是在函数模型中，将同一摄站拍摄的 5 幅影像中的一副影像的外方位元素视作未知数，其它 4 幅影像的外方位元素以相对此影像的位置偏移和姿态旋转来描述，且在整个测区内保持一致。这样做不仅可减少平差解算时未知数的个数，更重要的是在平差系统中引入了不同镜头间的固有几何约束关系，这与

RedEdge 相机中各镜头间存在刚体连接关系相一致，显著提高了平差系统的稳定性。然而要实现波段间的配准，一般需对每个波段做正射纠正处理，再将正射影像套合起来，组成多波段影像，使得配准结果除受空中三角测量处理精度影响外，还受到 DEM 匹配结果的影响，容易出现局部“失配”问题，不利于保持成图区内配准精度的一致性。

虚拟摄影方法是一种利用镜头间相互位置关系，将它们重新投影到一幅理想虚拟影像的方法。采用此方法处理 RedEdge 影像时，无须已知影像外方位元素和测区 DEM，仅需要航空摄影时的平均相对航高即可，是一种非常便利的波段配准方法。然而由虚拟摄影方法的原理可知，只有当各镜头投影中心重合时，地形起伏在影像上引起的像点位移不致在虚拟摄影时产生误差。受镜头物理结构限制，投影中心重合是无法实现的。实际上，RedEdge 相机各镜头间距较小，并且可视作在同一水平面上。经测算，当地形起伏相对于平均高程的高差不大于相对航高的 20% 时，地形起伏引起的像点位移误差小于 0.5 像元，满足波段配准要求。故本文采用虚拟摄影方法进行配准。

2.3.2 辐射定标

太阳辐射以一定的形式透过大气射入物体表面，随后又被反射回到传感器上，受大气气溶胶的影响、地形及邻近地物的图像等等，使原始影像中含有物体表面、大气，和太阳等信息合成。需要确定传感器入口处的准确辐射值。本文采用“白板定标法”进行多光谱影像的辐射校正^[62]，将记录的原始 DN 值转换为大气外层表面反射率（或称为辐射亮度值）。

2.3.3 影像拼接

无人机平台搭载的多光谱传感器的空间分辨率已经达到厘米级别，但受镜头限制，影像之地面分辨率与覆盖地物之区域有冲突，若需要在一幅镜像中覆盖更多的试验区，则需要提高采样高度，降低影响地面分辨率，故在使用时需要通过影像拼接解决这个矛盾。

影像拼接针对大面积试验区进行拍摄时，由于要求的高空间分辨率，针对设定的重叠度进行拼接成完整试验区影像的过程，其中涉及一系列计算机算法在此不过多赘述。本文采用 Pix4D 软件进行影像拼接工作，其工作流程如图 2-5。




图 2-5 影像拼接流程图

Fig. 2-5 Image mosaic flow chart

2.3.4 波段融合与裁剪

使用 ENVI5.3 软件的 Layer stacking 功能对处理后的多光谱数据进行波段合成处理，将 5 个波段的影像合成一幅图像。

无人机完整影像在拍摄时为确保完整性，往往包含了除研究区外其他地物的信息，在研究中为确保研究数据的有效性、避免数据冗余降低计算机处理时间，研究采用 ENVI5.3 中的 Subset Datavia ROIs 工具，对预处理后的试验区多光谱影像进行裁剪，确保裁剪结果仅包含试验所有小区。

2.3.5 选取感兴趣区

试验区各个小区间存在田垄裸地分隔，需要祛除田垄裸地获取只包含小麦的感兴趣区域（Region of Interest, ROI），在每个小区 ROI 大小相等并且尽可能的包含小麦植株前提下获得 290 个小区的 ROI，为确保样本量并且增强数据准确度，本研究将每个试验小区 ROI 划分为 9 等分，提取研究所需试验参数。




图 2-6 影像裁剪示意图

Fig. 2-6 Schematic diagram of image clipping




图 2-7 ROI 选取、分割示意图

Fig. 2-7 ROI Selection, Segmentation diagram

2.3.6 植被指数计算与特征提取

植被指数是根据各个波段反应植被生长发育相关信息的不同,通过多种计算方式所得,能够清楚反应出水分、墒情、营养情况和产量等作物相关数据,并能够将时空范围内的不同特性不同因素进行高效对比,是现代智慧农业研究中重要的研究工具^[63]。

因此，结合本研究选取的多光谱相机五波段信息能有效反应小麦生长变化情况计算的 40 种常用的植被指数，其中反射率信息及植被指数如表 2-4 所示。

表 2-4 多光谱特征列表

Table 2-4 Multispectral feature list

植被指数	全名	公式	文献
R	红光通道的反射率	3 波段反射率信息	-
G	绿光通道的反射率	2 波段反射率信息	-
B	蓝光通道的反射率	1 波段反射率信息	-
RE	红边通道的反射率	5 波段反射率信息	-
N	近红外通道的反射率	4 波段反射率信息	-
r	R 归一化值	$R / (R+G+B)$	[64]
g	G 归一化值	$G / (R+G+B)$	[64]
b	B 归一化值	$B / (R+G+B)$	[64]
红色因子 (Excess Red, EXR)		$1.4R-G$	[65]
可见差异植被指数 (Visible-band Difference Vegetation Index, VDVI)		$(2G-R-B) / (2G+R+B)$	[7]
归一化绿蓝指数 (Normalized Green-Blue Difference Index, NGBDI)		$(G-B) / (G+B)$	[66]
归一化绿红指数 (Normalized Green-Red Difference Index, NGRDI)		$(G-R) / (G+R)$	[66]
绿红比指数 (Green-Red Ratio Index, GRRI)		G/R	[67]
绿蓝比指数 (Green-Blue Ratio Index, GBRI)		G/B	[68]
蓝红比指数 (Blue-Red Ratio Index, BRRI)		B/R	[69]
归一化植被指数 (Normalized Difference Vegetation Index, NDVI)		$(RE-R) / (RE+R)$	[70]
绿色归一化差异植被指数 (Green normalized		$(RE-G) / (RE+G)$	[71]

difference vegetation index, GNDVI)		
比值植被指数 (Ratio Vegetation Index, RVI)	RE/R	[72]
归一化水体指数 (Normalized Difference Water Index, NDWI)	$(G-RE) / (G+RE)$	[73]
差异植被指数 (Different Vegetation Index, DVI)	$RE-R$	[74]
垂直植被指数 (Perpendicular Vegetation Index, PVI)	$(RE-10.489R-6.604) / \sqrt{(1+10.489^2)}$	[75]
土壤调整植被指数 (Soil Adjusted Vegetation Index, SAVI)	$1.5 (RE-R) / (RE+R+0.5)$	[47]
改良土壤调整植被指数 (Modified Soil Adjusted Vegetation Index, MSAVI)	$0.5 \{2 (RE+1) - \sqrt{[(2RE+1)^2 - 8 (RE-R)]}\}$	[77]
大气阻抗植被指数 (Atmospherically Resistant Vegetation Index, ARVI)	$\{RE-[R-(B-R)]\} / \{RE+[R-(B-R)]\}$	[78]
增强植被指数 (Enhanced Vegetation Index, EVI)	$[2.5 (RE-R)] / (RE+6R-7.5B+1)$	[79]
绿色耐大气指数 (Green Atmospherically Resistant Index, GARI)	$\{RE-[G-1.7 (B-R)]\} / \{RE+[G-1.7 (B-R)]\}$	[71]
绿色差异植被指数 (Green Difference Vegetation Index, GDVI)	$RE-G$	[80]
绿色比值植被指数 (Green Ratio Vegetation Index, GRVI)	RE/G	[80]
红外植被百分比指数 (Infrared Percentage Vegetation Index, IPVI)	$RE / (RE+R)$	[81]
叶面积指数 (Leaf Area Index, LAI)	$3.618EVI-0.118$	[82]
可见耐大气指数 (Visible Atmospherically Resistant Index, VARI)	$(G-R) / (G+R-B)$	[83]
改良叶绿素吸收率指数 (Modified Chlorophyll Absorption Ratio Index, MCARI)	$[(N-R) - 0.2 (N-G)] (N/R)$	[84]

修正三角植被指数 (Modified Triangular Vegetation Index, MTVI)	$1.2[1.2 (RE-G) - 2.5 (RE-G)]$	[85]
红边归一化植被指数 (Red Edge Normalized Difference Vegetation Index, RENDVI)	$(N-R) / (N+R)$	[86]
沃格曼红边指数 1 (Vogelmann Red Edge Index 1, VREI1)	N/R	[87]
三角植被指数 (Triangular Vegetation Index, TVI)	$0.5[120 (N-G) - 200 (R-G)]$	[88]
MERIS 陆地叶绿素指数 (MERIS Terrestrial Chlorophyll Index, MTCI)	$(RE-N) / (N-R)$	[89]
叶绿素吸收反射指数 (Chlorophyll Absorption Reflectance Index, CARI)	$(N-R) - 0.2 (N+R)$	[90]
花青素反射率指数 1 (Anthocyanin Reflectance Index 1, ARI1)	$1/G-1/N$	[91]
花青素反射率指数 2 (Anthocyanin Reflectance Index 2, ARI2)	$N (1/G-1/N)$	[91]
植物衰老反射指数 (Plant Senescence Reflectance Index, PSRI)	$(R-G) / N$	[92]
重整化差异植被指数 (Renormalized Difference Vegetation Index, RDVI)	$(RE-R) / \sqrt{(RE+R)}$	[93]
优化土壤调整植被指数 (Optimized Soil Adjusted Vegetation Index, OSAVI)	$[1.5 (RE-R)] / (RE+R+0.16)$	[94]
非线性指数 (Non-Linear Index, NLI)	$(RE^2-R) / (RE^2+R)$	[95]
修正非线性指数 (Modified Non-Linear Index, MNLI)	$[1.5 (RE^2-R)] / (RE^2+R+1.5)$	[96]

首先提取多光谱相机五通道的波谱信息, 即各单波段反射率数据, 后根据各植被指数计算得到 40 种指数结果, 共计 45 种样本参数, 根据划定的 ROI 及分类, 提取得到 290 个试验小区每个小区 9 个样本的 45 种特征参数, 即每幅多光谱影像经处理得到 2610 个样本数据。

灰度共生矩阵 (Gray-Level Co-occurrence Matrix, GLCM) 在图像纹理特征提取

中应用广泛^[97]，使用 ENVI 5.3 基于 GLCM 提取可见光影像 ROI 每个通道的 8 种纹理特征，分别为能量（Energy）、对比度（Contrast）、相关性（Correlation）、均值（Mean）、平方差（Variance）、熵（Entropy）、自相关（Autocorrelation）和逆差分矩阵熵（IDM）。提取纹理时选取最小的 3×3 窗口，角度为 0°。

2.4 研究方法

根据所选择的平台与传感器要求，将预处理完成的多光谱数据进行特征提取，包括两类波谱信息和纹理特征，基于此三类特征应用不同算法进行模型建立，并根据评价指标进行精度分析。本文的所有模型均基于 Python 语言的 Scikit-learn 库中实现。

2.4.1 线性回归

线性回归根据最小二乘法输入参数与输出变量中寻找一种最优的线性方程，算法原理较简单，在各种建模应用中普遍出现^[80]。线性回归模型一般形式为：

$$y = k_0 + k_1x_1 + k_2x_2 + \cdots + k_nx_n \quad 2-1$$

矩阵化表示为：

$$y = K^T X, \quad K = \begin{bmatrix} k_0 \\ k_1 \\ \vdots \\ k_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 \\ x_1 \\ \vdots \\ x_n \end{bmatrix} \quad 2-2$$

若有训练数据：

$$D = \{(X_1, Y_1), (X_2, Y_2), \dots, (X_m, Y_m)\} \quad 2-3$$

根据最小二乘法则需要最小化函数：

$$J = \sum [y(x^i) - y^i]^2 \quad 2-4$$

求解得：

$$K = (X^T X)^{-1} X^T y \quad 2-5$$

线性回归算法简单，应用性能好，但应用领域狭窄，大部分应用中建模所需的非线性数据难以拟合，且各部分系数均需要处理所有模型参数，无法忽视异常值的出现，对数据要求较高。

2.4.2 偏最小二乘回归

偏最小二乘回归基于主成分分析（Principal Component Analysis, PCA）和典型相关分析（Canonical Correlation Analysis, CCA）的思想，将自变量 X 和因变量 Y 投影到新的空间中并建立线性回归模型^[98]。可去除共线性问题并且建立的模型包含全部

影像特征，广泛应用于农业领域。

2.4.3 支持向量机回归

支持向量机是以区间最大为原则的优化线性回归算法，其目的在于找到一个超平面，使样品在超平面的两个端点尽可能地离开超平面^[99]。在作物参数反演研究中表现较好，适用于小样本研究。支持向量机的回归算法，介绍了敏感度损失函数，将所述分类任务转化为回归任务。以减少运算复杂度，用网格搜索法解决了最小二乘的求解问题。本文通过网格搜索确定核函数和 γ 参数，其余参数保持预设。

2.4.4 决策树

决策树根据样本中不同特征的信息纯度构成树的每个节点，每个特征的响应在每个节点上形成不同的分支，输入样本数据流经整棵决策树并最终将结果输出到叶子结点^[100]。决策树是一种分类算法，其主要功能就是对已知或未知类别的模式进行识别和分类，它也可以用来处理非确定问题。常见决策树包括 ID3，CART 和 C4.5 等 3 种，在这些任务中，回归任务使用了 CART。由于目前决策树主要是通过对历史数据进行学习得到，因此需要一个专门针对训练样本集的分类器来辅助决策。对回归树进行训练的过程，也就是对数据集中各个特征进行递归遍历的过程，使当前的特征作为结点的 MSE 达到最小值。决策树是一种基于统计学习理论发展起来的分类方法，它可以利用训练样本和测试样本的相关性来构建分类器，从而提高预测准确率。决策树比较适合高维数据的处理，但如果树深，进而易引起过拟合，且忽略了不同特征之间的关联性。决策树构建模型时，对全部特征进行不纯度计算，特征的重要程度可以按不纯度的高低排列。

2.4.5 随机森林

随机森林算法是一种基于决策树和 Bagging 技术的集成学习算法^[101]。为了提高随机森林算法对复杂数据的分类性能，提出一种多特征融合的随机森林分类器方法，利用多个特征向量来描述原始数据和决策属性之间的关系，同时考虑到各特征的重要性程度。随机森林对原始数据集中任意两个点之间的距离都有一个最优解，且该最优解与原始变量间存在着某种关系。在随机森林算法内整合多株不同决策树，故有良好的抗过拟合能力，对大规模数据集还能高效地处理。

2.4.6 梯度提升回归树

梯度提升回归树算法是一种基于 CART 决策树及 Boosting 技术的集成学习算法，其串行设置每株树，且每一棵树的建立都需要依靠前一棵树产生的结果^[102]。该方法采用了并行化策略，即通过并行处理多个分类器来实现整个模型的构建。在具有 n 种样本 m 种特征数据集上，先初始化树，基于该树，以残差为真实值，对下树建模，重复上述步骤，完成全部树木的构建。该模型具有较好的泛化能力，能够解决多分类问题，但由于采用了大量冗余属性导致运算效率低、训练时间长。在测试数据的预测中，预测结果是每株树结果总和。

2.4.7 评价方法

本文采用的评价指标有相关系数（Correlation Coefficient, R ）用于分析各特征与产量相关性；决定系数（coefficient of determination, R^2 ）、均方根误差（Root Mean Square Error, RMSE）用于综合评价模型精确度。

相关系数 R 是统计学家 Karl Pearson 设计的统计学指标，反映两变量间线性相关程度，定义为两变量间的协方差与标准差之商，范围为 $[-1, 1]$ ， R 为 0 表明两组变量不相关， $|R|$ 越趋近 1 表明两变量间相关性越强，表达式为：

$$R = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y} = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sqrt{\sum_{i=1}^n (X_i - \mu_X)^2} \sqrt{\sum_{i=1}^n (Y_i - \mu_Y)^2}} \quad 2-6$$

决定系数 R^2 表示估测值与实测值的拟合程度，范围在 $[-\infty, 1]$ ， R^2 越趋近 1 则表明模型的估测结果越好，当 R^2 小于等于 0 时，表明模型预测样本效果很差。表达式为：

$$R^2 = 1 - \frac{\sum_i (y_i - f_i)^2}{\sum_i (y_i - \bar{y})^2} \quad 2-7$$

其中 f_i 表示第 i 个样本的预测值， $\bar{y}$ 为因变量均值， y_i 为因变量实测值。

均方根误差 RMSE 反映了估测值与实测值之间的误差，范围在 $[0, \infty]$ ，值越小，表明模型的性能越好，表达式为：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - f_i)^2} \quad 2-8$$

2.5 本章小结

这一章主要阐述研究区的概况，各类数据介绍，数据预处理流程方法，研究方法等四个大的组成部分。

第一篇为本研究试验设计之详细描述，包括时间，地点，对象及种植安排。

第二篇详细描述测试中所使用的无人机及传感器信息，以及在什么时间，什么地

点、环境下获取数据。

第三篇分别介绍了多光谱数据的预处理各个流程，包括辐射校正、影像拼接和裁剪等，选用 ROI 及其它步骤，植被指数计算及特征提取等。

第四篇是对本文所用研究方法进行了详细阐述，其中有 LR，PLSR 的方法、SVM 和 DT、RF 和 GBRT 算法，文中还给出了模型的评价指标。

第三章 研究内容与结果

随着现今无人机与多光谱传感器领域应用的不断深入，基于此进行农作物长势监测，高通量表型获取并对关键参数进行小麦产量反演，具有广阔的发展前景。经过多年的努力，这种植被指数已经成为一种成熟且应用广泛的植被指数。在此基础上，利用不同时期获取的遥感影像，进一步分析冬小麦生长状况及其主要生态因子，并将这些因素作为变量加入到产量计算模型当中，提高了模拟效率，使模型更具实用性。本文将上述四种不同尺度下得到的遥感反射率数据作为训练集，以试验区各小区实测脱粒后产量为输出变量，通过遗传算法优化参数，利用支持向量机回归技术建立冬小麦产量估测模型。

在此基础上，本文提出了一种改进的基于无人机遥感的小麦籽粒生产高效监测系统框架，并结合实际种植情况进行了比较分析，结果表明，根据无人机遥感信息，可实现较高精度小麦籽粒生产效率测算。在此基础上还可计算得到其他作物相应指标下的最优估产模型，不同的模型算法以及生育期、采样高度、输入特征等模型精度差异较大，因此需要对具体每个建模影响因素进行深入研究。另外，由于受天气影响较大，传统地面调查难以及时提供准确可靠的田间空间信息，因此利用无人机遥感技术开展精确农业试验成为当前重要发展方向之一。目前，我国已经有一些学者利用无人机航拍系统，在大范围农田区域内获得了高空间分辨率遥感影像，但是这些图像多为单幅或者小范围的地物，不能满足对大面积农作物生长信息进行实时监测的需要。随着近年来无人机技术的发展，多架无人植保机已经逐渐应用到田间地头作业，为我国精准农业提供了有力支撑。

本章利用大疆 M300 RTK 无人机在 30m、60m 两个飞行高度下采集试验区小麦冠层多光谱数据（厘米级像素），基于不同的数据特征，对植被指数，纹理特征进行了分析、综合了波谱信息和纹理特征与冬小麦产量进行相关性分析，分析试验区冬小麦产量估测模型在不同算法下的最佳时期，根据模型精度指标分析数据分辨率、特征参数对模型构建的影响。


3.1 试验区多光谱数据分析

3.1.1 波段信息分析

本文中覆盖研究区 290 块试验小区小麦冠层的每景多光谱影像包含 5 个波段。选择抽穗期研究区数据为示例，根据所选择 ROI，使用 ENVI 提取各试验小区不同时期的各波段反射率信息，并生成光谱曲线图（图 3-1）。

从图 3-1 中可见，不同小区光谱曲线呈现出十分明显的植被特性。波长接近 B 波

段，是类胡萝卜素强吸收带，反射率小于 10%；波长接近 G 波段是叶绿素强烈反射带，显示出曲线上显著反射峰；波长靠近 R 波段是叶绿素强烈吸收带，在曲线上显示出明显吸收谷；波长接近 RE 波段，植被光谱反射率剧增，其斜率多与叶绿素含量相关；波长介于 N 波段，是植被极强反射带。另外，图中光谱曲线还显示了波长为 B 波段的微小反射峰变化趋势，和波长 N 后呈现明显吸收谷趋势。






图 3-1 30m 高度下，12 个时期试验区波段信息（A、B、C、D、E、F、G、H、I、J、K、L 分别为 12 个时期波段信息图像）

Fig. 3-1 At a height of 30m, the band information of the 12 experimental areas in different periods (A, B, C, D, E, F, G, H, I, J, K, L are respectively the band information images of the 12 periods)

通过对不同试验区光谱曲线进行比较，发现，本研究中的试验小区多光谱数据中，波段光谱曲线差异主要集中在不可见光区域的红边、近红外波段。主要是因为小麦的最终产量与其功能叶中叶绿素含量密切相关，产量愈高，代表小麦功能叶的叶绿素含量愈高。

3.1.2 植被指数分析

计算原始多光谱影像的 40 种植被指数，以 2022 年度抽穗期 60m 高度 NDVI 指数为例，进行可视化，结果如图 3-2 所示。




图 3-2 多光谱影像各波段与 NDVI 对比图 (A、B、C、D、E、F 分别为 B, G, R, RE, N, 和 NDVI 波段)

Fig.3-2 Comparison of various bands of multispectral images with NDVI (A、B、C、D、E、F are respectively B, G, R, RE, N, and NDVI)

图 3-2 是根据影像反射率信息进行颜色渲染的结果, 颜色对比越强、越红表示该区域植被密度越大, 由此可知波段数据的原始图像中可发现的信息较少, 并且裸地与植被信息混合较多, 但 NDVI 的处理结果可以发现植被指数能够明显改善多光谱数据的结果, 增强植被表达, 提高多光谱数据在建模中的应用性。





图 3-3 12 个时期试验区小麦 NDVI 变化趋势

Fig.3-3 Trend of NDVI changes of wheat in 12 experimental periods

本小节计算试验区 12 个时期的 NDVI 特征在不同小麦品种下的趋势对比,结果如图 3-3 所示。由图可知整体走势,各小区内 NDVI 特征值变化趋势相同,但是 NDVI 值在各品种之间有微小的差别,且差异部分变化规律性不强,因此,可以依此来发掘各种特征参数和产量的相关性,建立反演模型。

3.1.3 纹理特征分析

计算原始影像中每幅影像 R、G、B、N、RE 五通道的纹理特征值共 40 种,以 2022 年度抽穗期 60m 高度影像为例,进行可视化,结果如图 3-4 所示。






图 3-4 多光谱五波段纹理特征处理结果 (A、B、C、D、E 为 B、G、R、RE、N 处理结果，A-7 分别为为 Me、Var、Hom、Con、Dis、Ent、Sec 和 Cor)

Figure 3-4 Multispectral five band tTexture feature processing results (A, B, C, D, E represent B, G, R, RE, N processing results, and A-7 represent Me, Var, Hom, Con, Dis, Ent, Sec, and Cor, respectively)

由图 3-4 可以看出，各个通道的 8 个纹理特征结果差异较大，其中 R、G、B 三个可见光通道中冬小麦与裸地边界不明显，其中 R 通道纹理特征结果最难区分冬小麦与

裸地，B 通道次之，G 通道最强，与冬小麦颜色反射特征规律相符，该时期冬小麦呈现较强的绿色反射，红、蓝光强吸收；相比较 N、RE 通道纹理特征结果可明显观察到各小区冬小麦与裸地边界，其中 N 通道结果质量较好。且各通道纹理特征差异较大，反应出不同的数据特征。因此将多光谱数据纹理特征作为模型输入参数对冬小麦产量预测研究可行性高。

3.2 特征筛选

3.2.1 波段信息与产量相关性及其重要性分析

使用多光谱影像五通道特征与试验区冬小麦产量进行皮尔逊相关性分析以及使用随机森林算法计算影像特征权重然后排序，多光谱五通道波段信息与产量相关系数及权重如下表 3-1 和 3-2 所示。

表 3-1 60m 高度波段信息与试验区小麦产量相关系数及重要性

Table 3-1 Correlation coefficient and importance of 60m height band information with wheat yield in experimental area

波段信息、60m、2022 年		B	G	N	RE	R
4 月 9 日	相关性	-.352**	-.122*	.341**	-.152**	-.376**
	权重	25.7	3.7	29.4	6	34.9
4 月 12 日	相关性	-.346**	-.125*	.343**	-.154**	-.374**
	权重	24.3	2.3	18.3	8	47.1
4 月 18 日	相关性	-.350**	-.122*	.338**	-.153**	-.373**
	权重	33.1	1.6	22	5	38.1
4 月 23 日	相关性	-.349**	-.123*	.340**	-.151**	-.368**
	权重	27.9	2.7	21.3	4	43.4
5 月 1 日	相关性	-.348**	-.121*	.339**	-.151*	-.372**
	权重	33.3	2.3	21.5	9	33.6
5 月 6 日	相关性	-.348**	-.121*	.336**	-.152**	-.370**
	权重	23.3	2.3	19.3	4	51.1
5 月 11 日	相关性	-.344**	-.121*	.334**	-.149*	-.369**
	权重	31.1	2.3	20.8	3.6	41.9
5 月 16 日	相关性	-.348**	-.122*	.335**	-.151**	-.373**
	权重	20.5	2.2	20.5	5.7	51
5 月 21 日	相关性	-.348**	-.122*	.335**	-.152**	-.368**
	权重	26	3.2	22	7.6	41.1
5 月 24 日	相关性	-.345**	-.123*	.332**	-.151*	-.359**

5 月 28 日	权重	20.6	3.5	23.6	6	45.3
	相关性	-.348**	-.116*	.339**	-.142*	-.364**
6 月 1 日	权重	50.3	2.3	21	7	19.1
	相关性	-.352**	-.122*	.339**	-.147*	-.273**
	权重	43.3	3.3	23	8	21

从表 3-1 可知, 60m 高度下 12 个时期当中, 除了 G、RE 波段信息, 其余 3 种波段信息均与小麦产量在所有时期显示出极显著相关, 其中 R 波段信息与小麦产量负相关性最强, 相关系数为-0.376, 其中 RE 波段信息在 5 月 1 日、11 日、24 日、28 日和 6 月 1 日五个时期中显示出显著性, 其余时期显示出与冬小麦的极显著相关。根据权重系数, 5 个特征对模型均有贡献, 其中 R 波段权重系数最大, 表示共线性最多, G 波段权重系数最小, 权重累计包含 95%信息的优选特征组合为 R、B、N、RE 共计 4 个特征, 即此 4 个特征已经包含了全部特征总信息的 95%, 因此用这 4 个特征建立 60m 下基于波段信息的多元回归模型, 可以避免特征冗余并节省计算量。

表 3-2 30m 高度波段信息与试验区小麦产量相关系数及重要性

Table 3-2 Correlation coefficient and importance of 30m height band information with wheat yield in experimental area

波段信息、30m、2022 年		B	G	N	RE	R
4 月 9 日	相关性	-.377**	-.136*	.279**	-0.003	-.185*
	权重	39.88	8.04	30.74	1.98	19.37
4 月 12 日	相关性	-.356**	-.144*	.287**	-0.009	-.174*
	权重	38.94	9.3	30.53	2.05	19.18
4 月 18 日	相关性	-.371**	-.135*	.267**	-0.006	-.172*
	权重	40.02	7.96	30.6	2.04	19.38
4 月 23 日	相关性	-.368**	-.137*	.278**	-0.002	-.191*
	权重	38.44	8.99	31.27	2.08	19.23
5 月 1 日	相关性	-.364**	-.140*	.272**	-0.002	-.169*
	权重	40.28	8.17	30.35	1.97	19.24
5 月 6 日	相关性	-.364**	-.133*	.261**	-0.005	-.166*
	权重	41.45	7.52	29.92	1.94	19.17
5 月 11 日	相关性	-.347**	-.135*	.257**	0.002	-.162*
	权重	40.26	8.24	29.68	2.37	19.46
5 月 16 日	相关性	-.364**	-.136*	.262**	-0.005	-.177*
	权重	41.29	7.78	29.81	1.98	19.14

5 月 21 日	相关性	-.364**	-.138*	.260**	-0.009	-.176*
	权重	42.15	7.64	29.2	1.99	19.02
5 月 24 日	相关性	-.355**	-.139*	.252**	-0.025	-.182*
	权重	47.55	5.6	27.12	1.68	18.05
5 月 28 日	相关性	-.363**	-.123*	.281**	0.023	-.149*
	权重	38.17	9.41	30.42	2.01	19.99
6 月 1 日	相关性	-.378**	-.136*	.273**	0.005	-0.111
	权重	39.02	19.25	28.78	2.02	10.93

从表 3-2 可知, 30m 高度下 12 个时期当中, 各波段信息与冬小麦产量相关性与 60 高度下结果有所差异, B、N 波段信息在完整 12 个时期中均与小麦产量呈极显著相关, 其中 B 波段信息呈现极显著负相关, 最大相关系数为-0.378, N 波段信息的最大相关系数为 0.287, 剩余 G、R 波段信息中, 除 R 波段在 6 月 1 日是其中显示出无相关性, 其余时期中均显示显著相关性, RE 波段信息完整 12 个时期中均无相关性。5 个特征对于模型的建立均有贡献, 其中权重最大的特征为 B, 5 月 21 日时权重系数最大为 42.15%, 权重系数最小的特征为 RE, 权重系数总和达到 95%的最优特征组合为 R、B、G、N 共计 4 个特征, 即此 4 个特征已经包含了全部特征总信息的 95%, 因此用这 4 个特征建立 30m 下基于波段信息的多元回归模型, 可以避免特征冗余并节省计算量。

3.2.2 植被指数与产量相关性及其重要性分析

使用多光谱影像 40 种植被指数与试验区冬小麦产量进行皮尔逊相关性分析以及使用随机森林算法计算影像特征重要性然后排序, 40 种植被指数与产量相关系数及重要性筛选结果如下表 3-3 和 3-4 所示。

表 3-3 60m 高度植被指数与试验区小麦产量相关系数及重要性

Table 3-3 Correlation coefficient and importance of vegetation index at 60m height and wheat yield in experimental area

优选植被指数 60m	409		412		418	
	相关性	权重	相关性	权重	相关性	权重
NGBDI	.256**	8.75			.253**	7.77
BRRI	-.273**	32.19			-.263**	34.04
MCARI	.349**	50.38	.421**	16.25	.326**	50.33
VREI1	.272**	5.40	.434**	14.34		

RENDVI			.439**	65.43		
b					-.250**	4.69
优选植被指数 60m	423	501	506			
	相关性	权重	相关性	权重	相关性	权重
BRRI	-.253**	4.16	-.232**	5.27	-.266**	33.22
MCARI	.360**	51.05	.353**	52.34	.338**	51.08
VREI1	.292**	34.04	.278**	31.18	.261**	8.13
b					-.239**	4.89
ARI2	.254**	8.16				
CARI			.240**	8.24		
优选植被指数 60m	511	516	521			
	相关性	权重	相关性	权重	相关性	权重
MCARI	.343**	51.65	.371**	52.53		
VREI1	.268**	34.29	.310**	31.13		
ARI2	.224**	4.93			.197*	14.60
CARI	.230**	6.87	.276**	8.48		
TVI			.263**	5.08		
r					.214**	15.94
b					-.187*	4.33
BRRI					-.316**	62.13
优选植被指数 60m	524	528	601			
	相关性	权重	相关性	权重	相关性	权重
MCARI	.395**	13.19				
VREI1	.391**	4.09			.430**	18.56
ARI2			.336**	4.65	.414**	3.15
CARI	.408**	18.00	.387**	59.34	.424**	13.85
RENDVI	.431**	61.82	.368**	23.98	.436**	61.81
TVI			.364**	10.02		

从表 3-3 可知, 60m 高度下, 各时期与小麦产量呈现极显著相关的植被指数类型不一致, 且相关系数与重要性也有差异, 相同的植被指数在不同时期与产量相关性的重要性均有不同的变化。12 个时期中与小麦产量极显著相关且贡献度达 95% 的植被指数共有 9 个: NGBDI、BRRI、MCARI、VERI1、RENDVI、ARI2、CARI、TVI、b、r。其中 VERI1 在 9 个时期中显示出与小麦产量的及显著相关, MCARI 在 8 个时期中

显示出与小麦产量的极显著相关, 其中 RENDVI 在 4 月 12 数据中与小麦产量相关系数最大为 0.439, 权重系数 65.43%, 且该时期达到 95% 的指数组合为 3 种, 其余时期权重系数 95% 的指数组合均有四种植被指数。根据结果在不同时期均选择权重系数总和达到 95% 的最优特征组合, 建立 60m 高度下基于植被指数的小麦产量预测模型, 避免特征冗余并节省计算量。

表 3-4 30m 高度植被指数与试验区小麦产量相关系数及重要性

Table 3-4 Correlation coefficient and importance of vegetation index at 30m height and wheat yield in experimental area

优选植被指数、30m、2022 年		MCARI	RENDVI	VREI1	CARI	ARI2
4 月 9 日	相关性	.486**	.489**	.484**	.375**	
	权重	19.12	55.24	14.46	7.32	
4 月 12 日	相关性	.420**	.472**	.468**		.385**
	权重	14.11	59.77	19.43		4.8
4 月 18 日	相关性	.486**	.480**	.475**	.372**	
	权重	54.78	19.78	13.79	7.79	
4 月 23 日	相关性	.445**	.485**	.478**		.396**
	权重	14.12	58.23	19.11		4.91
5 月 1 日	相关性	.475**	.495**	.489**	.373**	
	权重	13.91	55.49	19.76	7.39	
5 月 6 日	相关性	.474**	.493**	.488**	.370**	
	权重	14.3	56.6	19.02	6.42	
5 月 11 日	相关性	.462**	.498**	.492**		.386**
	权重	13.13	57.51	19.35		6.72
5 月 16 日	相关性	.446**	.497**	.490**		.398**
	权重	14.38	56.52	19.66		5.76
5 月 21 日	相关性	.438**	.493**	.487**		.411**
	权重	13.74	57.88	19.63		5.35
5 月 24 日	相关性	.414**	.476**	.469**		.418**
	权重	4.03	57.88	19.74		14.87
5 月 28 日	相关性	.383**	.436**	.426**		.415**
	权重	3.89	58.16	14.7		20.54
6 月 1 日	相关性		.400**	.388**	.377**	.414**
	权重		21.09	15.3	3.58	56.59

从表 3-4 可知, 30m 高度下, 各时期与小麦产量呈现极显著相关的植被指数类型大致相同, 与 60m 下植被指数与小麦产量相关性与重要性筛选结果不一致, 且总体相关性结果均高于 60m 结果, 12 个时期中与小麦产量极显著相关且贡献度达 95% 的植被指数共有 5 个: MCARI、VERI1、RENDVI、ARI2、CARI。各个植被指数在不同时期相关性与重要性结果分布结果类似, 除 5 月 11 日与 6 月 1 日外, 其余时期中 RENDVI 均显示出与小麦产量的及显著相关且权重系数在各指数中为最大, 5 月 11 日相关系数最大为 0.498, 权重系数为 57.51。其中 RENDVI、VERI1 在 12 个时期中显示出与小麦产量的极显著相关, MCARI 在 11 个时期中显示出与小麦产量的极显著相关, 在 30m 高度下, 12 个时期权重系数 95% 的指数组合均为 4 种植被指数。根据结果在不同时期选择权重系数总和达到 95% 的最优特征组合, 建立 30m 高度下基于植被指数的小麦产量预测模型, 避免特征冗余并节省计算量。

3.2.3 纹理特征与产量相关性及其重要性分析

使用多光谱影像 5 通道纹理特征结果共 40 种与试验区冬小麦产量进行皮尔逊相关性分析以及使用随机森林算法计算影像特征重要性然后排序, 40 种纹理特征与产量相关系数及重要性筛选结果如下表 3-5 和 3-6 所示。

表 3-5 60m 高度纹理特征与试验区小麦产量相关系数及重要性

Table 3-5 Correlation coefficient and importance of texture characteristics at 60m height and wheat yield in experimental area

优选纹理特征 60m	yield in experimental area					
	4 月 9 日		4 月 12 日		4 月 18 日	
	相关性	权重	相关性	权重	相关性	权重
N_Cor	-.862**	74.278			-.798**	7.013
N_Con			-.999**	68.524		
N_Var			-.995**	31.47		
N_Ent					-.853**	22.147
N_Sec					.865**	68.343
R_Hom	.735**	16.132				
R_Con	-.735**	7.512				
优选纹理特征 60m	4 月 23 日		5 月 1 日		5 月 6 日	
	相关性	权重	相关性	权重	相关性	权重
N_Cor			-.686**	58.725	-.659**	74.943
N_Con			-.524**	24.094		
N_Ent			-.537**	15.001		
N_Sec					.657**	16.692
N_Dis	.656**	6.348				
N_Hom					.657**	8.365
B_Hom	.605**	4.223				

G_Var	.661**	88.844				
优选纹理特征 60m	5 月 11 日		5 月 16 日		5 月 21 日	
	相关性	权重	相关性	权重	相关性	权重
N_Var	-.777**	16.132	-.624**	88.419		
N_Ent	-.772**	7.512				
N_Cor	-.785**	74.278				
N_Hom			.586**	4.271	.694**	78.203
N_Con			-.595**	6.348	-.68**	7.12
N_Dis					-.689**	12.344
优选纹理特征 60m	5 月 24 日		5 月 28 日		6 月 1 日	
	相关性	权重	相关性	权重	相关性	权重
B_Cor	.970**	84.021	.487**	7.867		
R_Con	-.565**	6.509				
R_Cor	.613**	8.39			-.863**	7.103
R_Me			-.454**	3.607		
RE_Cor			-.608**	87.071	-.970**	60.394
G_Ent					.936**	8.12
G_Sec					-.946**	24.383

从表 3-5 可知, 60m 高度下, 各时期与小麦产量呈现极显著相关的纹理特征差异较大, 且相关系数与重要性也有差异, 各个时期中与小麦产量呈现极显著相关系数最大特征与贡献度达 95% 的纹理特征组合结果差异也较大。各波段纹理特征中 Cor 在不同时期均有极显著相关, 其中 4 月 12 日中 N_Con 与小麦产量极显著负相关性最高为 -0.999, 贡献度为 68.52%, 且该时期贡献度 95% 纹理特征组合为两种, 6 月 1 日贡献度 95% 组合纹理特征为 4 种, 其余时期与小麦产量极显著相关且贡献度 95% 的纹理特征组合均为 3 种。根据结果在不同时期均选择权重系数总和达到 95% 的最优特征组合, 建立 60m 高度下基于纹理特征的小麦产量预测模型, 避免特征冗余并节省计算量。

表 3-6 30m 高度纹理特征与试验区小麦产量相关系数及重要性

Table 3-6 Correlation coefficient and importance of texture characteristics at 30m height and wheat yield in experimental area

优选纹理特征 30m	4 月 9 日		4 月 12 日		4 月 18 日	
	相关性	权重	相关性	权重	相关性	权重
R_Hom	.866**	66.11			-.497**	17.968
R_Dis	-.864**	27.936			.489**	7.886
R_Ent	-.859**	5.077			.465**	5.84
N_Var			-.822**	11.979		
N_Dis			-.812**	7.62		
N_Ent			-.839**	20.798		
B_Cor					.567**	68.306
RE_Sec			-.891**	59.604		
优选纹理特征 30m	4 月 23 日		5 月 1 日		5 月 6 日	

	相关性	权重	相关性	权重	相关性	权重
N_Dis			-.652**	6.688		
N_Ent					-.887**	21.235
N_Cor			-.674**	72.135	-.801**	4.667
N_Hom			.652**	17.329		
N_Sec					.898**	72.767
G_Hom	.983**	27.862				
G_Dis	-.984**	54.96				
RE_Con	-.974**	11.482				
RE_Dis	-.969**	5.696				
优选纹理特征 30m	5月11日		5月16日		5月21日	
	相关性	权重	相关性	权重	相关性	权重
N_Hom	.882**	17.094			.683**	78.214
N_Dis	-.874**	5.528	-.718**	4.06	-.678**	13.852
N_Cor	-.893**	75.129			-.677**	6.016
N_Var			-.764**	85.916		
N_Con			-.751**	8.739		
优选纹理特征 30m	5月24日		5月28日		6月1日	
	相关性	权重	相关性	权重	相关性	权重
RE_Con	-.784**	82.377				
RE_Dis	-.631**	5.812				
RE_Cor	-.661**	7.352				
RE_Hom					-.741**	7.108
G_Con			-.569**	7.614		
G_Ent					.853**	20.725
G_Sec					-.865**	9.162
R_Hom					-.817**	63.005
R_Con			-.807**	80.274		
B_Con			-.806**	10.158		

从表 3-6 可知, 30m 高度下, 纹理特征与小麦产量相关性与重要性结果与 60m 高度下各时期与小麦产量呈现极显著相关的纹理特征结果分布有相同规律, 各时期呈现显著性相关的纹理特征差异较大且权重分布不同, 其中 4 月 23 日 G_Dis 特征与小麦产量极显著负相关系数最大为-0.984, 权重系数 54.96%。4 月 12 日、18 日、23 日、6 月 1 日数据种纹理特征与小麦产量及显著相关且权重系数达 95%组合有 4 种, 其余时期均为 3 种。根据结果在不同时期选择权重系数总和达到 95%的最优特征组合, 建立 30m 高度下基于植被指数的小麦产量预测模型, 避免特征冗余并节省计算量。

3.3 不同高度下冬小麦产量最佳单一时期模型构建

3.3.1 基于波段信息的冬小麦产量最佳单一时期模型构建

根据上文特征相关性和重要性考虑筛选影像波段信息构建冬小麦产量估测模型。针对不同高度下处理结果使用与冬小麦产量极显著相关且权重系数达 95% 的波段信息组合构建 12 个时期下基于波段信息的冬小麦估测模型。60m 高度选用 R、B、N、RE 四个波段信息作为输入参数，30m 高度选用 R、G、B、N 四个波段信息作为输入参数。

比较分析表明，这几种算法在处理相同问题时，得到的研究结果也有一些不同。其中，支持向量机就是其中之一、在机器学习领域中，决策树和随机森林是三种常用的算法，随机森林和梯度提升树算法均基于集成的学习方法，均以决策树为基学习器，且随机森林算法为基于 Bagging 原则的，梯度提升树算法基于 Boosting 原理。

模型建立具体的流程如下：

- (1) 利用网格搜索算法以及 10 折交叉验证在训练集上对比模型参数寻优，并结合得到的评分进行模型参数的筛选；
- (2) 依据参数结果重新设置模型参数并在训练集上重新训练；
- (3) 根据第 2 步训练得到的模型在验证集上进行评价，得到最终的评分。

表 3-7 60m 高度下基于波段信息小麦产量估测模型精度结果

时期/模型		LR	PLSR	SVM	DT	RF	GBRT
4 月 9 日	R ²	0.315	0.326	0.617	0.583	0.707	0.661
	RMSE	0.285	0.269	0.238	0.257	0.197	0.222
4 月 12 日	R ²	0.309	0.312	0.607	0.572	0.705	0.65
	RMSE	0.298	0.287	0.244	0.26	0.199	0.224
4 月 18 日	R ²	0.343	0.359	0.627	0.587	0.719	0.669
	RMSE	0.255	0.245	0.217	0.244	0.187	0.215
4 月 23 日	R ²	0.341	0.354	0.624	0.581	0.71	0.661
	RMSE	0.264	0.258	0.228	0.248	0.193	0.215
5 月 1 日	R ²	0.334	0.323	0.618	0.589	0.713	0.659
	RMSE	0.263	0.265	0.25	0.241	0.194	0.224
5 月 6 日	R ²	0.343	0.347	0.621	0.579	0.716	0.668
	RMSE	0.264	0.261	0.228	0.248	0.192	0.216
5 月 11 日	R ²	0.366	0.384	0.632	0.616	0.72	0.684
	RMSE	0.246	0.239	0.209	0.25	0.179	0.205
5 月 16 日	R ²	0.354	0.367	0.642	0.62	0.729	0.697
	RMSE	0.233	0.215	0.211	0.214	0.172	0.203
5 月 21 日	R ²	0.345	0.32	0.64	0.619	0.728	0.692

5月24日	RMSE	0.233	0.217	0.211	0.209	0.174	0.206
	R ²	0.368	0.385	0.642	0.616	0.723	0.68
5月28日	RMSE	0.245	0.231	0.208	0.211	0.178	0.207
	R ²	0.359	0.397	0.623	0.612	0.718	0.693
6月1日	RMSE	0.234	0.237	0.221	0.22	0.186	0.205
	R ²	0.39	0.358	0.614	0.61	0.715	0.671
	RMSE	0.248	0.246	0.225	0.231	0.183	0.214

表 3-8 30m 高度下基于波段信息小麦产量估测模型精度结果

Table 3-8 Precision results of wheat yield estimation model based on waveband information at a height of 30m

时期/模型		LR	PLSR	SVM	DT	RF	GBRT
4月9日	R ²	0.321	0.332	0.619	0.589	0.713	0.667
	RMSE	0.282	0.265	0.233	0.253	0.194	0.221
4月12日	R ²	0.319	0.325	0.613	0.584	0.715	0.658
	RMSE	0.291	0.282	0.241	0.257	0.196	0.222
4月18日	R ²	0.352	0.362	0.629	0.599	0.722	0.672
	RMSE	0.252	0.241	0.213	0.244	0.184	0.211
4月23日	R ²	0.339	0.361	0.627	0.596	0.715	0.668
	RMSE	0.258	0.254	0.222	0.246	0.191	0.214
5月1日	R ²	0.337	0.361	0.624	0.59	0.718	0.663
	RMSE	0.259	0.262	0.22	0.24	0.188	0.216
5月6日	R ²	0.353	0.359	0.627	0.592	0.72	0.67
	RMSE	0.254	0.257	0.225	0.243	0.187	0.212
5月11日	R ²	0.375	0.391	0.634	0.619	0.723	0.688
	RMSE	0.235	0.232	0.204	0.205	0.177	0.201
5月16日	R ²	0.361	0.377	0.646	0.626	0.735	0.702
	RMSE	0.238	0.211	0.208	0.21	0.167	0.197
5月21日	R ²	0.352	0.356	0.643	0.624	0.73	0.697
	RMSE	0.231	0.243	0.21	0.218	0.172	0.203
5月24日	R ²	0.373	0.385	0.645	0.625	0.728	0.686
	RMSE	0.243	0.235	0.204	0.215	0.174	0.203
5月28日	R ²	0.366	0.393	0.625	0.621	0.725	0.694
	RMSE	0.241	0.233	0.211	0.216	0.177	0.202
6月1日	R ²	0.36	0.363	0.619	0.613	0.722	0.677

RMSE	0.244	0.228	0.219	0.223	0.181	0.212
------	-------	-------	-------	-------	-------	-------

结果如表 3-7、3-8 所示，可以看出，在不同高度不同时期下，普通线性回归算法和偏最小二乘的回归算法比较，决定系数明显低于其他算法，或许是因为这两种算法都相对简单，拟合能力较弱，所以它的精度明显比其他算法低。SVM 算法适合小样本学习，不适合大规模数据集的训练，本章的实验样本量与小样本的样本量一致（本章样本量为 1827），从而达到比较理想的效果。另外，本文还研究了不同核函数对预测准确率的影响，结果表明径向基核函数比其它几种核有更好的泛化能力。决策树算法计算结果显著小于 RF 与 GBRT 算法，也许在多种树型算法，集成学习算法包括基学习器（决策树），所以最后取得的结果也将比简单决策树算法要好。还研究了基于 Bagging 原则的随机森林和 GBRT 算法，随机森林算法在 $R^2=0.735$ 和 $RMSE=0.167$ 的情况下取得了最好的性能，这是由于基于 Bagging 原理的算法能够有效地降低模型的方差，使得模型的鲁棒性增强，这在样品很小的情况下，与 Boosting 原则算法相比，在特征量较小的情况下取得了更好的结果。另外随机森林算法在训练集数据上有很强的适应性，所以随机森林算法比 GBRT 算法更准确。总之，本研究仅选择 SVM，DT 和 RF、GBRT 方法建立模型。

3.3.2 基于植被指数的冬小麦产量最佳单一时期模型构建

根据上文特征相关性和重要性考虑筛选影像植被指数构建冬小麦产量估测模型。针对不同高度下处理结果选用与冬小麦产量极显著相关且权重系数达 95% 的植被指数组合构建 12 个时期下基于植被指数的冬小麦估测模型。各高度下不同时期选用的最优植被指数组合不同，60m 高度下最优组合为 BRRI、MCARI、VERI1、RENDVI、ARI2、CARI、TVI、b，30m 高度下最优组合为 MCARI、VERI1、RENDVI、ARI2、CARI。本节模型构建与训练方法上文，根据前文结果，选取 SVM、DC、RF、GBRT 进行模型构建。

表 3-9 60m 高度下基于植被指数小麦产量估测模型精度结果

Table 3-9 Precision results of wheat yield estimation model based on vegetation index at a height of 60m

时期/模型		SVM	DT	RF	GBRT
4 月 9 日	R^2	0.604	0.587	0.708	0.626
	RMSE	0.196	0.234	0.17	0.178
4 月 12 日	R^2	0.604	0.582	0.707	0.625
	RMSE	0.193	0.239	0.17	0.183
4 月 18 日	R^2	0.611	0.589	0.713	0.632
	RMSE	0.191	0.231	0.168	0.175

4月23日	R^2	0.612	0.588	0.709	0.631
	RMSE	0.187	0.234	0.168	0.177
5月1日	R^2	0.613	0.593	0.717	0.636
	RMSE	0.185	0.225	0.155	0.172
5月6日	R^2	0.619	0.599	0.718	0.649
	RMSE	0.183	0.205	0.154	0.171
5月11日	R^2	0.626	0.601	0.723	0.651
	RMSE	0.181	0.204	0.15	0.165
5月16日	R^2	0.623	0.605	0.725	0.65
	RMSE	0.181	0.202	0.148	0.168
5月21日	R^2	0.624	0.6	0.722	0.652
	RMSE	0.182	0.203	0.15	0.167
5月24日	R^2	0.62	0.601	0.721	0.653
	RMSE	0.182	0.204	0.151	0.165
5月28日	R^2	0.617	0.598	0.715	0.648
	RMSE	0.184	0.217	0.156	0.171
6月1日	R^2	0.615	0.595	0.714	0.635
	RMSE	0.184	0.22	0.162	0.173

从表 3-9 可以看出, 60m 高度下, 综合 12 个时期的结果, 基于优选的 3-4 种植被指数构建的冬小麦产量估测模型中, RF 模型估测精度在各个时期均为最佳, 最高为 $R^2=0.725$, $RMSE=0.148$, DT 结果最差, 整体结果分布规律与基于波段信息构建的冬小麦产量预测模型结果相似。从时期上看, 各个模型表现出一致的结果分布规律, 模型精度较高时期分布在 5 月 6 日至 5 月 24 日, 整体精度表现为随时间先增高后下降的趋势, 模型精度最高时期为 5 月 16 日, RF 模型 $R^2=0.725$, $RMSE=0.148$, 最低的时期为 4 月 11 日, DT 模型 $R^2=0.582$, $RMSE=0.239$ 。

表 3-10 30m 高度下基于植被指数小麦产量估测模型精度结果

Table 3-10 Precision results of wheat yield estimation model based on vegetation index at a height of

		30m			
时期/模型		SVM	DT	RF	GBRT
4月9日	R^2	0.612	0.586	0.715	0.664
	RMSE	0.194	0.222	0.159	0.173
4月12日	R^2	0.613	0.586	0.715	0.66
	RMSE	0.194	0.225	0.159	0.175
4月18日	R^2	0.613	0.594	0.719	0.669

4 月 23 日	RMSE	0.192	0.216	0.158	0.17
	R ²	0.614	0.588	0.716	0.668
5 月 1 日	RMSE	0.191	0.221	0.159	0.173
	R ²	0.614	0.595	0.725	0.675
5 月 6 日	RMSE	0.19	0.212	0.15	0.169
	R ²	0.621	0.601	0.725	0.679
5 月 11 日	RMSE	0.187	0.203	0.148	0.164
	R ²	0.628	0.604	0.737	0.685
5 月 16 日	RMSE	0.178	0.197	0.142	0.16
	R ²	0.626	0.615	0.75	0.683
5 月 21 日	RMSE	0.179	0.191	0.137	0.161
	R ²	0.626	0.609	0.732	0.684
5 月 24 日	RMSE	0.179	0.195	0.145	0.159
	R ²	0.625	0.613	0.729	0.688
5 月 28 日	RMSE	0.181	0.192	0.146	0.157
	R ²	0.62	0.597	0.723	0.678
6 月 1 日	RMSE	0.188	0.203	0.152	0.165
	R ²	0.616	0.595	0.722	0.67
	RMSE	0.189	0.208	0.157	0.17

从表 3-10 可以看出, 30m 高度下, 综合 12 个时期的结果, 基于优选的 3-4 种植被指数构建的冬小麦产量估测模型中, 各个模型表现出与 60m 高度结果一致的规律, RF 为各时期的最佳模型, 且整体精度高于 60m 结果, 与基于波段信息构建的冬小麦产量预测模型结果呈现一致的规律, 且模型精度随时期结果分布规律与前文获得的结果一致, 总体均为随时间增加模型精度先增高后下降的趋势。模型精度最高时期分布在 5 月 6 日至 24 日之间, 其中 5 月 16 日预测模型结果最好, RF 模型 $R^2=0.75$, RMSE=0.137。

3.3.3 基于纹理特征的冬小麦产量最佳单一时期模型构建

根据上文特征相关性和重要性考虑筛选影像纹理特征构建冬小麦产量估测模型。针对不同高度下处理结果选用与冬小麦产量极显著相关且权重系数达 95% 的纹理特征组合构建 12 个时期下基于纹理特征的冬小麦估测模型。各高度下不同时期选用的最优纹理特征组合不同, 60m 高度下最优组合为 N_Con, N_Var, N_Cor, N_Sec, N_Hom, B_Cor, R_Con, R_Cor, 30m 高度下最优组合为 N_Var, N_Dis, N_Ent, RE_Sec,

N_Cor, N_Sec, RE_Con, RE_Cor, RE_Dis。本节模型构建与训练方法根据前文结果,选取 SVM、DC、RF、GBRT 进行模型构建。

表 3-11 60m 高度下基于纹理特征小麦产量估测模型精度结果

Table 3-11 Precision results of wheat yield estimation model based on texture features at a height of 60m

时期/模型		SVM	DT	RF	GBRT
4 月 9 日	R ²	0.601	0.585	0.71	0.631
	RMSE	0.224	0.249	0.175	0.205
4 月 12 日	R ²	0.6	0.587	0.69	0.636
	RMSE	0.225	0.243	0.178	0.201
4 月 18 日	R ²	0.605	0.593	0.717	0.645
	RMSE	0.217	0.241	0.166	0.194
4 月 23 日	R ²	0.605	0.592	0.712	0.637
	RMSE	0.217	0.242	0.173	0.2
5 月 1 日	R ²	0.611	0.595	0.719	0.649
	RMSE	0.211	0.241	0.154	0.191
5 月 6 日	R ²	0.614	0.601	0.725	0.656
	RMSE	0.211	0.23	0.148	0.189
5 月 11 日	R ²	0.617	0.608	0.726	0.659
	RMSE	0.21	0.22	0.14	0.189
5 月 16 日	R ²	0.629	0.603	0.728	0.664
	RMSE	0.2	0.228	0.138	0.185
5 月 21 日	R ²	0.627	0.604	0.726	0.665
	RMSE	0.206	0.227	0.14	0.185
5 月 24 日	R ²	0.624	0.606	0.724	0.663
	RMSE	0.209	0.22	0.152	0.186
5 月 28 日	R ²	0.608	0.599	0.719	0.652
	RMSE	0.212	0.24	0.161	0.189
6 月 1 日	R ²	0.607	0.598	0.718	0.638
	RMSE	0.216	0.24	0.162	0.197

从表 3-11 可以看出, 60m 高度下, 综合 12 个时期的结果, 基于优选的 3-4 种纹理特征构建的冬小麦产量估测模型中, RF 模型估测精度在各个时期均为最佳, 最高为 $R^2=0.728$, $RMSE=0.138$, DT 结果最差, 整体结果分布规律与前文获得结果相似。从时期上看, 各个模型表现出一致的结果分布规律, 各个模型精度较高时期分布略有不同, 但总体高精度时期均在 5 月 6 日至 5 月 24 日, 整体精度表现为随时间先增高后下

降的趋势,模型精度最高时期为 5 月 16 日,最低的时期为 4 月 9 日,DT 模型 $R^2=0.585$, $RMSE=0.249$ 。

表 3-12 30m 高度下基于纹理特征小麦产量估测模型精度结果

Table 3-12 Precision results of wheat yield estimation model based on texture features at a height of 30m

时期/模型		SVM	DT	RF	GBRT
4 月 9 日	R^2	0.613	0.586	0.725	0.64
	RMSE	0.218	0.243	0.171	0.199
4 月 12 日	R^2	0.61	0.587	0.722	0.646
	RMSE	0.219	0.243	0.172	0.199
4 月 18 日	R^2	0.614	0.594	0.731	0.647
	RMSE	0.215	0.231	0.159	0.196
4 月 23 日	R^2	0.613	0.588	0.73	0.646
	RMSE	0.217	0.236	0.17	0.199
5 月 1 日	R^2	0.621	0.595	0.733	0.655
	RMSE	0.203	0.231	0.147	0.194
5 月 6 日	R^2	0.623	0.605	0.737	0.666
	RMSE	0.203	0.227	0.146	0.194
5 月 11 日	R^2	0.625	0.62	0.739	0.671
	RMSE	0.201	0.221	0.143	0.194
5 月 16 日	R^2	0.634	0.608	0.74	0.674
	RMSE	0.197	0.224	0.142	0.187
5 月 21 日	R^2	0.627	0.61	0.738	0.675
	RMSE	0.198	0.223	0.144	0.183
5 月 24 日	R^2	0.625	0.618	0.735	0.672
	RMSE	0.198	0.222	0.147	0.192
5 月 28 日	R^2	0.621	0.6	0.732	0.656
	RMSE	0.207	0.23	0.149	0.194
6 月 1 日	R^2	0.616	0.597	0.731	0.647
	RMSE	0.213	0.231	0.151	0.198

从表 3-12 可以看出, 30m 高度下, 综合 12 个时期的结果, 基于优选的 3-4 种纹理特征构建的冬小麦产量估测模型中, 各个模型表现出与 60m 高度结果一致的规律, RF 为各时期的最佳模型, 且整体精度高于 60m 结果, 与前文模型结果呈现一致的规律。且模型精度随时期结果分布规律与前文获得的结果一致, 总体均为随时间增加模型精度先增高后下降的趋势。模型精度最高时期分布在 5 月 6 日至 24 日之间, 其中 5

月 16 日预测模型结果最好, RF 模型 $R^2=0.74$, $RMSE=0.142$ 。

3.4 生育期确定

由于不同时期遥感图像所包含的地物类型各不相同, 因此在利用这些影像获取作物信息时需要考虑其变化过程及其影响因素。与单时相遥感比较, 多时序遥感可以定量获得作物各生育期内的生长情况, 丰富了估产模型所需特征, 从而提高模型鲁棒性。同时由于其具有较好的时空相关性以及较强的预测能力等优势而成为当前国内外遥感应用的热点领域之一。因此, 基于时间序列数据的作物估产研究得到了更多的学者的选择。

目前在农作物生产管理中应用较广泛的是利用多时相多源遥感技术进行估产预测。如刘焕军^[106]仅根据 NDVI 进行了作物产量估测, 与其他研究不同的是, 作者深挖生育期信息, 对 NDVI 时间序列的构成算法进行优化, 综合比较了新算法和产量的相关性, 获得了较好的结果。王雪等^[107]利用 MODIS 标准产品数据, 对多种农作物产量进行预测, 重点突出 EVI 时间序列数据对作物产量预测模型的贡献。由于作物生长期间存在着复杂的光谱特征变化, 利用遥感图像对其监测时往往受到地物反射特性的限制。因此, 有必要通过一定的处理手段去除干扰信息, 提高农作物遥感技术应用水平。

总之, 多期生育信息构成的时间序列图像, 收录了作物生长过程中的综合信息, 可充实估产模型所需的特点, 从而提高了预测精度。因此, 本节将按照冬小麦生育期的角度对所得到的 12 个期多光谱影像进行分类, 依据各个生育期的组合情况, 构建估产模型, 以期更准确地估计小麦产量。

与小麦产量关系密切的生育期有拔节期 (Jointing Stage) 和抽穗期 (Heading Stage)、灌浆期 (Filling Stage) 和成熟期 (Ripening Stage) 四个阶段, 不同生育期常表现出不同特征与规律, 但生育期划分决定于全田全部小麦发育比率, 一般情况下, 当田块中 50% 以上小麦进入关键生育期时, 就认为田块已达到相应生育期。与各生育期相对应的生育期特征及具体划分根据见表 3-13, 将多光谱数据与小麦生育期分割依据相结合, 筛选并分割 2021-2022 年无人机成像多光谱影像数据, 获取不同关键生育期小麦影像数据, 为后续多生育期小麦估产提供参考。

表 3-13 小麦关键生育期分类表

Table 3-13 Classification of the key growth periods of Wheat

小麦关键生育期	划分依据
拔节期	小区内 50% 以上植株茎部第 1 节间露出地面 1-2 厘米。
抽穗期	小区内 50% 以上植株麦穗的 1/2 露出叶鞘时。

灌浆期

籽粒开始发育，体积变大，颜色由绿转黄，淀粉沉积。

成熟期

叶片、茎秆枯黄，籽粒变硬。

3.5 不同生育期构建小麦产量估测模型

小麦植株在各生育期呈现疏密程度差异，无人机的图像特征也会随着生育期的进展而呈现出显著不同的特征，所以，讨论不同生育期在产量反演模型中的作用，有很大研究意义。以 2021-2022 年陕西省杨凌示范区 30m 高度下拔节期拍摄、抽穗期及灌浆期、成熟期以多光谱影像为数据源，每张图像含有 290 个小麦试验小区，每个小区内含有 9 个 ROI，最后，获得 2610 个的样本数据，各样品基于 ROI 提取了 4 个优选波段的信息组合，3-4 种植被指数、纹理特征的优选组合，用于冬小麦产量估算模型的建立。

为了综合考虑生育期对模型的贡献，并分析其与产量的相关性，在这一章中，所有样本数据根据生育期（拔节期、抽穗期、灌浆期、成熟期）被分成 4 组，对样本进行随机处理，按 7:3 分成训练集（1827 个样本）与测试集（783 个样本）。同时，为了全面判断不同机器学习算法对基于多光谱影像特征的小麦产量反演任务的性能，不同算法之间关系与文中 3.3.1 部分相同。本节各种算法构建模型具体过程与 3.3.1 部分相同，评价指标采用决定系数 R^2 ，RMSE 等。

3.5.1 基于波段信息的冬小麦产量最佳生育期组合模型构建

基于前文波段信息与小麦产量相关性与重要性分析结果，30m 高度下各个时期中，权重系数总和达到 95% 的最优单波段组合为 R、B、G、N 共计 4 个特征，表示其包含了模型建立的主要贡献特征，可科学的避免数据冗余，建立 30m 下基于波段信息的冬小麦产量最佳生育预期组合模型。

根据所采集的无人机多光谱影像数据时期，结合实际试验小区小麦生长发育情况，本节对所分类的 4 个关键生育期中具体时期进行选择，依据前文各时期不同模型预测结果，选取每个关键生育期中相应模型精度最高的时期作为该生育期的代表时期进行生育期组合。

表 3-14 综合多生育期信息基于波段信息的小麦产量估测模型精度结果

Table 3-14 Precision results of wheat yield estimation model based on waveband information and integrating multiple growth period information

生育期/模型	SVM		RF		GBRT	
	R^2	RMSE	R^2	RMSE	R^2	RMSE
S1、S2	0.64	0.2	0.723	0.148	0.713	0.154

S1、S3	0.647	0.197	0.73	0.144	0.719	0.149
S1、S4	0.64	0.2	0.724	0.147	0.716	0.149
S2、S3	0.654	0.187	0.759	0.14	0.731	0.144
S2、S4	0.644	0.198	0.739	0.141	0.718	0.149
S3、S4	0.648	0.191	0.743	0.141	0.72	0.147
S1、S2、S3	0.658	0.184	0.777	0.133	0.749	0.141
S1、S2、S4	0.654	0.189	0.745	0.141	0.722	0.145
S1、S3、S4	0.655	0.185	0.76	0.135	0.743	0.143
S2、S3、S4	0.665	0.181	0.778	0.132	0.757	0.135
S1、S2、S3、S4	0.66	0.182	0.764	0.135	0.752	0.136

注：S1、S2、S3、S4 分别表示拔节期、抽穗期、灌浆期、成熟期

由表 3-14 可知,综合了生育期信息的冬小麦产量预测模型精度要显著高于单一时期的预测结果,本文所选用的三个模型精度均有不同程度的提高,证明了本试验方法的可行性。其中 RF 模型表现出最好的精度,GBRT 模型次之,SVM 精度最差。从生育期的角度看,综合了两个时期的模型精度整体高于单一时期预测结果,其中以拔节期和灌浆期的模型精度最高,RF 森林模型双生育期最高 $R^2=0.759$, $RMSE=0.14$,综合了 3 个生育期的模型精度整体高于 2 个生育期的模型精度,最高为综合抽穗期、灌浆期、成熟期信息的 RF 模型, $R^2=0.778$, $RMSE=0.132$,但并不是时期越多模型精度就一定高。在 RF 和 GBRT 模型中,综合了抽穗期和灌浆期的模型精度高于综合拔节期、抽穗期和成熟期的模型结果,在三类模型的预测结果中都表现出,结合了抽穗期、灌浆期、成熟期的模型预测精度高于综合所有时期的模型精度。

3.5.2 基于植被指数的冬小麦产量最佳生育期组合模型构建

基于前文 40 种植被指数与小麦产量相关性与重要性分析结果,30m 高度下各个时期中,最优植被指数组合为 MCARI、RENDVI、VREI1 和 CARI 共计 4 个特征,基于此构建 30m 下基于植被指数的冬小麦产量最佳生育预期组合模型。

根据所采集的无人机多光谱影像数据时期,结合实际试验小区小麦生长发育情况,本节对所分类的 4 个关键生育期中具体时期进行选择,依据前文各时期不同模型预测结果,选取每个关键生育期中相应模型精度最高的时期作为该生育期的代表时期进行生育期组合。

表 3-15 综合多生育期信息基于植被指数的小麦产量估测模型精度结果

Table 3-15 Precision results of wheat yield estimation model based on vegetation index and integrating multiple growth period information

生育期/模型	SVM		RF		GBRT	
	R ²	RMSE	R ²	RMSE	R ²	RMSE
S1、S2	0.669	0.177	0.76	0.13	0.741	0.129
S1、S3	0.672	0.171	0.766	0.127	0.743	0.128
S1、S4	0.669	0.18	0.757	0.13	0.743	0.128
S2、S3	0.685	0.165	0.783	0.126	0.77	0.124
S2、S4	0.671	0.174	0.762	0.129	0.759	0.126
S3、S4	0.676	0.171	0.781	0.127	0.761	0.124
S1、S2、S3	0.684	0.166	0.806	0.117	0.792	0.116
S1、S2、S4	0.68	0.168	0.783	0.123	0.775	0.123
S1、S3、S4	0.7	0.164	0.784	0.119	0.781	0.121
S2、S3、S4	0.704	0.161	0.808	0.112	0.798	0.11
S1、S2、S3、S4	0.703	0.163	0.8	0.119	0.797	0.11

由表 3-15 可知, 基于优选植被指数组合的小麦产量估测模型在综合了生育期信息后, 模型精度要显著高于单一时期的预测结果, 本文所选用的 3 个模型精度均有不同程度的提高, 证明了本试验方法的可行性, 并且基于植被指数组合构建的模型精度高于基于波段信息构建的模型精度。RF 模型仍表现出最好的精度, GBRT 模型次之, SVM 精度最差, GBRT 模型精度相比较前文模型有明显提升, RF 模型精度提升较小。从生育期的角度看, 综合了拔节期和灌浆期信息在双生育期建模时的模型精度最高为 RF 模型 $R^2=0.783$, $RMSE=0.126$, 综合了 3 个生育期的模型精度整体高于 2 个生育期的模型精度, 最高为综合抽穗期、灌浆期、成熟期信息的 RF 模型, $R^2=0.808$, $RMSE=0.112$ 。与此同时, 在 3 类模型的预测结果中都表现出, 结合了抽穗期、灌浆期、成熟期的模型预测精度高于综合所有时期的模型精度。

3.5.3 基于纹理特征的冬小麦产量最佳生育期组合模型构建

基于前文纹理特征与小麦产量相关性与重要性分析结果, 30m 高度下各个时期中, 权重系数总和达到 95% 的最优特征组合在不同时期差异较大。根据所采集的无人机多光谱影像数据时期, 结合实际试验小区小麦生长发育情况, 本节对所分类的 4 个关键生育期中具体时期进行选择, 依据前文各时期不同模型预测结果, 选取每个关键生育期中相应模型精度最高的时期作为该生育期的代表时期进行生育期组合, 不同模型选取的生育期时期与纹理特征优选组合结果见下表。

表 3-16 综合多生育期信息基于纹理特征的小麦产量估测模型精度结果

Table 3-16 Precision results of wheat yield estimation model based on texture features based on

comprehensive multiple growth period information						
生育期/模型	SVM		RF		GBRT	
	R ²	RMSE	R ²	RMSE	R ²	RMSE
S1、S2	0.654	0.182	0.744	0.139	0.725	0.145
S1、S3	0.653	0.189	0.738	0.14	0.727	0.145
S1、S4	0.654	0.186	0.749	0.139	0.731	0.133
S2、S3	0.67	0.174	0.767	0.134	0.754	0.132
S2、S4	0.663	0.182	0.75	0.136	0.738	0.133
S3、S4	0.665	0.179	0.759	0.134	0.744	0.132
S1、S2、S3	0.669	0.174	0.798	0.126	0.763	0.128
S1、S2、S4	0.667	0.177	0.774	0.131	0.759	0.13
S1、S3、S4	0.67	0.174	0.781	0.127	0.76	0.129
S2、S3、S4	0.675	0.171	0.8	0.120	0.784	0.125
S1、S2、S3、S4	0.674	0.172	0.799	0.121	0.774	0.127

由表 3-16 可知,综合了多个生育期的基于纹理特征进行小麦产量预测模型精度结果高于单一时期,与本文前两节试验结果呈现高度一致,针对于不同的模型结果也呈现出同样结果。基于纹理特征的冬小麦产量预测模型整体精度处于 4.2.1 与 4.2.2 小节 2 个试验模型精度之间,其中 RF 模型仍表现出最好的精度,GBRT 模型次之,SVM 精度最差。从生育期的角度看,综合了 2 个时期的模型精度整体高于单一时期预测结果,其中以拔节期和灌浆期的模型精度最高,RF 森林模型双生育期最高 $R^2=0.767$, $RMSE=0.134$,综合了 3 个生育期的模型精度整体高于 2 个生育期的模型精度,最高为抽穗期、灌浆期、成熟期组合的 RF 模型, $R^2=0.8$, $RMSE=0.12$ 。

3.6 基于不同特征组合的小麦产量估测模型构建

在前面研究的基础上,无人机多光谱影像可以较好地有效地预测小麦产量,但是也有缺陷,小麦产量估测只采用多光谱影像单一特征,模型精度易饱和。此外,由于遥感数据具有较小的冗余性、不完备性及不确定性等特点,使得传统方法在提取农作物特征参数方面往往面临较大困难。针对这一问题,许多学者引入作物株高,纹理特征,并分别与光谱特征相结合,对作物参数进行估计,取得较为理想的结果。与作物的株高相比,纹理信息更具有多面性,能体现图像灰度属性及空间位置关系,与光谱信息相结合,可以较好地削弱单纯使用植被指数反演作物产量所产生的低估现象,增强估算模型适用性等^[110]。因此,本文提出一种基于多光谱遥感数据与纹理特征提取的方法来研究小麦产量预测技术。

目前主要是利用高光谱及多光谱对小麦产量进行估测。刘畅等用的是无人机的高光谱影像^[111]，对光谱特征进行了对比分析、纹理特征及两者组合对冬小麦 AGB 预估精度的影响表明，将光谱特征与纹理特征结合起来，可以很好地解决产量估算中过早饱和的现象，并且模型的估算效果要好于单一光谱特征或者单一纹理特征。Zheng 等人^[112]根据无人机的多光谱影像进行研究，利用光谱信息以及光谱信息与纹理特征相结合的两类变量来估计水稻产量，结果表明用后者作为输入变量，可以较好地估测产量。基于无人机多光谱影像，Liu 等^[113]认为，采用偏最小二乘法与随机森林 2 种方法相结合的方法提取光谱特征、利用光谱特征和纹理特征进行油菜 AGB 估算，经比较发现 2 种方法利用融合指标所建立的模型是有效的。纹理特征提取非常依赖于影像的分辨率，文中选择采样高度为 30m，收集到的信息地面分辨率较高，从而可以得到更加细致和丰富的纹理特征，对这一章的研究提供了可行性。且根据前文结果发现，融合多种特征的模型表现出更好的预测精度，因此本节根据前人研究结合本文精度评价结果，选择融入纹理特征和波谱信息进行模型构建。

不同模型输入特征的预测精度结果差异较大，但仅限于单一特征进行模型构建容易出现精度饱和现象。以 2021-2022 年度在陕西省杨凌示范区拍摄的 30m 高度下抽穗期、灌浆期和成熟期组合的多光谱影像作为数据源，数据样本数同第三章样本提取结果，每个样本根据 ROI 分别提取 4 种优选波段信息组合、4 种植被指数、纹理特征优选组合进行冬小麦产量估测模型构建。

为了全面评估不同模型输入特征在小麦产量反演中的作用，甄别出小麦产量估测最佳模型特征参数，并建立基于此优选组合的最佳小麦产量估测模型，在本章中，所有样本数据根据其特点被划分为 3 组，分别为波段信息，纹理信息和植被指数，把样本顺序打乱，按 7:3 随机分成训练集（1827 个样本）与测试集（783 个样本），为了全面判断不同机器学习算法对基于多光谱影像特征的小麦产量反演任务的性能，不同算法之间关系与文中 3.3.1 部分相同。本节，使用了支持向量机，随机森林等技术、梯度提升树和其他机器学习算法构建了小麦产量反演的不同模型，比较了不同算法之间的区别，同时确定了最优模型，具体过程与 3.3.1 部分相同，评价指标采用决定系数 R^2 ，RMSE 等。

表 3-17 多生育期基于特征组合的小麦估产模型精度结果

Table 3-17 Precision results of wheat yield estimation model based on feature combination for multiple growth stages

特征组合/模型	SVM		RF		GBRT	
	R^2	RMSE	R^2	RMSE	R^2	RMSE
C1、C2	0.68	0.165	0.803	0.119	0.805	0.114
C1、C3	0.683	0.165	0.852	0.108	0.873	0.106

C2、C3	0.711	0.158	0.879	0.105	0.906	0.097
C1、C2、C3	0.708	0.162	0.893	0.101	0.927	0.091

注：C1、C2、C3 分别为波段信息、植被指数、纹理特征

模型精度结果如表 3-17，从结果可以看出，基于多种特征类型的小麦估产模型精度更高，其中 GBRT 模型表现出最高的精度， $R^2=0.927$ ， $RMSE=0.091$ ，RF 次之，SVM 较差。这与前文结果呈现类似规律，结合多生育期和多种光谱特征类型能够有效提高小麦产量预测模型的精度，进一步分析精度结果可知，波段信息与植被指数均基于图像反射率，数据类型表达信息相似，融合纹理特征后模型精度显著提高。今后在农作物产量估测方面，可以重点考虑不同类型数据特征融合。

3.7 小结

本章以 2021-2022 年度陕西省杨凌示范区农作一站所种植的小区试验中小麦 12 个时期分别在 60m、30m 拍摄得到的多光谱影像为数据源，提取传感器五通道单波段光谱信息，并进行各波段的纹理特征提取，随后对每幅图像计算 40 种植被指数，共计 85 种特征，根据数据特性定性研究，证实了依托无人机平台搭载多光谱传感器进行微小小区小麦产量估测的数据应用型强。经过特征相关性分析筛选，得到了 4 个优选波段的信息特征，以及 3-4 个植被指数和纹理特征优选组合在不同的时期、不同生育期、与 LR, PLSR, SVM, DT, RF 和 GBRT 算法等相结合构建小麦产量估算的回归模型，研究结果表明：

(1) 针对不同高度下优选波段信息组合不同，但在各个时期表现出一致的相关性结果，60m 高度选择 R、B、N、RE，30m 高度选择 R、B、G、N；针对不同高度和不同时期下优选的植被指数和纹理特征各有不同，并无统一结果，在建模时，根据时期和高度不同应选择不同的优选特征组合；

(2) 在本文所选取的 3 类多光谱影像特征中，波段信息特征构建模型时精度较差，植被指数特征模型精度最好；

(3) 在 12 个时期中，综合各个模型评价结果发现，在两个高度下模型精度较高结果均分布在 5 月 6 日至 5 月 24 日时期之间，采样高度为 30m，确定 MCARI、RENDVI、VREI1、ARI2 共 4 种植被指数特征作为输入，建立随机森林回归模型作为产量反演模型，模型 R^2 达到 0.75， $RMSE$ 为 0.137；

(4) 综合生育期进行小麦产量预测模型构建时，采样高度为 30m，各个模型均在结合抽穗期、灌浆期、成熟期的植被指数特征构建的模型精度最好，确定 MCARI、RENDVI、VREI1、ARI2 共 4 种植被指数作为优选组合，其中 RF 模型最高 $R^2=0.808$ ， $RMSE=0.112$ ；

(5) 于 30m 高度下, 结合抽穗期、灌浆期、成熟期小麦影像数据, 融合优选波段信息组合、植被指数组合于纹理特征组合, 基于 GBRT 算法构建的小麦产量预测模型精度最高, $R^2=0.934$, $RMSE=0.085$, 证明了本文研究方法的可行性, 后续将开展多年份多时相影像特征研究。

第四章 讨论

4.1 不同算法构建模型影响分析

根据本文的线性模型和五种机器学习模型在不同高度下获得的各类输入特征构建冬小麦产量预测模型精度评价结果表可以看出,传统线性回归方法在连续值的产量预测方面呈现出不如机器学习模型精准,这与赵鑫等^[104]的研究结果一致。一般的线性算法模型比较简单,对非线性数据或数据特征之间存在相关性的多项式回归,建模比较困难,很难对高度繁杂的资料进行良好的表示,拟合精度较低。在所选机器学习模型中,DT模型精度低于SVM、RF与GBRT模型,其中RF模型精度在不同时期不同输入特征条件下均为最高。根据陶惠林等的研究结果^[51],SVM模型预测结果较一般,与本文初步得到的结果有所差异,分析可知,SVM回归模型与概率测度和大数定律基本没有关系,所以与已有统计方法有所不同。实质上回避了由归纳向演绎过渡的传统程序,在训练样本和预报样本之间进行高效“转导推理”,极大地简化了一般分类,回归等操作,不适用于大规模数据集样本进行模型构建,对本章样本量1827个有很好的训练效果和模型精度,故取得了较好的精度。RF模型的结果与大多研究者结果高度一致,RF和GBRT基于集成学习的算法由基学习器组成,故效果优于决策树模型。其中RF模型是基于Bagging算法,先将训练集分离成多个子集,然后通过各个子集训练多个模型,在过程中有效平衡数据间误差,增强模型数据鲁棒性,GBRT模型基于Boosting算法,训练多个模型并组成一个序列,每个模型都会修正前一个模型的错误,适应于大量样本训练,在本章样本量小,特征参数少的情况下RF模型取得较优的评价结果。

4.2 不同高度对模型构建的影响分析

进一步结合30m、60m高度下构建的模型结果表可以看出,各模型在30m高度下精度总体高于60m,各个模型在不同高度均获得了类似的结果,例如RF模型在30m、60m高度下预测精度最高的时期均为5月16日。在基于波段信息小麦产量估测模型方法评价结果中,60m高度所有模型在全部时期的评价结果均低于30m高度。在基于植被指数的模型精度结果中有所不同,DT模型在4月9日和5月28日60m高度下模型精度更高,其余模型在30m高度下精度均高于60m。在基于纹理特征的模型精度结果中,DT模型在4月23日的60m高度下精度更高,其余模型均在所有时期的30m高度下精度更高。

产生以上结果的原因可能是,高度的降低会大大改变图像分辨率。本文选取30m

高度可获得高于 1cm 的地面分辨率，更高的分辨率会丰富图像的信息，植被指数可以更加精准的表现植被状态，纹理特征细节更全面，各个特征的相关性结果也显示出此规律，30m 高度下各类特征总体相关性均高于 60m。上述结果也出现在王妮^[55]等的研究中，根据分析研究数据共性可发现，更低的高度会带来更高的地面分辨率，具有更加丰富精准的图像信息，在构建模型时具有更高的精度。但是当在实际采集数据的过程中高度并不是越低越好，多光谱传感器一般需要多旋翼无人机承载，飞行高度过低时机翼高速旋转会影响小麦冠层发生摆动，无法捕捉到稳定的冠层图片数据，且在相同采集面积下，高度的降低会成倍的增加数据采集的时间与难度，并且后期处理数据量大、难度高，不利于后期模型建立，这是其一；同时高度的大幅度降低会提高数据采集的时间与经济成本，在实际数据采集过程中需要权衡影像分辨率和采样成本的双重影响。根据本章试验结果，本文选取 30m 高度作为优选高度进行冬小麦产量模型构建。

4.3 不同生育期组合对模型构建的影响分析

结合基于三类不同特征的小麦产量估测模型精度结果可知，本章所选用的三类模型在结合了生育期信息后，模型精度均高于单一时期的模型精度，且三类精度结果分布在生育期组合上有一致规律，在结合不同生育期时，并不是选用的时期越多越好，根据双时期结果可知，综合了抽穗期、灌浆期的模型精度普遍高于其他时期组合，此种规律在结合三种生育期特征的模型结果中也出现，表现为抽穗期、灌浆期、成熟期三个生育期信息的模型精度最高。可知拔节期与成熟期在基于机器学习模型进行小麦产量预测时相关性较弱。

本章试验结果与 Fei S 等人研究结果一致，灌浆期数据均在模型构建时明显提高结果精度，且生育期组合的模型精度结果更好^[53]。造成以上 4 个关键生育期差异结果的原因可能是，在拍摄数据结果后，植被在波谱信息和纹理特征中与裸地的区别并不明显，特别是不同时期叶片、麦穗的形态特征与裸地在数据中占比不同，根据无人机图像所提取出的特征中，含有以上几种物体的综合特征。小麦在进入灌浆期后，小麦群体的叶面积最大、光合作用最强；并且灌浆期无人机图像提取特征最稳定，这样就能综合有效地反演小麦产量。拔节期小麦群体密度小于灌浆期、叶面积小而裸土面积大，造成拔节期无人机影像提取特征干扰因素增加，无法全面有效反映小麦的自身特征，所以模型精度比灌浆期精度要低。小麦成熟后，当小麦叶片发黄时，植株之间的空隙增大，造成群体裸土面积扩大，各小麦品种冠层间群体特征相差不大，所以估产效果变差。综合起来看抽穗期总体、灌浆期无人机图像能有效表达小麦长势差异，所建产量反演模型的准确性也是最高的，所以，第五章还选取了抽穗期、灌浆期与成熟期为最佳生育期，开展了相关建模与反演分析的研究工作。

4.4 不同采样尺度对模型构建的影响

在前文的研究结果中，ROI 的选择原则是尺寸均匀，尽量全面覆盖小区，但因种植密度不均匀，存在边际效应等原因^[114]，将导致实际测得产量和小区整体平均情况不符。因此，在这一部分的研究中，使用 Python 语言编写代码，将原 ROI 以 100%、90%、80%、...、10% 的不同大小的 ROI 比例进行选择，为探讨不同采样尺度对产量反演模型的影响。为了弥补这一不足，需要建立一个能有效反映作物各生育期特征及规律的多源遥感技术融合方法来实现小麦估产。图 4-1 示例分别为原始包含所有信息 ROI、50%比例、20%比例示意图。




图 4-1 不同采样尺度图

Fig. 4-1 Different sampling scale maps

表 4-1 不同 ROI 尺度下小麦估产模型精度结果

Table 4-1 Precision results of wheat yield estimation models at different sampling scales

精度/采样尺度	10%	20%	30%	40%	50%	60%	70%	80%	90%	100%
R ²	0.723	0.713	0.815	0.839	0.899	0.889	0.917	0.934	0.923	0.927
RMSE	0.143	0.157	0.119	0.117	0.101	0.103	0.097	0.085	0.093	0.091

针对不同采样尺度进行 ROI 提取，获取优选特征，综合前面的成果，选综合抽穗期、灌浆期与成熟期的信息，构建 GBRT 回归模型，评价指标采用决定系数 R^2 和 RMSE。本文主要通过对各数据集的分析来验证所构建模型在实际中应用的有效性和可行性，并最终确定出最优模型参数组合方案。不同采样尺度和 GBRT 模型精度计算结果见表 4-1。随着 ROI 覆盖范围的扩大，模型性能表现为先增大后减小的趋势。一方面，由于 ROI 覆盖范围的增加，范围包含的信息也逐渐丰富，比较利于建立模型，因此模型表现为逐渐变优；另一方面则因为面积较大且覆盖较全面的区域内各网格点之间距离较近，因此模型对其内部信息的获取较为容易，因而模型的性能也相对比较理想。另一方面在 ROI 覆盖范围得到进一步拓展的情况下，田畦边缘部分也逐渐列入计算，受“边际效应”的影响，田畦边缘部分生长往往参差不齐，对建立的模型反而有干扰作

用，因此，模型表现逐渐变优，继而又逐渐下降。从表 4-1 中可以看出，ROI 尺度比例为 80% 时建立的模型性能最佳。

4.5 小结

本章对不同的模型构建方法、生育期、采样高度、采样尺度进行讨论，研究各类因素在构建小麦产量估测模型中的影响，结果显示：

（1）各模型在结合了生育期信息、融合多种特征进行冬小麦产量估测模型构建精度均明显高于单一时期结果，但并不是选取的生育期数目越多模型精度越高；

（2）所有选用的模型中，基于决策树算法的 RF 和 GBRT 模型对本研究适应性较好，精度最高；

（3）相比于波段信息和植被指数，结合纹理特征进行小麦产量估测模型建立能够有效提高模型精度。

（4）采样高度与尺度在一定程度上影像模型精度，30m 高度下，80% 的采样尺度可以获得更高的模型精度。

第五章 结论

5.1 小结

农作物产量收获前的无损估测是智慧农业领域的重要研究课题，关系到农业现代化和数字化发展进程。本文研究了基于复合特征下的冬小麦产量估测模型，利用大疆经纬 M300 RTK 无人机搭载多光谱相机 RedEdge-MX，拍摄得陕西省杨凌示范区 2021-2022 年度小麦拔节期、抽穗期、灌浆期、成熟期 4 个生育期 12 个时期的试验区 290 个微小区小麦多光谱影像数据，并在小麦成熟收获后由育种研究工作人员进行各个小区的小麦产量测定，获取不同小区的小麦品种实际产量，根据多光谱影像数据进行小麦产量估测研究，结果如下：

(1) 多光谱搭载平台选择大疆 M300RTK 四旋翼无人机，使用 RedEdge-MX 多光谱传感器获取试验区冬小麦各个小区 4 个关键生育期的多光谱数据，基于多种多光谱影像特征进行不同算法小麦估产模型的建立。首先，无人机影像经预处理后提取 5 种波段信息及每个波段 8 种纹理特征作为特征参数，计算与小麦生长以及产量相关的植被指数 40 种，然后利用相关性与权重分析各种特征获取建模参数优选特征组合，然后根据 LR、PLSR、SVM、DT、RF 和 GBRT 算法建立冬小麦产量估测模型，其中，RF 模型精度最高 ($R^2=0.75$)，且 RMSE 最低；同时，探讨了不同算法对模型构建方法的影响，以及不同高度对模型构建的影响，结果表明 5 月 16 日以 30m 为采样高度下 RF 小麦估产模型精度最高，最优波段组合为 B、G、R、N；最优植被指数组合为 MCARI、VERI1、RENDVI、ARI2；最优纹理特征组合为 N_Dis、N_Var、N_Con。

(2) 对于不同生育期以及不同模型输入特征，本文融合了不同生育期数据，选取适应小样本量的 SVM 模型，与 2 类基于决策树的不同算法建立微小区水平下冬小麦产量估测模型。研究发现，抽穗期、灌浆期、成熟期数据信息结合后，以 MCARI、VERI1、RENDVI、ARI2、CARI 植被指数组合作为输入参数的 RF 算法模型的决定系数 R^2 最高，达到了 0.808，且 RMSE 最低，分析发现选取更多的关键生育期组合对模型建立并不会有益。其次，选取最佳高度，最佳生育期组合利用 SVM、RF 和 GBRT 算法建立不同输入参数的模型，根据评价结果发现综合纹理特征与所有波谱信息优选组合 (B、G、R、N、MCARI、VERI1、RENDVI、ARI2、CARI、N_Var、N_Dis、N_Ent、RE_Sec、N_Cor、N_Sec、RE_Con、RE_Cor、RE_Dis) 的 GBRT 算法构建模型的决定系数最高 $R^2=0.934$ ，同时 $RMSE = 0.085$ 。最后，根据不同 ROI 尺度的选取对模型精度的影响研究，发现 80% 采样尺度下模型性能最佳，结果精度最高。

5.2 展望

本文基于无人机遥感技术，利用多光谱传感器获取小麦冠层影像数据进行小麦产量估测研究，探讨了不同分辨率、生育期、光谱特征以及建模算法对小麦产量估测模型构建的影响，取得了一定研究成果，但根据结果显示仍有一些不足及缺漏之处。

（1）从传感器来看，多光谱处理步骤多，基于不同时期进行数据采集处理量大，并没有对比 RGB 影像数据的建模精度，下一步可探究基于可见光数据多个生育期综合分析。

（2）本文研究区只设置了一种水分梯度和施肥梯度，没有进行多种水分梯度和施肥梯度对比，后续的研究可以增加水分和施肥梯度，进行对比分析研究。

（3）近几年，多源遥感影像结合热传感器温度和雷达信息渐渐兴起，后续若有条件，可以结合更多种传感器数据进行研究。

（4）目前，深度学习算法以及 AI 智能发展迅猛，探究新的作物估产研究方向，是论文后续可以持续跟进的内容，以实现精准农业的创新突破性进展。

参考文献

- [1] 中华人民共和国统计局.中国统计年鉴[M].北京: 中国统计出版社,2022.
- [2] 杨丽. 遥感技术在精准农业中的现状及发展趋势[J]. 农业与技术, 2019, 39(16): 21-22.
- [3] Deng L., Mao Z., Li X., et al. UAV-based multispectral remote sensing for precision agriculture: A comparison between different cameras[J]. *ISPRS journal of photogrammetry and remote sensing*, 2018, 146: 124-136.
- [4] Maes W. H., Steppe K. Perspectives for remote sensing with unmanned aerial vehicles in precision agriculture[J].*Trends in plant science*, 2019, 24(2): 152-164.
- [5] Colomina I, Molina P. 2014. Unmanned aerial systems for photogrammetry and remote sensing: A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 92:79-97.
- [6] Weiss M, Jacob F, Duveiller G. 2020. Remote sensing for agricultural applications: A meta-review. *Remote Sensing of Environment*, 236:111402.
- [7] Gago J, Douthe C, Coopman R E, Gallego P P, Ribas-Carbo M, Flexas J, Escalona J, Medrano H. 2015a. UAVs challenge to assess water stress for sustainable agriculture. *Agricultural Water Management*, 153:9-19.
- [8] Zhang D., Zhou X., Zhang J., et al. Developing a small UAV platform to detect sheath blight of rice[A]. *International Geoscience and Remote Sensing Symposium (IGARSS)*. IEEE, 2017: 3190-3193.
- [9] Holman F., Riche A., Michalski A., et al. High throughput field phenotyping of wheat plant height and growth rate in field plot trials using UAV based remote sensing[J]. *Remote Sensing*, 2016, 8(12): 1031.
- [10] Li W., Yuan H., Song L. Prediction of wheat gains with imagery from four-rotor UAV[A]. *2016 2nd IEEE International Conference on Computer and Communications (ICCC)*[C]. IEEE, 2016: 662-665.
- [11] 汪小钦, 王苗苗, 王绍强, 等. 基于可见光波段无人机遥感的植被信息提取[J]. 农业工程学报, 2015, 31(5): 152-159.
- [12] Liu T., Li R., Jin X., et al. Evaluation of seed emergence uniformity of mechanically sown wheat with UAV RGB imagery[J]. *Remote Sensing*, 2017, 9(12): 1241.
- [13] Feng Q., Liu J., Gong J. UAV remote sensing for urban vegetation mapping using random forest and texture analysis[J]. *Remote sensing*, 2015, 7(1): 1074-1094.
- [14] 郭鹏, 武法东, 戴建国, 等. 基于无人机可见光影像的农田作物分类方法比较[J]. 农业工程学报, 2017, 33(13): 112-119.
- [15] De Castro A. I., Torres-Sánchez J., Peña J. M., et al. An automatic random forest-OBIA algorithm for early weed mapping between and within crop rows using UAV imagery[J]. *Remote Sensing*, 2018, 10(2): 285.
- [16] 殷飞, 金世佳. 2015. 遥感在农业旱情监测中的应用现状与展望. 干旱环境监测, 29(02):87-92.
- [17] 吴炳方, 蒙继华, 李强子. 国外农情遥感监测系统现状与启示[J]. 地球科学进展, 2010, 25(10):1003-1012.
- [18] Wu, Meng, Li, Yan, Du, Zhang. Remote sensing-based global crop monitoring: experiences with China's CropWatch system[J]. *International Journal of Digital Earth*, 2014, 7(2).
- [19] 王蕾, 王鹏新, 李俐, 等.应用条件植被温度指数预测县域尺度小麦单产[J]. 武汉大学学报(信

- 息科学版), 2018, 43(10):1566-1573.
- [20] Moriondo M, Maselli F, Bindi M. A simple model of regional wheat yield based on NDVI data[J]. *European Journal of Agronomy*, 2007, 26: 266-274.
- [21] 薛利红, 曹卫星, 罗卫红, et al. 光谱植被指数与水稻叶面积指数相关性的研究[J]. 植物生态学报, 2004(01):50-55.
- [22] Barnett T L, Thompson D R. Large-Area Relation of Landsat MSS and NOAA-6 AVHRR Spectral Data to Wheat Yields[J]. *Remote Sensing of Environment*, 1983, 13(4): 277-290
- [23] M. Anjum Iqbal, Yanjun Shen, Ruzica Stricevic, et al. Evaluation of the FAO AquaCrop model for winter wheat on the North China Plain under deficit irrigation from field experiment to regional yield simulation[J]. *Agricultural Water Management*, 2014, 135.
- [24] 王涛, 吕昌河, 于伯华. 基于 WOFOST 模型的京津冀地区冬小麦生产潜力评价[J]. 自然资源学报, 2010, 25(03):475-487.
- [25] Jianmei Ji, Huanjie Cai, Jianqiang He, Hongjie Wang. Performance evaluation of CERES-Wheat model in Guanzhong Plain of Northwest China[J]. *Agricultural Water Management*, 2014, 144.
- [26] 王亚莉, 贺立源. 作物生长模拟模型研究和应用综述[J]. 华中农业大学学报, 2005(05):107-113.
- [27] 王东伟. 遥感数据与作物生长模型同化方法及其应用研究[D]. 北京师范大学, 2008.
- [28] 徐新刚, 吴炳方, 蒙继华, 李强子, 黄文江, 刘良云, 王纪华. 农作物单产遥感估算模型研究进展[J]. 农业工程学报, 2008(02):290-298.
- [29] Kiniry J R, Bean B, Xie Y, et al. Maize yield potential: critical processes and simulation modeling in a high-yielding environment[J]. *Agricultural Systems*, 2004, 82: 45-56.
- [30] 李宗南. 基于光能利用率模型和定量遥感的玉米生长监测方法研究[D]. 中国农业科学院, 2014.
- [31] Wenping Yuan, Shuguang Liu, Guangsheng Zhou, et al. Deriving a light use efficiency model from eddy covariance flux data for predicting daily gross primary production across biomes[J]. *Agricultural and Forest Meteorology*, 2006, 143(3).
- [32] Jianxi Huang, Liyan Tian, Shunlin Liang, et al. Improving winter wheat yield estimation by assimilation of the leaf area index from Landsat TM and MODIS data into the WOFOST model[J]. *Agricultural and Forest Meteorology*, 2015, 204.
- [33] Hongyuan Ma, Jianxi Huang, Dehai Zhu, et al. Estimating regional winter wheat yield by assimilation of time series of HJ-1 CCD NDVI into WOFOST-ACRM model with Ensemble Kalman Filter[J]. *Mathematical and Computer Modelling*, 2013, 58(3-4).
- [34] 唐延林. 水稻高光谱特征及其生物理化参数模拟与估测模型研究[D]. 浙江大学, 2004.
- [35] 李龙澍. 农作物长势的模糊综合评价[J]. 系统工程理论与实践, 1998(08):128-131.
- [36] Bartholome E. Radiometric measurements and crop yield forecasting Some observations over millet and sorghum experimental plots in Mali[J]. *International Journal of Remote Sensing*, 2007, 9(10-11):1539-1552.
- [37] Jensen JR. Introductory Digital Image Processing: A Remote Sensing Perspective. Ph D Thesis. Columbus, CA: University of South Carolina, 1986
- [38] Bannari A, Morin D, Bonn F, et al. A review of vegetation indices. *Remote Sensing Reviews*, 1995, 13:95-120
- [39] Clevers J. Application of a weighted infrared-red vegetation index for estimating leaf area index by correcting for soil moisture. *Remote Sensing of Environment*, 1989, 29:25-37

- [40] Myneni RB, Williams DL. On the relationship between FAPAR and NDVI. *Remote Sensing of Environment*, 1994, 49:200-211
- [41] Running SW, Justice CO, Salomonson V, et al. Terrestrial remote sensing science and algorithms planned for EOS/MODIS. *International Journal of Remote Sensing*, 1994, 15: 3587-3620
- [42] Huete A, Justice C, Leeuwen WV. MODIS Vegetation Index (MOD13) Algorithm Theoretical Basis Document[EB/OL]. (2013-10-10)[2017-01-01]. <http://modarc.gsfc.nasa.gov/MODIS/LAND/#vegetation-indices>, 1999
- [43] Chen JM, Govind A, Sonnentag O, et al. Leaf area index measurements at Fluxnet-Canada forest sites. *Agricultural and Forest Meteorology*, 2006, 140:257-268
- [44] Liang S-L, Li X-W, Wang J-D. Quantitative Remote Sensing, Concept and Algorithm. *Beijing: Science Press*, 2013
- [45] Lymburner L, Beggs PJ, Jacobson CR. Estimation of canopy-average surface-specific leaf area using Landsat TM data. *Photogrammetric Engineering and Remote Sensing*, 2000, 66:183-192
- [46] Chen JM. Optically-based methods for measuring seasonal variation of leaf area index in boreal conifer stands. *Agricultural and Forest Meteorology*, 1996, 80:135-163
- [47] Huete AR. A soil-adjusted vegetation index (SAVI). *Remote Sensing of Environment*, 1988, 25:295-309
- [48] Baret F, Guyot G, Major DJ. Crop biomass evaluation using radiometric measurements. *Photogrammetria*, 1989, 43:241-256
- [49] 田庆久, 闵祥军. 植被指数研究进展[J]. *地球科学进展*, 1998, 13(4):327-333.
- [50] 王正兴, 刘闯, HUETE Alfredo. 植被指数研究进展: 从 AVHRR-NDVI 到 MODIS-EVI[J]. *生态学报*, 2003(05):979-987.
- [51] 陶惠林, 冯海宽, 杨贵军, 等. 基于无人机数码影像和高光谱数据的冬小麦产量估算对比[J]. *农业工程学报*, 2019, 35(23): 111-118.
- [52] Mah A, Mya B, Ara E, et al. A rapid monitoring of NDVI across the wheat growth cycle for grain yield prediction using a multi-spectral UAV platform[J]. *Plant Science*, 2019, 282: 95-103.
- [53] Fei S, Hassan M A, He Z, et al. Assessment of Ensemble Learning to Predict Wheat Grain Yield Based on UAV-Multispectral Reflectance[J], 2021, 13(2): 2338.
- [54] Stroppiana D., Migliazzi M., Chiarabini V., et al. Rice yield estimation using multispectral data from UAV: A preliminary experiment in northern Italy[A]. *2015 IEEE International Geoscience and Remote Sensing Symposium (IGARSS)* [C]. IEEE, 2015: 4664-4667.
- [55] 王妮. 基于无人机平台的小麦长势监测与产量预测研究[D]; 南京农业大学, 2016.
- [56] 朱婉雪, 李仕冀, 张旭博, 等. 基于无人机遥感植被指数优选的田块尺度冬小麦估产[J]. *农业工程学报*, 2018, 34(11): 78-86.
- [57] 张少华, 段剑钊, 贺利, 等. 基于无人机平台多模态数据融合的小麦产量估算研究[J]. *作物学报*: 1-16.
- [58] Maimaitijiang M, Sagan V, Sidike P, et al. Soybean yield prediction from UAV using multi modal data fusion and deep learning[J]. *Remote Sensing of Environment*, 2019, 237:111599.
- [59] Feng A, Zhou J, Vories E D, et al. Yield estimation in cotton using UAV-based multi-sensor imagery[J]. *Biosystems Engineering*, 2020, 193(3): 101-114.
- [60] Zhou X., Zheng H., Xu X., et al. Predicting grain yield in rice using multi-temporal vegetation indices from UAV-based multispectral and digital imagery[J]. *ISPRS Journal of Photogrammetry*

- and Remote Sensing*, 2017, 130: 246-255.
- [61] Herwitz S R, Johnson L F, Dunagan S E, et al. Imaging from an unmanned aerial vehicle: Agricultural surveillance and decision support[J]. *Computers and Electronics in Agriculture*, 2004, 44(1): 49—61
- [62] 万余庆, 谭克龙, 周日平. 高光谱遥感应用研究[M]. 科学出版社, 2006.
- [63] 罗亚, 徐建华, 岳文泽. 基于遥感影像的植被指数研究方法述评[D], 2005.
- [64] Yang B, Wang M, Sha Z, Wang B, Chen J, Yao X, Cheng T, Cao W, Zhu Y. 2019. Evaluation of above ground nitrogen content of winter wheat using digital imagery of unmanned aerial vehicles[J]. *Sensors*, 19(20):4416.
- [65] Meyer G. E., Hindman T. W., Laksmi K. Machine vision detection parameters for plant species identification[A]. Precision Agriculture and Biological Quality[C]. *International Society for Optics and Photonics*, 1999: 327-335.
- [66] Hunt E. R., Cavigelli M., Daughtry C. S., et al. Evaluation of digital photography from model aircraft for remote sensing of crop biomass and nitrogen status[J]. *Precision Agriculture*, 2005, 6(4): 359-378.
- [67] Gamon J., Surfus J. Assessing leaf pigment content and activity with a reflectometer[J]. *The New Phytologist*, 1999, 143(1): 105-117.
- [68] Sellaro R., Crepy M., Trupkin S. A., et al. Cryptochrome as a sensor of the blue/green ratio of natural radiation in Arabidopsis[J]. *Plant physiology*, 2010, 154(1): 401-409.
- [69] 魏全全, 李岚涛, 任涛, 等. 基于数字图像技术的冬油菜氮素营养诊断[J]. *中国农业科学*, 2015, 48(19): 3877-3886.
- [70] Rouse Jr J. W., Haas R., Schell J., et al. Monitoring vegetation systems in the Great Plains with ERTS[J]. *NASA special publication*, 1974, 351: 309.
- [71] Gitelson A. A., Kaufman Y. J., Merzlyak M. N. Use of a green channel in remote sensing of global vegetation from EOS-MODIS[J]. *Remote sensing of Environment*, 1996, 58(3): 289-298.
- [72] Major D., Baret F., Guyot G. A ratio vegetation index adjusted for soil brightness[J]. *International Journal of Remote Sensing*, 1990, 11(5): 727-740.
- [73] Mcfeeters S. K. The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features[J]. *International journal of remote sensing*, 1996, 17(7): 1425-1432.
- [74] Shimada S., Matsumoto J., Sekiyama A., et al. A new spectral index to detect Poaceae grass abundance in Mongolian grasslands[J]. *Advances in Space Research*, 2012, 50(9): 1266-1273.
- [75] Richardson A. J., Wiegand C. Distinguishing vegetation from soil background information[J]. *Photogrammetric engineering and remote sensing*, 1977, 43(12): 1541-1552.
- [76] Huete A. R. A soil-adjusted vegetation index (SAVI)[J]. *Remote sensing of environment*, 1988, 25(3): 295-309.
- [77] Qi J., Chehbouni A., Huete A., et al. A modified soil adjusted vegetation index[J]. *Remote sensing of environment*, 1994, 48(2): 119-126.
- [78] Kaufman Y. J., Tanre D. Atmospherically resistant vegetation index (ARVI) for EOS MODIS[J]. *IEEE transactions on Geoscience and Remote Sensing*, 1992, 30(2): 261-270.
- [79] Huete A., Didan K., Miura T., et al. Overview of the radiometric and biophysical performance of the MODIS vegetation indices[J]. *Remote sensing of environment*, 2002, 83(1-2): 195-213.
- [80] Sripada R. P., Heiniger R. W., White J. G., et al. Aerial color infrared photography for determining

- early in-season nitrogen requirements in corn[J]. *Agronomy Journal*, 2006, 98(4): 968-977.
- [81] Crippen R. E. Calculating the vegetation index faster[J]. *Remote sensing of Environment*, 1990, 34(1): 71-73.
- [82] Boegh E., Søgaard H., Broge N., et al. Airborne multispectral data for quantifying leaf area index, nitrogen concentration, and photosynthetic efficiency in agriculture[J]. *Remote sensing of Environment*, 2002, 81(2-3): 179-193.
- [83] Gitelson A., Stark R., Grits U., et al. Vegetation and soil lines in visible spectral space: a concept and technique for remote estimation of vegetation fraction[J]. *International Journal of Remote Sensing*, 2002, 23(13): 2537-2562.
- [84] Daughtry C., Walthall C., Kim M., et al. Estimating corn leaf chlorophyll concentration from leaf and canopy reflectance[J]. *Remote sensing of Environment*, 2000, 74(2): 229-239.
- [85] Haboudane D., Miller J. R., Pattey E., et al. Hyperspectral vegetation indices and novel algorithms for predicting green LAI of crop canopies: Modeling and validation in the context of precision agriculture[J]. *Remote sensing of environment*, 2004, 90(3): 337-352.
- [86] Gitelson A., Merzlyak M. N. Spectral reflectance changes associated with autumn senescence of *Aesculus hippocastanum* L. and *Acer platanoides* L. leaves. Spectral features and relation to chlorophyll estimation[J]. *Journal of plant physiology*, 1994, 143(3): 286-292.
- [87] Broge N. H., Leblanc E. Comparing prediction power and stability of broadband and hyperspectral vegetation indices for estimation of green leaf area index and canopy chlorophyll density[J]. *Remote sensing of environment*, 2001, 76(2): 156-172.
- [88] Vogelmann J., Rock B., Moss D. Red edge spectral measurements from sugar maple leaves[J]. *Remote Sensing*, 1993, 14(8): 1563-1575.
- [89] Dash J., Curran P. MTCI: the MERIS terrestrial chlorophyll index[A]. *MERIS[C]*. 2004: 10-13.
- [90] Kim M. S., Daughtry C., Chappelle E., et al. The use of high spectral resolution bands for estimating absorbed photosynthetically active radiation[M]. *Proceedings of 6th International Symposium on Physical Measurements and Signatures in Remote Sensing*. 1994: 299-306.
- [91] Gitelson A. A., Merzlyak M. N., Chivkunova O. B. Optical properties and nondestructive estimation of anthocyanin content in plant leaves[J]. *Photochemistry and photobiology*, 2001, 74(1): 38-45.
- [92] Merzlyak M. N., Gitelson A. A., Chivkunova O. B., et al. Non-destructive optical detection of pigment changes during leaf senescence and fruit ripening[J]. *Physiologia plantarum*, 1999, 106(1): 135-141.
- [93] Roujean J.-L., Breon F.-M. Estimating PAR absorbed by vegetation from bidirectional reflectance measurements[J]. *Remote sensing of Environment*, 1995, 51(3): 375-384.
- [94] Rondeaux G., Steven M., Baret F. Optimization of soil-adjusted vegetation indices[J]. *Remote sensing of environment*, 1996, 55(2): 95-107.
- [95] Goel N. S., Qin W. Influences of canopy architecture on relationships between various vegetation indices and LAI and FPAR: A computer simulation[J]. *Remote Sensing Reviews*, 1994, 10(4): 309-347.
- [96] Yang Z., Willis P., Mueller R. Impact of band-ratio enhanced AWIFS image to crop classification accuracy[A]. *Proc Pecora[C]*. 2008: 18-20.
- [97] 杨宝华, 高远, 王梦玄, 等 基于光谱-空间特征的黄茶多酚含量估算模型[J]. *光谱学与光谱分*

- 析, 2021, 41(03): 936-942.
- [98] 高林, 杨贵军, 于海洋, 等. 基于无人机高光谱遥感的冬小麦叶面积指数反演[J]. 农业工程学报, 2016, 32(22): 113-120.
- [99] 刘畅, 杨贵军, 李振海, 等. 融合无人机光谱信息与纹理信息的冬小麦生物量估测[J]. 中国农业科学, 2018, 51(16): 3060-3073.
- [100] Magerman D. M. Statistical decision-tree models for parsing[A]. Proceedings of the 33rd annual meeting on Association for Computational Linguistics[C]. *Association for Computational Linguistics*, 1995: 276-283.
- [101] 田明璐, 班松涛, 常庆瑞, 等. 基于无人机成像光谱仪数据的棉花叶绿素含量反演[J]. 农业机械学报, 2016, 47(11): 285-293.
- [102] Yang R.-M., Zhang G.-L., Liu F., et al. Comparison of boosted regression tree and random forest models for mapping topsoil organic carbon concentration in an alpine ecosystem[J]. *Ecological Indicators*, 2016, 60: 870-878.
- [103] 刘昌华, 王哲, 陈志超, 等. 基于无人机遥感影像的冬小麦氮素监测[J]. 农业机械学报, 2018, 49(6): 207-214. DOI:10.6041/j.issn.1000-1298.2018.06.024.
- [104] 赵鑫. 基于机器学习算法分析无人机图像的小麦产量反演研究[D]. 安徽: 安徽大学, 2020.
- [105] Fu H, Wang C, Cui G, et al. Ramie Yield Estimation Based on UAV RGB Images[J]. *Sensors*, 2021, 21(2): 669.
- [106] 孟令华, 张新乐, 刘焕军, 等. 基于 NDVI-NDWI 植被指数的棉花灌溉信息提取[C]. 第二十届中国遥感大会论文集. 2016: 75-75.
- [107] 王雪, 常志州, 张恒敢, 等. 基于 MODIS 和天地图遥感数据的区域作物秸秆产量估算方法[J]. 农业工程学报, 2015(19): 177-182.
- [108] 朱婉雪, 李仕冀, 张旭博, 等. 基于无人机遥感植被指数优选的田块尺度冬小麦估产[J]. 农业工程学报, 2018, 34(11): 78-86.
- [109] 韩文霆, 汤建栋, 张立元, 等. 基于无人机遥感的玉米水分利用效率与生物量监测[J]. 农业机械学报, 2021, 52(5): 129-141.
- [110] 贾丹, 陈鹏飞. 低空无人机影像分辨率对冬小麦氮浓度反演的影响[J]. 农业机械学报, 2020, 51(7): 164-169.
- [111] 刘畅, 杨贵军, 李振海, 等. 融合无人机光谱信息与纹理信息的冬小麦生物量估测[J]. 中国农业科学, 2018, 51(16): 3060-3073.
- [112] Zheng H, Cheng T, Zhou M, et al. Precision Agriculture, 2019, 20(3): 611 .
- [113] Liu Yinuo, Liu Shishi, Li Jing, et al. Computers and Electronics in Agriculture, 2019, 166: 1050 .
- [114] 陈雨海, 余松烈. 小麦边际效应的研究[J]. 山东农业大学学报(自然科学版), 1999, 30(4): 431-435.