


分类号: _____
密 级: _____

单位代码: 10300
学 号: 20211249466

南京信息工程大学

硕士专业学位论文



论文题目: 基于深度学习的河南省冬小麦
产量预测算法研究

申请人姓名: 叶文峥

指导教师: 金子龙 副教授

学科名称: 计算机技术

研究方向: 数据挖掘

培养学院: 软件学院

提交时间: 2024年5月29日

二〇二四年五月

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于统计模型的产量预测方法.....	2
1.2.2 基于作物生长模型的产量预测方法.....	3
1.2.3 基于机器学习模型的产量预测方法.....	4
1.2.4 基于深度学习模型的产量预测方法.....	5
1.3 研究内容和技术路线.....	7
1.3.1 研究内容.....	7
1.3.2 技术路线.....	9
1.4 论文组织和章节安排.....	9
第二章 相关理论与技术	11
2.1 遥感影像.....	11
2.2 卷积神经网络.....	12
2.3 循环神经网络.....	13
2.4 注意力机制.....	14
第三章 研究区域与数据预处理	15
3.1 研究区.....	15
3.2 数据来源.....	15
3.2.1 MODIS 数据产品.....	15
3.2.2 气象环境数据.....	16
3.2.3 种植面积和产量数据.....	16
3.3 遥感影像数据预处理.....	16
3.4 冬小麦生育期样本划分.....	18
第四章 基于 CBTA 模型的冬小麦产量预测混合网络.....	19
4.1 CBTA 模型的构建	19
4.1.1 结合卷积注意力的卷积神经网络模块	20
4.1.2 结合注意力机制的双向门控循环单元模块	21
4.2 模型评价指标及参数设置	24
4.3 实验与分析.....	24
4.3.1 CBTA 模型县级产量预测精度	24
4.3.2 CBTA 模型性能评估	26
4.3.3 CBTA 模型稳定性验证	27
4.3.4 产量预测特征贡献度分析.....	28

4.3.5 冬小麦不同生育期预测性能分析.....	29
第五章 基于 SA-DCGAN 模型的冬小麦产量预测增强网络	31
5.1 产量预测增强网络的构建	31
5.1.1 生成对抗网络.....	32
5.1.2 结合自注意力机制的深度卷积生成对抗网络	33
5.2 模型评价指标及参数设置	35
5.3 实验与分析.....	36
5.3.1 增强网络县级产量预测精度.....	36
5.3.2 产量预测增强网络性能评估.....	40
5.3.3 增强网络冬小麦累计生育期预测效果分析	41
第六章 总结与展望	43
6.1 工作总结.....	43
6.2 研究展望.....	44
参考文献.....	45

摘要

及时准确预测冬小麦产量，确保冬小麦的高产稳产对保障国家粮食安全和社会安定具有重要的意义。本研究以中国河南省冬小麦种植区为研究区域，选取 2002~2017 年遥感影像数据、气象环境数据和冬小麦产量数据，构建了冬小麦单产预测数据集，并基于创新性的深度学习方法进行冬小麦产量预测相关研究。本文的具体研究工作如下：

（1）针对单一神经网络难以挖掘遥感影像中冬小麦生长特征的问题，本研究提出了一种基于三重注意力机制的CNN-BiGRU混合神经网络产量预测模型（CBTA）。该模型利用CNN挖掘融合气象环境数据的多光谱遥感影像的空间光谱特征，利用BiGRU从融合遥感影像时间序列中提取冬小麦生育期不同时间步之间的关联，并结合三重注意力机制深入挖掘特征变量对冬小麦产量的影响程度，从多方面整合冬小麦的生长发育特征进行产量预测。通过稳定性验证和模型比较，验证了CBTA能够准确预测县域冬小麦产量。此外，本研究探讨了不同特征变量对产量预测的贡献度，并将冬小麦的整个生育期分为6个时间步，对比不同时间步预测精度验证了CBTA产量预测模型提前1~2个月准确预测冬小麦产量的能力。

（2）针对冬小麦产量预测的样本数据集规模不足的问题，本研究提出了一种结合自注意力机制的深度卷积生成对抗网络（SA-DCGAN）的产量预测增强网络。该模型在生成器中利用卷积神经网络生成图像并结合自注意力机制捕捉全局信息间的依赖关系，提高生成图像的质量。通过对比原始数据集、伪造数据集和二者合并的增强数据集预测冬小麦产量结果差异，验证了数据增强的效果。同时，通过与传统GAN方法的增强结果对比，以及针对自注意力机制进行的相关消融实验验证了SA-DCGAN模型结构和性能的优越性。此外，本研究分别在三种冬小麦累计生育期时间步数据集上进行单产预测，验证了所提出的产量预测增强网络在冬小麦生育期的中后期拥有较高的产量预测精度，进一步提升了冬小麦产量预测的精度和时间提前量。

关键词：遥感影像，深度学习，数据增强，冬小麦，产量预测

Abstract

Timely and accurate prediction of winter wheat yield and ensuring high and stable yield are of great importance to national food security and social stability. In this study, winter wheat growing area in Henan Province of China is selected as the research area, remote sensing image data, meteorological environment data and winter wheat yield data from 2002 to 2017 are selected to construct winter wheat yield prediction data set, and related research on winter wheat yield prediction are carried out based on innovative deep learning methods. The specific research work of this paper is as follows:

(1) To solve the problem that it is difficult for a single neural network to mine winter wheat growth characteristics in remote sensing images, we propose a CNN-BiGRU method with triple attention for winter wheat yield prediction, named CBTA. The model uses convolutional neural networks to mine the spatial spectral information in hyperspectral remote sensing images. Furthermore, Bidirectional Gated Recurrent Unit is used to extract the correlation between different time steps of winter wheat growth stage from the time series of fusion remote sensing images. And the triple attention mechanism is combined to deeply explore the influence degree of characteristic variables on winter wheat yield. The yield prediction is made by integrating the growth and development features of winter wheat in many aspects. Through stability verification and model comparison, it is proved that CBTA can accurately predict winter wheat yield at county level. In addition, this study discusses the contribution degree of different characteristic variables to yield prediction. The whole growth period is divided into 6 time steps, and the study compares the prediction accuracy of different time steps to verify the ability of CBTA to accurately predict winter wheat yield 1-2 months in advance.

(2) To solve the problem of insufficient sample datasets for winter wheat yield prediction, we propose an enhanced yield prediction network based on a deep convolutional generative adversarial network combined with self-attention mechanism (SA-DCGAN). In this model, The convolutional neural network is used to generate images in the generator and the self-attention mechanism is utilized to capture the dependence between global information, so as to improve the quality of generated images. The effect of data enhancement is verified by comparing the original data set, the forged data set and the combined enhanced data set for

winter wheat yield prediction. Meanwhile, the structure and performance of the SA-DCGAN model are verified by comparing the enhancement results with the traditional GAN method and the correlation ablation experiments targeting the self-attention mechanism. In addition, this study carries out yield prediction on three kinds of winter wheat cumulative growth period time step data sets, and proves that the proposed yield prediction enhancement network has higher yield prediction accuracy in the middle and late growth period of winter wheat, and further improves the accuracy and advance of winter wheat yield prediction.

Key words: Remote sensing images; Deep learning; Data Augmentation; Winter wheat; Yield prediction

第一章 绪论

1.1 研究背景及意义

农业生产是人类社会发展与稳定的重要基石,粮食则是人们最基础的生活资源,粮食产出也从根源上影响着国民经济^[1]。中国是一个人口大国,粮食安全始终是我国国民经济发展、社会和谐稳定和国家安全自立的基础,关乎全局,具有重大的战略意义^[2]。当前我国正在全力推动新型“四化”的共同发展,粮食作物单产稳定增加,粮油产量也连年提高^[3]。

中国是世界上最大的小麦生产国和消费国^[4],在满足全国人民粮食需求方面将面临更多挑战。据统计,2021年全国小麦总产量为13695万吨,播种面积为2357万公顷,占全国粮食总产量的1/5。其中,冬小麦在秋季种植,第二年夏天收获,约占中国小麦总产量的94%,2021年冬小麦播种面积为2180万公顷,产量为12920万吨。在冬小麦的生长过程中,可能会遇到如干旱、洪涝、冻害等各种自然灾害。通过预测冬小麦的产量,可以提前预警并采取相应的灾害防控措施,减少灾害对冬小麦产量的影响,保障农业生产的稳定。因此,及时、准确的冬小麦生长监测和产量预测对地方、国家乃至国际层面的粮食生产过程中的一系列环节提供决策支持,对保障国家粮食储备、中国农民利益和居民生产生活具有重要意义^[5]。

一般来说,冬小麦在10月初播种,次年6月底成熟收获,其生长包括从播种期至成熟期共计12个生育期^[6]。冬小麦产量受农业技术水平、播种面积、自然生态状况等多种因素影响,其成长状态和过程十分复杂,产量的生成包含了相当多的自然生物过程,一般认为是在其生长发育阶段中日照、气温、土质、水分等多种影响因子共同叠加的结果^[7]。冬小麦的产量预测是指在冬小麦成熟期收获前采取一定方法取得多个影响因子组合的预测资料预先测定产量。作为重要的农产品,其价格波动对农业生产者和消费者都会产生影响。通过预测冬小麦的产量,可以帮助政府和企业提前做好市场调控,避免市场价格的大幅波动,维护市场的稳定。早期的冬小麦产量预测有利于冬小麦精准管理方案的制定,并且有助于改善冬小麦的品质,提高冬小麦的产量,提高人民生活水平,增加粮食供应,为国家粮食安全提供强力的保障。

综上所述,本文的研究意义在于基于深度学习方法及时准确的预测冬小麦产量并提高产量预测的精度,确保冬小麦的高产稳产,进而保障国家粮食安全和社会安定。

1.2 国内外研究现状

农作物产量预测是国内外智慧农业领域研究的热点问题之一。国内外在农作物产量预测方面取得了一些进展,但仍存在一些挑战和难点。现有的作物产量预测方法大致可分为以下几类:一是基于统计模型的产量预测方法;二是基于作物生长模型产量预测方法;三是基于机器学习模型的产量预测方法;四是基于深度学习模型的产量预测方法。不同区域内的不同农作物有各自特殊的生长发育状态和环境,国内外学者在对其影响因素展开充分了解分析的基础上,尝试了多种多样的预测方法,农作物产量预测的精度也日益提高。同时,随着来自众多来源的数据量不断增大以及计算机硬件、算法等条件不断改良,利用深度学习方法的冬小麦产量预测也逐渐成为了智慧农业应用中最具吸引力和挑战性的主题之一并且取得了日益优异的效果。

1.2.1 基于统计模型的产量预测方法

传统的产量预测统计模型主要包括时间序列分析模型和回归模型。其中,时间序列分析模型主要分析某区域过去的产量历史数据,基于其中的潜在规律预测未来的产量^[8]。而回归模型则是通过分析影响产量的各种因素建立数学模型,预测未来的产量^[9]。时间序列分析模型包括指数平滑模型^[10]、灰色预测模型^[11]和基于马尔可夫链的预测模型^[12]等,回归模型则包括各类线性回归模型^[13,14]、逐步回归模型^[15]等。近年来,这些模型在产量预测方面的应用非常多,国内外学者对其性能的优劣也做了许多对比总结,并在此基础上创新了多种多样高精度的基于统计模型的产量预测方法。Choudhury 等人^[16]使用简单指数平滑、双指数平滑、阻尼趋势线性指数平滑和分别应用于每个区域的自回归滑动平均模型(ARMA)来捕捉作物产量随时间变化的模式,实验发现由自回归模型与移动平均模型为基础“混合”构成的自回归滑动平均模型作为作物产量预测的时间序列模型比平滑技术更可靠。该研究为农业实践提供了有用的见解,即通过合适的时间序列模型,农场主、政策制定者和农业保险公司等利益相关者可以更好地了解作物产量的动态变化,并据此做出更加明智的决策。Michel 等人^[17]评估了线性回归、二次回归、三次回归、动态线性模型和霍尔特-温特(Holt-Winters)模型等八种不同的统计模型对分析产量时间序列的适用性,发现 Holt-Winters 模型和动态线性模型表现良好,能够给出准确的小麦产量预测。他们探讨了模型选择的依据,包括数据的特性(如平稳性、季节性、趋势性等)、模型的适用性和解释性等方面,通过比较不同模型的预测精度和适用性,

为实际应用提供了建议。张晓杰等人^[18]对比了线性回归、指数平滑等传统时间序列分析模型与差分整合移动平均自回归模型（ARIMA）在预测山东省粮食总产量方面的表现，发现 ARIMA 模型在预测未来趋势方面展现出了更高的准确性并且能够对未来几年内省内粮食总产量的增长趋势进行相应预测分析。然而，由于粮食生产受到包括气候变化、政策调整等多种因素的影响，在实际应用中需要谨慎对待模型的预测结果并结合其他信息进行综合判断。通过国内外学者的大量实验证明，基于统计模型的产量预测方法的优点是简单易行，考虑因素全面，预测精度较高，适用于数据量较大、趋势较为稳定的情况。而这些传统的数学统计预测模型缺点是对数据的要求较高，需要保证数据的准确性和完整性，难以区别短期数据和中长期数据的重要性，不能很好地反映事物发展的当前趋势，并且在大范围的地理位置和空间尺度上具有较差的区域普适性。

1.2.2 基于作物生长模型的产量预测方法

区域农作物产量预测另一种常用的方法是使用作物生长模型，它是根据作物品种、气象条件、土壤物理化学性质和作物栽培管理措施，模拟作物生长发育、籽粒形成及产量^[19]。帅细强等人^[20]利用本地数据集验证了已被提出的水稻生长模型ORYZA2000的作物监测能力，并考虑地形、天气条件等多种自然生态环境因素划分江南双季稻区的不同区域，成功模拟我国江南双季稻地区的水稻生长包括出苗、分蘖、拔节、抽穗和成熟等各个阶段。通过将该模型与气象数据相结合，他们分析了不同气象因素（如温度、降雨量、日照时间等）对水稻生长的影响。同时，他们发现气象因素对水稻生长具有显著影响。适宜的温度、降雨量和日照时间有助于水稻的健康生长和产量增加，而极端的气象条件可能导致减产或品质下降。此外，他们还利用该模型对未来的水稻产量进行了动态预测。根据历史气象数据和未来气象预报，模型能够预测未来的水稻生长状况和产量趋势。这种预测有助于农业生产者提前制定种植计划，优化资源配置，降低生产风险。Zhuo 等人^[21]根据15天THORPEX交互式全球预报数据集（TIGGE）生成的天气预报数据，利用作物生长WOFOST模型校准将研究区域划分为子区域在一定程度上解释作物和土壤性质的空间差异，并使用4DVar数据同化方法将遥感影像数据LAI同化到该模型中，使得区域尺度冬小麦产量预测更加准确。此外，他们还对不同年份和不同地区的数据进行了分析，探讨了影响冬小麦产量的主要气象因素，这些分析有助于更好地理解冬小麦的生长规律和气象因素对其产量的影响。

随着遥感技术的发展，遥感卫星可以实时动态地获得大量高质量、高时空分辨率、

大范围的图像,进而从不同光学波段的光谱信息中提取计算得到如归一化差异植被指数、增强型植被指数、作物水分胁迫指数等相关指标^[22]。这些植被指数能够作为反映大面积冬小麦生长信息的定量指标,被广泛用于冬小麦生长状况监测和大规模农作物产量预测等相关研究^[23]。Lai 等人^[24]提出了一种利用时间积分 Landsat NDVI 数据的实证模型来预测小麦产量。该模型对小麦生长过程中植被指数的变化进行监测和分析从而预测小麦的产量。此外,他们探讨了影响小麦产量的主要因素,如气象条件、土壤性质、种植技术等,这些因素对小麦生长和产量产生了重要影响,通过了解这些因素的作用机制,为预测模型提供更加准确的输入参数,较为准确地预测小麦的产量。Gaso 等人^[25]利用基于过程的作物生长模型将 Sentinel-2 的叶面积指数(LAI)检索耦合到作物模型中来预测田间产量变化,在低参数化水平下动态模拟作物发育和生长响应水分胁迫的生理过程,对大豆生长过程中叶面积指数的变化进行了监测和分析。然而,这些生长模拟模型虽然结合了遥感影像中提取到的信息,能够帮助预测和模拟生物体的生长过程,但往往无法全面考虑到作物生长发育的全部影响因素,并且复杂的生长模型参数也导致其在大空间尺度具有较大的不确定性,在参数标定应用中仍然面临着挑战和困难。

1.2.3 基于机器学习模型的产量预测方法

随着人工智能的迅速发展,面对大规模时空数据,越来越多的机器学习算法应用到预测农作物产量和挖掘特征变量间关系。机器学习能够通过其强大的数据驱动能力处理输入特征集的固有非线性^[26,27]。Han 等人^[28]对比评估了 8 种机器学习的方法,包括 K-最邻近回归、BP 神经网络、决策树回归(DT)、支持向量机(SVM)、高斯回归过程(GPR)、随机森林回归(RF)以及提升树(BST)和袋装树(BGT)这两种典型的集成学习算法,评估了其相应的预测能力。同时,他们通过划分小麦的整个生育期,以中国冬小麦主产区为例,基于谷歌地球引擎(GEE)平台构建了融合气候数据、遥感数据和土壤数据的建模框架,准确预测中国县级冬小麦收获日期前 1~2 个月的产量且产量误差小于 10%。结果表明支持向量机(SVM)、高斯过程回归和随机森林是研究测试的 8 种典型机器学习模型中预测产量的前三种最佳方法。Burdett 等人^[29]考虑包括 pH 值、土壤试验磷、锌、钾、海拔等属性,比较了决策树和随机森林等传统机器学习方法,确定能够在子田尺度(2 米)将土壤特性和作物产量联系起来的方法。交叉验证实验表明,在大多数情况下,随机森林模型可以预测训练数据集中田地的低产和高产区域,如果田地的土壤特性与产量具有相似的关系,则机器学习技术可用于预测没有现有产量地图的田地的高产区域。最

近, Zhou 等人^[30]结合气候数据和遥感卫星信息探讨了使用多种气候变量和遥感相关指标在随机森林、支持向量机等机器学习方法上进行小麦产量预测的效果。他们发现在不同的小麦种植区, 产量预测效果拥有很大的空间差异。其中支持向量机优于其他模型, 冬小麦种植区的预测效果优于春小麦种植区并验证了结合气候和遥感数据对中国县域产量进行准确预测的有效性。这些简单且可扩展的机器学习方法可以作为农业研究人员和顾问进一步工作的目标。国内外许多学者围绕机器学习模型进行了大量的产量预测实验, 结果表明机器学习模型能够从大量数据中提取有用的信息, 根据不同的数据特征和预测目标进行模型调整, 从而进行较为准确的农作物产量预测。同时, 对于大规模、复杂度高的产量预测问题, 机器学习模型能够提供更准确的预测结果, 可以广泛应用于不同领域和场景的产量预测问题。但是机器学习模型的预测精度很大程度上取决于数据的数量和质量, 如果数据不充分或者数据质量差, 模型的预测结果可能会出现偏差。而且其泛化能力有待提高, 如果训练数据和实际生产环境差异较大, 模型的预测结果可能会出现较大偏差。此外, 训练和预测需要大量的计算资源和时间, 对于大规模的产量预测问题, 可能需要高性能的计算机和长时间的运算。

1.2.4 基于深度学习模型的产量预测方法

经过大量的实验对比验证, 传统的机器学习方法从输入数据中提取特征的能力是局限性的, 而由多层神经网络架构组合而成的深度学习模型对特征的学习能力显著提高^[31]。如今, 随着来自众多来源的数据量的不断增大以及计算机硬件、算法等条件的改良, 结合遥感数据的冬小麦产值预估是深度学习在智慧农业中的应用中最具吸引力和挑战性的主题之一。许多研究者从区域卫星遥感影像中计算冬小麦植被指数等相关指标来建立与冬小麦产量之间的关系^[32,33]。但由于冬小麦植株的生长状态随时间的推移动态变化, 并且其周围的多种环境因素也复杂变化, 相关植被指标可能无法完全反映冬小麦的所有生长特征, 所以有些研究者倾向于使用深度神经网络如卷积神经网络(CNN)提取遥感影像的空间特征信息^[34,35]。尽管卷积神经网络善于提取图像特征, 但是在冬小麦生长监测及产量预估时, 仅仅使用传统的 CNN 架构难以学习到一系列遥感影像的时序特征^[36]。而循环神经网络(RNN)在学习时序序列的非线性特征中具有明显优势, 所以研究者将卷积神经网络和循环神经网络相结合去挖掘遥感影像的空间和时序特征。Khaki 等人^[37]使用 CNN-RNN 深度学习模型捕捉环境因子的时间依赖性和种子随时间变化的遗传改良, 使得其在新的地理环境中也拥有一定的产量预测能力。此外, 该模型与反向繁殖方法相

结合探索了气象、土壤及管理实践等条件对作物产量形成的影响程度,较为准确地预测了美国 13 个州的玉米和大豆产量。不过,其变体门控循环单元(GRU)需要更少的内部权重和计算成本,更适用于挖掘冬小麦生长发育期的长时间序列数据的内在联系^[38]。赫晓慧等人^[39]利用 CNN-GRU 产量预测模型从遥感影像中挖掘空间信息并学习冬小麦不同生长发育阶段的时序信息,深入探究时序遥感数据集与冬小麦的生长发育状态的关联,并预测了全国冬小麦主产区产量,最终获得了很大的产量预测精度的提升。Wang 等人^[40]也开发了 CNN-GRU 深度学习模型,利用植被温度条件指数(VTCI)3 个遥感变量,对关中平原县级冬小麦产量进行估算。他们利用该模型逐像素模拟了关中平原小麦产量并检查了预测产量的时空模式即产量分布呈现出东部低产、西部高产的空间特征,总体稳定、稳步增长的年际变化特征。Fan 等人^[41]将地理和时间知识结合起来,结合图神经网络(GNN)和循环神经网络进行作物产量预测。他们通过应用众所周知的线性模型、基于树的模型、深度学习方法并比较它们的性能,在各种指标上所提出的 GNN-RNN 模型始终优于现有最先进的方法,验证了考虑地理空间信息和时间信息的有效性,提高了产量预测的能力。

随着输入长度的增加,传统神经网络的性能和计算效率将会降低,而注意力机制的增加可以克服这些困难^[42]。近年来,注意力机制被广泛应用于自然语言处理、图像检测、数据挖掘等领域^[43,44,45]。为了深入了解各种输入特征变量对冬小麦产量的影响程度,提升产量预测模型内部的问责性,也有国内外学者开始将注意力机制引入到深度学习产量预测模型中去。林靖皓等人^[46]提出一种芒果产量预测模型(Self-attention CBiGRU),该模型使用卷积神经网络和双向门控循环单元,并引入自注意力机制,深入探寻广西部分区域由多个气象站点测得的相关气象要素与芒果产量的关联,从而提高了产量预测的准确性。Tian 等人^[47]利用关中平原冬小麦主要生育期的气象数据和叶面积指数、植被温度条件指数、两个遥感指标,建立了基于长短期记忆神经网络(LSTM)和注意力机制结合的深度学习模型 ALSTM,将注意力分配到输入序列的关键部分准确提取所需目标特征,提高了冬小麦产量预测的能力。然而,现在具有注意力机制的深度学习预测模型在跨尺度冬小麦产量预测方面的应用较少,潜力也尚未得到充分挖掘。

此外,由于农作物产量样本数据集规模相对很小,数据集有限,深度学习模型容易过拟合训练数据,导致在测试数据上表现不佳,进而导致产量预测精度下降。目前,国内外许多学者利用生成对抗网络(GAN)及其各种变体对多光谱遥感影像进行数据增强,进而完成后续分类或预测任务^[48,49,50,51]。GAN 利用判别器和生成器相互对抗,从复杂分

布数据集中发掘潜在规律,从而生成新的图片、文字等^[52]。以 GAN 及其变种为代表的增强技术可以学习良好的数据表示和生成高度真实的样本。自 2017 年以来,对在农业中进行图像增强或合成以提高模型性能的研究越来越多^[53]。Zhang 等人^[54]研究采用高光谱成像(HSI)结合基于生成对抗网络(GAN)的数据增强方法对单倍体玉米籽粒进行了鉴定。他们利用 GAN 的两个变体(深度卷积 GAN(DCGAN)和条件 GAN(CGAN))分别对两个玉米品种的单倍体和二倍体的光谱进行了扩展。经过 10000 个迭代轮次的训练,生成了与真实光谱非常相似的伪造光谱,并分析了它们之间的相似性。结果表明,DCGAN 和 CGAN 均能将每个分类器的准确率平均提高 10 %以上,而 CGAN 提高的每个分类器的准确率均高于 DCGAN。Zhang 等人^[55]为了应对中国关中平原数据集小、标注样本数量有限、提高冬小麦产量估算的准确性,提出了一种生成对抗网络和卷积神经网络相结合的冬小麦生长综合监测方法,结合遥感数据和气象数据,并利用 GAN 人工增加训练样本数量,从遥感指标和气象指标中提取出更多反映冬小麦生长状况和产量的重要特征,从而提高了冬小麦产量预测的效果。然而,当下国内外研究者关于数据增强技术在农作物产量预测上的应用仍然较少,这类方法能够通过扩大样本数据集提高预测模型的泛化能力进而改善农作物产量预测的效果,目前还有很大的探索和应用空间。

1.3 研究内容和技术路线

1.3.1 研究内容

基于上面的陈述,本文深入研究基于深度学习的河南省冬小麦产量预测算法。首先,从多渠道获取 2002~2017 年冬小麦发育期内的河南省各县域种植区 MODIS 遥感影像数据、气象环境数据、单位面积产量数据并对其进行相应预处理操作,然后从多波段融合遥感影像中充分提取与冬小麦产量相关的时空特征变量,建立遥感影像中的时空特征变量与冬小麦生长发育状态的时空联系。具体来讲,主要包括基于结合三重注意力机制的 CNN-BiGRU(CBTA 模型)冬小麦产量预测和基于结合自注意力机制的深度卷积生成对抗网络(SA-DCGAN 模型)的冬小麦产量预测增强网络两方面的研究内容:

(1) 基于CBTA模型的冬小麦产量预测混合网络

为从遥感影像中充分挖掘冬小麦生长发育特征,提高冬小麦产量预测的精度及时间提前量,本研究提出一种结合三重注意力机制的 CNN-BiGRU 混合神经网络产量预测模型(CBTA 模型)。该模型由结合卷积注意力的卷积神经网络模块(CNN_CBAM)和结

合注意力机制的双向门控循环单元模块 (BiGRU_Attention) 组成, 分别提取了丰富的光谱特征和空间相关性, 并捕获了长时间序列和短时间序列之间的依赖关系。具体而言, 利用 CNN 挖掘融合气象环境数据的遥感影像的空间光谱特征, 并利用 BiGRU 从长时间遥感影像序列中提取不同时期的依赖关系。同时, 结合三重注意力机制深入挖掘特征变量对冬小麦产量的影响程度, 捕捉冬小麦在不同时期的生长发育特征并进行产量预测。同时, 本研究将所提出的 CBTA 模型与现有模型进行对比并进行相关消融实验, 以验证所搭建的产量预测模型的结构和性能的优越性。此外, 本研究探究了遥感影像的不同波段所对应的特征变量与冬小麦生长发育的相关性及对冬小麦产量预测的贡献度, 冬小麦不同生育期所对应的数据对产量预测的影响并确定冬小麦产量预测的最佳时间窗。本文还研究了 CBTA 预测模型的稳定性及模型在不同年份不同区域性能的稳定性, 并分析性能差异的可能原因。

(2) 基于SA-DCGAN模型的冬小麦产量预测增强网络

针对冬小麦产量预测的样本数据集规模不足的问题, 本文利用结合自注意力机制的深度卷积生成对抗网络 (SA-DCGAN) 进行数据增强, 扩大县域冬小麦产量预测的样本集数目。真实数据样本由 2002~2017 年冬小麦发育期内的河南省各县域种植区的融合遥感影像和单位面积年产量组成。其中, 河南省各县域冬小麦完整的生长发育周期为每年的 10 月初至次年 6 月底, 由此确定遥感影像数据的时间分辨率为 2002~2017 年间每年的第 273 天到次年的第 193 天, 每个周期共 39 张遥感影像, 对应于一个冬小麦单位面积年产量标签值。利用 SA-DCGAN 捕获真实数据样本的潜在分布并生成和真实样本极其相似的新的数据样本, 从而扩大训练集和验证集的规模, 进而提升模型冬小麦产量预测的能力。本研究利用 SA-DCGAN 进行数据增强生成和原始数据集特性类似的伪造数据集, 并分别使用原始数据集、伪造数据集和二者合并的增强数据集预测冬小麦的产量, 对比预测结果差异, 验证利用 SA-DCGAN 进行数据增强的效果。同时, 本研究将 SA-DCGAN 的增强结果与传统 GAN 方法的增强结果对比, 并针对自注意力机制进行相关消融实验以验证所提出的数据增强模型结构和性能的优势。此外, 本研究分别用原始数据集、生成的伪造数据集和增强数据集的冬小麦所有累计生育期时间步数据进行单产预测并计算模型精度的评价指标, 以探究产量预测增强网络对河南省冬小麦产量预测精度和时间提前量两方面的提升效果。

1.3.2 技术路线

本研究整体的技术路线如图 1-1 所示：




图 1-1 冬小麦产量预测技术路线图

1.4 论文组织和章节安排

本文共分为六个章节，各章内容如下：

第一章是绪论。首先，介绍了本课题的研究背景和意义。接着，阐述了国内外相关研究现状，包括当前国内外研究的方法区别的进展、成果以及各种产量预测方法的优缺点，总结了当前农作物产量预测方面存在的一些问题。最后概括性地叙述了本课题的研

究内容、技术路线和各章节安排。

第二章是相关理论与技术。首先介绍了遥感影像的基本原理、特征及其在农业生产等领域的应用价值。接着详细解释了卷积神经网络的基本结构和工作原理。然后，阐述了循环神经网络的概念、特点、应用场景以及存在的问题和相应的改进方法。最后，主要介绍了注意力机制的概念、工作原理、分类和应用。

第三章是研究区域与数据预处理。首先，介绍了本研究选取的研究区域及选取该研究区域的背景与意义。接着详细描述了本研究所使用的多种数据集的定义和来源。然后具体阐述了各种数据集的预处理过程和方法。最后，科学合理的划分了冬小麦生育期样本以便后续冬小麦产量预测相关实验的进行。

第四章是基于 CBTA 模型的冬小麦产量预测混合网络。首先，介绍了结合三重注意力机制的 CNN-BiGRU 混合神经网络产量预测模型(CBTA 模型)的整体构建流程。接着具体说明了 CBTA 模型中的 CNN_CBAM 模块和 BiGRU_Attention 模块组成，以及模块内各组件方法的基本原理和功能。然后详细描述了产量预测模型的评价指标和参数设置。在实验与分析部分，首先分析了 CBTA 模型的县级产量预测精度，并通过对比实验和消融实验对 CBTA 模型进行了性能评估和稳定性验证。然后，探究了遥感影像的不同波段所对应的特征变量与冬小麦生长发育的相关性及对冬小麦产量预测的贡献度。最后，剖析了冬小麦不同生育期所对应的数据对产量预测的影响并确定冬小麦产量预测的最佳时间窗。

第五章是基于 SA-DCGAN 模型的冬小麦产量预测增强网络。首先，介绍了产量预测增强网络的整体构建流程。接着阐释了生成对抗网络的相关基础理论以及所提出的结合自注意力机制的深度卷积生成对抗网络的原理和架构组成。然后详细描述了产量预测增强网络的评价指标和参数设置。在实验与分析部分，首先分析了增强网络县级产量预测精度。接着通过数据增强方法对比实验和针对自注意力机制的相关消融实验验证了数据增强的效果并对产量预测增强网络的性能进行了评估。最后，对增强网络冬小麦累计生育期预测效果进行分析以探究产量预测增强网络对河南省冬小麦产量预测精度和时间提前量两方面的提升效果。

第六章是总结与展望。回顾本研究的全部工作，总结本文的工作内容，并对未来的研究进行展望。

第二章 相关理论与技术

2.1 遥感影像

遥感影像的原理主要基于电磁波与地表物体的相互作用以及遥感传感器的信息捕获能力^[56]。地表物体会反射、辐射或发射电磁波，这些电磁波包括可见光、红外线和微波等不同频段。不同类型的地物和物质会与这些电磁辐射以不同的方式相互作用，产生特定的反射和辐射特性。由于卫星、无人机等遥感平台上搭载的传感器经过特殊设计能够测量不同波长范围的电磁辐射，所以能够接收这些来自地表物体的电磁辐射，从而在远离目标物体的条件下探测目标地物，包括地物对电磁波的反射、辐射或散射特性以及地物的光谱特性的电磁波信息。传感器在接收到电磁辐射之后，会对接收到的电磁波进行测量、处理和分析工作并将其转换为可记录的数字信号，以确保能够准确地反映地表物体的特征。最后，通过对这些数字信号进行进一步的处理和分析，从而生成遥感影像。这些遥感影像以可视化的方式展示了地球表面的各种信息，如地形、地貌、植被覆盖、水体分布等^[57]。因此，遥感影像在环境监测、城市规划、农业生产等领域具有广泛的应用价值。

此外，遥感影像具有纹理、形状、色彩、温度等一系列特征，这些特征都可以通过遥感图像处理和分析技术来提取和分析，为地物分类、环境监测、资源管理、灾害评估等提供有价值的信息^[58]。其中，光谱特征是遥感影像最重要的特征。它是由地表物体反射或辐射的电磁辐射中所包含的各种波长的光谱信息，这些信息被捕获在可见光、红外线以及其他波段上，能够反映不同地表物质具体的组成、结构和性质等特征信息。而空间分辨率特征和时间分辨率特征是遥感影像的另外两个重要特征。遥感影像的空间分辨率特征决定了其可以辨别的最小物体或地物的大小。较高的空间分辨率可以提供更详细的地物边界和细节信息，而较低的空间分辨率适用于覆盖范围广泛的地物分析。时间分辨率特征主要反映在同一地区在不同时间采集的影像数据不同，特别是对于地表覆盖植被而言，其生长状态受时间因素的影响很大。分析不同时期的特征差异，可以实时监测目标的动态信息变化以及提高目标的识别能力和精度。因此，本研究旨在利用深度学习方法挖掘遥感影像中的上述特征与河南省冬小麦不同生长发育时期的生长发育状态之间的关系，从而进行及时准确的冬小麦产量预测。

2.2 卷积神经网络

卷积神经网络（CNN）具有多层次结构，能够处理具有类似网格结构的数据^[59]。其基本结构包括卷积层、激活函数层、池化层和全连接层^[60]。卷积层是CNN中的主要计算单元，主要用于计算输入图像或上一层的特征映射，它的核心是卷积核。卷积核的运作方式类似于眼睛中的视觉细胞，使其有位置感知的能力^[61]。在处理输入图像数据的过程中，卷积核在输入的特征图上按照固定的步长滑动，逐像素卷积遍历整张图像，并输出卷积计算后的局部特征图。随着卷积核数量的增加，从图像的同一位置能够提取不同的特征，形成多个特征图。

激活函数层通常位于卷积层之后，通过一系列非线性变换处理卷积层的输出，提高网络处理复杂任务的能力^[62]。常用的激活函数包括Sigmoid、Tanh、Softmax、ReLU和LeakyRelu等^[63]。不同激活函数的特点和定义如下所述：

Sigmoid激活函数将输入映射到(0, 1)区间，常用于二分类问题。其缺点是当输入值非常大或非常小时，梯度接近于0，导致训练困难。Sigmoid激活函数的定义为：

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2-1)$$

Tanh激活函数部分将输入映射到(-1, 1)区间，具有中心化的输出，使得网络训练更加稳定。Tanh激活函数的定义为：

$$\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-2)$$

Softmax激活函数多用于处理多分类问题，将多分类的输出转换为n个类别的概率分布。Softmax激活函数的定义为：

$$\text{Softmax}(x) = \frac{e^{x_i}}{\sum_i e^{x_i}} \quad (2-3)$$

ReLU激活函数十分常用，能有效缓解梯度消失的缺陷。当输入为正时，输出等于输入；当输入为负时，输出为0。ReLU激活函数的定义为：

$$\text{ReLU}(x) = \max(0, x) \quad (2-4)$$

LeakyRelu激活函数是对ReLU函数的改进，允许负输入值有一个小的非零梯度，从而避免某些神经元在训练过程中可能永远不会被激活的问题。LeakyRelu激活函数的定义为：

$$\text{LeakyReLU}(x) = \max(ax, x) \quad (2-5)$$

池化层利用特定的聚合函数对区域内的邻近值进行分组，从而对特征图进行降维操作，降低数据的空间尺寸，减少参数的数量，并增强网络的鲁棒性^[64]。常用的池化操作主要包括平均池化和最大池化。平均池化计算区域内像素的平均值，有利于保存背景信息。最大池化在区域内选择值最大的像素点，然后舍弃其余像素，有利于保存纹理信息。卷积层和池化层的交替使用，使得网络能够自动学习到数据的层次化特征表示。

全连接层是神经网络中的重要组成部分，它能够帮助网络整合信息、学习特征，并在分类和回归等任务中发挥关键作用^[65]。全连接层通常位于CNN的最后几层，它通过权重矩阵和偏置项将前面若干层输出的特征图连接起来，并利用激活函数引入非线性因素，进行分类或回归操作输出结果。全连接层能够整合前面层中学习到的所有信息，这使得网络能够对输入数据有一个全面的理解。

因此，本研究利用卷积神经网络从遥感影像数据中提取出与冬小麦生长特征及产量相关的空间光谱特征信息，进而构建准确的河南省冬小麦产量预测模型。

2.3 循环神经网络

循环神经网络(RNN)拥有短期记忆的能力，主要用于对时间序列数据进行建模^[66]。它的特点是神经元能够结合自身信息和其它神经元信息，进而使得RNN能够建立不同循环单元之间的联系，并且具有记忆前面内容的功能。因此，RNN尤其适用于处理当前输出与前面内容有关的任务，如语音识别、语言模型和自然语言生成等^[67,68,69]。在智慧农业中，RNN也被应用于灾害评估、农作物分类和产量预测等场景下^[70,71,72]。RNN通过引入一个隐藏状态 h_t 把握循环单元间的关联性信息，并在当前时间步 t 时刻考虑先前时间步0到 $t-1$ 的隐藏状态。当前时间步 t 的输出计算方式为：

$$h_t = f(Ux_t + Wh_{t-1} + b_h) \quad (2-6)$$

$$y_t = \text{Soft max}(Vh_t + b_y) \quad (2-7)$$

式中， x_t 、 h_t 、 y_t 分别为 t 时刻的输入、隐藏状态、输出， b_h 和 b_y 是隐藏状态和输入的偏置， U 、 W 、 V 是权重矩阵， f 是激活函数。

然而，对于长序列输入，RNN可能会面临梯度爆炸和消失问题。为了解决这个问题，越来越多的改进方法被提出，其中最有效的是引入门控机制，如长短期记忆网络(LSTM)、门控循环单元(GRU)、双向门控循环单元(BiGRU)等^[73]。总之，RNN是一种强大的工具，特别适用于处理序列数据和相关任务。它通过引入记忆机制，能够捕捉长时间

序列数据中的时间依赖关系，从而实现对复杂模式的有效建模。

由于冬小麦产量往往受到历史数据、季节性因素、生产条件等多种时间序列因素的影响，本研究利用循环神经网络及其相应变体准确捕捉序列数据时间依赖关系的能力，从长时间序列遥感影像数据中挖掘与冬小麦生长特征及产量相关的时间序列特征信息，进而构建准确的河南省冬小麦产量预测模型。

2.4 注意力机制

注意力机制（Attention Mechanism）借鉴了人类视觉从大批量信息中选择性迅速筛选出其中的高价值部分的注意力行为，使得机器能够选择性地将更多的注意力权重放在输入信息中相对重要的部分，同时忽略其他不相关的信息进而使模型在处理序列数据时更加准确和有效^[74]。在传统的神经网络中，每个神经元的输出对于前一层绝对依赖。而引入注意力机制后，每个神经元的输出考虑输入数据不同区域的权重关联值，使模型更加关注于其中的关键信息，进而提高模型的精度和效率。具体而言，注意力机制首先计算每个输入位置的注意力权重并将其相应赋值。在计算出注意力权重之后，下一步就是将每个输入位置的表示和对应的注意力权重相乘，并对所有加权结果进行求和。这样可以得到一个加权的输入表示，它可以更好地反映输入数据中所选择的重要部分。最后，注意力机制根据加权的输入表示和其他模型参数计算输出结果，这个输出结果可以作为下一层的输入，也可以作为最终的输出。

注意力机制通常被实现为一种通用的机制，可以应用于不同的神经网络结构中。比如，在卷积神经网络中可以插入注意力机制从多个维度来关注输入图像中的重要区域，也可以在循环神经网络中使用注意力机制来聚焦输入时间序列中的关键信息。注意力机制包括软注意力机制和硬注意力机制^[75]。软注意力机制通过加权计算操作处理多个输入信息，这种方式的好处是使所有输入特征信息在被聚合之前以自适应的方式重新加权，从而提前分离出重要特征信息，避免这些特征信息受到其余不重要特征信息的干扰，进而提高准确性。而硬注意力机制主要关注输入序列某一个位置上的信息，具体实现过程是随机且动态变化的。此外，根据不同的维度可将软注意力机制分为通道注意力机制、空间注意力机制以及自注意力机制等^[76]。这些注意力机制通过给输入的不同区域分配不同的权重，使得网络能够专注于对任务更重要的信息，从而提高模型的性能。

总而言之，注意力机制能够通过计算将有限的资源合理分配给更重要的部分，帮助机器更加有效地处理和理解输入数据，从而提高深度学习模型的准确性和性能。

第三章 研究区域与数据预处理

3.1 研究区

本研究的研究区为中国河南省。河南省地理位置十分优越,气候类型为暖温带和亚热带季风气候,充足的日照和充沛的雨量为该地区的农业发展提供了得天独厚的条件。同时,河南省地势西高东低,主要以平原为主,适宜于包括农业在内的诸多产业发展^[77]。冬小麦是河南省最主要的粮食作物之一,充足的光、热、水资源和肥沃的土地非常适宜冬小麦生长。研究区位置、县界及冬小麦种植区分布图如图3-1所示。




图 3-1 研究区地理位置和冬小麦种植区图

3.2 数据来源

3.2.1 MODIS数据产品

本研究主要使用4种MODIS数据产品,下载自美国国家航空航天局(NASA)的地球观测数据系统。其中,地表反射率产品MOD09A1提供空间分辨率为500米的1~7波段每8天合成的地表反射率数据,可以反映冬小麦的生长状态和环境^[78]。地表昼夜温度产品MOD11A2提供每8天空间分辨率为1千米的每像素陆地昼夜表面温度及相关的反射率数据,与冬小麦冠层温度联系紧密^[79]。MCD15A2H数据产品提供每8天空间分辨率为500米的叶面积指数LAI数据,与冬小麦光合作用、蒸腾作用以及生长发育状况密切相关^[80]。

土地覆盖类型产品MCD12Q1基于监督决策树分类技术提供年度空间分辨率为500米的17种土地覆盖类型以及5种不同的土地覆盖类型分类方案^[81]。本研究利用MODIS重投影工具(MRT)将MCD12Q1产品转换为空间分辨率为1 km的均匀朗伯特等面积投影,然后根据国际地圈-生物圈计划分类(IGBP)的分类方案中的种植功能分类,与研究区行政边界矢量图叠加,在ARCGIS上掩膜提取河南省各县域的冬小麦种植区(如图3-1所示)。

3.2.2 气象环境数据

气象环境数据来源于Terra Climate数据集,下载自气候学实验室。Terra Climate是1958~2019年间全球陆地表面的高空间分辨率(1/24°,约4公里)的月度气候和气候水平衡数据集^[82]。该数据集使用气候辅助插值,将高空间分辨率气候法线与其他来源的数据相结合,以生成降水、温度、风速等月度气候数据集。此外,数据集还根据一维水平衡模型生成月度地表水平衡数据集,该模型包含参考蒸散量、降水量、插值植物可提取土壤水容量等。本研究选取2002年10月~2017年6月该数据集中的河南省各县域气象环境数据,具体包括每月实际蒸散量、气候水分亏缺、雪水当量、土壤湿度、帕尔默干旱严重指数、降水量、下表面短波辐射、最低温度、最高温度、蒸汽压力、饱和水汽压差这些影响因素预测冬小麦产量。

3.2.3 种植面积和产量数据

河南省县级冬小麦播种面积数据和总产量数据来源于历年的《中国农业年鉴》、《河南省统计年鉴》。《中国农业年鉴》是一部反映我国农业、林业等各个行业多个方面基本情况的大型年度资料性工具书,其内容涵盖了中国各地农业、农村产业等农业相关的多方面情况。《河南统计年鉴》是一部反映河南省各个行业多个方面基本情况的年度资料性工具书,详细记录了全省各县市历年的各行业经济、发展情况。本研究结合两个统计年鉴的相关农业统计数据,收集了2002~2017年具有有效冬小麦播种面积和产量数据的县(包括县级市)共105个。为了便于预测,利用总产量数据与播种面积数据计算得到县级冬小麦单位面积产量数据。

3.3 遥感影像数据预处理

最终,本研究选取了河南省县域2002年10月~2017年6月与冬小麦产量形成密切相关的特征变量作为产量预测的影响因素,并将各波段特征变量融合构建了冬小麦产量

预测的样本数据集。具体的特征变量及其描述如表3-1所示。

表 3-1 特征变量及其描述

特征变量	描述	单位	来源
LSR	地表反射率	W m^{-2}	MOD09A1
LST	地表昼夜温度	K	MOD11A2
LAI	叶面积指数	/	MCD15A2H
AE	实际蒸散量	mm	Terra Climate
CMD	气候水分亏缺	$\text{Kg m}^{-2} \text{ s}^{-1}$	
SWE	雪水当量	Kg m^{-2}	
SM	土壤湿度	Kg m^{-2}	
PDSI	帕尔默干旱严重指数	/	
PR	降水量	mm	
SWR	下表面短波辐射	W m^{-2}	
$T_{\min}$	最低温度	$^{\circ}\text{C}$	
$T_{\max}$	最高温度	$^{\circ}\text{C}$	
VP	蒸汽压力	hPa	
VPD	饱和水汽压差	hPa	

为统一上述遥感影像的时空分辨率并融合遥感影像，首先利用NASA开发的MODIS重投影工具（MRT）批量提取2002~2017年间每年的第273天到次年的第193天的MOD09A1、MOD11A2、MCD12Q1、MCD15A2H遥感影像的各个波段，接着根据研究区经纬度计算得到墨卡托投影分度带（UTM ZONE）将遥感影像投影转换至WGS-84坐标系，并采用最邻近插值法将MOD11A2的空间分辨率重采样为500米。然后在ARCGIS平台上根据MCD12Q1的种植功能分类中的冬小麦种植区的唯一值，与研究区行政边界矢量图叠加进一步掩膜得到河南省各县域冬小麦种植区栅格数据并将其转为矢量数据。再利用得到的矢量数据在ARCGIS上批量裁剪经过MRT重投影得到的MOD09A1、MOD11A2、MCD15A2H遥感影像得到河南省各县域冬小麦种植区对应的遥感影像栅格数据。对于气象环境数据，在ARCGIS平台中创建netCDF栅格图层，将研究时间段内Terra Climate数据集每一个所需的气象环境特征导出为该影响因素对应的

单波段栅格数据，并定义与上述遥感影像相同的空间坐标系投影，然后利用相同的操作对其重采样并矢量掩膜。最后利用GDAL库对MOD09A1、MOD11A2、MCD15A2H各个波段和Terra Climate每个影响因素对应的波段进行提取、融合，将融合后的影像输出并逐像素点进行标准化操作以提高后续模型的精度和收敛速度。

3.4 冬小麦生育期样本划分

一般来说，研究区冬小麦一般在每年的10月初播种，次年6月底成熟，由此确定遥感影像数据的时间分辨率为2002~2017年间每年的第273天到次年的第193天，每个周期共39张遥感影像。冬小麦生长过程中共有12个生育期，每个生育期约24天，对应4张遥感影像，并且每一个生育期的最后一张遥感影像对应于后一个生育期的第一张遥感影像。为了方便后续实验的进行，本研究将每两个生育期划分为一个时间步，共有6个单一生育期时间步：播种~出苗期（SS1）、分蘖~越冬期（SS2）、返青~起身期（SS3）、拔节~孕穗期（SS4）、抽穗~开花期（SS5）、灌浆~成熟期（SS6）；共有6个累计生育期时间步：播种~出苗期（CS1）、播种~越冬期（CS2）、播种~起身期（CS3）、播种~孕穗期（CS4）、播种~开花期（CS5）、播种~成熟期（CS6）。

第四章 基于CBTA模型的冬小麦产量预测混合网络

4.1 CBTA模型的构建

为了从不同时间步的融合遥感影像中充分挖掘冬小麦生长发育过程中的空间和时间特征，本研究将结合卷积块注意力的卷积神经网络模块（CNN_CBAM模块）和结合注意力机制的双向门控循环单元模块（BiGRU_Attention模块）结合起来，开发了CNN、BiGRU与三重注意力机制结合的CBTA冬小麦产量预测模型，模型的总体结构如图4-1所示。CNN_CBAM模块包括CNN和双重注意力机制。在第一重通道注意力机制的作用下，CNN处理特征图通道的分布关系。然后，CNN在第二种空间注意力机制的作用下，更加关注遥感影像中的决定性像素区域，充分探索影像中更重要的空间光谱信息，忽略无关的噪声信息。BiGRU_Attention模块包括BiGRU和第三重注意力机制。BiGRU考虑了冬小麦生长过程前后的时间信息，并进一步挖掘了空间光谱特征映射的时间特征。最后，第三重注意力机制分配不同的权重来计算产量值。




图 4-1 CBTA模型的总体结构图

4.1.1 结合卷积注意力的卷积神经网络模块

冬小麦分布通常呈现聚集性，并且在生长发育的过程中反射空间光谱也在动态变化，因此准确的冬小麦产量预测必须考虑挖掘遥感影像中的空间光谱信息。卷积神经网络能够通过卷积层的一系列操作很好地提取空间特征，并利用包含多种不同形式非线性池化函数的子采样层不断压缩数据的空间大小，从而降低维度、减少计算的参数量^[83]。因此，本研究利用CNN独特的卷积结构提取遥感影像中丰富的光谱特征以及像素间的空间相关性。

另外，在注意力机制的指导下，卷积神经网络会给特征分配不同的权重参数并专注于对当前任务目标更关键的信息，从而增强深度学习模型提取和刻画这些特定特征的能力，提高预测模型的精度^[84]。卷积注意力模块（CBAM）是一种简单有效的轻量级注意力模块，可以方便地与大多数CNN模型结合，从通道和空间两个维度进行特征的自适应学习，在不显著增加计算量和参数数量的情况下，提高模型的特征筛选和提取能力^[85]。

如图4-2所示，CBAM包含第一重通道注意力模块（CAM）和第二重空间注意力模块（SAM），从通道和空间两个维度分配注意力权重以提升模型性能。其中，CAM采用全局最大池化和全局平均池化聚合特征图的空间信息，随后进入共享参数的感知机（MLP）中生成两次二维映射，得到通道的注意力权重，接着将这两个生成的二维映射进行加和操作，然后通过Sigmoid激活函数获得归一化注意力权重，最后通过乘法逐通道加权到原始输入特征图上。这一过程的公式为：

$$\begin{aligned} A_c(F) &= \sigma(MLP(Avgpool(F)) + MLP(Maxpool(F))) \\ &= \sigma(W_1(W_0(F_{avg}^c)) + W_1(W_0(F_{max}^c))) \end{aligned} \quad (4-1)$$

$$F' = A_c(F) \otimes F \quad (4-2)$$

其中，F为输入特征映射， A_c 代表通道注意力模块运行， σ 表示Sigmoid激活函数，MLP表示感知机，Avgpool表示平均池化，Maxpool表示最大池化， W_1 和 W_0 是MLP的权重，两者共享输入， F_{avg}^c 表示平均池化特征， F_{max}^c 表示最大池化特征， F' 为通道注意力模块提取后的输出， $\otimes$ 表示元素乘法。

SAM将经过CAM得到的特征图分别基于通道维度进行平均池化和最大池化，然后拼接起来利用卷积层降维生成空间注意力图编码对具体位置进行加权，通过Sigmoid激活函数生成空间权重系数，最后将空间注意力二维映射与通道注意力二维映射合并，输

出最终的特征图。这一过程的公式为：

$$\begin{aligned} A_s(F) &= \sigma(\text{Conv}([\text{Avgpool}(F); \text{Maxpool}(F)])) \\ &= \sigma(\text{Conv}([F_{avg}^s; F_{max}^s])) \end{aligned} \quad (4-3)$$

$$F'' = A_s(F') \otimes F' \quad (4-4)$$

其中，其中F为输入特征映射， A_s 代表空间注意力模块运行， σ 表示Sigmoid激活函数，Conv表示卷积运算，Avgpool表示平均池化，Maxpool表示最大池化， F_{avg}^s 表示平均池化特征， F_{max}^s 表示最大池化特征， F'' 为空间注意力模块提取后的输出， $\otimes$ 表示元素乘法。




图 4-2 CBAM模型的概览

如图4-1的左半部分所示，输入的数据为每个时间步的融合遥感图像。首先利用卷积神经网络四个隐藏层中 3×3 的卷积窗口滑动挖掘光谱特征，采用池化窗口为 2×2 、池化步长为2的最大池化处理得到特征映射结果。然后添加CBAM后,CNN模块在第一重通道注意力机制的作用下处理特征图通道的分配关系，并且在第二重空间注意力机制的作用下更加关注影像中起决定作用的像素空间区域，进而充分挖掘遥感影像中更主要的空间光谱信息，最终获得高维的空间光谱特征映射 $\{x_1, x_2, \dots, x_t\}$ 。

4.1.2 结合注意力机制的双向门控循环单元模块

在冬小麦生长发育过程中，其生长环境与植株形态会随时间的变化而改变。因此，在CNN和CBAM相结合得到不同时间步的空间光谱特征的基础上，利用结合注意力机制的双向门控循环单元神经网络进一步挖掘深层次的时序特征。由于每一时刻的输出和前一时刻的信息以及后一时刻的信息都密切相关，所以本研究选取由单向的、方向相反的门控循环单元（GRU）组成的双向门控循环单元(BiGRU)，学习冬小麦生长特征的动态变化规律。如图4-3 (a)所示，GRU是长短期记忆网络（LSTM）的变体，由重置门 r_t 、更新门 z_t 和隐藏状态 h_t 组成，其中隐藏状态 h_t 用来提取连续的时间序列特征，结合冬小麦先

前生长特征学习当前的特征信息；重置门 r_t 用于控制遗忘前一时刻的隐藏状态 h_{t-1} 的程度；更新门确定先前时刻的状态信息在当前隐藏状态 h_t 中的保留程度。 t 时刻的迭代参数计算如下：

$$r_t = \sigma(W_{xr}x_t + W_{hr}h_{t-1} + b_r) \quad (4-5)$$

$$z_t = \sigma(W_{xz}x_t + W_{hz}h_{t-1} + b_z) \quad (4-6)$$

$$\tilde{h}_t = \text{Tanh}(W_{xh}x_t + r_t \odot W_{hh}h_{t-1} + b_h) \quad (4-7)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (4-8)$$

其中， x_t 为 t 时刻的输入， r_t 、 z_t 、 $\tilde{h}_t$ 和 h_t 分别表示更新门、重置门、候选状态、隐藏状态， σ 是Sigmoid激活函数， $W_{\{\cdot\}\{\cdot\}}$ 和 $b_{\{\cdot\}}$ 表示权重矩阵和偏置， $\odot$ 表示矩阵运算。

为了了解冬小麦生长特征的动态变化规律，本研究由于各时刻的输出与前后时刻的信息密切相关，选择了由单向和反向GRU组成的BiGRU。如图4-3 (b)所示，BiGRU将不同时间步获取的高维空间光谱特征作为输入，并利用两个反向的GRU在 t 时刻同时处理输入信息。BiGRU当前的隐层状态由当前的输入 x_t 、 $(t-1)$ 时刻向前的隐层状态的输出 $\vec{h}_t$ 和反向的隐层状态的输出 $\overleftarrow{h}_t$ 三个部分共同决定，BiGRU在 t 时刻的隐层状态通过前向隐层状态 $\vec{h}_{t-1}$ 和反向隐层状态 $\overleftarrow{h}_{t-1}$ 加权求和得到：

$$\vec{h}_t = \text{GRU}(x_t, \vec{h}_{t-1}) \quad (4-9)$$

$$\overleftarrow{h}_t = \text{GRU}(x_t, \overleftarrow{h}_{t-1}) \quad (4-10)$$

$$h_t = w_t \vec{h}_t + v_t \overleftarrow{h}_t + b_t \quad (4-11)$$

其中， $\text{GRU}(\cdot)$ 函数表示对输入的非线性变换， w_t 、 v_t 分别表示 t 时刻前向隐层状态 $\vec{h}_t$ 和反向隐层状态 $\overleftarrow{h}_t$ 所对应的权重， b_t 表示 t 时刻隐层状态所对应的偏置。

为了反映特征向量在冬小麦不同生长阶段对产量的重要性，本研究加入第三重注意力机制，根据BiGRU的输出产生不同的注意力权重值。首先，利用Tanh激活函数对BiGRU层的输出映射矩阵 h_k 进行正交变换，得到其隐式矩阵表示 u_k ，接着利用Softmax激活函数归一化得到注意力概率分布值 $\{\alpha_1, \alpha_2, \dots, \alpha_t\}$ 。然后，注意力机制计算生成注意力权重矩阵 α 和特征表示 v ，并利用特征表示计算预测冬小麦产量输出 y ，具体过程如下：

$$u_k = \text{Tanh}(w_z h_k + b_z) \quad (4-12)$$

$$\alpha_k = \frac{\exp(u_k^T u_s)}{\sum_{k=1}^t \exp(u_k^T u_s)}, \sum_{k=1}^t \alpha_k = 1 \quad (4-13)$$

$$v = \sum_{k=1}^t \alpha_k h_k \quad (4-14)$$

$$y = W_r v + b_r \quad (4-15)$$

其中， w_z 为注意力机制层权重矩阵， b_z 为偏差向量， u_s 为随机初始化的时间序列注意力机制矩阵。重视值越高说明特征对冬小麦产量的影响越大。 r 为样本数， W_r 和 b_r 分别对应输出层的权重矩阵和偏移量。




图 4-3 GRU ((a))和BiGRU ((b))的模型的概览

如图4-1右半部分所示，将CNN_CBAM模块特征提取后得到的高维空间光谱特征映

射作为BiGRU_Attention模块的输入序列 $\{x_1, x_2, \dots, x_t\}$ 。为了避免过拟合问题，在BiGRU层前和注意机制层后分别添加了两个值均为0.5的退出层。最终，BiGRU的输出特征映射 $\{h_1, h_2, \dots, h_t\}$ 经过第三重注意力机制分配不同的权重计算输出得到冬小麦的产量值。

4.2 模型评价指标及参数设置

为了评价模型在冬小麦产量预测中的性能，本研究选择了4个评价指标，包括均方根误差(RMSE)、平均绝对误差(MAE)、决定系数(R^2)和误差系数(EC)，计算公式如下：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - y'_i)^2} \quad (4-16)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - y'_i| \quad (4-17)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (4-18)$$

$$EC = (y'_i - y_i) / y_i \quad (4-19)$$

其中， n 为样本量， y_i 和 y'_i 为样本 i 的真实产量和预测产量， $\bar{y}$ 为真实产量的平均值。

此外，本研究使用Pytorch来构建和训练冬小麦产量预测模型，并采用留一法来评价模型的准确性。具体来说，将河南省各县域2002~2017年每年的数据依次作为测试集，剩下的其他年份的数据作为训练集，最后计算多次测试结果的平均值，这样可以更好地反映模型的泛化能力。该过程在NVIDIA Tesla 2080Ti GPU上执行，内存为16GB。本研究将模型训练批量大小设置为64，迭代轮次设置为1000，学习率初始值为0.0001，并利用ReduceLROnPlateau回调函数不断优化学习率，采用均方误差(MSE)评价模型训练过程中的损失。此外，为了避免网络训练过程中过拟合的问题，保证网络具有足够的泛化能力，在BiGRU层之前和第三重注意力机制层之后分别增加两个值为0.5的退出层。此外，本研究还使用了均方误差(MSE)来评估训练过程中的损失。

4.3 实验与分析

4.3.1 CBTA模型县级产量预测精度

如图4-4所示，本研究采用留一法训练CBTA模型，根据2002~2017年河南省105个县

冬小麦生育期内的数据获得预测结果并绘制县级尺度冬小麦预测产量和真实产量的散点图。结果表明，CBTA模型在县域上的估算效果较好，RMSE、MAE、 R^2 分别为0.469吨/公顷、0.336吨/公顷、0.827，预测产量与真实产量总体接近1:1线，仅有零星几个离群值。此外，如图4-5所示，根据15年的预测结果计算预测产量和真实产量的误差系数的平均值进行空间可视化。可以看出，预测整体效果较好，大部分区县的误差系数介于-0.1~0.1之间，仅存在个别区县预测值过高或过低的情况，说明CBTA模型是一个合格的预测模型，具有准确预测冬小麦产量的能力。不过，对于部分产量较低的区县（如西峡县和栾川县）和部分产量较高的区县（如滑县和郸城县），CBTA模型预测误差偏大且表现出高估低产量区县和低估高产量区县的特点。这可能与数据集的样本量较小有关，因为在一个地区的一年内只有一个冬小麦产量，所以本研究处理的河南省样本量较小。在样品数据集中，低产量和高产样品的比例低于中间生产样品。CBTA深度学习模型在训练后不能完全学习这些信息的特征，但倾向于预测中等产量的样本。因此，本研究的第二个研究内容是扩大数据集样本，以提高CBTA的学习能力。




图 4-4 县级尺度冬小麦预测产量和真实产量的散点图




图 4-5 预测产量和真实产量的误差系数图

4.3.2 CBTA模型性能评估

如表4-1所示，为验证CBTA产量预测模型的优越性，本研究将其与当前流行的深度学习模型进行了比较，并进行了消融实验。为确保比较的公平性，所有产量预测模型均使用河南省各县域2002~2017年冬小麦发育期内的数据集且均在相同的软硬件环境下训练和测试。

表 4-1 不同方法之间的准确性评价的比较

模型	RMSE(吨/公顷)	MAE(吨/公顷)	R ²
CBTA	0.469	0.336	0.827
CNN_CBAM_BiGRU	0.542	0.425	0.781
CNN_ABiGRU	0.604	0.449	0.758
CNN_BiGRU	0.763	0.591	0.663
CNN_GRU	0.828	0.647	0.634
CNN_LSTM	0.845	0.668	0.612
CNN	0.957	0.783	0.546
BiGRU	0.995	0.807	0.514


从表4-1中可以看出，所提出的CBTA产量预测模型的RMSE、MAE、R²分别为0.469吨/公顷、0.336吨/公顷、0.827，相较于仅结合卷积注意力模块的CNN_CBAM_BiGRU模型、仅在BiGRU后结合一次注意力机制的CNN_ABiGRU和不结合注意力机制的

CNN_BiGRU模型的RMSE分别降低了13.47%、22.35%、38.53%，MAE分别降低了20.94%、25.16%、43.15%。这表明CBTA产量预测模型能准确预测冬小麦产量，并且模型中的三重注意力机制在提取遥感影像时空特征，挖掘特征变量与冬小麦产量的关系的过程中发挥了重要的作用。CNN与BiGRU相结合的产量预测模型的RMSE为0.763吨/公顷，比CNN与GRU结合的模型、CNN与LSTM结合的模型、单一的CNN模型和单一的BiGRU模型分别降低了7.85%、9.71%、20.27%、23.32%，CNN_BiGRU模型的MAE为0.591吨/公顷，比CNN_GRU、CNN_LSTM、CNN模型分别降低了8.66%、11.53%、24.52%、26.77%，表明使用单一的神经网络进行冬小麦产量预测效果不佳。CNN能有效地提取遥感影像中的空间光谱特征，但冬小麦在生长发育过程其形态特征随发育阶段动态变化，缺乏发育阶段前后的时序信息影响了CNN的性能，而BiGRU能整合冬小麦生长发育不同阶段前后的时间信息，但对空间信息的捕捉能力。因此，将CNN与BiGRU结合起来能够有效地提取冬小麦生长期的时空特征信息。而与CNN结合时，BiGRU与LSTM和GRU相比，在优化神经网络、加快模型收敛速度的基础上，充分兼顾前后时刻的输入信息，更能够提高特征提取的准确率，进而提高产量预测模型的预测精度。


因此，通过比较可知，本研究搭建的CBTA产量预测模型结合了三重注意力机制，利用CNN和BiGRU充分挖掘时间序列遥感影像的时间和空间特征信息，大大提高了河南省冬小麦产量预测的精度。

4.3.3 CBTA模型稳定性验证

如图4-6所示，本研究对2003~2017年CBTA模型与当前流行的CNN_GRU模型的年度评价指标数据进行了比较，验证了CBTA模型的稳定性。CBTA模型对应的RMSE、MAE和 R^2 值之间的最大差值分别为0.283吨/公顷、0.275吨/公顷和0.202，总体上相对稳定。然而，CNN_GRU模型对应的值差异很大，年份之间的最大差异分别为0.381吨/公顷、0.394吨/公顷和0.332，表明总体波动较大。相较于其他年份，2009年CBTA产量预测模型的RMSE、MAE、 R^2 分别为0.679吨/公顷、0.588吨/公顷、0.665，误差明显偏大，这是因为2009年河南省因风雹、洪涝等自然灾害导致的受灾面积显著高于其他年份，影响了当年冬小麦的产量，导致模型预测出现了偏差。虽然2009年的误差较大，但是仍然远小于以往的研究，这也验证CBTA模型具备优秀的预测能力并且能够很好的捕捉到冬小麦产量的年际变化。未来，本研究将考虑自然灾害等影响因素，改进数据集，以提高CBTA模型的预测性能。



(a)



(b)

图 4-6 CBTA模型((a))和CNN_GRU ((b))各年份RMSE、MAE、 R^2 的值 (RMSE、MAE的单位为吨/公顷)

4.3.4 产量预测特征贡献度分析

如表4-2所示, 为评估融合遥感影像中各个波段对应的特征变量对冬小麦产量预测的影响程度, 本研究依次删除一个特征变量对应的波段信息训练模型, 并计算模型的评

价指标。从表中可以看出,所选的特征指标对冬小麦产量形成影响较大。其中,MODIS的三款数据产品对应的LSR、LST、LAI对冬小麦产量预测的影响相较于Terra Climate的单波段气象环境指标更大,这表明这三种特征变量包含了更多冬小麦生长状态的信息。实际上,LSR和LAI包含了通过冬小麦冠层光谱特征及其差异变换反映的植被覆盖度、植被光合作用、生长状态等信息^{[86][87]},而LST与冬小麦冠层温度及其呼吸作用联系密切,对冬小麦产量的形起了非常重要的作用^[88]。此外,在Terra Climate的气象环境指标中,AE、VPD和SM对冬小麦产量的影响最大,这是因为它们与冬小麦蒸腾作用、水分传输和大气间的水汽交换有关^[89]。而PR、CMD、SWR、Tmax、Tmin、VP、SWE、PDSI这些气象因素都在一定程度上反映了冬小麦的生长发育情况,对冬小麦产量产生了影响。

表 4-2 依次删除每个特征波段的改变

特征变量	RMSE(吨/公顷)	MAE(吨/公顷)	R ²
LSR	↑0.227	↑0.250	↓0.229
LST	↑0.194	↑0.221	↓0.208
LAI	↑0.255	↑0.272	↓0.253
AE	↑0.150	↑0.166	↓0.174
CMD	↑0.076	↑0.083	↓0.089
SWE	↑0.017	↑0.021	↓0.023
SM	↑0.128	↑0.139	↓0.145
PDSI	↑0.012	↑0.012	↓0.016
PR	↑0.112	↑0.117	↓0.121
SWR	↑0.063	↑0.070	↓0.072
Tmin	↑0.038	↑0.047	↓0.048
Tmax	↑0.059	↑0.068	↓0.064
VP	↑0.024	↑0.033	↓0.035
VPD	↑0.139	↑0.153	↓0.156

4.3.5 冬小麦不同生育期预测性能分析

如图4-7所示,本研究分别对单一生育期时间步和累计生育期时间步进行单产预测并计算模型精度的评价指标,以探究冬小麦产量预测的最佳时间窗。图中评价指标RMSE、MAE前的C表示累计生育期,S表示单一生育期。由图可知,CBTA产量预测模型在冬小麦生育期初期性能较差,RMSE和MAE分别为0.913吨/公顷、0.749吨/公顷,这是因为产量预测模型在冬小麦生长发育初期输入的融合遥感影像数据量较少,难以学习到足够的

冬小麦生长状态和气象环境信息，但模型会随着累计时间步的堆叠发掘更多相关联的信息，使得预测越来越准确。显然，使用单一生育期时间步的预测效果比使用全部生育期时间步低很多，这是因为单一生育期时间步的融合遥感影像数据中的信息量十分局限，产量预测模型无法整合前后生育期冬小麦生长状态相关信息，从而难以进行准确的产量预测。另外，播种~孕穗期时间步（CS4）相较于播种~起身期时间步（CS3）产量预测效果显著提升。因为在返青~起身期（SS3）时，冬小麦叶片会随着春季温度的升高开始变得深绿，新叶新芽开始出现。而在拔节期，冬小麦基部节间开始伸长，露出地面1.5~2厘米，界限逐渐分明^[90]。这表明CBTA模型能够在冬小麦不同生长发育阶段准确捕捉其生长发育过程的特点和变化。还有，在播种~成熟期（CS6）时，CBTA产量预测模型精度最高，这表明在冬小麦生育后期，CBTA产量预测模型有效整合了冬小麦所有的生长发育信息，从而具备精确预测冬小麦单位面积产量的能力。从图中还能看出冬小麦播种~孕穗期（CS4）和播种~开花期（CS5）产量预测模型预测精度相当，RMSE分别为0.528吨/公顷和0.486吨/公顷，与播种~成熟期（CS6）精度非常接近，说明CBTA产量预测模型在冬小麦生育期的中后期已经达到不错的预测效果，进一步说明该模型有能力提前1~2个月预测冬小麦产量。




图 4-7 各生育期时间步CBTA模型产量预测精度

第五章 基于SA-DCGAN模型的冬小麦产量预测增强网络

5.1 产量预测增强网络的构建

针对冬小麦产量预测的样本数据集规模不足的问题,本研究利用结合自注意力机制的深度卷积生成对抗网络(SA-DCGAN)进行数据增强,扩大县域冬小麦产量预测的样本集数目。增强网络总体结构如图5-1所示。其中,生成器是一个反卷积过程,通过四个反卷积层将随机噪声矩阵转化为伪造图像;判别器是一个去除了全连接层的卷积神经网络,通过四个卷积层判断输入图像的真假并输出判断结果。同时,在生成器和判别器的卷积层中间加入自注意力机制,进一步获得全局信息和图像间的信息关联,从而实现高效的自注意力计算,加快模型学习和训练的速度,并提高模型的表现能力,增强模型对输入序列中不同特征的理解和提取能力。另外,判别器和生成器在相互对抗的同时不断迭代优化自己的性能。当伪造图像数据和真实图像数据极度相同,判别器无法分辨时,生成器此时已经学会了真实融合遥感影像数据的分布。接着将SA-DCGAN生成的增强遥感影像数据集作为CBTA冬小麦产量预测模型的输入数据集,最终训练得到冬小麦产量的预测值。




图 5-1 基于SA-DCGAN的产量预测增强网络的总体结构图

5.1.1 生成对抗网络

生成对抗网络(GAN)对于在复杂分布数据集上的相关应用极具潜力,这个深度学习框架的主要思想是最小最大两人博弈^[91]。GAN由两个协作紧密的部分构成:一个是生成器G,它致力于发掘真实数据样本内部的潜在分布规律,并根据这些特征生成尽可能逼真的全新的数据样本;另一个是判别器D,它需要精准鉴别输入样本的真伪性。基于GAN生成新数据样本的过程如图5-1所示。




图 5-2 GAN 数据增强过程

将真实数据和随机噪声分别作为判别器D和生成器G的输入。伪造样本G(z)由生成器G从随机噪声z中生成,并通过D的反馈进行优化,使其尽可能服从真实数据的分布,判别器D对真实数据进行真伪判别。D和G训练过程中的公式如下:

$$\min_G \max_D V(D, G) = E_{x \sim P_{data}(x)} [\log D(x)] + E_{z \sim P_z(z)} [\log(1 - D(G(z)))] \quad (5-1)$$

其中, $V(D, G)$ 表示最小最大两人博弈的值函数; $P_{data}(x)$ 表示真实数据x的概率分布, $P_{z(z)}$ 表示噪声变量z的概率分布; $x \sim P_{data}(x)$ 表示从真实样本数据中采样的值x, $z \sim P_{z(z)}$ 表示根据z的概率分布产生的随机噪声值z; E为真实数据x和噪声变量z的数学期望; $D(x)$ 表示x来自真实数据的概率; $D(G(z))$ 表示生成数据是真实数据的概率。训练判别器D调整参数的优化目标是使 $D(x)$ 最大化, $D(G(z))$ 最小化,即使训练样例和来自生成器G的样本都获得正确标签的概率最大化,而训练生成器G调整其参数的优化目标是使 $D(G(z))$ 最大化。

D和G在相互对抗的同时不断迭代优化自己的性能。当假数据和真实数据极度相同, D无法分辨时, 认为生成器G已经学会了真实数据的分布。生成器G和判别器D总体损失函数表示为使生成的数据分布与实际数据分布之间的距离最小。给定生成条件, 最佳判别器D的公式如(5-2)所示:

$$D(x) = \frac{P_{data}(x)}{P_{data}(x) + P_z(x)} \quad (5-2)$$

经过几个步骤的训练，G和D达到了一个点，即 $P_z = P_{data}$ ，两者都无法提高。鉴别器无法区分输入的两类数据内部的分布，此时 $D(x) = 1/2$ 。

5.1.2 结合自注意力机制的深度卷积生成对抗网络

传统的GAN方法在训练过程中自身的自由度过大，很容易失去收敛方向，并且GAN的深度神经网络在训练中不稳定，容易出现欠拟合或过拟合^{[92][93]}。因此，在训练过程中很难调整GAN本身的参数。生成器与判别器使用相同的反向传播网络也导致原始的GAN网络在生成器生成新图像的过程中不太稳定，难以保证得到高质量的生成结果，而深度卷积生成对抗网络（DCGAN）从卷积神经网络结构的多层感知器MLP结构扩展GAN^[94]。它其实是卷积神经网络在GAN中的一种特殊应用。在传统的CNN中，特征提取和下采样分别通过卷积层和池化层进行。但在DCGAN中，判别器和生成器取消了池化层^[95]，只留下卷积层，在卷积层和激活函数之间加入批处理归一化，实现局部归一化，允许网络自行学习空间上下采样，极大地改进了网络模型。这使得其在GAN的基础上进行了扩展，既保留了生成优秀数据的能力，又融合了CNN特征提取的优势，在图像分析和处理能力上有了提升。此外，为了进一步获得全局信息，采用更深层次的网络结构是常用的方法，但由于训练参数过大，训练难度大，会造成过拟合问题。而自注意力机制在计算每个像素位置的输出时能够和图像中所有位置计算相关性并分配不同的权重，从而捕捉图像中的全局依赖关系^[96]。将它们集成到DCGAN模型中可以简单有效地解决这一问题，即用自注意力特征映射代替传统的卷积特征映射。自注意力机制模块中权重的计算成本很小，这能够大大减少纯卷积GAN的参数计算量，同时兼顾其根据所有位置的提示信息生成详细数据，更好地协调位置细节和远程细节的能力。因此，本研究设计了基于结合自注意力机制的深度卷积生成对抗网络结构（SA-DCGAN）的产量预测增强网络，扩大河南省县域冬小麦产量预测的样本集数目，进一步提升模型产量预测的能力。

本研究所提出的增强网络中的自注意力机制结构如图5-3所示。首先，通过两次卷积再次得到前一层卷积得到的特征图，并对特征图的后两个维度进行平面化处理。其中， $f(x)$ 、 $g(x)$ 、 $h(x)$ 是 1×1 的普通卷积，分别通过不同大小的输出通道的卷积减少影像中的通道数。接着，将特征映射的输出通过卷积层 $f(x)$ 进行转

置,与 $g(x)$ 的输出相乘,然后通过Softmax分类器进行归一化,得到自注意力映射图。最后,将得到的自注意力图与 $h(x)$ 的输出特征图逐像素相乘,得到自注意力特征图。




图 5-3 自注意力机制结构图

而SA-DCGAN的生成器负责从潜在空间中获取随机向量,并将获取到的随机噪声矩阵映射到向量数据空间中的图像。此映射使用一系列反卷积层、批量归一化层和ReLU激活函数层。在每个反卷积层之后使用批量归一化有助于改善通过网络的梯度流,从而在训练过程中获得更好的性能和稳定性。同时,在反卷积层中间加入自注意力机制进一步获得图像的全局特征信息,提升生成器的能力。此外,生成器的最后一层使用Tanh激活函数来确保输出图像在 $[-1,1]$ 范围内,这是图像数据的预期范围。结合自注意力机制的DCGAN (SA-DCGAN)的生成器如图5-4所示:




图 5-4 SA-DCGAN 的生成器图

SA-DCGAN的判别器负责区分生成器生成出的图像的真伪性。对于SA-DCGAN图像生成过程,判别器使用跨步卷积代替池化层。这种方法使网络

能够开发自定义填充函数，从而提高性能，帮助判别器更准确地区分真实图像和伪造图像。此外，在卷积层中间加入自注意力机制进一步获得图像的全局特征信息，提升判别器鉴别真伪的能力。判别器具体包含一系列跨步卷积层、批量归一化和LeakyReLU激活函数层。最后，通过一个全连接层输出通过返回概率值的Sigmoid层传递以确保输出判断结果处于0~1之间。输出值接近1代表判断为真实图像，接近0代表判断为伪造图像。结合自注意力机制的DCGAN（SA-DCGAN）的判别器如图5-5所示：




图 5-5 SA-DCGAN 的判别器图

本研究所使用的融合遥感影像数据集的时间分辨率为2002~2017年间每年的第 273 天到次年的第193天，每个周期共39张遥感影像，对应于一个单位面积冬小麦年产量标签值。将河南省各县域时间分辨率内的融合遥感影像数据集作为输入层的输入，而标签集为目标向量，由各县域时间分辨率内的单位面积冬小麦年产量数据组成。在此基础上分别训练SA-DCGAN的判别器和生成器，二者在相互对抗的过程中不断迭代优化自己的性能。当生成器生成的伪造图像数据和真实图像数据极度相同导致判别器无法分辨时，生成器此时已经学会了真实融合遥感影像数据的分布。接着将SA-DCGAN生成的增强遥感影数据集作为CBTA冬小麦产量预测模型的输入数据集，最终训练得到冬小麦产量的预测值。

5.2 模型评价指标及参数设置

为了评价产量预测增强网络模型在冬小麦产量预测中的性能，本研究仍然选择上述4个评价指标，包括均方根误差(RMSE)、平均绝对误差(MAE)、决定系数

(R^2)和误差系数(EC)。此外,本研究仍然使用Pytorch来构建和训练本研究的模型,并采用留一法来评价模型的准确性。具体来说,利用SA-DCGAN进行数据增强,扩大河南省各县域时间分辨率内的数据集规模后,将河南省各县域每年的数据依次作为测试集,剩下的其他年份的数据作为训练集,最后计算多次测试结果的平均值,这样可以更好地反映模型的泛化能力。


对于SA-DCGAN图像生成,本研究使用ADAM优化器,学习率设置为0.0002,优化器对应的beta参数设置为(0.5,0.999),这些参数用于控制优化器的动量,有助于加速收敛和避免振荡。对于SA-DCGAN的判别器和生成器,本研究使用不同的优化器,以确保二者独立学习。对于生成器,卷积步长设置为 2×2 ,退出层设置为0.5,卷积核大小设置为 5×5 ,使用平均绝对误差和均方误差计算每轮训练后的生成器损失。对于判别器,卷积步长设置为 2×2 ,卷积核大小设置为 3×3 ,并采用LeakyRELU激活函数进行快速计算和快速收敛,利用二元交叉熵分析判别器的精度和损失。增强模型的整体训练损失为判别器和生成器的损失之和。整个训练过程在NVIDIA Tesla 2080Ti GPU上执行,内存为16GB。本研究将产量预测模型训练批量大小设置为64,迭代轮次设置为1500,学习率初始值为0.0001,并利用ReduceLROnPlateau回调函数不断优化学习率,采用均方误差(MSE)评价产量预测模型训练过程中的损失。此外,为了避免网络训练过程中过拟合的问题,保证网络具有足够的泛化能力,在BiGRU层之前和第三重注意力机制层之后分别增加两个值为0.5的退出层。此外,本研究还使用了均方误差(MSE)来评估产量预测模型训练过程中的损失。

5.3 实验与分析


5.3.1 增强网络县级产量预测精度

本研究利用SA-DCGAN在原有河南省冬小麦县域数据集的基础上额外生成了与原始数据集数量相同的伪造数据集,并将真实数据集与伪造数据集合并成为河南省冬小麦产量预测增强数据集。分别以伪造数据集和增强数据集作为CBTA产量预测模型的输入数据集进行产量预测,并采用留一法训练CBTA模型得到各自的预测结果。如图5-6和图5-7所示,本研究绘制县级尺度冬小麦预测产量和真

实产量（产量标签值）的散点图以及根据15年的预测结果计算预测产量和真实产量的误差系数的平均值进行空间可视化。从散点图中可以看出，利用训练好的SA-DCGAN生成器生成的伪造数据集在河南省县域上进行冬小麦产量预测的预测效果良好，RMSE、MAE、 R^2 分别为0.538吨/公顷、0.411吨/公顷、0.774，相较于原始数据集精度仅略微下降。此外，对比使用伪造数据集进行产量预测的散点图（图5-6 (a)）和使用原始数据集进行产量预测的散点图（图4-4）可以看出，二者的预测趋势相似度较高，总体来看，二者的预测产量与真实产量接近1:1线且离群值相对较少，预测结果整体效果较好。从图5-7 (a)可以看出，大部分区县的误差系数介于-0.1~0.1之间，仅存在个别区县预测值过高或过低的情况。同时，由于单独的一种数据集样本量不足，CBTA产量预测模型高估低产量区县和低估高产量区县的特点依然存在。这表明SA-DCGAN的生成器训练情况良好，有能力生成出与原始数据集拥有相似特性的伪造数据集，并且生成的数据集可以被用来作为CBTA冬小麦产量预测模型的输入数据集。另外，从图5-6 (b)中可以看出，当数据集样本数量增加即使用包含原始数据集和伪造数据集的增强数据集进行冬小麦产量预测时，RMSE、MAE、 R^2 分别达到了0.394吨/公顷、0.279吨/公顷、0.868，预测产量与真实产量更加接近1:1线且离群值相对更少，模型预测效果有了明显提升。同时，观察图5-7 (b)发现，相较于原始数据集的预测结果，有更多的区县的误差系数介于-0.1~0.1之间，模型预测的精度更高。而且，由于数据集规模的增加，CBTA产量预测模型能够学习到更多气象环境影响因素与冬小麦产量之间的关联信息，预测模型高估低产量区县和低估高产量区县的特点有了很大的改善。这也验证了通过SA-DCGAN数据增强方法扩大数据集规模对冬小麦产量预测能产生许多积极的影响，为通过数据增强等方法增加样本集数量来解决小样本问题特别是农作物产量预测提供了可能与思路。




(a)




(b)

图 5-6 使用伪造数据集((a))和增强数据集((b))冬小麦预测产量和真实产量的散点图



(a)



(b)

图 5-7 使用伪造数据集((a))和增强数据集((b))预测产量和真实产量的误差系数图

5.3.2 产量预测增强网络性能评估

为验证SA-DCGAN对融合遥感影像数据集的数据增强效果以及结合自注意力机制的有效性，本研究分别以SA-DCGAN生成的增强数据集、传统GAN方法生成的增强数据集、结合自注意力机制的GAN方法（SAGAN）生成的增强数据集、不结合注意力机制的纯卷积DCGAN生成的增强数据集、以及不包含任何生成数据集的原始数据集作为CBTA产量预测模型的输入数据集，进行河南省冬小麦产量预测对比实验，不同模型预测准确性如表5-1所示。为确保比较的公平性，SA-DCGAN、GAN、SAGAN、DCGAN模型均在相同的软硬件环境下训练和测试，并与CBTA结合进行产量预测。

表 5-1 不同模型的准确性评价的比较

模型	RMSE(吨/公顷)	MAE(吨/公顷)	R ²
SA-DCGAN_CBTA	0.394	0.279	0.868
SAGAN_CBTA	0.413	0.298	0.851
DCGAN_CBTA	0.422	0.303	0.845
GAN_CBTA	0.438	0.312	0.839
CBTA	0.469	0.336	0.827

从表5-1中可以看出，利用SA-DCGAN生成的增强数据集结合CBTA产量预测模型进行预测的RMSE、MAE、R²分别为0.394吨/公顷、0.279吨/公顷、0.868，相较于利用SAGAN、DCGAN、GAN做数据增强结合CBTA模型估产和不使用任何数据增强方法的CBTA产量预测模型的RMSE分别降低了4.6%、6.64%、10.05%和15.99%，MAE分别降低了6.38%、7.92%、10.58%和16.96%。这表明本研究所提出的SA-DCGAN在对河南省冬小麦融合遥感影像数据进行数据增强方面有着出色的能力，并且通过增强网络生成的增强数据集能作为研究内容一中所提出的CBTA产量预测模型的输入数据集，扩大冬小麦产量预测的样本数据集，从而显著提高模型冬小麦估产的能力。此外，使用在数据增强模型中加入自注意力机制得到的增强数据集进行预测比不添加自注意力机制模块的单一数据增强模型预测效果更好，这表明自注意力机制可以通过对判别器的注意力机制进行调整，使生成器更加注重生成图像的内容和结构，帮助生成器在生成图像时更好地关注到长距离相关结构，更好地控制生成图像的细节和纹理，从而提高生成图像的质量。

同时,自注意力机制能够更好地控制生成器和判别器之间的信息流,从而保持训练过程的稳定性。另外,利用DCGAN做数据增强结合CBTA模型估产比利用GAN生成增强数据集进行产量预测得到的RMSE、MAE分别低3.65%和2.88%, R^2 高0.72%,这是由于DCGAN使用了深度卷积神经网络,能够更好地捕捉图像中的细微结构,从而生成更加逼真、质量更高的图像,并且DCGAN通过改变网络结构提高了生成对抗网络的稳定性。此外,对比使用增强数据集进行产量预测和未使用增强数据集进行产量预测的结果可以发现,增强数据集扩大了原始数据集的样本集规模,CBTA产量预测模型能够从扩大样本规模后的遥感影像数据集中学习到更多关于冬小麦生长发育的信息,进而提高了模型冬小麦产量预测的能力。

因此,通过比较可知,本研究搭建的基于SA-DCGAN模型的产量预测增强网络,利用结合自注意力机制的深度卷积生成对抗网络能够生成高质量的增强数据集,从而扩大产量预测的输入样本集规模,显著提高河南省冬小麦产量预测模型的精度。

5.3.3 增强网络冬小麦累计生育期预测效果分析

由研究内容一可知,单一生育期的融合遥感影像数据中仅包含部分时间步的信息,CBTA产量预测模型无法整合前后生育期冬小麦生长状态相关信息,从而难以进行准确的产量预测。因此,如图5-8所示,本研究在提出SA-DCGAN数据增强模型的基础上,分别用原始数据集、生成的伪造数据集和增强数据集的冬小麦所有累计生育期时间步数据进行单产预测并计算模型精度的评价指标,以探究产量预测增强网络对河南省冬小麦产量预测精度和时间提前量两方面的提升效果。图中评价指标RMSE、MAE前的Y表示使用原始数据集,W表示使用伪造数据集,Z表示使用增强数据集。从图中不难发现,针对冬小麦累计生育期的所有时间步,三类数据集均在冬小麦生育期初期预测性能较差,但随着发育时间步的推移,产量预测网络能够获取到越来越多的影像中与冬小麦生长发育相关的信息,模型的预测性能逐渐提高。虽然使用伪造数据集进行产量预测的精度低于原始数据集,但其在冬小麦生育期产量预测的整体变化趋势与使用原始数据集得到的趋势十分相似。二者的产量预测精度都在拔节~孕穗期时间步(SS4)明显提升且在播种~成熟期(CS6)时产量预测模型精度最高,并且在播种~孕穗期(CS4)

和播种~开花期（CS5）产量预测模型预测精度相当，与播种~成熟期（CS6）精度非常接近。这进一步验证了SA-DCGAN数据增强模型优秀的增强效果，生成的伪造数据集与真实数据集拥有相似的特性。

从图中还可以看出，由于样本集规模的扩大，使用增强数据集进行产量预测的精度明显高于使用原始数据集得到的结果。并且随着累计生育期时间步的推移，增强网络产量预测模型的RMSE、MAE下降的趋势更快，模型精度提升的也更快。这说明由于增强数据集中数据样本量的增多，CBTA产量预测模型能够从数据集中挖掘到更多与冬小麦生长发育相关联的前后时间段的时间和空间信息。此外，值得注意的是，使用增强数据集在播种~孕穗期（CS4）时的RMSE、MAE分别为0.441吨/公顷和0.329吨/公顷，已经低于使用原始数据集在播种~成熟期（CS6）的RMSE和MAE对应的0.469吨/公顷和0.336吨/公顷。这表明基于SA-DCGAN的产量预测增强网络在冬小麦生育期的中后期已经达到了相对较高的产量预测精度，验证了SA-DCGAN数据增强的能力和实用性，进一步提升了冬小麦产量预测的时间提前量，为河南省冬小麦早期产量预测提供了可能。




图 5-8 使用不同数据集冬小麦累计时间步产量预测模型估产精度

第六章 总结与展望

6.1 工作总结

农业生产是国民经济的基础和命脉，河南省冬小麦在我国粮食产量中具有重要地位，及时、准确的冬小麦产量预测对国家粮食安全和农业可持续发展具有重要意义。本研究针对河南省县级尺度冬小麦产量预测问题，深入探索了深度学习技术在实际农业生产中的应用。本研究首先处理得到了包含河南省冬小麦生育期时间段内的遥感影像数据、气象环境数据的融合遥感影像数据集，接着设计了结合三重注意力机制的 CNN-BiGRU 混合神经网络模型（CBTA 模型）进行县域冬小麦产量预测。针对冬小麦产量预测样本集规模不足的问题，本研究提出了结合自注意力机制的深度卷积生成对抗网络（SA-DCGAN 模型）的数据增强方法扩大样本数据集，进一步提升河南省冬小麦产量预测的精度和时间提前量。本文的主要研究成果和结论如下：

（1）本研究提出了一种基于三重注意机制的 CNN-BiGRU 混合神经网络产量预测模型（CBTA）。该模型利用 CNN 挖掘综合气象环境数据的多光谱遥感图像的空间光谱特征，并利用 BiGRU 从多时态遥感图像序列中自适应学习冬小麦生长期不同阶段之间的时间依赖关系。在此基础上，结合三重注意机制，进一步提取了特征变量对冬小麦产量的影响程度。通过稳定性验证和模型比较，验证了 CBTA 能够准确预测县级尺度冬小麦产量。此外，本研究探讨了不同特征变量对冬小麦产量形成的影响和对产量预测的贡献度。本研究还将冬小麦的整个生育期分为 6 个时间步，CBTA 产量预测模型在播种~成熟期的预测精度最高，在播种~孕穗期和播种~开花期产量预测模型预测精度相当，与播种~成熟期非常接近，说明 CBTA 产量预测模型有能力提前 1~2 个月准确预测冬小麦产量。

（2）本研究提出了一种基于结合自注意力机制的深度卷积生成对抗网络（SA-DCGAN）的产量预测增强网络。该模型利用卷积神经网络替代传统 GAN 中的多层感知机生成图像从而提高生成图像的能力。此外，在生成器和判别器中加入了自注意力机制专注于分散在信号特征向量不同位置又与结构相关的区域并捕捉全局信息间的依赖关系，进一步提高生成图像的质量。本研究利用 SA-DCGAN 进行数据增强生成和原始数据集特性类似的伪造数据集，并分别使用原始数据集、伪造数据集和二者合并的增强数据集预测冬小麦的产量，对比预测结果差异，验证了数据增强的效果。同时，通过与传统 GAN 方法的增强结果对比，以及针对自注意力机制进行的相关消融实验验证了所

提出的数据增强模型结构和性能的优越性。此外，本研究分别在三种冬小麦累计生育期时间步数据集上进行单产预测，产量预测增强网络在播种~孕穗期的预测误差已经低于使用原始数据集在播种~成熟期的误差。这表明基于SA-DCGAN的产量预测增强网络在冬小麦生育期的中后期已经达到了相对较高的产量预测精度，进一步提升了冬小麦产量预测的精度和时间提前量。

6.2 研究展望

本文提出的基于深度学习的河南省冬小麦产量预测虽然在预测精度和时间提前量方面取得了一定的进展，但是仍然存在一些问题需要进一步研究和探讨，主要包括以下几点：

（1）本文所提出的CBTA模型和SA-DCGAN模型在冬小麦产量预测方面取得了显著的成果，但仍有进一步优化和提升的空间。因此，未来的研究将致力于改进模型结构、优化参数设置，以提高模型的预测精度和泛化能力。

（2）本文使用的数据集中包含了一部分遥感、气象和环境因素，但是影响冬小麦作物生长条件的指标还有很多，例如自然灾害和极端天气事件等因素，这将进一步决定产量的形成。因此，在未来的研究中，将考虑更多和冬小麦产量有关的影响因素，以提高模型的性能。

（3）本文主要聚焦于我国河南省的冬小麦产量预测问题，未来的研究将拓展到其他地区以及其他农作物种类，以提高产量预测模型在不同区域和农作物上的适用性和泛化性能。

参考文献

- [1] Coronado-Apodaca K G, Martínez-Ruiz M, Iqbal H M N, et al. Agro-food sustainability transitions: New Frontiers for food security[J]. *Current Opinion in Environmental Science & Health*, 2023, 31: 100412.
- [2] 成升魁, 李云云, 刘晓洁, 等. 关于新时代我国粮食安全观的思考[J]. *自然资源学报*, 2018, 33(6): 911-926.
- [3] 王晓君, 何亚萍, 蒋和平. “十四五”时期的我国粮食安全: 形势, 问题与对策[J]. *改革*, 2020 (9): 27-39.
- [4] He Z, Xia X, Zhang Y. Breeding noodle wheat in China[J]. *Asian noodles: Science, technology, and processing*, 2010: 1-23.
- [5] Cao J, Zhang Z, Tao F, et al. Identifying the contributions of multi-source data for winter wheat yield prediction in China[J]. *Remote Sensing*, 2020, 12(5): 750.
- [6] Acevedo E, Silva P, Silva H. Wheat growth and physiology[J]. *Bread wheat, improvement and production*, 2002, 30: 39-70.
- [7] Feng L, Wang Y, Zhang Z, et al. Geographically and temporally weighted neural network for winter wheat yield prediction[J]. *Remote Sensing of Environment*, 2021, 262: 112514.
- [8] Hamilton J D. Time series analysis[M]. Princeton university press, 2020.
- [9] Draper N R, Smith H. Applied regression analysis[M]. John Wiley & Sons, 1998.
- [10] Gardner Jr E S. Exponential smoothing: The state of the art[J]. *Journal of forecasting*, 1985, 4(1): 1-28.
- [11] Liu S, Lin Y. Grey Prediction[M]. Springer London, 2006.
- [12] Sarukkai R R. Link prediction and path analysis using markov chains[J]. *Computer networks*, 2000, 33(1-6): 377-386.
- [13] Marill K A. Advanced statistics: linear regression, part I: simple linear regression[J]. *Academic emergency medicine*, 2004, 11(1): 87-93.
- [14] Marill K A. Advanced statistics: linear regression, part II: multiple linear regression[J]. *Academic emergency medicine*, 2004, 11(1): 94-102.
- [15] Silhavy R, Silhavy P, Prokopova Z. Analysis and selection of a regression model for the use case points method using a stepwise approach[J]. *Journal of Systems and Software*, 2017, 125: 1-14.
- [16] Choudhury A, Jones J. Crop yield prediction using time series models[J]. *Journal of Economics and Economic Education Research*, 2014, 15(3): 53-67.
- [17] Michel L, Makowski D. Comparison of statistical models for analyzing wheat yield time series[J]. *PLoS One*, 2013, 8(10): e78615.
- [18] 张晓杰, 张希良. 时间序列分析模型在山东省粮食总产量预测中的应用[J]. *水土保持研究*, 2007, 14(3): 309-311.

- [19] Zhang Z, Li Z, Chen Y, et al. Improving regional wheat yields estimations by multi-step-assimilating of a crop model with multi-source data[J]. *Agricultural and Forest Meteorology*, 2020, 290: 107993.
- [20] 帅细强, 王石立, 马玉平, 等. 基于水稻生长模型的气象影响评价和产量动态预测[J]. *应用气象学报*, 2008, 19(1): 71-81.
- [21] Zhuo W, Fang S, Gao X, et al. Crop yield prediction using MODIS LAI, TIGGE weather forecasts and WOFOST model: A case study for winter wheat in Hebei, China during 2009–2013[J]. *International Journal of Applied Earth Observation and Geoinformation*, 2022, 106: 102668.
- [22] Xue J, Su B. Significant remote sensing vegetation indices: A review of developments and applications[J]. *Journal of sensors*, 2017, 2017.
- [23] Medina H, Tian D, Abebe A. On optimizing a MODIS-based framework for in-season corn yield forecast[J]. *International journal of applied earth observation and geoinformation*, 2021, 95: 102258.
- [24] Lai Y R, Pringle M J, Kopittke P M, et al. An empirical model for prediction of wheat yield, using time-integrated Landsat NDVI[J]. *International journal of applied earth observation and geoinformation*, 2018, 72: 99-108.
- [25] Gaso D V, de Wit A, Berger A G, et al. Predicting within-field soybean yield variability by coupling Sentinel-2 leaf area index with a crop growth model[J]. *Agricultural and Forest Meteorology*, 2021, 308: 108553.
- [26] Fieuzal R, Sicre C M, Baup F. Estimation of corn yield using multi-temporal optical and radar satellite data and artificial neural networks[J]. *International journal of applied earth observation and geoinformation*, 2017, 57: 14-23.
- [27] Ashapure A, Jung J, Chang A, et al. Developing a machine learning based cotton yield estimation framework using multi-temporal UAS data[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2020, 169: 180-194.
- [28] Han J, Zhang Z, Cao J, et al. Prediction of winter wheat yield based on multi-source data and machine learning in China[J]. *Remote Sensing*, 2020, 12(2): 236.
- [29] Burdett H, Wellen C. Statistical and machine learning methods for crop yield prediction in the context of precision agriculture[J]. *Precision Agriculture*, 2022, 23(5): 1553-1574.
- [30] Zhou W, Liu Y, Ata-Ul-Karim S T, et al. Integrating climate and satellite remote sensing data for predicting county-level wheat yield in China using machine learning methods[J]. *International Journal of Applied Earth Observation and Geoinformation*, 2022, 111: 102861.
- [31] Nevavuori P, Narra N, Lipping T. Predicción del rendimiento de los cultivos con redes neuronales convolucionales profundas[J]. 2019.
- [32] Nagy A, Fehér J, Tamás J. Wheat and maize yield forecasting for the Tisza river catchment using MODIS NDVI time series and reported crop statistics[J]. *Computers and Electronics in Agriculture*, 2018, 151: 41-49.
- [33] Shammí S A, Meng Q. Use time series NDVI and EVI to develop dynamic crop growth metrics for

- yield modeling[J]. *Ecological Indicators*, 2021, 121: 107124.
- [34] Han J, Shi L, Yang Q, et al. Rice yield estimation using a CNN-based image-driven data assimilation framework[J]. *Field Crops Research*, 2022, 288: 108693.
- [35] Li H, Tian Y, Zhang C, et al. Temporal sequence Object-based CNN (TS-OCNN) for crop classification from fine resolution remote sensing image time-series[J]. *The Crop Journal*, 2022, 10(5): 1507-1516.
- [36] Yuan Y, Lin L, Liu Q, et al. SITS-Former: A pre-trained spatio-spectral-temporal representation model for Sentinel-2 time series classification[J]. *International Journal of Applied Earth Observation and Geoinformation*, 2022, 106: 102651.
- [37] Khaki S, Wang L, Archontoulis S V. A cnn-rnn framework for crop yield prediction[J]. *Frontiers in Plant Science*, 2020, 10: 1750.
- [38] Zarzycki K, Ławryńczuk M. Advanced predictive control for GRU and LSTM networks[J]. *Information Sciences*, 2022, 616: 229-254.
- [39] 赫晓慧, 罗浩田, 乔梦佳. 基于 CNN-RNN 网络的中国冬小麦估产[J]. *农业工程学报*, 2021, 37(17): 124-132.
- [40] Wang J, Wang P, Tian H, et al. A deep learning framework combining CNN and GRU for improving wheat yield estimates using time series remotely sensed multi-variables[J]. *Computers and Electronics in Agriculture*, 2023, 206: 107705.
- [41] Fan J, Bai J, Li Z, et al. A GNN-RNN approach for harnessing geospatial and temporal information: application to crop yield prediction[C]. *Proceedings of the AAAI Conference on Artificial Intelligence*. 2022, 36(11): 11873-11881.
- [42] Chaudhari S, Mithal V, Polatkan G, et al. An attentive survey of attention models[J]. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 2021, 12(5): 1-32.
- [43] Galassi A, Lippi M, Torroni P. Attention in natural language processing[J]. *IEEE transactions on neural networks and learning systems*, 2020, 32(10): 4291-4308.
- [44] 吴晶辉, 严彩萍, 李红, 等. 边缘引导的双注意力图像拼接检测网络[J]. *中国图象图形学报*, 2024, 29(2): 430-443.
- [45] Zheng C, Fan X, Wang C, et al. Gman: A graph multi-attention network for traffic prediction[C]. *Proceedings of the AAAI conference on artificial intelligence*, 2020, 34(01): 1234-1241.
- [46] 林靖皓, 秦亮曦, 苏永秀, 等. 基于自注意力机制的双向门控循环单元和卷积神经网络的芒果产量预测[J]. *计算机应用*, 2020, 40(S01): 51-55.
- [47] Tian H, Wang P, Tansey K, et al. A deep learning framework under attention mechanism for wheat yield estimation using remotely sensed indices in the Guanzhong Plain, PR China[J]. *International Journal of Applied Earth Observation and Geoinformation*, 2021, 102: 102375.
- [48] Cao Y, Sui B, Zhang W. REL-SAGAN: Relative Generation Adversarial Network Integrated With Attention Mechanism for Scene Data Augmentation of Remote Sensing[J]. *IEEE Journal of Selected*

- Topics in Applied Earth Observations and Remote Sensing, 2022, 15: 3107-3119.
- [49] Lv N, Ma H, Chen C, et al. Remote sensing data augmentation through adversarial training[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2021, 14: 9318-9333.
- [50] Singh A, Bruzzone L. SIGAN: Spectral index generative adversarial network for data augmentation in multispectral remote sensing images[J]. IEEE Geoscience and Remote Sensing Letters, 2021, 19: 1-5.
- [51] Liu W, Luo B, Liu J. Synthetic data augmentation using multiscale attention CycleGAN for aircraft detection in remote sensing images[J]. IEEE Geoscience and Remote Sensing Letters, 2021, 19: 1-5.
- [52] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.
- [53] Lu Y, Chen D, Olaniyi E, et al. Generative adversarial networks (GANs) for image augmentation in agriculture: A systematic review[J]. Computers and Electronics in Agriculture, 2022, 200: 107208.
- [54] Zhang L, Nie Q, Ji H, et al. Hyperspectral imaging combined with generative adversarial network (GAN)-based data augmentation to identify haploid maize kernels[J]. Journal of Food Composition and Analysis, 2022, 106: 104346.
- [55] Zhang J, Tian H, Wang P, et al. Improving wheat yield estimates using data augmentation models and remotely sensed biophysical indices within deep neural networks in the Guanzhong Plain, PR China[J]. Computers and Electronics in Agriculture, 2022, 192: 106616.
- [56] 杜培军, 夏俊士, 薛朝辉, 等. 高光谱遥感影像分类研究进展[J]. 遥感学报, 2021, 20(2): 236-256.
- [57] Sabins Jr F F, Ellis J M. Remote sensing: Principles, interpretation, and applications[M]. Waveland Press, 2020.
- [58] 姜明, 张新长, 孙颖, 等. 全尺度特征聚合的高分辨率遥感影像变化检测网络[J]. 测绘学报, 2023, 52(10): 1738-1748.
- [59] Kattenborn T, Leitloff J, Schiefer F, et al. Review on Convolutional Neural Networks (CNN) in vegetation remote sensing[J]. ISPRS journal of photogrammetry and remote sensing, 2021, 173: 24-49.
- [60] Lu J, Tan L, Jiang H. Review on convolutional neural network (CNN) applied to plant leaf disease classification[J]. Agriculture, 2021, 11(8): 707.
- [61] Alzubaidi L, Zhang J, Humaidi A J, et al. Review of deep learning: concepts, CNN architectures, challenges, applications, future directions[J]. Journal of big Data, 2021, 8: 1-74.
- [62] Apicella A, Donnarumma F, Isgrò F, et al. A survey on modern trainable activation functions[J]. Neural Networks, 2021, 138: 14-32.
- [63] Dubey S R, Singh S K, Chaudhuri B B. Activation functions in deep learning: A comprehensive survey and benchmark[J]. Neurocomputing, 2022, 503: 92-108.
- [64] Zafar A, Aamir M, Mohd Nawi N, et al. A comparison of pooling methods for convolutional neural networks[J]. Applied Sciences, 2022, 12(17): 8643.
- [65] Basha S H S, Dubey S R, Pulabaigari V, et al. Impact of fully connected layers on performance of

- convolutional neural networks for image classification[J]. *Neurocomputing*, 2020, 378: 112-119.
- [66] Sherstinsky A. Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network[J]. *Physica D: Nonlinear Phenomena*, 2020, 404: 132306.
- [67] Shewalkar A, Nyavanandi D, Ludwig S A. Performance evaluation of deep neural networks applied to speech recognition: RNN, LSTM and GRU[J]. *Journal of Artificial Intelligence and Soft Computing Research*, 2019, 9(4): 235-245.
- [68] Regmi P, Dahal A, Joshi B. Nepali speech recognition using rnn-ctc model[J]. *International Journal of Computer Applications*, 2019, 178(31): 1-6.
- [69] Li H. Deep learning for natural language processing: advantages and challenges[J]. *National Science Review*, 2018, 5(1): 24-26.
- [70] Linardos V, Drakaki M, Tzionas P, et al. Machine learning in disaster management: recent developments in methods and applications[J]. *Machine Learning and Knowledge Extraction*, 2022, 4(2).
- [71] Zhong L, Hu L, Zhou H. Deep learning based multi-temporal crop classification[J]. *Remote sensing of environment*, 2019, 221: 430-443.
- [72] Sivanandhini P, Prakash J. Crop yield prediction analysis using feed forward and recurrent neural network[J]. *International Journal of Innovative Science and Research Technology*, 2020, 5(5): 1092-1096.
- [73] Islam M S, Islam M N, Hashim N, et al. New hybrid deep learning approach using BiGRU-BiLSTM and multilayered dilated CNN to detect arrhythmia[J]. *IEEE Access*, 2022, 10: 58081-58096.
- [74] 任欢, 王旭光. 注意力机制综述[J]. *计算机应用*, 2021, 41(S01): 1-6.
- [75] Niu Z, Zhong G, Yu H. A review on the attention mechanism of deep learning[J]. *Neurocomputing*, 2021, 452: 48-62.
- [76] LIU J, LUO X. Research progress in attention mechanism in deep learning[J]. *Chinese Journal of Engineering*, 2021, 43(11): 1499-1511.
- [77] 刘玉萍, 张立朝, 潘贞, 等. 生态河南建设中的地理国情监测研究[J]. *测绘与空间地理信息*, 2013, 36(9): 73-75.
- [78] Wang S, Li J, Zhang B, et al. Changes of water clarity in large lakes and reservoirs across China observed from long-term MODIS[J]. *Remote Sensing of Environment*, 2020, 247: 111949.
- [79] Fu G, Shen Z, Zhang X, et al. Estimating air temperature of an alpine meadow on the Northern Tibetan Plateau using MODIS land surface temperature[J]. *Acta Ecologica Sinica*, 2011, 31(1): 8-13.
- [80] Yan K, Park T, Yan G, et al. Evaluation of MODIS LAI/FPAR product collection 6. Part 2: Validation and intercomparison[J]. *Remote Sensing*, 2016, 8(6): 460.
- [81] Zhao J, Dong Y, Zhang M, et al. Comparison of identifying land cover tempo-spatial changes using GlobCover and MCD12Q1 global land cover products[J]. *Arabian Journal of Geosciences*, 2020, 13: 1-12.

- [82] Abatzoglou J T, Dobrowski S Z, Parks S A, et al. TerraClimate, a high-resolution global dataset of monthly climate and climatic water balance from 1958–2015[J]. Scientific data, 2018, 5(1): 1-12.
- [83] Gu J, Wang Z, Kuen J, et al. Recent advances in convolutional neural networks[J]. Pattern recognition, 2018, 77: 354-377.
- [84] Tian C, Xu Y, Li Z, et al. Attention-guided CNN for image denoising[J]. Neural Networks, 2020, 124: 117-129.
- [85] Wang W, Tan X, Zhang P, et al. A CBAM based multiscale transformer fusion approach for remote sensing image change detection[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2022, 15: 6817-6825.
- [86] Qin J, Impa S M, Tang Q, et al. Integrated nutrient, water and other agronomic options to enhance rice grain yield and N use efficiency in double-season rice crop[J]. Field Crops Research, 2013, 148: 15-23.
- [87] Peng Y, Li Y, Dai C, et al. Remote prediction of yield based on LAI estimation in oilseed rape under different planting methods and nitrogen fertilizer applications[J]. Agricultural and Forest Meteorology, 2019, 271: 116-125.
- [88] Peng B, Guan K, Zhou W, et al. Assessing the benefit of satellite-based Solar-Induced Chlorophyll Fluorescence in crop yield prediction[J]. International Journal of Applied Earth Observation and Geoinformation, 2020, 90: 102126.
- [89] 王来刚, 郑国清, 郭燕, 等. 融合多源时空数据的冬小麦产量预测模型研究[J]. 农业机械学报, 2022, 53(1): 198-204,458.
- [90] 姚宁, 宋利兵, 刘健, 等. 不同生长阶段水分胁迫对旱区冬小麦生长发育和产量的影响[J]. 中国农业科学, 2015, 48(12): 2379-2389.
- [91] 徐金鹏, 郭新峰, 王瑞波, 等. 基于 GAN 数据增强的软件缺陷预测聚合模型[J]. 计算机科学, 2023, 50(12): 24-31.
- [92] Zhao S, Liu Z, Lin J, et al. Differentiable augmentation for data-efficient gan training[J]. Advances in neural information processing systems, 2020, 33: 7559-7570.
- [93] Tran N T, Tran V H, Nguyen N B, et al. On data augmentation for gan training[J]. IEEE Transactions on Image Processing, 2021, 30: 1882-1897.
- [94] Viola J, Chen Y Q, Wang J. FaultFace: Deep convolutional generative adversarial network (DCGAN) based ball-bearing failure detection method[J]. Information Sciences, 2021, 542: 195-211.
- [95] Dewi C, Chen R C, Liu Y T, et al. Synthetic Data generation using DCGAN for improved traffic sign recognition[J]. Neural Computing and Applications, 2022, 34(24): 21465-21480.
- [96] Mi Z, Jiang X, Sun T, et al. GAN-generated image detection with self-attention mechanism against GAN generator defect[J]. IEEE Journal of Selected Topics in Signal Processing, 2020, 14(5): 969-981.