



学 校 代 码 10459

学号或申请号 201912562016294

密 级

郑 州 大 学

硕 士 学 位 论 文

基于混合神经网络的冬小麦产量预测
方法研究

作 者 姓 名: 罗浩田

导 师 姓 名: 赫晓慧 教授

学 科 门 类: 工 学

专 业 名 称: 测绘科学与技术

培 养 院 系: 地球科学与技术学院

完 成 时 间: 2022 年 5 月

A thesis submitted to
Zhengzhou University
for the degree of Master

**Research on forecasting method of winter wheat yield
based on hybrid neural network**

By Haotian Luo

Supervisor: Prof. Xiaohui He

Surveying and Mapping

The School of Geo-Science & Technology

May, 2022

摘要

冬小麦作为我国主要的粮食作物之一，其种植面积约占主要农作物总面积的 20%，其产量占总产量的 19%。因此，在收获前精确地预测我国冬小麦主产区的产量，对我国作物生产管理和粮食供应具有重要意义。然而，农作物的生长过程十分复杂，作物植株形态在不同生育期呈现明显的物候变化，其产量与诸多环境因素呈非线性关系。如何构建合适的作物特征挖掘算法，充分利用不同维度的特征信息，是实现作物产量精准预测的重要前提。因此，本文以 MODIS 遥感影像作为数据源，提出了基于多时相遥感影像的 CNN-GRU 估产模型和基于多源数据融合的 CTrm-SVR 估产模型，解决了传统回归模型的时空尺度普适性差和单一神经网络特征提取不充分的问题，实现了快速、准确的对我国冬小麦主产区进行产量预测。主要工作如下：

（1）单一神经网络难以有效地从遥感影像中挖掘农作物的生长特征。因此，本文提出了一个端到端的融合神经网络模型（CNN-GRU），以多时相遥感影像作为模型输入，利用 CNN 从影像中提取深层次的光谱-空间特征，并将其转化为长时间序列的特征向量，在此基础上，GRU 挖掘冬小麦整个生育期的时间依赖关系，最后利用单一神经元的全连接层输出预测产量。结果表明，CNN-GRU 估产模型的均方根误差和平均绝对误差分别为 818、560 kg/hm²，均优于其他对比模型，并且该模型在冬小麦生育期的中后期预测精度相当，能够准确预测大尺度范围内冬小麦产量，即该模型能够在冬小麦收获前 2 个月预测其产量。

（2）在大尺度区域进行产量预测时，不同地区的农作物生育期不同，为了解决这一难题，本文提出了一个基于注意力机制的混合神经网络模型（CTrm-SVR）。在该模型中，参考了 Transformer 的编码器结构，利用自注意力机制挖掘任意时间序列的依赖关系，以动态加权的方式确定作物产量预测的最佳生育期，弥补大尺度产量预测中不同地区的作物物候差异。此外，考虑到影响作物生长的环境因素多，数据获取难度大，而邻近区域的作物生长环境有较强的时空相关性。因此，本文利用预测单元的地理位置信息替代大量的环境因子，并设计了一个变异的 Laplace 核函数，引入支持向量回归融合神经网络提

取的深层次特征和预测单元的位置信息，替代全连接层进行最后的产量预测。结果表明，CTrm-SVR 估产模型性能均优于其他对比模型，并且能有效解决大尺度范围内不同地区作物物候期差异的问题。

关键词：冬小麦产量预测；遥感影像；卷积神经网络；循环神经网络；自注意力机制；支持向量回归

Abstract

Winter wheat is one of the main food crops in my country, and its planting area accounts for about 20% of the total area of the main crops, and its output accounts for 19% of the total output. Therefore, it is of great significance for crop production management and food supply in my country to accurately predict the yield of my country's main winter wheat producing areas before harvesting. However, the growth process of crops is very complex, and the plant morphology of crops exhibits obvious phenological changes in different growth stages, and its yield is non-linearly related to many environmental factors. How to construct a suitable crop feature mining algorithm and make full use of feature information of different dimensions is an important prerequisite for accurate crop yield prediction. Therefore, this paper uses MODIS remote sensing images as the data source, and proposes a CNN-GRU production estimation model based on multi-temporal remote sensing images and a CTrm-SVR production estimation model based on multi-source data fusion, which solves the traditional regression model. The problem of insufficient neural network feature extraction has achieved rapid and accurate yield prediction for the main winter wheat producing areas in my country. The main work is as follows:

(1) It is difficult for a single neural network to effectively mine the growth characteristics of crops from remote sensing images. Therefore, this paper proposes an end-to-end fusion neural network model (CNN-GRU), which takes multi-temporal remote sensing images as model input, uses CNN to extract deep spectral-spatial features from the images, and converts them into long-term sequences. On this basis, GRU mines the time dependence of winter wheat throughout the growth period, and finally uses the output of the fully connected layer of a single neuron to predict yield. The results show that the root mean square error and the mean absolute error of the CNN-GRU yield estimation model are 818 and 560 kg/hm², respectively, which are better than other comparative models, and the prediction accuracy of this model in the

middle and late growth period of winter wheat is comparable, and it can accurately predict Winter wheat yield on a large scale, i.e. the model was able to predict winter wheat yield 2 months before its harvest.

(2) When forecasting yield in large-scale regions, the growth periods of crops in different regions are different. To address this dilemma, this paper proposes an attention-based hybrid neural network model (CTrm-SVR). In this model, referring to the encoder structure of Transformer, the self-attention mechanism is used to mine the dependencies of any time series, and the optimal growth period for crop yield prediction is determined in a dynamic weighted manner, making up for the large-scale yield prediction in different regions. Crop phenological differences. In addition, considering that there are many environmental factors affecting crop growth, it is difficult to obtain data, and the crop growth environment in adjacent areas has a strong spatial and temporal correlation. Therefore, this paper uses the geographic location information of the prediction unit to replace a large number of environmental factors, and designs a mutated Laplace kernel function, introduces support vector regression to fuse the deep features extracted by the neural network and the location information of the prediction unit, and replaces the fully connected layer. Final production forecast. The results show that the CTrm-SVR yield estimation model has better performance than other comparative models, and can effectively solve the problem of crop phenological differences in different regions on a large scale.

Keywords: Winter wheat production forecast; Remote sensing image; Convolutional Neural Network; Gated Recurrent Unit; Self attention mechanism; Support Vector Regression

目 录

1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统估产方法.....	2
1.2.2 人工智能估产方法.....	4
1.2.3 目前研究存在的一些问题.....	6
1.3 论文研究内容和技术路线	7
1.3.1 研究内容	7
1.3.2 技术路线.....	7
1.4 论文组织和章节安排.....	9
2 基于遥感影像的农作物产量预测相关理论	10
2.1 神经网络概述.....	10
2.1.1 卷积神经网络.....	10
2.1.2 循环神经网络.....	12
2.2 注意力机制.....	15
2.3 支持向量机.....	15
2.4 本章小结.....	18
3 研究区与数据预处理	19
3.1 研究区概况.....	19
3.2 数据来源.....	19
3.2.1 产量数据	19
3.2.2 遥感影像数据.....	20
3.3 数据预处理.....	21
3.4 本章小结.....	23
4 基于多时相遥感影像的冬小麦产量预测	24
4.1 CNN-GRU 估产模型构建	24
4.1.1 基于 CNN 的空间光谱特征提取	25
4.1.2 基于 GRU 的时间相关性建模	26
4.2 结果与分析.....	27
4.2.1 数据贡献度分析.....	28
4.2.2 估产模型性能检测.....	30
4.2.3 不同生育期冬小麦产量预测.....	33
4.3 本章小结.....	35
5 基于多源数据融合的冬小麦产量预测	37

5.1 CTrm-SVR 估产模型构建	37
5.1.1 基于自注意力机制的最佳生育期筛选	38
5.1.2 基于多源数据融合的产量预测	40
5.2 结果分析	40
5.2.1 CTrm-SVR 估产模型自参数分析	40
5.2.2 SVR 核函数性能检测	43
5.2.3 估产模型性能检测	44
5.2.4 冬小麦最佳生育期的空间分布	47
5.3 本章小结	48
6 结论与展望	50
6.1 结论	50
6.2 创新点	51
6.3 展望和不足	51
参考文献	53

1 绪论

1.1 研究背景及意义

世界人口的迅速增长和极端的气候变化使全球粮食供应问题成为 21 世纪的重大挑战之一，粮食生产不仅仅是农业发展问题，同时与国家的经济发展水平、居民生活质量和国际影响力等各个方面息息相关^[1-2]。例如，2011 年我国云南省持续干旱导致了该地区农作物产量大幅度下降，进而引起粮食价格大幅上涨的连锁反应，直接造成约 3.4 亿美元的经济损失^[3]。冬小麦作为我国主要粮食作物之一，其播种面积占全国粮食作物总播种面积的 19.42%，产量占粮食作物总产量的 19.00%。但近年来，由于我国耕地面积不断减少、极端气候事件频发和消费需求持续增加等原因，全球粮食供应体系正面临着严重的威胁，粮食安全问题也越来越受到国内外学者的广泛关注^[4]。因此，及时、准确地预测冬小麦产量，能够为政府相关部门提供农作物的基础数据，辅助政府相关部门更好地指导农业生产，调整农业结构以保障国家粮食安全。

随着遥感技术的发展，每年将生成 PB 级的卫星图像，为地区、国家乃至全球的科学研究提供了丰富的高时间、高空间分辨率的遥感影像。在农业方面，遥感技术可应用于农作物长势监测、干旱和病虫害评估和种植面积获取等方向，而利用遥感图像进行大范围的农作物产量预测也是遥感应用的一个重要研究领域。中等分辨率成像光谱仪（moderate-resolution imaging spectroradiometer, MODIS）卫星影像具有较好的空间分辨率、光谱响应和时间分辨率，获取方便，适用于长时间、大范围的对地观测，为作物长势监测、产量预测提供了基础数据支持^[5]。已有研究基于 MODIS 数据的农作物产量预测，如对濮阳市^[6]、河南省^[7]、秦岭—淮河线以北五省^[8]冬小麦产量预测，并取得了较好的成果。

随着信息技术的发展，计算机的计算能力呈指数级增长，数据吞吐能力有极大提升，互联网和大数据技术正逐步改变人类的生产生活方式，并带来了新一轮的技术革命^[9]。目前，机器学习和深度学习在各行各业取得了突破性的进展，为信息化、智能化的现代农业提供了技术支持。随着计算机软硬件和计算能力的不断提高，结合神经网络算法和遥感影像对大尺度区域的农作物进行产量预

测是智慧农业的一个新趋势。卷积神经网络（Convolutional Neural Network, CNN）和循环神经网络（Recurrent Neural Network, RNN）是神经网络的重要分支，其优越的特征学习能力和时间序列数据处理能力被广泛的应用于农作物产量预测。神经网络强大的图像处理能力与遥感影像完美契合，利用遥感卫星、无人机等拍摄的地表作物图像能精准、及时预测大尺度农作物产量，有效克服传统方法中耗时长、精度低等缺点^[10]。因此，结合遥感图像和神经网络模型，准确、及时地预测大范围区域的农作物产量对国家粮食安全、农作物市场规划和农业可持续发展至关重要。

1.2 国内外研究现状

农作物产量预测是智慧农业中不可或缺的一部分，近年来受到了国内外学者的广泛关注。目前，作物产量预测方法主要集中在两个方面，一是传统估产方法，主要包括基于经验统计模型和作物生长模拟模型。传统估产方法比较依赖各种环境因素，其数据获取成本高，模型空间泛化能力低，难以扩展到其它区域^[11]。二是人工智能算法，如神经网络、机器学习模型和其他混合智能算法等。单一的智能算法被设计的初衷是解决某一特定领域的问题，而作物产量与其生长环境的诸多因素之间存在复杂的非线性关系，混合智能算法能充分发挥各自模型的优点来解决复杂问题。因此，混合智能算法是农业遥感应用的一个新趋势。

1.2.1 传统估产方法

传统的作物产量预测方法大多通过环境因素和采样数据进行回归分析，以达到估算作物产量的目的。其中，经验统计模型作为典型的农作物估产方法，其基本原理是通过建立预测变量与作物产量之间的线性关系对农作物产量进行预测。具体来说，经验统计模型主要包括基于气象数据的估产模型、基于农田抽样统计的估产模型和基于投入产出理论的估产模型。孙俊英等^[12]对历年来县域尺度的作物单产变化进行动态模拟，并对气象因子和作物产量进行了实验分析，利用与作物产量相关性最大的预测因子构建线性回归方程，来预测作物产

量,但部分多山区县的实验数据受地理环境的影响较大,其产量误差偏大。王人潮等^[13]根据田间采样数据构建作物产量预测模型,对我国水稻产量进行了实验分析。但由于农作耕地大多以家庭为基本单位,采用这种估产方法时,土地调查和田间采样工作会收到较大影响,需耗费大量的人力和物力。中国科学院陈锡康教授初次在国际上提出投入占用产出技术^[14],基于经济学的投入产出原理,对粮食和经济的投入产出占比进行实验分析,能详细分析粮食产量的整体趋势,但短期的作物产量预测精度一般。大量研究表明,粮食产量具有随机动态性和突变性,是一个复杂的非线性系统。而传统的经验统计模型是根据变量之间的物理关系来进行分析和预测,通常包含理论假设和先验知识,再建立一个合适的数学模型来拟合作物产量的历史曲线。然而,由于缺乏背景知识,难以利用传统的统计原理来构建一个学习算法对作物产量和相关环境因素进行建模分析。

典型的统计回归模型远不能满足于现代的作物估产研究的需求,有研究者基于环境因素与作物生长过程中一系列形态变化提出了作物同化方法,其中作物生长模型是应用最广的一个,它是一种面向作物生理过程的动态模型,其基本原理是将诸多影响作物生长的环境变量(温度、降水、土壤和管理措施等)作为预测因子来动态模拟作物生长过程^[15]。作物生长模型具有多输入和多输出的特点,不仅能对目标区域的作物生长状况进行定量描述,还可以获取作物在区域尺度上的变化。宋艳玲等^[16]结合 WOFOST 模型研究了中国北方干旱地区对冬小麦产量的影响,结果表明,初春的降水对小麦产量有较大的影响。辛景峰等^[17]利用 NOAA/AVHRR 卫星的归一化差异植被指数(Normalized Difference Vegetation Index, NDVI)数据和地面实测数据对不同物候期的作物产量进行预测,结果表明不同地区作物物候期不同,冬小麦的物候期由南向北推迟,呈现明显的地域差异^[18]。何英彬等^[19]对水稻不同物候期的 NDVI 数据进行反演得到逐日的 LAI 数据,结合 SIMRIW 作物生长模型,对黑龙江省水稻进行产量预测。黄敬峰等^[20]结合多个植被指数构建了水稻遥感估产模型,并利用 GIS 技术提取水稻的种植区域,解决了遥感数据空间分辨率低的问题。然而作物生长模型仍存在一些局限性,一方面,作物生长模型需要模拟农作物整个生育期的生长和发育,模型构建过程中需要进行局部校准,该模型依赖于大量的输入,如气候

条件、土壤环境和施肥管理数据等。另一方面大尺度的作物 NDVI 数据量较大,作物生长模型的计算成本增加,难以应用于大规模的作物产量预测。

总的来说,由于传统估产模型本身和数据方面的诸多限制,难以实现低成本、高效、准确的对大尺度范围内的农作物进行产量预测。目前来说传统估产模型仍存在一些不足:(1)传统估产方法是依靠大量的环境因子,如昼夜温度、降水量、日照时间、土壤性质和施肥量等,数据获取需要实地测量,需耗费大量的人力物力,并且模型的区域扩展非常困难。(2)传统估产方法是依靠经验模型,针对不同作物的环境因素、不同物候期的特征设计的产量预测模型,这类模型的预测精度较高,但空间、时间维度普适性较差,仅针对某一地区的某一种农作物。因此,研究者逐渐转向构建数据获取便捷、普适性更高的农作物估产模型。

1.2.2 人工智能估产方法

随着人工智能技术的发展,出现了包括随机森林(Random Forest, RF)^[21]、支持向量机(Support Vector Machines, SVM)^[22]、决策树(DecisionTree, DT)^[23]和 K-最近邻(K-Nearest Neighbors, KNN)^[24]等在内的机器学习算法,在非线性建模和内在关系挖掘问题上凸显了强大的拟合能力。另一方面,基于机器学习的作物估产方法以易获取、覆盖面积广的遥感影像作为数据源,很大程度上提升了作物估产的效率。因此,机器学习方法逐渐成为农作物产量预测的主流方法。现有研究已经证明机器学习方法能够捕获产量与环境要素之间的相互联系^[25-27],并构建复杂的、非线性的隐式函数来拟合多个预测因子。Dawei Li 等^[28]结合植被指数的光谱特征,如 NDVI^[29]、增强植被指数(Enhanced Vegetation Index, EVI)^[30]、土壤调整植被指数(Soil Adjusted Vegetation Index, SAVI)^[31]等,利用 SVM 的非线性核函数生成一个最优超平面构建不同地物光谱-纹理联合特征集,以获取不同作物的种植面积。Yumiao Wang 等^[32]利用遥感影像的植被指数(Vegetation Indexs, VIs)、气候数据和土壤成分,分别构建两种线性回归模型:最小二乘法(Ordinary Least Squares, OLS)、最小绝对收缩与选择算子(Least Absolute Shrinkage and Selection Operator, LASSO)和四种机器学习算

法：支持向量机、随机森林、自适应增强（Adaptive Boost, AdaBoost）和深度神经网络（Deep Neural Networks, DNN）对美国县级冬小麦进行产量预测，结果表明，机器学习方法均优于线性回归模型^[33-35]。然而传统机器学习方法处理大容量、高纬度的影像数据比较困难。目前，基于机器学习的农作物产量预测通常使用植被指数。但植被指数本质上是遥感影像光谱还原产物，不能完全反映地表作物特征，会造成影像波段信息缺失，从而影响估产模型的整体性能。

与典型的机器学习方法相比，深度学习技术表现出更好的性能，最流行的 CNN 和 RNN 均被用于作物产量预测，并取得了丰硕的研究成果。CNN 在图像处理方面表现出显著优势，其局部连接和滑动窗口结构能挖掘整幅遥感影像中的光谱特征。Qi Yang 等^[36]利用无人机获取高分辨率 RGB 图像和多光谱数据，并构建两个独立分支的 CNN 结构分别处理 RGB 和多光谱图像，对水稻试验田进行产量预测，并测试不同物候期估产模型的性能，其结果表明，基于遥感影像的 CNN 结构明显优于 VIs 的回归模型^[37]。Nevavuori 等^[38]提出了一种 3D-CNN 框架，结合无人机的 RGB 数据和作物生育期的气候数据对试验田的作物产量进行预测，该模型结合环境因素能更好的描述田间作物的生长特征。Jiaxuan You 等^[39]提出一种基于直方图的降维方法，将 4 维（宽度、高度、深度和时间）原始图像数据转换为 3 维（强度、时间和深度）标准化直方图^[8,40]，并利用 CNN 网络预测县级大豆产量。植被遵循由植物的生物学特性所决定的生长周期，比如发芽，开花、结果和衰老等。随着生育期的发展，植物的光谱反射特征也会随之发生变化。而 CNN 难以有效地挖掘作物不同生育期的时间相关性，仅依靠特定物候期影像中的光谱信息不能充分描述作物的生长特征。

因此，为了挖掘长时间序列遥感影像中农作物不同生育期的作物生长特征，一些研究利用 RNN 来捕捉作物整个生长周期时间序列的内在联系，对作物进行产量预测。Zehui Jiang 等^[41]采用一种特殊的 RNN 结构长期短期记忆网络，用气象和土壤数据预测玉米产量。Crisóstomo de Castro Filho 等^[42]结合 Bi-LSTM 和 Sentinel-1 时间序列检测水稻种植区域，其结果优于其余四种传统机器学习方法^[43]。Alibabaei 等^[44]基于 RNN 的两个变体网络 LSTM 和 GRU 分析长时间序列的环境数据来进行作物估产，包括气候数据、灌溉量和土壤成分等，结果表明，LSTM 和 GRU 在时间序列数据的处理上优于 CNN 和其他机器学习方法。

虽然基于 CNN 和 RNN 的农作物估产方法均取得了比传统估产模型和机器学习方法更好的结果,但是,基于 CNN 的方法侧重于挖掘单一生育期的作物光谱特征,基于 RNN 的方法虽然可以对作物生长过程的时间相关性建模,但由于其自身结构限制,难以获取遥感影像中的空间信息。因此,如何结合这两类方法的优点,同时实现对作物的空间-光谱-时域特征的挖掘,获取更精准的农作物产量预测结果,仍有待于进一步研究。

1.2.3 目前研究存在的一些问题

目前,我国利用遥感技术对农田作物种植面积估算、产量预测、长势监测和农作物病虫害评估的方法日渐成熟,但还存在相应的问题有待深入研究。目前的研究存在的问题主要有以下方面:

(1) 大量的研究表明, CNN 能从遥感图像中提取丰富的空间信息, RNN 能有效的融合时间序列数据,挖掘深层次的时间特征。而农作物生长是一个非线性的自然过程,大多数研究者仅使用单一的 CNN 提取农作物某一生育期的空间特征,或利用 RNN 融合作物生长周期的时间信息。但对于农作物而言,生育期各阶段形态变化对其产量预测都很重要。因此,如何同时提取农作物生长过程中丰富的光谱以及时间信息,是作物产量预测的关键所在。

(2) 由于不同区域的地理环境和气候条件不同,农作物的物候期有明显差异,即同一作物在不同地区的播种、开花、结果和收获的时间节点不同。因此,对大尺度范围内的农作物进行产量预测时,如何解决不同地区作物物候差异问题至关重要。

(3) 由于作物生理过程的复杂性,诸多环境因素与作物产量呈非线性关系,如土壤类型、降水量、施肥量、作物管理等,仅通过遥感影像不能完全反映与作物生长相关的许多特征。因此,如何将环境因素应用到农作物产量预测中这一问题有待解决。

1.3 论文研究内容和技术路线

1.3.1 研究内容

为了充分提取农作物生长过程中的信息，提高农作物产量预测的精度。本文结合深度学习和机器学习的方法，构建农作物估产模型。首先本文基于神经网络从多时相、多光谱遥感影像中挖掘农作物的空谱特征以及生长过程中的时间特征。之后为了进一步提升预测精度，引用预测单元的的空间位置信息，并利用机器学习方法进行时空相关性建模，实现农作物产量的精准预测。具体的研究内容如下：

（1）基于多时相遥感影像的 CNN-GRU 估产模型

为从遥感影像中充分挖掘作物生长特征。本文使用多时相 MODIS 影像作为数据源，同时引入 CNN 和 GRU 作为特征提取网络。首先利用 CNN 从每个时间点的影像中获取能反映农作物生长状态的空间-光谱特征。在此基础上，利用 GRU 对农作物生长过程中的时间关系进行建模，以实现从多尺度、全方位地挖掘作物整个生育期的空间-光谱-时间联合特征。

（2）基于多源数据融合的 CTrm-SVR 估产模型

针对不同地区的作物物候差异问题，本文引入了注意力机制，计算不同时间步作物特征的权重分布，挖掘长时间序列作物信息的内在联系，确定作物产量预测的最佳生育期。然后结合支持向量回归的强拟合能力，代替神经网络最后的全连接层，进行最后的预测产量输出。同时研究了 SVR 中核函数的构建方法，将深层空间-光谱-时间特征以及预测单元的空间位置特征同时进行编码，共同用于农作物产量预测结果的输出，减少作物产量预测的误差，进一步提升估产模型的泛化能力。

1.3.2 技术路线

本文的技术路线如下：




图 1.1 技术路线图

1.4 论文组织和章节安排

第一章，绪论。主要介绍了本课题的背景和研究意义，对国内外作物产量预测的相关研究进行了详细分析，总结了当前作物估产领域存在的一些问题，然后详细阐述了本文的主要研究内容、技术路线和后面的章节安排。

第二章，基于遥感影像的农作物产量预测相关理论。主要介绍本文使用的神经网络相关理论，包括卷积神经网络、循环神经网络，以及注意力机制和支持向量回归模型。

第三章，研究区与数据预处理。从研究区自然地理环境简介开始，介绍研究区的基本农业概况，为开展研究工作奠定基础。数据分为作物产量数据与遥感数据，并介绍了不同数据基本处理流程和操作方法。

第四章，基于多时相遥感影像的冬小麦产量预测。首先简单介绍 CNN-GRU 估产模型的网络结构，然后与传统机器学习算法（SVR、RF、DT）和深度学习方法（CNN、GRU、LSTM）进行实验分析，结果表明所提出的 CNN-GRU 估产模型能从多时相影像中同时挖掘作物的空间-光谱-时间联合特征，在大尺度区域产量预测的可行性。

第五章，基于多源数据融合的冬小麦产量预测。主要介绍了基于注意力机制的混合神经网络模型（CTrm-SVR），引入了自注意力机制，动态地对每个生育期进行自相关建模，最后利用 SVM 核函数的结构将预测单元的空间位置信息与神经网络提取的深层次作物生长特征相结合，实验结果表明 CTrm-SVR 估产模型能挖掘能有效解决不同地区农作物的物候差异问题，减少了作物产量预测的误差，进一步提升估产模型的预测精度。

第六章，结论和展望。对本文研究内容和主要工作进行总结，并给出了实验过程中的不足之处，指明了下一步研究和后续工作的方向。

2 基于遥感影像的农作物产量预测相关理论

2.1 神经网络概述

近年来,深度学习已成功应用于自然语言处理、计算机视觉和遥感图像解译等领域的研究,而人工神经网络作为人工智能方向比较成熟的部分也得到了迅猛发展。

人工神经网络(Artificial Neural Networks, ANNs)是受生物神经系统启发的信息处理系统,其灵感主要来自于人类大脑和视觉系统的功能和结构。ANNs由相互连接的神经元或细胞组成,神经元之间协同工作以处理更复杂的科学问题^[45-47]。ANNs包括输入层、隐藏层和输出层,其中输入层用于处理输入到神经网络中的原始数据,其学习过程是通过输入数据来获取知识;隐藏层的每个神经元用于存储网络学习到的特征,在隐藏单元中,神经网络能够自适应的处理非线性、非结构化的数据;最后根据研究需求,由输出层输出相应的结果。人工神经网络能够动态地挖掘不同来源的数据集中的有用信息,并利用并行计算来加速拟合,与高性能计算和大数据技术完美契合。因此,人工神经网络受到了研究者的广泛关注,也用于处理实际生活中的诸多难题。

2.1.1 卷积神经网络

卷积神经网络是深度学习中最具代表性的算法之一,是具有卷积算子和多层次结构的前馈神经网络。CNN是一种深层次的非线性结构,可以从图像中自动提取不同类型的各种代表性特征,网络的层次数量直接决定了CNN对数据特征的描述能力,使其能处理更复杂的问题^[48-51]。典型的CNN模型包括卷积层、激活函数、池化层、全连接层^[52-53]。

(1) 卷积层

卷积层是CNN中的主要计算单元,主要用于计算输入图像或上一层的特征映射。不同于其他神经网络,CNN每个特征提取层的神经元并没有与相邻层的所有神经元相连,而是只连接上一层的输入图像或特征图的特征映射的部分重

叠的神经元，在图像中该区域被称为局部感受野。卷积层的核心是卷积核。卷积核的运作方式类似于眼睛中的视觉细胞，使其有了位置感知的能力^[54]。卷积核是按照固定的步长参数在整个图像上滑动，对图像各个区域的每个像素进行卷积操作，以遍历整张图像，并输出卷积计算后的特征图。

卷积核最重要的特性是共享参数机制，即在卷积计算过程中权重不变，其权重可以在网络训练中不断更新，这一特性极大地降低了训练参数的计算复杂度，有效缓解了过拟合问题，并在一定程度上提高了 CNN 模型的泛化能力。

(2) 激活函数

任何一个神经网络的关键元素都是神经元的层激活功能，利用激活函数处理非线性特征。否则，模型只能获取到原始数据的线性映射，难以解决高维复杂的非线性问题。这在计算机视觉领域尤为重要，因为大多数的科学问题都属于输入和输出之间没有直接线性关系的范畴。另外激活函数也能保证卷积层输出的特征图的值保持在一定范围，这能大大降低计算难度，避免出现数值溢出的极值问题。常用的激活函数包括 Sigmoid、Tanh、Softmax 和 ReLu。其中 Sigmoid 激活函数的定义为：

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2.1)$$

Sigmoid 激活函数是早期神经网络研究中所提出的，目前常用于网络最后一次的二分类问题，其主要缺点是在反向传播的过程中，随着神经网络中层数的增加，容易出现梯度消失的问题。

Tanh 激活函数部分解决了 Sigmoid 关于 0 中心的问题，其导数范围在 (0, 1) 之间，并且梯度消失的问题也有所缓解。但 Tanh 和 Sigmoid 激活函数都包含指数计算，计算量较大。Tanh 激活函数的定义为：

$$\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.2)$$

Softmax 激活函数多用于处理多分类问题，它会输出 n 个类别的概率分布，其函数表达式为：

$$\text{Softmax}(x) = \frac{\exp(a_i)}{\sum_n \exp(a_i)} \quad (2.3)$$

ReLU 激活函数具有非线性、易于计算等特点^[55-56]，是目前神经网络中最常用的激活函数，其基本原理是将部分神经元转化为零，减少神经元的依赖，增强网络的稀疏性，有效缓解模型过拟合问题。ReLU 激活函数的定义为：

$$\text{ReLU}(x) = \text{Max}(0, x) \quad (2.4)$$

(3) 池化层

在卷积操作和非线性激活后，输出的矩阵被传递到池化层。池化是通过特定的聚合函数对区域内的邻近值进行分组，比较常用的池化有两种：一种是平均池化，即计算该区域内像素的平均值；另一种是最大池化，即在区域内选择值最大的像素点，然后舍弃其余像素。如上所述，池化的主要思想是利用区域内某个值来表示该区域中最重要的特征，这可能会导致信息丢失，但池化操作在实践中是非常有效的，它不仅降低了网络参数、计算成本和模型复杂度，减少了背景噪声的影响，还保证了模型训练的不变性，如尺度不变性、平移不变性和旋转不变性等^[57]。

(4) 全连接层

全连接层主要扮演着分类器或回归器的角色。一般来说，在卷积层从输入图像中提取深层次的特征并将其应用于分类或回归任务中，需要将多组特征映射组合成一维的特征向量，并将其转换为预期的输出形状。对于分类任务，将输出转换为每个类的概率集合；而回归任务是将输出转换为特定的目标值。通常增加全连接层的数量可以加强网络学习特征和目标之间的映射能力。但由于全连接层的工作原理，需要与前一层的所有神经元进行参数计算，这会大大增加网络参数。在 VGG16 中，全连接层的参数占模型总参数的 80% 以上，因此，应根据研究需求确定网络中全连接层的维度和数量。

2.1.2 循环神经网络

循环神经网络是传统前馈网络的扩展，不同于 CNN，它可以处理不同时间

步长的序列信息。在传统前馈网络中，输入和输出之间是相互独立的，而 RNN 能建立不同循环单元之间的联系，即当前输出依赖于之前的每一个输入。因此，常用于自然语言处理、视频动作识别等。在智慧农业方面，也被用于处理长时间变化的应用，如灾害评估、农作物分类和产量预测等。

RNN 是通过引入一个隐藏状态 h_t ，来建立循环单元之间的联系，即在计算当前时间步 t 的输出时，网络会考虑之前时间步 0 到 $t-1$ 的隐藏状态。当前时间步 t 的输出计算方式：

$$h_t = f(Ux_t + Wh_{t-1} + b_h) \quad (2.5)$$

$$y_t = \text{softmax}(Vh_t + b_y) \quad (2.6)$$

式中， x_t 、 h_t 和 y_t 分别是时间步 t 的输入、隐藏状态和输出， b_h 和 b_y 分布是隐藏状态 h_t 和输入 y_t 的偏置， U 、 W 和 V 是计算过程中的权重矩阵， f 是激活函数，通常是 Tanh 函数。

在 RNN 中，随着隐藏层不断加深，容易出现梯度消失的问题，并且 RNN 难以处理长时间序列之间的依赖关系^[58-59]。基于 RNN 改进的两个主流版本：长短期记忆网络和门控循环单元，两个改进网络都引入了门的结构，能有效解决传统 RNN 中梯度消失和梯度爆炸的问题。

(1) LSTM

不同于传统 RNN，长短期记忆网络引入了记忆单元和门的机制^[60]，其中记忆单元用于保存长时间步的序列信息，并利用不同的门控制历史信息的遗忘和更新。LSTM 由三个不同的门来调节循环单元内的信息流，包括输入门、输出门和遗忘门。由输入门更新循环单元的细胞状态，确定网络的输入有多少信息保存到细胞状态中；遗忘门确定在当前细胞状态之前，保留多少先前时刻细胞状态的信息；输出门根据细胞状态更新隐藏状态的信息，并确定循环单元的输出。

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f) \quad (2.7)$$

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i) \quad (2.8)$$

$$c_t = f_t c_{t-1} + i_t \text{Tanh}(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (2.9)$$

$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co}c_t + b_o) \quad (2.10)$$

$$h_t = o_t \text{Tanh}(c_t) \quad (2.11)$$

式中, x_t 为 t 时刻的输入, f_t 、 i_t 和 o_t 分别表示遗忘门、输入门和输出门, c_{t-1} 和 h_{t-1} 为上一时刻的细胞状态和隐藏状态, c_t 和 h_t 为 t 时刻的细胞状态和隐藏状态, $W_{\{f,i,o\}}$ 和 $b_{\{f,i,o\}}$ 对应各个门的权重矩阵和偏置, σ 表示 Sigmoid 函数。

(2) GRU

门控循环单元继承了 LSTM 的优点, 并优化了 LSTM 的门结构^[61], 同时舍弃了循环单元的细胞状态, 大大降低了模型参数, 加快了模型的收敛速度。尽管 GRU 的门单元数量减少, 模型参数少, 但其性能在诸多领域与 LSTM 相当。GRU 由重置门、更新门和隐藏状态组成, 重置门用于控制之前时刻的隐藏单元对当前输入的影响, 更新门确定在当前隐藏状态之前, 保留多少先前时刻的状态信息。

$$r_t = \sigma(W_{xr}x_t + W_{hr}h_{t-1} + b_r) \quad (2.12)$$

$$z_t = \sigma(W_{xz}x_t + W_{hz}h_{t-1} + b_z) \quad (2.13)$$

$$h_t = \text{Tanh}(W_{xh}x_t + r_t \odot h_{t-1}) \quad (2.14)$$

$$h_t = z_t \odot h_t \oplus (1 - z_t) \odot h_t \quad (2.15)$$

式中, x_t 为 t 时刻的输入, h_{t-1} 表示上一个时间步的隐藏状态, r_t 、 z_t 、 h_t 、 h_t 分别表示更新门、重置门、候选状态、隐藏状态, σ 是 Sigmoid 激活函数, $W_{\{r,z\}}$ 和 $b_{\{r,z\}}$ 表示权重矩阵和偏执向量, $\odot$ 表示矩阵运算。

LSTM 三个门的参数各自更新, 参数多, 结构复杂, 训练和预测的时间成本高^[62]。Chung 等^[63]对 LSTM 结构做了进一步优化, 提出了门控循环单元 (GRU), 将原本 LSTM 中的门单元从三个减少到两个, 简化了网络参数, 训练时间短, 速度快, 相较于 LSTM 更容易收敛。一般规模的数据集上, LSTM 和 GRU 性能相当, 而在大规模的数据集下 LSTM 的性能略优于 GRU。

2.2 注意力机制

注意力机制是人类利用注意力从大量信息中快速筛选出高价值信息的一种方法，是人类在长期进化过程中形成的一种生存机制。Mnih 等^[64]根据生物体的特定观察行为首次提出了模拟人脑的注意力机制模型，核心思想是将更多的注意力权重放在相对重要的部分，使其充分有效地表达^[65]，进而优化传统模型。注意力机制的原理是在模型输出时，有选择地关注输入的相应信息，非常适合挖掘多模态数据之间的映射关系，能极大提高信息处理的效率和准确性。诸多研究表明，注意力机制能有效提高深度学习模型的性能，包括文档分类^[66]、机器翻译^[67]、情感分析^[68]、序列学习^[69]和作物产量预测^[70]等。

自注意力机制是计算所有时间步的任意两个输入向量之间的相关性，能获取序列数据之间的内在联系。与迭代机制的循环神经网络不同，自注意力机制能进行并行计算，加速网络训练。Google 大脑团队提出的 Transformer 模型是完全依靠自注意力机制进行长时间序列的相关性建模，并构建了多头自注意力模型，缩短了序列中不同位置之间信息传递的路径长度，能直接提取序列中任意时间位置的依赖关系，极大地提高了序列信息相关性表示的能力。

2.3 支持向量机

20 世纪 90 年代末，Vapnik^[71]基于统计学理论和结构风险最小化原理提出了支持向量机。SVM 是一种有监督的机器学习模型，具有良好的泛化能力，能够有效处理小样本问题，在复杂、高维的数据集上有很好的适用性，通常用于模式识别、分类和回归分析。

SVM 的基本思想是将输入向量映射到一个高维的特征空间，并通过最大化边界来找到分离目标类的最优超平面^[72]。一般来说，数据集中的一个小子集称为支持向量，支持向量的数量应小于数据集中数据点的数量。当数据是线性可分的，这种线性超平面能完美的分离目标类。然而在日常生活中存在诸多复杂、非线性的问题，SVM 将原本样本空间中的非线性问题映射到高维特征空间中，将其转化为线性问题，但在高维的特征空间中，计算的复杂度会随着维度的增加呈指数级增加，甚至会导致“维度灾难”。因此，SVM 利用核函数隐式地定义

了一个到更高维特征空间的映射，同时将目标问题转化为凸优化问题，能有效避免陷入局部最小值，从而得到全局最优解。并且引入的核函数几乎没有增加模型参数计算的复杂度，在一定程度上避免了“维度灾难”。支持向量机最初被设计为二元分类器，随着需求的增加和技术的进步，SVM 逐渐扩展为解决多分类问题，其主要方法有一对多（One Against All, OAA）和一对一（One Against One, OAO）。第一种方法主要思想是利用优化公式在分类过程中同时考虑所有的类别数量，以实现多分类，当类别数量较多时，构建的目标函数非常复杂，算法复杂度高，实际应用比较困难。第二种方法主要思想是组合多个二分类 SVM 实现多分类的效果，包括一对其他（One Against the Rest, OAR），即构建 N 个 SVM，每个 SVM 用于区分目标类数据和其余类数据；一对一方法是将 N 类数据两两组合，构建 $n(n-1)/2$ 个支持向量机，最后采用投票机制确定分类结果。

SVM 也可用于回归预测，即支持向量回归（SVR），其广泛应用于诸多预测问题，如医学诊断、语音识别、文本挖掘和图像处理等。SVR 的基本思想是在高维特征空间中寻找一个最优超平面，使最远的样本点到平面的距离最小。假定训练数据为 $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，其中 x_i 表示输入向量， y_i 表示目标值， n 表示训练数据总数。对线性可分的数据进行回归分析，其表达式为：

$$f(x) = wx + b \quad (2.16)$$

其中 w 使最优超平面的法向量， b 是偏移量。在给定条件下，通过最小化欧几里得范数来预测目标值，即 $\|w\|^2$ ，其表示如下：

$$\min \frac{1}{2} \|w\|^2 \dots s.t. \begin{cases} y_i - wx_i - b \leq \varepsilon \\ wx_i + b - y_i \leq \varepsilon \end{cases} \quad (2.17)$$

其中 ε 表示预测值与目标值的偏差，即在回归问题中，如果预测值在目标值的 ε 偏差范围内，则认为预测值是准确的。在回归问题中引入松弛变量 (ξ_i, ξ_i^*) ，如下：

$$\min \left(\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i, \xi_i^*) \right) \quad (2.18)$$

$$s.t. \begin{cases} y_i - wx_i - b \leq \varepsilon + \xi_i \\ wx_i + b - y_i \leq \varepsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0 \end{cases} \quad (2.19)$$

式中, C 是正则化常数。对于非线性回归问题, 可以利用核函数将其映射到高维特征空间进行回归分析, 常用的核函数包括线性核 (linear kernel)、多项式核 (polynomial kernel)、Sigmoid 核、径向基核 (RBF kernel)、指数核 (Exponential kernel) 和拉普拉斯核函数 (Laplace kernel)。

线性核函数是最简单的核函数, 由 x 和 y 的内积表示:

$$Linear(x_i, y_i) = x_i^T y_i \quad (2.20)$$

多项式核函数是非平稳的核, 适用于归一化之后的数据, 其表达式如下:

$$Poly(x_i, y_i) = (\gamma x_i^T y_i + C)^d, d \geq 1, \gamma > 0 \quad (2.21)$$

Sigmoid 核函数表达式如下:

$$Sigmoid(x_i, y_i) = \tanh(\gamma x_i^T y_i + C), \gamma > 0 \quad (2.22)$$

径向基核、指数核和拉普拉斯核函数都是指数型核函数, 而拉普拉斯核对 σ 参数不那么敏感, 其表达式如下:

$$RBF(x_i, y_i) = \exp\left(-\gamma \frac{\|x_i - y_i\|^2}{2\sigma^2}\right) \quad (2.23)$$

$$Exp(x_i, y_i) = \exp\left(-\gamma \frac{\|x_i - y_i\|}{2\sigma^2}\right) \quad (2.24)$$

$$Laplace(x_i, y_i) = \exp\left(-\gamma \frac{\|x_i - y_i\|}{\sigma}\right) \quad (2.25)$$

式中, γ 、 σ 和 C 为可调节核参数

结合核函数, 回归函数可表示为:

$$f(x) = \sum_{i=1}^n (\xi_i - \xi_i^*) K(x_i, y_i) + b \quad (2.26)$$

2.4 本章小结

本章主要对遥感影像的概念和农作物估产相关的神经网络理论，第一部分介绍了遥感的相关概念及其基本原理。第二部分简单阐述了神经网络的工作原理，并对神经网络中两大典型算法卷积神经网络和循环神经网络进行了详细阐述。首先介绍了卷积神经网络的主要结构及其各部分的功能；其次介绍了循环神经网络基本原理和基于 RNN 改进的两个主流版本：长短期记忆网络和门控循环单元，分析了 LSTM 和 GRU 在不同应用场景的优劣；最后介绍了注意力机制和支持向量机的基本工作原理。

3 研究区与数据预处理

3.1 研究区概况

本文根据各区县的冬小麦产量和种植面积，选取了全国 14 个省和自治区作为研究区，包括浙江、安徽、河北、云南、山西、陕西、江苏、河南、湖北、山东、四川、甘肃、新疆维吾尔自治区和宁夏回族自治区，共 1713 个区县。图 3.1 为 2008 年全国冬小麦主产区示意图，颜色由浅到深表示该区域冬小麦产量高低。图中研究区内冬小麦产量占全国冬小麦总产量的 95% 以上，因此，选取的全国冬小麦主产区更具代表性。




图 3.1 全国冬小麦主产区示意图

3.2 数据来源

3.2.1 产量数据

本文以 2001—2018 年全国冬小麦主产区的区县作为预测单元，各区县冬小

麦年平均值作为预测值。其中 2001—2008 年的冬小麦产量值和播种面积来源于中国科学院资源学科创新平台^[73] (<http://www.data.ac.cn>)，2009—2018 年的作物数据收集自各省、市、区县统计年鉴。

3.2.2 遥感影像数据

遥感是利用不同的传感器和波段来获取地物信息，如卫星、无人机、地面车辆或探测器等，其基本原理是通过传感器接收的电磁波来辨别各种地物类别，如道路、水体、植被、农田、城镇和矿地等。随着卫星通讯和传感器技术的不断发展，遥感卫星能在短时间内对大尺度区域进行观测。目前，现代遥感进入了一个实时、快速、动态地对地观测新阶段^[74]。遥感具有高时空分辨率、重访周期快和获取便捷等特点，为广大研究者提供了丰富的高质量卫星图像进行科学研究，如城市路网提取、自然灾害评估、农业遥感监测等。

MODIS 是由美国宇航局主导开发的对地观测卫星，主要搭载在地球观测系统 (Earth Observation System, EOS) 中的 TERRA 和 AQUA 卫星上，该系统计划发射 15 颗卫星以组成一个全方位、全天候的地球气候监测系统^[75]。与 NOAA/AVHRR 相比，MODIS 有更高的空间和光谱分辨率，其最高幅宽可达 2000 多公里，足以覆盖一个国家，另外 MODIS 包括 36 个不同的光谱通道，波长从 0.4 μm -14.4 μm ，通过不同的波段组合能得到不同的地物信息。与 SPOT (Système Probatoire d'Observation de la Terre, 地球观测系统) 或 TM (Thematic mapper, 专题绘图仪) 多光谱数据相比，MODIS 具有更高的时间分辨率，搭载 MODIS 的 AQUA 和 TERRA 卫星之间相互配合能实现每 1-2 天观测一次地球表面，大大提高了 MODIS 数据的时效性。MODIS 能提供高光谱和高时间分辨率定期获取大尺度范围的影像数据，是区域和全球尺度遥感应用的关键卫星影像。

因此，本文采用中等分辨率成像光谱仪 (MODIS) 卫星图像，其具有较高的时间分辨率和光谱响应，能为大尺度作物估产提供长时间序列的科学数据。MODIS 影像数据下载自谷歌地球引擎 (Google Earth Engine, GEE)。GEE 是一个基于地理空间数据分析的云平台，由多源卫星数据和高性能计算服务组成，能为用户提供大容量的数据存储和强大的模型计算能力^[76]。其 PB 级的地理空间

数据和高性能计算能力为不同用户的不同需求研究提供了技术保障，并且该平台能轻松获取多尺度、多时相的遥感影像，允许用户自定义算法进行动态实验，避免了实际应用中下载和存储图像带来的不便，极大地提高研究人员的科研效率^[77]。GEE 已广泛的应用于地方、区域和全球范围内的许多领域的科学研究，包括森林监测^[78]、作物产量估算^[79]和作物制图^[80]等。

本文使用 3 种 MODIS 产品数据，如表 3.1 所示。MOD09A1 产品由 MODIS Level-2G 产品（MOD09GA）组成，该产品针对气体、气溶胶和瑞利散射等大气条件进行了矫正，其每个像素都是 8 天内基于高观测覆盖、低视角、无云或云影的最佳观测值。MOD09A1 数据提供了 500 米空间分辨率和 8 天时间分辨率的地表反射率影像，包括 7 个波段，如红外波段、近红外波段和蓝光波段等，能有效地描述地表作物的植株状态和不同物候期的生长变化^[81-82]；MOD11A2 V6 产品提供了地表昼夜温度数据，空间分辨率为 1000 米。昼夜地表温度能有效地描述作物生长过程中周围环境的状况，是农作物长势监测和产量预测方面的重要指标^[83]。MCD12Q1 V6 产品提供了全球地物掩膜数据，空间分辨率为 500 米，时间分辨率为 1 年，主要包括草原、农田、城市、水体等 17 类土地类型^[84]。

表 3.1 MODIS 影像类别

影像	波段描述	时间分辨率	空间分辨率	数值比例	数值范围
MOD09A1	Band1-7	8day	500m	0.0001	(-100,16000)
MOD11A2	LST of day	8day	1000m	0.02	(7500-65535)
	LST of night				
MCD12Q1	LC_Type1	1year	500m	/	(1-17)

3.3 数据预处理

在深度学习中，数据需要被制作为特定维度大小的张量进行网络训练，大多数现有方法是直接使用影像波段平均值或植被指数作为模型输入，这会降低模型计算的复杂度，但这往往会舍弃影像中的不同波段对地物反射的细微差异。因此，本文使用多时相 MODIS 影像的原始波段数据作为估产模型的输入。根据中国大田作物的常规播种和收获日期，冬小麦一般在 10 月中旬播种，第二年 6 月底左右收获。因此，将 MODIS 遥感影像的时间范围划分到 10 月 15 日到 7 月

1 日，每 8 天一张影像，则冬小麦整个生育期包括 30 个时间步。在影像数据下载前，结合中国冬小麦主产区的县边界，以县为单位获取遥感影像，并通过 MCD12Q1 中农作物掩膜数据获取农作物的种植面积，但由于其不能提取精细的冬小麦种植区域。因此，需要进一步的数据处理保证影像数据的可靠性，首先本文以冬小麦主产区作为研究区，根据农业农村部中国农业信息网显示，冬小麦的种植面积与大豆和水稻种植面积在空间上几乎没有重叠，因此可以剔除大部分的大豆和水稻数据。由于冬小麦是越冬作物，冬小麦的生育期与其他作物冲突较少，如玉米、大豆、花生等。因此，本文根据冬小麦的生育期构建数据集，避免了中国大多数主要农作物的影响，保证了数据的可靠性。

在遥感影像处理阶段，根据冬小麦产量数据，剔除产量较低的区县，然后在 GEE 平台，取 2×2 为阈值，剔除掩膜后的影像像素点偏少的县。当影像中冬小麦的像素点太少，神经网络模型很难提取到作物特征，反而会将其当成噪声数据，影响模型的整体性能。最后将 MOD09A1 地表反射率的 7 个波段和 MOD11A2 昼夜温度数据的 2 个波段进行融合，将其共同作为网络的输入特征。

一般来说，冬小麦的生长过程可划分为 12 个生育期，包括：播种期、出苗期、分蘖期、越冬期、返青期、起身期、拔节期、孕穗期、抽穗期、开花期、灌浆期、成熟期，每个生育期约为 21 天，为方便本文后续实验研究，将两个生育期划分为一个时间节点，而每个时间节点对应于数据集中的 5 个时间步，即播种-出苗期（0~5）、分蘖-越冬期（5~10）、返青-起身期（10~15）、拔节-孕穗期（15~20）、抽穗-开花期（20~25）、灌浆-成熟期（25~30）。由于各区县的冬小麦种植面积不同，为统一网络输入，取 32×32 作为阈值，当影像中冬小麦像素大于阈值时，取相对集中、大面积的冬小麦像素点，剔除零星分布的种植区域；反之，则将其余像素点填充为零。为提升网络的收敛速度，对冬小麦数据集进行标准化。

$$x_n = \frac{x_i - \mu}{\sigma} \quad (3.1)$$

式中， μ 表示均值， σ 表示方差。最终冬小麦估产数据集由 30 个时间序列的影像块组成，即（30，32，32，9），其中 32 表示单一影像块的大小，9 表示影像

波段，包括 7 个地表反射率波段和 2 个昼夜温度波段。

3.4 本章小结

本章主要介绍了本文所使用的数据和数据集的处理过程，首先介绍了全国冬小麦主产区以及选取的依据；然后介绍了产量数据的来源和 MODIS 影像数据的类型及其获取方法，包括 MOD09A1 地表反射率、MOD09A1 昼夜温度数据和 MCD12Q1 全球土地覆盖类型数据；最后重点描述了冬小麦数据集的制作流程，包括 3 种 MODIS 产品数据的掩膜、波段融合、冬小麦生育期的选择和数据标准化。

4 基于多时相遥感影像的冬小麦产量预测

小麦是最重要的谷类作物之一，广泛分布于亚洲、欧洲和美洲。中国是小麦的主要生产国，而冬小麦产量占小麦总产量的 95% 以上。因此，及时准确地预测中国冬小麦产量对国家粮食安全和农业可持续发展具有重要意义。

随着遥感卫星技术的飞速发展，高时空分辨率的遥感影像为大范围农作物估产提供了数据支持。大多研究者使用影像中的植被指数来构建农作物产量预测模型，而植被指数是手工构建的特征，不能完全反映作物的生长特征。因此，本文基于 MODIS 地表反射率和昼夜温度影像构建了冬小麦产量预测数据集，不预加任何手工特征，完全保留影像中的农作物信息。

诸多研究表明，CNN 能高效地提取图像特征，而 RNN 能有效关联上下文信息，适用于处理长时间序列问题。农作物的生长环境复杂，植株形态随时间发展不断变化，单一使用 CNN 或 RNN 不能有效地从多时相遥感影像中获取作物不同时期的生长特征。因此本章结合 CNN 和 GRU 构建了端到端的融合神经网络估产模型（CNN-GRU），建立农作物不同生育期的植株形态变化和遥感影像中不同波段的农作物反射率与作物产量之间的内在联系，从多时相遥感图像中挖掘空间-光谱-时间联合特征，以实现对中国冬小麦主产区的产量准确估测。

4.1 CNN-GRU 估产模型构建

如图 4.1 所示，所提出的 CNN-GRU 估产模型由 CNN、GRU 和全连接层组成。网络由多时相遥感影像作为输入，包括 30 个时间序列的影像立方块（32，32，9），其中 32 表示单一影像块的大小，9 表示影像波段。首先，CNN 从不同时间步的遥感图像中获取高层次的光谱-空间特征，并将其转换为一维特征向量。在此基础上，GRU 以 30 个时间步的特征向量作为输入，整合冬小麦不同生育期之间的时间依赖。最后利用单一神经元的全连接层进行产量预测。




图 4.1 CNN-GRU 估产模型体系结构

4.1.1 基于 CNN 的空间光谱特征提取

在遥感影像中，光谱反射率会随着作物不同物候期的生物量变化而发生波动^[85]，同时农作物是一种高聚集性地物，影像中邻近作物像素通常表现出很强的空间相关性。因此，从影像中提取作物的光谱-空间特征是产量预测的关键。而诸多研究表明，CNN 在图像处理方面有显著优势，其滑动卷积和多层次结构能有效提取影像中地物特征^[86-87]。

本章所使用的 CNN 包括 4 个卷积层、4 个池化层和一个全连接层，如图 4.2 所示。输入数据为不同时间步的冬小麦遥感影像，每个卷积层使用 3×3 的卷积核来获取固定大小的作物光谱信息，并利用滑动窗口覆盖影像的整个空间维度，以提取影像中作物的光谱-空间特征。本文选择 ReLu 作为卷积层的激活函数，

以避免反向传播中的梯度消失或梯度爆炸，还能加速网络收敛，提升模型训练速度。CNN 输出的特征图表示为：

$$x_{i+1} = f(\sum x_i \odot) \quad (4.1)$$

其中， $f(\bullet)$ 表示 ReLu 激活函数， x_i 表示上一个卷积层的输出， w_i 和 b_i 表示第 $i+1$ 层和第 i 层之间的权重和偏置项， $\odot$ 表示矩阵运算。




图 4.2 CNN 模型结构

为降低网络参数和计算成本，在卷积之后，使用最大池化层（Max Pooling Layer）来处理卷积计算得到的特征映射，其中池化窗口为 2×2 ，池化步长为 2。最大池化层的表达式如下：

$$x_{pool} = \text{Max}(x_{i+1}) \quad (4.2)$$

式中， x_{pool} 表示最大池化层的输出。最终，利用包含 1024 个神经元的全连接层将每个时间序列的冬小麦影像块映射为一维的特征向量 $\{f_1, f_2, \dots, f_{30}\}$ ，其中 f_i 表示特征向量。

4.1.2 基于 GRU 的时间相关性建模

在农作物不同的物候期，其植株形态会有显著的变化，而 CNN 能有效提取影像中作物生长的光谱-空间特征，缺乏对不同时间步作物形态变化的描述。RNN 能有效关联上下文信息，擅长对时间序列数据进行建模分析^[88-89]。但传统的 RNN 难以处理长时间序列数据，存在梯度消失的问题。门控循环单元是基于 RNN 改进循环神经网络，引入了门机制，不仅缓解了梯度消失的问题^[90]，还能够有效地挖掘长时间序列数据的内在联系。

因此，在 CNN 的基础上，使用 GRU 网络来挖掘冬小麦不同生育期之间深层次的时序特征。GRU 由更新门 z_t 、重置门 r_t 和隐藏状态 h_t 组成，将 30 个时间

步的特征向量 x_t 作为输入，其中更新门用于确定在当前隐藏状态 h_t 之前，保留多少先前时刻的状态信息；重置门用来控制前一时刻的隐藏状态 h_{t-1} 对当前输入 x_t 的影响；隐藏状态用于整合连续的冬小麦时序特征，即在考虑之前时间步的冬小麦生长状态的情况下，学习当前输入 x_t 的特征。第 $t, t \in (0, 30)$ 个时间步各个门的迭代参数（ r_t, z_t, h_t 和 h_t ）可表示为：

$$r_t = \sigma(W_{xr}x_t + W_{hr}h_{t-1} + b_r) \quad (4.3)$$

$$z_t = \sigma(W_{xz}x_t + W_{hz}h_{t-1} + b_z) \quad (4.4)$$

$$h_t = \text{Tanh}(W_{xh}x_t + r_t \odot \quad)) \quad (4.5)$$

$$h_t = z_t \odot \quad \odot \quad (4.6)$$

式中， x_t 表示第 t 个时间步的输入， r_t 、 z_t 、 h_t 和 h_t 分别表示第 t 个时间步的重置门、更新门、候选状态和隐藏状态， σ 表示 Sigmoid 激活函数， W_{xr} 、 W_{hr} 、 W_{xz} 、 W_{hz} 、 W_{xh} 、 W_{hh} 、 b_r 和 b_z 分别表示迭代过程中的权重矩阵和偏置项， $\odot$ 表示矩阵运算。GRU 中门机制能保存生育期前期冬小麦的生长状况，随着时间的推移，不断整合所有生育期冬小麦的生长特征，挖掘其内在联系，为产量预测提供可靠依据。

4.2 结果与分析

本文使用 python 语言对遥感影像数据进行预处理，在 TensorFlow 的深度学习框架下进行估产模型的构建、训练和测试，并安装了 CUDA 等运算平台以利用 GPU 加速估产模型的训练。实验的硬件仿真环境为 Intel(R) Core(TM) i7-6900K CPU，使用 NVIDIA GeForce GTX 1080 GPU 对模型进行加速，其显存大小为 8G。

为对中国冬小麦主产区的产量预测，本文对不同的估产模型进行训练。在模型训练阶段，以全国冬小麦主产区整个生育期的遥感影像作为训练数据，各区县的年平均产量作为标签，年份从 2001-2015 年，时间步 $t \in (0, 30)$ 。为保证无偏性，每个批次从数据集中随机抽取 32 个样本进行训练。初始学习率为 0.0001，分阶段逐步递减为初始学习率的 10 倍，达到迭代次数时，停止训练。

在预测阶段,以 2016-2018 年全国冬小麦主产区的年平均产量和遥感影像作为预测数据,分别对各个估产模型进行性能评估。

本文使用平均绝对误差 (Mean Absolute Error, MAE)、均方根误差 (Root Mean Square Error, RMSE) 和决定系数 (Coefficient of determination, R^2) 来评估不同模型的性能^[91-93]。

$$MAE = \frac{1}{n} \sum_{i=1}^n |real_{id} - pred_{id}| \quad (4.7)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (real_{id} - pred_{id})^2} \quad (4.8)$$

$$R^2 = \frac{\sum_{i=1}^n ((real_{id} - \overline{real_{id}})(pred_{id} - \overline{pred_{id}}))^2}{\sum_{i=1}^n (real_{id} - \overline{real_{id}})^2 \sum_{i=1}^n (pred_{id} - \overline{pred_{id}})^2} \quad (4.9)$$

其中 $n(i=1,2,\dots,n)$ 表示冬小麦数据集的样本数, $real_{id}$ 和 $\overline{real_{id}}$ 分别表示冬小麦统计产量和对应的平均值, $pred_{id}$ 和 $\overline{pred_{id}}$ 分别表示估产模型的产量预测值和对应的平均值。 R^2 越接近 1, 表明产量预测值和统计值拟合的越好, 估产模型的性能越高。 RMSE 和 MAE 的值越小, 表明产量预测值和统计值之间的差异越小, 估产模型的预测精度越高。

4.2.1 数据贡献度分析

一般来说, 卫星影像的不同波段对不同地物的敏感性有差异, 因此, 为评估 MODIS 影像中不同波段对农作物产量预测的影响程度, 包括地表反射率的 7 个波段: 红光波段、近红外波段、蓝光波段、绿光波段、短波红外波段、中短波红外波段、长短波红外波段, 以及昼夜温度数据的 2 个波段: 日间地表温度和夜间地表温度。

本节对地表反射率数据和昼夜温度数据分别进行训练, 遥感影像中不同光谱波段包含了作物生长状况和产量之间的相关信息, 因此, 分别对地表反射率的 7 个波段进行评估, 依次去除一个波段, 使用剩余波段作为估产模型的输入。如表 4.1 所示 (以 RMSE 为例, 单位 kg/hm^2), 删除波段 1 表示去除第一个波

段, 仅使用第 2~7 个波段, 以此类推。波段 1~7 表示使用地表反射率中所有波段。实验结果表明:

1) 将地表反射率的所有波段作为估产模型的输入, 其预测精度最高, 表明地表反射率的 7 个波段均对农作物产量预测起关键作用。在分别删除红光波段、近红外波段和长短波红外波段, 即删除地表反射率中第 1、2 和 7 波段, 估产模型的 RMSE 下降了 8% 左右; 而在删除蓝光波段后, 即地表反射率中的第三个波段, 估产模型的 RMSE 下降了 3%, 表明红光波段、近红外波段和长短波红外波段相较于地表反射率的其他波段更能反映地表作物真实的生长状况, 红光波段和近红外波段波长的光谱反射和作物冠层光吸收的生理过程高度相关, 并且地表作物中的叶绿素等生物成分在近红外波段和其他波段间存在显著的光谱差异。而蓝光波段主要反映植被的下垫面土壤和植被间的差异, 可能相较于其他波段不能更直接的反映农作物生长的植株形态变化。

2) 仅使用地表反射率进行训练的 RMSE 年平均值为 841 kg/hm^2 , 其精度优于仅使用昼夜温度数据的 1059 kg/hm^2 , 表明相较于昼夜温度数据, 地表反射率的 7 个波段更能反映农作物不同阶段的生长信息。如红光波段对绿色植被有强吸收性, 对地表作物的覆盖度和生长状态比较敏感; 短波红外波段对地表作物的叶片含水量和农作物的生理特性非常敏感^[94-95], 对农作物产量预测有极大帮助。

表 4.1 MODIS 影像不同波段对产量预测的影响 (以 RMSE 为例)

年份	地表昼夜 温度	地表反射率							波段 1-7
		删除波 段 1	删除波 段 2	删除波 段 3	删除波 段 4	删除波 段 5	删除波 段 6	删除波 段 7	
2018	990	927	880	874	895	913	896	909	852
2017	1 087	890	891	848	849	834	854	856	830
2016	1 101	876	890	839	880	860	881	904	842
平均值	1 059	897	887	853	874	869	877	889	841

4.2.2 估产模型性能检测

为评估 CNN-GRU 融合神经网络模型的性能，将其与其他估产模型进行实验对比，包括深度学习模型（CNN、GRU、LSTM）和机器学习算法（SVR、RF、DT）。为保证对比实验的可靠性，所有估产模型在同一软硬件环境下进行训练和测试。CNN 能有效提取影像中的作物特征，但难以挖掘作物不同时间序列的内在联系，则需要将影像中的波段信息和时间序列叠加作为模型输入，即输入为 $(32, 32, 30 \times 9)$ 。由于循环神经网络模型的结构不同，GRU 和 LSTM 需要将影像数据转化为时间序列特征向量，即 $(30, 32 \times 32 \times 9)$ 。此外，由于机器学习模型的本身的结构限制，需要将影像数据转化为一维向量，即 $30 \times 32 \times 32 \times 9 = 276480$ ，但维度太高，机器学习模型容易陷入“维度灾难”。则使用冬小麦影像的植被指数 NDVI 作为模型输入。

本节使用网格搜索来确定各个估产模型的关键参数，其基本思想是通过在参数给定的区域内调整不同参数的组合，找到一组最优参数使模型性能最佳，另外，在冬小麦训练数据集中使用 5 倍的交叉验证，确保最优参数的可靠性。不同估产模型的关键参数设置如下：

1) 卷积神经网络（CNN）：包括 4 个卷积层、4 个池化层和一个全连接层，批处理大小为 32，初始学习率为 0.0001。

2) 长短期记忆网络（LSTM）：由包含 128 个神经元的 LSTM 和一个全连接层组成，批处理大小为 32，初始学习率为 0.001。

3) 门控循环单元模型（GRU）：由包含 128 个神经元的 GRU 和一个全连接层组成，批处理大小为 32，初始学习率为 0.001。

4) 支持向量回归（SVR）：使用径向基（RBF）作为 SVR 的核函数，惩罚因子 $C=2, 5, 10, 100$ ，松弛变量 $\gamma = 10^{-1}, 10^{-2}, 10^{-3}$ 。

5) 决策树 DT：包括树的最大深度 $\max_depth=3, 4, 5, 6, 7$ ，叶子节点最少样本数 $\min_samples_leaf=10, 15, 20, 30$ ，内部节点再划分所需最小样本数 $\min_samples_split=5, 8, 10$ 。

6) 随机森林（RF）：包括子树的数量 $\text{num_estimators}=50, 80, 100$ ，每棵树的深度 $\max_depth=3, 6, 9$ 。

表 4.2 不同估产模型性能对比

年份	模型	RMSE (kg·hm ⁻²)	MAE (kg·hm ⁻²)	R ²
2018	CNN-GRU	879	624	0.703
	CNN	960	705	0.618
	GRU	1008	749	0.609
	LSTM	1040	787	0.582
	SVR	1200	898	0.443
	RF	1289	976	0.341
	DT	1232	929	0.356
2017	CNN-GRU	853	606	0.761
	CNN	937	678	0.687
	GRU	1010	749	0.658
	LSTM	1049	780	0.638
	SVR	1113	870	0.592
	RF	1220	910	0.489
	DT	1295	973	0.452
2016	CNN-GRU	850	586	0.768
	CNN	1071	763	0.667
	GRU	965	691	0.701
	LSTM	1051	746	0.644
	SVR	1170	903	0.557
	RF	1259	912	0.403
	DT	1344	1 008	0.351

在本节中,使用 CNN-GRU 估产模型和其他估产网络进行对比实验,以 2001—2015 年数据作为训练集,2016—2018 年作为测试集。由表 4.2 可知:

1) 深度学习模型(CNN-GRU、CNN、LSTM、和 GRU)预测精度均优于机器学习模型(SVR、RF 和 DT),表明在作物产量预测领域,深度学习模型能有效提取遥感图像中的作物特征,相较于机器学习模型更能描述作物产量与预测变量之间的非线性关系。

2) 深度学习模型中,CNN 模型性能优于 RNN,其中 CNN 的年平均 RMSE 和 MAE 分别为 989、715 kg/hm²。LSTM 和 GRU 的预测精度相当,年平均 RMSE 分别为 994 和 1046kg/hm²,年平均 MAE 分别为 729 和 771kg/hm²,但 GRU 预

测精度略优于 LSTM，这是因为统计的产量数据有限，而 GRU 在偏小的数据集上性能优于 LSTM。单一的深度学习模型预测精度均低于 CNN-GRU 估产模型，表明单一的深度学习模型难以同时挖掘影像中不同生育期的作物特征。CNN 能有效提取遥感影像中作物的光谱-空间信息，但难以挖掘多时相影像中作物的时间联系，而作物在不同时间阶段呈现出不同的植株形态，生长过程有明显的时间相关性，农作物不同生育期的时间相关性的缺失会严重影像估产模型的整体性能；而循环神经网络（LSTM 和 GRU）能整合影像中作物不同生育期的时间联系，但难以捕捉区域作物之间复杂的空间相关性。因此，所提出的 CNN-GRU 估产模型结合了 CNN 和 GRU 的优点，能从多时相遥感影像中充分挖掘作物的光谱-空间-时间联合特征，为大尺度作物产量预测提供了新思路。

3) 所提出的 CNN-GRU 估产模型年平均 RMSE 为 860.6 kg/hm^2 ，相较于 CNN、GRU、LSTM、SVR、RF 和 DT 分别降低了 14.94%、15.61%、21.69%、35%、46.04%和 50.03%，年平均 MAE 为 605.3 kg/hm^2 ，相较于其他模型分别降低了 18.17%、20.58%、27.42%、47.08%、54.02%和 60.3%。表明所提出的 CNN-GRU 估产模型能从多时相遥感影像中挖掘冬小麦的生长特征，并建立与历史产量之间的内在联系，以实现大尺度范围内冬小麦产量的精准预测。但对于部分高产量的区县（河南省南阳市的新野县和陕西省西安市的灞桥区）和部分低产量的区县（如新疆维吾尔自治区的和硕县和伊宁县）CNN-GRU 估产模型预测的误差偏大（如图 4.3 所示），导致这一问题的原因可能是冬小麦数据集中低产量和高产量的区县数量占比偏低，估产模型对占比较低的高产量和低产量的区县拟合能力较差，预测的误差偏高。对于高产量的新野县和灞桥区来说，地处平原，均为冬小麦气候适宜区，种植面积较大，而模型输入中没有表达区域异质性的参数，导致低估了部分高产量地区的冬小麦产量；对于低产量的新疆维吾尔自治区，其环境复杂、海拔高等不确定性因素均会影响估产模型的预测精度。




图 4.3 CNN-GRU 估产模型的全国冬小麦主产区空间分布图（2016 年为例）

4.2.3 不同生育期冬小麦产量预测

为评估 CNN-GRU 估产网络预测冬小麦产量的最佳时间窗，对冬小麦累计生育期的时间步（0~5，0~10，0~15，0~20，0~25，0~30）和单一生育期的时间步（0~5，>5~10，>10~15，>15~20，>20~25，>25~30）进行单产预测。

如图 4.4 所示，CNN-GRU 估产模型在冬小麦生长初期的预测精度较差，累计生育期的年平均 RMSE 和 MAE 分别为 1 109、840.6 kg/hm²，单一生育期的年平均 RMSE 和 MAE 分别为 1 117.3、855.6 kg/hm²，这是由于在冬小麦生长初期模型缺乏足够的遥感影像来描述作物的生长状态和环境信息，随着时间推移，不同生育期的农作物生长特征被整合到估产模型中，估产模型的性能逐步提升。

1) 使用单一生育期的冬小麦影像，估产模型的性能较低，相较于累计生育期的所有遥感影像（0~30）预测精度降低了 25%到 28%。单一生育期的作物影像仅包含部分时间步的作物特征，前后时间跨度短，植株形态变化不明显，缺乏不同生育期作物特征的前后对比，估产模型难以捕捉不同生育期遥感影像中作物的生长特征，会严重影响估产模型预测精度。


2) 在累计生育期的实验中（如图 4.4 红线部分），返青-起身期和拔节-孕穗期两个时间步的预测精度相差最大，相较于返青-起身期，拔节-孕穗期的年平均 RMSE 降低了 10%左右。在返青-起身期时，冬小麦苗长出初春第一片叶子，植株茎部开始伸长，但未完全露出地面。而在拔节期，冬小麦生长特征比较明显，

茎部露出地面约 1.5~2 cm, 估产模型已经能捕捉到冬小麦的生长状态。表明 CNN-GRU 估产模型能充分挖掘不同生育期冬小麦的生长特征及其变化过程。

3) CNN-GRU 估产模型在灌浆-成熟期的预测精度最高, 平均 RMSE 和 MAE 分别为 817、556 kg/hm², R² 为 0.76, 均优于冬小麦的其他生育期。在作物的生长后期估产模型的预测精度最高, 如成熟期或收获期, 多时相影像中作物生长特征均被融合到 CNN-GRU 估产模型中, 能构建不同生育期作物形态变化之间的内在联系, 充分发挥 CNN-GRU 估产模型的优势, 有能力精准预测大尺度的冬小麦产量。

4) 累计生育期中拔节-孕穗期和抽穗-开花期估产模型性能相当, 年平均 RMSE 分别为 849、823 kg/hm², 比成熟期低 3.84%和 0.69%, 年平均 MAE 分别为 571、560 kg/hm², 比成熟期低 2.64%和 0.71%。表明在冬小麦生育期中后期, CNN-GRU 估产模型能够准确预测大尺度范围内的冬小麦产量, 即该估产模型能提前 2 个月预测中国主产区冬小麦的产量。

5) 图 4.4a 中, 抽穗-开花期和灌浆-成熟期的估产模型预测精度非常接近, 其中抽穗-开花期 2018 年的 RMSE 为 840 kg/hm², 优于灌浆-成熟期, 而 2016 年的 RMSE 为 826 kg/hm², 仅比灌浆-成熟期低 0.4%。这是由于 CNN-GRU 估产网络中是从冬小麦整个生育期中挖掘时间信息, 但部分地区的冬小麦实际成熟时间与统计的时间不一致。因此, 在冬小麦生育后期会存在不同程度的噪声, 这会影响估产网络的性能。






图 4.4 不同生育期 CNN-GRU 估产模型精度

4.3 本章小结

本章节结合卷积神经网络和循环神经网络的特点，针对农作物复杂的生长环境和不同时期变化的生长特征，构建了 CNN-GRU 估产模型对中国冬小麦主产区进行产量预测，并对 CNN-GRU 估产模型的体系结构进行了详细阐述。实验表明该模型能从多时相遥感图像中挖掘光谱-空间-时间联合特征，构建作物产量和不同生育期的生长特征之间的动态联系。结论如下：

1) 探索了 MODIS 影像中地表反射率和昼夜温度数据的不同波段对农作物产量预测的影响程度，使用地表反射率的预测精度优于仅使用昼夜温度数据，其中地表反射率中的 7 个波段中红光波段、近红外波段和长短波红外波段对冬小麦产量预测影响最大；

2) 然后将提出的 CNN-GRU 估产模型与单一的深度学习网络（CNN、LSTM 和 GRU）和传统机器学习模型（SVR、RF 和 DT）进行性能对比，CNN-GRU 估产模型均优于其余对比模型，并且提出的方法能直接从原始的卫星图像中挖掘深层次的农作物生长特征，而不需要任何手工制作的特征或对图像进行降维。

3) 最后根据冬小麦不同生育期期，划分不同的时间步以寻找冬小麦产量预测的最佳时间窗。CNN-GRU 估产模型在冬小麦成熟期的预测精度最高，年平均 RMSE 和 MAE 分别为 817、556 kg/hm²。冬小麦拔节-孕穗期和抽穗-开花期的预

测精度与成熟期相当，年平均 RMSE 仅比成熟期高 3.84%和 0.69%，表明 CNN-GRU 估产模型在冬小麦生育期的中后期已经能够准确预测其产量。

5 基于多源数据融合的冬小麦产量预测

对大尺度的农作物进行产量预测时，不同地区的气候环境存在差异，会导致农作物的生育期不同，而在数据集中统一所有地区农作物生育期的时间难度很大，人力和时间成本很高。因此，本文引入注意力机制，计算冬小麦生育期的每一个时间步的权重，以动态加权的方式确定产量预测的最佳生育期，弥补对大尺度区域产量预测时，数据集中不同区域存在的作物物候期差异。

考虑到农作物的产量与周围的环境因素息息相关，如日照时间、降水量、温度、湿度、土壤性质和施肥量等，但这些数据获取难度大，费时费力，不适合大尺度的产量预测。而邻近区域的作物生长环境有较强的时空相关性，即邻近区县的土壤类型、温度、降水等环境因素非常接近，且不会随着时间发生显著性变化^[39]。因此，本文利用预测单元的位置信息替代大量的环境因子，并设计了一个变异的 Laplace 核函数，使用 SVR 融合神经网络提取的深层次特征和预测单元的位置信息，替代全连接层进行最后的产量预测。

5.1 CTrm-SVR 估产模型构建

为解决上述问题，本文提出了一个混合神经网络（CTrm-SVR）来进行农作物产量预测。如图 5.1 所示，首先利用 CNN 从每个时间步的遥感影像中提取深层次的空间-光谱特征，并利用包含 256 个神经元的全连接层将其映射为一维的特征向量，最终得到 30 个时间步的特征向量，其维度为（30，256）。其次借鉴了自然语言处理领域的 Transformer 的编码器结构，利用自注意力机制自适应的调整不同生育期作物特征的权重分布，以动态加权的方式确定冬小麦的最佳生育期。然后使用强拟合能力的 SVR 替代全连接层进行产量预测，并设计了一个变异的 Laplace 核函数，融合神经网络提取的深层次特征和预测单元的位置信息，进一步提升估产模型的泛化能力。




图 5.1 CTrm-SVR 估产模型体系结构

5.1.1 基于自注意力机制的最佳生育期筛选

针对大尺度农作物产量预测中不同地区作物物候差异问题，本章引入了自注意力机制，其基本结构参考了 Transformer 的编码器结构，主要包括位置编码、多头自注意力机制和前馈网络，为防止网络退化、梯度消失等问题，在多头注意和前馈网络之后还有一个残差连接结构。其中自注意力机制无法捕捉不同时间位置信息^[96]，因此，需要对不同的输入时间序列的特征向量利用不同的正余弦函数进行位置编码（Positional Encoding, PE），使其具有相对或绝对的位置关联，而不引入额外的参数。位置编码函数表达式如下：

$$PE_{(pos, 2i)} = \sin(pos / 10000^{2i/d_{model}}) \quad (5.1)$$

$$PE_{(pos, 2i+1)} = \cos(pos / 10000^{2i/d_{model}}) \quad (5.2)$$

式中, pos 表示位置, i 表示位置特征的维度, d_{model} 表示位置编码的维度。对于不同位置使用三角函数 $\sin$ 和 $\cos$ 进行编码, 任意位置 $pos+k$ 都能用位置 k 的向量线性表示, 使得每个时间步的特征向量具备了相对位置信息。

然后, 将包含位置信息时间序列特征向量输入自注意力机制 (Self Attention mechanism) 中, 其内部会将特征向量映射为查询键值矩阵 (Q, K, V), 其中 Q 和 V 表示时间序列的特征向量, K 表示每个时间序列之间的相似度。自注意力机制是学习输入序列的内部联系, 即当前时间步与其他序列之间的加权和, 最终捕获全局时间序列信息。多头自注意力模块 (Multi-Head self-attention Module) 包含多个自注意力机制, 每个自注意力被称为头^[96]。多头自注意力模块是将自注意力中的 Q, K, V 矩阵映射到不同的低维特征子空间中, 在子空间中计算不同时间序列的相关性, 该结构使模型能共同关注不同时间的子空间信息。其表达式如下:

$$Attention(Q, K, V) = Softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5.3)$$

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h) \quad (5.4)$$

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (5.5)$$

式中, Q, K, V 表示注意力矩阵, d_k 表示特征向量维度, $Softmax$ 表示激活函数, $Concat$ 表示矩阵相加, W_i^Q, W_i^K, W_i^V 分别表示 Q, K, V 的权重矩阵。

前馈网络包含一个全连接层 (Fully Connected Layer, FC) 和一个 ReLu 激活函数的非线性变换, 在全连接层之前应用层归一化 (Layer Normalization, LN)。前馈网络的输出使用残差连接, 以避免网络退化和梯度消失, 其表达式如下:

$$x_{out} = x_{in} + FC(LN(x_{in})) \quad (5.6)$$

式中, x_{in} 和 x_{out} 分别表示前馈网络的输入和输出, FC 表示全连接层, LN 表示层归一化。

5.1.2 基于多源数据融合的产量预测

作物生长与诸多因素相关，如作物基因型、环境因素和实际管理等，而作物产量与作物生长的诸多因素呈现高度复杂的非线性关系，有研究表明，环境因素对作物产量的影响大于作物基因型^[97]。而环境因素，如温度、日降水量、土壤性质和施肥量等，数据获取难度大，不适用于大尺度的产量预测。邻近预测单元的环境因素有较强的时空相关性，因此，利用每个预测单元的空间位置信息替代大量的环境因素。

神经网络均需要大量的训练数据，且可能存在过拟合问题。本章使用具有强拟合能力的支持向量回归替代全连接层进行最后的产量预测，以有效解决小样本问题，提高模型整体的泛化能力。SVR 是将支持向量机应用到回归问题中，能高效的解决小样本、非线性问题，其基本思想是通过核函数将输入映射到高维特征空间，在新的特征空间中建立一个最优超平面来拟合数据样本^[98]。为嵌入预测单元的位置信息，本文设计了一个变异的 Laplace 核函数，用于融合神经网络提取的深层次特征和预测单元的位置信息。其表达式如下：

$$K(x, x') = \exp\left(-\frac{\|spa_t - spa_t'\|}{\sigma_{spa_t}} - \frac{\|loc - loc'\|}{\sigma_{loc}}\right) \quad (5.7)$$

式中， spa_t 表示神经网络提取的冬小麦特征向量， loc 表示预测单元的位置信息， σ_{spa_t} 、 σ_{loc} 是拉普拉斯核函数中的超参数。

5.2 结果分析

5.2.1 CTrm-SVR 估产模型自参数分析

本章所提出的 CTrm-SVR 估产模型参数多，结构复杂，其可调节超参数主要在 Transformer 的编码器部分，包括位置编码的维度 $d_{model}=[256,512,1204]$ 、前馈网络的神经元个数 $Dff=[256,512,1204,2048]$ 和编码器的迭代次数 $N=1,2,...,6$ ，其中在 CTrm-SVR 估产模型参数传递中，输入的特征向量维度应

小于等于前馈网络的神经元个数，即 $d_{model} \leq D_{ff}$ 。




图 5.2 Transformer 的编码器迭代次数

如图 5.2 所示，CTM-SVR 估产模型的预测精度并没有随着编码器迭代次数的增加而提升，其中，编码器迭代 3 次时估产模型性能最优，RMSE 和 MAE 的年平均值分别为 888、628 kg/hm²，R² 为 0.726。Transformer 最初是用于自然语言处理（Natural Language Processing, NLP），包括词法分析、语言翻译等，其难点在于如何获取一个单词的上下文信息，而 Transformer 对编码器进行多次迭代是为了挖掘文章中某一个词与其他单词或语句之间的联系，其关联词句之间的距离跨度远超产量预测中的作物不同生育期的时间跨度。因此，在本文所提出的 CTM-SVR 估产模型中，编码器迭代 3 次效果最好，迭代次数的增加反而会使作物特征更抽象，估产模型难以准确捕捉作物生长信息。

在位置编码时，位置编码的维度与每个自注意力头的 QKV 矩阵维度相关，即 $(T, d_{model}/8)$ ，其中 T 表示冬小麦的时间序列， d_{model} 表示位置编码维度。 QKV 矩阵维度增加会提高多头自注意力部分的整体计算成本，增加模型复杂度。在前馈网络中包含一个全连接层和一个 ReLU 激活函数的非线性变换，保证模型在作物特征向量的不同位置上进行非线性变化，引入非线性因素，增加模型的泛化能力。但包含多个神经元的全连接层会增加大量的计算参数，但其神经元数量过少，模型难以有效地构建特征和目标之间的映射关系。

表 5.1 Transformer 的编码器参数分析

年份	位置编码维度	神经元个数	RMSE (kg·hm ⁻²)	MAE (kg·hm ⁻²)	R ²
2018	256	256	909	642	0.680
		512	890	619	0.694
		1024	891	618	0.693
		2048	928	650	0.667
	512	512	929	662	0.667
		1024	924	675	0.670
		2048	906	633	0.683
	1024	1024	935	680	0.663
		2048	950	683	0.652
2017	256	256	888	653	0.740
		512	902	653	0.732
		1024	872	620	0.749
		2048	887	644	0.741
	512	512	1048	820	0.638
		1024	920	669	0.721
		2048	1080	829	0.616
	1024	1024	939	705	0.710
		2048	938	714	0.711
2016	256	256	930	645	0.721
		512	884	591	0.748
		1024	880	583	0.750
		2048	924	641	0.724
	512	512	890	611	0.744
		1024	895	617	0.741
		2048	937	678	0.717
	1024	1024	897	634	0.741
		2048	908	626	0.734

因此, 为保证 CTrm-SVR 估产模型能达到最佳性能, 对位置编码的维度 $d_{model}=[256,512,1204]$ 和前馈网络的神经元个数 $Dff=[256,512,1204,2048]$ 进行实验分析, 如表 5.1 所示, 当 d_{model} 取 256, Dff 取 1024 时, CTrm-SVR 估产模型的预测精度最高, 年平均 RMSE 和 MAE 分别为 881、607 kg/hm², R² 为 0.731,

均优于其他组合。在 CTrm-SVR 估产模型编码器部分最优参数为： $n=3$ 、 $d_{model}=256$ 和 $Dff=1024$ 。

5.2.2 SVR 核函数性能检测

为评估不同核函数对冬小麦产量预测的影响，使用 CTrm-SVR 估产模型对 2016-2018 年中国冬小麦主产区进行产量预测，对 SVR 回归预测部分构建了 6 种不同的核函数，包括线性核（linear kernel）、多项式核（polynomial kernel）、Sigmoid 核、径向基核（RBF kernel）、指数核（Exponential kernel）和拉普拉斯核函数（Laplace kernel）。在本节中，使用网格搜索的方法来调整 SVR 核函数的关键参数，主要包括 d 、 C 、 γ 和 σ ，其中 $d(d=[2,3,...,6])$ 是多项式核的最高项次数； $C(C=[10^{-1},10^{-2},...,10^{-9}])$ 是多项式核和 Sigmoid 核函数的常数偏差项； $\gamma(\gamma=[1\times10^{-4},2\times10^{-4},...,9\times10^{-4}])$ 是除线性核函数外的其他所有核函数的系数； $\sigma(\sigma=[1\times10^{-4},2\times10^{-4},...,9\times10^{-4}])$ 是径向基核、指数核和拉普拉斯核函数的尺度参数。

如表 5.2 所示，CTrm 网络表示不使用 SVR，linear、poly、Sigmoid、RBF、Exp 和 Laplace 分别表示 CTrm-SVR 估产模型中 SVR 部分使用线性核、多项式核、Sigmoid 核、径向基核、指数核和拉普拉斯核。使用线性核函数的 CTrm-SVR 估产模型精度反而下降，是因为线性核函数很难从神经网络提取的高层次作物特征中捕捉复杂的非线性关系。使用拉普拉斯核函数的 CTrm-SVR 估产模型性能最优，年平均 RMSE 为 792 kg/hm²，相较于线性核、多项式核、Sigmoid 核、径向基核和指数核函数分别下降了 18%、3.53%、4.83%、2.22%、4.2%，年平均 MAE 为 532.6 kg/hm²，相较于其他核函数下降了 22.23%、3.75%、5.25%、2.62%、4.39%。除了线性核函数，其他所有核函数的 CTrm-SVR 估产模型性能相较于 CTrm 模型均有不同程度的提升，表明 SVR 的核函数能有效增强估产模型的泛化能力，提升预测精度。

表 5.2 SVR 核函数性能检测

年份	模型	RMSE (kg·hm ⁻²)	MAE (kg·hm ⁻²)	R ²	时间(s)
2018	CTrm	874	609	0.705	-
	linear	937	663	0.643	2
	Poly	825	562	0.740	5
	Sigmoid	831	566	0.735	9
	RBF	808	550	0.751	1275
	Exp	817	556	0.745	968
	Laplace	780	529	0.764	933
2017	CTrm	844	585	0.767	-
	linear	922	634	0.660	2
	Poly	830	575	0.775	5
	Sigmoid	837	582	0.770	9
	RBF	816	568	0.781	1280
	Exp	833	580	0.770	928
	Laplace	805	560	0.785	918
2016	CTrm	845	534	0.767	-
	linear	972	656	0.583	3
	Poly	805	521	0.788	4
	Sigmoid	823	534	0.781	7
	RBF	805	522	0.788	1262
	Exp	826	532	0.777	920
	Laplace	791	509	0.796	947

5.2.3 估产模型性能检测

为评估 CTrm-SVR 估产模型的性能, 将其与其他估产模型进行实验对比, 包括深度学习方法 (CNN、GRU、LSTM)、机器学习方法 (SVR、RF、DT) 以及 CNN 和 Transformer 编码器融合的 CTrm 估产模型, 其中 Transformer 编码器部分参数均为: $n=3$ 、 $d_{model}=256$ 和 $Dff=1024$, SVR 部分使用 Laplace 核函数。

本节使用不同的估产模型对中国冬小麦主产区进行产量预测, 以 2001—

2015 年数据作为训练集，2016—2018 年作为测试集，结果如表 5.3 所示：

1) CTrm-SVR 估产模型在预测精度上优于其他对比模型，年平均 RMSE 为 794.6 kg/hm^2 ，相较于 CTrm、CNN、GRU、LSTM、SVR、RF 和 DT 分别降低了 6.79%、23.08%、29.78%、30.50%、45.31%、56.31%、62.47%，年平均 MAE 为 534.6 kg/hm^2 ，相较于其他模型分别降低了 9.24%、27.12%、41.84%、37.35%、61.61%、80.75%、91.73%，表明 CTrm-SVR 估产模型能够捕捉影像中冬小麦的生长特征，并精准地预测大范围内的冬小麦产量。但 CTrm-SVR 估产模型的训练时间高于其他模型，其中机器学习算法（SVR、RF、DT）和 CNN 的训练时间短，但机器学习算法依赖于手工特征，其预测精度偏低，不适用于大尺度的作物产量预测；CNN 的性能和训练时间均优于循环神经网络（GRU、LSTM），并且循环神经网络的模型参数是 CNN 的 3 倍左右，表明 CNN 在影像特征提取方面优于循环神经网络，其参数共享机制能大大降低模型参数和计算的复杂度；CTrm-SVR 估产模型的性能最佳，但训练时间最长，而混合神经网络特征提取占据了训练时间的 95%左右。

2) CTrm 模型的性能仅次于 CTrm-SVR 估产模型，其年平均 RMSE 和 MAE 分别为 848.6 、 584 kg/hm^2 ， R^2 为 0.74，表明 SVR 泛化能力优于全连接层，并且在样本数据偏少的情况下仍能保持较高的性能，其核函数能高效的解决非线性特征，与农作物产量预测高度契合。然而单一的 SVR 模型性能表现不佳，其主要原因在于 SVR 难以从原始影像中直接挖掘作物特征，依赖于手工特征或神经网络的深层次特征。CTrm 模型优于其他对比模型，表明在作物估产中引入注意力机制能自适应的计算农作物不同生育期的权重比例，确定作物的最佳生育期，为产量预测提供了可靠依据，能有效解决大尺度范围内不同地区作物物候期差异的问题。

表 5.3 不同估产模型性能对比

年份	模型	RMSE (kg·hm ⁻²)	MAE (kg·hm ⁻²)	R ²	时间(s)
2018	CTrm-SVR	792	538	0.756	22007
	CTrm	860	591	0.715	21074
	CNN	979	677	0.632	8063
	GRU	1006	744	0.610	20841
	LSTM	1068	798	0.561	22590
	SVR	1159	854	0.481	8286
	RF	1293	1018	0.329	1596
	DT	1214	971	0.414	18
2017	CTrm-SVR	801	558	0.788	22225
	CTrm	835	594	0.764	21307
	CNN	954	671	0.701	6805
	GRU	1061	792	0.629	22768
	LSTM	1011	692	0.674	24148
	SVR	1119	833	0.587	10215
	RF	1227	949	0.503	1452
	DT	1295	1018	0.436	18
2016	CTrm-SVR	791	508	0.796	23330
	CTrm	843	567	0.766	22383
	CNN	1001	691	0.678	7158
	GRU	1027	739	0.611	25111
	LSTM	1032	713	0.657	26630
	SVR	1186	905	0.546	9846
	RF	1206	932	0.453	1346
	DT	1364	1087	0.369	14

5.2.4 冬小麦最佳生育期的空间分布

农作物的生育期受区域环境因素的影响较大，不同地区的作物物候期有明显差异，如四川地区的冬小麦在 4 月中旬到 5 月下旬左右收获，河南地区的冬小麦一般在 5 月底到 6 月中旬左右收获，并且部分地区是春冬麦混种，增加了大尺度范围内冬小麦产量预测的难度。如图 5.3 所示，

1) 新疆维吾尔自治区被天山山脉分割为南疆（天山南部）和北疆（天山北部）两大区域，而南北疆均为春冬麦混种区，其中南疆以冬小麦为主，北疆以春小麦为主^[99]。因此网络输出的最佳生育期与冬小麦实际生育期有部分差异，如阿勒泰地区的富蕴县、福海县和克拉玛依市的克拉玛依区在生育中期效果最佳，吐鲁番市的高昌区和和田地区的皮山县在生育前期效果最佳，其原因在于实际地区包含部分冬春麦混种区，而该区域的其他作物光谱反射会变成噪音影响估产网络的整体性能。

2) 受季风气候的影响，云南的小麦大多在五月中旬左右收获，而丽江市、大理白族自治州等地的小麦秋季播种，春季收获^[100]，如丽江市的玉龙纳西族自治县、古城区和大理白族自治州的鹤庆县、剑川县在生育期中期预测精度最高。

3) 以秦岭、淮河为界，中国冬小麦主产区可分为北方冬小麦区（河南、河北、山东、陕西、山西）和南方冬小麦区（安徽、湖北、浙江、江苏）。一般来说，北方冬小麦区的收获时间为 5 月底到 6 月中旬左右，冬小麦的实际生育期与数据集中比较吻合，在生育后期，估产模型的预测精度最高，如河南省安阳市的滑县和河北省保定市的安国市在生育后期效果最佳。南方冬小麦区的收获时间基本与北方冬小麦区的时间点相当，但部分地区受环境因素影响，收获时间提前，如江苏省盐城市的滨海县和浙江省台州市的临海县在生育中后期预测精度最高。




图 5.3 不同地区冬小麦物候差异

5.3 本章小结

针对大尺度范围内作物产量预测中不同地区作物物候差异问题，本节引入了自注意力机制和支持向量回归，构建了混合神经网络 CTrm-SVR 估产模型，对其整体架构做了详细阐述，并实验证明了其鲁棒性。实验表明，CTrm-SVR 估产模型相较于其他模型有较强的拟合能力，自注意力机制能有效的解决了农作物物候差异问题，并且支持向量回归能进一步提升估产模型的泛化能力，提高预测精度。结论如下：

1) 所提出的 CTrm-SVR 估产模型结构复杂，参数量大，实验分析了可调节超参数，包括位置编码的维度、前馈网络神经元的个数和编码器迭代次数，结果表明编码器迭代次数为 3 次，位置编码的维度和前馈网络神经元的个数分别为 256 和 1024，CTrm-SVR 估产模型性能最佳。

2) 将所提出的变异拉普拉斯核函数与其他核函数进行对比，包括线性核、多项式核、Sigmoid 核、径向基核和指数核函数，其中拉普拉斯核函数泛化能力最强，预测精度最高，相较于其他核函数提升了 3%—5%左右。

3) 将 CTrm-SVR 估产模型与其他模型进行性能检测，包括单一的深度学习

网络（CNN、GRU、LSTM）、机器学习模型（SVR、RF、DT）和不适用 SVR 的 CTrm 模型。CTrm-SVR 估产模型的预测精度均优于其他对比模型，表明该模型能有效捕捉不同地区的作物物候差异，并且 SVR 能融合预测单元的位置信息，进一步提高模型的预测精度。

4) 不同地区的农作物有明显的物候差异，将自注意力机制的权重进行空间可视化，详细分析了中国冬小麦主产区中不同区域的冬小麦最佳生育期。其中新疆维吾尔自治区为春冬麦混种区，最佳生育期的权重在生育期的前中后期均有分布；云南省受季风气候的影响，收获时间较早，最佳生育期主要分布于中后期。秦岭淮河南北部的冬小麦种植区的实际生育期与统计数据比较吻合，最佳生育期主要分布于生育后期。

6 结论与展望

6.1 结论

农业是一个国家生存和发展的基石，农作物的产量预测对粮食安全和农业可持续发展具有重要意义，是现代智慧农业不可或缺的一部分。作物的生长受温度、太阳辐射、水分和其他环境因素的影响，传统的回归预测方法有诸多的局限性，而遥感卫星能大面积地监测地表地物的时空变化，为大尺度区域的作物产量预测提供了数据支持。随着计算机的算力提升，深度学习在诸多领域表现出了强大的特征学习能力，为农业遥感的智能化和信息化提供了理论基础。因此，本文结合多了时相遥感影像与深度学习算法，提出了基于多时相遥感影像的 CNN-GRU 估产模型和基于多源数据融合的 CTrm-SVR 估产模型，实现了大尺度范围内对冬小麦产量的精准预测。本文的主要成果和结论如下：

（1）针对单一的神经网络模型不能有效的从多时相遥感影像中提取农作物的生长特征，本文构建了一个端到端的融合神经网络估产模型（CNN-GRU），利用 CNN 和 GRU 的优点，建立了遥感影像不同波段农作物反射率和作物不同生育期的植株形态变化与作物产量之间的内在联系，同时从多时相遥感影像中挖掘农作物的空间-光谱-时间联合特征，实现大尺度范围的冬小麦产量预测。结果表明，所提出的 CNN-GRU 估产模型整体性能优于单一的深度学习网络（CNN、GRU、LSTM）和传统的机器学习模型（SVR、RF、DT），并且该模型能直接从原始影像中挖掘深层次的作物生长特征，而不需要任何手工特征或数据降维处理。在冬小麦生育期的中后期，CNN-GRU 估产模型已经能准确地预测冬小麦产量，即该模型能提前 2 个月预测全国冬小麦主产区产量。

（2）对大尺度范围内农作物产量预测时，不同区域的农作物有明显的物候差异。为此，本文提出了一个混合神经网络（CTrm-SVR）估产模型，引入自注意力机制计算任意时间位置的相关性，以动态加权的方式确定作物产量预测的最佳生育期，弥补大尺度产量预测中的物候差异问题。邻近区域的作物生长环境有较强的时空性关系，使用预测单元的位置信息替代大量的环境因素，设计

了一个变异的 Laplace 核函数，使用强拟合能力的 SVR 融合神经网络提取的深层次特征和预测单元的位置信息，替代全连接层进行产量预测。根据估产模型中自注意力机制的权重进行空间可视化，结果表明，中国冬小麦主产区不同区域的冬小麦生育期有明显的不同，CTrm-SVR 估产模型能有效解决不同地区的作物物候差异问题，并且 SVR 能融合预测单元的位置信息，强化了不同区域作物产量的时空相关性，进一步提升了估产模型的泛化能力。

6.2 创新点

本文在现有研究的基础上，融合神经网络、自注意力机制和机器学习模型，对中国冬小麦主产区产量预测进行研究。本文的特色和主要创新点有以下两个方面：

(1) 为充分挖掘多时相遥感影像中作物的生长特征，本文提出了一个端到端的 CNN-GRU 估产模型，充分利用 CNN 和 GRU 模型的优点，解决了传统回归模型的时空尺度普适性差和单一神经网络特征提取不充分的问题，实现了快速、准确的对我国冬小麦主产区进行产量预测。

(2) 针对不同地区农作物物候差异问题，本文提出了基于多源数据融合的 CTrm-SVR 估产模型，并引入自注意力机制，以动态加权的方式确定作物产量月的最佳生育期，有效的解决了作物物候差异问题。然后利用 SVR 融合预测单元的位置信息，进一步增强作物特征的时空相关性，提升估产模型的泛化能力。

6.3 展望和不足

本文基于中国冬小麦主产区的多时相 MODIS 遥感影像和冬小麦产量数据，收集了 2001-2018 年的相关数据，分别提出了基于多时相遥感影像的 CNN-GRU 估产模型和基于多源数据融合的 CTrm-SVR 估产模型，充分利用遥感影像和深度学习技术，实现了对大尺度区域的冬小麦产量预测，为智慧农业的发展和应用提供了新思路。由于数据资源、实验环境等原因，仍存在部分问题需要进一步的研究和探讨，主要有以下几点：

1) 研究区。目前只统计了中国冬小麦主产区的相关数据，而冬小麦的种植

区广泛分布于亚洲、欧洲和美洲等世界各地，后续应统计其他国家乃至全球冬小麦的相关数据做进一步研究。

2) 作物种类。本文仅对冬小麦进行了相关研究，而对其他主要粮食作物的研究还有些许欠缺，如玉米、水稻等，后续应统计其他农作物的相关数据做进一步研究。

参考文献

- [1] 高铭悦. 基于神经网络的安徽省粮食产量组合预测研究[D]. 合肥: 安徽农业大学, 2016.
- [2] Saravi B, Nejadhashemi A P, Tang B. Quantitative model of irrigation effect on maize yield by deep neural network[J]. Neural Computing and Applications, 2020, 32(14): 10679-10692.
- [3] Huang J, Wang H, Dai Q, et al. Analysis of NDVI data for crop identification and yield estimation[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2014, 7(11): 4374-4384.
- [4] 赵文亮, 贺振, 贺俊平, 等. 基于 MODIS-NDVI 的河南省冬小麦产量遥感估测[J]. 地理研究, 2012, 31(12): 2310-2320.
- [5] 李军玲, 郭其乐, 彭记永. 基于 MODIS 数据的河南省冬小麦产量遥感估算模型[J]. 生态环境学报, 2012, 21(10): 1665-1669.
- [6] 刘红超, 梁燕, 张喜旺. 多时相影像的冬小麦种植面积提取及估产[J]. 遥感信息, 2017, 32(05): 87-92.
- [7] 林滢, 邵怀勇. 基于随机森林算法的河南省冬小麦产量预测最佳时间窗和影响因子研究[J]. 麦类作物学报, 2020, 40(07): 874-880.
- [8] 周亮, 慕号伟, 马海蛟, 等. 基于卷积神经网络的中国北方冬小麦遥感估产[J]. 农业工程学报, 2019, 35(15): 119-128.
- [9] 徐里萍. 计算机图像处理技术及其发展趋势分析[J]. 无线互联科技, 2020, 17(01): 162-163.
- [10] Wang X, Huang J, Feng Q, et al. Winter wheat yield prediction at county level and uncertainty analysis in main wheat-producing regions of China with deep learning approaches[J]. Remote Sensing, 2020, 12(11): 1744.
- [11] 薛利红, 曹卫星, 罗卫红. 基于冠层反射光谱的水稻产量预测模型[J]. 遥感学报, 2005, 2005(01): 100-105.
- [12] 孙俊英, 黄进良, 李晓冬, 等. 基于农业气象模型的农作物单产估算——以湖北省中稻为例[J]. 安徽农业科学, 2009, 37(17): 8103-8105.
- [13] 王人潮, 王珂, 沈掌泉, 等. 水稻单产遥感估测建模研究[J]. 遥感学报, 1998, 1998(02): 119-124.
- [14] 陈锡康. 投入占用产出技术与全国粮食、棉花产量预测研究[J]. 科学决策, 1995, 1995(03): 29-32.
- [15] 马波, 田军仓. 作物生长模拟模型研究综述[J]. 节水灌溉, 2010, 2010(02): 1-5.
- [16] 宋艳玲, 董文杰. 1961-2000 年干旱对我国冬小麦产量的影响[J]. 自然灾害学报, 2006, 2006(S1): 235-240.

- [17] 辛景峰, 宇振荣, P.M.Driessen. 利用 NOAA NDVI 数据集监测冬小麦生育期的研究[J]. 遥感学报, 2001, 2001(06): 442-447.
- [18] 王纯枝, 宇振荣, 辛景峰, 等. 基于遥感和作物生长模型的作物产量差估测[J]. 农业工程学报, 2005, 2005(07): 84-89.
- [19] 何英彬, 陈佑启, 唐华俊. 基于 MODIS 反演逐日 LAI 及 SIMRIW 模型的冷害对水稻单产的影响研究[J]. 农业工程学报, 2007(11): 188-194.
- [20] 黄敬峰, 杨忠恩, 王人潮, 等. 基于 GIS 的水稻遥感估产模型研究[J]. 遥感技术与应用, 2002, 2002(03): 125-128.
- [21] Rhee J, Im J. Meteorological drought forecasting for ungauged areas based on machine learning: Using long-range climate forecast and remote sensing data[J]. Agricultural and Forest Meteorology, 2017, 237: 105-122.
- [22] Cai Y, Guan K, Lobell D, et al. Integrating satellite and climate data to predict wheat yield in Australia using machine learning approaches[J]. Agricultural and forest meteorology, 2019, 274: 144-159.
- [23] 南小琴, 张泽, 印彩霞, 等. 基于决策树算法的棉花产量预测研究[J]. 农村科技, 2019, 2019(01): 29-35.
- [24] Appelhans T, Mwangomo E, Hardy D R, et al. Evaluating machine learning approaches for the interpolation of monthly air temperature at Mt. Kilimanjaro, Tanzania[J]. Spatial Statistics, 2015, 14: 91-113.
- [25] Chlingaryan A, Sukkarieh S, Whelan B. Machine learning approaches for crop yield prediction and nitrogen status estimation in precision agriculture: A review[J]. Computers and electronics in agriculture, 2018, 151: 61-69.
- [26] Van Klompenburg T, Kassahun A, Catal C. Crop yield prediction using machine learning: A systematic literature review[J]. Computers and Electronics in Agriculture, 2020, 177: 105709.
- [27] Liakos K G, Busato P, Moshou D, et al. Machine learning in agriculture: A review[J]. Sensors, 2018, 18(8): 2674.
- [28] Li D, Yang F, Wang X. Study on ensemble crop information extraction of remote sensing images based on SVM and BPNN[J]. Journal of the Indian Society of Remote Sensing, 2017, 45(2): 229-237.
- [29] Kouadio L, Newlands N K, Davidson A, et al. Assessing the performance of MODIS NDVI and EVI for seasonal crop yield forecasting at the ecodistrict scale[J]. Remote Sensing, 2014, 6(10): 10193-10214.
- [30] 尚雪, 何钊全, 张铜会. 增强型植被指数时空变化特征及其驱动机理[J]. 森林与环境学报, 2020, 40(05): 478-485.

- [31] 朱相兵, 杜健民, 刘浩. 基于土壤调整植被指数对荒漠草原地表高光谱影像中植被识别[J]. 农家参谋, 2020, 2020(07): 123.
- [32] Wang Y, Zhang Z, Feng L, et al. Combining multi-source data and machine learning approaches to predict winter wheat yield in the conterminous United States[J]. Remote Sensing, 2020, 12(8): 1232.
- [33] Han J, Zhang Z, Cao J, et al. Prediction of winter wheat yield based on multi-source data and machine learning in China[J]. Remote Sensing, 2020, 12(2): 236.
- [34] Kim N, Ha K J, Park N W, et al. A comparison between major artificial intelligence models for crop yield prediction: Case study of the midwestern United States, 2006–2015[J]. ISPRS International Journal of Geo-Information, 2019, 8(5): 240.
- [35] Kang Y, Ozdogan M, Zhu X, et al. Comparative assessment of environmental variables and machine learning algorithms for maize yield prediction in the US Midwest[J]. Environmental Research Letters, 2020, 15(6): 064005.
- [36] Yang Q, Shi L, Han J, et al. Deep convolutional neural networks for rice grain yield estimation at the ripening stage using UAV-based remotely sensed images[J]. Field Crops Research, 2019, 235: 142-153.
- [37] Nevavuori P, Narra N, Lipping T. Crop yield prediction with deep convolutional neural networks[J]. Computers and electronics in agriculture, 2019, 163: 104859.
- [38] Nevavuori P, Narra N, Linna P, et al. Crop yield prediction using multitemporal UAV data and spatio-temporal deep learning models[J]. Remote Sensing, 2020, 12(23): 4000.
- [39] You J, Li X, Low M, et al. Deep gaussian process for crop yield prediction based on remote sensing data[C]. In Thirty-First AAAI conference on artificial intelligence. 2017. 4559-4565.
- [40] Sabini M, Rusak G, Ross B. Understanding satellite-imagery-based crop yield predictions[J]. Stanford, 2017.
- [41] Jiang Z, Liu C, Hendricks N P, et al. Predicting county level corn yields using deep long short term memory models[J]. arXiv preprint arXiv:1805.12044, 2018.
- [42] Crisóstomo de Castro Filho H, Abílio de Carvalho Júnior O, Ferreira de Carvalho O L, et al. Rice crop detection using LSTM, Bi-LSTM, and machine learning models from Sentinel-1 time series[J]. Remote Sensing, 2020, 12(16): 2655.
- [43] Alhnaity B, Pearson S, Leontidis G, et al. Using deep learning to predict plant growth and yield in greenhouse environments[C]. In International Symposium on Advanced Technologies and Management for Innovative Greenhouses: GreenSys2019 1296. 2019. 425-432.
- [44] Alibabaei K, Gaspar P D, Lima T M. Crop yield estimation using deep learning based on climate big data and irrigation scheduling[J]. Energies, 2021, 14(11): 3004.

- [45] Wajda A H. Deep Learning for Electroencephalography and Near-Infrared Spectroscopy Data[D]. Philadelphia: Widener University, 2020.
- [46] 张驰, 郭媛, 黎明. 人工神经网络模型发展及应用综述[J]. 计算机工程与应用, 2021, 57(11): 57-69.
- [47] 夏瑜潞. 人工神经网络的发展综述[J]. 电脑知识与技术, 2019, 15(20): 227-229.
- [48] Liu Y, Piramanayagam S, Monteiro S T, et al. Semantic segmentation of multisensor remote sensing imagery with deep ConvNets and higher-order conditional random fields[J]. Journal of Applied Remote Sensing, 2019, 13(1): 016501.
- [49] Zhao L, Zhang W, Tang P. Analysis of the inter-dataset representation ability of deep features for high spatial resolution remote sensing image scene classification[J]. Multimedia Tools and Applications, 2019, 78(8): 9667-9689.
- [50] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks[J]. science, 2006, 313(5786): 504-507.
- [51] Nogueira K, Penatti O A B, Dos Santos J A. Towards better exploiting convolutional neural networks for remote sensing scene classification[J]. Pattern Recognition, 2017, 61: 539-556.
- [52] Alshehhi R, Marpu P R, Woon W L, et al. Simultaneous extraction of roads and buildings in remote sensing imagery with convolutional neural networks[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2017, 130: 139-149.
- [53] Li Y, Xu L, Rao J, et al. A Y-Net deep learning method for road segmentation using high-resolution visible remote sensing images[J]. Remote sensing letters, 2019, 10(4): 381-390.
- [54] Ciresan D C, Meier U, Masci J, et al. Flexible, high performance convolutional neural networks for image classification[C]. In Twenty-second international joint conference on artificial intelligence. 2011. 1237-1242.
- [55] Le Q V, Jaitly N, Hinton G E. A simple way to initialize recurrent networks of rectified linear units[J]. arXiv preprint arXiv:1504.00941, 2015.
- [56] Sermanet P, Eigen D, Zhang X, et al. Overfeat: Integrated recognition, localization and detection using convolutional networks[J]. arXiv preprint arXiv:1312.6229, 2013.
- [57] Taylor G W, Fergus R, LeCun Y, et al. Convolutional learning of spatio-temporal features[C]. In European conference on computer vision. Springer, Berlin, Heidelberg, 2010. 140-153.
- [58] Lipton Z C, Berkowitz J, Elkan C. A critical review of recurrent neural networks for sequence learning[J]. arXiv preprint arXiv:1506.00019, 2015.
- [59] Wang Y, Long M, Wang J, et al. Predrnn: Recurrent neural networks for predictive learning using spatiotemporal lstms[J]. Advances in neural information processing systems, 2017, 30.
- [60] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.

- [61] Kumar S, Hussain L, Banarjee S, et al. Energy load forecasting using deep learning approach-LSTM and GRU in spark cluster[C]. In 2018 fifth international conference on emerging applications of information technology (EAIT). IEEE, 2018. 1-4.
- [62] Shewalkar A N. Comparison of rnn, lstm and gru on speech recognition data[J]. 2018.
- [63] Chung J, Gulcehre C, Cho K H, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. arXiv preprint arXiv:1412.3555, 2014.
- [64] Mnih V, Heess N, Graves A. Recurrent models of visual attention[J]. Advances in neural information processing systems, 2014, 27.
- [65] Tan M, Santos C, Xiang B, et al. Lstm-based deep learning models for non-factoid answer selection[J]. arXiv preprint arXiv:1511.04108, 2015.
- [66] Yang Z, Yang D, Dyer C, et al. Hierarchical attention networks for document classification[C]. In Proceedings of the 2016 conference of the North American chapter of the association for computational linguistics: human language technologies. 2016. 1480-1489.
- [67] Luong M T, Pham H, Manning C D. Effective approaches to attention-based neural machine translation[J]. arXiv preprint arXiv:1508.04025, 2015.
- [68] Zhang Y, Zheng J, Jiang Y, et al. A text sentiment classification modeling method based on coordinated CNN-LSTM-attention model[J]. Chinese Journal of Electronics, 2019, 28(1): 120-126.
- [69] Miech A, Laptev I, Sivic J. Learnable pooling with context gating for video classification[J]. arXiv preprint arXiv:1706.06905, 2017.
- [70] Alwis S D, Zhang Y, Na M, et al. Duo attention with deep learning on tomato yield prediction and factor interpretation[C]. In Pacific Rim International Conference on Artificial Intelligence. Springer, Cham, 2019. 704-715.
- [71] Cortes C, Vapnik V. Support-vector networks[J]. Machine learning, 1995, 20(3): 273-297.
- [72] Vapnik V N. An overview of statistical learning theory[J]. IEEE transactions on neural networks, 1999, 10(5): 988-999.
- [73] 中国科学院“十三五”信息化专项 科学大数据工程[J]. 中国科学院院刊, 2018, 33(08): 893.
- [74] 彭丽. 基于 MODIS 和气象数据的陕西省小麦与玉米产量估算模型研究[D]. 杭州: 浙江大学, 2014.
- [75] 向金鑫. 基于卫星遥感图像的谷物产量预测研究[D]. 西安: 西安电子科技大学, 2020.
- [76] Huang H, Chen Y, Clinton N, et al. Mapping major land cover dynamics in Beijing using all Landsat images in Google Earth Engine[J]. Remote Sensing of Environment, 2017, 202: 166-176.

- [77] Kumar L, Mutanga O. Google Earth Engine applications since inception: Usage, trends, and potential[J]. Remote Sensing, 2018, 10(10): 1509.
- [78] Hansen M C, Potapov P V, Moore R, et al. High-resolution global maps of 21st-century forest cover change[J]. science, 2013, 342(6160): 850-853.
- [79] Gao F, Anderson M. Evaluating yield variability of corn and soybean using Landsat-8, Sentinel-2 and Modis in Google Earth Engine[C]. In IGARSS 2019-2019 IEEE International Geoscience and Remote Sensing Symposium. IEEE, 2019. 7286-7289.
- [80] Zhang W, Brandt M, Prishchepov A V, et al. Mapping the Dynamics of Winter Wheat in the North China Plain from Dense Landsat Time Series (1999 to 2019)[J]. Remote Sensing, 2021, 13(6): 1170.
- [81] Vermote E. MOD09A1 MODIS/terra surface reflectance 8-day L3 global 500m SIN grid V006[J]. NASA EOSDIS Land Processes DAAC, 2015, 10.
- [82] Tang H, Yu K, Hagolle O, et al. A cloud detection method based on a time series of MODIS surface reflectance images[J]. International Journal of Digital Earth, 2013, 6(sup1): 157-171.
- [83] Idso S B, Jackson R D, Reginato R J. Remote-Sensing of Crop Yields: Canopy temperature and albedo measurements have been quantitatively correlated with final harvests of wheat[J]. Science, 1977, 196(4285): 19-25.
- [84] Sulla-Menashe D, Gray J M, Abercrombie S P, et al. Hierarchical mapping of annual global land cover 2001 to present: The MODIS Collection 6 Land Cover product[J]. Remote Sensing of Environment, 2019, 222: 183-194.
- [85] 赵新飞,冯嘉敏,张大伟,等. 不同生育期水稻光谱反射率的变化规律[J].仲恺农业工程学院学报, 2015, 28(04): 26-31.
- [86] He J, Li D, Yang B, et al. Multi view facial action unit detection based on CNN and BLSTM-RNN[C]. In 2017 12th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2017). IEEE, 2017. 848-853.
- [87] Bhimra M A, Nazir U, Taj M. Using 3d residual network for spatio-temporal analysis of remote sensing data[C]. In ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019. 1403-1407.
- [88] Jin X B, Yang N X, Wang X Y, et al. Hybrid deep learning predictor for smart agriculture sensing based on empirical mode decomposition and gated recurrent unit group model[J]. Sensors, 2020, 20(5): 1334.
- [89] 林靖皓, 秦亮曦, 苏永秀, 等. 基于自注意力机制的双向门控循环单元和卷积神经网络的芒果产量预测[J]. 计算机应用, 2020, 40(S1): 51-55.
- [90] Lee K, Kim J K, Kim J, et al. CNN and GRU combination scheme for bearing anomaly detection in rotating machinery health monitoring[C]. In 2018 1st IEEE International conference on knowledge innovation and invention (ICKII). IEEE, 2018. 102-105.

- [91] Dennison P E, Roberts D A. Endmember selection for multiple endmember spectral mixture analysis using endmember average RMSE[J]. Remote sensing of environment, 2003, 87(2-3): 123-135.
- [92] Chai T, Draxler R R. Root mean square error (RMSE) or mean absolute error (MAE)?—Arguments against avoiding RMSE in the literature[J]. Geoscientific model development, 2014, 7(3): 1247-1250.
- [93] Willmott C J, Matsuura K. Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance[J]. Climate research, 2005, 30(1): 79-82.
- [94] 王利民, 刘佳, 杨玲波, 等. 短波红外波段对玉米大豆种植面积识别精度的影响[J]. 农业工程学报, 2016, 32(19): 169-178.
- [95] 刘佳, 王利民, 杨福刚, 等. 红边与短波红外谱段的玉米大豆识别能力研究[J]. 中国农学通报, 2018, 34(35): 120-129.
- [96] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [97] Khaki S, Wang L. Crop yield prediction using deep neural networks[J]. Frontiers in plant science, 2019, 10: 621.
- [98] Drucker H, Burges C J, Kaufman L, et al. Support vector regression machines[J]. Advances in neural information processing systems, 1996, 9.
- [99] 轩俊伟, 郑江华, 刘志辉. 近 50 年新疆小麦需水量时空特征及气候影响因素分析[J]. 水土保持研究, 2015, 22(4): 155-160.
- [100] 鲁永新, 邹萍, 张中平, 等. 云南小麦种植气候生态类型区划[J]. 贵州农业科学, 2012, 40(12): 191-194.