

基于逐步回归和 ARIMA 模型的青海省农作物产量预测分析

黄 倩

(青海大学财经学院, 青海 西宁 810016)

摘 要:【目的】准确预测青海省的农作物产量。【方法】选取青海省 2002—2021 年农作物产量数据, 将农业机械总动力、农作物播种面积、有效灌溉面积、农用薄膜使用量、农药使用量作为青海省农作物产量预测的自变量, 农作物产量作为因变量建立逐步回归和 ARIMA 模型, 分别运用逐步回归模型、ARIMA 模型以及组合模型对青海省 2016—2021 年农作物产量数据预测精度进行了检验和对比, 并采用组合模型预测了青海省 2022—2026 年农作物产量。【结果】1) 逐步回归模型通过逐步引入对产量有显著影响的变量, 优化了模型结构, 预测平均误差为 1.17%; 2) ARIMA 模型则有效捕捉了时间序列数据的动态特性, 预测平均误差为 1.29%; 3) 组合预测模型的预测精度较高, 平均相对误差降至 1.00%, 优于单一模型。【结论】农作物产量的准确预测对于保障粮食安全和推动地区经济发展具有重要意义。未来的研究可以通过优化各模型的权重分配、利用机器学习方法自动调整权重等方式处理更大规模的数据集, 并考虑如气候变化、政策变动等更多的影响因素, 这将有助于构建更为全面和精细的预测模型, 为农业生产和政策制定提供更加有力的数据支持。

关键词: 农作物产量; 逐步回归模型; ARIMA 模型; 组合预测模型

中图分类号: F326.11; TP18

文献标志码: A

DOI: 10.3969/j.issn.1672-3872.2025.04.046

0 引言

中国作为农业大国, 粮食对国家稳定和人民幸福至关重要, 同时粮食也是农民经济的重要来源, 确保粮食的稳定供给对于国家经济的持续健康发展至关重要。青海是我国西北地区重要农作物生产基地, 青海省致力于构建“三区一带”的农牧业发展新模式, 通过优化地理布局、提升基础设施、调整产业架构、普及优质种子和先进农艺、发展特色产业, 提升了农牧区域的生产效能。对青海省农作物产量进行预测, 有利于详细了解其产量的变化趋势, 可为青海省农业发展提供更明确的方向。

目前, 关于农作物产量预测的文献从预测模型上看, 一类是单模型预测, 另一类是多模型组合预测; 从预测方法上看, 大致可分为基于机器学习和基于统计学的产量预测; 从影响因素上来看, 一部分是来自气候因素, 另一部分是来自生物特征。徐宁等^[1](2024)利用全球气候和土壤数据, 通过机器学习模型预测了埃塞俄比亚未来 30 年 5 种主要粮食作物的产量变化。吴彬溶等^[2](2024)开发了一种基于自适应差分进化算法和注意力机制的循环神经网络模型, 识别了影响中国粮食产量的关键变量。孙少杰等^[3](2022)提出了一种结合卷积和反向传播神经网络的冬小麦产量预测方法, 并验证了模型精度。田东霞等^[4](2022)使用逐步回归法预测苹果产量, 平

均相对误差为 11.6%。王鹏飞等^[5](2023)通过多元线性回归模型预测鸭梨花盛花期, 结果准确。王辉^[6](2023)和阳红燕等^[7](2022)应用 ARIMA 模型预测苧麻纤维和贵州茶叶产量, 均达到 95% 以上的预测精度。吴越等^[8](2020)选取长三角地区为研究对象, 分别使用 Holt 两参数指数平滑法和 ARIMA 模型预测 2019—2023 年长三角地区的粮食产量, 并对模型进行检验, 检验结果均通过, 表明长三角地区的粮食产量将保持稳定增长的趋势, 预测效果理想。这些研究展示了不同模型在提高作物产量预测准确性方面的潜力, 因此本文选择组合预测模型对青海省农作物产量进行预测分析。

1 指标选取与研究方法

1.1 指标选取

在农作物产量预测中, 为提高预测的准确性, 需要对影响因素进行筛选, 剔除与农作物产量相关性较小的因素, 本文采用灰色关联度法来进行自变量的筛选。以青海省农作物产量作为参考序列, 以农作物播种面积、有效灌溉面积等相关影响因素作为比较序列, 采用初值法对数据进行无量纲化处理, 再依次计算差序列、极差、灰色关联度系数和灰色关联度。依据灰色关联度可得相关影响因素对农作物产量的影响强弱, 剔除掉对农作物产量影响程度较小的影响因

作者简介: 黄倩(1999—), 女, 土家族, 湖北恩施人, 硕士研究生, 研究方向为战略管理。

素,本文最终选取农业机械总动力、农作物播种面积、有效灌溉面积、农用薄膜使用量、农药使用量作为青海省农作物产量预测的自变量,农作物产量作为因变量,分别设定为 X_1 、 X_2 、 X_3 、 X_4 、 X_5 、 Y 。研究数据来自《中国统计年鉴》和《青海统计年鉴》。

1.2 研究方法

逐步回归模型^[9]和ARIMA模型^[10]是做预测中常用的模型,逐步回归模型具有较好的灵活性,研究者可以根据模型的统计检验结果(如 P 值、AIC、BIC等)来决定何时停止添加或删除变量,且逐步回归模型对于不同的数据集和预测问题也有较强的适应性。相对于其他复杂的时间序列模型,ARIMA模型建立和参数估计过程相对简单,容易理解和实现,而且还可以与其他模型相结合,如与GARCH模型^[11]结合用于波动性预测,或与机器学习模型结合进行混合建模。ARIMA模型还能够较好地捕捉并预测时间序列的长期趋势,适用于长期预测问题,且逐步回归模型和ARIMA模型在预测的精度上都具有良好的表现。因此,本文选择了这两种模型,对青海省2002—2021年农作物产量数据进行预测,再用2016—2021年实际产量数据进行模型检验和对比,通过数据结果对模型进行评价,并预测了青海省2022—2026年农作物产量。

2 基于逐步回归模型的青海省农作物产量预测

2.1 逐步回归模型

多元线性逐步回归分析首先将所有候选自变量纳入模型,然后根据各自变量对因变量的影响力度,通过显著性检验逐步排除那些影响不显著的自变量。这个过程旨在识别并保留那些对预测因变量的影响最为关键的自变量,从而构建一个统计上有意义的回归模型,准确捕捉多个自变量与因变量之间的相互关系。

2.2 模型检验

对逐步回归模型进行检验,从 F 检验的结果分析可以得到,显著性 P 值为0.000***,水平呈现显著性,拒绝回归系数为0的原假设;对于变量共线性表现,VIF全部小于10,因此模型没有多重共线性问题,模型构建良好。模型的公式如下:

$$Y=36.94+0.06*X_1+0.141*X_2 \quad (1)$$

基于逐步回归模型的青海省2016—2021年农作物产量预测精度结果如表1所示,利用2016—2021

年数据进行检验:逐步回归预测模型计算得出的绝对误差分别是0.04万t、2.61万t、2.71万t、0.74万t、0.64万t、0.55万t;相对误差分别是0.04%、2.55%、2.63%、0.70%、0.60%、0.50%,6年的平均相对误差为1.17%,说明模型的拟合效果较好。

表1 基于逐步回归模型的青海省2016—2021年农作物产量预测精度结果 单位:万t

年份	实际产量	预测产量	绝对误差	相对误差	平均相对误差
2016	104.78	104.74	0.04	0.04%	1.17%
2017	102.55	105.16	2.61	2.55%	
2018	103.06	105.77	2.71	2.63%	
2019	105.54	106.28	0.74	0.70%	
2020	107.42	108.06	0.64	0.60%	
2021	109.09	109.64	0.55	0.50%	

3 基于ARIMA模型的青海省农作物产量预测

3.1 ARIMA模型

ARIMA模型,即自回归滑动平均模型,属于时间序列分析中的一种,20世纪70年代,由美国统计学家金肯(Jenkins)和波克斯(Box)提出。ARIMA模型的表达式为 $ARIMA(p,d,q)$,其中,AR为自回归, p 为自回归项数;MA为滑动平均, q 为滑动平均项数, d 为使之成为平稳序列所做的差分次数(阶数),模型结构如下:

$$(1-\sum_{i=1}^p \phi_i L^i)(1-L)^d X_t = (1+\sum_{i=1}^q \theta_i L^i) \epsilon_t, d \in Z, d > 0 \quad (2)$$

3.2 平稳性检验

ARIMA模型属于时间序列分析模型,要求数据是平稳的,不平稳的时间序列可能会产生误导性的统计关系,平稳的时间序列更容易进行预测。平稳性检验有助于识别时间序列中的趋势、季节性等非平稳成分,从而更好地理解数据的特性。常用的平稳性检验方法包括ADF检验、KPS检验等,本文采用了ADF检验,结果如表2所示。

表2 ADF检验结果

变量	差分阶数	t	P	AIC	临界值		
					1%	5%	10%
农作物产量/万t	0	0.195	0.972	26.285	-4.223	-3.189	-2.73
	1	-4.719	0.000***	24.696	-4.223	-3.189	-2.73
	2	-0.968	0.765	31.63	-4.332	-3.233	-2.749

注:***、**、*分别代表1%、5%、10%的显著性水平。

该序列的检验结果显示:原数据的显著性 P 值为0.972,水平上不呈现显著性,不能拒绝原假设,该序列为不平稳的时间序列;在差分为1阶时,显著性 P 值为0.000***,水平上呈现显著性,拒绝原假设,该序列为平稳的时间序列;在差分为2阶时,显著性 P 值

为0.765,水平上不呈现显著性,不能拒绝原假设,该序列为不平稳的时间序列。因此,为保证序列的平稳性,本文对原始数据进行一阶差分处理。

3.3 模型系数选取

ARIMA(p,d,q)中,一般通过判断序列的自相关系数(ACF)和偏自相关系数(PACF)的拖尾或结尾情况确定 p 、 q 值。由表2可以看出原序列为不平稳序列,对序列进行一阶差分处理后为平稳序列,因此ARIMA(p,d,q)预测模型中的 d 值取1,即确定为ARIMA($p,1,q$)。

3.4 模型检验

ARIMA模型的前提是残差应呈现无自相关的特性,即残差应表现为随机白噪声。通过检视模型的检验表格,可以依据 Q 统计量的 P 值来判断残差是否为白噪声(若 P 值超过0.1,则认为残差是白噪声)。结果显示: Q 统计量的 P 值均大于0.1,接受原假设,即模型残差为白噪声;AIC和BIC值用于多次分析模型对比,且越低越好,而该模型的AIC值和BIC值都较低; R^2 代表时间序列的拟合程度,越接近1效果越好,该模型的拟合优度为0.855,拟合程度较好。通过以上分析,确定可用ARIMA(0,1,0)进行青海省农作物产量预测。

基于ARIMA模型的青海省2016—2021年农作物产量预测精度结果如表3所示,将2016—2021年的预测产量与实际产量进行对比,2016—2021年的绝对误差分别是0.38万t、3.28万t、0.71万t、1.72万t、1.19万t、0.84万t,相对误差分别是0.36%、3.20%、0.69%、1.63%、1.11%、0.77%;绝对误差除了2017年、2019年和2020年较高外,其他年份的绝对误差都没有超过1万t;而相对误差最大是3.20%,最小是0.36%,平均相对误差为1.29%,说明ARIMA(0,1,0)的预测效果较好。

表3 基于ARIMA模型的青海省2016—2021年农作物产量预测精度结果 单位:万t

年份	实际产量	预测产量	绝对误差	相对误差	平均相对误差
2016	104.78	105.16	0.38	0.36%	1.29%
2017	102.55	105.83	3.28	3.20%	
2018	103.06	103.77	0.71	0.69%	
2019	105.54	103.82	1.72	1.63%	
2020	107.42	106.23	1.19	1.11%	
2021	109.09	108.25	0.84	0.77%	

4 组合预测模型

4.1 模型检验

组合预测模型通过整合多个独立预测模型的预测结果,并为每个模型分配相应的权重,以增强整体模型的预测准确性。加权方法包括算术平均、最优权重分配以及方差倒数法等。方差倒数法由Bates和Granger提出,它基于各模型误差平方和最小化的原则来确定各模型的权重,为组合预测模型的研究提供了一种有效的权数确定方法。其计算公式如下:

$$X = \sum_{j=1}^m w_j \hat{x}_j \quad (3)$$

本文采用了逐步回归和ARIMA两种模型,通过构建它们的线性组合来进行预测,并使用方差倒数法来确定各模型在组合中的权重,以实现预测模型的优化。本文基于逐步回归模型和ARIMA模型,构建线性组合预测模型进行组合优化,权数结果如表4所示,基于组合预测模型的青海省2016—2021年农作物产量预测精度结果如表5所示。

表4 组合权数

方法	权数
逐步回归	0.40
ARIMA	0.60

表5 基于组合预测模型的青海省2016—2021年农作物产量预测精度结果 单位:万t

年份	实际值	组合预测值	绝对误差	相对误差	平均相对误差
2016	104.78	104.99	0.21	0.20%	1.00%
2017	102.55	105.56	3.01	2.94%	
2018	103.06	104.57	1.51	1.47%	
2019	105.54	104.80	0.74	0.70%	
2020	107.42	106.96	0.46	0.43%	
2021	109.09	108.81	0.28	0.26%	

由表4和表5可知,组合预测模型中ARIMA模型所占比重相对较大,结合相关文献也可以发现ARIMA模型是在各种预测中运用较多的模型。从预测结果来看,组合预测模型的绝对误差最大为3.01万t,最小为0.21万t,相对误差最大为2.94%,最小为0.20%,相较于单个的逐步回归模型和ARIMA模型,二者的组合预测模型的平均相对误差最小,为1.00%;说明该组合预测模型的精度较高,预测准确度较好,抵抗外部因素干扰的能力优于单一预测模型。

4.2 预测

采用逐步回归模型与ARIMA模型组合预测青海省2022—2026年的农作物产量,如表6和图1所示。由表6和图1可知,青海省2022—2026年农作物产量

呈稳步增长趋势。

表6 青海省2022—2026年农作物产量预测结果 单位: 万t

年份	2022	2023	2024	2025	2026
组合预测值	110.35	111.28	112.19	112.94	113.86




图1 青海省2022—2026年农作物产量预测趋势

5 结论

在预测领域,单项预测模型虽然在特定情况下能够提供有价值的洞察,但它们往往受限于自身的假设和条件,可能无法全面捕捉数据的复杂性和动态性。这种局限性在处理时间序列数据时尤为明显,因为时间序列包含了丰富的历史信息 and 潜在的趋势、季节性等特征。而通过一定的方式对单项预测模型进行组合,得到的组合预测模型往往能提高预测精度。

因此,本文设计了一种由逐步回归模型和ARIMA模型相结合的组合预测模型,选取了青海省2002—2021年的农作物产量数据,对所设计的组合预测模型进行了实证分析。通过与单一模型的预测结果进行比较,发现组合模型在预测精度上具有显著优势,平均相对误差为1.00%,低于单一模型的误差水平。这一结果验证了组合模型在时间序列预测方面的有效性,本文只设计了一种由两个单项预测模型结合的组合预测模型,若在此基础上引入新的预测模型进一步组合,可能会得到更精确的预测结果,通过优化各模型的权重分配,甚至利用机器学习方法自动

调整权重,可能会进一步提升预测的精度。随着计算能力的提高和大数据技术的发展,未来的研究可以处理更大规模的数据集,并考虑更多的影响因素,如气候变化、政策变动等。这将有助于构建更为全面和精细的预测模型,为农业生产和政策制定提供更加有力的数据支持。

参考文献:

- [1] 徐宁,李发东,张秋英,等.基于机器学习和未来气候变化模式的埃塞俄比亚粮食产量预测[J].中国生态农业学报(中英文),2024,32(3):490-506.
- [2] 吴彬溶,王林.基于注意力机制的ADE-Bi-IndRNN模型的中国粮食产量预测[J].运筹与管理,2024,33(1):102-107.
- [3] 孙少杰,吴门新,庄立伟,等.基于CNN卷积神经网络和BP神经网络的冬小麦县级产量预测[J].农业工程学报,2022,38(11):151-160.
- [4] 田东霞,曹久才.基于逐步回归法和BP神经网络模型的苹果产量预测[J].现代农业科技,2022(14):131-133+142.
- [5] 王鹏飞,李涛,于春亮,等.基于多元线性逐步回归和BP神经网络建立鸭梨盛花期预测模型[J].山东农业科学,2023,55(7):159-166.
- [6] 王辉.基于ARIMA模型的苎麻纤维产量预测研究[J].江苏经贸职业技术学院学报,2023(5):8-10.
- [7] 阳红燕,蔡承智,耿芳艳.基于ARIMA模型的贵州茶叶产量预测分析[J].耕作与栽培,2022,42(6):85-87.
- [8] 吴越,张焕明.基于Holt两参数指数平滑法和ARIMA模型的长三角粮食产量的预测[J].武汉轻工大学学报,2020,39(1):30-36.
- [9] 俞海军,李刚,马扩彦,等.逐步回归法优化填料改性与助剂提高烟草薄片浆料留着率的研究[J].中国造纸,2024,43(5):143-150+164.
- [10] 王夏鑫,周健.基于VAR-MGM-BP组合模型的中国粮食产量短期预测[J].兰州文理学院学报(自然科学版),2024,38(3):30-38.
- [11] 杨炜明,刘涛,王琴.基于新权重函数的MIX-GARCH-L模型及其应用[J].统计与决策,2024,40(8):22-27.

(上接第165页)

- [5] 李旭荣,胡月来,李明震《Pro/E设计与实验》课程思政的设计与实践[J].教育现代化,2019,6(79):188-190.
- [6] 胡见前.职业教育思想下高职学生工匠精神培育研究[J].黑龙江教师发展学院学报,2024,43(7):89-92.
- [7] 郑瑶,李士军.新工科专业多元融合教育教学理念的研究与实践[J].梧州学院学报,2024,34(1):76-82.
- [8] 席丙洋.应用型产品设计课程思政中工匠意识的目标探究[J].教育现代化,2019,6(103):290-292.
- [9] 杨诗瑶,肖芬.“大思政”背景下高校实践育人共同体构建的意义、挑战与策略探析[J].现代职业教育,2024(19):33-36.
- [10] 窦婷微.课程思政背景下影视录音技术课程改革反思[J].西部广播电视,2021,42(11):42-44.