

作品编号：TJJM20260416350473

2026 年（第十二届）全国大学生统计建模大
赛参赛作品
参赛作品

参赛学校：西安理工大学

论文题目：把脉中原粮仓：多源遥感驱动深度学习
的玉米产量预测研究

参赛队员：郭正阳 舒艺林 李垚

指导老师：郝孟丽

把脉中原粮仓：多源遥感驱动深度学习的玉米产量预测研究

摘要

保障国家粮食安全是新时代农业农村工作的首要任务，河南省作为全国粮食生产核心区，玉米播种面积和产量均位居全国前三，年产量约占全国总产量的10%，其稳产增产直接关系到国家粮食安全大局与区域农业高质量发展。传统产量预测依赖统计报表与田间抽样，存在数据滞后性强、空间覆盖有限、难以捕捉极端气象导致的非线性产量波动等短板，无法满足精准农业发展与粮食宏观调控的迫切需求，亟需开展构建高精度预测体系的研究。

本研究以河南省18个地级市为研究单元，基于2002-2024年GEE平台多源遥感与ERA5-Land气象再分析数据，结合China Crop Dataset农作物空间分布数据进行分区掩膜提取，经数据清洗、核心指标筛选后，系统对比Lasso、SVR、随机森林、XGBoost、LSTM、1D-CNN六种预测方法，明确各类算法的适用场景与局限。针对单一模型缺陷，创新性提出Detrending-LSTM-1D-CNN-XGBoost组合模型：通过线性去趋势化分离技术进步趋势产量与气象波动残差，利用LSTM结合时间注意力机制提取作物全生育期长程生长特征，通过1D-CNN捕捉短期极端气象突变信号，最终由XGBoost拟合残差重构产量。结果显示，该模型测试集 R^2 达0.8236，RMSE为380.83kg/ha，MAPE低至5.11%，较基准模型精度显著提升；消融实验验证各模块的协同作用，SHAP分析明确太阳辐射、植被指数为核心影响因子。

本研究通过多模型与多遥感技术的深度融合，构建“多源数据融合—多方法系统对比—组合模型优化预测”的完整技术框架，为河南省玉米生产动态监测、粮食产能核算、收购政策制定提供精准数据支撑。研究成果丰富农业统计方法体系，为全国其他粮食主产区的产量预测提供可借鉴的实践范式，助力筑牢国家粮食安全防线。

关键词：遥感数据；玉米产量预测；组合模型；消融实验；SHAP分析

目录

一、 引言	1
(一) 研究背景	1
(二) 研究内容	2
二、 文献综述	3
(一) 遥感技术在粮食产量估算中的应用研究	3
(二) 多方法预测模型在农业领域的研究进展	4
(三) 现有研究评述与本文切入点	4
三、 数据来源及预处理	5
(一) 研究区域概况	5
(二) 数据来源	6
(三) 核心指标筛选	7
(四) 数据清洗	8
(五) 数据集划分	8
四、 模型预测分析	9
(一) 线性收缩与特征选择回归(Lasso)	9
(二) 支持向量回归(SVR)	11
(三) 随机森林回归(RF)	13
(四) 极度梯度提升树(XGBoost)	16
(五) 长短期记忆网络模型(LSTM)	18
(六) 一维卷积神经网络模型(1D-CNN)	22
(七) 组合模型	24
五、 总结与建议	34
(一) 主要结论	34
(二) 政策建议	35
(三) 研究局限与展望	35
参考文献	37
附录	39
致谢	46

表格与插图清单

- 表 1 遥感数据指标体系表
- 表 2 数据指标说明表
- 表 3 Lasso 模型 2023 预测误差表
- 表 4 SVR 模型 2023 预测误差表
- 表 5 RF 模型 2023 预测误差表
- 表 6 XGBoost 模型 2023 预测误差表
- 表 7 LSTM 模型 2023 预测误差表
- 表 8 1D-CNN 模型 2023 预测误差表
- 表 9 XGBoost 参数寻优结果表
- 表 10 多模型指标对比表
- 表 11 消融实验结果表

- 图 1 河南省粮食产量研究词云图
- 图 2 整体研究路线图
- 图 3 研究区域地形图
- 图 4 核心指标三维空间相关性矩阵图
- 图 5 Lasso 求解流程图
- 图 6 Lasso 模型特征系数收缩路径图
- 图 7 SVR 求解过程图
- 图 8 SVR 测试集隔离带拟合图
- 图 9 RF 架构图
- 图 10 RF 核心指标重要性排序图
- 图 11 RF 测验集预测散点图
- 图 12 XGBoost 架构图
- 图 13 XGBoost 迭代学习与误差下降曲线图
- 图 14 LSTM 架构图
- 图 15 LSTM 训练损失下降图

图 16 LSTM2023 年预测对比图

图 17 1D-CNN 架构图

图 18 1D-CNN2023 年单产预测图

图 19 组合模型构建流程图

图 20 Detrending-LSTM-1D-CNN-XGBoost 架构图

图 21 XGBoost 参数寻优的过程图

图 22 测验集真实与预测单产散点拟合图

图 23 玉米单产的真实值与多模型预测值对比图

图 24 消融实验组合模型预测对比图

图 25 SHAP 特征重要性蜂群图

一、引言

（一）研究背景

河南省是我国重要粮食主产区，玉米作为其主要粮食作物之一，在保障国家粮食安全中发挥举足轻重的作用。据国家统计局统计，河南省玉米年产量占全国玉米总产量 10%左右。玉米生产稳定发展对区域农业经济与国家粮食安全保障具有重要意义。

传统粮食产量预测主要依赖统计年鉴数据和田间试验观测，数据时效性差、空间分辨率低，难以满足精准农业发展需求。随着遥感技术与云计算的快速发展，多源遥感数据在农业监测领域展现巨大应用潜力^[1]。如多光谱植被指数、气象再分析数据等，为监测提供新数据源。机器学习与深度学习方法快速发展为作物产量预测提供强大技术工具，线性回归、支持向量回归等方法在农业预测领域得到广泛应用。但单一方法难以全面捕捉遥感数据中的时空特征，如何建立多方法对比体系实现方法融合，成为提高产量预测精度重要研究方向。

利用 Python 词频统计绘制研究热点词云图如图 1 所示。词云图中，粮食产量、冬小麦、夏玉米、气候变化等关键词出现频次高，反映现今核心聚焦方向，即主要粮食作物；同时，机器学习、随机森林等方法类关键词高频出现，体现多模型结合、非线性建模已成为该领域主流趋势。领域热点梳理表明，针对河南省玉米产量预测的多源遥感和深度学习融合模型存在待提升空间，为本研究提供研究基础。



图 1 河南省粮食产量研究词云图

(二) 研究内容

本文以河南省为研究区域，玉米为研究对象，围绕多源遥感数据支撑下产量预测方法对比核心问题展开。研究路线图如图 2 所示，具体包括如下：

首先，进行多源数据预处理，整合遥感、统计、作物分布、气象数据，经缺失值处理，构建分析数据集。

其次，进行模型预测分析，搭建线性、传统机器学习、深度学习模型，评价各模型性能，明晰优劣。最后构建组合预测模型，并对组合模型预测结果进行验证评测，开展消融实验、SHAP 特征分析与多模型对比，验证组合模型有效性。

最后，总结应用建议，凝练研究创新与实践价值，为区域玉米估产、粮食安全管控提供技术与决策支撑。




图 2 整体研究路线图

二、文献综述

(一) 遥感技术在粮食产量估算中的应用研究

准确预测粮食产量对于保障国家粮食安全、制定农业政策具有重要意义。传统估算方法主要包括统计报表法、田间抽样调查法和农学模型估算法，能反映粮食生产状况，但存在数据获取周期长、空间分辨率低、人力成本高等问题，难以满足现实需求。

随着卫星遥感技术发展，基于遥感数据的作物产量估算方法成为研究热点。遥感数据能提供大面积、周期性、客观一致的观测信息，为粮食产量预测提供新

技术途径。在植被指数方面，归一化植被指数是最为广泛应用的指标之一，研究表明归一化植被指数与作物生物量、产量之间存在显著正相关关系。然而，在高生物量条件下植被指数增长缓慢，难以准确反映作物生长状况^[2]。研究者提出增强型植被指数，引入蓝光波段和土壤调节参数，有效解决增长缓慢问题，对高生物量作物具有更好敏感性^[3]。

生理参数上，叶面积指数和光合有效辐射吸收比例是表征作物冠层结构的核心参数，直接影响作物光合作用效率和干物质积累。蒸散发作为作物水分消耗直接指标，反映作物生长发育状况，也与产量形成密切相关。研究表明，作物生育期的累计蒸散发量与产量之间呈显著正相关，可作为产量预测有效指标^[4]。

随着谷歌地球引擎的应用，基于遥感大数据作物产量估算研究取得显著进展。不同方法在捕捉数据特征、处理非线性关系方面具有各自的优势和局限，如何选择合适的预测方法并实现方法融合，成为该领域研究热点。

（二）多方法预测模型在农业领域的研究进展

产量预测研究中，单一预测方法局限性逐渐显现。线性回归方法简单直观，但难以捕捉变量间的非线性关系；支持向量回归处理高维数据和小样本问题时表现良好，但对参数敏感且计算复杂度较高；BP 神经网络虽拟合能力强，但易陷入局部最优且泛化能力不足^[5]；随机森林方法能处理非线性问题并提供特征重要性排序，但难以捕捉时间序列的时序依赖性^[6]；长短期记忆网络能有效学习时间序列的长期依赖关系^[7]，但需大量训练数据且容易过拟合。

研究者开始探索方法融合与集成学习策略。集成学习通过组合多个模型预测结果，能有效降低预测方差、提高模型稳健性^[8]。Stacking 和 Boosting 是两种主要集成策略，其中 XGBoost 作为代表性算法，在各类预测中取得优异成绩。该算法通过梯度提升框架迭代优化损失函数，结合正则化技术有效防止过拟合，在农业产量预测领域展现良好应用潜力。

多方法对比研究在该领域具有重要价值。比较不同方法的预测性能，有助于理解各方法优势与局限。在不同数据条件和预测任务下，最优方法可能不同，因此建立完善的方法对比体系。

（三）现有研究评述与本文切入点

综上所述，遥感技术与机器学习方法在粮食产量预测中取得较好成果，但仍

存在以下不足：其一，多方法系统对比研究不足，局限于单一模型，缺乏不同模型间的对比；其二，组合方法的能力在不同预测场景的应用有待开发。其三，数据的深度挖掘受限，模型对作物动态生长特征的捕获不稳健^{[9][10]}。则以河南省为研究区域，构建“遥感数据—多方法对比—组合预测”技术框架，切入点在以下三个方面：

数据支撑：本文依托 GEE 云平台提取 2002–2024 年长时序、高时空分辨率的多源遥感特征。为深度学习模型捕捉河南省玉米生长的演变规律奠定数据基础。

多模型对比：本文通过对各类模型进行定量评估，明确各类算法在产量预测中的优势及局限。

组合模型：线性去趋势化、时间注意力机制与残差拟合的组合预测模型，通过剥离技术进步带来趋势增量，使模型能抓取产量的波动特征，实现长势时序规律与突变信号融合。

三、数据来源及预处理

（一）研究区域概况

河南省位于中国中东部、黄河中下游，地理坐标介于北纬 $31^{\circ}23'$ – $36^{\circ}22'$ 、东经 $110^{\circ}21'$ – $116^{\circ}39'$ 之间，下辖 18 个地级市。全省土地面积 16.7 万平方公里，年均气温 12–16℃，年均降水量 500–900 毫米，降水集中在 6–8 月。河南省是全国重要粮食生产基地，常年粮食播种面积约 1.6 亿亩，玉米是仅次于小麦的第二大粮食作物，年产量约 2500 万吨，研究区域地形图如图 3 所示。




图 3 研究区域地形图

(二) 数据来源

1. 多源卫星遥感数据

遥感数据通过 GoogleEarthEngine 云平台提取，时间跨度为 2002-2024 年，空间覆盖河南省 18 个地级市，时间分辨率为每 8 天一个时间步，通过农作物空间分布数据共提取玉米生长季 11 个时间步的遥感特征数据^[1]。遥感数据来源包括 MODIS 系列卫星产品和 ERA5-Land 再分析数据。如表 1 所示，具体包括：

表 1 遥感数据指标体系表

指标类别	指标名称	数据来源	空间分辨率
植被指数	NDVI_Mean,EVI_Mean	MODIS MYD13Q1	250m
冠层结构	LAI_Mean,FPAR_Mean	MODIS MYD15A2H	500m
蒸散发	Total_ET_mm	MODIS MOD16A2GF	500m
气象土壤	气温、降水、辐射、土壤水分	ERA5-Land	0.25°

2. 统计数据

统计数据包括河南省 18 个地级市 2002-2024 年的玉米播种面积和产量数据，来源于历年《河南统计年鉴》。提取各市历年玉米实际单产作为模型预测目标变量。

3. 玉米分布数据

玉米分布数据来源于科学数据银行发布的 China Crop Dataset 数据集，采用河南省农作物分布 1 栅格数据，地类编码为 6 的玉米种植区域图层，有助于更加精细的多源遥感与气象特征空间提取。

4. 地理边界数据

空间绘制河南省 18 个地级市行政区划矢量边界数据，获取自阿里云可视化地理信息开放平台。该平台数据集依托于国家基础地理信息中心的测绘数据，空间参考坐标系设定为标准 WGS84 坐标系统。利用该矢量边界数据为卫星遥感的市级分区裁剪和最终模型预测结果提供高精度地理坐标参照。

(三) 核心指标筛选

1. 数据说明及依据

原始卫星影像与气象数据维度高。为保证模型可解释性，最终锁定 9 个核心指标。如表 2 所示，这 9 个指标构成预测玉米产量的必要条件。

表 2 数据指标说明表

变量	指标名称	选取依据
X_1	叶面积指数 (LAI)	表征冠层光合有效面积，决定产量上限基数
X_2	归一化植被指数 (NDVI)	监测早期生长发育，与生物量积累高度正相关
X_3	增强型植被指数 (EVI)	修正大气与背景噪声，弥补高郁闭度下的信号饱和
X_4	地表温度 (LST)	探测冠层水分亏缺与热胁迫的敏感指示器
X_5	降水量 (Precipitation)	维持作物水分平衡的核心外部输入
X_6	土壤含水量 (SoilMoisture)	表征根系可利用水分，直接约束光合速率
X_7	蒸散量 (ET)	反映水分循环强度与作物生理代谢水平
X_8	日均气温 (Temperature)	决定发育历期，监测关键期极端高温危害
X_9	太阳辐射 (Radiation)	提供物质转化的能量来源，影响干物质积累

2. 相关性分析

为探究指标之间的相关性，计算 9 项核心指标的皮尔逊相关系数，并绘制

三维空间相关性矩阵图如图 4 所示。




图 4 核心指标三维空间相关性矩阵图

可知叶面积指数、归一化植被指数、等植被长势指标两两间呈显著正相关，反映此类表征作物变量存在多重共线性，而地表温度与日均气温强正相关、温度类指标与土壤含水量、降水量的显著负相关，呼应河南玉米种植区高温胁迫与水分约束，从统计层面验证本研究采用 1D-CNN 与 LSTM 开展非线性特征降维与融合必要性。

(四) 数据清洗

在数据采集与集成过程中，受卫星传感器校准、云层覆盖遮挡以及地面气象站瞬时通讯故障等因素影响，原始序列中存在少量缺失值，为保证数据连续性，进行数据清洗。

采用邻近值均值填充法。该方法假设在较短时间步长内，指标变化是线性平滑的，通过提取缺失点前后有效观测值进行加权平均。

设原始时序序列为 $X = \{x_1, x_2, \dots, x_t\}$ ，若在 t 时刻出现数据缺失，则其填充值 $\hat{x}_t$ 计算公式如下：

$$\hat{x}_t = \frac{x_{t-1} + x_{t+1}}{2} \quad \text{公式(1)}$$

其中， x_{t-1} 为缺失时刻前一句有效观测值， x_{t+1} 为后一句有效观测值。

(五) 数据集划分

为体现模型预测能力，对数据集进行划分。选取 2002 年至 2022 年历史数据

作为训练集进行模型参数学习与网络训练，占比约为 87%。将最新的 2023 年至 2024 年作为测验集验证方法的有效性，占比约为 13%。

四、模型预测分析

选取涵盖线性回归、树集成学习、深度神经网络等 6 种经典方法进行独立建模。通过分析这些单一模型在预测玉米产量方面的优缺点及数学原理，为后续组合模型构建提供理论依据。

（一）线性收缩与特征选择回归(Lasso)

1. 基本原理

Lasso 是一种在线性回归中引入 L_1 范数正则化的估计方法。通过惩罚绝对值过大的权重，使得冗余的共线性特征权重归零，提取核心估产指标。求解流程如图 5 所示。




图 5 Lasso 求解流程图

2. 求解步骤

①线性映射。接收输入向量 $X = \{x_1, x_2, \dots, x_n\}$ ，初始化权重矩阵 w 与偏置 b ，计算预期产量：

$$\hat{y}_i = w^T x_i + b \quad \text{公式(2)}$$

其中 x_i 为第 i 个样本输入特征向量， $\hat{y}_i$ 为第 i 个样本模型预期产量。

②构建损失函数。引入惩罚系数 α ，在均方误差之上叠加 L_1 范数：

$$J(w, b) = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^M |w_j| \quad \text{公式(3)}$$

其中, y_i 为第 i 个样本真实产量, $J(w,b)$ 为引入 L_1 范数正则化损失函数, M 为特征总维度数。

③坐标下降法寻优。对损失函数逐维求导并更新参数, 将不重要特征权重压缩为 0:

$$w_j^* = \text{sign}(w_j) \max(0, |w_j| - \alpha) \quad \text{公式(4)}$$

其中 $\text{sign}(w_j)$ 为符号函数, 取特征权重 w_j 正负号。

④输出最终产量。代入最优权重 w^* 得最终单产:

$$y_{\text{final}} = (w^*)^T x + b^* \quad \text{公式(5)}$$

其中, y_{final} 为保留非零权重后计算得最终单产预测值, b^* 为优化后最优偏置项。

3. 结果分析




图 6 Lasso 模型特征系数收缩路径图

图 6 的特征系数收缩路径显示, 随惩罚系数 α 增大, 降水、土壤水分和气温因与其他指标共线性较强, 权重快速收敛, 保留 NDVI、EVI 和太阳辐射等核心估产指标, 体现其特征降维、剔除冗余项优势。

表 3 Lasso 模型 2023 预测误差表

城市	绝对误差 (%)	城市	绝对误差 (%)
三门峡市	1.39%	洛阳市	8.22%
信阳市	2.28%	济源市	5.20%
南阳市	8.41%	漯河市	11.38%
周口市	5.36%	濮阳市	10.77%
商丘市	1.92%	焦作市	11.49%
安阳市	8.42%	许昌市	6.14%
平顶山市	16.64%	郑州市	15.79%
开封市	17.80%	驻马店市	0.66%
新乡市	6.53%	鹤壁市	13.91%

结合表 3 预测结果来看，驻马店、三门峡、商丘等 2023 年农业生产条件稳定的城市预测误差较小，但开封、平顶山、郑州等当年遭遇高温的城市误差较大，暴露了线性模型无法拟合作物生长中突发气象导致的非线性产量变化。

（二）支持向量回归(SVR)

1.基本原理

SVR 通过寻找一个宽度为 2ε 的隔离区间，可将区间内预测误差忽略，具备较强抗异常值干扰能力。对非线性问题，利用核函数将特征映射至高维空间寻找平滑超平面，如图 7 所示。




图 7 SVR 求解过程图

2.求解步骤

①高维映射。输入向量 x ，利用径向基核函数 $K(x_i, x)$ 将低维气象特征向高维特征空间进行非线性映射：

$$K(x_i, x) = \exp(-\gamma \|x_i - x\|^2) \quad \text{公式(6)}$$

其中 γ 为径向基核函数的超参数。

②构建目标优化问题。引入松弛变量 ξ_i, ξ_i^* ，允许部分样本越界，构建主优化目标：

$$\min_{w, b} \left\{ \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \right\} \quad \text{公式(7)}$$

$$\text{约束条件} \quad |y_i - w^T \phi(x_i) - b| \leq \varepsilon + \xi_i$$

其中 w 为权重参数， C 为惩罚参数，用于平衡模型复杂度， ε 为无惩罚隔离带宽度， $\phi(x_i)$ 为将输入特征映射到高维空间的函数。

③对偶求解支持向量。利用拉格朗日乘子法转化为对偶问题求解乘子 α_i, α_i^* ，非零乘子对应样本为支持向量：

$$\max_{\alpha, \alpha^*} \left\{ -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*) K(x_i, x_j) - \varepsilon \sum_{i=1}^n (\alpha_i + \alpha_i^*) + \sum_{i=1}^n y_i (\alpha_i - \alpha_i^*) \right\} \quad \text{公式(8)}$$

④输出最终产量。结合计算的支持向量，输出最终连续产量预测值：

$$\hat{y} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b^* \quad \text{公式(9)}$$

3.结果分析




图 8 SVR 测试集隔离带拟合图

表 4 SVR 模型 2023 预测误差表

城市	绝对误差 (%)	城市	绝对误差 (%)
三门峡市	1.27%	洛阳市	19.51%
信阳市	13.25%	济源市	8.76%
南阳市	19.37%	漯河市	1.41%
周口市	5.86%	濮阳市	12.71%
商丘市	0.71%	焦作市	6.18%
安阳市	0.59%	许昌市	0.22%
平顶山市	42.19%	郑州市	21.17%
开封市	14.78%	驻马店市	6.48%
新乡市	9.67%	鹤壁市	11.77%

图 8 SVR 测试集隔离带拟合图显示，仅有 5 个样本落入无惩罚隔离带内，对应许昌、安阳等 5 个城市，结合表 4 数据可知这些城市的绝对误差均低于 1.5%，体现损失函数高误差规避能力，能有效避免个别噪声样本干扰整体模型稳定性。但绝大多数样本落在带外，其中平顶山市误差高达 42.19%，洛阳、南阳、郑州等城市误差也均超过 19%，暴露 SVR 面对强时间依赖性农业序列数据无法提取玉米生育期特征演变的上下文时序特征。

（三）随机森林回归(RF)

1. 基本原理

RF 是一种基于自举汇聚的集成学习方法。并行构建成百上千棵各不相同的决策树，利用大数定律，有效捕捉指标的非线性机制，降低过拟合。如图 9 所示。




图 9 RF 架构图

2. 求解步骤

①自举重采样。从包含 n 个样本原始数据集 D 中有放回地抽取 n 个样本，生成 K 个子数据集 D_k ：

$$D_k = Bootstrap(D, n), (k = 1, 2, \dots, K) \quad \text{公式(10)}$$

②随机分裂建树。在每个子集上建立回归树，每次分裂随机选取 m 个特征。寻找最佳切分特征 j 和阈值 s ，使得切分后左右子树均方误差最小：

$$\min_{j,s} \left[\sum_{x_i \in R_{left}(j,s)} (y_i - \bar{y}_{left})^2 + \sum_{x_i \in R_{right}(j,s)} (y_i - \bar{y}_{right})^2 \right] \quad \text{公式(11)}$$

其中 $R_{left}(j,s)$ 为在选取特征 j 的阈值 s 进行切分后，划分出的左子节点区域， $R_{right}(j,s)$ 为切分后划分的右子节点区域， $\bar{y}_{left}$ 为落入左子区域中所有样本真实产量平均值， $\bar{y}_{right}$ 为落入右子区域中所有样本真实产量平均值。

③单树预测输出。将输入特征 x 输入第 k 棵树，数据落入某一叶子节点区域 R_m ，输出该区域历史样本均值 c_m ：

$$h_k(x) = \sum_{m=1}^{M_k} c_m I(x \in R_m) \quad \text{公式(12)}$$

其中 $I(\cdot)$ 为指示函数，当数据样本 x 落入区域 R_m 时取 1，否则取 0， M_k 为第 k 棵决策树中，最终划分的叶子节点总个数。

④预测产量。对 K 棵决策树输出结果求算术平均，作为最终评估产量：

$$\hat{y}_{RF} = \frac{1}{K} \sum_{k=1}^K h_k(x) \quad \text{公式(13)}$$

其中 $h_k(x)$ 为第 k 棵决策树对输入特征 x 预测输出结果， $\hat{y}_{RF}$ 为对 k 棵树的结果求平均后的最终产量。

3. 结果分析




图 10 RF 核心指标重要性排序图




图 11 RF 测验集预测散点图

图 10 RF 核心指标重要性排序图显示，太阳辐射、NDVI、气温是影响河南省玉米产量前三大因子，EVI、地表温度等也有不同程度贡献，体现随机森林能抓取多特征间非线性交互关系的优势。但图 11 的测验集预测散点图呈现显著趋中效应，绝大多数预测点偏离理想基准线。

表 5 RF 模型 2023 预测误差表

城市	绝对误差 (%)	城市	绝对误差 (%)
三门峡市	2.03%	洛阳市	23.63%
信阳市	6.42%	济源市	1.50%
南阳市	10.19%	漯河市	13.52%
周口市	6.93%	濮阳市	9.84%
商丘市	0.30%	焦作市	11.99%
安阳市	1.67%	许昌市	5.66%
平顶山市	33.04%	郑州市	27.98%
开封市	16.08%	驻马店市	1.59%
新乡市	5.01%	鹤壁市	9.99%

结合表 5 误差可知，济源、驻马店、商丘等产量接近历史均值的城市预测误差较小，而洛阳、郑州等高产城市误差超过偏大，暴露树模型缺乏外推预测能力缺陷，当 2023 年部分城市因农业技术进步使产量突破历史极值时，RF 只能输出历史高产年的平均值，低估技术发展带来的产量增量。

（四）极度梯度提升树(XGBoost)

1. 基本原理

XGBoost 采用串行机制。每一棵新增加的决策树都优化上一轮模型预测权重，如图 12 所示。通过二阶泰勒展开式地加速误差下降速度。




图 12 XGBoost 架构图

2. 求解步骤

①初始化基础产量。给定输入向量 $\mathbf{x}$ ，设定初始预期产量 $\hat{y}_i^{(0)}$ ：

$$\hat{y}_i^{(0)} = \frac{1}{n} \sum_{i=1}^n y_i \quad \text{公式(14)}$$

②计算误差一阶与二阶梯度。在第 t 轮迭代中，分别计算损失函数在上一轮预测值处一阶导数 g_i 与二阶导数 h_i ：

$$g_i = \partial_{\hat{y}_i^{(t-1)}} l(y_i, \hat{y}_i^{(t-1)}), h_i = \partial_{\hat{y}_i^{(t-1)}}^2 l(y_i, \hat{y}_i^{(t-1)}) \quad \text{公式(15)}$$

其中， $\hat{y}_i^{(t-1)}$ 为经过 $t-1$ 轮迭代后累加得最终预测单产， l 代表可导的损失函数。

③构建新树并优化叶子节点权重。建立第 t 棵树 $f_t(x)$ ，引入 L1/L2 正则化项防过拟合。通过二阶泰勒展开，直接推导使该树目标函数取得极小值的最优叶子节点分数 w_j^* ：

$$w_j^* = -\frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad \text{公式(16)}$$

其中， I_j 为第 j 个叶子节点上样本集合， λ 为正则化系数。

④模型更新与最终产量输出。将新树的输出乘以学习率 η 后累加于前一轮模型中，经过 K 轮迭代得最终预测单产：

$$\hat{y}_i^{(K)} = \hat{y}_i^{(K-1)} + \eta f_K(x_i) = \hat{y}_i^{(0)} + \eta \sum_{t=1}^K f_t(x_i) \quad \text{公式(17)}$$

其中， $f_K(x_i)$ 为第 K 棵新建立回归树输出结果。

3. 结果分析




图 13 XGBoost 迭代学习与误差下降曲线图

图 13 给出了 XGBoost 误差下降曲线图，由图所示，训练集误差随迭代轮数增加而下降，100 轮时降至约 430kg/ha，测验集误差在 30 轮左右收敛后基本保持平稳，两者差距逐渐拉大，体现 XGBoost 通过二阶泰勒展开优化带来的快速

收敛特性，也反映一定过拟合倾向。

表 6 XGBoost 模型 2023 预测误差表

城市	绝对误差 (%)	城市	绝对误差 (%)
三门峡市	3.10%	洛阳市	28.03%
信阳市	10.40%	济源市	0.14%
南阳市	9.31%	漯河市	10.36%
周口市	5.49%	濮阳市	8.69%
商丘市	2.04%	焦作市	13.27%
安阳市	1.70%	许昌市	8.79%
平顶山市	31.95%	郑州市	26.66%
开封市	13.19%	驻马店市	6.27%
新乡市	1.66%	鹤壁市	11.07%

结合表 6 误差,济源、新乡、安阳等农业生产条件稳定的城市预测误差较小,验证其在处理多维特征时较强非线性拟合精度。但洛阳、郑州、平顶山等城市误差较大,暴露其缺陷:一是继承树模型缺乏外推预测能力的问题;二是作为黑盒模型,无法抓取玉米生长期长势与气象因子演变时序逻辑,难以区分不同生育期相同环境条件对产量的差异化影响。

（五）长短期记忆网络模型(LSTM)

1. 基本原理

LSTM 是专门为处理时序特征的门控循环神经网络^[13]。通过细胞状态传递,能记住作物自播种来的长期生长积累特征,并利用门控机制筛选掉短期气象噪音,如图 14 所示。




图 14 LSTM 架构图

2. 求解步骤

①遗忘门过滤历史信息。接收动态时序矩阵 X ，在时刻 t ，结合上一时刻的隐藏状态 h_{t-1} 与当前特征输入 X_t ，输出一个 0 到 1 之间的概率矩阵，决定历史状态 C_{t-1} 中有哪些无用信息需被遗忘：

$$f_t = \sigma(W_f \cdot [h_{t-1}, X_t] + b_f) \quad \text{公式(18)}$$

其中， f_t 为概率矩阵。 σ 为 Sigmoid 激活函数。

②输入门提取新信息。计算当前 t 时刻有多少新信息被选中 i_t ，并生成当前细胞状态增量 $\tilde{C}_t$ ：

$$i_t = \sigma(W_i \cdot [h_{t-1}, X_t] + b_i) \quad \text{公式(19)}$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, X_t] + b_C) \quad \text{公式(20)}$$

其中， i_t 决定当前时刻新特征输入中，有多少关键信息被选中，并准备写入核心细胞状态中。 $\tanh$ 为双曲正切激活函数。

③细胞状态更新。结合遗忘门和输入门，舍弃旧状态中无用信息，融入新状态有益部分，完成生物量记忆通道 C_t 更新：

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad \text{公式(21)}$$

④输出门计算当前特征。基于更新后记忆细胞 C_t ，决定在 t 时刻对外输出特征表征 h_t ：

$$o_t = \sigma(W_o \cdot [h_{t-1}, X_t] + b_o) \quad \text{公式(22)}$$

$$h_t = o_t \odot \tanh(C_t) \quad \text{公式(23)}$$

其中， o_t 为更新后内部记忆细胞状态。

⑤最终产量预测。在最后一个生育期时间步 T 结束时，截取网络最终状态特征 h_T ，通过全连接层映射为最终连续单产值：

$$\hat{y} = W_{fc} \cdot h_T + b_{fc} \quad \text{公式(24)}$$

其中， W_f, W_i, W_C, W_o 分别对应遗忘门、输入门、细胞状态更新和输出门的可学习权重。 b_f, b_i, b_C, b_o 分别对应上述四个计算单元偏置项向量。 W_{fc} 为最终全连接映射层权重矩阵。 b_{fc} 为最终全连接层偏置项。

3. 结果分析




图 15 LSTM 训练损失下降图




图 16 LSTM2023 年预测对比图

图 15 LSTM 训练损失下降图显示，训练集损失在 100 轮左右快速收敛，验证集损失则在 100 轮后稳定，两者差距逐渐拉大，说明模型在训练集上拟合效果良好，但存在一定过拟合倾向，体现 LSTM 能敏锐捕捉作物生长长程状态记忆的优势。但图 16 预测对比图呈现显著平滑特性，LSTM 预测曲线波动幅度远小于真实产量，峰值和被过滤。

表 7 LSTM 模型 2023 预测误差表

城市	绝对误差(%)	城市	绝对误差(%)
三门峡市	0.54%	洛阳市	9.78%
信阳市	16.11%	济源市	1.98%
南阳市	3.66%	漯河市	16.84%
周口市	11.19%	濮阳市	7.65%
商丘市	6.08%	焦作市	7.85%
安阳市	7.89%	许昌市	12.93%
平顶山市	13.60%	郑州市	20.65%
开封市	13.34%	驻马店市	6.89%
新乡市	5.66%	鹤壁市	15.24%

表 7 数据显示，三门峡、济源等产量平稳的城市预测误差低，而信阳、漯河、郑州等当年遭遇极端气象灾害、产量波动剧烈的城市误差高，暴露 LSTM 倾向于提取平滑、连续的时序特征，无法准确捕捉突变导致的产量变化。

（六）一维卷积神经网络模型(1D-CNN)

1. 基本原理

1D-CNN 具备局部感受和权值共享特性。在时间轴上滑动的一维卷积核提取短时间窗内发生的气象突变，弥补 LSTM 对极值过滤的缺陷，如图 17 所示。




图 17 1D-CNN 架构图

2. 求解步骤

①特征矩阵转置输入。为适应卷积运算，将 2D 矩阵 X 沿着通道与时间轴转置为 $X^{in} = X^T \in R^{M \times T}$ 。

②滑动卷积提取特征。利用大小为 K 的卷积核矩阵 W_k 沿时间轴滑动步进，对短时窗口内的序列执行点积运算，捕捉突变的局部响应 c_t ：

$$c_t = \sum_{k=1}^K W_k x_{t+k-1} + b \quad \text{公式(25)}$$

其中，为 x_{t+k-1} 时间轴上滑动步进短时窗口内的序列输入。 b 为卷积运算偏置项。

③非线性激活。通过 ReLU 激活函数将响应图中的负值截断为零，过滤平缓底噪信号，保留突变信号 a_t ：

$$a_t = \text{ReLU}(c_t) = \max(0, c_t) \quad \text{公式(26)}$$

④最大池化降维。对特征序列进行降维，在池化内只取响应最强烈的一个值，压缩为向量 p ：

$$p = \max(a_1, a_2, \dots, a_{T-K+1}) \quad \text{公式(27)}$$

⑤展平与产量回归。将池化后的特征图展平，输入多全连接层进行最终产量回归：

$$\hat{y} = W_{out} \cdot Flatten(p) + b_{out} \quad \text{公式(28)}$$

其中， $Flatten(p)$ 为展平后特征序列输入。 W_{out}, b_{out} 为全连接层进行最终产量回归的权重矩阵与偏置项。

3. 结果分析




图 18 1D-CNN2023 年单产预测图

图 18 1D-CNN2023 年单产预测图显示，1D-CNN 的预测曲线对真实产量的突变响应更为敏锐，与 LSTM 平滑特性形成对比。在平顶山、郑州、漯河等真实产量出现骤降或骤升的关键节点，预测曲线能快速跟随变化，体现其擅长捕捉时间突变信号的优势，但易造成预测峰值过大。

表 8 1D-CNN 模型 2023 预测误差表

城市	绝对误差(%)	城市	绝对误差(%)
三门峡市	1.32%	洛阳市	12.00%
信阳市	6.75%	济源市	0.55%
南阳市	6.25%	漯河市	14.26%
周口市	10.59%	濮阳市	7.41%
商丘市	3.96%	焦作市	7.68%
安阳市	6.25%	许昌市	10.73%
平顶山市	17.28%	郑州市	15.38%
开封市	10.55%	驻马店市	1.22%
新乡市	6.72%	鹤壁市	11.17%

结合表 8 数据，济源、三门峡、驻马店等城市预测误差低，验证其对短期气象波动的良好捕捉能力。但南阳、周口等生育期较长、产量受前期生长状况影响较大的城市误差高，其缺陷：受限于卷积核局部感受野大小，模型缺乏全局记忆能力，无法理解玉米播种初期 NDVI 积累跨越数月最终转化为产量的关系，同时对局部信号的敏感也易导致预测值偏差。

（七）组合模型

单一模型都有着各自的优势，也存在一定缺陷。若将两种及以上单一模型相结合，搭建组合预测框架，能提升整体预测准确度，减少单一模型自身短板带来的预测误差。在对比分析各类单一模型基础上，结合模型自身特性与适用场景，选取 1D-CNN、LSTM 和 XGBoost 作为基础模型，引入趋势分解与注意力机制进行优化，构建组合预测模型。构建流程如图 19 所示。




图 19 组合模型构建流程图

该组合模型共包含五大模块，数据输入层、机理分解层、双通道深度网络层、特征融合与集成层及产量重构层，网络架构图如图 20 所示。




图 20 Detrending-LSTM-1D-CNN-XGBoost 架构图

1. 数据再处理

① 数据对齐与张量化

将 9 个核心指标分别映射至两个特征张量中：

目标标签向量(y):记为 $y \in R^N$ ，代表 N 个样本对应的地市级历史玉米单产。

遥感特征张量(X_{remote}):包含指标 X_1 (LAI)、 X_2 (NDVI)、 X_3 (EVI)、 X_4 (LST)，记为 $X_{remote} \in R^{N \times T \times D_r}$ 。

气象特征张量(X_{meteo}):包含指标 X_5 (降水)、 X_6 (土壤水分)、 X_7 (蒸散量)、 X_8 (气温)、 X_9 (辐射)，记为 $X_{meteo} \in R^{N \times T \times D_m}$ 。

此处， T 为时间序列的步长， D_r 和 D_m 分别代表遥感与气象的特征维度。

② 数据标准化处理

由于不同特征差异较大，为减小影响，防止网络中的梯度消失，对所有输入特征进行 **Z-score** 标准化：

$$X_{norm}^{(i,j,k)} = \frac{X^{(i,j,k)} - \mu_{j,k}}{\sigma_{j,k}} \quad \text{公式(29)}$$

其中， $X^{(i,j,k)}$ 为第 i 个样本在第 j 个时间步第 k 维原始特征值， $\mu_{j,k}$ 与 $\sigma_{j,k}$ 分别为训练集内该维度特征的样本均值与标准差。

2. 模型建立

① 线性回归去趋势化

农业系统中，作物实际单产通常由趋势产量与气象产量叠加构成。传统决策树模型缺乏线性外推能力，易低估技术进步带来的高产年份^[14]。因此进行产量机理分解：

$$Y_{actual} = Y_{trend} + Y_{residual} \quad \text{公式(30)}$$

Y_{actual} 为作物实际总单产。 Y_{trend} 为表征农业技术进步趋势产量。 $Y_{residual}$ 为剥离趋势后，由气象与环境导致波动的产量残差。

针对河南省 18 个地市，建立以时间为自变量的一元线性回归模型分解技术趋势：

$$Y_{trend}^{(c)} = \beta_1^{(c)} \cdot t + \beta_0^{(c)}, c \in \{1, 2, \dots, 18\} \quad \text{公式(31)}$$

其中， $Y_{trend}^{(c)}$ 第 c 个地市表征农业技术进步的趋势产量。 $\beta_1^{(c)}, \beta_0^{(c)}$ 为通过最小二乘法计算得出的对应地市回归斜率与截距。 t 为时间自变量。

在完成趋势化后，后端神经网络与集成模型仅需拟合非线性的残差 $Y_{residual}$ 。

② 双通道特征提取

在预测残差 $Y_{residual}$ 时，为同时捕捉作物的时序特征与极值特征，构建左右并行双通道神经网络。

LSTM 与时间注意力机制

遥感指数反映玉米生命周期内连续生理与冠层变化。长短期记忆网络引入可减小长距离带来的缺陷。

由于玉米在不同时期产量不同，在 LSTM 顶层引入时间注意力机制。通过自主学习序列权重的分配，聚焦于关键时间：

$$u_t = \tanh(W_w h_t + b_w) \quad \text{公式(32)}$$

$$\alpha_t = \frac{\exp(u_t^T v_w)}{\sum_{\tau=1}^T \exp(u_{\tau}^T v_w)} \quad \text{公式(33)}$$

其中， u_t 为经过非线性映射后得的第 t 个时间步的注意力隐藏表示。 w_w 为注意力机制层的权重矩阵。 b_w 为注意力的偏置项。 h_t 为 LSTM 提取的第 t 个时间步的隐藏状态特征。 v_w 为可学习参数，评估当前时间步特征重要程度。 α_t 为模型

的关键时间序列注意力权重分配系数。

最终，通过对 LSTM 进行注意力加权求和，提取全生育期的遥感特征向量 V_{remote} ：

$$V_{remote} = \sum_{t=1}^T \alpha_t h_t \quad \text{公式(34)}$$

气象通道：1D-CNN

采用一维卷积神经网络对气象张量进行滤波。对于输入的气象序列 X_{meteo} ，单层卷积操作数学表达式为：

$$C_i^{(m)} = \text{ReLU} \left(\sum_{j=0}^{K-1} X_{meteo, i+j} \cdot W_j^{(m)} + b^{(m)} \right) \quad \text{公式(35)}$$

其中， K 为卷积核大小，决定的时间跨度； $W_j^{(m)}$ 为第 m 个卷积核权重； $b^{(m)}$ 为第 m 个卷积核对应偏置项； $X_{meteo, i+j}$ 为落在当前短时计算窗口内气象序列输入值； $C_i^{(m)}$ 为第 m 个独立卷积核在时间步位置 i 处提取的局部特征值。

经过多层卷积提取后，接入自适应平均池化层，将特征图映射为表征 V_{meteo} 。

损失函数优化

在双通道网络反向传播训练阶段，为防止极值干扰梯度更新的全局方向，舍弃传统均方误差，采用更加 Huber 损失函数 $L_\delta(y, \hat{y})$ ：

$$L_\delta(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2; & \text{if } |y - \hat{y}| \leq \delta \\ \delta|y - \hat{y}| - \frac{1}{2}\delta^2; & \text{otherwise} \end{cases} \quad \text{公式(36)}$$

该损失函数引入参数 δ 作为阈值。当预测误差绝对值小于 δ 时，函数呈现 L_2 范数特性，确保在零点附近可导性，有助于模型在最优解附近收敛；当预测误差大于 δ 时，函数线性退化为 L_1 范数特性，梯度被约束，可有效避免梯度爆炸^{[15][14]}。

③ 异构特征与 XGBoost 拟合

获取由双通道网络提取的时空特征后，将其与表征地理空间差异编码矩阵 X_{static} 进行级联，构建新综合特征：

$$X_{fused} = [V_{remote} \oplus V_{meteo} \oplus X_{static}] \quad \text{公式(37)}$$

其中， X_{fused} 为级联后输入给 XGBoost 的综合特征。

随后，引入极度梯度提升树针对气象产量残差 $Y_{residual}$ 进行非线性映射。XGBoost 通过前向分布算法构建 K 棵回归树集合。设第 k 棵树的预测结构为 f_k ，其目标函数考虑预测误差，还引入树复杂度惩罚项 Ω ，以降低过拟合风险：

$$L(k) = \sum_{i=1}^N l(y_{res,i}, \hat{y}_{res,i}^{(k-1)} + f_k(X_{fused,i})) + \Omega(f_k) \quad \text{公式(38)}$$

为实现目标函数快速且精准优化，XGBoost 对其进行二阶泰勒展开近似：

$$L(k) \approx \sum_{i=1}^N \left[g_i f_k(X_{fused,i}) + \frac{1}{2} h_i f_k^2(X_{fused,i}) \right] + \gamma T + \frac{1}{2} \lambda |w|^2 \quad \text{公式(39)}$$

其中 $y_{res,i}$ 为真实单产残差， $\hat{y}_{res,i}^{(k-1)}$ 为前 $k-1$ 棵树累加预测残差； g_i 和 h_i 分别为损失函数关于预测值一阶偏导数和二阶偏导数； T 为叶子节点数， $|w|^2$ 为叶子权重 L_2 范数， γ 和 λ 为正则化惩罚系数； l 代表可导损失函数。

为 XGBoost 模型提取最优参数，采用网格进行搜索，范围和最优解如表 9 所示。

表 9 XGBoost 参数寻优结果表

超参数	搜索范围	最优值
学习率	[0.001,0.01,0.05,0.1]	0.01
最大深度	[3,5,7,9]	5
弱学习器数量	[100,200,300,400]	300
子样本比例	[0.6,0.7,0.8,0.9]	0.8

绘制参数寻优的过程图，如示图 21 所示。




图 21 XGBoost 参数寻优的过程图

可得不断调整三个参数的组合，拟合较最优参数点，模型在训练集上的误差持续下降，决定系数越高。寻优迭代完成时，图像最优点为最右点。

④ 产量重构与输出

经过前述模块处理，模型预测总结果 $\hat{Y}_{actual}$ ，由 XGBoost 预测的气象残差 $\hat{Y}_{residual}$ 与模型剥离的趋势产量 y_{trend} 相加得出：

$$\hat{Y}_{actual} = Y_{trend} + \hat{Y}_{residual} \quad \text{公式(40)}$$

3. 结果分析及指标评测

① 模型评价指标

为评价组合模型及其余对比模型在测验集上的预测效能，选取决定系数、均方根误差和平均绝对百分比误差三项回归评测指标。

决定系数(R^2)

R^2 衡量模型预测值对真实产量方差的反应程度，取值介于 [0,1] 之间。该值越接近 1，说明总体拟合优度越高。其数学计算公式为：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad \text{公式(41)}$$

其中， y_i 为第 i 个市真实单产， $\hat{y}_i$ 为模型最终预测单产（即 $\hat{Y}_{actual}$ ）， $\bar{y}$ 为真实单产样本均值， n 为测试集样本总数。

均方根误差(RMSE)

RMSE 衡量预测值与真实值之间偏差，单位与原数据保持一致。因在计算过程中进行平方操作，RMSE 对局部出现的显著估产偏差较为敏感。是反映模型稳定性指标：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad \text{公式(42)}$$

平均绝对百分比误差(MAPE)

MAPE 通过计算预测误差占真实值的相对百分比，消除产量数值影响，反映模型估产在决策中相对可靠程度。在国家级宏观农业估产与粮食安全评估任务中，

MAPE 是具有直观参考价值指标:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad \text{公式(43)}$$

② 组合模型估产表现

首先检验组合模型在测验集上的拟合表现。测试结果显示，取得较为优异的成绩：决定系数 R^2 高达 0.8236，均方根误差 RMSE 仅为 380.83kg/ha，MAPE 低至 5.11%。为直观展示预测值与真实单产的分布状态，绘制如图 22 所示的测验集真实与预测单产散点拟合图。




图 22 测验集真实与预测单产散点拟合图

可得在预测方面：全局拟合的高精度，绝大多数预测散点基本都收敛于 $y = x$ 的对角线两侧，数据离散程度小，证明组合模型在预测玉米产量波动方面具有较高精度；趋中效应的有效解决，散点依然保持较高的对角线贴合度。开始的趋势化模块成功抓住技术进步带来的效果，而中间的一维卷积又捕获气象灾害引发的产量骤降，有效解决趋中效应。

③ 多模型预测精度对比

为展现组合模型预测效果，将其与单一模型进行预测精度结果对比，对比结果如表 10 所示。

表 10 多模型指标对比表

方法	R^2	RMSE(kg/ha)	MAPE(%)
Lasso	0.5084	635.73	9.44
SVR	0.7331	468.45	6.12
RF	0.4648	663.33	9.74
XGBoost	0.5314	620.66	8.42
LSTM	0.6989	497.55	6.33
1D-CNN	0.7852	420.23	6.19
Detrending-LSTM-1D-CNN-XGBoost	0.8236	380.83	5.11

由表 10 可见：Lasso 作为线性基准模型， R^2 仅为 0.5084，是所有模型中最低的，表明产量与遥感特征之间存在显著非线性关系；传统机器学习模型中，SVR 的表现最优， R^2 为 0.7331，而 RF 和 XGBoost 的性能较差， R^2 分别仅为 0.4648 和 0.5314；深度学习模型中，LSTM 略优于多数传统方法，而 1D-CNN 性能进一步提升， R^2 达 0.7852。

组合模型取得最优效果， R^2 达 0.8236，较基准模型 Lasso 提升约 62.0%；同时，RMSE 由 635.73kg/ha 降至 380.83kg/ha，降低约 40.1%；MAPE 由 9.44% 降至 5.11%，降低约 45.9%。为更直观地展示各模型性能落差，绘制测验集上的预测对比图，如图 23 所示。




图 23 玉米单产的真实值与多模型预测值对比图

从图 23 可见分单一模型在测试集上出现明显精度滑坡，预测曲线与真实产量曲线偏差较大，尤其在濮阳等产量高值区和南阳等产量低值区，拟合效果明显不足。

相比之下，组合模型展现整体较优位置：其预测曲线与真实产量曲线贴合度最高，但也略有不足，在信阳、商丘等城市的预测误差略大。

④ 消融实验

为评估组合模型中各技术模块的贡献，进行消融实验，各组合模型在测验集上的评价指标数据如表 11 所示。

表 11 消融实验结果表

模型	R ²	RMSE(kg/ha)	MAPE(%)
LSTM-1D-CNN-XGBoost	0.6859	508.14	6.24
Detrending-1D-CNN-XGBoost	0.7168	482.54	7.09
Detrending-LSTM-XGBoost	0.4709	659.52	8.89
Detrending-LSTM-1D-CNN	0.7883	417.20	5.27
LSTM-1D-CNN	0.0257	894.99	12.41
Detrending-LSTM-1D-CNN-XGBoost	0.8236	380.83	5.11

绘制在 2023 年上的产量预测对比图，如图 24 所示。




图 24 消融实验组合模型预测对比图

消融实验表明，每个技术模块都对模型性能有所提升，全模块融合后模型达最优效果^[12]，仅保留部分模块的消融模型均存在不同程度的偏差，如基础模型 LSTM-1D-CNN 整体低估产量、Detrending-LSTM-XGBoost 在平顶山市等地出现预测波动。

⑤ SHAP 指标重要性分析

在复杂机器学习与深度学习模型中，其内部非线性网络虽然能极大提升产量预测精度，但也导致“黑盒”属性。为解决此问题，引入基于博弈论的 SHAP 方法，对模型进行深度分析^[16]。

SHAP 的数学理论与核心公式

估产模型中，可以将每一次产量预测视为一场合作博弈，将特征向量 X 中的每一个输入特征 X_j 视为参与博弈的玩家。对于给定的测试集地市样本，设其输入特征向量为 $X = [X_1, X_2, \dots, X_M]^T$ 。设模型的最终预测单产为 $\hat{y} = f(x)$ ，模型在所有历史样本上的期望预测单产为 $E[f(X)]$ 。

SHAP 方法构建一个加性特征归因模型，其核心公式调整如下^[17]：

$$f(X) = \phi_0 + \sum_{j=1}^M \phi_j \quad \text{公式(44)}$$

其中， $\phi_0 = E[f(X)]$ ：代表基准值，即不考虑特征时，河南省玉米全局平均预期单产；

为求解 ϕ_j ，设 $\{X_1, X_2, \dots, X_M\}$ 为所有特征的集合， S 为不包含特征 X_j 的任意特征子集。特征 X_j 的 ϕ_j 的计算公式为：

$$\phi_j = \sum_{S \subseteq F \setminus \{X_j\}} \frac{|S|!(M-|S|-1)!}{M!} [f_x(S \cup \{X_j\}) - f_x(S)] \quad \text{公式(45)}$$

其中， $f_x(S)$ ：表示当模型仅输入子集 S 中的特征，对当前样本的预期产出 $f_x(S \cup \{X_j\}) - f_x(S)$ 为农业特征 X_j 加入子集 S 后，所引发的单产变化量。

SHAP 蜂群图分析

通过 SHAP 特征重要性蜂群图揭示各关键指标的贡献分布规律，结果如图 25 所示。




图 25 SHAP 特征重要性蜂群图

由结果可见，太阳辐射是玉米产量预测首要影响因子，整体贡献度最高，对产量呈显著双向作用：辐射过高时 SHAP 值为负，抑制产量；辐射适中或偏低时呈正向作用，利于增产。夏季强辐射常伴随高温热胁迫，模型精准捕捉此环境限制因素。

EVI、NDVI、FPAR 等植被长势指标为产量核心正向驱动因素，综合影响仅次于太阳辐射。三者变化规律一致，印证植被指数可表征作物长势与光合潜力，是决定产量的关键要素。

降水、土壤湿度、气温等气象水分指标存在双向效应：过量降水易引发涝渍、作物倒伏，抑制产量；适宜偏高的土壤湿度可保障作物正常光合；气温在高温胁迫阈值内升高，适配玉米喜温特性，利于增产。

LAI、ET 为次要调节因子，直接驱动作用较弱；其中 LAI 过高会导致田间郁闭、通风透光性下降，对玉米生长产生消极影响。

五、总结与建议

（一）主要结论

本研究以河南省 18 个地级市为研究区域，基于 2002-2024 年多源遥感与气象数据，构建 Detrending-LSTM-1D-CNN-XGBoost 组合预测模型，通过多模型

对比、消融实验、相关性与 SHAP 可解释性分析，系统探究河南省玉米产量预测方法优化，结论如下：

1. 组合模型预测精度优于单一模型

在六种对比模型中，融合模型表现最优，测试集决定系数 R^2 达 0.8236，均方根误差 RMSE 为 380.83kg/ha，平均绝对百分比误差 MAPE 低至 5.11%；较线性基准模型 Lasso， R^2 提升 62.0%，RMSE 降低 40.1%，MAPE 降低 45.9%。

2. 模型各核心模块具备不可替代的协同作用

消融实验验证各模块的必要性，缺失任一模块均会导致模型精度下降；其中去趋势化模块有效捕捉农业技术进步带来的产量增量，双通道特征提取实现长势时序规律与气象突变信号的互补融合。

3. 关键因子对产量的影响具有明确双向机制

SHAP 分析显示，太阳辐射为首要影响因子，高辐射易抑制产量，适中辐射则正向驱动产量形成；EVI、NDVI、FPAR 是核心驱动因子，植被长势越好产量越高；降水、土壤湿度、气温等因子为复杂双向影响，LAI 与蒸散量为次要调节因子，高 LAI 易产生负向影响。

（二）政策建议

基于结果与实验分析，提出以下政策建议：

1. 构建遥感动态监测体系，推进精准估产业务化

将多源遥感融合预测模型纳入河南省农业监测日常工作，依托 GEE 云平台实现市级尺度玉米产量实时、快速预测，为粮食产能核算、收购政策制定、市场调控提供精准数据支撑。

2. 聚焦关键生育期管理，提升作物长势水平

以 LAI、EVI、NDVI 等遥感长势指标为指导，重点加强玉米拔节期至吐丝期的田间管理，通过科学施肥、合理密植优化冠层结构，避免 LAI 过高导致田间郁闭，充分发挥植被长势对产量的正向驱动作用。

（三）研究局限与展望

1. 研究局限

在河南省玉米产量预测方面取得一定成果，但仍存在以下局限：

①空间尺度与分辨率受限：以地级市为单元，未细化至田块尺度，同时遥感

数据空间分辨率有限，对小块耕地、分散种植区监测精度不足。

②未考虑品种与管理措施差异：未区分不同玉米品种的生理特性、种植模式与田间管理措施差异，模型普适性有待进一步验证。

③未融入未来气候情景：仅基于历史数据开展预测，未结合气候模式模拟未来气候变化情景，无法评估气候变暖对河南省玉米产量的长期影响。

2. 未来展望

对上述研究局限，可从以下方向开展深化研究：

①细化模型输入维度：融入玉米品种、种植制度、田间管理等农业管理数据，构建分品种、分区域的精细化预测模型，增强模型实用性。

②拓展模型应用功能：将产量预测与水资源利用、碳排放、经济效益相结合，构建多目标优化决策模型，服务河南省农业绿色高质量发展。

参考文献

- [1] 严海军, 卓越, 李茂娜, 等。基于机器学习和无人机多光谱遥感的苜蓿产量预测[J]. 农业工程学报, 2022,38(11):64-71.
- [2] 陈拉, 黄敬峰, 王秀珍。不同传感器的模拟植被指数对水稻叶面积指数的估测精度和敏感性分析[J]. 遥感学报, 2008,12(1):143-151.
- [3] 张宏鸣, 刘雯, 韩文霆, 等。基于梯度提升树算法的夏玉米叶面积指数反演[J]. 农业机械学报, 2019,50(5):251-259.
- [4] 康迪, 李斐, 等。基于多源数据融合的小麦产量估测模型优化及关键因子比较[J]. 麦类作物学报, 2024,44(1):115-126.
- [5] 计雪伟, 霍兴赢, 薛端, 伍晓平。基于神经网络的农作物产量预测方法[J]. 南方农机, 2022,53(3):36-39;宗宸生, 郑焕霞, 王林山。改进粒子群优化 BP 神经网络粮食产量预测模型[J]. 计算机系统应用, 2018,27(12):204-209.
- [6] 孙少杰, 吴门新, 庄立伟, 等。基于 CNN 卷积神经网络和 BP 神经网络的冬小麦县级产量预测[J]. 农业工程学报, 2022,38(11):151-160.
- [7] 罗浩田, 杨贵军, 等。基于混合神经网络的冬小麦产量预测方法研究[J]. 农业机械学报, 2023,54(6):228-236.
- [8] 张耀其, 李建平, 陈明, 等。基于气象因素的玉米单产堆栈集成学习建模与预测[J]. 中国农业科学, 2024,57(4):765-780.
- [9] 李长春, 杜涌泉, 马潇潇, 等。基于多源遥感和机器学习的玉米最佳估产时段研究[J]. 农业现代化研究, 2025,46(4):811-820.
- [10] 李志强, 王鹏新, 张泽, 等。基于时序影像及不同模型的玉米早期估产研究[J]. 光谱学与光谱分析, 2023,43(8):2627-2636.
- [11] 王汇涵, 张泽, 康孝岩, 等。基于 Sentinel-2A 的棉花种植面积提取及产量预测[J]. 农业工程学报, 2022,38(9):205-214.
- [12] 裴杰, 谭绍锋, 郭韩, 等。结合 GWRFR 和作物物候信息的玉米产量早期预测[J]. 农业工程学报, 2024,40(1):153-161.
- [13] Cao J, Li M, Wang X. BO-CNN-BiLSTM deep learning model integrating multisource remote sensing data for improving winter wheat yield estimation[J]. FieldCropsResearch, 2026,337,110263.

Frontiers in Plant Science, 2024, 15: 1500499.

- [14] Tian H, Wang P, Zhang Q. An LSTM neural network for improving wheat yield estimates by integrating remote sensing data and meteorological data in the Guanzhong Plain, PR China[J]. Agricultural and Forest Meteorology, 2021, 310: 108629.
- [15] Shi J, Chen W, Yuan R, et al. Global de-trending significantly improves the accuracy of XGBoost-based county-level maize and soybean yield prediction in the Midwestern United States[J]. Remote Sensing, 2024, 16(9): 1540.
- [16] Han L, Yang G, Feng H. Analysis of corn yield prediction potential at various growth phases using a process-based model and deep learning[J]. Computers and Electronics in Agriculture, 2023, 205: 107625.
- [17] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]//Advances in Neural Information Processing Systems, 2017: 4765-4774.

附录

核心代码

缺失值线性插值与张量构建

```
1. import pandas as pd
2. import numpy as np
3. df=pd.read_csv('Henan_Corn_HighPrecision_2002_2024.csv')
4. feature_cols=['NDVI','EVI','LAI','FPAR','蒸散发 ET(mm)','平均
气温(℃)','8 天累计降水(mm)','8 天累计辐射(MJ)','土壤水分
(m3/m3)']
5. df[feature_cols]=df.groupby(['城市','年份
'])[feature_cols].transform(lambda
x:x.interpolate(method='linear',limit_direction='both'))
6. df_yield=pd.read_csv('河南省各市玉米产量(2002-
2024).csv').melt(id_vars=['地区'],var_name='年份',value_name='产量')
7. df_area=pd.read_csv('河南省各市玉米播种面积(2002-
2024).csv').melt(id_vars=['地区'],var_name='年份',value_name='播种面
积')
8. df_yield['年份'],df_area['年份']=df_yield['年份
'].astype(int),df_area['年份'].astype(int)
9. df_target=pd.merge(df_yield,df_area,on=['地区','年份'])
10. df_target['实际单产(Y)']=(df_target['产量']/df_target['播种面积
'])*10000
11. df_target.rename(columns={'地区':'城市'},inplace=True)
12. df_features=df.sort_values(by=['城市','年份','时间步(Step)'])
13. unique_samples=df_features[['城市','年份
']].drop_duplicates().reset_index(drop=True)
14. N,T=len(unique_samples),11
```

```

15.
X_remote,X_meteo,Y=np.zeros((N,T,4)),np.zeros((N,T,5)),np.zeros((N
,))
16. for i,row in unique_samples.iterrows():
17.     c,y=row['城市'],row['年份']
18.     sd=df_features[(df_features['城市']==c)&(df_features['年份']==y)]
19.     X_remote[i,:,:]=sd[['NDVI','EVI','LAI','FPAR']].values
20.     X_meteo[i,:,:]=sd[['蒸散发 ET(mm)','平均气温(℃)','8 天累
计降水(mm)','8 天累计辐射(MJ)','土壤水分(m3/m3)']].values
21.     tv=df_target[(df_target['城市']==c)&(df_target['年份']==y)][['实
际单产(Y)']].values
22.     Y[i]=tv[0] if len(tv)>0 else np.nan
23. valid_idx=~np.isnan(Y)
24.
X_remote,X_meteo,Y=X_remote[valid_idx],X_meteo[valid_idx],Y[valid_idx]

```

Lasso, SVR, RF, XGBoost 模型

```

1. from sklearn.linear_model import Lasso
2. from sklearn.svm import SVR
3. from sklearn.ensemble import RandomForestRegressor
4. import xgboost as xgb
5. # 数据特征在时间轴上求均值压缩为二维以适应传统 ML 模型
6. X_ml=np.mean(np.concatenate([X_rem_s,X_met_s],axis=-1),axis=1)
7. # 1. Lasso 回归 (提取 9 维特征)
8. lasso_model=Lasso(alpha=0.1,random_state=42)
9. lasso_model.fit(X_ml[train_idx],Y[train_idx])
10. lasso_pred=lasso_model.predict(X_ml)
11. # 2. 支持向量回归(SVR)
12. svr_model=SVR(kernel='rbf',C=10,gamma='scale')

```

```

13. svr_model.fit(X_ml[train_idx], Y_train_scaled)
14. svr_pred=scaler_y.inverse_transform(svr_model.predict(X_ml).reshape(-
1,1)).flatten()
15. # 3. 随机森林(RF)
16.
rf_model=RandomForestRegressor(n_estimators=100,max_depth=6,min_samples_
split=4,random_state=42)
17. rf_model.fit(X_ml[train_idx], Y[train_idx])
18. rf_pred=rf_model.predict(X_ml)
19. # 4. XGBoost
20.
xgb_base=xgb.XGBRegressor(n_estimators=100,max_depth=4,learning_rate=0.0
5,random_state=42,eval_metric="rmse")
21. xgb_base.fit(X_ml[train_idx], Y[train_idx])
22. xgb_pred=xgb_base.predict(X_ml)

```

Detrending-LSTM-1D-CNN-XGBoost 组合模型

```

1. import torch
2. import torch.nn as nn
3. from sklearn.linear_model import LinearRegression
4. import xgboost as xgb
5. # 1. 线性去趋势化(Detrending)
6. Y_trend, Y_residual=np.zeros_like(Y), np.zeros_like(Y)
7. for city in sample_info['城市'].unique():
8.     c_mask=sample_info['城市']==city
9.     c_train_mask=c_mask&(sample_info['年份']<=2021)
10.    yrs_all=sample_info.loc[c_mask, '年份'].values.reshape(-1,1)
11.    yrs_train=sample_info.loc[c_train_mask, '年份'].values.reshape(-
1,1)

```

```

12.     y_train_city=Y[c_train_mask]
13.     if len(yrs_train)>0:
14.         lr=LinearRegression().fit(yrs_train,y_train_city)
15.         Y_trend[c_mask]=lr.predict(yrs_all)
16.         Y_residual[c_mask]=Y[c_mask]-Y_trend[c_mask]
17. # 2. 深度时空特征提取器(LSTM + 1D-CNN)
18. class MD_STFF_Extractor(nn.Module):
19.     def __init__(self):
20.         super().__init__()
21.
22. self.lstm=nn.LSTM(input_size=4,hidden_size=64,batch_first=True)
23.
24. self.attention=nn.Sequential(nn.Linear(64,64),nn.Tanh(),nn.Linear(64,1))
25.
26. self.cnn1d=nn.Sequential(nn.Conv1d(5,32,kernel_size=3,padding=1),nn.ReLU(),nn.MaxPool1d(2),nn.Conv1d(32,64,kernel_size=3,padding=1),nn.ReLU(),nn.AdaptiveAvgPool1d(1))
27.
28.     def forward(self,x_rem,x_met):
29.         lstm_out,_=self.lstm(x_rem)
30.         attn_weights=torch.softmax(self.attention(lstm_out),dim=1)
31.         feat_rem=torch.sum(attn_weights*lstm_out,dim=1)
32.         feat_met=self.cnn1d(x_met.transpose(1,2)).squeeze(-1)
33.         return torch.cat([feat_rem,feat_met],dim=1)
34. # 3. 提取特征并利用 XGBoost 拟合气象残差
35. md_extractor=MD_STFF_Extractor().to(device)
36. md_extractor.eval()
37. with torch.no_grad():
38.     X_r_tensor=torch.FloatTensor(X_rem_s).to(device)
39.     X_m_tensor=torch.FloatTensor(X_met_s).to(device)

```

```

36.
fused_features=md_extractor(X_r_tensor,X_m_tensor).cpu().numpy()
37. xgb_head=xgb.XGBRegressor(n_estimators=100,random_state=42)
38. xgb_head.fit(fused_features[train_idx],Y_residual[train_idx])
39. pred_residuals=xgb_head.predict(fused_features)
40. # 4. 产量重构
41. final_predictions=Y_trend+pred_residuals

```

LSTM 和 1D-CNN 模型

```

1. import torch.nn as nn
2. # 1. 纯 LSTM 基准模型
3. class PureLSTM(nn.Module):
4.     def __init__(self,input_dim=9,hidden_dim=64):
5.         super().__init__()
6.         self.lstm=nn.LSTM(input_dim,hidden_dim,batch_first=True)
7.         self.fc=nn.Linear(hidden_dim,1)
8.     def forward(self,x):
9.         out,_=self.lstm(x)
10.        return self.fc(out[:,-1,:])
11. # 2. 纯 1D-CNN 基准模型
12. class PureCNN(nn.Module):
13.     def __init__(self,in_channels=9):
14.         super().__init__()
15.
16.        self.conv=nn.Sequential(nn.Conv1d(in_channels,32,kernel_size=3,padding=1),
17.        nn.ReLU(),nn.MaxPool1d(2),nn.Conv1d(32,64,kernel_size=3,padding=1),n
18.        n.ReLU(),nn.AdaptiveAvgPool1d(1))
19.        self.fc=nn.Linear(64,1)
20.    def forward(self,x):

```

```

18.         feat=self.conv(x.transpose(1,2)).squeeze(-1)
19.         return self.fc(feat)

```

深度学习网络训练与核心评估指标计算

```

1. import torch.optim as optim
2. from sklearn.metrics import r2_score, mean_squared_error
3. import numpy as np
4. # 1. 深度学习通用训练函数(自适应保存最优验证集权重)
5. def train_dl_model(model, X_tr, Y_tr, X_val, Y_val, epochs=500):
6.
optimizer=optim.Adam(model.parameters(), lr=0.005, weight_decay=1e-4)
7.     criterion=nn.MSELoss()
8.     best_val_loss, best_wts=float('inf'), None
9.     for epoch in range(epochs):
10.         model.train()
11.         optimizer.zero_grad()
12.         loss=criterion(model(X_tr), Y_tr)
13.         loss.backward()
14.         optimizer.step()
15.         model.eval()
16.         with torch.no_grad():
17.             val_loss=criterion(model(X_val), Y_val).item()
18.             if val_loss<best_val_loss:
19.                 best_val_loss, best_wts=val_loss, model.state_dict()
20.         model.load_state_dict(best_wts)
21.     return model
22. # 2. 模型多维评价指标计算函数
23. def evaluate_model(y_true, y_pred):
24.     r2=r2_score(y_true, y_pred)

```

```
25.     rmse=np.sqrt(mean_squared_error(y_true,y_pred))
26.     mape=np.mean(np.abs((y_true-y_pred)/y_true))*100
27.     return r2,rmse,mape
```

统计软件、开发环境与工具链补充说明

本研究的实现涉及跨平台的庞大工作流，涵盖了卫星遥感大数据的获取、多维时间序列的清洗、深度学习网络的搭建以及树模型的集成。具体使用的软件及工具链规范如下：

遥感大数据获取与空间聚合软件

Google Earth Engine (GEE): 作为云端遥感计算引擎，主要用于 MODIS 影像集合与 ERA5-Land 气象张量的在线处理。利用其内置的 JavaScript API 编写空间掩膜代码，实现按河南省地市级行政边界及玉米分布栅格的精准裁剪与像素均值聚合。

数据清洗与统计分析软件

Python (Pandas 与 NumPy): 用于构建数据清洗流。特别是在处理卫星传感器因云层遮挡导致的缺失值时，利用 Pandas 的 `interpolate` 方法实现了基于时间步长的精确线性插值，填平了时序数据的断点。

SciPy 与 Scikit-learn: 用于执行皮尔逊相关性分析，并实现特征数据的零均值标准化，消除量纲差异，保障深度学习梯度的平稳传播。

核心建模与可视化软件

PyTorch 框架: 作为构建 LSTM 和 1D-CNN 双通道深度学习架构的底层计算图框架，负责神经网络的反向传播与参数更新，模型采用 Adam 优化器，并运行于 CUDA 硬件加速环境。

XGBoost 库: 独立调用其 Python 接口实现极端梯度提升树模型，运用其二阶泰勒展开特性对深度学习输出的残差进行非线性拟合。

Matplotlib 与 Seaborn: 用于生成正文中呈现的所有高维相关性热力图、模型误差下降曲线、SHAP 特征重要性蜂群图及产量拟合散点图。

致谢

在本次建模的过程中，首先感谢指导老师的悉心指导。从建模思路的梳理、数据处理方法的选择，到模型的优化与论文细节的打磨，老师都给予了耐心的点拨和关键的建议，帮我们及时理清方向、解决了不少难题。

同时，也感谢一起参与建模的同学。大家在遇到瓶颈时互相讨论、分工协作，一起调试模型、核对结果，在互帮互助中顺利完成了本次建模工作。

2026 年 5 月 12 日